进化与群智计算

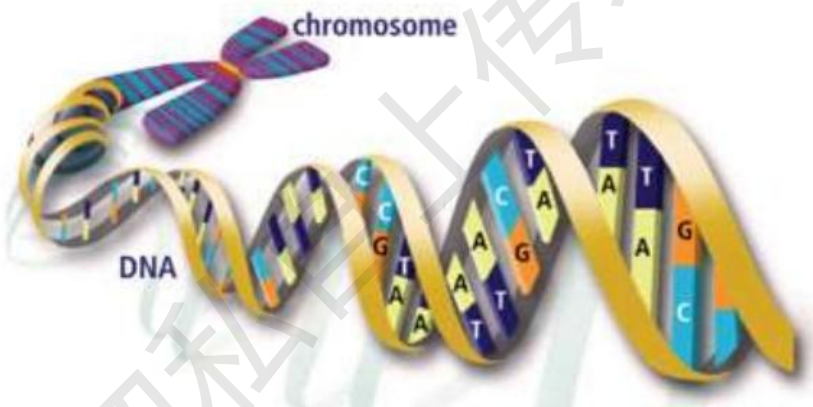

Chromosome 1	11011001001101 10

Chromosome 2	11011110000111 10

马冲
计算机与人工智能学院

请勿私自上传本课件

进化计算与群智能

1.1 智能计算概述

1.2 粒子群算法

1.3 遗传算法

请勿私自上传本课件

1.1 智能计算概述

■ 背景

智能计算

- 模糊逻辑
- 遗传算法
- 模拟退火算法
- 人工神经网络
- DNA计算
- 禁忌搜索算法
- 免疫算法
- 膜计算
- 量子计算
- ……

群智能算法

- 粒子群算法
- 蚁群算法
- 蜂群算法
- 鱼群算法
- 细菌群算法
- ……

请勿私自上传本课件

1.1 智能计算概述

■ 背景

□ 智能计算的主要组成部分

类别	代表算法	灵感来源	典型应用
1. 进化计算（Evolutionary Computation）或称 **进化算法**	遗传算法（GA）、遗传编程（GP）、差分进化（DE）	达尔文生物进化论（选择、交叉、变异）	函数优化、自动设计、调度问题
2. 群智能算法（Swarm Intelligence）	**粒子群优化**（PSO）、**蚁群优化**（ACO）、人工蜂群（ABC）	昆虫/鸟群/鱼群等群体协作行为	路径规划、组合优化、神经网络训练
3. 人工神经网络（Artificial Neural Networks, ANN）	感知机、BP 网络、CNN、RNN、Transformer	人脑神经元结构与信息处理机制	模式识别、图像处理、自然语言处理
4. 模糊系统（Fuzzy Systems）	模糊逻辑控制器、模糊推理	人类语言与模糊推理（如“有点热”）	控制系统、决策支持
5. 免疫计算、人工生命等	人工免疫算法、细胞自动机	生物免疫机制、生命演化	异常检测、自适应系统

请勿私自上传本课件

1.1 智能计算概述

- **代表性方法：进化算法**(evolutionary algorithms，EA)是基于自然选择和自然遗传等生物进化机制的一种搜索算法。
  - ✓ 生物进化是通过繁殖、变异、竞争和选择实现的；而进化算法则主要通过**选择、重组和变异**这三种操作实现优化问题的求解。
  - ✓ 进化算法是一个“算法簇”，包括遗传算法(Genetic Algorithm, GA)、遗传规划、进化策略和进化规划等。
  - ✓ 进化算法可广泛应用于组合优化、**机器学习**、自适应控制、规划设计和人工生命等领域。

进化计算是通过模拟自然界中生物进化机制进行搜索的一种算法。本章学习的重点是GA进化算法，即遗传算法

请勿私自上传本课件

1.1 智能计算概述

■ **代表性方法：群智能算法**

我们经常能够看到成群的鸟、鱼、蚂蚁、蜜蜂或者浮游生物。这些生物的聚集行为有利于它们觅食和逃避捕食者。它们的群落动辄以十、百、千甚至万计，并且经常不存在一个统一的指挥者。它们是如何完成聚集、移动、交流这些群体协作功能呢?

1.1 智能计算概述

■ 代表性方法：群智能算法

- 受动物群体智能启发的算法。
- 由简单个体组成的群落与环境以及个体之间的互动行为。
- 常见算法包括粒子群优化算法、蚁群算法、蜂群算法、……

从不同的群研究得到不同的应用。最引人注目的是对鸟群和蚁群的研究。其中粒子群优化方法就是模拟鸟群的社会行为发展而来。

请勿自上传本课件

1.1 智能计算概述

■ 智能计算 vs 传统计算

特性	传统计算	智能计算
问题类型	确定性、结构化、可解析	复杂、不确定、非线性、NP-hard
求解方式	精确算法、数学推导	启发式、近似、自适应搜索
是否保证最优解	是（如线性规划）	通常为**近似最优**或**满意解**
鲁棒性	对模型假设敏感	对噪声、缺失数据鲁棒

请勿私自上传本课件

1.1 智能计算概述

■ 应用领域

(1) 组合优化　　(2) 函数优化
(3) 自动控制　　(4) 生产调度
(5) 图像处理　　(6) 机器学习
(7) 人工生命　　(8) 数据挖掘

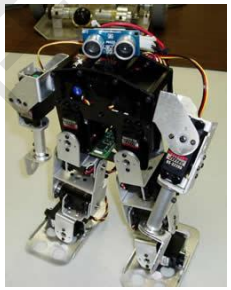

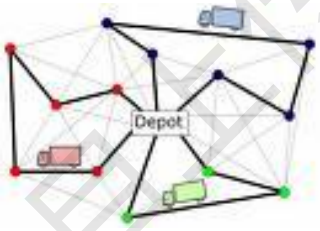

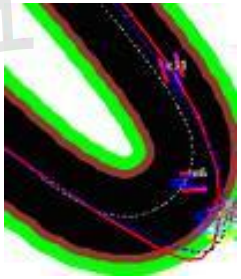

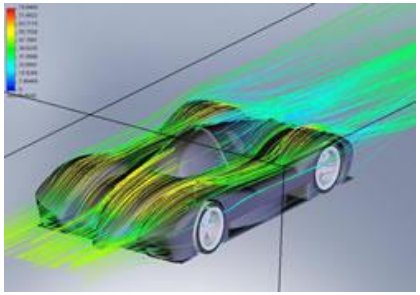

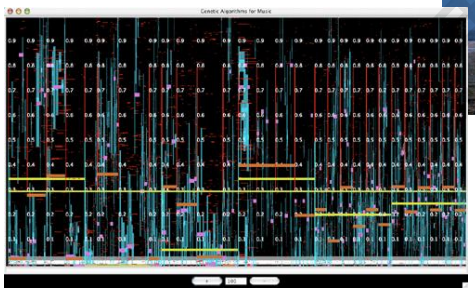

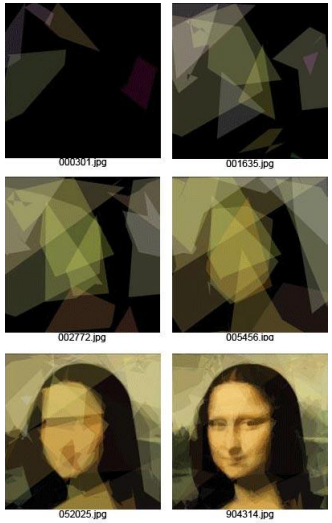

进化计算与群智能

1.1 智能计算概述

1.2 粒子群算法

1.3 遗传算法

请勿私自上传本课件

1.2 粒子群算法

■ PSO算法

粒子群优化（Particle Swarm Optimization, PSO）算法是由美国普渡大学的Kennedy和Eberhart于1995年提出，它的基本概念源于对鸟群觅食行为的研究。

粒子群优化算法的基本思想是通过群体中个体之间的协作和信息共享来寻找最优解。

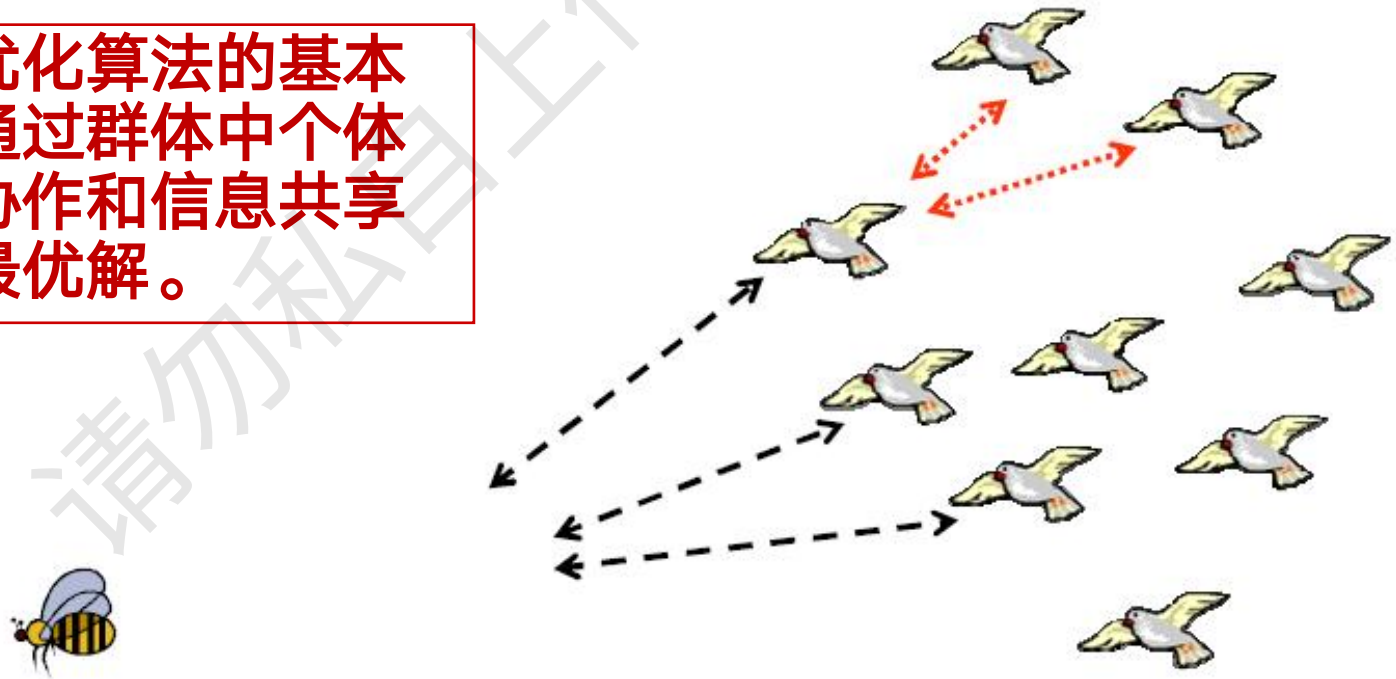

请勿私自上传本课件

1.2 粒子群算法

- 鸟被抽象为没有质量和体积的微粒(点)，并延伸到N维空间，粒子I 在N维空间的位置表示为矢量Xi = (x1，x2，…，xN)，飞行速度表示为矢量Vi = (v1，v2，…，vN)．每个粒子都有一个由目标函数决定的适应值(fitness value)，并且知道自己到目前为止发现的最好位置(个体极值:pbest)和现在的位置Xi．这个可以看作是粒子自己的飞行经验。
- 除此之外，每个粒子还知道到目前为止整个群体中所有粒子发现的最好位置(全局极值:gbest)(gbest是pbest中的最好值)．这个可以看作是粒子同伴的经验．粒子就是通过自己的经验和同伴中最好的经验来决定下一步的运动。

青刚科技工程本课件

1.2 粒子群算法

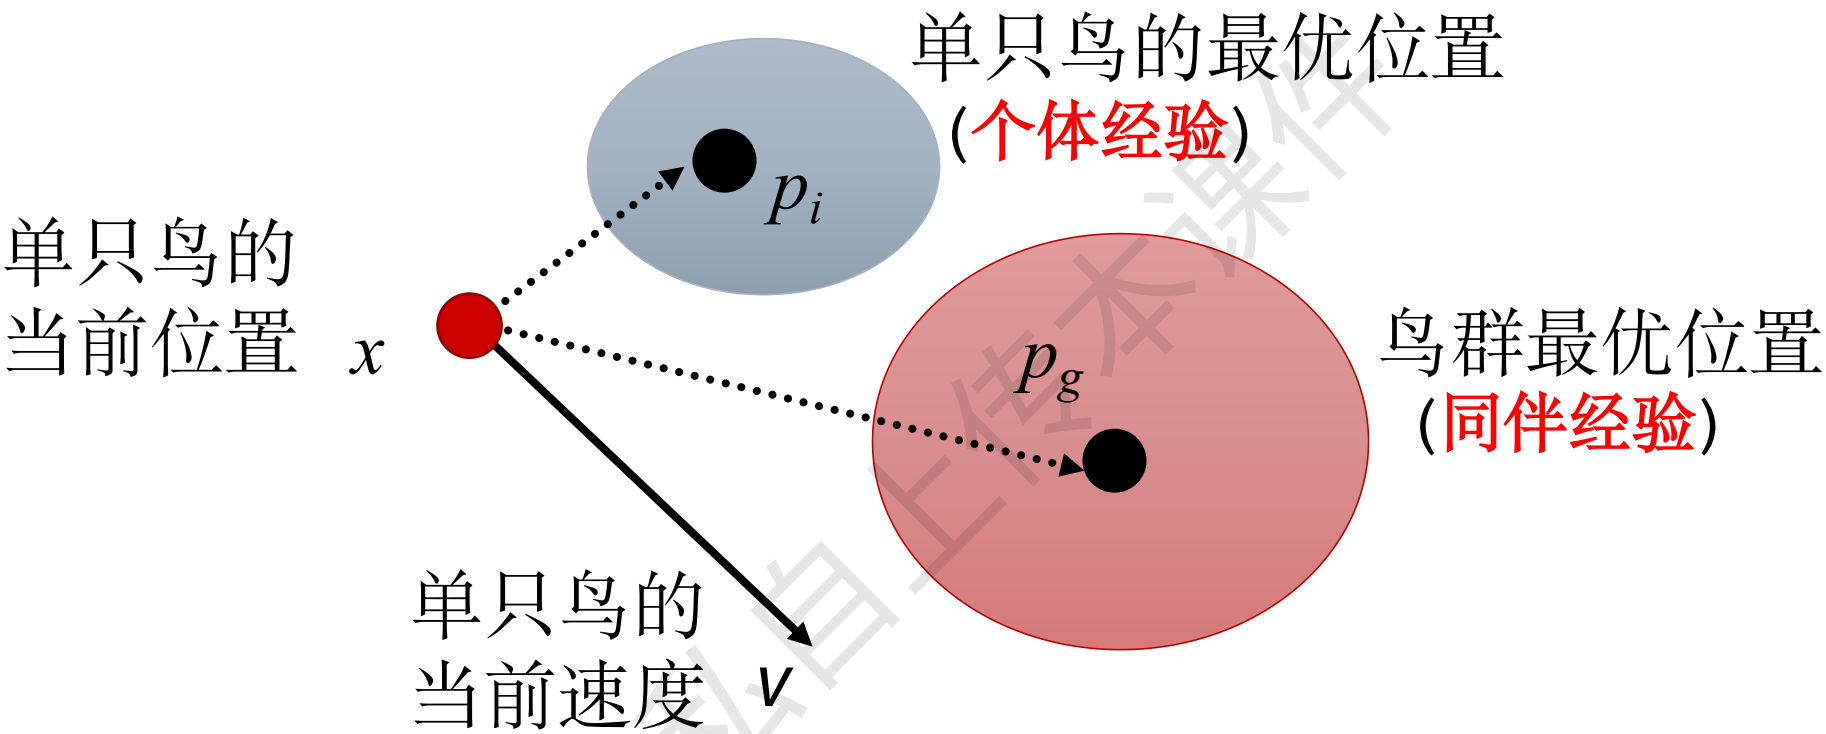

PSO初始化为一群随机粒子，然后通过迭代找到最优解。在每一次迭代中，**粒子通过跟踪两个“极值”来更新自己**。第一个就是粒子本身所找到的最优解，这个解称为**个体极值**。另个一是整个种群目前找到的最优解，这个解称为**全局极值**。

请勿私自上传本课件

1.2 粒子群算法

■ PSO算法

步骤:

- ✓ 初始化粒子群
- ✓ 评估粒子极值（适应度）
- ✓ 计算粒子个体最优解
- ✓ 计算粒子群全体最优解
- ✓ 更新粒子速度
- ✓ 移动粒子

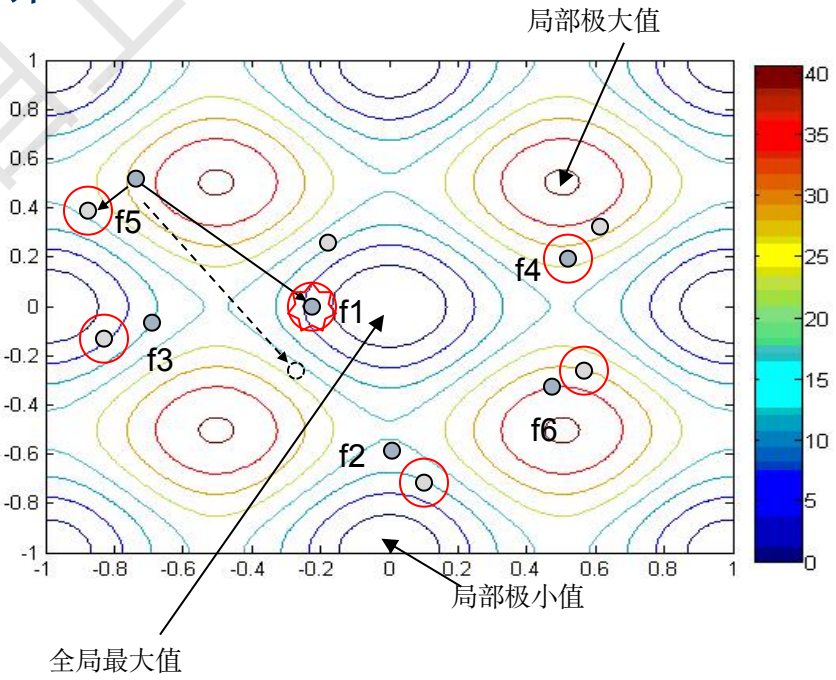

请勿私自上传本课件

1.2 PSO算法原理

■ 数学定义

在n 维连续搜索空间中，对粒子群中的第i (i=1, 2, …, m)个粒子进行定义：

$x^i(k)=\begin{bmatrix} x_1^i & x_2^i & \cdots & x_n^i \end{bmatrix}^T$ 表示搜索空间中粒子的当前位置。

$v^i(k)=\begin{bmatrix} v_1^i & v_2^i & \cdots & v_n^i \end{bmatrix}^T$ 表示该粒子的搜索方向与移动步长。

$p^i(k)=\begin{bmatrix} p_1^i & p_2^i & \cdots & p_n^i \end{bmatrix}^T$ **粒子个体**经历过的最优位置（pbest）

$p^g(k)=\begin{bmatrix} p_1^g & p_2^g & \cdots & p_n^g \end{bmatrix}^T$ **粒子群体**经历过的最优位置(gbest)

则基本的PSO算法为：

$$v_j^i(k+1)=\omega(k)v_j^i(k)+\varphi_1 rand(0,a_1)\left(p_j^i(k)-x_j^i(k)\right)+\varphi_2 rand(0,a_2)\left(p_j^g(k)-x_j^i(k)\right)$$

$$x_j^i(k+1)=x_j^i(k)+v_j^i(k+1)$$

$i=1,2,\cdots,m;\quad j=1,2,\cdots,n$ m是粒子群中粒子的数量，n是**搜索空间的维度**

其中，ω 是惯性权重因子。φ_1，φ_2 是加速度常数，均为非负值。$rand(0,a_1)$和$rand(0,a_2)$为[0, a_1]、[0, a_2]范围内的具有均匀分布的随机数，a_1 与 a_2 为相应的控制参数。

请勿私自上传本课件

1.2 PSO算法原理

■ 更新公式★

$$v_j^i(k+1)=\omega(k)v_j^i(k)+\varphi_1 rand(0,a_1)\left(p_j^i(k)-x_j^i(k)\right)+\varphi_2 rand(0,a_2)\left(p_j^g(k)-x_j^i(k)\right)$$

- ✓ 公式右边的第1部分是粒子在前一时刻的速度（惯性）。
- ✓ 第2部分为**个体“认知”分量**（认知项）。
- ✓ 第3部分是**群体“社会(social)”分量**（社会项）。
- ✓ φ_1，φ_2分别控制个体认知分量和群体社会分量相对**贡献的学习率**。
- ✓ 随机系数增加搜索方向的随机性和算法多样性。

- ◆ **个体“认知”**，粒子本身的思考，将现有的位置和曾经历过的最优位置相比。
- ◆ **群体“认知”**，表示粒子间通过信息共享与相互合作得出的最佳结果。

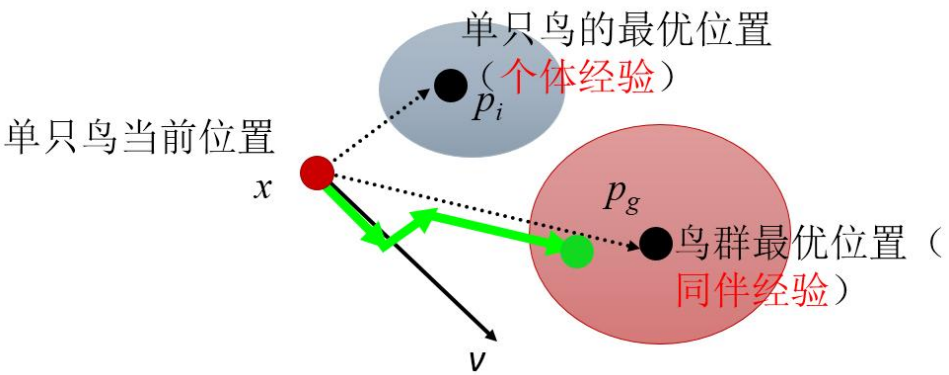

青州私自上传本课件

1.2 粒子群PSO算法

■ 算法流程图与伪代码

- Begin
  - Initialize swarm
  - Locate leader (p_g)
  - it=0
  - **While** it < max_it
    - For each particle
      - Update Position
      - Evaluation (*fitness*)
      - **Update *particle's best (p)***
    - EndFor
    - **Update leader (p_g)**
    - it++;
  - **EndWhile**
- End

1. **初始化：**随机生成 N 个粒子的位置 x_i 和速度 v_i；
2. 计算每个粒子的适应度 f(x_i)；
3. 初始化 pbest_i = x_i，gbest = min{pbest_i}；
4. 重复以下步骤直到满足停止条件（如最大迭代次数）：
   a. 对每个粒子 i：
      - 按速度公式更新 v_i；
      - 按位置公式更新 x_i；
      - 若 x_i 超出边界，进行边界处理（如反弹、截断）；
   b. 计算新位置的适应度 f(x_i)；
   c. 更新 pbest_i：若 f(x_i) < f(pbest_i)，则 pbest_i = x_i；
   d. 更新 gbest：若 f(x_i) < f(gbest)，则 gbest = x_i；
5. 输出 gbest 作为最优解。

请勿私自上传本课件

1.2 粒子群PSO算法

■ 算法流程图与伪代码

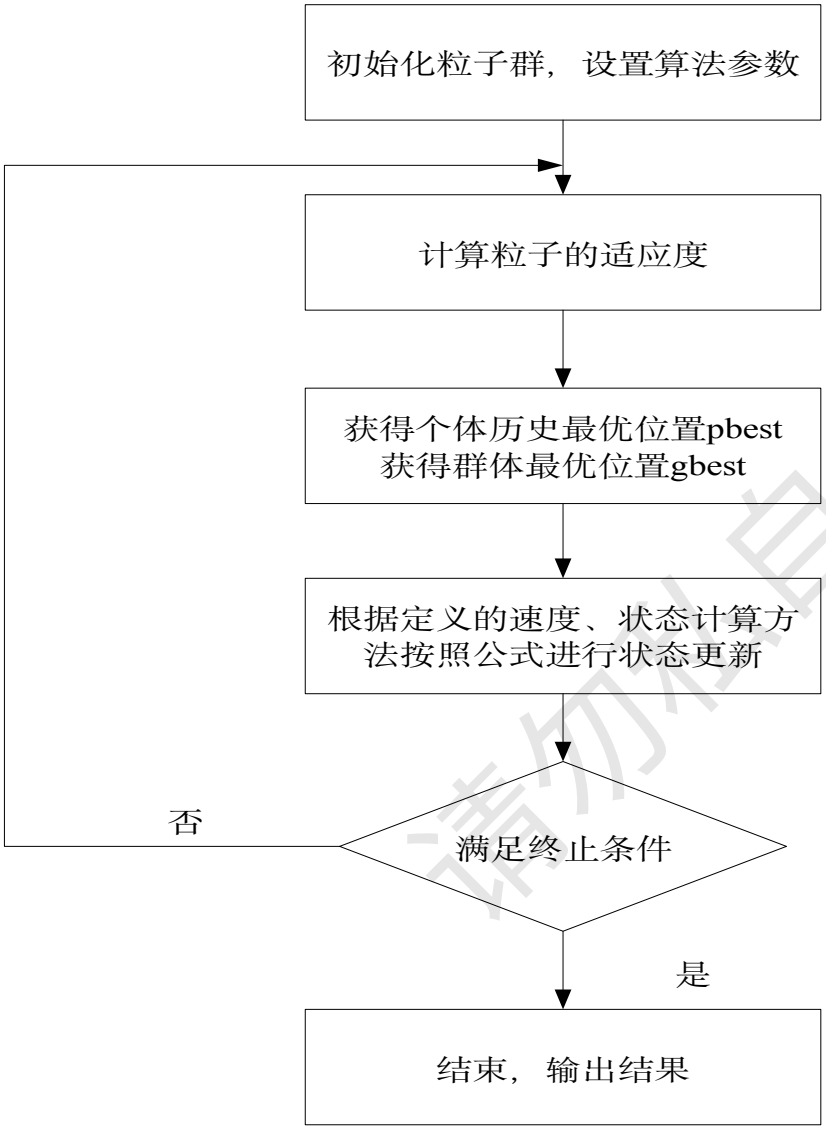

1. **初始化：** 随机生成 N 个粒子的位置 x_i 和速度 v_i；
2. 计算每个粒子的适应度 f(x_i)；
3. 初始化 pbest_i = x_i，gbest = min{pbest_i}；
4. 重复以下步骤直到满足停止条件（如最大迭代次数）：
   a. 对每个粒子 i：
      - 按速度公式更新 v_i；
      - 按位置公式更新 x_i；
      - 若 x_i 超出边界，进行边界处理（如反弹、截断）；
   b. 计算新位置的适应度 f(x_i)；
   c. 更新 pbest_i：若 f(x_i) < f(pbest_i)，则 pbest_i = x_i；
   d. 更新 gbest：若 f(x_i) < f(gbest)，则 gbest = x_i；
5. 输出 gbest 作为最优解。

请勿私自上传本课件

1.2 粒子群算法

■ 思考　如果过度关注全局最优，是否会出现“扎堆”现象？

$$v_j^i(k+1)=\underbrace{\omega(k)v_j^i(k)}_{\text{惯性}}+\underbrace{\varphi_1 rand(0,a_1)\left(p_j^i(k)-x_j^i(k)\right)}_{\text{认知项}}+\underbrace{\varphi_2 rand(0,a_2)\left(p_j^g(k)-x_j^i(k)\right)}_{\text{社会项}}$$

答：会！而且这正是标准 PSO 容易“早熟收敛”的根本原因

■ 为什么会“扎堆”？

- 社会项会把所有粒子拉向同一个点（gbest）；
- 如果φ_2很大，或φ_1 很小（社会项主导）→ 所有粒子迅速向 gbest 靠拢；
- 一旦 gbest 是局部最优，整个群体就“集体陷落”，失去探索能力。

■ 个体最优（pbest）的作用：维持多样性与探索能力

- pbest 的核心价值在于：让每个粒子保留自己的“探索记忆”；
- 即使群体找到了一个不错的解（gbest），某个粒子可能曾经在另一个区域找到过**次优但不同的好解**（它的 pbest）；
- 认知项会阻止该粒子完全放弃自己的历史经验，使得粒子在向 gbest 靠拢的同时，仍保留一定的“个性”和探索方向。

请勿私自传播课件

1.2 粒子群算法

■ 参数φ_1和φ_2的平衡

$$v_j^i(k+1)=\underbrace{\omega(k)v_j^i(k)}_{\text{惯性}}+\underbrace{\varphi_1 rand(0,a_1)\left(p_j^i(k)-x_j^i(k)\right)}_{\text{认知项}}+\underbrace{\varphi_2 rand(0,a_2)\left(p_j^g(k)-x_j^i(k)\right)}_{\text{社会项}}$$

参数	作用	值过大	值过小
φ_1（认知因子）	强化个体经验	粒子“固执己见”，收敛慢，可能不合作	失去多样性，易早熟
φ_2（社会因子）	强化群体协作	所有粒子迅速扎堆，早熟收敛	群体“各自为战”，收敛慢

经典设置：

- $\varphi_1=\varphi_2=2.0$（Kennedy & Eberhart 原始建议）
  → 平衡个体与社会影响，实践中效果较好。

动态调整策略（进阶）：

- **前期**：$\varphi_1>\varphi_2$ → 鼓励探索（每个粒子多试试自己的路）；
- **后期**：$\varphi_2>\varphi_1$ → 加速收敛（向已知最优靠拢）。

请勿私自上传本课件

1.2 粒子群算法

■ PSO算法特性

特性	说明
✅ 简单易实现	仅需位置、速度、两个记忆，代码通常 < 50 行
✅ 收敛速度快	在低维连续优化问题上，常比遗传算法更快
✅ 参数少	主要调 ω，φ_1，φ_2，比 GA 的交叉/变异率更易调
✅ 并行性好	粒子更新相互独立，适合并行计算
⚠️ 易陷入局部最优	尤其在高维、多峰函数中，可能早熟收敛
⚠️ 无理论收敛保证	属启发式算法，不能保证找到全局最优
⚠️ 对参数敏感	w 过大 → 震荡；过小 → 早熟

请勿私自上传本课件

1.2 粒子群算法

■ PSO算法的改进

- □ 缓解“扎堆”：
  - 局部 PSO：每个粒子只与邻居通信，gbest 变为 lbest（局部最优）。避免全局信息过快传播，保留多个“探索中心”。
  - 带变异的 PSO：随机对部分粒子位置加扰动（类似 GA 的变异）。主动打破扎堆。
- □ 自适应惯性权重：ω 随迭代递减（如从 $0.9 \to 0.4$），前期探索，后期开发；
- □ 带约束处理：用于解决带约束的优化问题；
- □ 混合算法：PSO + GA（用变异增加多样性）、PSO + 梯度法（局部精细搜索）；
- □ 多群 PSO：多个子群并行搜索，防止早熟。

请勿私自上传本课件

1.2 粒子群算法

■ PSO算法应用领域

领域	应用示例
工程优化	天线设计、电力系统调度、结构优化
机器学习	神经网络权重优化、特征选择、超参数调优
图像处理	图像分割阈值选取、边缘检测
经济与金融	投资组合优化、风险预测模型参数优化

请勿私自上传本课件

进化计算与群智能

1.1 智能计算概述

1.2 粒子群算法

1.3 遗传算法

请勿私自上传本课件

1.3 遗传算法

■ 生物学背景

进化-适者生存：最适应环境的群体会产生更多的后代群体。

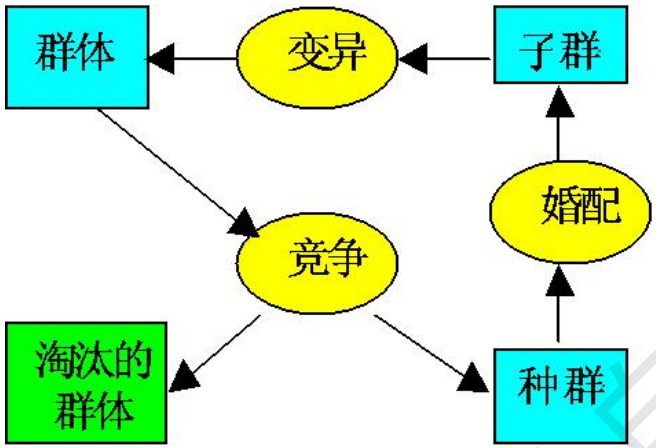

染色体(chromosome)：生物的遗传物质的主要载体。

基因(gene)：扩展生物性状的遗传物质的功能单元和结构单位。

基因座（locus）：染色体中基因的位置。

等位基因（alleles）：基因所取的值。

- ✓ 进化是指在生物延续生存过程中，逐渐适应其生存环境，使得其品质不断得到改良的一种生命现象。
- ✓ 遗传是指前代利用遗传基因将自身的基因信息传递给后代，使后代能够继承其前代的特征的这种生命现象。
- ✓ 变异是指后代和前代之间，以及后代的各个不同个体之间产生差异的现象。变异是生物进化过程中发生的一种随机现象，是一种不可逆过程，在生物多样性方面具有不可替代的作用。

请勿私自上传本课件

1.3 遗传算法

■ 遗传算法思想

来源于生物进化过程, 它是基于进化过程中的信息遗传机制和优胜劣汰的自然选择原则的搜索算法(以字符串表示状态空间)。其中的几个关键步骤是借助选择，交叉，变异等操作来实现的，使得要解决的问题**一步步的逼近最优解**。

核心概念:

- **种群**（Population）：一组候选解（称为“个体”或“染色体”）；
- **适应度**（Fitness）：衡量个体优劣的函数（目标函数的映射）；
- **遗传操作:**
  - ✓ 选择（Selection）
  - ✓ 交叉（Crossover）
  - ✓ 变异（Mutation）

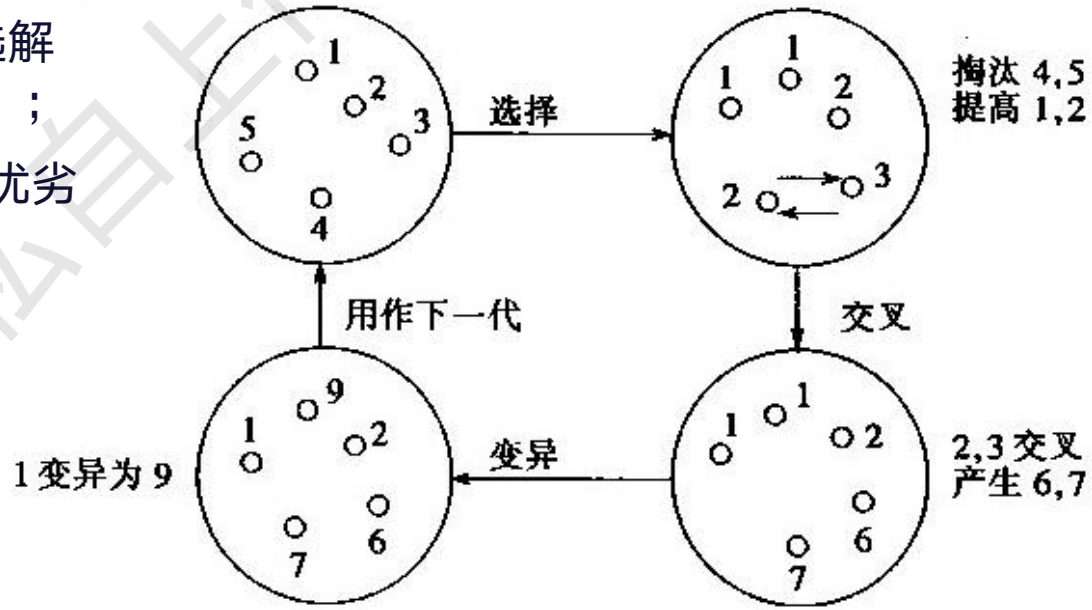

请勿私自上传本课件

1.3 遗传算法

- **适应度函数**：度量某个物种对于生存环境的适应程度
  - ✓ 对生存环境适应程度较高的物种将获得更多的繁殖机会，而对生存环境适应程度较低的物种，其繁殖机会就会相对较少，甚至逐渐灭绝。
  - ✓ 其函数值是遗传算法实现优胜劣汰的主要依据。
- **遗传操作**：是指作用于种群而产生新的种群操作。

标准的遗传操作包括以下3种基本形式：

- ✓ 选择（Selection）：从群体中选择优胜的个体，淘汰劣质个体的操作
- ✓ 交叉（Crosssover）：把两个父代个体的部分结构加以替换重组而生成新个体
- ✓ 变异（Mutation）：对群体中的个体串的某些值作变动

变异（编码翻转）： **1 1 0 0 0 > 1 1 0 1 0**

变异（编码交换）：个体A：1001↑111 → 1001↑000 新个体
个体B：0011↑000 → 0011 ↑111 新个体

请勿私自上传本课件

1.3 遗传算法

生物遗传概念	遗产算法中的应用
适者生存	目标值比较大的解被选择的可能性大
个体（Individual)	解
染色体（Chromosome)	解的编码（字符串、向量等)
基因（Gene)	解的编码中每一分量
适应性（Fitness)	适应度函数值
群体（Population)	根据适应度值选定的一组解（解的个数为群体的规模)
婚配（Marry)	交叉（Crossover）选择两个染色体进行交叉产生一组新的染色体的过程
变异（Mutation)	编码的某一分量发生变化的过程

请勿私自上传本课件

遗传算法设计的关键元素

- **参数编码**：怎样把优化问题的解进行编码。
- **适应度函数**：怎样根据目标函数构建适应度函数。
- **选择策略**：优胜劣汰。
- **控制参数**：种群的规模、算法执行的最大代数、执行不同遗传操作的概率等。
- **遗传算子**：选择、交叉、变异。
- **算法终止准则**：规定一个最大的演化代数，或算法在连续多少代以后解的适应值没有改进。

请勿私自上传本课件

■ 遗传算法设计——编码

将问题的候选解（解空间中的点）转换为遗传算法可操作的染色体形式（通常是字符串或向量）。

常见类型

编码类型	适用问题	染色体形式	举例
二进制编码	离散、整数优化	0/1 字符串	优化 $x \in [0, 31]$ → `10110` (=22)
实数编码	连续优化	实数向量	神经网络权重 → `[0.73, -1.2, 4.5]`
排列编码	组合优化（顺序）	无重复整数序列	TSP 路径 → `[3, 1, 4, 2]`
树编码	符号回归、GP	语法树	表达式 `x + sin(x)` 的树结构

请勿私自上传本课件

■ 遗传算法设计——编码

1.1二进制编码（属于位串编码——将问题空间的参数编码为一维排列的染色体的方法）：用若干二进制数表示一个个体，将原问题的解空间映射到位串空间 $B=\{0, 1\}$上，然后在位串空间上进行遗传操作。

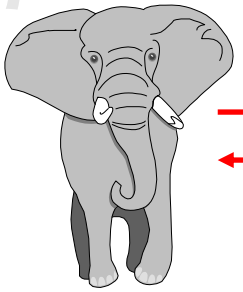

编码 →

← 解码

1 1 1 1 1 1 1

- ✓ **符合生物遗传理论**
- ✓ **交叉、变异容易实现**

□ **相邻整数可能存在较大Hamming距离（汉明悬崖问题）**

(**Hamming距离：**用于衡量两个等长字符串在相同位置上不同字符的个数)

□ **求解复杂高维问题时，编码过长导致计算效率低**

适用于离散/整数问题

请勿私自上传本课件

■ 遗传算法设计——编码

1.2 格雷码（二进制编码的改进）：用若干二进制数表示一个个体，特点是：任意两个相邻整数的编码之间，仅有一位二进制位不同（即汉明距离恒为 1）。

编码过程

■ 设标准二进制为 $b_{n-1}b_{n-2}\ldots b_0$，对应格雷码为 $g_{n-1}g_{n-2}\cdots g_0$ 则：

$$g_{n-1} = b_{n-1}$$

$$g_i = b_{i+1} \oplus b_i \quad \text{for } i = n-2, \ldots, 0$$

其中 $\oplus$ 表示异或（XOR）

请勿私自上传本课件

■ 遗传算法设计——编码

1.2 格雷码（二进制编码的改进）：用若干二进制数表示一个个体，特点是：任意两个相邻整数的编码之间，仅有一位二进制位不同（即汉明距离恒为 1）。

编码过程

✅ **举例：二进制 `1000`（=8）→ 格雷码**

- $b_3 = 1, b_2 = 0, b_1 = 0, b_0 = 0$
- $g_3 = b_3 = 1$
- $g_2 = b_3 \oplus b_2 = 1 \oplus 0 = 1$
- $g_1 = b_2 \oplus b_1 = 0 \oplus 0 = 0$
- $g_0 = b_1 \oplus b_0 = 0 \oplus 0 = 0$
- → 格雷码 = `1100`

十进制	标准二进制	格雷码	相邻格雷码汉明距离
7	`0111`	`0100`	
8	`1000`	`1100`	**1**（仅第1位不同）

有效解决汉明悬崖问题

请勿私自上传本课件

■ 遗传算法设计——编码

2.实数编码：使用一维实数向量表示染色体：

$$\mathbf{x} = [x_1, x_2, \ldots, x_n], \quad x_i \in \mathbb{R}$$

每个基因对应一个连续变量（如神经网络权重、工程参数等）。

- ✓ **精度高：**无需离散化，避免二进制编码的量化误差（如 8 位二进制只能表示 256 个值）
- ✓ **语义一致性更强，无汉明悬崖：**相邻实数值在编码上“距离近”，变异/交叉更平滑（对比二进制中 7→8 需翻转所有位）
- ✓ **可用于神经网络的权重优化问题（实数权重矩阵）**

- ☐ **不适用于离散问题**
- ☐ **缺乏“结构突变”能力**

适用于连续优化问题：函数优化、神经网络超参调优等

请勿私自上传本课件

■ 遗传算法设计——编码

3.排列编码：染色体是一个排列（无重复的整数序列）：

$$\pi = [\pi_1, \pi_2, \ldots, \pi_n], \quad \pi_i \in \{1, 2, \ldots, n\}, \text{且互不相同}$$

表示顺序、路径或任务序列。

- ✓ **天然表达顺序关系：**直接建模“谁在前、谁在后”的约束
- ✓ **无冗余解：**所有个体都是合法排列（若交叉/变异设计得当）
- ✓ **与问题语义一致：**如 TSP 中 [1,3,2,4] 直接对应路径，无需解码
- ☐ **交叉操作复杂：**普通单点交叉会产生非法个体（重复或缺失元素）
- ☐ **搜索空间巨大：**n 个元素的排列数为 n!，随 n 增长极快，易陷入局部最优

适用于组合优化问题：

- 旅行商问题（TSP）：城市访问顺序
- 车间调度（Job Shop Scheduling）：任务执行顺序

请勿私自上传本课件

1.3 遗传算法 三种编码方法对比

对比维度	二进制编码（Binary Encoding）	实数编码（Real-valued Encoding）	排列编码（Permutation Encoding）
问题类型	离散优化、整数优化、小规模组合问题	**连续优化**	**组合优化**（强调顺序、路径、调度）
典型应用	简单函数优化、特征选择（0/1）、早期GA实验	函数优化（Rosenbrock等）、神经网络超参数调优、控制系统设计	TSP、车间调度（JSP）、车辆路径问题（VRP）、任务排序
编码形式	0/1 位串，如 `10110`	实数向量：$[x_1, x_2, \ldots, x_n]$，$x_i \in \mathbb{R}$	无重复整数排列：$[\pi_1, \pi_2, \ldots, \pi_n]$，$\pi_i \in \{1, \ldots, n\}$
染色体长度	通常较长（精度要求高时需更多位）	等于变量个数 n	等于元素个数 n
合法性	总是合法（但解码后可能精度不足）	**通常合法**（需处理边界，如截断或反射）	**易产生非法解**（重复/缺失），需专用算子保证合法性
主要优点	- 理论成熟 - 操作简单 - 适合小规模离散问题	- **无量化误差** - **无汉明悬崖** - 精度高 - 操作自然	- **语义清晰** - 天然表达顺序关系 - 解即方案
主要缺点	- **汉明悬崖问题** - **精度与长度矛盾** - 解码开销 - 不适合高维连续问题	- 不适用于离散/组合问题 - 变异步长需调参	- **交叉/变异设计复杂** - 搜索空间巨大（$n!$） - 易陷入局部最优

请勿私自上传本课件

■ 遗传算法设计——适应度函数

衡量个体优劣程度的数值函数，是 *GA* 中“自然选择”的依据。

设计思路： 计算个体在群体中被使用的概率，它的设计应结合求解问题本身的要求而定。适应度函数的选取直接影响遗传算法的收敛速度以及能否找到最优解。适应度函数可由目标函数变换而成。

- 若目标函数为**最大化**问题，则 $Fit(f(x)) = f(x)$
- 若目标函数为**最小化**问题，则 $Fit(f(x)) = \dfrac{1}{f(x)}$

➢ **将目标函数转换为求最大值的形式,且保证函数值非负!**

- 若目标函数为**最大化**问题，则

$$Fit(f(x)) = \begin{cases} f(x) - C_{\min} & f(x) > C_{\min} \\ 0 & \text{其他情况} \end{cases}$$

- 若目标函数为**最小化**问题，则

$$Fit(f(x)) = \begin{cases} C_{\max} - f(x) & f(x) < C_{\max} \\ 0 & \text{其他情况} \end{cases}$$

c_{min}是原始适应函数f(x)的一个下界。如果$c_{min}(x)$ 未知，则可用当前代或到目前为止各演化代中的f(x)的最小值来代替。

请勿私自上传资源群

■ 遗传算法设计——选择

➢ **选择：** 从旧的种群中选择适应度高的染色体，放入匹配集（缓冲区），为以后染色体交换、变异，产生新的染色体作准备。

- **个体概率分配方法**——适应度比例法：按各染色体适应度大小比例来决定其被选择数目的多少

某染色体被选的概率：P_c

$$P_c = f(x_i) \Big/ \sum f(x_i)$$

x_i 为种群中第i个染色体，

$f(x_i)$ 第i个染色体的适应度值

$\sum f(x_i)$ 种群中所有染色体适应度值之和。

请勿私自上传本课件

1.3 遗传算法

- **选择个体方法：转轮赌选择方法**

- *按个体的选择概率产生一个轮盘，轮盘每个区的角度与个体的选择概率成比例。*
- *产生一个随机数，它落入转盘的哪个区域就选择相应的个体交叉。*

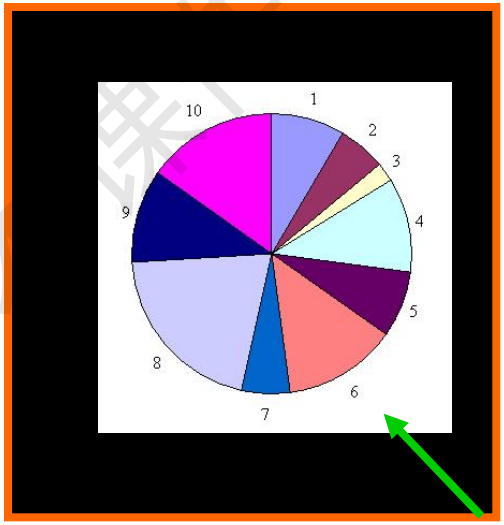

个体	1	2	3	4	5	6	7	8	9	10	11
适应度	2.0	1.8	1.6	1.4	1.2	1.0	0.8	0.6	0.4	0.2	0.1
选择概率	0.18	0.16	0.15	0.13	0.11	0.09	0.07	0.06	0.03	0.02	0.0
累积概率	0.18	0.34	0.49	0.62	0.73	0.82	0.89	0.95	0.98	1.00	1.00

第1轮产生一个随机数：**0.81**　　第2轮产生一个随机数：**0.32**

✓ **优点：**简单直观；

□ **缺点：**适应度差异大时，超级个体垄断繁殖。

1.3 遗传算法

- **选择个体方法：**锦标赛选择方法

从群体中随机选择个个体，将其中适应度最高的个体保存到下一代。这一过程反复执行，直到保存到下一代的个体数达到预先设定的数量为止。

案例：
- 种群适应度：[0.8, 0.3, 0.9, 0.5]
- 随机选 2 个：0.3 和 0.9 → 选 0.9
- 再选 2 个：0.8 和 0.5 → 选 0.8
- 父代 = [0.9, 0.8, ...]

✓ **参数少、鲁棒、可控制选择压力（最常用于现代 GA）**

- **选择个体方法：**最佳个体保存方法

把群体中适应度最高的个体不进行交叉而直接复制到下一代中，保证遗传算法终止时得到的最后结果一定是历代出现过的最高适应度的个体。

请勿私自上传本课件

■ 遗传算法设计——交叉

➢ **交叉：** 两个父代交换部分基因，产生新子代

单纯的复制不能创新，交换可以实现染色体的创新

- **方法：** 随机选择两个染色体作为双亲染色体；
  随机指定一点或多点位置，进行交换；
  可得两个新的染色体(子辈染色体)。

双亲染色体：染色体 A　11010|110　交换点
　　染色体 B　01011|001

新的子辈染色体：A'　11010001
　　B'　01011110

注意：交叉不是必须对所有个体进行，而是以交叉概率p_c决定是否执行；

请勿私自传播课件

1.3 遗传算法

- **一(单)点交叉：** 在个体串中随机设定一个交叉点，实行交叉时，该点前或后的两个个体的部分结构进行互换，并生成两个新的个体。

后侧互换的情况

- **二点交叉：** 随机设置两个交叉点，将两个交叉点之间的码串相互交换。

请勿私自上传本课件

1.3 遗传算法

□ 修正交叉：解决交叉过程中出现非法染色体的策略。

- **部分映射交叉(PMX)**
  1. 使用二点交叉法线交换双亲染色体；
  2. 按照交换区域内的映射关系，替代交换区域外的值
  3. 得到最终的新染色体

$$A = 9\ \ 8\ \ 4\ \ |\ \ 5\ \ 6\ \ 7\ \ |\ \ 1\ \ 3\ \ 2$$

$$B = 8\ \ 7\ \ 1\ \ |\ \ 2\ \ 3\ \ 9\ \ |\ \ 5\ \ 4\ \ 6$$

出现重复编码如9、3、2、7...

$$A' = \boxed{9}\ \ 8\ \ 4\ \ |\ \ 2\ \ 3\ \ \boxed{9}\ \ |\ \ 1\ \ 3\ \ 2$$

$$B' = 8\ \ \boxed{7}\ \ 1\ \ |\ \ 5\ \ 6\ \ \boxed{7}\ \ |\ \ 5\ \ 4\ \ 6$$

交换两点内结构

$$A'' = \boxed{7}\ \ 8\ \ 4\ \ |\ \ 2\ \ 3\ \ 9\ \ |\ \ 1\ \ \boxed{6}\ \ \boxed{5}$$

$$B'' = 8\ \ \boxed{9}\ \ 1\ \ |\ \ 5\ \ 6\ \ 7\ \ |\ \ \boxed{2}\ \ 4\ \ \boxed{3}$$

交换区映射关系：

2 ⟷ 5

3 ⟷ 6

9 ⟷ 7

请勿私自上传本课件

1.3 遗传算法

■ 遗传算法设计——变异

➢ **变异：** 模拟生物在自然界环境变化,引起基因的突变。突变产生染色体的多样性,避免进化中早期成熟,陷入局部极值点,突变的概率很低。

✓ **内变异：** 所谓内变异就是在自己内部发生变异

- 逆转变异

- 位点变异

  在染色体二进制编码中,1变成0;或0变成1

✓ **外变异：** 外变异是引入创新，突破传统的质的飞跃, 也是启发算法中的全域搜索。充当前基因中引入外部基因（当前集合的补集）。

- 或在实数编码个体中添加高斯噪声或扰动

请勿私自上传本课件

1.3 遗传算法

■ 遗传算法设计——变异

➢ **变异：** 模拟生物在自然界环境变化,引起基因的突变。突变产生染色体的多样性,避免进化中早期成熟,陷入局部极值点,突变的概率很低。

以小概率随机改变个体的某些基因，模拟基因突变。

关键参数

- 变异率 p_m：通常为 1/L（L 为染色体长度）或 0.001~0.1；
- 过高 → 破坏优良基因，退化为随机搜索；
- 过低 → 多样性丧失，早熟收敛。

请勿私自上传本课件

1.3 遗传算法

■ 遗传算法设计五大操作的核心作用

操作	作用	类比生物过程	关键参数
编码	解 → 染色体	DNA 表示性状	编码类型
适应度函数	评价个体优劣	生存适应能力	映射方式
选择	优胜劣汰	自然选择	p_{select}
交叉	基因重组	有性繁殖	交叉概率 p_c
变异	引入新基因	基因突变	变异率 p_m

➢ **遗传算法本质：**通过选择保留优秀解，通过交叉组合优秀片段，通过变异探索未知区域——三者协同，实现“进化式优化”。

请勿私自上传本课件

遗传算法计算过程实例

- **产生初始种群（例：二进制编码的个体）**

0001100000	0101111001	0000000101	1001110100	1010101010
(8)	(5)	(2)	(10)	(7)
1110010110	1001011011	1100000001	1001110100	0001010011
(12)	(5)	(19)	(10)	(14)

- **计算适应度：这个函数是计算个体在群体中被使用的概率。它的设计应结合求解问题本身的要求而定**

请勿私自上传本课件

遗传算法计算过程实例

- **选择**

在0～1之间产生一个随机数：

淘汰！

生成10次：

0.070221
0.545929
0.784567
0.446930
0.507893
0.291198
0.716340
0.270901
0.371435
0.854641

淘汰未被选中的个体

个体	染色体	适应度	选择概率	累积概率
1	0001100000	8	0.086957	0.086957
2	0101111001	5	0.054348	0.141304
3	0000000101	2	0.021739	0.163043
4	1001110100	10	0.108696	0.271739
5	1010101010	7	0.076087	0.347826
6	1110010110	12	0.130435	0.478261
7	1001011011	5	0.054348	0.532609
8	1100000001	19	0.206522	0.739130
9	1001110100	10	0.108696	0.847826
10	0001010011	14	0.152174	1.000000

请勿私自上传本课件

遗传算法计算过程实例

- 交叉

0001100000	1110010110	1100000001	1001110100	1010101010
1110010110	1001011011	1001110100	1100000001	0001010011

0001010110	1111011011	1100000100	1001110100	1010101011
1110100000	1000010110	1001110001	1100000001	0001010010

请勿私自上传本课件

遗传算法计算过程实例

- **变异（例：位点变异）**

0001010110	1111011011	1100000100	1001110100	1010101011
1110100000	1000010110	1001**1**10001	1100000001	0001010010

0001010110	1111011011	1100000100	1001110100	1010101011
1110100000	1000010110	1001**0**10001	1100000001	0001010010

- **终止：**至下一代，再一次进行适应度计算→选择→交叉→变异，直至满足终止条件。

请勿私自上传本课件

遗传算法计算过程实例

■ 算法步骤

(1) 使用随机方法或者其它方法，产生一个有*N*个染色体的初始群体 ***pop(1)***，$t := 1$ ；

(2) 对群体中的每一个染色体$pop_i(t)$，计算其适应值

$$f_i = fitness(pop_i(t))$$

(3) 若满足停止条件，则算法停止；否则，以概率

$$p_i = f_i / \sum_{j=1}^{N} f_j$$

从***pop(t)***中随机选择一些染色体构成一个新种群

$$newpop(t+1) = \{pop_j(t) \mid j = 1,2,\ldots,N\}$$

请勿私自上传本课件

遗传算法计算过程实例

■ 算法步骤

(4) 以概率 p_c 进行交叉产生一些新的染色体，得到一个新的群体

$$crosspop\,(t+1)$$

(5) 以一个较小的概率 p_m 使染色体的一个基因发生变异，形成 $mutpop\,(t+1)$； $t := t+1$，成为一个新的群体

$$pop\,(t) = mutpop\,(t+1)$$

返回 (2) 。

请勿私自上传本课件

1.3 遗传算法

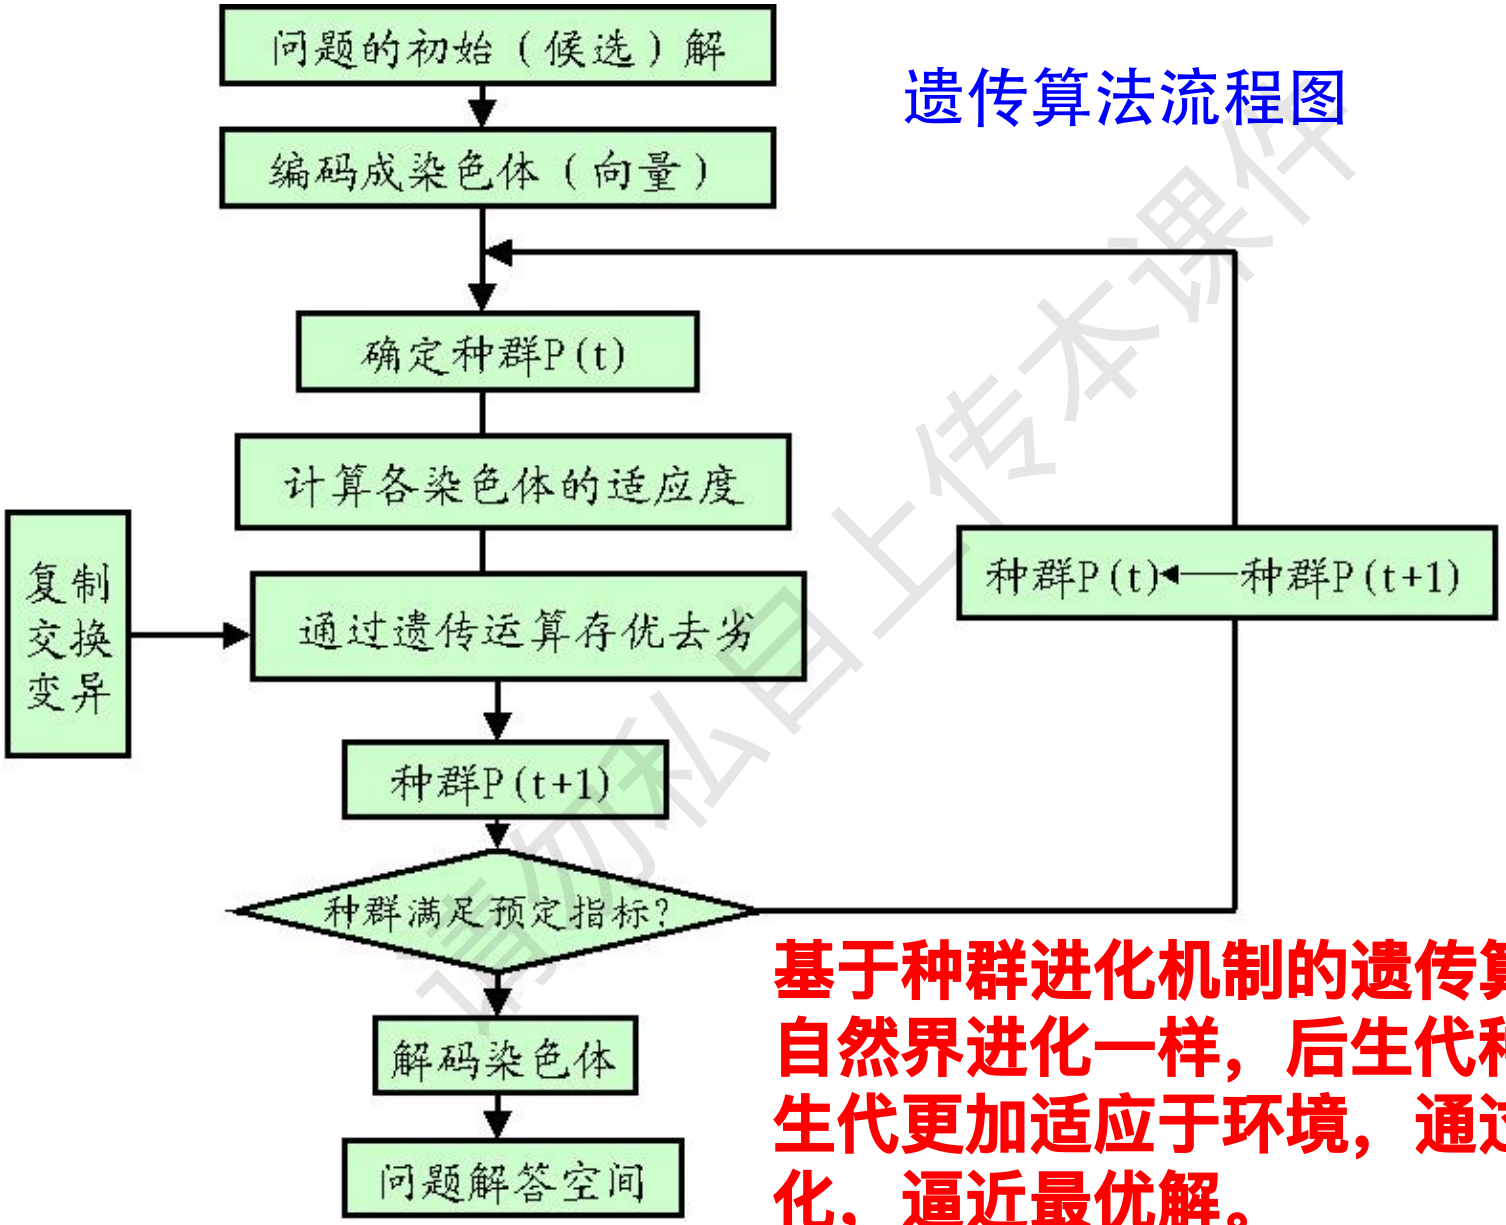

遗传算法流程图

基于种群进化机制的遗传算法如同自然界进化一样，后生代种群比前生代更加适应于环境，通过逐代进化，逼近最优解。

请勿私自上传本课件

PSO vs. GA

核心思想对比

算法	灵感来源	核心机制
PSO	鸟群/鱼群协作觅食	个体通过**自身历史最优**（pbest）和**群体最优**（gbest）调整速度与位置
GA	达尔文生物进化论	通过**选择**、**交叉**（重组）模拟“适者生存”

- ✓ GA中强调“适者生存”，不好的个体在竞争中被淘汰；
- ✓ PSO强调“协同合作”，不好的个体通过学习，向好的方向转变。不好的个体被保留还可以增强群体的多样性。
- ✓ GA中最好的个体通过产生更多的后代来传播自己的基因；
- ✓ PSO中的最佳个体通过吸引其它个体向它靠近来传播自己的位置。

关键区别：

•粒子群算法PSO 是速度-位置驱动的**轨迹**搜索；

•遗传算法GA 是基于种群演化的**概率**搜索。

请勿私自上传本课件

PSO vs. GA

具体对比：

✅ 1. 收敛速度

- **PSO 优势**：
  - 通常**收敛更快**，尤其在低维、单峰或平滑函数上；
  - 因所有粒子都向 gbest 靠拢，信息传播快。
- **GA 劣势**：
  - 依赖交叉和变异，收敛较慢；
  - 早期可能在解空间“盲目探索”。

> 📌 **适用场景**：若需快速获得满意解（如实时优化），PSO 更优。

请勿私自上传本课件

PSO vs. GA

具体对比：

✅ 2. 实现复杂度与参数

- **PSO 优势**：
  - **代码更简单**（仅需位置、速度更新）；
  - **参数少**：主要调 w, c_1, c_2（通常 $c_1 = c_2 = 2$ 即可）。
- **GA 劣势**：
  - 需设计**编码方式**（二进制/实数）、**选择策略**（轮盘赌/锦标赛）、**交叉/变异算子**；
  - 参数多：种群大小、交叉率 p_c、变异率 p_m 等，调参更复杂。

> 💡 举例：PSO 用 20 行 Python 可实现，GA 通常需 50 行以上。

请勿私自上传本课件

PSO vs. GA

具体对比：

✅ **3. 全局搜索能力 vs 局部开发能力**

- **GA 优势**：
  - **全局探索能力强**：交叉和变异能跳出局部最优，适合**多峰、高维、离散问题**；
  - 种群多样性保持较好（尤其使用精英保留策略时）。
- **PSO 劣势**：
  - 易**早熟收敛**（premature convergence）：一旦 gbest 陷入局部最优，所有粒子迅速聚集，丧失多样性；
  - 在高维或复杂地形中表现不稳定。

> 📌 **适用场景**：
>
> - 多峰函数、组合优化（如 TSP）→ **GA 更稳健**；
> - 连续、低维、单峰函数 → **PSO 更高效**。

请勿私自上传本课件

PSO vs. GA

维度	PSO	GA
收敛速度	⭐⭐⭐⭐ 快	⭐⭐ 较慢
实现难度	⭐ 简单	⭐⭐⭐ 较复杂
参数数量	少（2–3 个）	多（3–5 个）
全局搜索能力	⭐⭐ 易早熟	⭐⭐⭐⭐ 强（多样性好）
连续优化	⭐⭐⭐⭐ 优秀	⭐⭐⭐ 良好
离散/组合优化	⭐ 需改造	⭐⭐⭐⭐ 天然支持
高维问题	⭐⭐ 可能失效	⭐⭐⭐ 更稳健
并行性	⭐⭐⭐⭐ 好（粒子独立）	⭐⭐⭐ 好（个体独立）

请勿私自上传本课件

课堂练习

用遗传算法求函数

$$f(x)=x^2$$

的最大值，其中x为[0，31]间的整数。

请勿私自上传本课件

课堂练习

例 用遗传算法求函数

$$f(x)=x^2$$

的最大值，其中x为[0，31]间的整数。

解：这个问题本身比较简单，其最大值很显然是在x=31处。但作为一个例子，它有着较好的示范性和可理解性。

按照遗传算法，其求解过程如下：

(1) 编码

由于x的定义域是区间[0，31]上的整数，由5位二进制数即可全部表示。因此，可采用二进制编码方法，其编码串的长度为5。

例如，用二进制串00000来表示x=0,11111来表示x=31等。其中的0和1为基因值。

(2) 生成初始种群

若假设给定的种群规模N=4，则可用4个随机生成的长度为5的二进制串作为初始种群。再假设随机生成的初始种群（即第0代种群）为：

s_{01}=0 1 1 0 1　　s_{02}=1 1 0 0 1

s_{03}=0 1 0 0 0　　s_{04}=1 0 0 1 0

请勿私自上传本课件

课堂练习

(3) 计算适应度

要计算个体的适应度，首先应该定义适应度函数。由于本例是求f(x)的最大值，因此可直接用f(x)来作为适应度函数。即：

$$f(s)=f(x)$$

其中的二进制串s对应着变量x的值。根据此函数，初始种群中各个个体的适应值及其所占比例如下表所示。

初始种群情况表

编号	个体串（染色体）	x	适应值	百分比%	累计百分比%	选中次数
S_{01}	01101	13	169	14.44	14.44	1
S_{02}	11001	25	625	52.88	67.18	2
S_{03}	01000	8	64	5.41	72.59	0
S_{04}	10010	18	324	27.41	100	1

可以看出，在4个个体中S_{02}的适应值最大，是当前最佳个体。

请勿私自上传本课件

课堂练习

(4) 选择操作

假设采用轮盘赌方式选择个体，且依次生成的4个随机数（相当于轮盘上指针所指的数）为0.85、0.32、0.12和0.46，经选择后得到的新的种群为：

S_{01}=10010

S_{02}=11001

S_{03}=01101

S_{04}=11001

其中，染色体11001在种群中出现了2次，而原染色体01000则因适应值太小而被淘汰

编号	个体串（染色体）	x	适应值	百分比%	累计百分比%	选中次数
S_{01}	01101	13	169	14.44	14.44	1
S_{02}	11001	25	625	52.88	67.18	2
~~S_{03}~~	~~01000~~	~~8~~	~~64~~	~~5.41~~	~~72.59~~	~~0~~
S_{04}	10010	18	324	27.41	100	1

请勿私自上传本课件

课堂练习

(5) 交叉

假设交叉概率P_c为50%，则种群中只有1/2的染色体参与交叉。若规定种群中的染色体按顺序两两配对交叉，且有S_{01}与S_{02}交叉，S_{03}与S_{04}不交叉，则交叉情况如下表所示。

初始种群的交叉情况表

编号	个体串（染色体）	交叉对象	交叉位	子代	适应值
S01	10010	S02	3	10001	289
S02	11001	S01	3	11010	676
S03	01101	S04	N	01101	169
S04	11001	S03	N	11001	625

可见，经交叉后得到的新的种群为：

S_{01}=10001

S_{02}=11010

S_{03}=01101

S_{04}=11001

交叉位也是随机选择

请勿私自上传课件

课堂练习

(6) 变异

变异概率Pm一般都很小，假设本次循环中没有发生变异，则变异前的种群即为进化后所得到的第1代种群。即：

S_{11}=10001

S_{12}=11010

S_{13}=01101

S_{14}=11001

然后，对第新一代种群重复上述(4)-(6)的操作

请勿私自上传本课件

课堂练习

对第新一代种群，同样重复上述(4)-(6)的操作。其选择情况如下表所示。

种群的选择情况表

编号	个体串（染色体）	x	适应值	百分比%	累计百分比%	选中次数
S_{11}	10001	27	289	16.43	16.437	1
S_{12}	11010	26	676	38.43	54.86	2
S_{13}	01101	13	169	9.61	64.47	0
S_{14}	11001	25	625	35.53	100	1

其中若假设按轮盘赌选择时依次生成的4个随机数为0.14、0.51、0.24和0.82，经选择后得到的新的种群为：

S_{11}=10001

S_{12}=11010

S_{13}=11010

S_{14}=11001

可以看出，染色体11010被选择了2次，而原染色体01101则因适应值太小而被淘汰。

请勿私自上传本课件

课堂练习

其交叉情况如下表所示。

新代种群的交叉情况表

编号	个体串（染色体）	交叉对象	交叉位	子代	适应值
S_{11}	10001	S12	3	10010	324
S_{12}	11010	S11	3	11001	625
S_{13}	11010	S14	2	11001	625
S_{14}	11001	S13	2	11010	675

可见，经杂交后得到的新的种群为：

S_{11}=10010

S_{12}=11001

S_{13}=11001

S_{14}=11010

可以看出，第3位基因均为0，已经不可能通过交配达到最优解。这种过早陷入局部最优解的现象称为早熟。为解决这一问题，需要采用变异操作。

请勿私自上传本课件

课堂练习

其变异情况如下表所示。

种群的变异情况表

编号	个体串（染色体）	是否变异	变异位	子代	适应值
S_{11}	10010	N		10010	324
S_{12}	11001	N		11001	625
S_{13}	11001	N		11001	625
S_{14}	11010	Y	3	11110	900

它是通过对S_{14}的第3位的变异来实现的。变异后所得到的第2代种群为：

S_{21}=10010

S_{22}=11001

S_{23}=11001

S_{24}=11110

接着，再对后续新代种群同样重复上述(4)-(6)的操作：

请勿私自上传本课件

课堂练习

对第2代种群，同样重复上述(4)-(6)的操作。其选择情况如下表所示。

第2代种群的选择情况表

编号	个体串（染色体）	x	适应值	百分比%	累计百分比%	选中次数
S21	10010	18	324	23.92	23.92	1
S22	11001	25	625	22.12	46.04	1
S23	11001	25	625	22.12	68.16	1
S24	11110	30	900	31.84	100	1

其中若假设按轮盘赌选择时依次生成的4个随机数为0.42、0.15、0.59和0.91，经选择后得到的新的种群为：

S_{21}=11001

S_{22}=10010

S_{23}=11001

S_{24}=11110

请勿私自上传本课件

课堂练习

对第2代种群，其交叉情况如下表所示。

编号	个体串（染色体）	交叉对象	交叉位	子代	适应值
S_{21}	11001	S_{22}	3	11010	676
S_{22}	10010	S_{21}	3	10001	289
S_{23}	11001	S_{24}	4	11000	576
S_{24}	11110	S_{23}	4	11111	961

这时，函数的最大值已经出现，其对应的染色体为11111，经解码后可知问题的最优解是在点x=31处。

求解过程结束。

请勿私自上传本课件