机器学习核心知识总结

基于西瓜书整理

2025 年 12 月 17 日

目录

1 绪论 **2**

1.1 符号定义 2
1.2 机器学习定义 2
1.2.1 核心目标 2
1.2.2 显式编程 vs 非显式编程 3
1.3 机器学习问题分类 3
1.4 机器学习三要素 4
1.4.1 线性回归的三要素 4
1.4.2 神经网络的三要素 4
1.5 没有免费午餐定理（No Free Lunch Theorem） 4

2 模型评估与选择 **5**

2.1 机器学习核心流程 5
2.2 模型选择与超参数选择 5
2.2.1 超参数定义 5
2.2.2 欠拟合与过拟合 5
2.2.3 验证集划分方法 5
2.3 性能评估指标 6
2.3.1 回归问题指标 6
2.3.2 分类问题通用指标 6
2.3.3 二分类问题专用指标 7
2.4 偏差与方差（泛化误差分解） 8
2.4.1 基础前提 8
2.4.2 核心概念 8
2.4.3 泛化误差分解公式 8

3 线性模型 9
3.1 凸优化基础 . . . 9
3.1.1 向量范数 . . . 9
3.1.2 凸集与凸函数 . . . 9
3.2 一元线性回归 . . . 9
3.2.1 模型形式 . . . 9
3.2.2 损失函数 . . . 10
3.2.3 求解过程 . . . 10
3.3 多元线性回归 . . . 11
3.3.1 模型形式 . . . 11
3.3.2 矩阵表示 . . . 11
3.3.3 损失函数与解析解 . . . 11
3.4 多项式回归 . . . 12
3.4.1 模型形式 . . . 12
3.4.2 转化为多元线性回归 . . . 12
3.5 正则化（防止过拟合） . . . 12
3.5.1 Lasso 回归（L1 正则化） . . . 12
3.5.2 岭回归（L2 正则化） . . . 12
3.6 逻辑回归（二分类） . . . 13
3.6.1 模型核心 . . . 13
3.6.2 Sigmoid 函数性质 . . . 13
3.6.3 损失函数推导 . . . 13
3.6.4 梯度计算 . . . 14
3.6.5 梯度下降求解 . . . 14
3.7 线性判别分析（LDA） . . . 14
3.7.1 核心思想 . . . 14
3.7.2 投影计算 . . . 15
3.7.3 均值与方差 . . . 15
3.7.4 目标函数 . . . 15
3.7.5 最优解 . . . 15
3.8 多分类扩展策略 . . . 15

4 决策树 16
4.1 基本概念 . . . 16
4.2 属性划分准则 . . . 16
4.2.1 信息熵 . . . 16
4.2.2 信息增益 . . . 17
4.2.3 信息增益率 . . . 18

4.2.4 基尼指数 18
4.3 决策树构建流程 19
4.4 决策树剪枝 19
4.5 连续值处理 20
4.6 缺失值处理 20

5 神经网络 20
5.1 感知机模型 20
5.1.1 核心前提 20
5.1.2 模型公式 20
5.1.3 常用激活函数 21
5.2 神经网络基本结构 21
5.3 前向传播 21
5.3.1 单隐层网络 21
5.4 反向传播算法（BP 算法） 23
5.4.1 核心思想 23
5.4.2 损失函数 23
5.4.3 梯度计算（输出层） 23
5.4.4 梯度计算（隐层） 23
5.4.5 参数更新 24
5.5 梯度下降变体 24

6 支持向量机 24
6.1 线性支持向量机（硬间隔） 24
6.1.1 核心目标 24
6.1.2 模型形式 24
6.1.3 间隔推导 25
6.1.4 优化问题 25
6.2 对偶问题 26
6.2.1 拉格朗日函数 26
6.2.2 对偶问题推导 26
6.2.3 KKT 条件 26
6.2.4 参数求解 27
6.3 核函数方法（非线性 SVM） 27
6.3.1 核心思路 27
6.3.2 核技巧 27
6.3.3 常用核函数 27
6.3.4 核化对偶问题 27

6.3.5 决策函数 28
6.4 软间隔支持向量机 28
6.4.1 核心改进 28
6.4.2 优化问题 28
6.4.3 对偶问题 28

7 贝叶斯分类器 **28**
7.1 贝叶斯定理 28
7.2 朴素贝叶斯假设 29
7.3 离散属性朴素贝叶斯 29
7.3.1 核心思想 29
7.3.2 计算步骤 29
7.4 拉普拉斯平滑 30
7.5 连续属性朴素贝叶斯 31
7.5.1 核心思想 31
7.5.2 计算步骤 31

A 西瓜数据集 2.0 **33**
A.1 数据集统计信息 33
A.1.1 类别分布 33
A.1.2 属性取值统计 34
A.1.3 各属性在不同类别下的分布 35

1 绪论

1.1 符号定义

在机器学习中，我们需要统一使用数学符号来描述数据和模型。

定义 1.1 (标量). 标量是单个数值，用小写字母表示，如 $x = 1$，$y = 5.2$。

定义 1.2 (向量). 向量是一组有序数值的集合，用粗体小写字母或带箭头表示：

$$\mathbf{x} = [x_1, x_2, \cdots, x_d]^T = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

其中 d 称为向量的维度。

定义 1.3 (矩阵). 矩阵是二维数组，用大写字母表示：

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} \end{bmatrix}_{m \times d}$$

其中 m 为行数（样本数），d 为列数（特征数）。

定义 1.4 (随机变量). 随机变量用大写字母表示，如 $X \sim N(\mu, \sigma^2)$ 表示 X 服从均值为 μ、方差为 σ^2 的正态分布。

1.2 机器学习定义

阿瑟·萨缪尔的定义

机器学习是不通过显式编程赋予机器学习能力的学科。

1.2.1 核心目标

以自动驾驶为例：

- **输入**：d_1、d_2、d_3（3 个距离参数）
- **输出**：v（速度）、θ（转向角）
- **目标**：根据输入参数调节速度和转向角，实现在车道内自动行驶

1.2.2 显式编程 vs 非显式编程

显式编程示例（传统规则方法）：

```
if d1 > d3:
    theta = theta + 1
    v = v - 1
elif d1 < d3:
    theta = theta - 1
    v = v - 1
...
```

非显式编程示例（机器学习方法）：

$$
\begin{aligned}
(d_{11}, d_{12}, d_{13}) &\to (v_1, \theta_1) \\
(d_{21}, d_{22}, d_{23}) &\to (v_2, \theta_2) \\
&\vdots \\
(d_{n1}, d_{n2}, d_{n3}) &\to (v_n, \theta_n)
\end{aligned}
$$

通过大量数据样本，让机器自动学习输入到输出的映射关系。

1.3 机器学习问题分类

表 1: 机器学习问题分类

学习类型	问题类型	核心特征	典型算法
监督学习	回归问题	有标签、标签为连续值	线性回归
监督学习	分类问题	有标签、标签为离散值	逻辑回归、决策树、SVM
无监督学习	聚类问题	无标签	k 均值、高斯混合聚类

西瓜数据集示例

以西瓜数据集为例，判断西瓜是否为” 好瓜” 是一个**二分类问题**：

- 输入特征：色泽、根蒂、敲声、纹理、脐部、触感（6 个离散特征）
- 输出标签：好瓜（是/否）
- 样本数量：17 个

这是典型的监督学习分类问题。

1.4 机器学习三要素

机器学习的核心由三个要素组成：**模型**、**策略**、**算法**。

1.4.1 线性回归的三要素

1. **模型**：$f(x) = w_1 x + w_2$

   模型定义了假设空间，即所有可能的函数集合。

2. **策略**：损失函数（评价模型好坏的指标）

$$Loss = \sum_{i=1}^{n} (w_1 x_i + w_2 - y_i)^2$$

3. **算法**：求解最优参数的方法

$$w^* = (X^T X)^{-1} X^T y \quad \text{（解析解）}$$

1.4.2 神经网络的三要素

1. **模型**：$f = \phi(x, w)$（非线性函数）

2. **策略**：

$$Loss = \sum_{i=1}^{n} (\phi(x_i, w) - y_i)^2$$

3. **算法**：梯度下降法

$$w^* = \arg\min_{w} Loss(w)$$

1.5 没有免费午餐定理（No Free Lunch Theorem）

定理 1.1 (NFL 定理). *考虑所有可能的学习问题，任意学习算法 A 和学习算法 B 的平均性能相同。*

关键推论：

1. 如果在一个问题上模型 A 比模型 B 好，总能找到另一个问题使得模型 A 比模型 B 差

2. 没有一种模型可以解决所有机器学习问题

3. 需根据具体问题和数据特点选取合适模型

4. 简单模型（如线性回归）参数少，倾向于**欠拟合**；复杂模型（如神经网络）参数多，倾向于**过拟合**

2 模型评估与选择

2.1 机器学习核心流程

1. **基础流程**：训练集训练模型 → 测试集测试模型
2. **完整流程**：训练集 → 模型选择与超参数调优 → 完整训练 → 交付使用

2.2 模型选择与超参数选择

2.2.1 超参数定义

定义 2.1 (超参数). 超参数是在训练前需要人为设定的参数，不能通过训练数据直接学习得到。例如多项式模型：

$$f = \sum_{i=1}^{k} w_i x^i + w_{k+1}$$

其中 k（多项式次数）就是超参数。

2.2.2 欠拟合与过拟合

关键矛盾

- **欠拟合**：模型复杂度不足，训练误差和测试误差均高
- **过拟合**：模型复杂度过高，训练误差低但测试误差高

2.2.3 验证集划分方法

1. **留出法**：直接划分训练集、验证集、测试集（如 7:1.5:1.5）
2. **交叉验证法**：如 k 折交叉验证
   - 将数据分成 k 份
   - 每次用 k-1 份训练，1 份验证
   - 计算 k 次验证误差的平均值

   比较模型 A 和 B：若 $\frac{1}{k}\sum_{i=1}^{k} e_{Ai} < \frac{1}{k}\sum_{i=1}^{k} e_{Bi}$，则模型 A 更优。
3. **自助法**：有放回抽样，适用于小样本数据

西瓜数据集：交叉验证示例

使用西瓜数据集（17 个样本）进行 4 折交叉验证：

1. 将 17 个样本分成 4 份（约 4-5 个样本/份）

2. 第 1 折：用样本 1-4 验证，5-17 训练

3. 第 2 折：用样本 5-8 验证，其余训练

4. 第 3 折：用样本 9-12 验证，其余训练

5. 第 4 折：用样本 13-17 验证，其余训练

6. 计算 4 次验证准确率的平均值作为模型性能估计

2.3 性能评估指标

2.3.1 回归问题指标

设有 m 个样本，预测值为 f_i，真实值为 y_i。

1. **平方和误差（SSE）：**

$$SSE = \sum_{i=1}^{m}(f_i - y_i)^2$$

2. **均方误差（MSE）：**

$$MSE = \frac{1}{m}\sum_{i=1}^{m}(f_i - y_i)^2$$

3. **均方根误差（RMSE）：**

$$RMSE = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(f_i - y_i)^2}$$

4. **平均绝对误差（MAE）：**

$$MAE = \frac{1}{m}\sum_{i=1}^{m}|f_i - y_i|$$

2.3.2 分类问题通用指标

定义 2.2 (准确率与错误率)**.**

$$acc = \frac{1}{m}\sum_{i=1}^{m}\mathbb{I}(f_i = y_i) \quad \text{（预测正确样本占比）} \tag{1}$$

$$err = \frac{1}{m}\sum_{i=1}^{m}\mathbb{I}(f_i \neq y_i) \quad \text{（预测错误样本占比）} \tag{2}$$

其中 $\mathbb{I}(\cdot)$ 为指示函数，条件成立时为 *1*，否则为 *0*。

显然有：$acc + err = 1$

2.3.3 二分类问题专用指标

（1）混淆矩阵

表 2: 混淆矩阵

真实 \ 预测	正例	反例
正例	TP（真阳性）	FN（假阴性）
反例	FP（假阳性）	TN（真阴性）

（2）核心指标

定义 2.3 (查准率、查全率与 F1 值).

$$P = \frac{TP}{TP + FP} \quad \text{（查准率：预测为正例中真实正例占比）} \tag{3}$$

$$R = \frac{TP}{TP + FN} \quad \text{（查全率：真实正例中被正确预测的占比）} \tag{4}$$

$$F_1 = \frac{2PR}{P + R} \quad \text{（}F1\text{ 值：}P\text{ 和 }R\text{ 的调和平均）} \tag{5}$$

例题 2.1 (混淆矩阵计算). 某分类器在西瓜数据集上的预测结果如下：

- 真实好瓜 *8* 个，预测为好瓜 *6* 个，预测为坏瓜 *2* 个
- 真实坏瓜 *9* 个，预测为好瓜 *1* 个，预测为坏瓜 *8* 个

解：构建混淆矩阵：

真实 \ 预测	好瓜	坏瓜
好瓜	*TP=6*	*FN=2*
坏瓜	*FP=1*	*TN=8*

计算各指标：

$$P = \frac{TP}{TP + FP} = \frac{6}{6 + 1} = \frac{6}{7} \approx 85.7\%$$

$$R = \frac{TP}{TP + FN} = \frac{6}{6 + 2} = \frac{6}{8} = 75\%$$

$$F_1 = \frac{2PR}{P + R} = \frac{2 \times \frac{6}{7} \times \frac{6}{8}}{\frac{6}{7} + \frac{6}{8}} = \frac{2 \times \frac{36}{56}}{\frac{48+42}{56}} = \frac{72}{90} = 80\%$$

$$acc = \frac{TP + TN}{TP + FN + FP + TN} = \frac{6 + 8}{17} \approx 82.4\%$$

2.4 偏差与方差（泛化误差分解）

2.4.1 基础前提

假设数据生成过程为：

$$y_D(x) = y(x) + \epsilon$$

其中 $y(x)$ 是真实函数，$\epsilon \sim N(0, \sigma^2)$ 是噪声。

2.4.2 核心概念

定义 2.4 (偏差与方差).

- **期望泛化误差**：模型在所有可能数据集上的平均误差

$$\mathbb{E}_D\left[(f_D - y_D)^2\right]$$

- **偏差（*Bias*）**：模型预测均值与真实值的偏离

$$bias^2 = (y - \mathbb{E}_D[f_D])^2$$

反映模型的**欠拟合**倾向。

- **方差（*Variance*）**：不同数据集训练的模型预测值的波动

$$var = \mathbb{E}_D\left[(f_D - \mathbb{E}_D[f_D])^2\right]$$

反映模型的**过拟合**倾向。

2.4.3 泛化误差分解公式

定理 2.1 (偏差-方差分解).

$$\mathbb{E}_D\left[(f_D - y_D)^2\right] = \underbrace{(y - \mathbb{E}_D[f_D])^2}_{bias^2} + \underbrace{Var[f_D]}_{variance} + \underbrace{\sigma^2}_{noise}$$

即：泛化误差 = 偏差 ^{2} + 方差 + 噪声

推导过程：

设 $\bar{f} = \mathbb{E}_D[f_D]$，则：

$$\begin{aligned}\mathbb{E}_D[(f_D - y_D)^2] &= \mathbb{E}_D[(f_D - y + y - y_D)^2] \\ &= \mathbb{E}_D[(f_D - y)^2] + \mathbb{E}_D[(y - y_D)^2] + 2\mathbb{E}_D[(f_D - y)(y - y_D)]\end{aligned}$$

由于 $\mathbb{E}[\epsilon] = 0$，交叉项为 0，继续展开：

$$\begin{aligned}\mathbb{E}_D[(f_D - y)^2] &= \mathbb{E}_D[(f_D - \bar{f} + \bar{f} - y)^2] \\ &= \mathbb{E}_D[(f_D - \bar{f})^2] + (\bar{f} - y)^2 \\ &= Var[f_D] + bias^2\end{aligned}$$

而 $\mathbb{E}_D[(y - y_D)^2] = \mathbb{E}[\epsilon^2] = \sigma^2$，得证。

3 线性模型

3.1 凸优化基础

3.1.1 向量范数

定义 3.1 (向量范数). 向量范数是衡量向量”大小”的函数，满足正定性、齐次性、三角不等式。常见范数：

$$\|x\|_1 = \sum_{i=1}^{d} |x_i| \quad (1 \text{ 范数/曼哈顿距离}) \tag{6}$$

$$\|x\|_2 = \sqrt{\sum_{i=1}^{d} x_i^2} \quad (2 \text{ 范数/欧氏距离}) \tag{7}$$

$$\|x\|_\infty = \max_{i=1}^{d} |x_i| \quad (\text{无穷范数}) \tag{8}$$

例 3.1 (范数计算). 设 $x = [3, -4, 0]^T$，计算各范数：

$$\|x\|_1 = |3| + |-4| + |0| = 7$$
$$\|x\|_2 = \sqrt{3^2 + (-4)^2 + 0^2} = \sqrt{25} = 5$$
$$\|x\|_\infty = \max\{|3|, |-4|, |0|\} = 4$$

3.1.2 凸集与凸函数

定义 3.2 (凸集). 集合 C 是凸集，当且仅当对任意 $x, y \in C$ 和 $\lambda \in [0, 1]$：

$$\lambda x + (1 - \lambda) y \in C$$

即任意两点的连线仍在集合内。例如：$\mathbb{R}^d$、半空间 $\{x : a^T x \leq b\}$ 都是凸集。

定义 3.3 (凸函数). 函数 f 是凸函数，当且仅当对任意 x, y 和 $\lambda \in [0, 1]$：

$$f(\lambda x + (1 - \lambda) y) \leq \lambda f(x) + (1 - \lambda) f(y)$$

二阶判定条件：若 f 二阶可微，则 f 是凸函数当且仅当海森矩阵 $\nabla^2 f(x)$ 半正定。

定理 3.1 (凸优化性质). 凸优化问题的局部最优解即为全局最优解。

3.2 一元线性回归

3.2.1 模型形式

$$f(x) = w_1 x + w_2$$

其中 w_1 为斜率，w_2 为截距。

3.2.2 损失函数

给定训练数据 $\{(x_i, y_i)\}_{i=1}^n$，平方和损失函数为：

$$Loss(w_1, w_2) = \sum_{i=1}^{n}(w_1 x_i + w_2 - y_i)^2$$

3.2.3 求解过程

步骤 1：展开损失函数

$$\begin{aligned} Loss &= \sum_{i=1}^{n}(w_1 x_i + w_2 - y_i)^2 \\ &= \sum_{i=1}^{n}(w_1^2 x_i^2 + w_2^2 + y_i^2 + 2w_1 w_2 x_i - 2w_1 x_i y_i - 2w_2 y_i) \\ &= w_1^2 \sum x_i^2 + n w_2^2 + \sum y_i^2 + 2w_1 w_2 \sum x_i - 2w_1 \sum x_i y_i - 2w_2 \sum y_i \end{aligned}$$

步骤 2：计算梯度

$$\begin{aligned} \frac{\partial Loss}{\partial w_1} &= 2w_1 \sum x_i^2 + 2w_2 \sum x_i - 2 \sum x_i y_i = 0 \\ \frac{\partial Loss}{\partial w_2} &= 2nw_2 + 2w_1 \sum x_i - 2 \sum y_i = 0 \end{aligned}$$

步骤 3：解方程组得最优解

$$w_1^* = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} \tag{9}$$

$$w_2^* = \frac{\sum y_i - w_1^* \sum x_i}{n} = \bar{y} - w_1^* \bar{x} \tag{10}$$

例题 3.1 (一元线性回归). 给定 5 组训练数据：$x = [1, 2, 3, 4, 5]$，$y = [4.5, 7.1, 9.9, 11.9, 12.3]$，求最优线性模型。

解：计算中间量：

$$\begin{aligned} n = 5, \quad \sum x_i = 15, \quad \sum y_i = 45.7 \\ \sum x_i^2 = 1 + 4 + 9 + 16 + 25 = 55 \\ \sum x_i y_i = 1 \times 4.5 + 2 \times 7.1 + 3 \times 9.9 + 4 \times 11.9 + 5 \times 12.3 \\ = 4.5 + 14.2 + 29.7 + 47.6 + 61.5 = 157.5 \end{aligned}$$

代入公式：

$$\begin{aligned} w_1^* &= \frac{5 \times 157.5 - 15 \times 45.7}{5 \times 55 - 15^2} = \frac{787.5 - 685.5}{275 - 225} = \frac{102}{50} = 2.04 \\ w_2^* &= \frac{45.7 - 2.04 \times 15}{5} = \frac{45.7 - 30.6}{5} = \frac{15.1}{5} = 3.02 \end{aligned}$$

最终模型：$\boxed{f(x) = 2.04x + 3.02}$

验证凸性：海森矩阵

$$\nabla^2 Loss = \begin{bmatrix} 2\sum x_i^2 & 2\sum x_i \\ 2\sum x_i & 2n \end{bmatrix} = \begin{bmatrix} 110 & 30 \\ 30 & 10 \end{bmatrix}$$

特征值均为正，故损失函数是凸函数，所求为全局最优解。

3.3 多元线性回归

3.3.1 模型形式

$$f(\mathbf{x}) = w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + w_{d+1} = \mathbf{w}^T \mathbf{x}$$

3.3.2 矩阵表示

设计矩阵（增广矩阵）：

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{bmatrix}_{m\times(d+1)}$$

参数向量：$\mathbf{w} = [w_1, w_2, \cdots, w_d, w_{d+1}]^T$

标签向量：$\mathbf{y} = [y_1, y_2, \cdots, y_m]^T$

3.3.3 损失函数与解析解

$$Loss(\mathbf{w}) = (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y}) \tag{11}$$

$$= \mathbf{w}^T X^T X \mathbf{w} - 2\mathbf{w}^T X^T \mathbf{y} + \mathbf{y}^T \mathbf{y} \tag{12}$$

求解：令梯度为零

$$\nabla Loss = 2X^T X\mathbf{w} - 2X^T \mathbf{y} = 0$$

定理 3.2 (多元线性回归解析解)**.**

$$\mathbf{w}^* = (X^T X)^{-1} X^T \mathbf{y}$$

前提：$X^T X$ 可逆（即 X 列满秩）。

凸性验证：海森矩阵 $\nabla^2 Loss = 2X^T X$ 半正定，故损失函数是凸函数。

3.4 多项式回归

3.4.1 模型形式

$$f(x) = w_1 x^k + w_2 x^{k-1} + \cdots + w_k x + w_{k+1}$$

其中 k 为多项式次数，是**超参数**。

3.4.2 转化为多元线性回归

将 $x^k, x^{k-1}, \cdots, x, 1$ 视为新特征，构造设计矩阵：

$$X = \begin{bmatrix} x_1^k & x_1^{k-1} & \cdots & x_1 & 1 \\ x_2^k & x_2^{k-1} & \cdots & x_2 & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_m^k & x_m^{k-1} & \cdots & x_m & 1 \end{bmatrix}$$

解析解同样为：$\mathbf{w}^* = (X^T X)^{-1} X^T \mathbf{y}$

3.5 正则化（防止过拟合）

3.5.1 Lasso 回归（L1 正则化）

$$Loss(\mathbf{w}) = (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y}) + \lambda \|\mathbf{w}\|_1$$

特点：可实现特征选择（部分权重变为 0）。

3.5.2 岭回归（L2 正则化）

$$Loss(\mathbf{w}) = (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y}) + \lambda \|\mathbf{w}\|_2^2$$

解析解：

$$\mathbf{w}^* = (X^T X + \lambda I)^{-1} X^T \mathbf{y}$$

特点：稳定参数估计，防止 $X^T X$ 奇异。

正则化参数 λ

- λ 越大，正则化越强，模型越简单，偏向欠拟合
- λ 越小，正则化越弱，模型越复杂，偏向过拟合
- λ 是超参数，需通过验证集调优

3.6 逻辑回归（二分类）

3.6.1 模型核心

逻辑回归用于二分类问题，输出样本属于正类的概率。

线性部分：

$$z = \mathbf{w}^T\mathbf{x} = w_1x_1 + w_2x_2 + \cdots + w_dx_d + w_{d+1}$$

Sigmoid 映射：

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

概率输出：

$$P(Y=1|\mathbf{x}) = \sigma(\mathbf{w}^T\mathbf{x}) = \frac{1}{1+e^{-\mathbf{w}^T\mathbf{x}}} \tag{13}$$

$$P(Y=0|\mathbf{x}) = 1 - P(Y=1|\mathbf{x}) = \frac{e^{-\mathbf{w}^T\mathbf{x}}}{1+e^{-\mathbf{w}^T\mathbf{x}}} \tag{14}$$

3.6.2 Sigmoid 函数性质

1. 值域：$(0,1)$，适合表示概率
2. 单调递增
3. 导数：$\sigma'(z) = \sigma(z)(1-\sigma(z))$
4. 对称性：$\sigma(-z) = 1-\sigma(z)$

3.6.3 损失函数推导

似然函数（最大化样本出现概率）：

$$L(\mathbf{w}) = \prod_{i=1}^{m} P(Y=y_i|\mathbf{x}_i) = \prod_{i=1}^{m} \sigma(\mathbf{x}_i)^{y_i}(1-\sigma(\mathbf{x}_i))^{1-y_i}$$

对数似然：

$$\log L(\mathbf{w}) = \sum_{i=1}^{m} [y_i \log \sigma(\mathbf{x}_i) + (1-y_i)\log(1-\sigma(\mathbf{x}_i))]$$

负对数似然（交叉熵损失）：

$$H(\mathbf{w}) = -\log L(\mathbf{w}) = \sum_{i=1}^{m} [-y_i \log \sigma(\mathbf{x}_i) - (1-y_i)\log(1-\sigma(\mathbf{x}_i))]$$

3.6.4 梯度计算

$$\begin{aligned}\frac{\partial H}{\partial \mathbf{w}} &= \sum_{i=1}^{m}\left[-y_i\frac{\sigma'(\mathbf{x}_i)}{\sigma(\mathbf{x}_i)} + (1-y_i)\frac{\sigma'(\mathbf{x}_i)}{1-\sigma(\mathbf{x}_i)}\right]\mathbf{x}_i \\ &= \sum_{i=1}^{m}\left[-y_i(1-\sigma(\mathbf{x}_i)) + (1-y_i)\sigma(\mathbf{x}_i)\right]\mathbf{x}_i \\ &= \sum_{i=1}^{m}\left[\sigma(\mathbf{x}_i) - y_i\right]\mathbf{x}_i\end{aligned}$$

3.6.5 梯度下降求解

由于无解析解，使用梯度下降法迭代：

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta\nabla H(\mathbf{w}^{(t)})$$

其中 η 为学习率。

例题 3.2 (逻辑回归预测). 已知逻辑回归模型：

$$P(Y=1|\mathbf{x}) = \frac{1}{1+e^{-(1.2x_1+0.6x_2-10)}}$$

对以下样本进行预测（阈值 *0.5*）：

解：

1. $\mathbf{x} = [3,4]^T$：

$$z = 1.2\times 3 + 0.6\times 4 - 10 = 3.6 + 2.4 - 10 = -4$$

$$P(Y=1) = \frac{1}{1+e^4} \approx 0.018 < 0.5 \Rightarrow \text{预测标签} = 0$$

2. $\mathbf{x} = [5,6]^T$：

$$z = 1.2\times 5 + 0.6\times 6 - 10 = 6 + 3.6 - 10 = -0.4$$

$$P(Y=1) = \frac{1}{1+e^{0.4}} \approx 0.401 < 0.5 \Rightarrow \text{预测标签} = 0$$

3. $\mathbf{x} = [7,8]^T$：

$$z = 1.2\times 7 + 0.6\times 8 - 10 = 8.4 + 4.8 - 10 = 3.2$$

$$P(Y=1) = \frac{1}{1+e^{-3.2}} \approx 0.961 > 0.5 \Rightarrow \text{预测标签} = 1$$

3.7 线性判别分析（LDA）

3.7.1 核心思想

通过投影向量 $\mathbf{w}$ 将样本投影到一维空间，使投影后**两类均值差最大、类内方差和最小**。

3.7.2 投影计算

样本 $\mathbf{x}$ 的投影值：$z = \mathbf{w}^T\mathbf{x}$

3.7.3 均值与方差

设两类样本的原始均值为 $\tilde{\mu}_0, \tilde{\mu}_1$，协方差矩阵为 Σ_0, Σ_1。
投影后：

$$\text{类均值：} \quad \mu_i = \mathbf{w}^T\tilde{\mu}_i \tag{15}$$

$$\text{类方差：} \quad \sigma_i^2 = \mathbf{w}^T\Sigma_i\mathbf{w} \tag{16}$$

3.7.4 目标函数

最大化类间分离度：

$$J(\mathbf{w}) = \frac{(\mu_1 - \mu_0)^2}{\sigma_1^2 + \sigma_0^2} = \frac{\mathbf{w}^T(\tilde{\mu}_1 - \tilde{\mu}_0)(\tilde{\mu}_1 - \tilde{\mu}_0)^T\mathbf{w}}{\mathbf{w}^T(\Sigma_1 + \Sigma_0)\mathbf{w}}$$

定义：

- 类间散度矩阵：$S_b = (\tilde{\mu}_1 - \tilde{\mu}_0)(\tilde{\mu}_1 - \tilde{\mu}_0)^T$
- 类内散度矩阵：$S_w = \Sigma_0 + \Sigma_1$

则目标函数为：

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_b\mathbf{w}}{\mathbf{w}^T S_w\mathbf{w}}$$

3.7.5 最优解

$$\mathbf{w}^* = S_w^{-1}(\tilde{\mu}_1 - \tilde{\mu}_0)$$

3.8 多分类扩展策略

表 3: 二分类器扩展多分类策略

策略	核心思路	分类器数量
一对一（OvO）	每两类训练一个分类器，投票	$C_k^2 = \frac{k(k-1)}{2}$
一对多（OvR）	每类对其他所有类，取概率最大	k
多对多（MvM）	类别划分为子集组合	自定义

4 决策树

4.1 基本概念

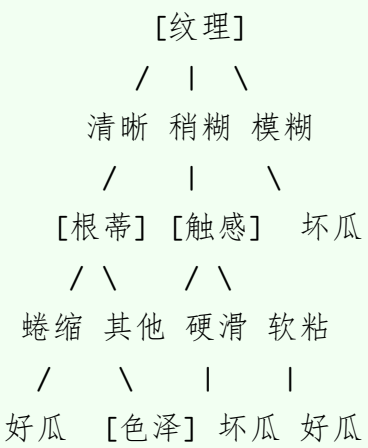
定义 4.1 (决策树结构). 决策树由以下部分组成：

- **根节点**：最顶层节点，对应第一个划分属性
- **内部节点**：对应特征属性
- **叶节点**：对应类别标签
- **分支**：对应属性的取值

一条从根到叶的路径对应一条分类规则。

西瓜数据集决策树示例

以西瓜数据集为例，一个可能的决策树：



4.2 属性划分准则

决策树构建的关键是选择最优属性，核心目标是**降低样本标签的不确定性**。

4.2.1 信息熵

定义 4.2 (信息熵). 信息熵衡量样本集合的不确定性：

$$Ent(D) = -\sum_{i=1}^{k} p_i \log_2 p_i$$

其中 p_i 为第 i 类样本占比，k 为类别数。

性质：

- $Ent(D) \geq 0$

- 当所有样本属于同一类时，$Ent(D) = 0$（最确定）
- 当各类样本均匀分布时，$Ent(D)$ 最大（最不确定）

例 4.1 (信息熵计算). 设样本集 D 有 *15* 个样本，其中 *9* 个正例、*6* 个反例。

$$\begin{aligned} p_+ = \frac{9}{15} = 0.6, \quad p_- &= \frac{6}{15} = 0.4 \\ Ent(D) &= -0.6 \log_2 0.6 - 0.4 \log_2 0.4 \\ &= -0.6 \times (-0.737) - 0.4 \times (-1.322) \\ &= 0.442 + 0.529 = 0.971 \end{aligned}$$

4.2.2 信息增益

定义 4.3 (信息增益). 信息增益衡量属性划分后样本集信息熵的减少量：

$$Gain(D, a) = Ent(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} Ent(D^v)$$

其中 V 为属性 a 的取值数，D^v 为属性 a 取第 v 个值的样本子集。

选择准则：选择信息增益最大的属性进行划分。

例题 4.1 (西瓜数据集：信息增益计算). 使用西瓜数据集（*17* 个样本，*8* 个好瓜，*9* 个坏瓜），计算”色泽”属性的信息增益。

解：

步骤 *1*：计算根节点信息熵

$$Ent(D) = -\frac{8}{17} \log_2 \frac{8}{17} - \frac{9}{17} \log_2 \frac{9}{17} = 0.998$$

步骤 *2*：按”色泽”划分

- 青绿（*6* 个）：好瓜 *3* 个，坏瓜 *3* 个

$$Ent(D^{\text{青绿}}) = -\frac{3}{6} \log_2 \frac{3}{6} - \frac{3}{6} \log_2 \frac{3}{6} = 1.0$$

- 乌黑（*6* 个）：好瓜 *4* 个，坏瓜 *2* 个

$$Ent(D^{\text{乌黑}}) = -\frac{4}{6} \log_2 \frac{4}{6} - \frac{2}{6} \log_2 \frac{2}{6} = 0.918$$

- 浅白（*5* 个）：好瓜 *1* 个，坏瓜 *4* 个

$$Ent(D^{\text{浅白}}) = -\frac{1}{5} \log_2 \frac{1}{5} - \frac{4}{5} \log_2 \frac{4}{5} = 0.722$$

步骤 *3*： 计算信息增益

$$\begin{aligned} Gain(D, \text{色泽}) &= Ent(D) - \sum_v \frac{|D^v|}{|D|} Ent(D^v) \\ &= 0.998 - \left(\frac{6}{17} \times 1.0 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722 \right) \\ &= 0.998 - (0.353 + 0.324 + 0.212) \\ &= 0.998 - 0.889 = \boxed{0.109} \end{aligned}$$

4.2.3 信息增益率

定义 4.4 (信息增益率). 信息增益偏向取值多的属性，引入属性固有值进行修正：

$$IV(a) = -\sum_{v=1}^{V} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

信息增益率：

$$Gain_ratio(D, a) = \frac{Gain(D, a)}{IV(a)}$$

例 4.2 (信息增益率计算). 继续上例，计算”色泽”的信息增益率：

$$\begin{aligned} IV(\text{色泽}) &= -\frac{6}{17} \log_2 \frac{6}{17} - \frac{6}{17} \log_2 \frac{6}{17} - \frac{5}{17} \log_2 \frac{5}{17} \\ &= -0.353 \times (-1.503) - 0.353 \times (-1.503) - 0.294 \times (-1.766) \\ &= 0.530 + 0.530 + 0.519 = 1.579 \end{aligned}$$

$$Gain_ratio(D, \text{色泽}) = \frac{0.109}{1.579} = 0.069$$

4.2.4 基尼指数

定义 4.5 (基尼值与基尼指数). 基尼值衡量随机抽取两个样本标签不同的概率：

$$Gini(D) = 1 - \sum_{i=1}^{k} p_i^2$$

基尼指数（划分后加权平均）：

$$Gini_index(D, a) = \sum_{v=1}^{V} \frac{|D^v|}{|D|} Gini(D^v)$$

选择准则： 选择基尼指数最小的属性进行划分。

例题 4.2 (西瓜数据集：基尼指数计算). 计算西瓜数据集按”纹理”属性划分的基尼指数。

解：

步骤 *1*： 按”纹理”划分

- 清晰（9 个）：好瓜 7 个，坏瓜 2 个

$$Gini(D^{\text{清晰}}) = 1 - \left(\frac{7}{9}\right)^2 - \left(\frac{2}{9}\right)^2 = 1 - 0.605 - 0.049 = 0.346$$

- 稍糊（5 个）：好瓜 1 个，坏瓜 4 个

$$Gini(D^{\text{稍糊}}) = 1 - \left(\frac{1}{5}\right)^2 - \left(\frac{4}{5}\right)^2 = 1 - 0.04 - 0.64 = 0.32$$

- 模糊（3 个）：好瓜 0 个，坏瓜 3 个

$$Gini(D^{\text{模糊}}) = 1 - 0^2 - 1^2 = 0$$

步骤 2：计算基尼指数

$$\begin{aligned} Gini_index(D, \text{纹理}) &= \frac{9}{17} \times 0.346 + \frac{5}{17} \times 0.32 + \frac{3}{17} \times 0 \\ &= 0.183 + 0.094 + 0 = \boxed{0.277} \end{aligned}$$

4.3 决策树构建流程

1. 计算所有属性的划分准则（信息增益/增益率/基尼指数）
2. 选择最优属性作为当前节点
3. 按属性取值划分样本，生成子节点
4. 对每个子节点递归执行步骤 1-3
5. 终止条件：
   - 子集样本属于同一类（叶节点标记为该类）
   - 无属性可用（叶节点标记为多数类）
   - 子集为空（叶节点标记为父节点多数类）

4.4 决策树剪枝

表 4: 决策树剪枝策略

类型	核心思路	优缺点
预剪枝	生长过程中提前停止	训练快，有欠拟合风险
后剪枝	先生成完整树，再剪去冗余分支	泛化好，训练开销大

4.5 连续值处理

定义 4.6 (连续属性离散化). 对连续属性 a，将样本按 a 排序后，取相邻值的中点作为候选划分点：

$$t_i = \frac{a_i + a_{i+1}}{2}, \quad i = 1, 2, \cdots, n-1$$

选择最优划分点：

$$t^* = \arg\max_{t_i} Gain(D, a, t_i)$$

4.6 缺失值处理

计算信息增益时，仅考虑有该属性值的样本，权重为" 无缺失值样本占比"：

$$Gain(D, a) = \rho \times Gain(\tilde{D}, a)$$

其中 $\rho = \frac{|\tilde{D}|}{|D|}$，$\tilde{D}$ 为无缺失值的样本子集。

5 神经网络

5.1 感知机模型

5.1.1 核心前提

感知机仅适用于**线性可分**问题，是最简单的神经网络模型。

5.1.2 模型公式

$$y = f\left(w_1 x_1 + w_2 x_2 + \cdots + w_d x_d - \theta\right) \tag{17}$$

$$= f\left(\sum_{i=1}^{d} w_i x_i - \theta\right) \tag{18}$$

$$= f\left(\mathbf{w}^T \mathbf{x} - \theta\right) \tag{19}$$

其中：

- $\mathbf{w} = [w_1, w_2, \cdots, w_d]^T$ 为权重向量
- θ 为阈值（偏置）
- $f(\cdot)$ 为激活函数

5.1.3 常用激活函数

1. **符号函数**（阶跃函数）：

$$sgn(z) = \begin{cases} 1, & z \geq 0 \\ -1, & z < 0 \end{cases}$$

输出离散值，用于简单分类。

2. **Sigmoid 函数**：

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

输出 $(0, 1)$ 区间值，适用于概率输出。

3. **ReLU 函数**：

$$ReLU(z) = \max(0, z)$$

计算简单，缓解梯度消失问题。

4. **Tanh 函数**：

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

输出 $(-1, 1)$ 区间值，零中心化。

5.2 神经网络基本结构

表 5: 神经网络各层特点

层级	核心特点
输入层	无神经元，节点数 = 输入特征数 d
隐层	有神经元，层数和节点数为超参数
输出层	有神经元，回归问题 1 个节点，k 分类问题 k 个节点

5.3 前向传播

前向传播是输入数据从输入层经隐层到输出层的计算过程。

5.3.1 单隐层网络

设输入 $\mathbf{x} \in \mathbb{R}^d$，隐层有 q 个节点。

隐层计算：

$$\text{线性变换：} \quad \mathbf{z} = W^T\mathbf{x} - \mathbf{b} \tag{20}$$

$$\text{激活变换：} \quad \mathbf{a} = \sigma(\mathbf{z}) \tag{21}$$

其中 $W \in \mathbb{R}^{d\times q}$ 为隐层权重矩阵，$\mathbf{b} \in \mathbb{R}^q$ 为隐层偏置向量。

输出层计算：

$$\text{线性变换：} \quad t = \mathbf{v}^T\mathbf{a} - \theta \tag{22}$$

$$\text{激活变换：} \quad y = \sigma(t) \tag{23}$$

其中 $\mathbf{v} \in \mathbb{R}^q$ 为输出层权重向量，θ 为输出层阈值。

整体公式：

$$y = \sigma\left(\mathbf{v}^T\sigma\left(W^T\mathbf{x} - \mathbf{b}\right) - \theta\right)$$

例题 5.1 (前向传播计算). 给定神经网络参数：

- 输入：$\mathbf{x} = [1, 2, 3]^T$
- 隐层权重：$w_{11} = 2, w_{21} = 1, w_{31} = 4; w_{12} = -2, w_{22} = -3, w_{32} = 1$
- 隐层偏置：$b_1 = 14, b_2 = -4$
- 输出层权重：$v_1 = 1, v_2 = 2$
- 输出层阈值：$\theta = 2$
- 激活函数：*Sigmoid* $\sigma(z) = \frac{1}{1+e^{-z}}$

计算网络输出。

解：

步骤 *1*： 隐层输入

$$\begin{aligned} z_1 &= w_{11}x_1 + w_{21}x_2 + w_{31}x_3 - b_1 \\ &= 2 \times 1 + 1 \times 2 + 4 \times 3 - 14 \\ &= 2 + 2 + 12 - 14 = 2 \\ z_2 &= w_{12}x_1 + w_{22}x_2 + w_{32}x_3 - b_2 \\ &= -2 \times 1 + (-3) \times 2 + 1 \times 3 - (-4) \\ &= -2 - 6 + 3 + 4 = -1 \end{aligned}$$

步骤 *2*： 隐层输出

$$a_1 = \sigma(z_1) = \sigma(2) = \frac{1}{1+e^{-2}} \approx 0.8808$$

$$a_2 = \sigma(z_2) = \sigma(-1) = \frac{1}{1+e^{1}} \approx 0.2689$$

步骤 3： 输出层输入

$$\begin{aligned} t &= v_1 a_1 + v_2 a_2 - \theta \\ &= 1 \times 0.8808 + 2 \times 0.2689 - 2 \\ &= 0.8808 + 0.5378 - 2 = -0.5814 \end{aligned}$$

步骤 4： 最终输出

$$y = \sigma(t) = \sigma(-0.5814) = \frac{1}{1 + e^{0.5814}} \approx \boxed{0.3586}$$

5.4 反向传播算法（BP 算法）

5.4.1 核心思想

利用链式法则，从输出层向输入层逐层计算损失函数对各参数的梯度，然后用梯度下降更新参数。

5.4.2 损失函数

对于单个样本 $(\mathbf{x}, y)$，均方误差损失：

$$E = \frac{1}{2}(\hat{y} - y)^2$$

5.4.3 梯度计算（输出层）

设输出层输入为 t，输出为 $\hat{y} = \sigma(t)$。

$$\frac{\partial E}{\partial v_j} = \frac{\partial E}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial t} \cdot \frac{\partial t}{\partial v_j} \tag{24}$$

$$= (\hat{y} - y) \cdot \sigma'(t) \cdot a_j \tag{25}$$

定义输出层误差项：

$$\delta_o = (\hat{y} - y) \cdot \sigma'(t) = (\hat{y} - y) \cdot \hat{y}(1 - \hat{y})$$

则：$\frac{\partial E}{\partial v_j} = \delta_o \cdot a_j$

5.4.4 梯度计算（隐层）

$$\frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial a_j} \cdot \frac{\partial a_j}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_{ij}} \tag{26}$$

$$= \delta_o \cdot v_j \cdot \sigma'(z_j) \cdot x_i \tag{27}$$

定义隐层误差项：

$$\delta_j = \delta_o \cdot v_j \cdot \sigma'(z_j) = \delta_o \cdot v_j \cdot a_j(1 - a_j)$$

则：$\frac{\partial E}{\partial w_{ij}} = \delta_j \cdot x_i$

5.4.5 参数更新

$$v_j \leftarrow v_j - \eta \cdot \delta_o \cdot a_j \tag{28}$$

$$w_{ij} \leftarrow w_{ij} - \eta \cdot \delta_j \cdot x_i \tag{29}$$

$$\theta \leftarrow \theta + \eta \cdot \delta_o \tag{30}$$

$$b_j \leftarrow b_j + \eta \cdot \delta_j \tag{31}$$

其中 η 为学习率。

5.5 梯度下降变体

1. **批量梯度下降（BGD）**：使用全部样本计算梯度

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \cdot \frac{1}{m} \sum_{i=1}^{m} \nabla E_i$$

2. **随机梯度下降（SGD）**：每次使用单个样本

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \cdot \nabla E_i$$

3. **小批量梯度下降（Mini-batch）**：使用小批量样本

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \cdot \frac{1}{|B|} \sum_{i \in B} \nabla E_i$$

6 支持向量机

6.1 线性支持向量机（硬间隔）

6.1.1 核心目标

找到最大化” 间隔” 的分隔超平面，使两类样本被正确分开且距离超平面最远。

6.1.2 模型形式

决策函数：

$$f(\mathbf{x}) = sign(\mathbf{w}^T \mathbf{x} + b)$$

其中 $\mathbf{w}$ 为权重向量，b 为偏置。

6.1.3 间隔推导

点到超平面距离：

对于超平面 $\mathbf{w}^T\mathbf{x}+b=0$，样本 $\mathbf{x}_i$ 到超平面的距离为：

$$d_i=\frac{|\mathbf{w}^T\mathbf{x}_i+b|}{\|\mathbf{w}\|}$$

函数间隔与几何间隔：

定义函数间隔：$\hat{\gamma}_i=y_i(\mathbf{w}^T\mathbf{x}_i+b)$

几何间隔：$\gamma_i=\frac{y_i(\mathbf{w}^T\mathbf{x}_i+b)}{\|\mathbf{w}\|}=\frac{\hat{\gamma}_i}{\|\mathbf{w}\|}$

间隔：

令最小函数间隔为 1（归一化），则间隔为：

$$\gamma=\frac{2}{\|\mathbf{w}\|}$$

6.1.4 优化问题

原始问题：

$$\min_{\mathbf{w},b}\quad \frac{1}{2}\|\mathbf{w}\|^2 \tag{32}$$

$$\text{s.t.}\quad y_i(\mathbf{w}^T\mathbf{x}_i+b)\geq 1,\quad i=1,2,\cdots,m \tag{33}$$

这是一个凸二次规划问题。

例题 6.1 (硬间隔 SVM). 训练样本：正例 $[3,3]^T$、$[4,3]^T$，负例 $[1,1]^T$。求最优分隔超平面。

解：

步骤 *1*： 建立优化问题

$$\begin{aligned}\min\quad & \frac{1}{2}(w_1^2+w_2^2)\\ s.t.\quad & 3w_1+3w_2+b\geq 1\ \text{（正例 1）}\\ & 4w_1+3w_2+b\geq 1\ \text{（正例 2）}\\ & -(w_1+w_2+b)\geq 1\ \text{（负例）}\end{aligned}$$

步骤 *2*： 利用 KKT 条件求解

由对称性和约束条件，可得：

$$w_1^*=0.5$$

$$w_2^*=0.5$$

$$b^*=-2$$

步骤 3：决策函数

$$\boxed{f(\mathbf{x}) = sign(0.5x_1 + 0.5x_2 - 2)}$$

验证：

- $[3,3]^T$：$0.5 \times 3 + 0.5 \times 3 - 2 = 1 \geq 1$
- $[4,3]^T$：$0.5 \times 4 + 0.5 \times 3 - 2 = 1.5 \geq 1$
- $[1,1]^T$：$0.5 \times 1 + 0.5 \times 1 - 2 = -1 \leq -1$

6.2 对偶问题

6.2.1 拉格朗日函数

引入拉格朗日乘子 $\alpha_i \geq 0$：

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\mathbf{w}\|^2 - \sum_{i=1}^{m} \alpha_i \left[y_i(\mathbf{w}^T\mathbf{x}_i + b) - 1\right]$$

6.2.2 对偶问题推导

对 $\mathbf{w}$ 和 b 求偏导并令其为零：

$$\frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^{m} \alpha_i y_i \mathbf{x}_i = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^{m} \alpha_i y_i \mathbf{x}_i \tag{34}$$

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^{m} \alpha_i y_i = 0 \Rightarrow \sum_{i=1}^{m} \alpha_i y_i = 0 \tag{35}$$

代入拉格朗日函数，得对偶问题：

$$\max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \tag{36}$$

$$\text{s.t.} \quad \sum_{i=1}^{m} \alpha_i y_i = 0 \tag{37}$$

$$\alpha_i \geq 0, \quad i = 1, 2, \cdots, m \tag{38}$$

6.2.3 KKT 条件

$$\alpha_i^* \left[y_i(\mathbf{w}^{*T}\mathbf{x}_i + b^*) - 1\right] = 0$$

关键性质：

- $\alpha_i^* > 0$ 的样本称为**支持向量**，位于间隔边界上
- $\alpha_i^* = 0$ 的样本不影响决策函数

6.2.4 参数求解

$$\mathbf{w}^* = \sum_{i=1}^{m} \alpha_i^* y_i \mathbf{x}_i \tag{39}$$

$$b^* = y_j - \sum_{i=1}^{m} \alpha_i^* y_i \mathbf{x}_i^T \mathbf{x}_j \quad \text{（任选 } \alpha_j^* > 0 \text{ 的样本）} \tag{40}$$

6.3 核函数方法（非线性 SVM）

6.3.1 核心思路

对于线性不可分问题，将样本映射到高维空间，使其线性可分。

设映射函数 $\phi : \mathbb{R}^d \to \mathbb{R}^D$（$D \gg d$），则在高维空间中：

$$f(\mathbf{x}) = sign\left(\mathbf{w}^T \phi(\mathbf{x}) + b\right)$$

6.3.2 核技巧

定义核函数：

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

核函数直接计算高维空间内积，无需显式定义映射函数。

6.3.3 常用核函数

表 6: 常用核函数

核函数	表达式
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$
高斯核（RBF）	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|}{\sigma}\right)$
Sigmoid 核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^T \mathbf{x}_j + \theta)$

6.3.4 核化对偶问题

$$\max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \kappa(\mathbf{x}_i, \mathbf{x}_j) \tag{41}$$

$$\text{s.t.} \quad \sum_{i=1}^{m} \alpha_i y_i = 0, \quad \alpha_i \geq 0 \tag{42}$$

6.3.5 决策函数

$$f(\mathbf{x}) = sign\left(\sum_{i=1}^{m} \alpha_i^* y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b^*\right)$$

6.4 软间隔支持向量机

6.4.1 核心改进

引入松弛变量 $\xi_i \geq 0$，允许部分样本跨越间隔线（容错）。

6.4.2 优化问题

$$\min_{\mathbf{w},b,\boldsymbol{\xi}} \quad \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m}\xi_i \tag{43}$$

$$\text{s.t.} \quad y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1 - \xi_i \tag{44}$$

$$\xi_i \geq 0, \quad i = 1, 2, \cdots, m \tag{45}$$

其中 $C > 0$ 为惩罚系数：

- C 越大，对误分类惩罚越重，间隔越小
- C 越小，对误分类容忍度越高，间隔越大

6.4.3 对偶问题

$$\max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m}\alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \mathbf{x}_i^T\mathbf{x}_j \tag{46}$$

$$\text{s.t.} \quad \sum_{i=1}^{m}\alpha_i y_i = 0 \tag{47}$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \cdots, m \tag{48}$$

与硬间隔的区别：约束条件变为 $0 \leq \alpha_i \leq C$。

7 贝叶斯分类器

7.1 贝叶斯定理

定理 7.1 (贝叶斯定理). *对于分类问题，样本 $\mathbf{x}$ 属于类别 c 的后验概率为：*

$$P(Y = c|X = \mathbf{x}) = \frac{P(Y = c) \cdot P(X = \mathbf{x}|Y = c)}{P(X = \mathbf{x})}$$

其中：

- $P(Y = c)$：类先验概率（类别 c 的样本占比）
- $P(X = \mathbf{x}|Y = c)$：类条件概率（类别 c 下观测到 $\mathbf{x}$ 的概率）
- $P(X = \mathbf{x})$：证据因子（所有类别共享，比较时可忽略）

贝叶斯决策规则：

$$\hat{y} = \arg\max_c P(Y = c|X = \mathbf{x}) = \arg\max_c P(Y = c) \cdot P(X = \mathbf{x}|Y = c)$$

7.2 朴素贝叶斯假设

定义 7.1 (属性条件独立性假设). 给定类别标签时，各特征属性相互独立：

$$P(X = \mathbf{x}|Y = c) = \prod_{i=1}^{d} P(X_i = x_i|Y = c)$$

这大幅简化了类条件概率的计算。

7.3 离散属性朴素贝叶斯

7.3.1 核心思想

离散特征的概率通过训练样本的**频次统计**估算。

7.3.2 计算步骤

1. **计算类先验概率：**
$$P(Y = c) = \frac{|D_c|}{|D|}$$
其中 $|D_c|$ 为类别 c 的样本数，$|D|$ 为总样本数。

2. **计算属性条件概率：**
$$P(X_i = x_i|Y = c) = \frac{|D_{c,x_i}|}{|D_c|}$$
其中 $|D_{c,x_i}|$ 为类别 c 中属性 X_i 取值为 x_i 的样本数。

3. **计算后验概率：**
$$P(Y = c|X = \mathbf{x}) \propto P(Y = c) \prod_{i=1}^{d} P(X_i = x_i|Y = c)$$

4. **预测：**选择后验概率最大的类别。

例题 7.1 (西瓜数据集：朴素贝叶斯分类). 使用西瓜数据集（17 个样本），预测样本”色泽 = 青绿，根蒂 = 蜷缩，敲声 = 浊响”是否为好瓜。

解：

步骤 1： 统计类先验概率

$$P(Y = \text{好瓜}) = \frac{8}{17} \approx 0.471$$
$$P(Y = \text{坏瓜}) = \frac{9}{17} \approx 0.529$$

步骤 2： 统计属性条件概率

对于好瓜（8 个样本）：

$$P(\text{色泽} = \text{青绿}|\text{好瓜}) = \frac{3}{8} = 0.375$$
$$P(\text{根蒂} = \text{蜷缩}|\text{好瓜}) = \frac{5}{8} = 0.625$$
$$P(\text{敲声} = \text{浊响}|\text{好瓜}) = \frac{6}{8} = 0.75$$

对于坏瓜（9 个样本）：

$$P(\text{色泽} = \text{青绿}|\text{坏瓜}) = \frac{3}{9} = 0.333$$
$$P(\text{根蒂} = \text{蜷缩}|\text{坏瓜}) = \frac{3}{9} = 0.333$$
$$P(\text{敲声} = \text{浊响}|\text{坏瓜}) = \frac{4}{9} = 0.444$$

步骤 3： 计算后验概率

$$\begin{aligned} P(\text{好瓜}) \prod P(x_i|\text{好瓜}) &= 0.471 \times 0.375 \times 0.625 \times 0.75 \\ &= 0.471 \times 0.176 = 0.083 \\ P(\text{坏瓜}) \prod P(x_i|\text{坏瓜}) &= 0.529 \times 0.333 \times 0.333 \times 0.444 \\ &= 0.529 \times 0.049 = 0.026 \end{aligned}$$

步骤 4： 预测结果

由于 $0.083 > 0.026$，预测该样本为**好瓜**。

7.4 拉普拉斯平滑

零概率问题

当某个属性值在训练集中未出现时，会导致 $P(X_i = x_i|Y = c) = 0$，使整个后验概率为 0。

定义 7.2 (拉普拉斯平滑). 为避免零概率问题，引入平滑：

$$P(Y=c)=\frac{|D_c|+1}{|D|+K} \tag{49}$$

$$P(X_i=x_i|Y=c)=\frac{|D_{c,x_i}|+1}{|D_c|+N_i} \tag{50}$$

其中 K 为类别数，N_i 为属性 X_i 的取值数。

7.5 连续属性朴素贝叶斯

7.5.1 核心思想

假设每个连续属性在各类别下服从**正态分布**，用概率密度函数替代离散概率。

7.5.2 计算步骤

1. **估算正态分布参数：**

   对每个类别 c 和特征 X_i，计算均值和方差：

$$\mu_{c,i}=\frac{1}{|D_c|}\sum_{\mathbf{x}\in D_c}x_i \tag{51}$$

$$\sigma_{c,i}^2=\frac{1}{|D_c|}\sum_{\mathbf{x}\in D_c}(x_i-\mu_{c,i})^2 \tag{52}$$

2. **计算属性条件概率密度：**

$$p(X_i=x_i|Y=c)=\frac{1}{\sqrt{2\pi}\sigma_{c,i}}\exp\left(-\frac{(x_i-\mu_{c,i})^2}{2\sigma_{c,i}^2}\right)$$

3. **计算后验概率：**

$$P(Y=c|X=\mathbf{x})\propto P(Y=c)\prod_{i=1}^{d}p(X_i=x_i|Y=c)$$

例题 7.2 (连续属性朴素贝叶斯). 给定训练数据（*10* 个样本，*2* 个连续特征）：

X_1	X_2	Y	X_1	X_2	Y
0.1	*5.0*	*-1*	*0.5*	*4.5*	*+1*
0.2	*5.5*	*-1*	*0.6*	*4.0*	*+1*
0.15	*5.2*	*-1*	*0.55*	*4.2*	*+1*
0.25	*5.3*	*-1*	*0.45*	*4.8*	*+1*
0.18	*5.1*	*-1*	*0.52*	*4.3*	*+1*

预测样本 $[0.21, 5.2]^T$ 的类别。

解：

步骤 *1*： 计算类先验概率

$$P(Y=-1) = P(Y=+1) = \frac{5}{10} = 0.5$$

步骤 *2*： 估算正态分布参数

对于 $Y=-1$：

$$\mu_{-1,1} = \frac{0.1+0.2+0.15+0.25+0.18}{5} = 0.176$$
$$\sigma^2_{-1,1} = \frac{(0.1-0.176)^2+\cdots+(0.18-0.176)^2}{5} = 0.00283$$
$$\mu_{-1,2} = \frac{5.0+5.5+5.2+5.3+5.1}{5} = 5.22$$
$$\sigma^2_{-1,2} = \frac{(5.0-5.22)^2+\cdots+(5.1-5.22)^2}{5} = 0.0296$$

对于 $Y=+1$：

$$\mu_{+1,1} = \frac{0.5+0.6+0.55+0.45+0.52}{5} = 0.524$$
$$\sigma^2_{+1,1} = 0.00283$$
$$\mu_{+1,2} = \frac{4.5+4.0+4.2+4.8+4.3}{5} = 4.36$$
$$\sigma^2_{+1,2} = 0.0824$$

步骤 *3*： 计算概率密度

对于 $Y=-1$，$\mathbf{x}=[0.21, 5.2]^T$：

$$p(X_1=0.21|Y=-1) = \frac{1}{\sqrt{2\pi\times 0.00283}}\exp\left(-\frac{(0.21-0.176)^2}{2\times 0.00283}\right)$$
$$\approx 6.12$$
$$p(X_2=5.2|Y=-1) = \frac{1}{\sqrt{2\pi\times 0.0296}}\exp\left(-\frac{(5.2-5.22)^2}{2\times 0.0296}\right)$$
$$\approx 2.31$$

对于 $Y=+1$：

$$p(X_1=0.21|Y=+1) \approx 0.0001 \text{ （远离均值）}$$
$$p(X_2=5.2|Y=+1) \approx 0.0003 \text{ （远离均值）}$$

步骤 *4*： 计算后验概率

$$P(Y=-1)\cdot p(\mathbf{x}|Y=-1) = 0.5\times 6.12\times 2.31 \approx 7.07$$
$$P(Y=+1)\cdot p(\mathbf{x}|Y=+1) = 0.5\times 0.0001\times 0.0003 \approx 0$$

预测结果： $\boxed{Y=-1}$

A 西瓜数据集 2.0

西瓜数据集是机器学习领域常用的示例数据集，包含 17 个样本，6 个离散特征，1 个二分类标签。

表 7: 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

A.1 数据集统计信息

A.1.1 类别分布

- 好瓜（正例）：8 个样本（编号 1-8）
- 坏瓜（反例）：9 个样本（编号 9-17）

A.1.2 属性取值统计

表 8: 属性取值分布

属性	取值	数量
色泽	青绿	6
	乌黑	6
	浅白	5
根蒂	蜷缩	8
	稍蜷	7
	硬挺	2
敲声	浊响	10
	沉闷	5
	清脆	2
纹理	清晰	9
	稍糊	5
	模糊	3
脐部	凹陷	7
	稍凹	6
	平坦	4
触感	硬滑	12
	软粘	5

A.1.3 各属性在不同类别下的分布

表 9: 属性条件概率统计（用于朴素贝叶斯）

属性	取值	好瓜中数量	坏瓜中数量
色泽	青绿	3	3
	乌黑	4	2
	浅白	1	4
根蒂	蜷缩	5	3
	稍蜷	3	4
	硬挺	0	2
敲声	浊响	6	4
	沉闷	2	3
	清脆	0	2
纹理	清晰	7	2
	稍糊	1	4
	模糊	0	3
脐部	凹陷	6	1
	稍凹	2	4
	平坦	0	4
触感	硬滑	6	6
	软粘	2	3