机器学习

第 3 章 线性模型

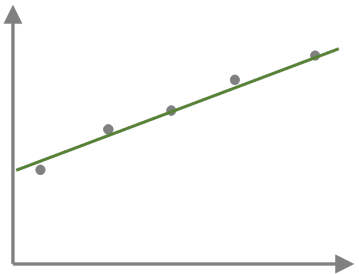
詹大为

计算机与人工智能学院

zhandawei@swjtu.edu.cn

1. 线性回归模型：一元线性回归

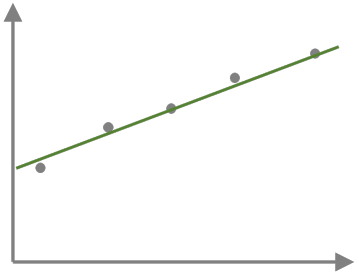
x	y
1	4.5
2	7.1
3	9.9
4	11.9
5	12.3



模型：$f = w_1 x + w_2$

1. 线性回归模型：一元线性回归

x	y	f
1	4.5	$w_1 + w_2$
2	7.1	$2w_1 + w_2$
3	9.9	$3w_1 + w_2$
4	11.9	$4w_1 + w_2$
5	12.3	$5w_1 + w_2$

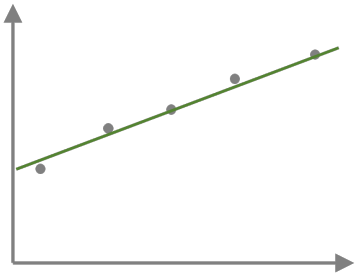


损失函数：

$$Loss(w_1, w_2) = (w_1 + w_2 - 4.5)^2 + (2w_1 + w_2 - 7.1)^2 + (3w_1 + w_2 - 9.9)^2 + (4w_1 + w_2 - 11.9)^2 + (5w_1 + w_2 - 12.3)^2$$

1. 线性回归模型：一元线性回归

x	y	f
1	4.5	$w_1 + w_2$
2	7.1	$2w_1 + w_2$
3	9.9	$3w_1 + w_2$
4	11.9	$4w_1 + w_2$
5	12.3	$5w_1 + w_2$

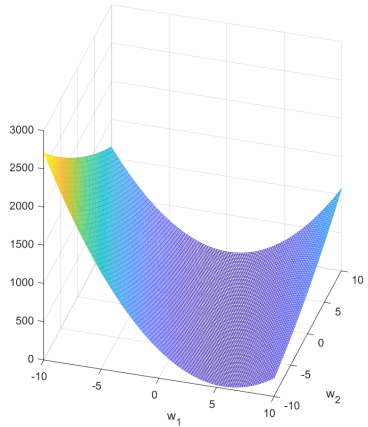


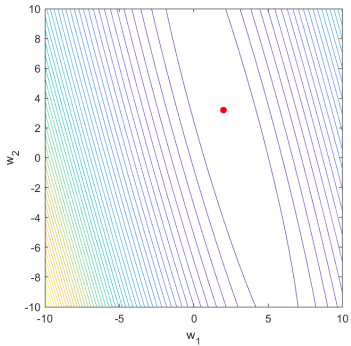
损失函数：

$$Loss(w_1, w_2) = 55w_1^2 + 5w_2^2 + 30w_1w_2 - 315w_1 - 91.4w_2 + 461.57$$

1. 线性回归模型：一元线性回归

$$Loss(w_1, w_2) = 55w_1^2 + 5w_2^2 + 30w_1w_2 - 315w_1 - 91.4w_2 + 461.57$$





$Loss(w_1, w_2)$ 是**凸函数**，如何证明？

全局最优解、局部最优解

(1) $\boldsymbol{x}^\star \in \mathbb{R}^d$，$\forall \boldsymbol{x} \in \mathbb{R}^d$，$f(\boldsymbol{x}^\star) \leq f(\boldsymbol{x})$，$\boldsymbol{x}^\star$ 为全局最优解，$f(\boldsymbol{x}^\star)$ 是全局最小值。

(2) $\boldsymbol{x}^\star \in \mathbb{R}^d$，$\forall \boldsymbol{x} \in \{\boldsymbol{x} \mid \|\boldsymbol{x} - \boldsymbol{x}^\star\| \leq \epsilon\}$，$f(\boldsymbol{x}^\star) \leq f(\boldsymbol{x})$，$\boldsymbol{x}^\star$ 为局部最优解，$f(\boldsymbol{x}^\star)$ 是局部最小值。

向量范数：$\|\boldsymbol{x}\|_p = (|x_1|^p + |x_2|^p + \cdots + |x_d|^p)^{\frac{1}{p}} = \left(\sum_{i=1}^{d} |x_i|^p\right)^{\frac{1}{p}}$，$p > 0$

(1) 1 范数：$\|\boldsymbol{x}\|_1 = \sum_{i=1}^{d} |x_i|$

(2) 2 范数：$\|\boldsymbol{x}\|_2 = \sqrt{\sum_{i=1}^{d} x_i^2}$

(3) ∞ 范数：$\|\boldsymbol{x}\|_\infty = \max_{i=1}^{d} |x_i|$

全局最优解、局部最优解

(1) $\boldsymbol{x}^\star \in \mathbb{R}^d$，$\forall \boldsymbol{x} \in \mathbb{R}^d$，$f(\boldsymbol{x}^\star) \leq f(\boldsymbol{x})$，$\boldsymbol{x}^\star$ 为全局最优解，$f(\boldsymbol{x}^\star)$ 是全局最小值。

(2) $\boldsymbol{x}^\star \in \mathbb{R}^d$，$\forall \boldsymbol{x} \in \{\boldsymbol{x} \mid \|\boldsymbol{x} - \boldsymbol{x}^\star\| \leq \epsilon\}$，$f(\boldsymbol{x}^\star) \leq f(\boldsymbol{x})$，$\boldsymbol{x}^\star$ 为局部最优解，$f(\boldsymbol{x}^\star)$ 是局部最小值。

向量范数：$\|\boldsymbol{x}\|_p = (|x_1|^p + |x_2|^p + \cdots + |x_d|^p)^{\frac{1}{p}} = \left(\sum_{i=1}^{d} |x_i|^p\right)^{\frac{1}{p}}$，$p > 0$。

(1) 正定性：$\|\boldsymbol{x}\|_p \geq 0$，当且仅当 $\boldsymbol{x} = \boldsymbol{0}$，$\|\boldsymbol{x}\|_p = 0$。

(2) 齐次性：$\|a\boldsymbol{x}\|_p = |a| \cdot \|\boldsymbol{x}\|_p$。

(3) 三角不等式：$\|\boldsymbol{x} + \boldsymbol{y}\|_p \leq \|\boldsymbol{x}\|_p + \|\boldsymbol{y}\|_p$。

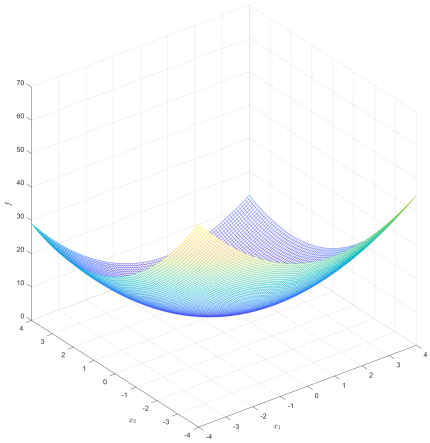
凸优化问题：定义

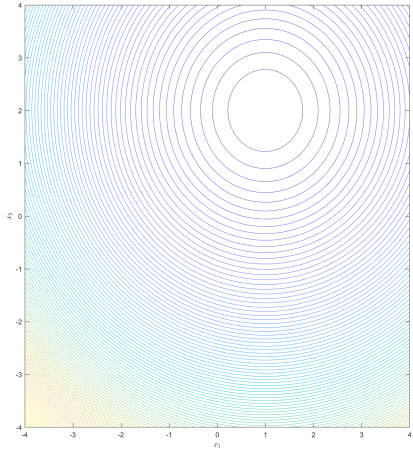
$$\begin{aligned} \text{minimize:} \quad & f(\boldsymbol{x}) \\ \text{subject to:} \quad & \boldsymbol{x} \in \mathcal{S} \end{aligned}$$

若可行域 $\mathcal{S}$ 为**凸集**，$f(\boldsymbol{x})$ 为**凸函数**，该优化问题为**凸优化问题**。

优化问题

$$\text{minimize:} \quad f(\boldsymbol{x}) = (x_1 - 1)^2 + (x_2 - 2)^2$$

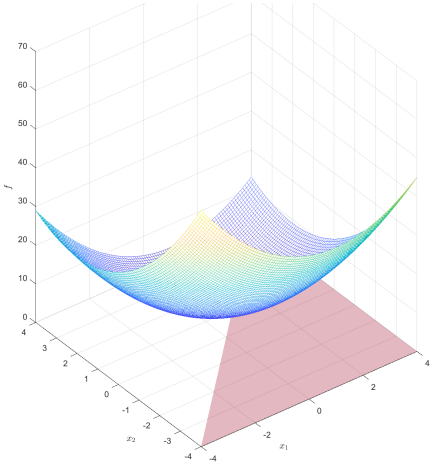


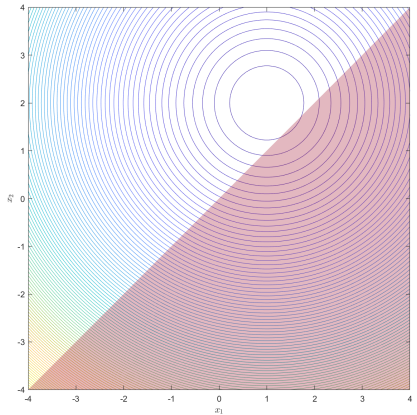


优化问题

$$\text{minimize:} \quad f(\boldsymbol{x}) = (x_1 - 1)^2 + (x_2 - 2)^2$$

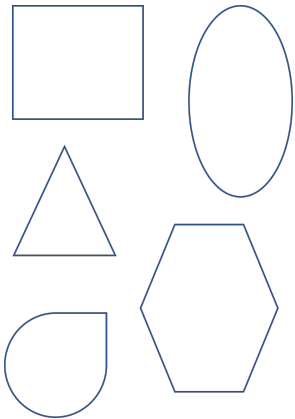
$$\text{subject to:} \quad x_1 \geq x_2$$



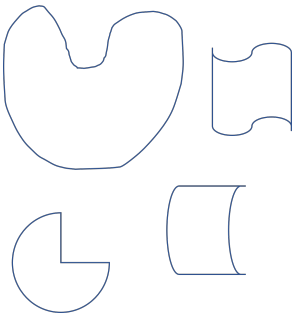


凸优化问题：凸集

$\forall \boldsymbol{x}_1, \boldsymbol{x}_2 \in \mathcal{S}$，$\forall \theta \in [0,1]$，都有 $\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2 \in \mathcal{S}$，则 $\mathcal{S}$ 为凸集。



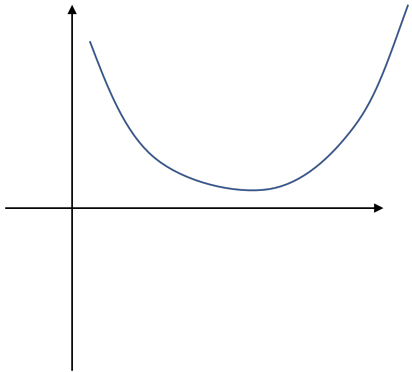
凸集



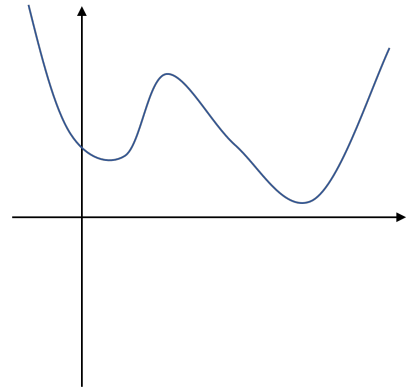
非凸集

凸优化问题：凸函数

$\forall \boldsymbol{x}_1, \boldsymbol{x}_2 \in \mathcal{S}$，$\forall \theta \in [0,1]$，都有 $f(\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2) \leq \theta f(\boldsymbol{x}_1) + (1-\theta) f(\boldsymbol{x}_2)$，则 $f(\boldsymbol{x})$ 为凸函数。



凸函数



非凸函数

凸优化问题：性质

性质：**凸优化问题的所有局部最优解都是全局最优解。**

反证法：

1. 假设 $\boldsymbol{x}_1$ 为局部最优解，$\boldsymbol{x}_2$ 为全局最优解，且 $\boldsymbol{x}_1 \neq \boldsymbol{x}_2$，有 $f(\boldsymbol{x}_1) > f(\boldsymbol{x}_2)$。
2. 由 $f(\boldsymbol{x})$ 是凸函数，得 $\forall \theta \in [0,1]$，$f(\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2) \leq \theta f(\boldsymbol{x}_1) + (1-\theta) f(\boldsymbol{x}_2)$。
3. 由 $f(\boldsymbol{x}_1) > f(\boldsymbol{x}_2)$，得 $f(\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2) < \theta f(\boldsymbol{x}_1) + (1-\theta) f(\boldsymbol{x}_1)$。
4. 得 $f(\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2) < f(\boldsymbol{x}_1)$。
5. 取 $\theta \to 1$ 但 $\theta \neq 1$, 得 $\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2$ 在 $\boldsymbol{x}_1$ 的邻域。
6. 与 $\boldsymbol{x}_1$ 是局部最优解冲突。

凸优化问题：常见凸集

(1) $\mathcal{S}=\mathbb{R}^d$，实数域是凸集。

(2) $\mathcal{S}=\{\boldsymbol{x}\mid \boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}\leq b\}$，半空间是凸集。

证明 (2)：

$$
\begin{aligned}
&\forall \boldsymbol{x}_1,\boldsymbol{x}_2\in\mathcal{S},\forall\theta\in[0,1],\ \boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}_1\leq b,\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}_2\leq b\\
&\quad \boldsymbol{a}^{\mathrm{T}}\left[\theta\boldsymbol{x}_1+(1-\theta)\boldsymbol{x}_2\right]=\theta\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}_1+(1-\theta)\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}_2\\
&\qquad\qquad\qquad\qquad\leq \theta b+(1-\theta)b\\
&\qquad\qquad\qquad\qquad= b
\end{aligned}
$$

所以 $\theta\boldsymbol{x}_1+(1-\theta)\boldsymbol{x}_2\in\mathcal{S}$，$\mathcal{S}$ 为凸集。

凸优化问题：常见凸函数

(1) $f(\boldsymbol{x}) = \boldsymbol{a}^{\mathrm{T}}\boldsymbol{x} + b$，线性函数是凸函数。

(2) $f(\boldsymbol{x}) = \|\boldsymbol{x}\|$，范数函数是凸函数。

证明 (1)：

$$
\begin{aligned}
&\forall \boldsymbol{x}_1, \boldsymbol{x}_2 \in \mathcal{S}, \forall \theta \in [0,1] \\
&\quad f\left(\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2\right) = \boldsymbol{a}^{\mathrm{T}}\left[\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2\right] + b \\
&\qquad\qquad = \theta \boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}_1 + (1-\theta)\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}_2 + \theta b + (1-\theta)b \\
&\qquad\qquad = \theta\left(\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}_1 + b\right) + (1-\theta)\left(\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}_2 + b\right) \\
&\qquad\qquad = \theta f(\boldsymbol{x}_1) + (1-\theta) f(\boldsymbol{x}_2)
\end{aligned}
$$

所以 $f(\boldsymbol{x}) = \boldsymbol{a}^{\mathrm{T}}\boldsymbol{x} + b$ 是凸函数。

凸优化问题：常见凸函数

(1) $f(\boldsymbol{x}) = \boldsymbol{a}^{\mathrm{T}}\boldsymbol{x} + b$，线性函数是凸函数。

(2) $f(\boldsymbol{x}) = \|\boldsymbol{x}\|$，范数函数是凸函数。

证明 (2)：

$$
\begin{aligned}
&\forall \boldsymbol{x}_1, \boldsymbol{x}_2 \in \mathcal{S}, \forall \theta \in [0,1] \\
&\quad f\left(\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2\right) = \|\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2\| \\
&\qquad\qquad \leq \theta\|\boldsymbol{x}_1\| + (1-\theta)\|\boldsymbol{x}_2\| \\
&\qquad\qquad = \theta f(\boldsymbol{x}_1) + (1-\theta) f(\boldsymbol{x}_2)
\end{aligned}
$$

所以 $f(\boldsymbol{x}) = \|\boldsymbol{x}\|$ 是凸函数。

凸优化问题：凸函数二阶判定条件

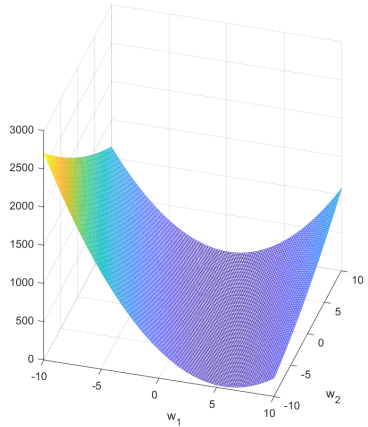
二阶判定条件：$f(\boldsymbol{x})$ 二阶导数存在，若 $\nabla^2 f(\boldsymbol{x})$ 为半正定矩阵，则 $f(\boldsymbol{x})$ 为凸函数。

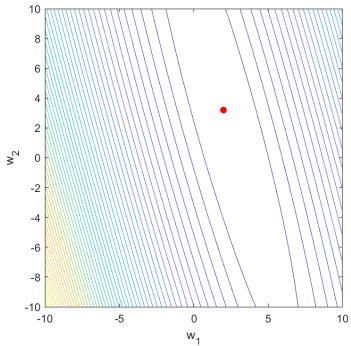
半正定矩阵定义：$d \times d$ 对称矩阵 $\boldsymbol{A}$，$\forall \boldsymbol{x} \in \mathbb{R}^d$，都有 $\boldsymbol{x}^{\mathrm{T}} \boldsymbol{A} \boldsymbol{x} \geq 0$，则 $\boldsymbol{A}$ 为半正定矩阵。

半正定矩阵判定：$\lambda_1, \lambda_2, \cdots, \lambda_d$ 为 $\boldsymbol{A}$ 的特征值，若 $\lambda_1, \lambda_2, \cdots, \lambda_d \geq 0$，则 $\boldsymbol{A}$ 为半正定矩阵。

1. 线性回归模型：一元线性回归

$$Loss(w_1, w_2) = 55w_1^2 + 5w_2^2 + 30w_1w_2 - 315w_1 - 91.4w_2 + 461.57$$





$Loss(w_1, w_2)$ 是**凸函数**，如何证明？

1. 线性回归模型：作业 2

$$Loss(w_1, w_2) = 55w_1^2 + 5w_2^2 + 30w_1w_2 - 315w_1 - 91.4w_2 + 461.57$$

证明 $Loss(w_1, w_2)$ 是凸函数？

$$\nabla^2 Loss = \begin{bmatrix} 110 & 30 \\ 30 & 10 \end{bmatrix}$$

对任意 $\boldsymbol{x} = [x_1, x_2]^{\mathrm{T}}$

$$\boldsymbol{x}^{\mathrm{T}} \left(\nabla^2 Loss\right) \boldsymbol{x} = (10x_1 + 3x_2)^2 + 10x_1^2 + x_2^2 \geq 0$$

$\nabla^2 Loss$ 半正定矩阵，$Loss(w_1, w_2)$ 是凸函数。

1. 线性回归模型：一元线性回归

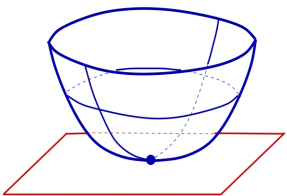
求解损失函数：

$$Loss(w_1, w_2) = 55w_1^2 + 5w_2^2 + 30w_1w_2 - 315w_1 - 91.4w_2 + 461.57$$

利用导数与驻点的关系：$\nabla Loss = \mathbf{0}$

1. 线性回归模型：驻点的性质

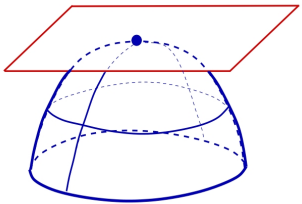
$\nabla f(\boldsymbol{x}) = \mathbf{0}$ 对应的点为驻点，可能是：局部最小值点、局部最大值点、鞍点。



$f = x_1^2 + x_2^2$

$$\nabla^2 f = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

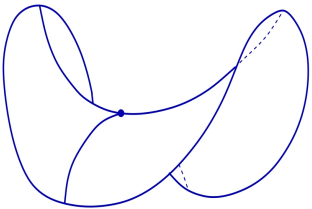
$\nabla^2 f$ 正定



$f = -x_1^2 - x_2^2$

$$\nabla^2 f = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix}$$

$\nabla^2 f$ 负定



$f = x_1^2 - x_2^2$

$$\nabla^2 f = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$$

$\nabla^2 f$ 不定

1. 线性回归模型：一元线性回归

$$Loss(w_1, w_2) = 55w_1^2 + 5w_2^2 + 30w_1w_2 - 315w_1 - 91.4w_2 + 461.57$$

利用导数与驻点的性质：

$$\frac{\partial Loss}{\partial w_1} = 110w_1 + 30w_2 - 315 = 0$$

$$\frac{\partial Loss}{\partial w_2} = 30w_1 + 10w_2 - 91.4 = 0$$

求得：$w_1^\star = 2.04, w_2^\star = 3.02$。

$$\nabla^2 Loss = \begin{bmatrix} 110 & 30 \\ 30 & 10 \end{bmatrix}$$

$\nabla^2 Loss$ 为正定矩阵，这个解是局部最小解

$Loss(w_1, w_2)$ 凸函数，这个解是全局最小解。

训练好的模型：$f = 2.04x + 3.02$

1. 线性回归模型：多元线性回归

模型：$f = w_1x_1 + w_2x_2 + w_3x_3 + \cdots + w_dx_d + w_{d+1}$

训练数据：

$$\left\{ \begin{array}{c} (\boldsymbol{x}_1, y_1) \\ (\boldsymbol{x}_2, y_2) \\ \cdots \\ (\boldsymbol{x}_m, y_m) \end{array} \right\}$$

损失函数：

$$\begin{aligned} Loss = & (w_1x_{11} + w_2x_{12} + \cdots + w_dx_{1d} + w_{d+1} - y_1)^2 \\ & + (w_1x_{21} + w_2x_{22} + \cdots + w_dx_{2d} + w_{d+1} - y_2)^2 \\ & \cdots \\ & + (w_1x_{m1} + w_2x_{m2} + \cdots + w_dx_{md} + w_{d+1} - y_m)^2 \end{aligned}$$

1. 线性回归模型：多元线性回归

$$
\begin{aligned}
Loss = &(w_1 x_{11} + w_2 x_{12} + \cdots + w_d x_{1d} + w_{d+1} - y_1)^2 \\
&+ (w_1 x_{21} + w_2 x_{22} + \cdots + w_d x_{2d} + w_{d+1} - y_2)^2 \\
&\cdots \\
&+ (w_1 x_{m1} + w_2 x_{m2} + \cdots + w_d x_{md} + w_{d+1} - y_m)^2
\end{aligned}
$$

$$
\boldsymbol{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & & & & \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{bmatrix} \qquad \boldsymbol{w} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_{d+1} \end{bmatrix} \qquad \boldsymbol{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}
$$

$$
Loss(\boldsymbol{w}) = (\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})
$$

1. 线性回归模型：多元线性回归

证明 $Loss(\boldsymbol{w}) = (\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})$ 是凸函数？

$$\nabla Loss(\boldsymbol{w}) = 2\boldsymbol{X}^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})$$

$$\nabla^2 Loss(\boldsymbol{w}) = 2\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}$$

对任意 $\boldsymbol{x}$

$$\boldsymbol{x}^{\mathrm{T}}\left(2\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}\right)\boldsymbol{x} = 2\left(\boldsymbol{X}\boldsymbol{x}\right)^{\mathrm{T}}\left(\boldsymbol{X}\boldsymbol{x}\right) \geq 0$$

1. 线性回归模型：多元线性回归

求解 $Loss(\boldsymbol{w}) = (\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})$？

$$\nabla Loss(\boldsymbol{w}) = 2\boldsymbol{X}^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y}) = \boldsymbol{0}$$

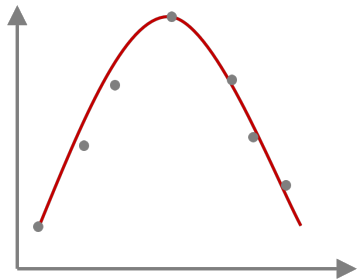
解得：

$$\boldsymbol{w}^{\star} = \left(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}\right)^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{y}$$

因为 $\nabla^2 Loss(\boldsymbol{w})$ 是半正定矩阵，所以这个解是局部最小值。

又因为 $Loss(\boldsymbol{w})$ 是凸函数，所以这个解也是全局最小值。

1. 线性回归模型：一元多项式回归



模型：$f = w_1 x^k + w_2 x^{k-1} + \cdots + w_k x + w_{k+1}$

1. 线性回归模型：一元多项式回归

$$
\begin{aligned}
Loss = &\left(w_1 x_1^k + w_2 x_1^{k-1} + \cdots, + w_k x_1 + w_{k+1} - y_1\right)^2 \\
&+ \left(w_1 x_2^k + w_2 x_2^{k-1} + \cdots + w_k x_2 + w_{k+1} - y_2\right)^2 \\
&\cdots \\
&+ \left(w_1 x_m^k + w_2 x_m^{k-1} + \cdots + w_k x_m + w_{k+1} - y_m\right)^2
\end{aligned}
$$

$$
\boldsymbol{X} = \begin{bmatrix} x_1^k & x_1^{k-1} & \cdots & x_1 & 1 \\ x_2^k & x_2^{k-1} & \cdots & x_2 & 1 \\ \vdots & & & & \\ x_m^k & x_m^{k-1} & \cdots & x_m & 1 \end{bmatrix} \qquad \boldsymbol{w} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_{k+1} \end{bmatrix} \qquad \boldsymbol{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}
$$

$$
Loss(\boldsymbol{w}) = (\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})
$$

$$
\boldsymbol{w}^{\star} = \left(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}\right)^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{y}
$$

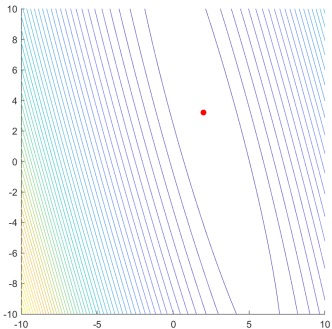
1. 线性回归模型：正则化、Lasso 回归、岭回归

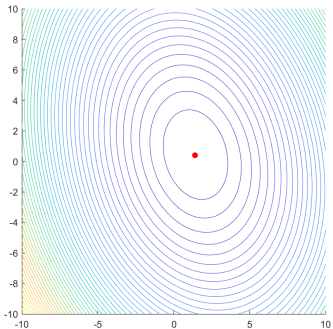
Lasso 回归：

$$Loss(\boldsymbol{w}) = (\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y}) + \lambda \parallel \boldsymbol{w} \parallel_1$$

岭回归：

$$Loss(\boldsymbol{w}) = (\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y}) + \lambda \parallel \boldsymbol{w} \parallel_2^2$$

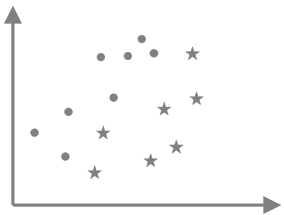


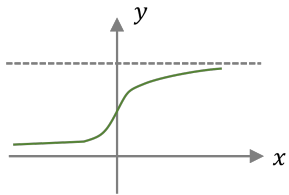


2. 逻辑回归模型：logistic regression

$$f = w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + w_{d+1} = \boldsymbol{w}^{\mathrm{T}} \boldsymbol{x}$$

二分类问题





$$y = \frac{1}{1+e^{-x}}$$

模型：

$$P(Y=1|\boldsymbol{x}) = \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}}}$$

$$P(Y=0|\boldsymbol{x}) = 1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}}}$$

2. 逻辑回归模型：作业 3

现用逻辑回归模型求解一个二分类问题，训练得到的模型：

$$P(Y=1|\boldsymbol{x})=\frac{1}{1+e^{-(1.2x_1+0.6x_2-10)}}$$

计算样本 $[3,4]^{\mathrm{T}}$，$[5,6]^{\mathrm{T}}$，$[7,8]^{\mathrm{T}}$ 的预测标签。
将样本带入到模型

$$P(Y=1|\boldsymbol{x}_1)=\frac{1}{1+e^{-(1.2\times3+0.6\times4-10)}}=0.018<0.5$$
$$P(Y=1|\boldsymbol{x}_2)=\frac{1}{1+e^{-(1.2\times5+0.6\times6-10)}}=0.4013<0.5$$
$$P(Y=1|\boldsymbol{x}_3)=\frac{1}{1+e^{-(1.2\times7+0.6\times8-10)}}=0.9608>0.5$$

所以 $[3,4]^{\mathrm{T}}$，$[5,6]^{\mathrm{T}}$，$[7,8]^{\mathrm{T}}$ 的标签依次是 0，0，1。

2. 逻辑回归模型：logistic regression

模型：

$$P(Y=1|\boldsymbol{x}) = \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}}}$$

$$P(Y=0|\boldsymbol{x}) = 1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}}}$$

训练数据：

$$\left\{ \begin{array}{c} (\boldsymbol{x}_1, y_1) \\ (\boldsymbol{x}_2, y_2) \\ \cdots \\ (\boldsymbol{x}_m, y_m) \end{array} \right\}$$

策略：似然函数

$$L(\boldsymbol{w}) = \prod_{i=1}^{m} \left(\frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right)^{y_i} \left(1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right)^{(1-y_i)}$$

算法：梯度下降

$$\boldsymbol{w}^{\star} = \arg\max L(\boldsymbol{w})$$

2. 逻辑回归模型：logistic regression

似然函数：

$$L(\boldsymbol{w}) = \prod_{i=1}^{m} \left(\frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right)^{y_i} \left(1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right)^{(1-y_i)}$$

取对数：

$$\begin{aligned}
\log L(\boldsymbol{w}) &= \log \left[\prod_{i=1}^{m} \left(\frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right)^{y_i} \left(1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right)^{(1-y_i)} \right] \\
&= \sum_{i=1}^{m} \log \left[\left(\frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right)^{y_i} \left(1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right)^{(1-y_i)} \right] \\
&= \sum_{i=1}^{m} \left[y_i \log \left(\frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right) + (1-y_i) \log \left(1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right) \right]
\end{aligned}$$

求最小值：

$$-\log L(\boldsymbol{w}) = \sum_{i=1}^{m} \left[-y_i \log \left(\frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right) - (1-y_i) \log \left(1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right) \right]$$

2. 逻辑回归模型：logistic regression

$$H(\boldsymbol{w}) = -\log L(\boldsymbol{w})$$

$$H(\boldsymbol{w}) = \sum_{i=1}^{m} \left[-y_i \log \left(\frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right) - (1-y_i) \log \left(1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right) \right]$$

引入 sigmoid 中间变量 $\sigma = \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}}$

$$H(\boldsymbol{w}) = \sum_{i=1}^{m} \left[-y_i \log \sigma - (1-y_i) \log (1-\sigma) \right]$$

$H(\boldsymbol{w})$ 是**凸函数**，如何证明？

1. 已知凸函数相加为凸函数。
2. 若标量 $u(\boldsymbol{x})$ 是 $\boldsymbol{x}$ 的函数，向量 $\boldsymbol{a}$ 不是 $\boldsymbol{x}$ 的函数，则

$$\frac{\partial (u\boldsymbol{a})}{\partial \boldsymbol{x}} = \frac{\partial u}{\partial \boldsymbol{x}} \boldsymbol{a}^{\mathrm{T}}$$

2. 逻辑回归模型：logistic regression

取 $H(\boldsymbol{w})$ 中的第 i 项 $H_i(\boldsymbol{w}) = -y_i \log \sigma - (1-y_i)\log(1-\sigma)$

求梯度：

$$\begin{aligned}\nabla H_i(\boldsymbol{w}) &= -y_i \frac{1}{\sigma}\sigma(1-\sigma)\boldsymbol{x_i} - (1-y_i)\frac{1}{1-\sigma}(-1)\sigma(1-\sigma)\boldsymbol{x_i} \\ &= -y_i \boldsymbol{x_i} + \sigma \boldsymbol{x_i}\end{aligned}$$

求海森矩阵：

$$\nabla^2 H_i(\boldsymbol{w}) = \frac{\partial(\sigma \boldsymbol{x}_i)}{\partial \boldsymbol{w}} = \frac{\partial \sigma}{\partial \boldsymbol{w}} \boldsymbol{x}_i^{\mathrm{T}} = \sigma(1-\sigma)\boldsymbol{x}_i \boldsymbol{x}_i^{\mathrm{T}}$$

海森矩阵是半正定矩阵，$H_i(\boldsymbol{w})$ 是凸函数。

凸函数相加是凸函数，所以 $H(\boldsymbol{w}) = -\log L(\boldsymbol{w})$ 是凸函数。

2. 逻辑回归模型：logistic regression

如何求 $H(\boldsymbol{w})$ 的最小值点

$$H(\boldsymbol{w}) = \sum_{i=1}^{m} \left[-y_i \log \left(\frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right) - (1-y_i) \log \left(1 - \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}} \right) \right]$$

引入变量：

$$\sigma(\boldsymbol{x}_i) = \frac{1}{1+e^{-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i}}$$

损失函数为：

$$H(\boldsymbol{w}) = \sum_{i=1}^{m} \left[-y_i \log \sigma(\boldsymbol{x}_i) - (1-y_i) \log \left(1 - \sigma(\boldsymbol{x}_i) \right) \right]$$

损失函数梯度为：

$$\nabla H(\boldsymbol{w}) = \sum_{i=1}^{m} -y_i \boldsymbol{x_i} + \sigma(\boldsymbol{x}_i) \boldsymbol{x_i}$$

2. 逻辑回归模型：梯度下降法

$$H(\boldsymbol{w}) = \sum_{i=1}^{m} \left[-y_i \log \sigma(\boldsymbol{x}_i) - (1-y_i) \log \left(1-\sigma(\boldsymbol{x}_i)\right)\right]$$

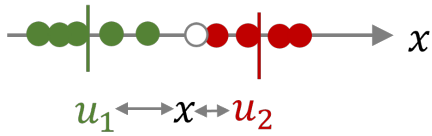
$$\nabla H(\boldsymbol{w}) = \sum_{i=1}^{m} -y_i \boldsymbol{x_i} + \sigma(\boldsymbol{x}_i)\boldsymbol{x_i}$$

Algorithm 1 梯度下降法

选择初始点 $\boldsymbol{w}_0$
for $i = 0$ to $n-1$ **do**
    $\boldsymbol{w}_{i+1} = \boldsymbol{w}_i - \eta \nabla H(\boldsymbol{w}_i)$
end for

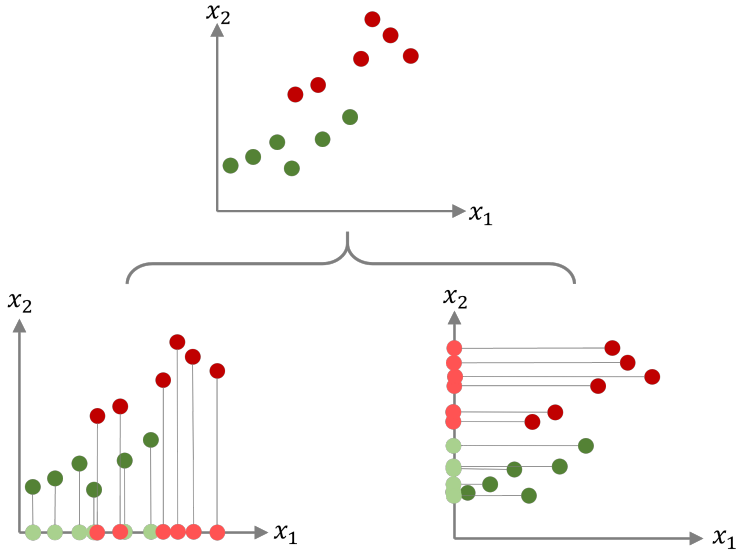
3. 线性判别分析模型：Linear Discriminant Analysis, LDA

单变量二分类问题:

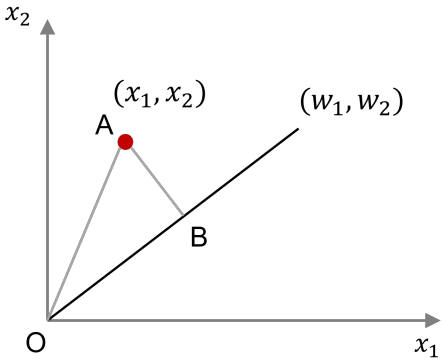


3. 线性判别分析模型：Linear Discriminant Analysis, LDA

两个变量二分类问题:



3. 线性判别分析模型：Linear Discriminant Analysis, LDA

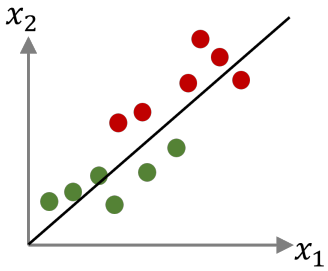


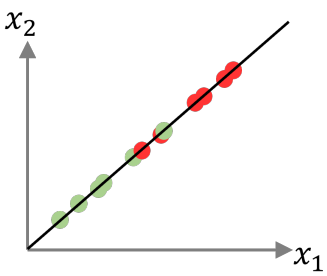
投影向量 $\boldsymbol{w}$ 且 $|\boldsymbol{w}|=1$，向量 $\overrightarrow{OA}=\boldsymbol{x}$, 向量 $\overrightarrow{OB}$ 与 $\boldsymbol{w}$ 同向

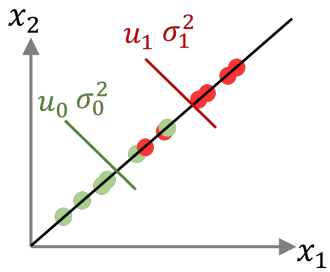
投影的坐标值：

$$
\begin{aligned}
|\overrightarrow{OB}| &= |\overrightarrow{OA}| \cos\theta \\
&= |\boldsymbol{x}| \cos\theta \\
&= |\boldsymbol{x}| \frac{\boldsymbol{x}\cdot\boldsymbol{w}}{|\boldsymbol{x}||\boldsymbol{w}|} \\
&= \boldsymbol{x}\cdot\boldsymbol{w} \\
&= \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}
\end{aligned}
$$

3. 线性判别分析模型：Linear Discriminant Analysis, LDA







模型：

$$z = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}$$

策略：

$$L(\boldsymbol{w}) = \frac{(\mu_1 - \mu_0)^2}{\sigma_1^2 + \sigma_0^2}$$

3. 线性判别分析模型：Linear Discriminant Analysis, LDA

训练数据：

$$\left\{\begin{array}{c}(\boldsymbol{x}_1, y_1)\\(\boldsymbol{x}_2, y_2)\\\cdots\\(\boldsymbol{x}_m, y_m)\end{array}\right\}$$

投影向量 $\boldsymbol{w}$

$$\left\{\begin{array}{c}z_1 = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_1\\z_2 = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_2\\\cdots\\z_m = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_m\end{array}\right\}$$

假设总样本数为 m，其中正例的数量为 n，计算所有的正例样本的均值和方差

$$\mu = \frac{1}{n}\sum_{i=1}^{n} z_i = \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i = \boldsymbol{w}^{\mathrm{T}}\left(\frac{1}{n}\sum_{i=1}^{n}\boldsymbol{x}_i\right) = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}$$

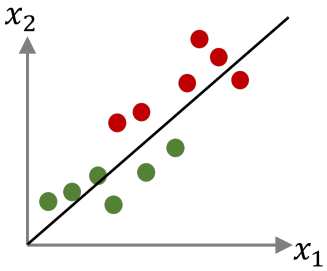
$$\sigma^2 = \frac{1}{n-1}\sum_{i=1}^{n}(z_i - \mu)^2$$

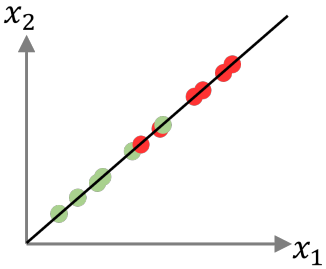
3. 线性判别分析模型：Linear Discriminant Analysis, LDA

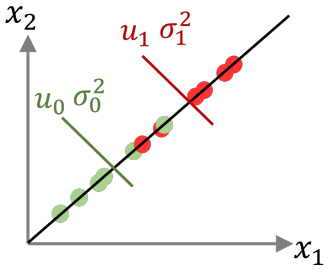
$$\mu = \frac{1}{n}\sum_{i=1}^{n} z_i = \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i = \boldsymbol{w}^{\mathrm{T}}\left(\frac{1}{n}\sum_{i=1}^{n}\boldsymbol{x}_i\right) = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}$$

$$\begin{aligned}
\sigma^2 &= \frac{1}{n-1}\sum_{i=1}^{n}(z_i-\mu)^2 = \frac{1}{n-1}\sum_{i=1}^{n}(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i - \boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu})^2 \\
&= \frac{1}{n-1}\sum_{i=1}^{n}\left[\boldsymbol{w}^{\mathrm{T}}(\boldsymbol{x}_i-\boldsymbol{\mu})\right]^2 \\
&= \frac{1}{n-1}\sum_{i=1}^{n}\boldsymbol{w}^{\mathrm{T}}(\boldsymbol{x}_i-\boldsymbol{\mu})(\boldsymbol{x}_i-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{w} \\
&= \boldsymbol{w}^{\mathrm{T}}\left[\frac{1}{n-1}\sum_{i=1}^{n}(\boldsymbol{x}_i-\boldsymbol{\mu})(\boldsymbol{x}_i-\boldsymbol{\mu})^{\mathrm{T}}\right]\boldsymbol{w} \\
&= \boldsymbol{w}^{\mathrm{T}}\boldsymbol{\Sigma}\boldsymbol{w}
\end{aligned}$$

3. 线性判别分析模型：Linear Discriminant Analysis, LDA



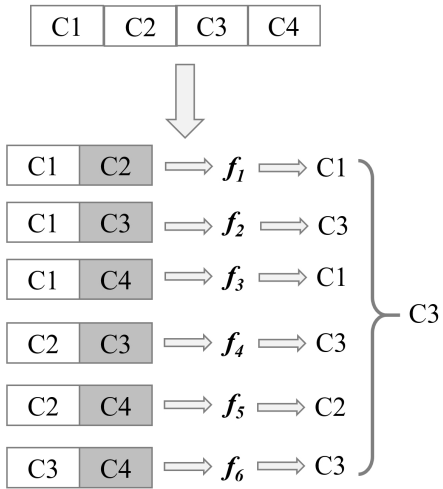




策略：

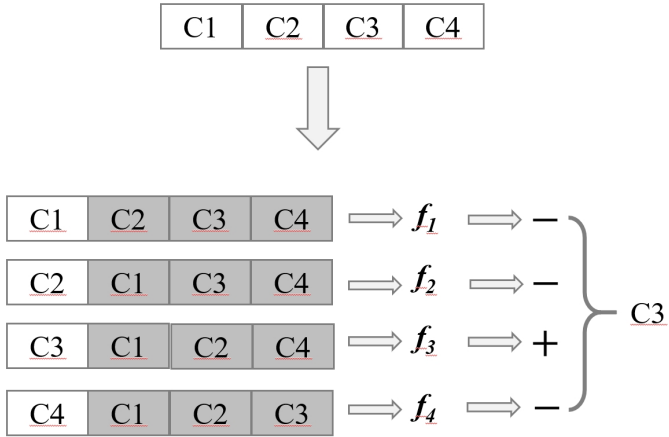
$$
\begin{aligned}
L(\boldsymbol{w}) &= \frac{(\mu_1 - \mu_0)^2}{\sigma_1^2 + \sigma_0^2} \\
&= \frac{(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}_1 - \boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}_0)^2}{(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\Sigma}_1\boldsymbol{w}) + (\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\Sigma}_0\boldsymbol{w})} \\
&= \frac{\boldsymbol{w}^{\mathrm{T}}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^{\mathrm{T}}\boldsymbol{w}}{\boldsymbol{w}^{\mathrm{T}}(\boldsymbol{\Sigma}_1 + \boldsymbol{\Sigma}_0)\boldsymbol{w}}
\end{aligned}
$$

4. 二分类器求多分类问题：一对一策略



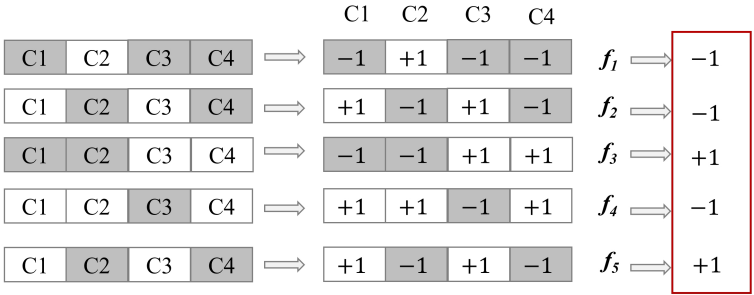
训练二分类器数量 C_k^2

4. 二分类器求多分类问题：一对多策略

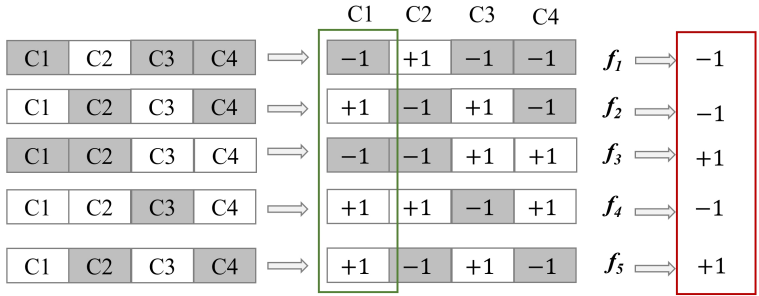


训练二分类器数量 k

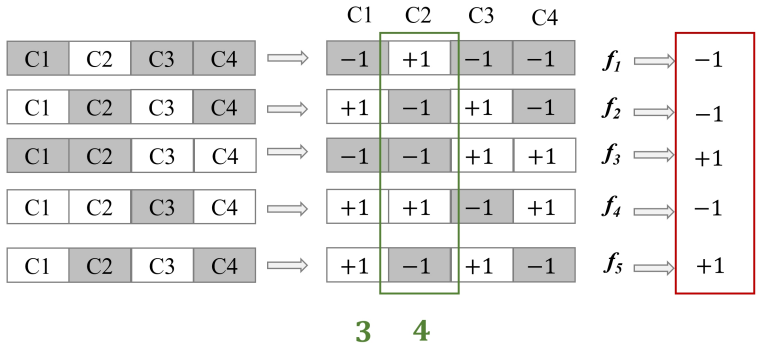
4. 二分类器求多分类问题：多对多策略



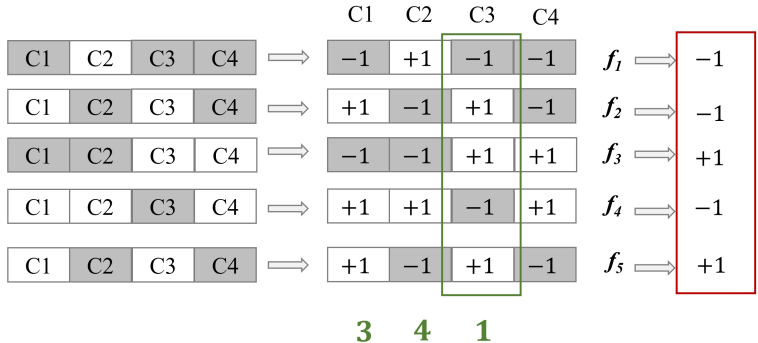
4. 二分类器求多分类问题：多对多策略



4. 二分类器求多分类问题：多对多策略



4. 二分类器求多分类问题：多对多策略



4. 二分类器求多分类问题：多对多策略

