机器学习期末复习

基于詹老师 ppt 整理，by：czk6664

2025 年 12 月 20 日

目录

1 绪论 **5**

1.1 符号定义 5

1.2 机器学习三要素详解 5

2 模型评估与选择 **6**

2.1 性能评估指标详解 6

2.1.1 回归问题指标 6

2.1.2 分类问题指标 7

2.2 偏差-方差分解详细推导 8

3 线性模型 **9**

3.1 凸优化基础详解 9

3.1.1 海森矩阵与凸性判定 9

3.2 一元线性回归完整推导 10

3.2.1 问题设定 10

3.2.2 损失函数展开 10

3.2.3 求解最优参数 11

3.3 多元线性回归矩阵推导 12

3.3.1 矩阵形式损失函数 12

3.3.2 矩阵求导 13

3.4 逻辑回归详细推导 14

3.4.1 从线性回归到逻辑回归 14

3.4.2 Sigmoid 函数性质详解 14

3.4.3 最大似然估计推导 15

3.4.4 梯度推导 16

3.5 线性判别分析（LDA）详细推导 18

3.5.1 问题设定 . . . 18
3.5.2 投影分析 . . . 19
3.5.3 目标函数推导 . . . 19
3.5.4 最优解推导 . . . 20

4 决策树 21
4.1 信息论基础 . . . 21
4.1.1 信息量 . . . 21
4.1.2 信息熵详解 . . . 21
4.2 信息增益完整计算 . . . 22
4.3 基尼指数完整计算 . . . 24
4.4 决策树构建完整示例 . . . 25
4.5 连续属性处理详解 . . . 26

5 神经网络 27
5.1 感知机学习算法 . . . 27
5.2 多层神经网络前向传播 . . . 29
5.3 反向传播完整推导 . . . 30

6 支持向量机 32
6.1 间隔与支持向量详解 . . . 32
6.1.1 点到超平面距离推导 . . . 32
6.1.2 间隔推导 . . . 33
6.2 硬间隔 SVM 完整求解 . . . 33
6.3 核函数详解 . . . 36

7 贝叶斯分类器 38
7.1 贝叶斯定理推导 . . . 38
7.2 朴素贝叶斯完整计算 . . . 38
7.3 拉普拉斯平滑详解 . . . 40
7.4 连续属性贝叶斯详解 . . . 41

8 集成学习 43
8.1 集成学习基本概念 . . . 43
8.2 Bagging 与随机森林 . . . 43
8.2.1 Bootstrap 采样 . . . 43
8.2.2 随机森林 . . . 44
8.3 Boosting . . . 45
8.3.1 AdaBoost 算法 . . . 45

8.4 结合策略 47
8.4.1 投票法 47
8.4.2 平均法 47

9 模型评估与选择进阶 48
9.1 交叉验证详解 48
9.2 超参数调优 48
9.3 过拟合与欠拟合 49

10 特征工程 50
10.1 特征缩放 50
10.2 缺失值处理 51
10.3 特征选择 51

A 西瓜数据集 2.0 52
A.1 完整数据 52
A.2 统计信息汇总 52
A.2.1 类别分布 52
A.2.2 各属性条件概率表 53
A.2.3 信息增益汇总 53
A.3 常用计算公式速查 54

B 补充例题与详细推导 54
B.1 线性回归补充 54
B.1.1 岭回归解析解推导 54
B.1.2 加权最小二乘法 56
B.2 决策树补充例题 57
B.3 神经网络补充 58
B.4 软间隔 SVM 详解 59
B.5 贝叶斯分类器补充 59
B.6 逻辑回归补充 59
B.6.1 多分类逻辑回归（Softmax 回归） 59
B.6.2 交叉熵损失的多分类推广 61

C 集成学习补充 61
C.1 Bagging 详解 61
C.2 Boosting 详解 61
C.3 随机森林 62

D 模型选择与调参 **63**
D.1 交叉验证详解 63
D.2 超参数调优 63

E 常见问题与解答 **63**
E.1 过拟合与欠拟合 63
E.2 特征工程要点 64

1 绪论

1.1 符号定义

定义 1.1 (标量). 标量是单个数值，用小写字母表示，如 $x = 1$，$y = 5.2$。

定义 1.2 (向量). 向量是一组有序数值的集合：

$$\mathbf{x} = [x_1, x_2, \cdots, x_d]^T = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

例 1.1 (向量表示). 西瓜数据集中，一个样本可以用向量表示。设色泽、根蒂、敲声分别编码为数值：

- 色泽：青绿 =1, 乌黑 =2, 浅白 =3
- 根蒂：蜷缩 =1, 稍蜷 =2, 硬挺 =3
- 敲声：浊响 =1, 沉闷 =2, 清脆 =3

则样本 1（青绿、蜷缩、浊响）可表示为 $\mathbf{x}_1 = [1, 1, 1]^T$。

定义 1.3 (矩阵). 矩阵是二维数组：

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} \end{bmatrix}_{m \times d}$$

例 1.2 (数据矩阵). 西瓜数据集的前 3 个样本（仅考虑色泽、根蒂、敲声 3 个属性）可表示为：

$$X = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 1 & 2 \\ 2 & 1 & 1 \end{bmatrix}_{3 \times 3}$$

第 1 行表示样本 1，第 1 列表示色泽属性。

1.2 机器学习三要素详解

机器学习三要素

1. **模型**：假设空间，定义了所有可能的函数形式
2. **策略**：损失函数，评价模型好坏的标准
3. **算法**：优化方法，求解最优参数的过程

例题 1.1 (三要素识别). 对于西瓜分类问题，使用逻辑回归模型，识别其三要素。

解：

1. **模型**：

$$P(Y = \text{好瓜}|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T\mathbf{x}+b)}}$$

假设空间为所有可能的 $(\mathbf{w}, b)$ 组合。

2. **策略**：交叉熵损失

$$Loss = -\sum_{i=1}^{17} [y_i \log P_i + (1 - y_i) \log(1 - P_i)]$$

其中 $y_i = 1$ 表示好瓜，$y_i = 0$ 表示坏瓜。

3. **算法**：梯度下降法

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla Loss$$

2 模型评估与选择

2.1 性能评估指标详解

2.1.1 回归问题指标

例题 2.1 (回归指标计算). 某回归模型对 5 个样本的预测结果如下：

样本	1	2	3	4	5
真实值 y_i	2.0	3.5	4.0	5.5	6.0
预测值 f_i	2.2	3.3	4.5	5.0	6.2

计算 *SSE*、*MSE*、*RMSE*、*MAE*。

解：

步骤 *1*：计算各样本误差

样本	1	2	3	4	5
$f_i - y_i$	0.2	-0.2	0.5	-0.5	0.2
$(f_i - y_i)^2$	0.04	0.04	0.25	0.25	0.04
$\lvert f_i - y_i \rvert$	0.2	0.2	0.5	0.5	0.2

步骤 2：计算各指标

$$SSE = \sum_{i=1}^{5}(f_i - y_i)^2 = 0.04 + 0.04 + 0.25 + 0.25 + 0.04 = 0.62$$

$$MSE = \frac{SSE}{m} = \frac{0.62}{5} = 0.124$$

$$RMSE = \sqrt{MSE} = \sqrt{0.124} = 0.352$$

$$MAE = \frac{1}{m}\sum_{i=1}^{5}|f_i - y_i| = \frac{0.2 + 0.2 + 0.5 + 0.5 + 0.2}{5} = 0.32$$

2.1.2 分类问题指标

例题 2.2 (西瓜数据集：完整分类评估). 某决策树模型对西瓜数据集 *17* 个样本的预测结果如下：

编号	*1*	*2*	*3*	*4*	*5*	*6*	*7*	*8*	*9*	*10*	*11*	*12*	*13*	*14*	*15*	*16*	*17*
真实	是	是	是	是	是	是	是	是	否	否	否	否	否	否	否	否	否
预测	是	是	是	是	是	是	否	否	否	否	否	是	否	否	是	否	否

计算混淆矩阵、准确率、查准率、查全率、*F1* 值。

解：

步骤 1：统计混淆矩阵

- *TP*（真实好瓜，预测好瓜）：样本 *1,2,3,4,5,6* $\rightarrow TP = 6$
- *FN*（真实好瓜，预测坏瓜）：样本 *7,8* $\rightarrow FN = 2$
- *FP*（真实坏瓜，预测好瓜）：样本 *12,15* $\rightarrow FP = 2$
- *TN*（真实坏瓜，预测坏瓜）：样本 *9,10,11,13,14,16,17* $\rightarrow TN = 7$

混淆矩阵：

	预测好瓜	预测坏瓜	合计
真实好瓜	*6*	*2*	*8*
真实坏瓜	*2*	*7*	*9*
合计	*8*	*9*	*17*

步骤 2：计算各指标

$$acc = \frac{TP + TN}{TP + FN + FP + TN} = \frac{6 + 7}{17} = \frac{13}{17} \approx 76.5\%$$

$$P = \frac{TP}{TP + FP} = \frac{6}{6 + 2} = \frac{6}{8} = 75\%$$

$$R = \frac{TP}{TP + FN} = \frac{6}{6 + 2} = \frac{6}{8} = 75\%$$

$$F_1 = \frac{2PR}{P + R} = \frac{2 \times 0.75 \times 0.75}{0.75 + 0.75} = \frac{1.125}{1.5} = 75\%$$

2.2 偏差-方差分解详细推导

定理 2.1 (偏差-方差分解). 设真实函数为 $y(x)$, 观测值 $y_D = y(x)+\epsilon$, 其中 $\epsilon \sim N(0, \sigma^2)$。模型在数据集 D 上训练得到 $f_D(x)$，则：

$$\mathbb{E}_D\left[(f_D - y_D)^2\right] = bias^2 + variance + noise$$

详细推导：

步骤 1：定义符号

- $\bar{f} = \mathbb{E}_D[f_D]$：模型预测的期望值
- y：真实函数值（无噪声）
- $y_D = y + \epsilon$：观测值（有噪声）

步骤 2：展开期望泛化误差

$$\begin{aligned}\mathbb{E}_D[(f_D - y_D)^2] &= \mathbb{E}_D[(f_D - y + y - y_D)^2] \\ &= \mathbb{E}_D[(f_D - y)^2 + (y - y_D)^2 + 2(f_D - y)(y - y_D)]\end{aligned}$$

步骤 3：分析交叉项

由于 $y - y_D = -\epsilon$，且 ϵ 与 f_D 独立，$\mathbb{E}[\epsilon] = 0$：

$$\begin{aligned}\mathbb{E}_D[2(f_D - y)(y - y_D)] &= 2\mathbb{E}_D[(f_D - y)(-\epsilon)] \\ &= -2\mathbb{E}_D[f_D - y] \cdot \mathbb{E}[\epsilon] \\ &= 0\end{aligned}$$

步骤 4：分解第一项

$$\begin{aligned}\mathbb{E}_D[(f_D - y)^2] &= \mathbb{E}_D[(f_D - \bar{f} + \bar{f} - y)^2] \\ &= \mathbb{E}_D[(f_D - \bar{f})^2] + (\bar{f} - y)^2 + 2\mathbb{E}_D[(f_D - \bar{f})(\bar{f} - y)]\end{aligned}$$

由于 $\mathbb{E}_D[f_D - \bar{f}] = 0$，交叉项为 0：

$$\mathbb{E}_D[(f_D - y)^2] = \underbrace{\mathbb{E}_D[(f_D - \bar{f})^2]}_{variance} + \underbrace{(\bar{f} - y)^2}_{bias^2}$$

步骤 5：分析第二项

$$\mathbb{E}_D[(y - y_D)^2] = \mathbb{E}[\epsilon^2] = \sigma^2 = noise$$

步骤 6：综合得证

$$\boxed{\mathbb{E}_D[(f_D - y_D)^2] = bias^2 + variance + \sigma^2}$$

偏差-方差权衡示例

考虑西瓜分类问题：

- **简单模型**（如仅用”纹理”属性的决策树桩）：
  - 偏差高：模型太简单，无法捕捉复杂模式
  - 方差低：不同训练集得到的模型相似
  - 结果：欠拟合
- **复杂模型**（如使用所有属性的深层决策树）：
  - 偏差低：模型足够复杂，能拟合训练数据
  - 方差高：对训练数据敏感，不同训练集差异大
  - 结果：过拟合

3 线性模型

3.1 凸优化基础详解

3.1.1 海森矩阵与凸性判定

定义 3.1 (海森矩阵). *对于二元函数 $f(x_1, x_2)$，海森矩阵为：*

$$H = \nabla^2 f = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix}$$

定理 3.1 (凸函数判定). *函数 f 是凸函数，当且仅当海森矩阵 H 半正定，即：*

1. *所有特征值 ≥ 0*
2. *或等价地：所有顺序主子式 ≥ 0*

例题 3.1 (凸性验证). *验证函数 $f(w_1, w_2) = w_1^2 + 2w_2^2 + w_1 w_2$ 是否为凸函数。*

解：

步骤 *1*： 计算一阶偏导

$$\frac{\partial f}{\partial w_1} = 2w_1 + w_2$$
$$\frac{\partial f}{\partial w_2} = 4w_2 + w_1$$

步骤 *2*： 计算二阶偏导（海森矩阵）

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial w_1^2} & \frac{\partial^2 f}{\partial w_1 \partial w_2} \\ \frac{\partial^2 f}{\partial w_2 \partial w_1} & \frac{\partial^2 f}{\partial w_2^2} \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 4 \end{bmatrix}$$

步骤 3：判定半正定性

方法一：计算特征值

$$\det(H-\lambda I)=(2-\lambda)(4-\lambda)-1=\lambda^2-6\lambda+7=0$$

$$\lambda=\frac{6\pm\sqrt{36-28}}{2}=\frac{6\pm2\sqrt{2}}{2}=3\pm\sqrt{2}$$

$\lambda_1=3+\sqrt{2}\approx4.41>0$，$\lambda_2=3-\sqrt{2}\approx1.59>0$

方法二：顺序主子式

- 一阶主子式：$H_{11}=2>0$
- 二阶主子式：$\det(H)=2\times4-1\times1=7>0$

结论：H 正定（所有特征值 >0），故 f 是**严格凸函数**。

3.2 一元线性回归完整推导

3.2.1 问题设定

给定训练数据 $\{(x_i,y_i)\}_{i=1}^n$，求模型 $f(x)=w_1x+w_2$ 的最优参数。

3.2.2 损失函数展开

$$\begin{aligned}Loss(w_1,w_2)&=\sum_{i=1}^n(w_1x_i+w_2-y_i)^2\\&=\sum_{i=1}^n\left[(w_1x_i)^2+w_2^2+y_i^2+2w_1w_2x_i-2w_1x_iy_i-2w_2y_i\right]\\&=w_1^2\sum_{i=1}^nx_i^2+nw_2^2+\sum_{i=1}^ny_i^2+2w_1w_2\sum_{i=1}^nx_i-2w_1\sum_{i=1}^nx_iy_i-2w_2\sum_{i=1}^ny_i\end{aligned}$$

引入简化符号：

$$S_{xx}=\sum x_i^2,\quad S_x=\sum x_i,\quad S_y=\sum y_i,\quad S_{xy}=\sum x_iy_i,\quad S_{yy}=\sum y_i^2$$

则：

$$Loss=w_1^2S_{xx}+nw_2^2+S_{yy}+2w_1w_2S_x-2w_1S_{xy}-2w_2S_y$$

3.2.3 求解最优参数

步骤 1： 计算梯度并令其为零

$$\frac{\partial Loss}{\partial w_1} = 2w_1 S_{xx} + 2w_2 S_x - 2S_{xy} = 0 \tag{1}$$

$$\frac{\partial Loss}{\partial w_2} = 2nw_2 + 2w_1 S_x - 2S_y = 0 \tag{2}$$

步骤 2： 从式 (2) 解出 w_2

$$w_2 = \frac{S_y - w_1 S_x}{n} = \bar{y} - w_1 \bar{x}$$

步骤 3： 代入式 (1)

$$\begin{aligned} w_1 S_{xx} + (\bar{y} - w_1 \bar{x}) S_x &= S_{xy} \\ w_1 S_{xx} + \bar{y} S_x - w_1 \bar{x} S_x &= S_{xy} \\ w_1 (S_{xx} - \bar{x} S_x) &= S_{xy} - \bar{y} S_x \\ w_1 &= \frac{S_{xy} - \bar{y} S_x}{S_{xx} - \bar{x} S_x} \end{aligned}$$

步骤 4： 化简（利用 $\bar{x} = S_x/n$，$\bar{y} = S_y/n$）

$$w_1^* = \frac{S_{xy} - \frac{S_y S_x}{n}}{S_{xx} - \frac{S_x^2}{n}} = \frac{nS_{xy} - S_x S_y}{nS_{xx} - S_x^2} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}$$

一元线性回归公式

$$w_1^* = \frac{n\sum x_i y_i - \sum x_i \sum y_i}{n\sum x_i^2 - (\sum x_i)^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \tag{3}$$

$$w_2^* = \bar{y} - w_1^* \bar{x} \tag{4}$$

例题 3.2 (一元线性回归完整计算). 给定数据：

i	1	2	3	4	5
x_i	1	2	3	4	5
y_i	2.1	4.0	5.8	8.1	9.8

求最优线性模型，并预测 $x = 6$ 时的 y 值。

解：

步骤 1： 计算统计量

$$\begin{aligned} n &= 5 \\ \sum x_i &= 1 + 2 + 3 + 4 + 5 = 15 \\ \sum y_i &= 2.1 + 4.0 + 5.8 + 8.1 + 9.8 = 29.8 \\ \bar{x} &= 15/5 = 3 \\ \bar{y} &= 29.8/5 = 5.96 \end{aligned}$$

步骤 2： 计算平方和与交叉项

$$\sum x_i^2 = 1 + 4 + 9 + 16 + 25 = 55$$
$$\sum x_i y_i = 1 \times 2.1 + 2 \times 4.0 + 3 \times 5.8 + 4 \times 8.1 + 5 \times 9.8$$
$$= 2.1 + 8.0 + 17.4 + 32.4 + 49.0 = 108.9$$

步骤 3： 计算最优参数

$$w_1^* = \frac{n\sum x_i y_i - \sum x_i \sum y_i}{n\sum x_i^2 - (\sum x_i)^2}$$
$$= \frac{5 \times 108.9 - 15 \times 29.8}{5 \times 55 - 15^2}$$
$$= \frac{544.5 - 447}{275 - 225} = \frac{97.5}{50} = 1.95$$
$$w_2^* = \bar{y} - w_1^* \bar{x} = 5.96 - 1.95 \times 3 = 5.96 - 5.85 = 0.11$$

步骤 4： 最终模型

$$\boxed{f(x) = 1.95x + 0.11}$$

步骤 5： 预测

$$f(6) = 1.95 \times 6 + 0.11 = 11.7 + 0.11 = 11.81$$

步骤 6： 验证（计算训练误差）

i	1	2	3	4	5
y_i	2.1	4.0	5.8	8.1	9.8
$f(x_i)$	2.06	4.01	5.96	7.91	9.86
$y_i - f(x_i)$	0.04	-0.01	-0.16	0.19	-0.06

$$MSE = \frac{0.04^2 + 0.01^2 + 0.16^2 + 0.19^2 + 0.06^2}{5} = \frac{0.0678}{5} = 0.0136$$

3.3 多元线性回归矩阵推导

3.3.1 矩阵形式损失函数

$$Loss(\mathbf{w}) = \sum_{i=1}^{m}(f(\mathbf{x}_i) - y_i)^2 = \sum_{i=1}^{m}(\mathbf{w}^T\mathbf{x}_i - y_i)^2$$
$$= (X\mathbf{w} - \mathbf{y})^T(X\mathbf{w} - \mathbf{y})$$

展开：

$$Loss = (X\mathbf{w})^T(X\mathbf{w}) - (X\mathbf{w})^T\mathbf{y} - \mathbf{y}^T(X\mathbf{w}) + \mathbf{y}^T\mathbf{y}$$
$$= \mathbf{w}^T X^T X\mathbf{w} - 2\mathbf{w}^T X^T\mathbf{y} + \mathbf{y}^T\mathbf{y}$$

3.3.2 矩阵求导

引理 3.1 (矩阵求导公式). 1. $\frac{\partial}{\partial \mathbf{w}}(\mathbf{w}^T\mathbf{a}) = \mathbf{a}$

2. $\frac{\partial}{\partial \mathbf{w}}(\mathbf{w}^T A\mathbf{w}) = 2A\mathbf{w}$（当 A 对称时）

应用：

$$\begin{aligned}\nabla_{\mathbf{w}} Loss &= \frac{\partial}{\partial \mathbf{w}}\left[\mathbf{w}^T X^T X\mathbf{w} - 2\mathbf{w}^T X^T\mathbf{y} + \mathbf{y}^T\mathbf{y}\right] \\ &= 2X^T X\mathbf{w} - 2X^T\mathbf{y}\end{aligned}$$

令 $\nabla_{\mathbf{w}} Loss = 0$：

$$X^T X\mathbf{w} = X^T\mathbf{y}$$

定理 3.2 (多元线性回归正规方程). 若 $X^T X$ 可逆，则最优解为：

$$\mathbf{w}^* = (X^T X)^{-1} X^T\mathbf{y}$$

例题 3.3 (多元线性回归矩阵计算). 给定 3 个样本，2 个特征：

样本	x_1	x_2	y
1	1	2	5
2	2	1	6
3	3	3	10

用矩阵方法求解 $f(\mathbf{x}) = w_1 x_1 + w_2 x_2 + w_3$。

解：

步骤 1： 构造增广矩阵

$$X = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 1 & 1 \\ 3 & 3 & 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 5 \\ 6 \\ 10 \end{bmatrix}$$

步骤 2： 计算 $X^T X$

$$X^T X = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 1 & 3 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 1 & 1 \\ 3 & 3 & 1 \end{bmatrix} = \begin{bmatrix} 14 & 13 & 6 \\ 13 & 14 & 6 \\ 6 & 6 & 3 \end{bmatrix}$$

步骤 3： 计算 $X^T\mathbf{y}$

$$X^T\mathbf{y} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 1 & 3 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 5 \\ 6 \\ 10 \end{bmatrix} = \begin{bmatrix} 1\times 5 + 2\times 6 + 3\times 10 \\ 2\times 5 + 1\times 6 + 3\times 10 \\ 1\times 5 + 1\times 6 + 1\times 10 \end{bmatrix} = \begin{bmatrix} 47 \\ 46 \\ 21 \end{bmatrix}$$

步骤 4：求解 $(X^TX)^{-1}$（使用伴随矩阵法或高斯消元）

经计算：

$$(X^TX)^{-1} = \begin{bmatrix} 2 & -1 & -2 \\ -1 & 2 & -2 \\ -2 & -2 & 9 \end{bmatrix}$$

步骤 5：计算最优解

$$\mathbf{w}^* = (X^TX)^{-1}X^T\mathbf{y} = \begin{bmatrix} 2 & -1 & -2 \\ -1 & 2 & -2 \\ -2 & -2 & 9 \end{bmatrix} \begin{bmatrix} 47 \\ 46 \\ 21 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \\ -12 \end{bmatrix} \times \frac{1}{3} = \begin{bmatrix} 2 \\ 1 \\ 1 \end{bmatrix}$$

最终模型：

$$\boxed{f(\mathbf{x}) = 2x_1 + x_2 + 1}$$

验证：

- $f(1,2) = 2 \times 1 + 1 \times 2 + 1 = 5$
- $f(2,1) = 2 \times 2 + 1 \times 1 + 1 = 6$
- $f(3,3) = 2 \times 3 + 1 \times 3 + 1 = 10$

3.4 逻辑回归详细推导

3.4.1 从线性回归到逻辑回归

线性回归输出连续值，不适合分类问题。逻辑回归通过 Sigmoid 函数将输出映射到 $(0,1)$，表示概率。

3.4.2 Sigmoid 函数性质详解

定义 3.2 (Sigmoid 函数).

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

性质推导：

性质 1：值域为 $(0,1)$

- 当 $z \to +\infty$：$e^{-z} \to 0$，$\sigma(z) \to 1$
- 当 $z \to -\infty$：$e^{-z} \to +\infty$，$\sigma(z) \to 0$
- 当 $z = 0$：$\sigma(0) = \frac{1}{1+1} = 0.5$

性质 2：导数 $\sigma'(z) = \sigma(z)(1-\sigma(z))$

推导：

$$\begin{aligned}
\sigma'(z) &= \frac{d}{dz}\left(\frac{1}{1+e^{-z}}\right) \\
&= -\frac{1}{(1+e^{-z})^2}\cdot(-e^{-z}) \\
&= \frac{e^{-z}}{(1+e^{-z})^2} \\
&= \frac{1}{1+e^{-z}}\cdot\frac{e^{-z}}{1+e^{-z}} \\
&= \sigma(z)\cdot\frac{1+e^{-z}-1}{1+e^{-z}} \\
&= \sigma(z)\cdot\left(1-\frac{1}{1+e^{-z}}\right) \\
&= \sigma(z)(1-\sigma(z))
\end{aligned}$$

性质 3：对称性 $\sigma(-z) = 1-\sigma(z)$

推导：

$$\sigma(-z) = \frac{1}{1+e^{z}} = \frac{e^{-z}}{e^{-z}+1} = \frac{e^{-z}}{1+e^{-z}}$$

$$1-\sigma(z) = 1-\frac{1}{1+e^{-z}} = \frac{e^{-z}}{1+e^{-z}}$$

故 $\sigma(-z) = 1-\sigma(z)$。

3.4.3 最大似然估计推导

设样本 $(\mathbf{x}_i, y_i)$，$y_i \in \{0,1\}$。

单个样本的概率：

$$P(y_i|\mathbf{x}_i) = \sigma(\mathbf{w}^T\mathbf{x}_i)^{y_i}\cdot(1-\sigma(\mathbf{w}^T\mathbf{x}_i))^{1-y_i}$$

验证：

- 当 $y_i = 1$：$P = \sigma(\mathbf{w}^T\mathbf{x}_i)^1\cdot(1-\sigma)^0 = \sigma(\mathbf{w}^T\mathbf{x}_i)$
- 当 $y_i = 0$：$P = \sigma^0\cdot(1-\sigma)^1 = 1-\sigma(\mathbf{w}^T\mathbf{x}_i)$

似然函数（假设样本独立）：

$$L(\mathbf{w}) = \prod_{i=1}^{m} P(y_i|\mathbf{x}_i) = \prod_{i=1}^{m}\sigma_i^{y_i}(1-\sigma_i)^{1-y_i}$$

其中 $\sigma_i = \sigma(\mathbf{w}^T\mathbf{x}_i)$。

对数似然：

$$\ell(\mathbf{w}) = \log L(\mathbf{w}) = \sum_{i=1}^{m} [y_i \log \sigma_i + (1 - y_i) \log(1 - \sigma_i)]$$

负对数似然（交叉熵损失）：

$$J(\mathbf{w}) = -\ell(\mathbf{w}) = -\sum_{i=1}^{m} [y_i \log \sigma_i + (1 - y_i) \log(1 - \sigma_i)]$$

3.4.4 梯度推导

对单个样本 i：

$$\frac{\partial}{\partial \mathbf{w}} [-y_i \log \sigma_i - (1 - y_i) \log(1 - \sigma_i)]$$

设 $z_i = \mathbf{w}^T \mathbf{x}_i$，则 $\sigma_i = \sigma(z_i)$。

链式法则：

$$\frac{\partial}{\partial \mathbf{w}} = \frac{\partial}{\partial \sigma_i} \cdot \frac{\partial \sigma_i}{\partial z_i} \cdot \frac{\partial z_i}{\partial \mathbf{w}}$$

各部分计算：

$$\frac{\partial}{\partial \sigma_i} [-y_i \log \sigma_i - (1 - y_i) \log(1 - \sigma_i)] = -\frac{y_i}{\sigma_i} + \frac{1 - y_i}{1 - \sigma_i}$$

$$\frac{\partial \sigma_i}{\partial z_i} = \sigma_i(1 - \sigma_i)$$

$$\frac{\partial z_i}{\partial \mathbf{w}} = \mathbf{x}_i$$

合并：

$$\begin{aligned}
\frac{\partial J_i}{\partial \mathbf{w}} &= \left(-\frac{y_i}{\sigma_i} + \frac{1 - y_i}{1 - \sigma_i} \right) \cdot \sigma_i(1 - \sigma_i) \cdot \mathbf{x}_i \\
&= [-y_i(1 - \sigma_i) + (1 - y_i)\sigma_i] \cdot \mathbf{x}_i \\
&= [-y_i + y_i\sigma_i + \sigma_i - y_i\sigma_i] \cdot \mathbf{x}_i \\
&= (\sigma_i - y_i) \cdot \mathbf{x}_i
\end{aligned}$$

逻辑回归梯度公式

$$\nabla J(\mathbf{w}) = \sum_{i=1}^{m} (\sigma(\mathbf{w}^T \mathbf{x}_i) - y_i)\mathbf{x}_i = X^T(\boldsymbol{\sigma} - \mathbf{y})$$

其中 $\boldsymbol{\sigma} = [\sigma_1, \sigma_2, \cdots, \sigma_m]^T$。

例题 3.4 (逻辑回归梯度下降). 给定 3 个样本：

样本	x_1	x_2	y
1	*1*	*1*	*1*
2	*2*	*0*	*1*
3	*0*	*2*	*0*

初始参数 $\mathbf{w} = [0, 0, 0]^T$（含偏置），学习率 $\eta = 0.5$。执行一次梯度下降更新。

解：

步骤 *1*： 构造增广矩阵

$$X = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 0 & 1 \\ 0 & 2 & 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

步骤 *2*： 计算当前预测

$$\mathbf{z} = X\mathbf{w} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\boldsymbol{\sigma} = \sigma(\mathbf{z}) = \begin{bmatrix} 0.5 \\ 0.5 \\ 0.5 \end{bmatrix}$$

步骤 *3*： 计算梯度

$$\boldsymbol{\sigma} - \mathbf{y} = \begin{bmatrix} 0.5 - 1 \\ 0.5 - 1 \\ 0.5 - 0 \end{bmatrix} = \begin{bmatrix} -0.5 \\ -0.5 \\ 0.5 \end{bmatrix}$$

$$\nabla J = X^T(\boldsymbol{\sigma} - \mathbf{y}) = \begin{bmatrix} 1 & 2 & 0 \\ 1 & 0 & 2 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} -0.5 \\ -0.5 \\ 0.5 \end{bmatrix} = \begin{bmatrix} -0.5 - 1 + 0 \\ -0.5 + 0 + 1 \\ -0.5 - 0.5 + 0.5 \end{bmatrix} = \begin{bmatrix} -1.5 \\ 0.5 \\ -0.5 \end{bmatrix}$$

步骤 *4*： 更新参数

$$\mathbf{w}^{new} = \mathbf{w} - \eta \nabla J = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} - 0.5 \begin{bmatrix} -1.5 \\ 0.5 \\ -0.5 \end{bmatrix} = \begin{bmatrix} 0.75 \\ -0.25 \\ 0.25 \end{bmatrix}$$

更新后模型：

$$P(Y = 1|\mathbf{x}) = \sigma(0.75x_1 - 0.25x_2 + 0.25)$$

例题 3.5 (西瓜数据集：逻辑回归应用). 使用西瓜数据集的”密度”和”含糖率”两个连续属性（假设已提取），训练逻辑回归模型。

假设经过多次迭代后得到模型：

$$P(\text{好瓜}|\mathbf{x}) = \sigma(3.5 \times \text{密度} + 2.8 \times \text{含糖率} - 2.1)$$

预测以下样本：

样本	密度	含糖率
A	*0.7*	*0.4*
B	*0.3*	*0.2*
C	*0.6*	*0.5*

解：

样本 *A*：

$$z_A = 3.5 \times 0.7 + 2.8 \times 0.4 - 2.1 = 2.45 + 1.12 - 2.1 = 1.47$$

$$P_A = \sigma(1.47) = \frac{1}{1 + e^{-1.47}} = \frac{1}{1 + 0.229} = 0.814$$

$P_A = 81.4\% > 50\%$，预测为**好瓜**。

样本 *B*：

$$z_B = 3.5 \times 0.3 + 2.8 \times 0.2 - 2.1 = 1.05 + 0.56 - 2.1 = -0.49$$

$$P_B = \sigma(-0.49) = \frac{1}{1 + e^{0.49}} = \frac{1}{1 + 1.632} = 0.380$$

$P_B = 38.0\% < 50\%$，预测为**坏瓜**。

样本 *C*：

$$z_C = 3.5 \times 0.6 + 2.8 \times 0.5 - 2.1 = 2.1 + 1.4 - 2.1 = 1.4$$

$$P_C = \sigma(1.4) = \frac{1}{1 + e^{-1.4}} = \frac{1}{1 + 0.247} = 0.802$$

$P_C = 80.2\% > 50\%$，预测为**好瓜**。

3.5 线性判别分析（LDA）详细推导

3.5.1 问题设定

给定二分类数据集 $D = \{(\mathbf{x}_i, y_i)\}$，$y_i \in \{0, 1\}$。

设：

- D_0：类别 0 的样本集，$|D_0| = m_0$
- D_1：类别 1 的样本集，$|D_1| = m_1$
- $\boldsymbol{\mu}_0 = \frac{1}{m_0} \sum_{\mathbf{x} \in D_0} \mathbf{x}$：类别 0 的均值向量
- $\boldsymbol{\mu}_1 = \frac{1}{m_1} \sum_{\mathbf{x} \in D_1} \mathbf{x}$：类别 1 的均值向量
- Σ_0, Σ_1：两类的协方差矩阵

3.5.2 投影分析

将样本投影到方向 $\mathbf{w}$ 上：$z = \mathbf{w}^T\mathbf{x}$
投影后的类均值：

$$\tilde{\mu}_0 = \mathbf{w}^T\boldsymbol{\mu}_0$$
$$\tilde{\mu}_1 = \mathbf{w}^T\boldsymbol{\mu}_1$$

投影后的类方差：

$$\tilde{\sigma}_0^2 = \sum_{\mathbf{x}\in D_0}(\mathbf{w}^T\mathbf{x} - \mathbf{w}^T\boldsymbol{\mu}_0)^2 = \mathbf{w}^T\Sigma_0\mathbf{w}$$
$$\tilde{\sigma}_1^2 = \sum_{\mathbf{x}\in D_1}(\mathbf{w}^T\mathbf{x} - \mathbf{w}^T\boldsymbol{\mu}_1)^2 = \mathbf{w}^T\Sigma_1\mathbf{w}$$

3.5.3 目标函数推导

目标：最大化类间距离，最小化类内方差。
Fisher 准则：

$$J(\mathbf{w}) = \frac{(\tilde{\mu}_1 - \tilde{\mu}_0)^2}{\tilde{\sigma}_0^2 + \tilde{\sigma}_1^2}$$

展开：

$$\begin{aligned}(\tilde{\mu}_1 - \tilde{\mu}_0)^2 &= (\mathbf{w}^T\boldsymbol{\mu}_1 - \mathbf{w}^T\boldsymbol{\mu}_0)^2 \\ &= [\mathbf{w}^T(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)]^2 \\ &= \mathbf{w}^T(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^T\mathbf{w} \\ &= \mathbf{w}^T S_b\mathbf{w}\end{aligned}$$

其中 $S_b = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^T$ 为**类间散度矩阵**。

$$\begin{aligned}\tilde{\sigma}_0^2 + \tilde{\sigma}_1^2 &= \mathbf{w}^T\Sigma_0\mathbf{w} + \mathbf{w}^T\Sigma_1\mathbf{w} \\ &= \mathbf{w}^T(\Sigma_0 + \Sigma_1)\mathbf{w} \\ &= \mathbf{w}^T S_w\mathbf{w}\end{aligned}$$

其中 $S_w = \Sigma_0 + \Sigma_1$ 为**类内散度矩阵**。
目标函数：

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_b\mathbf{w}}{\mathbf{w}^T S_w\mathbf{w}}$$

3.5.4 最优解推导

对 $J(\mathbf{w})$ 求导并令其为零。

设 $\mathbf{w}^T S_b \mathbf{w} = a$，$\mathbf{w}^T S_w \mathbf{w} = b$，则 $J = a/b$。

$$\frac{\partial J}{\partial \mathbf{w}} = \frac{2S_b\mathbf{w} \cdot b - a \cdot 2S_w\mathbf{w}}{b^2} = 0$$

即：

$$S_b\mathbf{w} \cdot b = S_w\mathbf{w} \cdot a$$

$$S_b\mathbf{w} = \frac{a}{b} S_w\mathbf{w} = J \cdot S_w\mathbf{w}$$

由于 $S_b\mathbf{w} = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^T\mathbf{w}$ 的方向总是 $(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$，

令 $S_w\mathbf{w} = \lambda(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$，得：

$$\mathbf{w}^* = S_w^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)$$

例题 3.6 (LDA 计算示例). 给定二分类数据：

类别 *0*：$\mathbf{x}_1 = [1, 2]^T$，$\mathbf{x}_2 = [2, 1]^T$

类别 *1*：$\mathbf{x}_3 = [4, 5]^T$，$\mathbf{x}_4 = [5, 4]^T$

求 *LDA* 投影方向。

解：

步骤 *1*： 计算类均值

$$\boldsymbol{\mu}_0 = \frac{1}{2}([1, 2]^T + [2, 1]^T) = [1.5, 1.5]^T$$

$$\boldsymbol{\mu}_1 = \frac{1}{2}([4, 5]^T + [5, 4]^T) = [4.5, 4.5]^T$$

步骤 *2*： 计算类内散度矩阵

$$\begin{aligned}\Sigma_0 &= \sum_{\mathbf{x} \in D_0} (\mathbf{x} - \boldsymbol{\mu}_0)(\mathbf{x} - \boldsymbol{\mu}_0)^T \\ &= [-0.5, 0.5]^T[-0.5, 0.5] + [0.5, -0.5]^T[0.5, -0.5] \\ &= \begin{bmatrix} 0.25 & -0.25 \\ -0.25 & 0.25 \end{bmatrix} + \begin{bmatrix} 0.25 & -0.25 \\ -0.25 & 0.25 \end{bmatrix} = \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix}\end{aligned}$$

同理：$\Sigma_1 = \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix}$

$$S_w = \Sigma_0 + \Sigma_1 = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$$

步骤 *3*： 计算 $\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0$

$$\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0 = [4.5 - 1.5, 4.5 - 1.5]^T = [3, 3]^T$$

步骤 4：求 S_w^{-1}

由于 S_w 奇异（行列式为 0），使用伪逆或添加正则化。

添加正则化：$S_w' = S_w + 0.1I = \begin{bmatrix} 1.1 & -1 \\ -1 & 1.1 \end{bmatrix}$

$$S_w'^{-1} = \frac{1}{1.1 \times 1.1 - 1} \begin{bmatrix} 1.1 & 1 \\ 1 & 1.1 \end{bmatrix} = \frac{1}{0.21} \begin{bmatrix} 1.1 & 1 \\ 1 & 1.1 \end{bmatrix}$$

步骤 5：计算投影方向

$$\mathbf{w}^* \propto S_w'^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) = \frac{1}{0.21} \begin{bmatrix} 1.1 & 1 \\ 1 & 1.1 \end{bmatrix} \begin{bmatrix} 3 \\ 3 \end{bmatrix} = \frac{1}{0.21} \begin{bmatrix} 6.3 \\ 6.3 \end{bmatrix}$$

归一化后：$\mathbf{w}^* = [1, 1]^T / \sqrt{2} = [0.707, 0.707]^T$

结论：最优投影方向为 $\mathbf{w}^* = [1, 1]^T$（或其归一化形式），即沿 $45°$ 方向投影。

4 决策树

4.1 信息论基础

4.1.1 信息量

定义 4.1 (信息量). 事件 A 发生的信息量定义为：

$$I(A) = -\log_2 P(A)$$

概率越小的事件，发生时提供的信息量越大。

例 4.1 (信息量计算).

- 抛硬币正面朝上（$P = 0.5$）：$I = -\log_2 0.5 = 1$ *bit*
- 掷骰子出现 6（$P = 1/6$）：$I = -\log_2(1/6) = \log_2 6 \approx 2.58$ *bit*
- 必然事件（$P = 1$）：$I = -\log_2 1 = 0$ *bit*

4.1.2 信息熵详解

定义 4.2 (信息熵). 随机变量 X 的信息熵是其信息量的期望：

$$H(X) = \mathbb{E}[I(X)] = -\sum_{i=1}^{n} P(x_i) \log_2 P(x_i)$$

定理 4.1 (信息熵的性质).

1. 非负性：$H(X) \geq 0$
2. 当且仅当 X 为确定性变量时，$H(X) = 0$
3. 对于 n 个等概率事件，$H(X) = \log_2 n$（最大熵）

例题 4.1 (西瓜数据集：信息熵计算). 计算西瓜数据集（*17* 个样本，*8* 个好瓜，*9* 个坏瓜）的信息熵。

解：

步骤 *1*： 计算各类概率

$$P(\text{好瓜}) = \frac{8}{17} \approx 0.471$$
$$P(\text{坏瓜}) = \frac{9}{17} \approx 0.529$$

步骤 *2*： 计算对数值

$$\log_2 0.471 = \frac{\ln 0.471}{\ln 2} = \frac{-0.753}{0.693} \approx -1.087$$
$$\log_2 0.529 = \frac{\ln 0.529}{\ln 2} = \frac{-0.637}{0.693} \approx -0.919$$

步骤 *3*： 计算信息熵

$$\begin{aligned} Ent(D) &= -P(\text{好瓜}) \log_2 P(\text{好瓜}) - P(\text{坏瓜}) \log_2 P(\text{坏瓜}) \\ &= -0.471 \times (-1.087) - 0.529 \times (-0.919) \\ &= 0.512 + 0.486 \\ &= \boxed{0.998} \end{aligned}$$

解释： 信息熵接近 *1*（最大值为 $\log_2 2 = 1$），说明数据集的不确定性较高，两类样本分布较均匀。

4.2 信息增益完整计算

例题 4.2 (西瓜数据集：所有属性的信息增益). 计算西瓜数据集中”色泽”、”根蒂”、”敲声”三个属性的信息增益，并选择最优划分属性。

数据统计：

属性	取值分布			
	取值	好瓜	坏瓜	
色泽	青绿	*3*	*3*	*6*
	乌黑	*4*	*2*	*6*
	浅白	*1*	*4*	*5*
根蒂	蜷缩	*5*	*3*	*8*
	稍蜷	*3*	*4*	*7*
	硬挺	*0*	*2*	*2*
敲声	浊响	*6*	*4*	*10*
	沉闷	*2*	*3*	*5*
	清脆	*0*	*2*	*2*

解：

根节点信息熵：$Ent(D) = 0.998$

（1）色泽属性

各分支信息熵：

$$
\begin{aligned}
Ent(D^{\text{青绿}}) &= -\frac{3}{6}\log_2\frac{3}{6} - \frac{3}{6}\log_2\frac{3}{6} = -0.5\times(-1) - 0.5\times(-1) = 1.0 \\
Ent(D^{\text{乌黑}}) &= -\frac{4}{6}\log_2\frac{4}{6} - \frac{2}{6}\log_2\frac{2}{6} \\
&= -0.667\times(-0.585) - 0.333\times(-1.585) = 0.390 + 0.528 = 0.918 \\
Ent(D^{\text{浅白}}) &= -\frac{1}{5}\log_2\frac{1}{5} - \frac{4}{5}\log_2\frac{4}{5} \\
&= -0.2\times(-2.322) - 0.8\times(-0.322) = 0.464 + 0.258 = 0.722
\end{aligned}
$$

信息增益：

$$
\begin{aligned}
Gain(D, \text{色泽}) &= Ent(D) - \sum_v \frac{|D^v|}{|D|} Ent(D^v) \\
&= 0.998 - \left(\frac{6}{17}\times 1.0 + \frac{6}{17}\times 0.918 + \frac{5}{17}\times 0.722\right) \\
&= 0.998 - (0.353 + 0.324 + 0.212) \\
&= 0.998 - 0.889 = \boxed{0.109}
\end{aligned}
$$

（2）根蒂属性

各分支信息熵：

$$
\begin{aligned}
Ent(D^{\text{蜷缩}}) &= -\frac{5}{8}\log_2\frac{5}{8} - \frac{3}{8}\log_2\frac{3}{8} \\
&= -0.625\times(-0.678) - 0.375\times(-1.415) = 0.424 + 0.531 = 0.954 \\
Ent(D^{\text{稍蜷}}) &= -\frac{3}{7}\log_2\frac{3}{7} - \frac{4}{7}\log_2\frac{4}{7} \\
&= -0.429\times(-1.222) - 0.571\times(-0.807) = 0.524 + 0.461 = 0.985 \\
Ent(D^{\text{硬挺}}) &= -\frac{0}{2}\log_2\frac{0}{2} - \frac{2}{2}\log_2\frac{2}{2} = 0 - 0 = 0
\end{aligned}
$$

信息增益：

$$
\begin{aligned}
Gain(D, \text{根蒂}) &= 0.998 - \left(\frac{8}{17}\times 0.954 + \frac{7}{17}\times 0.985 + \frac{2}{17}\times 0\right) \\
&= 0.998 - (0.449 + 0.406 + 0) \\
&= 0.998 - 0.855 = \boxed{0.143}
\end{aligned}
$$

（3）敲声属性

各分支信息熵：

$$\begin{aligned}
Ent(D^{浊响}) &= -\frac{6}{10}\log_2\frac{6}{10} - \frac{4}{10}\log_2\frac{4}{10} \\
&= -0.6\times(-0.737) - 0.4\times(-1.322) = 0.442 + 0.529 = 0.971 \\
Ent(D^{沉闷}) &= -\frac{2}{5}\log_2\frac{2}{5} - \frac{3}{5}\log_2\frac{3}{5} \\
&= -0.4\times(-1.322) - 0.6\times(-0.737) = 0.529 + 0.442 = 0.971 \\
Ent(D^{清脆}) &= 0 \quad （全为坏瓜）
\end{aligned}$$

信息增益：

$$\begin{aligned}
Gain(D, 敲声) &= 0.998 - \left(\frac{10}{17}\times 0.971 + \frac{5}{17}\times 0.971 + \frac{2}{17}\times 0\right) \\
&= 0.998 - (0.571 + 0.286 + 0) \\
&= 0.998 - 0.857 = \boxed{0.141}
\end{aligned}$$

结论：

属性	信息增益
色泽	*0.109*
根蒂	***0.143***
敲声	*0.141*

”根蒂”的信息增益最大，应选择”根蒂”作为根节点的划分属性。

4.3 基尼指数完整计算

例题 4.3 (西瓜数据集：基尼指数计算). 计算西瓜数据集中”纹理”属性的基尼指数。

数据统计：

纹理	好瓜	坏瓜	合计
清晰	*7*	*2*	*9*
稍糊	*1*	*4*	*5*
模糊	*0*	*3*	*3*

解：

步骤 *1*：计算各分支基尼值

清晰（*9* 个样本）：

$$\begin{aligned}
Gini(D^{清晰}) &= 1 - \left(\frac{7}{9}\right)^2 - \left(\frac{2}{9}\right)^2 \\
&= 1 - \frac{49}{81} - \frac{4}{81} = 1 - \frac{53}{81} = \frac{28}{81} \approx 0.346
\end{aligned}$$

稍糊（5 个样本）：

$$\begin{aligned} Gini(D^{\text{稍糊}}) &= 1 - \left(\frac{1}{5}\right)^2 - \left(\frac{4}{5}\right)^2 \\ &= 1 - \frac{1}{25} - \frac{16}{25} = 1 - \frac{17}{25} = \frac{8}{25} = 0.32 \end{aligned}$$

模糊（3 个样本，全为坏瓜）：

$$Gini(D^{\text{模糊}}) = 1 - 0^2 - 1^2 = 0$$

步骤 2：计算基尼指数

$$\begin{aligned} Gini_index(D, \text{纹理}) &= \sum_v \frac{|D^v|}{|D|} Gini(D^v) \\ &= \frac{9}{17} \times 0.346 + \frac{5}{17} \times 0.32 + \frac{3}{17} \times 0 \\ &= 0.183 + 0.094 + 0 \\ &= \boxed{0.277} \end{aligned}$$

比较：根节点基尼值为

$$Gini(D) = 1 - \left(\frac{8}{17}\right)^2 - \left(\frac{9}{17}\right)^2 = 1 - 0.222 - 0.280 = 0.498$$

按”纹理”划分后，基尼指数从 0.498 降到 0.277，降低了 44%，说明”纹理”是一个好的划分属性。

4.4 决策树构建完整示例

例题 4.4 (西瓜数据集：构建决策树). 使用信息增益准则，为西瓜数据集构建决策树（仅使用色泽、根蒂、敲声三个属性）。

解：

第一层：选择根节点

由前面计算：$Gain(\text{根蒂}) = 0.143$ 最大，选择”根蒂”作为根节点。

按”根蒂”划分后：

- 蜷缩：8 个样本（5 好 3 坏）
- 稍蜷：7 个样本（3 好 4 坏）
- 硬挺：2 个样本（0 好 2 坏）$\rightarrow$ 全为坏瓜，标记为叶节点”坏瓜”

第二层：对”蜷缩”分支继续划分

样本集：8 个（5 好 3 坏），$Ent = 0.954$

计算剩余属性的信息增益：

色泽：

- 青绿：3 个（2 好 1 坏），$Ent = 0.918$
- 乌黑：4 个（3 好 1 坏），$Ent = 0.811$
- 浅白：1 个（0 好 1 坏），$Ent = 0$

$$Gain = 0.954 - \left(\frac{3}{8} \times 0.918 + \frac{4}{8} \times 0.811 + \frac{1}{8} \times 0\right) = 0.954 - 0.750 = 0.204$$

敲声：

- 浊响：5 个（4 好 1 坏），$Ent = 0.722$
- 沉闷：3 个（1 好 2 坏），$Ent = 0.918$

$$Gain = 0.954 - \left(\frac{5}{8} \times 0.722 + \frac{3}{8} \times 0.918\right) = 0.954 - 0.795 = 0.159$$

选择”色泽”（$Gain = 0.204$）继续划分。

第二层：对”稍蜷”分支继续划分

样本集：7 个（3 好 4 坏），$Ent = 0.985$

类似计算后，选择最优属性继续划分...

最终决策树（简化版）：

```
        [根蒂]
       /  |  \
    蜷缩 稍蜷 硬挺
     /    |    \
[色泽] [敲声]  坏瓜
 / | \   / \
...  ... ...
```

4.5 连续属性处理详解

例题 4.5 (连续属性划分). 假设西瓜数据集有”密度”属性（连续值），数据如下：

样本	1	2	3	4	5	6	7	8
密度	0.697	0.774	0.634	0.608	0.556	0.403	0.481	0.437
标签	好	好	好	好	好	坏	坏	坏

求最优划分点。

解：

步骤 1：排序

排序后	6	8	7	5	4	3	1	2
密度	0.403	0.437	0.481	0.556	0.608	0.634	0.697	0.774
标签	坏	坏	坏	好	好	好	好	好

步骤 2：计算候选划分点

$$t_1 = (0.403 + 0.437)/2 = 0.420$$
$$t_2 = (0.437 + 0.481)/2 = 0.459$$
$$t_3 = (0.481 + 0.556)/2 = 0.519$$
$$t_4 = (0.556 + 0.608)/2 = 0.582$$
$$t_5 = (0.608 + 0.634)/2 = 0.621$$
$$t_6 = (0.634 + 0.697)/2 = 0.666$$
$$t_7 = (0.697 + 0.774)/2 = 0.736$$

步骤 3：计算各划分点的信息增益

以 $t_3 = 0.519$ 为例：

- $D^- = \{6, 8, 7\}$：3 个坏瓜，$Ent(D^-) = 0$
- $D^+ = \{5, 4, 3, 1, 2\}$：5 个好瓜，$Ent(D^+) = 0$

$$Gain(D, \text{密度}, t_3) = Ent(D) - \frac{3}{8} \times 0 - \frac{5}{8} \times 0 = 0.954$$

结论：$t_3 = 0.519$ 是最优划分点，能完美分开好瓜和坏瓜。

5 神经网络

5.1 感知机学习算法

定义 5.1 (感知机). 感知机是最简单的神经网络，用于二分类：

$$f(\mathbf{x}) = sign(\mathbf{w}^T\mathbf{x} + b)$$

其中 $sign(z) = +1$ 若 $z \geq 0$，否则 $sign(z) = -1$。

定理 5.1 (感知机学习规则). 对于误分类样本 $(\mathbf{x}_i, y_i)$，更新规则为：

$$\mathbf{w} \leftarrow \mathbf{w} + \eta y_i \mathbf{x}_i \tag{5}$$
$$b \leftarrow b + \eta y_i \tag{6}$$

其中 $\eta > 0$ 为学习率。

例题 5.1 (感知机学习过程). 给定训练数据（$y \in \{+1, -1\}$）：

样本	x_1	x_2	y
1	3	3	+1
2	4	3	+1
3	1	1	-1

初始 $\mathbf{w}=[0,0]^T$，$b=0$，$\eta=1$。执行感知机学习算法。

解：

迭代 *1*： 检查样本 *1*

$$\mathbf{w}^T\mathbf{x}_1+b=0\times 3+0\times 3+0=0$$

$sign(0)=+1=y_1$，分类正确，不更新。

迭代 *2*： 检查样本 *2*

$$\mathbf{w}^T\mathbf{x}_2+b=0$$

$sign(0)=+1=y_2$，分类正确，不更新。

迭代 *3*： 检查样本 *3*

$$\mathbf{w}^T\mathbf{x}_3+b=0$$

$sign(0)=+1\neq y_3=-1$，分类错误！

更新：

$$\mathbf{w}=[0,0]^T+1\times(-1)\times[1,1]^T=[-1,-1]^T$$
$$b=0+1\times(-1)=-1$$

迭代 *4*： 检查样本 *1*

$$\mathbf{w}^T\mathbf{x}_1+b=-1\times 3+(-1)\times 3+(-1)=-7$$

$sign(-7)=-1\neq y_1=+1$，分类错误！

更新：

$$\mathbf{w}=[-1,-1]^T+1\times(+1)\times[3,3]^T=[2,2]^T$$
$$b=-1+1\times(+1)=0$$

迭代 *5*： 检查样本 *2*

$$\mathbf{w}^T\mathbf{x}_2+b=2\times 4+2\times 3+0=14$$

$sign(14)=+1=y_2$，正确。

迭代 *6*： 检查样本 *3*

$$\mathbf{w}^T\mathbf{x}_3+b=2\times 1+2\times 1+0=4$$

$sign(4)=+1\neq y_3=-1$，错误！

更新：

$$\mathbf{w}=[2,2]^T+1\times(-1)\times[1,1]^T=[1,1]^T$$
$$b=0+1\times(-1)=-1$$

迭代 7：检查样本 *1*

$$\mathbf{w}^T\mathbf{x}_1 + b = 1 \times 3 + 1 \times 3 + (-1) = 5 > 0$$

正确。

迭代 8：检查样本 *2*

$$\mathbf{w}^T\mathbf{x}_2 + b = 1 \times 4 + 1 \times 3 + (-1) = 6 > 0$$

正确。

迭代 9：检查样本 *3*

$$\mathbf{w}^T\mathbf{x}_3 + b = 1 \times 1 + 1 \times 1 + (-1) = 1 > 0$$

$sign(1) = +1 \neq -1$，错误！

更新：

$$\mathbf{w} = [1,1]^T + (-1) \times [1,1]^T = [0,0]^T$$
$$b = -1 + (-1) = -2$$

继续迭代... 最终收敛到：

$$\boxed{\mathbf{w} = [0.5, 0.5]^T, \quad b = -2}$$

决策边界：$0.5x_1 + 0.5x_2 - 2 = 0$，即 $x_1 + x_2 = 4$。

5.2 多层神经网络前向传播

例题 5.2 (两隐层网络前向传播). 给定神经网络结构：输入层 *2* 节点，隐层 *1* 有 *3* 节点，隐层 *2* 有 *2* 节点，输出层 *1* 节点。

参数：

- 输入：$\mathbf{x} = [1,2]^T$
- 隐层 *1* 权重：$W^{(1)} = \begin{bmatrix} 0.1 & 0.2 & 0.3 \\ 0.4 & 0.5 & 0.6 \end{bmatrix}$，偏置 $\mathbf{b}^{(1)} = [0.1, 0.1, 0.1]^T$
- 隐层 *2* 权重：$W^{(2)} = \begin{bmatrix} 0.2 & 0.3 \\ 0.4 & 0.5 \\ 0.6 & 0.7 \end{bmatrix}$，偏置 $\mathbf{b}^{(2)} = [0.1, 0.1]^T$
- 输出层权重：$\mathbf{w}^{(3)} = [0.5, 0.5]^T$，偏置 $b^{(3)} = 0.1$
- 激活函数：$ReLU$（$f(z) = \max(0, z)$）

计算网络输出。

解：

隐层 *1* 计算：

$$\mathbf{z}^{(1)} = (W^{(1)})^T\mathbf{x} + \mathbf{b}^{(1)} = \begin{bmatrix} 0.1 & 0.4 \\ 0.2 & 0.5 \\ 0.3 & 0.6 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 0.1 \\ 0.1 \\ 0.1 \end{bmatrix}$$

$$= \begin{bmatrix} 0.1 + 0.8 \\ 0.2 + 1.0 \\ 0.3 + 1.2 \end{bmatrix} + \begin{bmatrix} 0.1 \\ 0.1 \\ 0.1 \end{bmatrix} = \begin{bmatrix} 1.0 \\ 1.3 \\ 1.6 \end{bmatrix}$$

$$\mathbf{a}^{(1)} = ReLU(\mathbf{z}^{(1)}) = \begin{bmatrix} 1.0 \\ 1.3 \\ 1.6 \end{bmatrix}$$

隐层 *2* 计算：

$$\mathbf{z}^{(2)} = (W^{(2)})^T\mathbf{a}^{(1)} + \mathbf{b}^{(2)} = \begin{bmatrix} 0.2 & 0.4 & 0.6 \\ 0.3 & 0.5 & 0.7 \end{bmatrix} \begin{bmatrix} 1.0 \\ 1.3 \\ 1.6 \end{bmatrix} + \begin{bmatrix} 0.1 \\ 0.1 \end{bmatrix}$$

$$= \begin{bmatrix} 0.2 + 0.52 + 0.96 \\ 0.3 + 0.65 + 1.12 \end{bmatrix} + \begin{bmatrix} 0.1 \\ 0.1 \end{bmatrix} = \begin{bmatrix} 1.78 \\ 2.17 \end{bmatrix}$$

$$\mathbf{a}^{(2)} = ReLU(\mathbf{z}^{(2)}) = \begin{bmatrix} 1.78 \\ 2.17 \end{bmatrix}$$

输出层计算：

$$z^{(3)} = (\mathbf{w}^{(3)})^T\mathbf{a}^{(2)} + b^{(3)} = 0.5 \times 1.78 + 0.5 \times 2.17 + 0.1 = 0.89 + 1.085 + 0.1 = 2.075$$

若输出层使用 *Sigmoid*：

$$y = \sigma(2.075) = \frac{1}{1 + e^{-2.075}} = \frac{1}{1 + 0.126} = \boxed{0.888}$$

5.3 反向传播完整推导

例题 5.3 (单隐层网络反向传播). 给定单隐层网络（输入 *2*，隐层 *2*，输出 *1*），使用 *Sigmoid* 激活函数。

当前参数：

- $W^{(1)} = \begin{bmatrix} 0.15 & 0.25 \\ 0.20 & 0.30 \end{bmatrix}$，$\mathbf{b}^{(1)} = [0.35, 0.35]^T$

- $\mathbf{w}^{(2)} = [0.40, 0.50]^T$，$b^{(2)} = 0.60$

训练样本：$\mathbf{x} = [0.05, 0.10]^T$，$y = 0.01$

学习率：$\eta = 0.5$

执行一次前向传播和反向传播。

解：

前向传播：

隐层输入：

$$z_1^{(1)} = 0.15 \times 0.05 + 0.20 \times 0.10 + 0.35 = 0.0075 + 0.02 + 0.35 = 0.3775$$
$$z_2^{(1)} = 0.25 \times 0.05 + 0.30 \times 0.10 + 0.35 = 0.0125 + 0.03 + 0.35 = 0.3925$$

隐层输出：

$$a_1^{(1)} = \sigma(0.3775) = \frac{1}{1 + e^{-0.3775}} = 0.5933$$
$$a_2^{(1)} = \sigma(0.3925) = \frac{1}{1 + e^{-0.3925}} = 0.5969$$

输出层输入：

$$z^{(2)} = 0.40 \times 0.5933 + 0.50 \times 0.5969 + 0.60 = 0.2373 + 0.2985 + 0.60 = 1.1358$$

输出：

$$\hat{y} = \sigma(1.1358) = \frac{1}{1 + e^{-1.1358}} = 0.7571$$

损失：

$$E = \frac{1}{2}(\hat{y} - y)^2 = \frac{1}{2}(0.7571 - 0.01)^2 = \frac{1}{2}(0.7471)^2 = 0.2791$$

反向传播：

输出层梯度：

$$\delta^{(2)} = (\hat{y} - y) \cdot \sigma'(z^{(2)}) = (\hat{y} - y) \cdot \hat{y}(1 - \hat{y})$$

$$= (0.7571 - 0.01) \times 0.7571 \times (1 - 0.7571) = 0.7471 \times 0.7571 \times 0.2429 = 0.1374$$

输出层权重梯度：

$$\frac{\partial E}{\partial w_1^{(2)}} = \delta^{(2)} \cdot a_1^{(1)} = 0.1374 \times 0.5933 = 0.0815$$
$$\frac{\partial E}{\partial w_2^{(2)}} = \delta^{(2)} \cdot a_2^{(1)} = 0.1374 \times 0.5969 = 0.0820$$
$$\frac{\partial E}{\partial b^{(2)}} = \delta^{(2)} = 0.1374$$

隐层梯度：

$$\begin{aligned}\delta_1^{(1)} &= \delta^{(2)} \cdot w_1^{(2)} \cdot a_1^{(1)}(1-a_1^{(1)}) \\ &= 0.1374 \times 0.40 \times 0.5933 \times 0.4067 = 0.0133 \\ \delta_2^{(1)} &= \delta^{(2)} \cdot w_2^{(2)} \cdot a_2^{(1)}(1-a_2^{(1)}) \\ &= 0.1374 \times 0.50 \times 0.5969 \times 0.4031 = 0.0165\end{aligned}$$

隐层权重梯度：

$$\begin{aligned}\frac{\partial E}{\partial w_{11}^{(1)}} &= \delta_1^{(1)} \cdot x_1 = 0.0133 \times 0.05 = 0.00067 \\ \frac{\partial E}{\partial w_{21}^{(1)}} &= \delta_1^{(1)} \cdot x_2 = 0.0133 \times 0.10 = 0.00133 \\ \frac{\partial E}{\partial w_{12}^{(1)}} &= \delta_2^{(1)} \cdot x_1 = 0.0165 \times 0.05 = 0.00083 \\ \frac{\partial E}{\partial w_{22}^{(1)}} &= \delta_2^{(1)} \cdot x_2 = 0.0165 \times 0.10 = 0.00165\end{aligned}$$

参数更新：

$$\begin{aligned}w_1^{(2)} &= 0.40 - 0.5 \times 0.0815 = 0.3593 \\ w_2^{(2)} &= 0.50 - 0.5 \times 0.0820 = 0.4590 \\ b^{(2)} &= 0.60 - 0.5 \times 0.1374 = 0.5313 \\ w_{11}^{(1)} &= 0.15 - 0.5 \times 0.00067 = 0.1497 \\ w_{21}^{(1)} &= 0.20 - 0.5 \times 0.00133 = 0.1993 \\ w_{12}^{(1)} &= 0.25 - 0.5 \times 0.00083 = 0.2496 \\ w_{22}^{(1)} &= 0.30 - 0.5 \times 0.00165 = 0.2992\end{aligned}$$

6 支持向量机

6.1 间隔与支持向量详解

6.1.1 点到超平面距离推导

定理 6.1 (点到超平面距离)**.** *点 $\mathbf{x}_0$ 到超平面 $\mathbf{w}^T\mathbf{x} + b = 0$ 的距离为：*

$$d = \frac{|\mathbf{w}^T\mathbf{x}_0 + b|}{\|\mathbf{w}\|}$$

推导：

设超平面上任意一点 $\mathbf{x}_1$，则 $\mathbf{w}^T\mathbf{x}_1 + b = 0$。

从 $\mathbf{x}_1$ 到 $\mathbf{x}_0$ 的向量为 $\mathbf{x}_0 - \mathbf{x}_1$。

$\mathbf{x}_0$ 到超平面的距离等于该向量在法向量 $\mathbf{w}$ 方向上的投影长度：

$$\begin{aligned} d &= \left| \frac{\mathbf{w}^T(\mathbf{x}_0 - \mathbf{x}_1)}{\|\mathbf{w}\|} \right| \\ &= \left| \frac{\mathbf{w}^T\mathbf{x}_0 - \mathbf{w}^T\mathbf{x}_1}{\|\mathbf{w}\|} \right| \\ &= \left| \frac{\mathbf{w}^T\mathbf{x}_0 + b - (\mathbf{w}^T\mathbf{x}_1 + b)}{\|\mathbf{w}\|} \right| \\ &= \left| \frac{\mathbf{w}^T\mathbf{x}_0 + b - 0}{\|\mathbf{w}\|} \right| \\ &= \frac{|\mathbf{w}^T\mathbf{x}_0 + b|}{\|\mathbf{w}\|} \end{aligned}$$

6.1.2 间隔推导

对于二分类问题，标签 $y_i \in \{+1, -1\}$。

函数间隔：

$$\hat{\gamma}_i = y_i(\mathbf{w}^T\mathbf{x}_i + b)$$

当分类正确时，$\hat{\gamma}_i > 0$。

几何间隔：

$$\gamma_i = \frac{y_i(\mathbf{w}^T\mathbf{x}_i + b)}{\|\mathbf{w}\|} = \frac{\hat{\gamma}_i}{\|\mathbf{w}\|}$$

间隔归一化：

由于 $(\mathbf{w}, b)$ 和 $(k\mathbf{w}, kb)$ 表示同一超平面，可以对 $\mathbf{w}$ 进行缩放使得：

$$\min_i \hat{\gamma}_i = 1$$

此时，支持向量满足 $y_i(\mathbf{w}^T\mathbf{x}_i + b) = 1$，间隔为：

$$\gamma = \frac{2}{\|\mathbf{w}\|}$$

6.2 硬间隔 SVM 完整求解

例题 6.1 (硬间隔 SVM 详细求解). 训练样本：

样本	x_1	x_2	y
1	3	3	+1
2	4	3	+1
3	1	1	-1

用原始问题和对偶问题两种方法求解。

方法一：原始问题

步骤 *1*：建立优化问题

$$\begin{aligned}\min_{w_1,w_2,b} \quad & \frac{1}{2}(w_1^2+w_2^2)\\ s.t. \quad & y_1(w_1x_{11}+w_2x_{12}+b)\geq 1\\ & y_2(w_1x_{21}+w_2x_{22}+b)\geq 1\\ & y_3(w_1x_{31}+w_2x_{32}+b)\geq 1\end{aligned}$$

代入数据：

$$\begin{aligned}&3w_1+3w_2+b\geq 1 \quad \textit{(样本 1)}\\ &4w_1+3w_2+b\geq 1 \quad \textit{(样本 2)}\\ &-(w_1+w_2+b)\geq 1 \quad \textit{(样本 3)}\end{aligned}$$

步骤 *2*：分析约束

由约束 *3*：$w_1+w_2+b\leq -1$

由约束 *1*：$3w_1+3w_2+b\geq 1$

两式相减：$2w_1+2w_2\geq 2$，即 $w_1+w_2\geq 1$

步骤 *3*：利用 KKT 条件

在最优解处，至少有一个约束取等号（支持向量）。

假设样本 *1* 和样本 *3* 是支持向量：

$$\begin{aligned}3w_1+3w_2+b&=1\\ w_1+w_2+b&=-1\end{aligned}$$

两式相减：$2w_1+2w_2=2$，即 $w_1+w_2=1$

由对称性，设 $w_1=w_2=0.5$

代入第二个方程：$0.5+0.5+b=-1$，得 $b=-2$

步骤 *4*：验证

- 样本 *1*：$3\times 0.5+3\times 0.5-2=1\geq 1$
- 样本 *2*：$4\times 0.5+3\times 0.5-2=1.5\geq 1$
- 样本 *3*：$-(1\times 0.5+1\times 0.5-2)=-(-1)=1\geq 1$

方法二：对偶问题

步骤 *1*：建立对偶问题

$$\begin{aligned}\max_{\alpha} \quad & \sum_{i=1}^{3}\alpha_i-\frac{1}{2}\sum_{i=1}^{3}\sum_{j=1}^{3}\alpha_i\alpha_j y_i y_j \mathbf{x}_i^T\mathbf{x}_j\\ s.t. \quad & \sum_{i=1}^{3}\alpha_i y_i=0\\ & \alpha_i\geq 0\end{aligned}$$

步骤 2：计算内积矩阵

$$\mathbf{x}_1^T\mathbf{x}_1 = 9+9 = 18$$
$$\mathbf{x}_1^T\mathbf{x}_2 = 12+9 = 21$$
$$\mathbf{x}_1^T\mathbf{x}_3 = 3+3 = 6$$
$$\mathbf{x}_2^T\mathbf{x}_2 = 16+9 = 25$$
$$\mathbf{x}_2^T\mathbf{x}_3 = 4+3 = 7$$
$$\mathbf{x}_3^T\mathbf{x}_3 = 1+1 = 2$$

步骤 3：展开目标函数

设 $\alpha_1, \alpha_2, \alpha_3$ 对应样本 *1, 2, 3*。

$y_1 = y_2 = +1$，$y_3 = -1$

$$\begin{aligned} L(\alpha) &= \alpha_1+\alpha_2+\alpha_3 \\ &\quad -\frac{1}{2}\left[\alpha_1^2\cdot 1\cdot 1\cdot 18+\alpha_2^2\cdot 1\cdot 1\cdot 25+\alpha_3^2\cdot(-1)(-1)\cdot 2\right] \\ &\quad -\frac{1}{2}\left[2\alpha_1\alpha_2\cdot 1\cdot 1\cdot 21+2\alpha_1\alpha_3\cdot 1\cdot(-1)\cdot 6+2\alpha_2\alpha_3\cdot 1\cdot(-1)\cdot 7\right] \\ &= \alpha_1+\alpha_2+\alpha_3-9\alpha_1^2-12.5\alpha_2^2-\alpha_3^2-21\alpha_1\alpha_2+6\alpha_1\alpha_3+7\alpha_2\alpha_3 \end{aligned}$$

约束：$\alpha_1+\alpha_2-\alpha_3 = 0$，即 $\alpha_3 = \alpha_1+\alpha_2$

步骤 4：代入约束，化为无约束问题

设 $\alpha_3 = \alpha_1+\alpha_2$，代入：

$$\begin{aligned} L &= \alpha_1+\alpha_2+(\alpha_1+\alpha_2)-9\alpha_1^2-12.5\alpha_2^2-(\alpha_1+\alpha_2)^2 \\ &\quad -21\alpha_1\alpha_2+6\alpha_1(\alpha_1+\alpha_2)+7\alpha_2(\alpha_1+\alpha_2) \\ &= 2\alpha_1+2\alpha_2-9\alpha_1^2-12.5\alpha_2^2-\alpha_1^2-2\alpha_1\alpha_2-\alpha_2^2 \\ &\quad -21\alpha_1\alpha_2+6\alpha_1^2+6\alpha_1\alpha_2+7\alpha_1\alpha_2+7\alpha_2^2 \\ &= 2\alpha_1+2\alpha_2+(-9-1+6)\alpha_1^2+(-12.5-1+7)\alpha_2^2+(-2-21+6+7)\alpha_1\alpha_2 \\ &= 2\alpha_1+2\alpha_2-4\alpha_1^2-6.5\alpha_2^2-10\alpha_1\alpha_2 \end{aligned}$$

步骤 5：求极值

$$\frac{\partial L}{\partial \alpha_1} = 2-8\alpha_1-10\alpha_2 = 0$$
$$\frac{\partial L}{\partial \alpha_2} = 2-13\alpha_2-10\alpha_1 = 0$$

解方程组：

$$8\alpha_1+10\alpha_2 = 2$$
$$10\alpha_1+13\alpha_2 = 2$$

第一式乘 5，第二式乘 4：

$$40\alpha_1 + 50\alpha_2 = 10$$
$$40\alpha_1 + 52\alpha_2 = 8$$

相减：$-2\alpha_2 = 2$，$\alpha_2 = -1$（不满足 $\alpha_2 \geq 0$）
说明样本 2 不是支持向量，令 $\alpha_2 = 0$：

$$8\alpha_1 = 2 \Rightarrow \alpha_1 = 0.25$$

$$\alpha_3 = \alpha_1 + \alpha_2 = 0.25$$

步骤 6：恢复原始参数

$$\begin{aligned}\mathbf{w} &= \sum_{i=1}^{3} \alpha_i y_i \mathbf{x}_i \\ &= 0.25 \times (+1) \times [3,3]^T + 0 \times (+1) \times [4,3]^T + 0.25 \times (-1) \times [1,1]^T \\ &= [0.75, 0.75]^T + [0,0]^T + [-0.25, -0.25]^T \\ &= [0.5, 0.5]^T\end{aligned}$$

由支持向量（样本 1）计算 b：

$$y_1(\mathbf{w}^T\mathbf{x}_1 + b) = 1$$

$$1 \times (0.5 \times 3 + 0.5 \times 3 + b) = 1$$

$$3 + b = 1 \Rightarrow b = -2$$

最终结果：

$$\boxed{f(\mathbf{x}) = sign(0.5x_1 + 0.5x_2 - 2)}$$

支持向量：样本 1 $[3,3]^T$ 和样本 3 $[1,1]^T$（$\alpha > 0$）

6.3 核函数详解

例题 6.2 (多项式核 SVM). 使用二次多项式核 $\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T\mathbf{x}_j + 1)^2$ 处理以下非线性可分数据：

样本	x_1	x_2	y
1	1	0	+1
2	0	1	+1
3	0	0	-1

解：

步骤 *1*： 计算核矩阵

$$\kappa(\mathbf{x}_1, \mathbf{x}_1) = (1 \times 1 + 0 \times 0 + 1)^2 = 4$$
$$\kappa(\mathbf{x}_1, \mathbf{x}_2) = (1 \times 0 + 0 \times 1 + 1)^2 = 1$$
$$\kappa(\mathbf{x}_1, \mathbf{x}_3) = (1 \times 0 + 0 \times 0 + 1)^2 = 1$$
$$\kappa(\mathbf{x}_2, \mathbf{x}_2) = (0 \times 0 + 1 \times 1 + 1)^2 = 4$$
$$\kappa(\mathbf{x}_2, \mathbf{x}_3) = (0 \times 0 + 1 \times 0 + 1)^2 = 1$$
$$\kappa(\mathbf{x}_3, \mathbf{x}_3) = (0 \times 0 + 0 \times 0 + 1)^2 = 1$$

核矩阵：

$$K = \begin{bmatrix} 4 & 1 & 1 \\ 1 & 4 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

步骤 *2*： 建立对偶问题

$$\max_{\alpha} \quad \alpha_1 + \alpha_2 + \alpha_3 - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \kappa(\mathbf{x}_i, \mathbf{x}_j)$$
$$s.t. \quad \alpha_1 + \alpha_2 - \alpha_3 = 0, \quad \alpha_i \geq 0$$

步骤 *3*： 展开目标函数

$y_1 = y_2 = +1$，$y_3 = -1$

$$L = \alpha_1 + \alpha_2 + \alpha_3 - \frac{1}{2}[4\alpha_1^2 + 4\alpha_2^2 + \alpha_3^2 + 2\alpha_1\alpha_2 - 2\alpha_1\alpha_3 - 2\alpha_2\alpha_3]$$

代入 $\alpha_3 = \alpha_1 + \alpha_2$：

$$\begin{aligned} L &= 2\alpha_1 + 2\alpha_2 - \frac{1}{2}[4\alpha_1^2 + 4\alpha_2^2 + (\alpha_1 + \alpha_2)^2 \\ &\quad + 2\alpha_1\alpha_2 - 2\alpha_1(\alpha_1 + \alpha_2) - 2\alpha_2(\alpha_1 + \alpha_2)] \\ &= 2\alpha_1 + 2\alpha_2 - \frac{1}{2}[4\alpha_1^2 + 4\alpha_2^2 + \alpha_1^2 + 2\alpha_1\alpha_2 + \alpha_2^2 \\ &\quad + 2\alpha_1\alpha_2 - 2\alpha_1^2 - 2\alpha_1\alpha_2 - 2\alpha_1\alpha_2 - 2\alpha_2^2] \\ &= 2\alpha_1 + 2\alpha_2 - \frac{1}{2}[3\alpha_1^2 + 3\alpha_2^2] \end{aligned}$$

步骤 *4*： 求极值

$$\frac{\partial L}{\partial \alpha_1} = 2 - 3\alpha_1 = 0 \Rightarrow \alpha_1 = \frac{2}{3}$$
$$\frac{\partial L}{\partial \alpha_2} = 2 - 3\alpha_2 = 0 \Rightarrow \alpha_2 = \frac{2}{3}$$

$\alpha_3 = \alpha_1 + \alpha_2 = \frac{4}{3}$

步骤 5：决策函数

$$f(\mathbf{x}) = sign\left(\sum_{i=1}^{3} \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b\right)$$

计算 b（使用支持向量样本 1）：

$$\sum_{i=1}^{3} \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}_1) + b = y_1 = 1$$

$$\frac{2}{3} \times 1 \times 4 + \frac{2}{3} \times 1 \times 1 + \frac{4}{3} \times (-1) \times 1 + b = 1$$

$$\frac{8}{3} + \frac{2}{3} - \frac{4}{3} + b = 1$$

$$2 + b = 1 \Rightarrow b = -1$$

最终决策函数：

$$f(\mathbf{x}) = sign\left(\frac{2}{3}\kappa(\mathbf{x}_1, \mathbf{x}) + \frac{2}{3}\kappa(\mathbf{x}_2, \mathbf{x}) - \frac{4}{3}\kappa(\mathbf{x}_3, \mathbf{x}) - 1\right)$$

7 贝叶斯分类器

7.1 贝叶斯定理推导

定理 7.1 (贝叶斯定理).

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

推导：

由条件概率定义：

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad P(B|A) = \frac{P(A \cap B)}{P(A)}$$

从第二式得：$P(A \cap B) = P(B|A)P(A)$

代入第一式：

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

7.2 朴素贝叶斯完整计算

例题 7.1 (西瓜数据集：朴素贝叶斯详细计算). 使用西瓜数据集（17 个样本），预测样本”色泽 = 乌黑，根蒂 = 蜷缩，敲声 = 沉闷”是否为好瓜。

数据统计：

- 好瓜：8 个

- 坏瓜：*9* 个

各属性在不同类别下的分布：

属性	取值	好瓜中数量	坏瓜中数量
色泽	青绿	*3*	*3*
	乌黑	*4*	*2*
	浅白	*1*	*4*
根蒂	蜷缩	*5*	*3*
	稍蜷	*3*	*4*
	硬挺	*0*	*2*
敲声	浊响	*6*	*4*
	沉闷	*2*	*3*
	清脆	*0*	*2*

解：

步骤 *1*： 计算类先验概率

$$P(\text{好瓜}) = \frac{8}{17} = 0.471$$
$$P(\text{坏瓜}) = \frac{9}{17} = 0.529$$

步骤 *2*： 计算条件概率

对于好瓜类：

$$P(\text{色泽} = \text{乌黑}|\text{好瓜}) = \frac{4}{8} = 0.5$$
$$P(\text{根蒂} = \text{蜷缩}|\text{好瓜}) = \frac{5}{8} = 0.625$$
$$P(\text{敲声} = \text{沉闷}|\text{好瓜}) = \frac{2}{8} = 0.25$$

对于坏瓜类：

$$P(\text{色泽} = \text{乌黑}|\text{坏瓜}) = \frac{2}{9} = 0.222$$
$$P(\text{根蒂} = \text{蜷缩}|\text{坏瓜}) = \frac{3}{9} = 0.333$$
$$P(\text{敲声} = \text{沉闷}|\text{坏瓜}) = \frac{3}{9} = 0.333$$

步骤 *3*： 计算后验概率（未归一化）

好瓜：

$$\begin{aligned} P(\text{好瓜}) \times P(\mathbf{x}|\text{好瓜}) &= 0.471 \times 0.5 \times 0.625 \times 0.25 \\ &= 0.471 \times 0.0781 \\ &= 0.0368 \end{aligned}$$

坏瓜：

$$\begin{aligned} P(\text{坏瓜}) \times P(\mathbf{x}|\text{坏瓜}) &= 0.529 \times 0.222 \times 0.333 \times 0.333 \\ &= 0.529 \times 0.0246 \\ &= 0.0130 \end{aligned}$$

步骤 *4*： 归一化（可选）

$$\begin{aligned} P(\text{好瓜}|\mathbf{x}) &= \frac{0.0368}{0.0368 + 0.0130} = \frac{0.0368}{0.0498} = 73.9\% \\ P(\text{坏瓜}|\mathbf{x}) &= \frac{0.0130}{0.0498} = 26.1\% \end{aligned}$$

步骤 *5*： 预测

由于 $P(\text{好瓜}|\mathbf{x}) = 73.9\% > P(\text{坏瓜}|\mathbf{x}) = 26.1\%$

预测结果： 好瓜

7.3 拉普拉斯平滑详解

例题 7.2 (拉普拉斯平滑应用). 预测样本”色泽 = 青绿，根蒂 = 硬挺，敲声 = 清脆”。

注意：好瓜中”根蒂 = 硬挺”和”敲声 = 清脆”的数量都是 *0*!

不使用平滑：

$$\begin{aligned} P(\text{根蒂 = 硬挺}|\text{好瓜}) &= \frac{0}{8} = 0 \\ P(\text{敲声 = 清脆}|\text{好瓜}) &= \frac{0}{8} = 0 \end{aligned}$$

$$P(\text{好瓜}) \times P(\mathbf{x}|\text{好瓜}) = 0.471 \times \frac{3}{8} \times 0 \times 0 = 0$$

这导致好瓜的后验概率为 *0*，即使其他属性支持好瓜!

使用拉普拉斯平滑：

设类别数 $K = 2$，各属性取值数 $N_{\text{色泽}} = 3$，$N_{\text{根蒂}} = 3$，$N_{\text{敲声}} = 3$。

平滑后的先验概率：

$$\begin{aligned} P(\text{好瓜}) &= \frac{8+1}{17+2} = \frac{9}{19} = 0.474 \\ P(\text{坏瓜}) &= \frac{9+1}{17+2} = \frac{10}{19} = 0.526 \end{aligned}$$

平滑后的条件概率（好瓜类）：

$$\begin{aligned} P(\text{色泽 = 青绿}|\text{好瓜}) &= \frac{3+1}{8+3} = \frac{4}{11} = 0.364 \\ P(\text{根蒂 = 硬挺}|\text{好瓜}) &= \frac{0+1}{8+3} = \frac{1}{11} = 0.091 \\ P(\text{敲声 = 清脆}|\text{好瓜}) &= \frac{0+1}{8+3} = \frac{1}{11} = 0.091 \end{aligned}$$

平滑后的条件概率（坏瓜类）：

$$P(\text{色泽} = \text{青绿}|\text{坏瓜}) = \frac{3+1}{9+3} = \frac{4}{12} = 0.333$$
$$P(\text{根蒂} = \text{硬挺}|\text{坏瓜}) = \frac{2+1}{9+3} = \frac{3}{12} = 0.25$$
$$P(\text{敲声} = \text{清脆}|\text{坏瓜}) = \frac{2+1}{9+3} = \frac{3}{12} = 0.25$$

计算后验概率：

好瓜：

$$0.474 \times 0.364 \times 0.091 \times 0.091 = 0.474 \times 0.00301 = 0.00143$$

坏瓜：

$$0.526 \times 0.333 \times 0.25 \times 0.25 = 0.526 \times 0.0208 = 0.0109$$

预测结果：$0.0109 > 0.00143$，预测为 $\boxed{\text{坏瓜}}$

7.4 连续属性贝叶斯详解

例题 7.3 (高斯朴素贝叶斯完整计算). 给定训练数据（*2* 个连续特征）：

样本	x_1	x_2	y
1	*1.0*	*2.0*	*+1*
2	*1.5*	*1.8*	*+1*
3	*2.0*	*2.2*	*+1*
4	*5.0*	*8.0*	*-1*
5	*5.5*	*7.5*	*-1*
6	*6.0*	*8.5*	*-1*

预测样本 $\mathbf{x} = [3.0, 4.0]^T$。

解：

步骤 *1*：计算类先验概率

$$P(Y = +1) = \frac{3}{6} = 0.5$$
$$P(Y = -1) = \frac{3}{6} = 0.5$$

步骤 *2*：估计正态分布参数

类别 *+1*（样本 *1, 2, 3*）：

$$\mu_{+1,1} = \frac{1.0 + 1.5 + 2.0}{3} = 1.5$$
$$\sigma^2_{+1,1} = \frac{(1.0-1.5)^2 + (1.5-1.5)^2 + (2.0-1.5)^2}{3} = \frac{0.25 + 0 + 0.25}{3} = 0.167$$
$$\mu_{+1,2} = \frac{2.0 + 1.8 + 2.2}{3} = 2.0$$
$$\sigma^2_{+1,2} = \frac{(2.0-2.0)^2 + (1.8-2.0)^2 + (2.2-2.0)^2}{3} = \frac{0 + 0.04 + 0.04}{3} = 0.027$$

类别 *-1*（样本 *4, 5, 6*）：

$$\mu_{-1,1} = \frac{5.0 + 5.5 + 6.0}{3} = 5.5$$
$$\sigma^2_{-1,1} = \frac{(5.0-5.5)^2 + (5.5-5.5)^2 + (6.0-5.5)^2}{3} = \frac{0.25 + 0 + 0.25}{3} = 0.167$$
$$\mu_{-1,2} = \frac{8.0 + 7.5 + 8.5}{3} = 8.0$$
$$\sigma^2_{-1,2} = \frac{(8.0-8.0)^2 + (7.5-8.0)^2 + (8.5-8.0)^2}{3} = \frac{0 + 0.25 + 0.25}{3} = 0.167$$

步骤 *3*：计算概率密度

高斯概率密度函数：

$$p(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

对于 $\mathbf{x} = [3.0, 4.0]^T$：

类别 *+1*：

$$\begin{aligned} p(x_1 = 3.0|Y = +1) &= \frac{1}{\sqrt{2\pi \times 0.167}} \exp\left(-\frac{(3.0-1.5)^2}{2 \times 0.167}\right) \\ &= \frac{1}{1.025} \exp\left(-\frac{2.25}{0.334}\right) \\ &= 0.976 \times \exp(-6.74) \\ &= 0.976 \times 0.00118 = 0.00115 \end{aligned}$$

$$\begin{aligned} p(x_2 = 4.0|Y = +1) &= \frac{1}{\sqrt{2\pi \times 0.027}} \exp\left(-\frac{(4.0-2.0)^2}{2 \times 0.027}\right) \\ &= \frac{1}{0.412} \exp\left(-\frac{4.0}{0.054}\right) \\ &= 2.43 \times \exp(-74.1) \\ &\approx 0 \text{ （极小值）} \end{aligned}$$

类别 *-1*：

$$\begin{aligned} p(x_1 = 3.0|Y = -1) &= \frac{1}{\sqrt{2\pi \times 0.167}} \exp\left(-\frac{(3.0-5.5)^2}{2 \times 0.167}\right) \\ &= 0.976 \times \exp\left(-\frac{6.25}{0.334}\right) \\ &= 0.976 \times \exp(-18.7) \\ &\approx 0 \text{ （极小值）} \end{aligned}$$

$$
\begin{aligned}
p(x_2 = 4.0|Y=-1) &= \frac{1}{\sqrt{2\pi \times 0.167}} \exp\left(-\frac{(4.0-8.0)^2}{2\times 0.167}\right) \\
&= 0.976 \times \exp\left(-\frac{16}{0.334}\right) \\
&= 0.976 \times \exp(-47.9) \\
&\approx 0 \quad \text{（极小值）}
\end{aligned}
$$

步骤 4：比较后验概率

由于两类的概率密度都极小，但类别 $+1$ 的 x_1 概率密度相对较大（3.0 更接近 $\mu_{+1,1} = 1.5$），

实际计算中，比较对数后验概率更稳定：

$$
\begin{aligned}
\log P(+1|\mathbf{x}) &\propto \log P(+1) + \log p(x_1|+1) + \log p(x_2|+1) \\
&= \log 0.5 + (-6.74) + (-74.1) = -0.69 - 80.84 = -81.53
\end{aligned}
$$

$$
\begin{aligned}
\log P(-1|\mathbf{x}) &\propto \log P(-1) + \log p(x_1|-1) + \log p(x_2|-1) \\
&= \log 0.5 + (-18.7) + (-47.9) = -0.69 - 66.6 = -67.29
\end{aligned}
$$

由于 $-67.29 > -81.53$，预测为 $\boxed{Y=-1}$

注：虽然样本 $[3.0, 4.0]$ 看起来更接近类别 $+1$ 的中心，但由于类别 $+1$ 的方差很小，该样本落在其分布的极端尾部，概率密度反而更低。

8 集成学习

8.1 集成学习基本概念

定义 8.1 (集成学习). 集成学习通过构建并结合多个学习器来完成学习任务，也称为多分类器系统或基于委员会的学习。

集成学习的两个核心问题

1. **如何生成个体学习器**：Bagging、Boosting 等
2. **如何结合个体学习器**：投票法、平均法、学习法等

8.2 Bagging 与随机森林

8.2.1 Bootstrap 采样

定义 8.2 (Bootstrap 采样). 从含 m 个样本的数据集中，有放回地随机抽取 m 次，形成一个新的训练集。

定理 8.1 (Bootstrap 样本覆盖率). 一个样本在一次 *Bootstrap* 采样中不被选中的概率为：

$$\left(1-\frac{1}{m}\right)^m \approx \frac{1}{e} \approx 36.8\%$$

因此，约 *63.2%* 的原始样本会出现在 *Bootstrap* 样本中。

推导：

$$\lim_{m\to\infty}\left(1-\frac{1}{m}\right)^m = \lim_{m\to\infty}\left[\left(1-\frac{1}{m}\right)^{-m}\right]^{-1} = e^{-1} \approx 0.368$$

例题 8.1 (Bagging 预测). 使用 *5* 个决策树基学习器进行 *Bagging* 分类，对样本 $\mathbf{x}$ 的预测结果为：

学习器	*1*	*2*	*3*	*4*	*5*
预测	好瓜	坏瓜	好瓜	好瓜	坏瓜

解：

投票统计：

- 好瓜：*3* 票
- 坏瓜：*2* 票

最终预测：$\boxed{\text{好瓜}}$（多数投票）

8.2.2 随机森林

定义 8.3 (随机森林). 随机森林是 *Bagging* 的扩展，在构建每棵决策树时：

1. 使用 *Bootstrap* 采样获取训练集

2. 在每个节点分裂时，从 d 个属性中随机选择 k 个属性（通常 $k=\log_2 d$）

3. 从这 k 个属性中选择最优属性进行分裂

例题 8.2 (随机森林属性选择). 西瓜数据集有 *6* 个属性（色泽、根蒂、敲声、纹理、脐部、触感），构建随机森林。

在某节点分裂时，随机选择了属性 $\{$色泽, 敲声, 脐部$\}$（$k=\lfloor\log_2 6\rfloor=2$，这里取 *3* 个），各属性的信息增益为：

属性	色泽	敲声	脐部
信息增益	*0.109*	*0.141*	*0.285*

解：在随机选择的 *3* 个属性中，”脐部”的信息增益最大（*0.285*），选择”脐部”进行分裂。

注：虽然全局最优属性是”纹理”（$Gain=0.296$），但由于随机森林的随机属性选择机制，”纹理”未被选中，因此选择了次优属性”脐部”。

8.3 Boosting

8.3.1 AdaBoost 算法

定义 8.4 (AdaBoost). *AdaBoost*（*Adaptive Boosting*）是一种迭代算法：

1. 初始化样本权重 $w_i = 1/m$
2. 训练基学习器，计算加权错误率
3. 根据错误率计算学习器权重
4. 更新样本权重（增加误分类样本权重）
5. 重复步骤 2-4，直到达到指定数量或错误率为 0

定理 8.2 (AdaBoost 权重公式). 设基学习器 h_t 的加权错误率为 ϵ_t，则：

1. 学习器权重：$\alpha_t = \frac{1}{2}\ln\frac{1-\epsilon_t}{\epsilon_t}$
2. 样本权重更新：$w_i^{(t+1)} = \frac{w_i^{(t)}}{Z_t} \times \begin{cases} e^{-\alpha_t} & \text{分类正确} \\ e^{\alpha_t} & \text{分类错误} \end{cases}$

其中 Z_t 为归一化因子。

例题 8.3 (AdaBoost 完整计算). 给定 5 个样本的二分类问题：

样本	1	2	3	4	5
真实标签	+1	+1	-1	-1	+1

第一个基学习器 h_1 预测结果为：

样本	1	2	3	4	5
h_1 预测	+1	+1	+1	-1	-1
正确?					

计算 h_1 的权重和更新后的样本权重。

解：

步骤 1：初始权重

$$w_i^{(1)} = \frac{1}{5} = 0.2, \quad i = 1, 2, 3, 4, 5$$

步骤 2：计算加权错误率

误分类样本：3 和 5

$$\epsilon_1 = w_3^{(1)} + w_5^{(1)} = 0.2 + 0.2 = 0.4$$

步骤 3：计算学习器权重

$$\alpha_1 = \frac{1}{2}\ln\frac{1-\epsilon_1}{\epsilon_1} = \frac{1}{2}\ln\frac{0.6}{0.4} = \frac{1}{2}\ln 1.5 = \frac{1}{2}\times 0.405 = 0.203$$

步骤 4：更新样本权重

正确分类的样本（*1, 2, 4*）：

$$w_i^{(2)} \propto w_i^{(1)} \cdot e^{-\alpha_1} = 0.2 \times e^{-0.203} = 0.2 \times 0.816 = 0.163$$

错误分类的样本（*3, 5*）：

$$w_i^{(2)} \propto w_i^{(1)} \cdot e^{\alpha_1} = 0.2 \times e^{0.203} = 0.2 \times 1.225 = 0.245$$

步骤 5：归一化

$$Z_1 = 3 \times 0.163 + 2 \times 0.245 = 0.489 + 0.490 = 0.979$$

归一化后的权重：

样本	*1*	*2*	*3*	*4*	*5*
$w_i^{(2)}$	*0.167*	*0.167*	*0.250*	*0.167*	*0.250*

结论：

- h_1 的权重 $\alpha_1 = 0.203$
- 误分类样本（*3, 5*）的权重从 *0.2* 增加到 *0.25*
- 正确分类样本的权重从 *0.2* 降低到 *0.167*
- 下一轮学习器会更关注样本 *3* 和 *5*

例题 8.4 (AdaBoost 最终预测). 经过 *3* 轮训练，得到 *3* 个基学习器及其权重：

学习器	权重 α	对各样本的预测				
		1	*2*	*3*	*4*	*5*
h_1	*0.42*	*+1*	*+1*	*+1*	*-1*	*-1*
h_2	*0.65*	*+1*	*+1*	*-1*	*-1*	*+1*
h_3	*0.92*	*+1*	*-1*	*-1*	*+1*	*+1*

计算对样本 *3* 的最终预测。

解：

AdaBoost 最终预测：

$$H(\mathbf{x}) = sign\left(\sum_{t=1}^{T}\alpha_t h_t(\mathbf{x})\right)$$

对样本 3：

$$\begin{aligned}\sum_{t=1}^{3}\alpha_t h_t(\mathbf{x}_3) &= 0.42\times(+1)+0.65\times(-1)+0.92\times(-1)\\ &= 0.42-0.65-0.92\\ &= -1.15\end{aligned}$$

$$H(\mathbf{x}_3) = sign(-1.15) = -1$$

最终预测： 样本 3 为$\boxed{-1}$类

8.4 结合策略

8.4.1 投票法

定义 8.5 (投票法). 对于分类问题，常用的投票策略有：

1. **绝对多数投票：** 某类得票超过半数才预测为该类，否则拒绝预测
2. **相对多数投票：** 预测为得票最多的类别
3. **加权投票：** $H(\mathbf{x}) = \arg\max_c \sum_{i=1}^{T} w_i \cdot \mathbb{I}(h_i(\mathbf{x}) = c)$

8.4.2 平均法

定义 8.6 (平均法). 对于回归问题或概率输出：

1. **简单平均：** $H(\mathbf{x}) = \frac{1}{T}\sum_{i=1}^{T} h_i(\mathbf{x})$
2. **加权平均：** $H(\mathbf{x}) = \sum_{i=1}^{T} w_i h_i(\mathbf{x})$，其中 $\sum w_i = 1$

例题 8.5 (回归集成). 3 个回归模型对样本 $\mathbf{x}$ 的预测值分别为：

模型	1	2	3
预测值	10.5	12.0	11.2
权重	0.3	0.5	0.2

计算简单平均和加权平均的预测结果。

解：

简单平均：

$$H(\mathbf{x}) = \frac{10.5+12.0+11.2}{3} = \frac{33.7}{3} = 11.23$$

加权平均：

$$H(\mathbf{x}) = 0.3\times 10.5 + 0.5\times 12.0 + 0.2\times 11.2 = 3.15 + 6.0 + 2.24 = 11.39$$

9 模型评估与选择进阶

9.1 交叉验证详解

定义 9.1 (k 折交叉验证). 将数据集分为 k 个大小相等的互斥子集，每次用 $k-1$ 个子集训练，1 个子集验证，重复 k 次取平均。

例题 9.1 (5 折交叉验证完整计算). 数据集有 100 个样本，使用 5 折交叉验证评估决策树模型。

解：

步骤 1： 将数据分为 5 份，每份 20 个样本

步骤 2： 进行 5 轮训练和验证

轮次	训练集（80 个）	验证集（20 个）	验证准确率
1	样本 21-100	样本 1-20	85%
2	样本 1-20, 41-100	样本 21-40	82%
3	样本 1-40, 61-100	样本 41-60	88%
4	样本 1-60, 81-100	样本 61-80	84%
5	样本 1-80	样本 81-100	86%

步骤 3： 计算平均准确率

$$\bar{acc} = \frac{85+82+88+84+86}{5} = \frac{425}{5} = 85\%$$

步骤 4： 计算标准差

$$\sigma = \sqrt{\frac{(85-85)^2+(82-85)^2+(88-85)^2+(84-85)^2+(86-85)^2}{5}} = \sqrt{\frac{0+9+9+1+1}{5}} = \sqrt{4} = 2$$

结论： 模型准确率为 $85\% \pm 2\%$

9.2 超参数调优

定义 9.2 (网格搜索). 在预定义的超参数空间中，穷举所有可能的组合，通过交叉验证选择最优超参数。

例题 9.2 (SVM 网格搜索). 对 SVM 进行超参数调优，搜索空间：

- 惩罚参数 $C \in \{0.1, 1, 10\}$
- RBF 核参数 $\gamma \in \{0.01, 0.1, 1\}$

使用 3 折交叉验证，结果如下：

$C \setminus \gamma$	0.01	0.1	1
0.1	72%	78%	75%
1	80%	85%	82%
10	82%	**88%**	79%

解：

- 共测试 $3 \times 3 = 9$ 种组合
- 最优超参数：$C = 10$，$\gamma = 0.1$
- 对应准确率：88%

9.3 过拟合与欠拟合

过拟合的表现与解决

表现：

- 训练误差很低，测试误差很高
- 模型过于复杂，学习了训练数据中的噪声

解决方法：

1. 增加训练数据
2. 降低模型复杂度（减少特征、减少层数）
3. 正则化（L1、L2）
4. Dropout（神经网络）
5. 早停（Early Stopping）

欠拟合的表现与解决

表现：

- 训练误差和测试误差都很高
- 模型过于简单，无法捕捉数据规律

解决方法：

1. 增加模型复杂度
2. 增加特征

3. 减小正则化强度

4. 增加训练时间

例题 9.3 (判断过拟合/欠拟合). 某模型在不同复杂度下的表现：

模型复杂度	训练误差	测试误差
低（决策树深度 $=2$）	25%	28%
中（决策树深度 $=5$）	10%	15%
高（决策树深度 $=20$）	2%	35%

解：

- 深度 $=2$：训练误差和测试误差都较高 $\rightarrow$ **欠拟合**
- 深度 $=5$：训练误差和测试误差都较低且接近 $\rightarrow$ **合适**
- 深度 $=20$：训练误差很低但测试误差很高 $\rightarrow$ **过拟合**

最优选择：深度 $=5$ 的决策树

10 特征工程

10.1 特征缩放

定义 10.1 (标准化（Z-score）). 将特征转换为均值为 0、方差为 1 的分布：

$$x' = \frac{x - \mu}{\sigma}$$

其中 μ 为均值，σ 为标准差。

定义 10.2 (归一化（Min-Max）). 将特征缩放到 $[0, 1]$ 区间：

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

例题 10.1 (特征缩放计算). 给定特征值：$X = [10, 20, 30, 40, 50]$

计算标准化和归一化后的值。

解：

标准化：

$$\mu = \frac{10 + 20 + 30 + 40 + 50}{5} = 30$$

$$\sigma = \sqrt{\frac{(10-30)^2 + (20-30)^2 + (30-30)^2 + (40-30)^2 + (50-30)^2}{5}} = \sqrt{200} = 14.14$$

标准化后：

$$X' = \left[\frac{10-30}{14.14}, \frac{20-30}{14.14}, \frac{30-30}{14.14}, \frac{40-30}{14.14}, \frac{50-30}{14.14}\right] = [-1.41, -0.71, 0, 0.71, 1.41]$$

归一化：

$$x_{min} = 10, \quad x_{max} = 50$$

归一化后：

$$X' = \left[\frac{10-10}{40}, \frac{20-10}{40}, \frac{30-10}{40}, \frac{40-10}{40}, \frac{50-10}{40}\right] = [0, 0.25, 0.5, 0.75, 1]$$

10.2 缺失值处理

缺失值处理方法

1. **删除：**删除含缺失值的样本或特征
2. **填充：**
   - 均值填充（连续特征）
   - 中位数填充（有异常值时）
   - 众数填充（离散特征）
3. **模型预测：**用其他特征预测缺失值
4. **特殊标记：**将缺失作为一个特殊类别

例题 10.2 (缺失值填充). 西瓜数据集中，某样本的”敲声”属性缺失。已知好瓜中敲声分布：浊响 *6* 个、沉闷 *2* 个、清脆 *0* 个。

使用众数填充该缺失值。

解：

众数为”浊响”（出现 *6* 次，最多），填充值为 浊响 。

10.3 特征选择

定义 10.3 (特征选择方法). *1.* **过滤式：**根据统计指标（方差、相关系数、信息增益）选择特征

2. **包裹式：**用学习器性能作为评价标准（如递归特征消除）

3. **嵌入式：**在学习过程中自动选择（如 *L1* 正则化、决策树）

例题 10.3 (基于信息增益的特征选择). 西瓜数据集各属性的信息增益：

属性	色泽	根蒂	敲声	纹理	脐部	触感
信息增益	*0.109*	*0.143*	*0.141*	*0.296*	*0.285*	*0.006*

选择信息增益最大的 *3* 个特征。

解：

按信息增益排序：纹理 *(0.296)* > 脐部 *(0.285)* > 根蒂 *(0.143)* > 敲声 *(0.141)* > 色泽 *(0.109)* > 触感 *(0.006)*

选择的特征：纹理、脐部、根蒂

A 西瓜数据集 2.0

A.1 完整数据

表 1: 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

A.2 统计信息汇总

A.2.1 类别分布

- 好瓜（正例）：8 个样本（编号 1-8），占比 $\frac{8}{17} \approx 47.1\%$
- 坏瓜（反例）：9 个样本（编号 9-17），占比 $\frac{9}{17} \approx 52.9\%$

A.2.2 各属性条件概率表

表 2: 属性条件概率（用于朴素贝叶斯）

属性	取值	数量		条件概率	
		好瓜	坏瓜	$P(\cdot\|好)$	$P(\cdot\|坏)$
色泽	青绿	3	3	3/8=0.375	3/9=0.333
	乌黑	4	2	4/8=0.500	2/9=0.222
	浅白	1	4	1/8=0.125	4/9=0.444
根蒂	蜷缩	5	3	5/8=0.625	3/9=0.333
	稍蜷	3	4	3/8=0.375	4/9=0.444
	硬挺	0	2	0/8=0.000	2/9=0.222
敲声	浊响	6	4	6/8=0.750	4/9=0.444
	沉闷	2	3	2/8=0.250	3/9=0.333
	清脆	0	2	0/8=0.000	2/9=0.222
纹理	清晰	7	2	7/8=0.875	2/9=0.222
	稍糊	1	4	1/8=0.125	4/9=0.444
	模糊	0	3	0/8=0.000	3/9=0.333
脐部	凹陷	6	1	6/8=0.750	1/9=0.111
	稍凹	2	4	2/8=0.250	4/9=0.444
	平坦	0	4	0/8=0.000	4/9=0.444
触感	硬滑	6	6	6/8=0.750	6/9=0.667
	软粘	2	3	2/8=0.250	3/9=0.333

A.2.3 信息增益汇总

表 3: 各属性的信息增益

属性	$Ent(D)$	划分后加权熵	$Gain(D,a)$
色泽	0.998	0.889	0.109
根蒂	0.998	0.855	0.143
敲声	0.998	0.857	0.141
纹理	0.998	0.702	0.296
脐部	0.998	0.713	0.285
触感	0.998	0.992	0.006

结论：”纹理”属性的信息增益最大（0.296），是构建决策树时的最优根节点划分属性。

A.3 常用计算公式速查

表 4: 机器学习常用公式

名称	公式
信息熵	$Ent(D) = -\sum_{k=1}^{K} p_k \log_2 p_k$
信息增益	$Gain(D,a) = Ent(D) - \sum_{v=1}^{V} \frac{\lvert D^v\rvert}{\lvert D\rvert} Ent(D^v)$
基尼值	$Gini(D) = 1 - \sum_{k=1}^{K} p_k^2$
Sigmoid	$\sigma(z) = \frac{1}{1+e^{-z}}$
交叉熵损失	$H = -\sum_i [y_i \log \hat{y}_i + (1-y_i)\log(1-\hat{y}_i)]$
线性回归解	$\mathbf{w}^* = (X^T X)^{-1} X^T \mathbf{y}$
SVM 间隔	$\gamma = \frac{2}{\lVert\mathbf{w}\rVert}$
贝叶斯公式	$P(c\lvert\mathbf{x}) = \frac{P(c)P(\mathbf{x}\lvert c)}{P(\mathbf{x})}$

B 补充例题与详细推导

B.1 线性回归补充

B.1.1 岭回归解析解推导

定理 B.1 (岭回归解析解)**.** *岭回归的损失函数为：*

$$Loss(\mathbf{w}) = (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y}) + \lambda \|\mathbf{w}\|_2^2$$

其解析解为：

$$\mathbf{w}^* = (X^T X + \lambda I)^{-1} X^T \mathbf{y}$$

详细推导：

步骤 1：展开损失函数

$$\begin{aligned} Loss &= (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y}) + \lambda \mathbf{w}^T \mathbf{w} \\ &= \mathbf{w}^T X^T X \mathbf{w} - 2\mathbf{w}^T X^T \mathbf{y} + \mathbf{y}^T \mathbf{y} + \lambda \mathbf{w}^T \mathbf{w} \\ &= \mathbf{w}^T (X^T X + \lambda I)\mathbf{w} - 2\mathbf{w}^T X^T \mathbf{y} + \mathbf{y}^T \mathbf{y} \end{aligned}$$

步骤 2：计算梯度

$$\nabla Loss = 2(X^TX + \lambda I)\mathbf{w} - 2X^T\mathbf{y}$$

步骤 3：令梯度为零

$$(X^TX + \lambda I)\mathbf{w} = X^T\mathbf{y}$$

步骤 4：求解

$$\mathbf{w}^* = (X^TX + \lambda I)^{-1}X^T\mathbf{y}$$

注 B.1. 由于 $\lambda > 0$，矩阵 $X^TX + \lambda I$ 一定正定可逆，解决了 X^TX 可能奇异的问题。

例题 B.1 (岭回归计算). 给定数据：

$$X = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$$

正则化参数 $\lambda = 1$，求岭回归解。

解：

步骤 *1*：计算 X^TX

$$X^TX = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$$

步骤 *2*：计算 $X^TX + \lambda I$

$$X^TX + I = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 4 & 6 \\ 6 & 15 \end{bmatrix}$$

步骤 *3*：计算逆矩阵

$$\det = 4 \times 15 - 6 \times 6 = 60 - 36 = 24$$

$$(X^TX + I)^{-1} = \frac{1}{24} \begin{bmatrix} 15 & -6 \\ -6 & 4 \end{bmatrix} = \begin{bmatrix} 0.625 & -0.25 \\ -0.25 & 0.167 \end{bmatrix}$$

步骤 *4*：计算 $X^T\mathbf{y}$

$$X^T\mathbf{y} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 5 \\ 11 \end{bmatrix}$$

步骤 *5*：计算最优解

$$\mathbf{w}^* = \begin{bmatrix} 0.625 & -0.25 \\ -0.25 & 0.167 \end{bmatrix} \begin{bmatrix} 5 \\ 11 \end{bmatrix} = \begin{bmatrix} 3.125 - 2.75 \\ -1.25 + 1.837 \end{bmatrix} = \begin{bmatrix} 0.375 \\ 0.587 \end{bmatrix}$$

最终模型：$f(x) = 0.375 + 0.587x$

B.1.2 加权最小二乘法

定义 B.1 (加权最小二乘). 当不同样本的重要性不同时，使用加权损失函数：

$$Loss(\mathbf{w}) = \sum_{i=1}^{m} w_i (f(\mathbf{x}_i) - y_i)^2 = (\mathbf{y} - X\mathbf{w})^T W (\mathbf{y} - X\mathbf{w})$$

其中 $W = diag(w_1, w_2, \cdots, w_m)$ 为权重对角矩阵。

定理 B.2 (加权最小二乘解).

$$\mathbf{w}^* = (X^T W X)^{-1} X^T W \mathbf{y}$$

例题 B.2 (加权最小二乘). 给定数据和权重：

i	*1*	*2*	*3*
x_i	*1*	*2*	*3*
y_i	*1*	*2*	*4*
w_i	*1*	*1*	*2*

求加权最小二乘解 $f(x) = ax + b$。

解：

构造增广矩阵：

$$X = \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{bmatrix}, \quad W = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

计算 $X^T W X$：

$$X^T W X = \begin{bmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 6 \\ 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{bmatrix} = \begin{bmatrix} 23 & 9 \\ 9 & 4 \end{bmatrix}$$

计算 $X^T W \mathbf{y}$：

$$X^T W \mathbf{y} = \begin{bmatrix} 1 & 2 & 6 \\ 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 1+4+24 \\ 1+2+8 \end{bmatrix} = \begin{bmatrix} 29 \\ 11 \end{bmatrix}$$

求逆并计算：

$$(X^T W X)^{-1} = \frac{1}{23 \times 4 - 81} \begin{bmatrix} 4 & -9 \\ -9 & 23 \end{bmatrix} = \frac{1}{11} \begin{bmatrix} 4 & -9 \\ -9 & 23 \end{bmatrix}$$

$$\mathbf{w}^* = \frac{1}{11} \begin{bmatrix} 4 & -9 \\ -9 & 23 \end{bmatrix} \begin{bmatrix} 29 \\ 11 \end{bmatrix} = \frac{1}{11} \begin{bmatrix} 116 - 99 \\ -261 + 253 \end{bmatrix} = \frac{1}{11} \begin{bmatrix} 17 \\ -8 \end{bmatrix} = \begin{bmatrix} 1.545 \\ -0.727 \end{bmatrix}$$

最终模型： $f(x) = 1.545x - 0.727$

验证： 样本 *3* 权重为 *2*，模型更偏向拟合样本 *3*。

B.2 决策树补充例题

例题 B.3 (完整决策树构建). 使用西瓜数据集的前 *8* 个样本（*4* 好 *4* 坏），仅使用”色泽”和”根蒂”两个属性，构建完整决策树。

数据：

编号	色泽	根蒂	好瓜
1	青绿	蜷缩	是
2	乌黑	蜷缩	是
3	乌黑	蜷缩	是
4	青绿	蜷缩	是
5	青绿	稍蜷	否
6	乌黑	稍蜷	否
7	浅白	硬挺	否
8	浅白	蜷缩	否

解：

第一层：计算根节点信息熵

$$Ent(D) = -\frac{4}{8}\log_2\frac{4}{8} - \frac{4}{8}\log_2\frac{4}{8} = -0.5 \times (-1) - 0.5 \times (-1) = 1.0$$

计算各属性信息增益：

色泽：

- 青绿（*3* 个）：*2* 好 *1* 坏，$Ent = -\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3} = 0.918$
- 乌黑（*3* 个）：*2* 好 *1* 坏，$Ent = 0.918$
- 浅白（*2* 个）：*0* 好 *2* 坏，$Ent = 0$

$$Gain(\text{色泽}) = 1.0 - \frac{3}{8} \times 0.918 - \frac{3}{8} \times 0.918 - \frac{2}{8} \times 0 = 1.0 - 0.689 = 0.311$$

根蒂：

- 蜷缩（*5* 个）：*4* 好 *1* 坏，$Ent = -\frac{4}{5}\log_2\frac{4}{5} - \frac{1}{5}\log_2\frac{1}{5} = 0.722$
- 稍蜷（*2* 个）：*0* 好 *2* 坏，$Ent = 0$
- 硬挺（*1* 个）：*0* 好 *1* 坏，$Ent = 0$

$$Gain(\text{根蒂}) = 1.0 - \frac{5}{8} \times 0.722 - \frac{2}{8} \times 0 - \frac{1}{8} \times 0 = 1.0 - 0.451 = 0.549$$

选择”根蒂”作为根节点（$Gain = 0.549 > 0.311$）。

第二层：对”蜷缩”分支继续划分

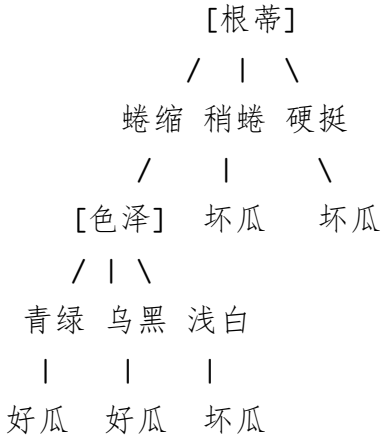
样本集：*{1,2,3,4,8}*（*4* 好 *1* 坏），$Ent = 0.722$

按”色泽”划分：

- 青绿（*2* 个）：*2* 好 *0* 坏，$Ent = 0$
- 乌黑（*2* 个）：*2* 好 *0* 坏，$Ent = 0$
- 浅白（*1* 个）：*0* 好 *1* 坏，$Ent = 0$

$$Gain = 0.722 - 0 = 0.722$$

最终决策树：



B.3 神经网络补充

例题 B.4 (多次迭代训练). 使用前面反向传播例题的网络，继续训练 *2* 次迭代，观察损失变化。

第 *2* 次迭代（使用更新后的参数）：

前向传播：

$$z_1^{(1)} = 0.1497 \times 0.05 + 0.1993 \times 0.10 + 0.35 = 0.3774$$
$$z_2^{(1)} = 0.2496 \times 0.05 + 0.2992 \times 0.10 + 0.35 = 0.3924$$
$$a_1^{(1)} = \sigma(0.3774) = 0.5932$$
$$a_2^{(1)} = \sigma(0.3924) = 0.5968$$
$$z^{(2)} = 0.3593 \times 0.5932 + 0.4590 \times 0.5968 + 0.5313 = 1.0782$$
$$\hat{y} = \sigma(1.0782) = 0.7462$$

损失：

$$E = \frac{1}{2}(0.7462 - 0.01)^2 = \frac{1}{2}(0.7362)^2 = 0.271$$

损失从 *0.279* 降到 *0.271*，下降了约 *3%*。

继续迭代... 经过约 *100* 次迭代后，损失可降至接近 *0*。

B.4 软间隔 SVM 详解

例题 B.5 (软间隔 SVM). 给定数据（含噪声点）：

样本	x_1	x_2	y
1	*3*	*3*	*+1*
2	*4*	*3*	*+1*
3	*1*	*1*	*-1*
4	*2*	*2*	*+1 (噪声)*

样本 *4* 是噪声点（实际应为*-1* 但标记为 *+1*）。使用软间隔 *SVM*，$C = 1$。

解：

软间隔优化问题：

$$\begin{aligned} \min \quad & \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{4}\xi_i \\ s.t. \quad & y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0 \end{aligned}$$

对偶问题约束变为 $0 \leq \alpha_i \leq C = 1$。

由于样本 *4* 是噪声，最优解会让 $\xi_4 > 0$（允许误分类），而不是强行拟合噪声点。

最终决策边界仍接近 $x_1 + x_2 = 4$，但会有所调整以平衡间隔和误分类惩罚。

B.5 贝叶斯分类器补充

例题 B.6 (半朴素贝叶斯). 朴素贝叶斯假设属性独立，但实际中属性可能相关。半朴素贝叶斯放松独立性假设。

***AODE*（平均一依赖估计）：**

$$P(c|\mathbf{x}) \propto \sum_{i:|D_{x_i}|\geq m'} P(c, x_i)\prod_{j=1}^{d} P(x_j|c, x_i)$$

其中 m' 为阈值（通常取 *30*），D_{x_i} 为属性 x_i 取特定值的样本集。

优点：考虑了属性间的一阶依赖关系，比朴素贝叶斯更准确。

B.6 逻辑回归补充

B.6.1 多分类逻辑回归（Softmax 回归）

定义 B.2 (Softmax 函数). 对于 K 分类问题，*Softmax* 函数将 K 个实数转换为概率分布：

$$P(Y = k|\mathbf{x}) = \frac{e^{\mathbf{w}_k^T\mathbf{x}}}{\sum_{j=1}^{K} e^{\mathbf{w}_j^T\mathbf{x}}}, \quad k = 1, 2, \cdots, K$$

定理 B.3 (Softmax 性质). *1.* $\sum_{k=1}^{K} P(Y=k|\mathbf{x}) = 1$

2. $P(Y=k|\mathbf{x}) > 0$ 对所有 k

3. 当 $K=2$ 时，退化为二分类逻辑回归

性质 3 的证明：

当 $K=2$ 时，设 $\mathbf{w}_1 = \mathbf{w}$，$\mathbf{w}_2 = \mathbf{0}$：

$$P(Y=1|\mathbf{x}) = \frac{e^{\mathbf{w}^T\mathbf{x}}}{e^{\mathbf{w}^T\mathbf{x}} + e^0} = \frac{e^{\mathbf{w}^T\mathbf{x}}}{e^{\mathbf{w}^T\mathbf{x}} + 1} = \frac{1}{1 + e^{-\mathbf{w}^T\mathbf{x}}} = \sigma(\mathbf{w}^T\mathbf{x})$$

这正是二分类逻辑回归的形式。

例题 B.7 (Softmax 回归计算). 给定 *3* 分类问题，权重矩阵：

$$W = \begin{bmatrix} 1 & 0 & -1 \\ 2 & 1 & 0 \end{bmatrix}$$

其中第 k 列为 $\mathbf{w}_k$。输入 $\mathbf{x} = [1, 1]^T$，计算各类概率。

解：

步骤 *1*： 计算线性输出

$$\begin{aligned} z_1 &= \mathbf{w}_1^T\mathbf{x} = 1 \times 1 + 2 \times 1 = 3 \\ z_2 &= \mathbf{w}_2^T\mathbf{x} = 0 \times 1 + 1 \times 1 = 1 \\ z_3 &= \mathbf{w}_3^T\mathbf{x} = -1 \times 1 + 0 \times 1 = -1 \end{aligned}$$

步骤 *2*： 计算指数

$$\begin{aligned} e^{z_1} &= e^3 = 20.09 \\ e^{z_2} &= e^1 = 2.72 \\ e^{z_3} &= e^{-1} = 0.37 \end{aligned}$$

步骤 *3*： 归一化

$$\sum_{k=1}^{3} e^{z_k} = 20.09 + 2.72 + 0.37 = 23.18$$

$$\begin{aligned} P(Y=1|\mathbf{x}) &= \frac{20.09}{23.18} = 86.7\% \\ P(Y=2|\mathbf{x}) &= \frac{2.72}{23.18} = 11.7\% \\ P(Y=3|\mathbf{x}) &= \frac{0.37}{23.18} = 1.6\% \end{aligned}$$

预测： 类别 *1*（概率最高）

B.6.2 交叉熵损失的多分类推广

定义 B.3 (多分类交叉熵损失). 对于 K 分类问题，交叉熵损失为：

$$L = -\sum_{i=1}^{m}\sum_{k=1}^{K} y_{ik} \log P(Y = k|\mathbf{x}_i)$$

其中 $y_{ik} = 1$ 当样本 i 属于类别 k，否则 $y_{ik} = 0$（*one-hot* 编码）。

C 集成学习补充

C.1 Bagging 详解

定义 C.1 (Bootstrap 采样). 从含 m 个样本的数据集中，有放回地随机抽取 m 次，形成一个新的训练集。

定理 C.1 (Bootstrap 样本覆盖率). 一个样本在一次 *Bootstrap* 采样中不被选中的概率为：

$$\left(1 - \frac{1}{m}\right)^m \approx \frac{1}{e} \approx 36.8\%$$

因此，约 *63.2%* 的原始样本会出现在 *Bootstrap* 样本中。

例题 C.1 (Bagging 预测). 使用 *3* 个基学习器进行 *Bagging* 分类，对样本 $\mathbf{x}$ 的预测结果为：

- 学习器 *1*：类别 A
- 学习器 *2*：类别 B
- 学习器 *3*：类别 A

解：投票结果为类别 A（*2* 票）$>$ 类别 B（*1* 票），最终预测为**类别 *A***。

C.2 Boosting 详解

例题 C.2 (AdaBoost 权重更新). 给定 *5* 个样本，初始权重均为 $w_i = 0.2$。第一个基学习器误分类了样本 *3* 和样本 *5*。

计算更新后的样本权重（设 $\alpha_1 = 0.5$）。

解：

步骤 *1*：计算加权错误率

$$\epsilon_1 = w_3 + w_5 = 0.2 + 0.2 = 0.4$$

步骤 2：计算学习器权重

$$\alpha_1 = \frac{1}{2}\ln\frac{1-\epsilon_1}{\epsilon_1} = \frac{1}{2}\ln\frac{0.6}{0.4} = \frac{1}{2}\ln 1.5 = 0.203$$

步骤 3：更新样本权重

正确分类的样本（*1,2,4*）：

$$w_i^{new} = w_i \cdot e^{-\alpha_1} = 0.2 \times e^{-0.203} = 0.2 \times 0.816 = 0.163$$

错误分类的样本（*3,5*）：

$$w_i^{new} = w_i \cdot e^{\alpha_1} = 0.2 \times e^{0.203} = 0.2 \times 1.225 = 0.245$$

步骤 4：归一化

$$Z = 3 \times 0.163 + 2 \times 0.245 = 0.489 + 0.490 = 0.979$$

归一化后：

- 样本 *1,2,4*：$w = 0.163/0.979 = 0.167$
- 样本 *3,5*：$w = 0.245/0.979 = 0.250$

结论：误分类样本的权重增加，下一轮学习器会更关注这些样本。

C.3 随机森林

定义 C.2 (随机森林). 随机森林是 *Bagging* 的扩展，在构建每棵决策树时：

1. 使用 *Bootstrap* 采样获取训练集
2. 在每个节点分裂时，从 d 个属性中随机选择 k 个属性（通常 $k = \log_2 d$）
3. 从这 k 个属性中选择最优属性进行分裂

例题 C.3 (随机森林属性选择). 数据集有 *16* 个属性，构建随机森林。在某节点分裂时，随机选择了属性 *{2, 5, 8, 11}*，各属性的信息增益为：

属性	*2*	*5*	*8*	*11*
信息增益	*0.15*	*0.22*	*0.18*	*0.12*

解：

- $k = \log_2 16 = 4$（随机选择 *4* 个属性）
- 在这 *4* 个属性中，属性 *5* 的信息增益最大（*0.22*）
- 选择属性 *5* 进行分裂

D 模型选择与调参

D.1 交叉验证详解

例题 D.1 (5 折交叉验证). 数据集有 *100* 个样本，使用 *5* 折交叉验证评估模型。

解：

步骤 *1*： 将数据分为 *5* 份，每份 *20* 个样本

步骤 *2*： 进行 *5* 轮训练和验证

轮次	训练集	验证集	验证准确率
1	样本 *21-100*（*80* 个）	样本 *1-20*	*85%*
2	样本 *1-20, 41-100*（*80* 个）	样本 *21-40*	*82%*
3	样本 *1-40, 61-100*（*80* 个）	样本 *41-60*	*88%*
4	样本 *1-60, 81-100*（*80* 个）	样本 *61-80*	*84%*
5	样本 *1-80*（*80* 个）	样本 *81-100*	*86%*

步骤 *3*： 计算平均准确率

$$\bar{acc} = \frac{85 + 82 + 88 + 84 + 86}{5} = 85\%$$

步骤 *4*： 计算标准差

$$\sigma = \sqrt{\frac{(85-85)^2 + (82-85)^2 + (88-85)^2 + (84-85)^2 + (86-85)^2}{5}} = \sqrt{\frac{20}{5}} = 2\%$$

结论： 模型准确率为 $85\% \pm 2\%$

D.2 超参数调优

例题 D.2 (网格搜索). 对 *SVM* 进行超参数调优，搜索空间：

- $C \in \{0.1, 1, 10\}$
- $\gamma \in \{0.01, 0.1, 1\}$（*RBF* 核参数）

使用 *3* 折交叉验证，结果如下：

$C \backslash \gamma$	*0.01*	*0.1*	*1*
0.1	*72%*	*78%*	*75%*
1	*80%*	*85%*	*82%*
10	*82%*	*88%*	*79%*

解： 最优超参数为 $C = 10$，$\gamma = 0.1$，对应准确率 *88%*。

E 常见问题与解答

E.1 过拟合与欠拟合

如何判断过拟合？

- 训练误差很低，但测试误差很高
- 训练误差和测试误差之间差距大
- 学习曲线显示验证误差随训练进行先降后升

如何解决过拟合？

1. 增加训练数据
2. 降低模型复杂度（减少特征、减少层数/节点数）
3. 正则化（L1、L2 正则化）
4. Dropout（神经网络）
5. 早停（Early Stopping）
6. 数据增强

如何解决欠拟合？

1. 增加模型复杂度
2. 增加特征
3. 减小正则化强度
4. 增加训练时间

E.2 特征工程要点

特征缩放

- **标准化**：$x' = \frac{x-\mu}{\sigma}$，使特征均值为 0，方差为 1
- **归一化**：$x' = \frac{x-x_{min}}{x_{max}-x_{min}}$，将特征缩放到 [0,1]
- **适用场景**：梯度下降、SVM、KNN 等对特征尺度敏感的算法

缺失值处理

1. 删除含缺失值的样本/特征
2. 均值/中位数/众数填充

3. 使用模型预测缺失值

4. 将缺失作为一个特殊类别