计算机网络

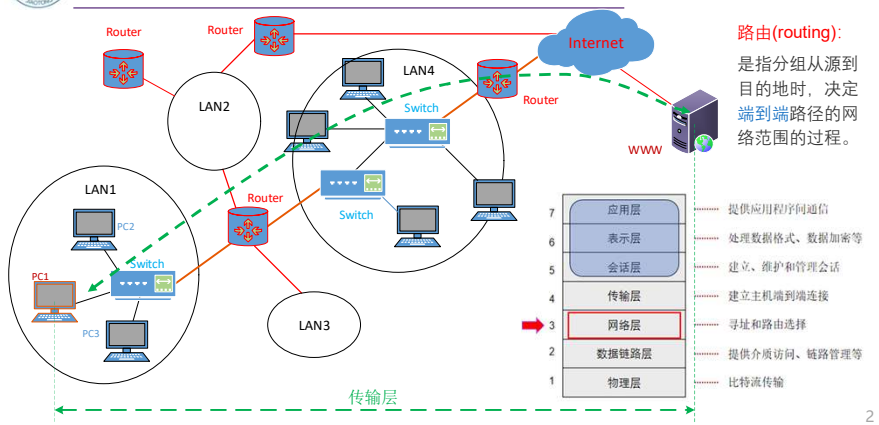
第五章 网络层

授课教师：张新有

Email：Ben_eric@qq.com

计算机与人工智能学院
School of Computing and Artificial Intelligence

回顾（DL功能和LAN）：



路由(routing):
是指分组从源到目的地时，决定端到端路径的网络范围的过程。

本章目标

1. 学习网络层服务：无连接和面向连接服务：数据报和虚电路网络
2. 学习Internet网络层协议：IPv4/IPv6, ICMP, DHCP, NAT, ARP
3. 掌握链路状态、距离矢量等路由算法，了解层次路由结构
4. 掌握Internet路由协议：OSPF、RIP、BGP，了解MPLS
5. 了解路由器工作原理：控制层和数据层，报文转发机制，交换结构
6. 了解网络拥塞及拥塞控制思想
7. 了解网络服务质量及设计思想
8. 了解其它重要的网络层相关机制：三层交换、VPN
9. 了解IPv6相关机制

本章内容

5.1 网络层服务
5.2 Internet网际协议
5.3 路由算法
5.4 Internet路由协议
5.5 路由器工作原理
5.6 拥塞控制算法
5.7 服务质量
5.8 三层交换与VPN
5.9 IPv6技术



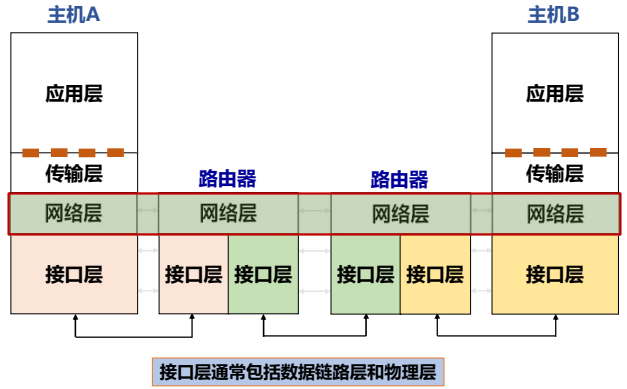
本章内容

5.1 网络层服务
5.2 Internet网际协议(P28)
5.3 路由算法(P74)
5.4 Internet路由协议(P126)
5.5 路由器工作原理(P162)
5.6 拥塞控制算法(P170)
5.7 服务质量
5.8 三层交换与VPN
5.9 IPv6技术

1. 网络层服务概述
2. 无连接服务的实现
3. 面向连接服务的实现
4. 虚电路与数据报网络的比较

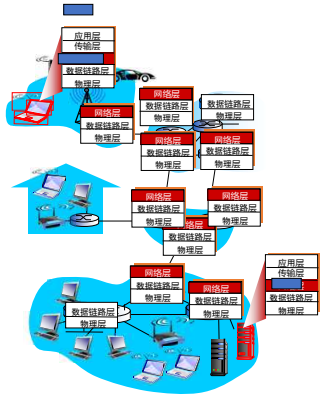
本章对应<实验五、六、七、八>四个实验

1. 网络层服务概述



网络层服务的实现

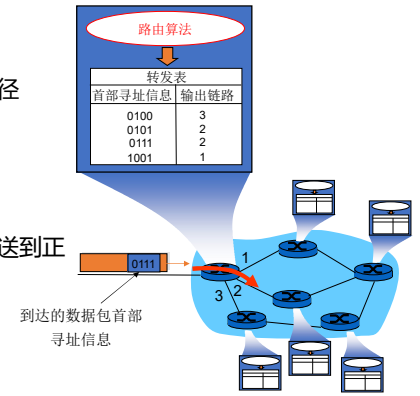
➢网络层实现端系统间多跳传输可达
➢网络层功能存在每台主机和路由器中
- 发送端：将传输层数据单元封装在数据包（分组）中
- 接收端：解析接收的数据包中，取出传输层数据单元，交付给传输层
- 路由器：检查数据包首部，转发数据包



网络层关键功能

➢ 路由（控制面）
- 选择数据报从源端到目的端的路径
- 核心：路由算法与协议

➢ 转发（数据面）
- 将数据报从路由器的输入接口传送到正确的输出接口



提供给传输层的服务

- 网络通信的可靠交付服务，谁来负责？

  “网络” OR **“端系统”**

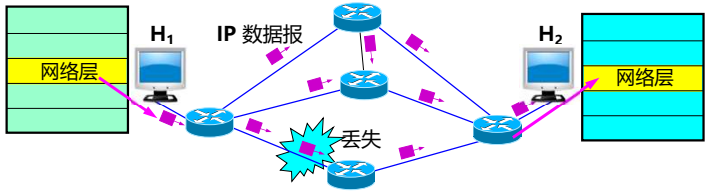
- 网络层应该向运输层提供怎样的服务？

  “面向连接”（虚电路）OR **“无连接 “**（数据报）

2. 无连接服务的实现

- 无连接服务：如寄信
  - 不需要提前建立连接
- 数据报服务
  - 网络层向上只提供简单灵活无连接的、尽最大努力交付的数据报服务
  - 发送分组时不需要先建立连接，每个分组独立发送
  - 数据报独立转发，相同源-目的的数据报可能经过不同的路径
  - 网络层不提供服务质量的承诺
- 尽力而为交付
  - 传输网络不提供端到端的可靠传输服务：丢包、乱序、错误
  - 优点：网络的造价大大降低，运行方式灵活，能够适应多种应用

无连接服务的实现

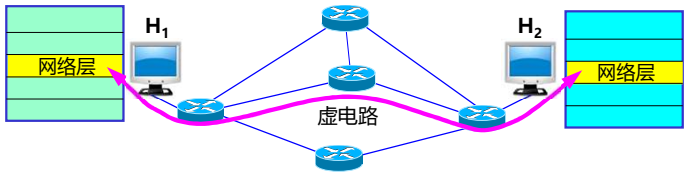


H1 发送给 H2 的分组可能沿着不同路径传送
在数据包分片的情况下，尽量还是沿相同路径

3. 面向连接服务的实现

- 面向连接服务：如打电话
  - 通信之间先建立逻辑连接：在此过程中，如有需要，可以预留网络资源
  - 结合使用可靠传输的网络协议，保证所发送的分组无差错按序到达终点
- 虚电路是逻辑连接
  - 虚电路表示这只是一条逻辑上的连接，分组都沿着这条逻辑连接按照存储转发方式传送，而并不是真正建立了一条物理连接
  - 注意，电路交换的电话通信是先建立了一条真正的连接
  - 因此分组交换的虚连接和电路交换的连接只是类似，但并不完全相同

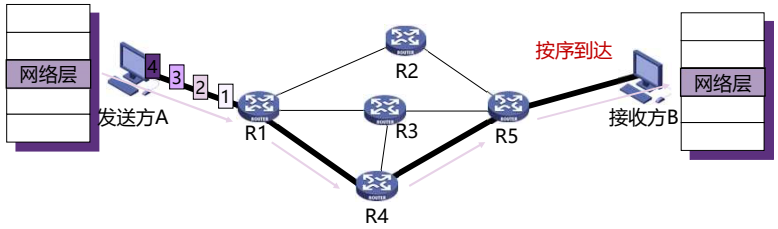
面向连接服务的实现



H_1 发送给 H_2 的所有分组都沿着同一条虚电路传送

面向连接的虚电路

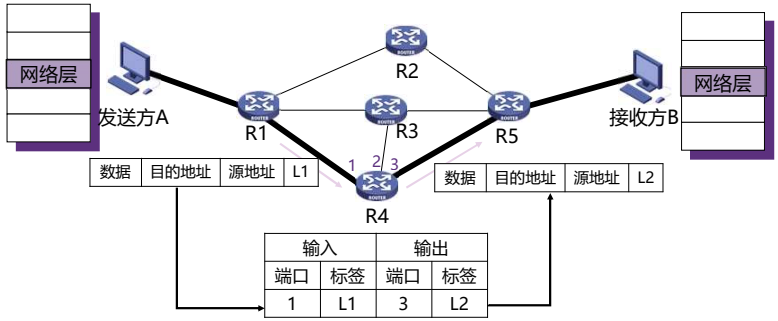
- 虚电路（Virtual Circuit）：面向连接的方法



面向连接的方法也不一定能完全保证数据的可靠传输，链路中的任何一个组成环节仍有可能失效，而这种失效是严重的，可能导致所有数据丢失；但可以提供一定的质量保证。

虚电路转发策略

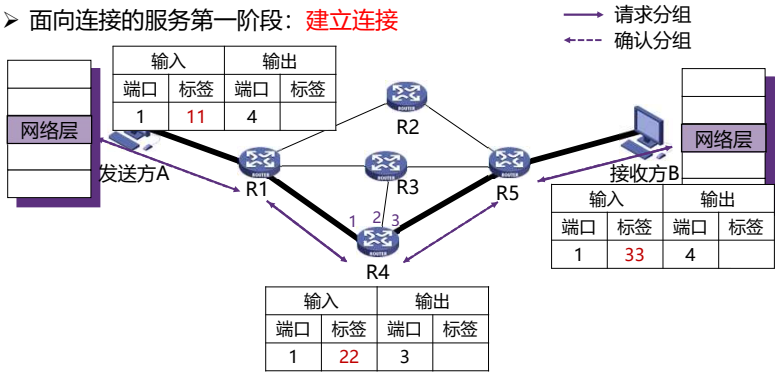
- 虚电路的转发策略：虚电路转发决策基于分组标签，即虚电路号



输入		输出	
端口	标签	端口	标签
1	L1	3	L2

虚电路的建立

- 面向连接的服务第一阶段：建立连接



输入		输出	
端口	标签	端口	标签
1	11	4	

输入		输出	
端口	标签	端口	标签
1	33	4	

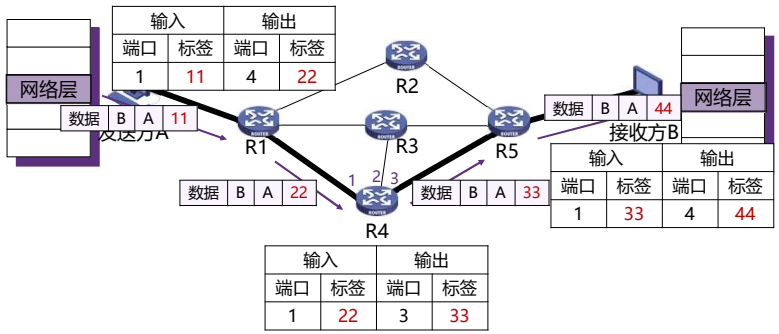
输入		输出	
端口	标签	端口	标签
1	22	3	

虚电路的使用

- 面向连接的服务第二阶段：发送数据

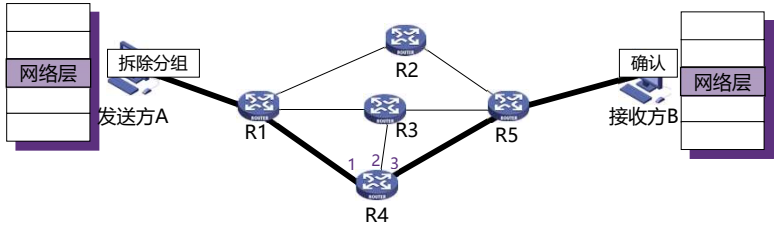
数据	目的地址	源地址	标签

分组



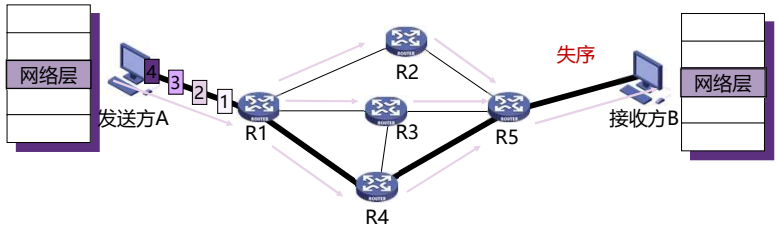
虚电路的释放

- 面向连接的服务第三阶段：释放连接



无连接的数据报（IP）

- 数据报（Datagram）：无连接的方法

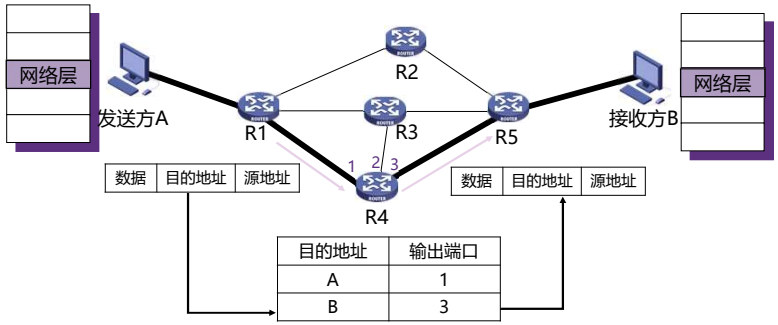


1）无连接的方法允许分组有选择不同路径的可能性，但这样可能会导致接收数据的失序；

2）为避免增加额外的开销进行数据排序，网络并不会完全随意地发送数据，在大多数情况下，仍然是会尽量沿着某一条路径发送。

数据报的转发策略

- 数据报转发策略：数据报转发决策基于分组的目的地址



4. 虚电路与数据报网络的比较

对比内容	虚电路服务	数据报服务
可靠传输的保证	可靠通信由网络保证	可靠通信由主机保证
连接的建立	必须要	不需要
地址	每个分组含有一个短的虚电路号	每个分组需要有源地址和目的地址
状态信息	建立好的虚电路要占用子网表空间	子网不存储状态信息
路由选择	分组必须经过建立好的路由发送	每个分组独立选择路由
分组顺序	总是按序到达	可能乱序
路由器失效	所有经过失效路由器的虚电路都要终止	失效结点可能丢失分组
差错处理和流量控制	网络或用户主机负责	用户主机负责
拥塞控制	容易控制	难控制

虚电路与数据报网络的比较

- 虚电路 *vs.* 数据报：哪种方法更好？
- 取决于从什么角度进行比较
  - 性能
  - 效率
  - 对失败的控制
  - 实现的复杂性
  - ……

虚电路与数据报网络的性能比较

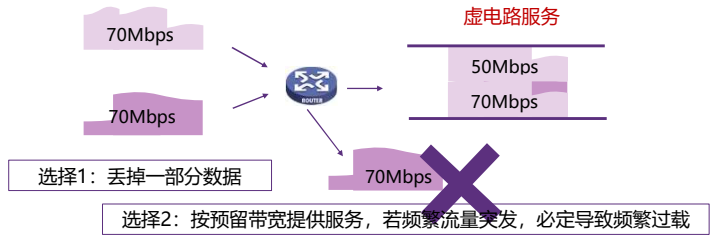
- 例1：从性能角度比较
  - 假设总带宽100Mbps，有2个数据源共享带宽
  - 如果每个数据源按50Mbps的**恒定速率**发送数据，使用虚电路服务，结果如何？



带宽不浪费
每个数据源发送数据的带宽都可被保证

虚电路与数据报网络的性能比较

- 例1：从性能角度比较
  - 假设总带宽100Mbps，有2个数据源共享带宽
  - 如果每个数据源都是**突发流量**，且最高可达70Mbps，使用虚电路服务，结果如何？



选择1：丢掉一部分数据

选择2：按预留带宽提供服务，若频繁流量突发，必定导致频繁过载

虚电路与数据报网络的性能比较

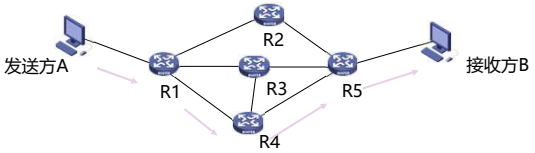
- 例1：从性能角度比较
  - 假设总带宽100Mbps，有2个数据源共享带宽
  - 如果每个数据源都是**突发流量**，且最高可达70Mbps，使用数据报服务，结果如何？



性能完全不受影响,也不会过载

虚电路与数据报网络的效率比较

- 例2：从时延角度比较
  - 假设不考虑过载，发送同样多的数据，消耗的时间比较



- 假设不考虑A的发送时延和链路传播时延，在上图3个转接节点的情况下，链路上的数据传输速率*B* bps，每个分组的长度*P* bit，每个分组的开销*H* bit，虚电路分组交换的呼叫建立时间*S* s，每个转接点的转接延迟时间*D* s，则：
  - 虚电路分组交换总时延 T=S+3[D+(P+H)/B]
  - 数据报分组交换总时延 T=3[D+(P+H)/B]

虚电路与数据报网络的发展历史

- 70-80年代：分组交换
  - X.25，帧中继
- 80年代末-90年代：研究人员和工业应用认为电路交换更好
  - 认为语音/电视直播将成为互联网真正的杀手级应用
- 目前，分组交换已经成为因特网的实际服务方式，电路交换最终没有广泛应用于互联网...Why?
  - 人们重新编写应用程序以适应网络（应用程序并不需要保证带宽）
  - Email和Web广泛应用（突发流量）
- 虚电路仍有使用（MPLS，租用专线等），因特网使用IP数据报
  - 企业分支结构之间，昂贵，通常是静态设置（而非最初所希望的动态预留资源）

思考：？
到底哪种方法更好?

本章内容

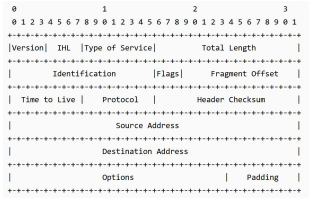
5.1 网络层服务(P5)
5.2 Internet网际协议
5.3 路由算法(P74)
5.4 Internet路由协议(P126)
5.5 路由器工作原理(P162)
5.6 拥塞控制算法(P170)
5.7 服务质量
5.8 三层交换与VPN
5.9 IPv6技术

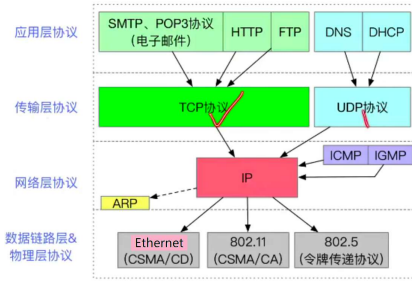
1. IPv4协议
2. IP地址
3. DHCP
4. ARP
5. NAT
6. ICMP

IP协议详解:
https://mp.weixin.qq.com/s/E6x_a6Y9Uga32K4zKHIp6w

1. IPv4协议

- IPv4协议，网际协议版本4(rfc 791)，一种无连接的协议，是互联网的核心，也是使用最广泛的网际协议版本，其后继版本为IPv6(rfc 2460)。RFC791定义的IPv4：

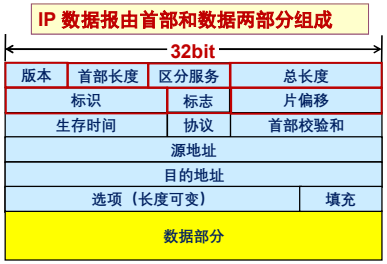




- IP协议执行两个基本功能
  - 寻址(addressing)
  - 分片(fragmentation)

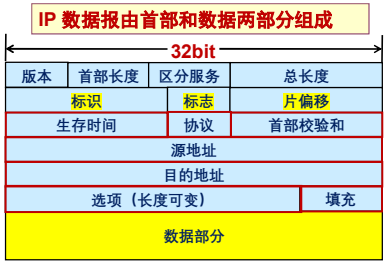
IPv4数据报格式

- 版本：4bit，表示采用的IP协议版本
- 首部长度：4bit，表示整个IP数据报首部的长度
- 区分服务：8bit，该字段一般情况下不使用
- 总长度：16bit，表示整个IP报文的长度,能表示的最大字节为2^{16}-1=65535字节
- 标识：16bit， IP软件通过计数器自动产生，每产生1个数据报计数器加1；在ip分片以后，用来标识同一片分片
- 标志：3bit，目前只有两位有意义； MF，置1表示后面还有分片，置0表示是最后1个数据分片；DF，不能分片，置0时表示允许分片
- 片偏移：13bit，表示IP分片后，相应的IP片在总的IP片的相对位置，8字节为单位2^3。



IPv4数据报格式

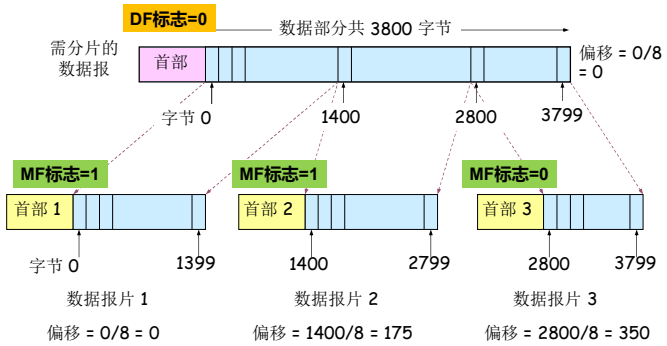
- 生存时间TTL(Time To Live)：8bit,表示数据报在网络中的生命周期，用通过路由器的数量来计量，即跳数（每经过一个路由器会减1）
- 协议：8bit，标识上层协议（TCP/UDP/ICMP...）
- 首部校验和：16bit，对数据报首部进行校验，不包括数据部分
- 源地址：32bit，标识IP片的发送源IP地址
- 目的地址：32bit，标识IP片的目的地IP地址
- 选项：可扩充部分，具有可变长度，定义了安全性、严格源路由、松散源路由、记录路由、时间戳等选项
- 填充：用全0的填充字段补齐为4字节的整数倍



数据报分片策略

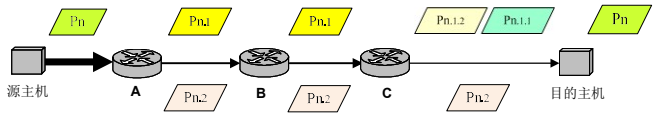
- MTU（Maximum Transmission Unit），最大传输单元
  - 链路MTU
  - 路径MTU (Path MTU)
- 分片策略
  - 允许途中分片：根据下一跳链路的MTU实施分片
  - 不允许途中分片：发出的数据报长度小于路径MTU（路径MTU发现机制）
- 重组策略
  - 途中重组，实施难度太大
  - 目的端重组（互联网采用的策略）
  - 重组所需信息：原始数据报编号、分片偏移量、是否收集所有分片

数据报分片



原始报文和分片报文具有相同的IP标识（IP头部字段）

数据报分片



- IPv4分组在传输途中可以多次分片
  - 源端系统，中间路由器（可通过标志位设定是否允许路由器分片）
- IPv4分片只在目的IP对应的目的端系统进行重组
- IPv4分片、重组字段在基本IP头部
  - 标识、标志、片偏移
- *IPv6分片机制有较大变化（见IPv6部分的介绍）*

IP协议功能及报头字段总结

网络层基本功能

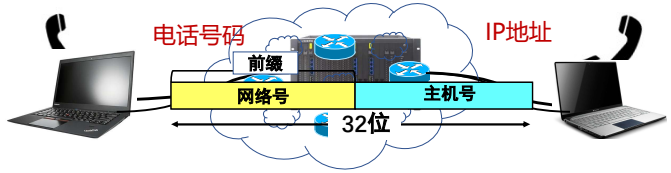
- 支持多跳寻路将IP数据报送达目的端：*目的IP地址*
- 表明发送端身份：*源IP地址*
- 根据IP头部协议类型，提交给不同上层协议处理：*协议*

其它相关问题

- 数据报长度大于传输链路的MTU的问题，通过分片机制解决：*标识、标志、片偏移*
- 防止循环转发浪费网络资源(路由错误、设备故障...)，通过跳数限制解决：*生存时间TTL*
- IP报头错误导致无效传输，通过头部机校验解决：首部校验和（checksum）

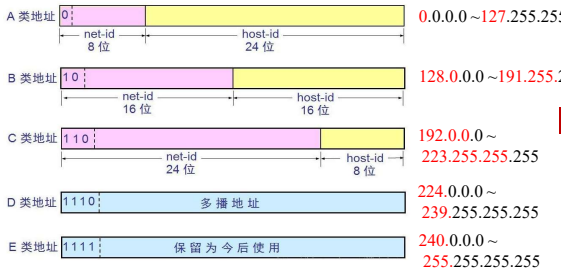
2. IP地址

- IP地址，网络上的每一台主机（或路由器）的每一个接口都会分配一个全球唯一的32位的标识符
- 将IP地址划分为固定的类，每一类都由两个字段组成
- 网络号相同的这块连续IP地址空间称为地址的前缀，或网络前缀



1) 分类的IP地址

- IP地址共分为A、B、C、D、E五类，A类、B类、C类为单播地址
- IP地址的书写采用点分十进制记法，其中每一段取值范围为0到255



0.0.0.0 ~127.255.255.255; 0, 127网络号保留

128.0.0.0 ~191.255.255.255

192.0.0.0 ~ 223.255.255.255

224.0.0.0 ~ 239.255.255.255

240.0.0.0 ~ 255.255.255.255

请判断下列地址的类型

10.2.1.1	A类
128.63.2.100	B类
201.222.5.64	C类
256.241.201.10	不存在

IP地址范围

常用的三种类别的 IP 地址：

IP 地址的使用范围

网络类别	最大网络数	第一个可用的网络号	最后一个可用的网络号	每个网络中最大的主机数
A	126 ($2^7 - 2$)	1	126	16,777,214
B	16,384 (2^{14})	128.0	191.255	65,534
C	2,097,152 (2^{21})	192.0.0	223.255.255	254

http://www.iana.org/assignments/ipv4-address-space/

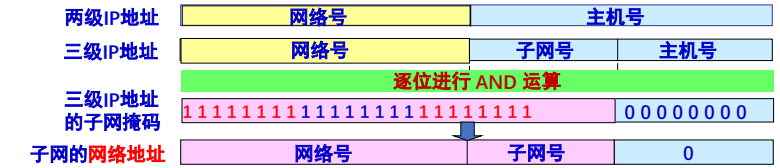
IANA与ICANN。1998年起，ICANN行使IANA的职能。

IP特殊地址

地址	用途
全0网络地址	只在系统启动时有效，用于启动时临时通信，又叫主机地址
网络127.0.0.0	指本地节点(一般为127.0.0.1)，用于测试网卡及TCP/IP软件，这样浪费了1700万个地址
全0主机地址	用于指定网络本身，称之为网络地址或者网络号
全1主机地址	用于广播，也称定向广播，需要指定目标网络
0.0.0.0	指任意地址
255.255.255.255	用于本地广播，也称有限/受限广播，无须知道本地网络地址

2) 子网（Subnet）划分

- 子网划分(subnetting)，在网络内部将一个网络块进行划分以供多个内部网络使用，对外仍是一个网络
- 子网(subnet)，一个网络进行子网划分后得到的一系列结果网络称为子网
- 子网掩码(subnet mask)，与 IP 地址一一对应，是32 bit 的二进制数，置1表示网络位，置0表示主机位，（变长子网掩码VLSM）
- 子网划分减少了 IP 地址的浪费、网络的组织更加灵活、便于维护和管理



子网划分

172	16	2	160	
255	255	255	192	
10101100	00010000	00000010	10100000	逐位进行 AND 运算
11111111	11111111	11111111	11000000	
前缀			主机位	
10101100	00010000	00000010	10000000	
10101100	00010000	00000010	10111111	

主机位全0，子网地址 172.16.2.128

主机位全1，广播地址 172.16.2.191

可分配IP地址范围 172.16.2.128+1 ~ 172.16.2.191-1

子网拥有主机数量 $2^n-2=62$（n=6）

IP地址分配示例1

例题：已知某计算机所使用的IP地址是：202.117.1.207，子网掩码是：255.255.255.224，经计算该机器的网络号是_____；子网号是_____；主机号是_____。

解题：IP地址202.117.1.207，子网掩码255.255.255.224

	11001010	01110101	00000001	110 01111
and	11111111	11111111	11111111	111 00000
	11001010	01110101	00000001	110 00000

因此：网络号：202.117.1.0；子网地址为：202.117.1.192　主机号为：0.0.0.15

该子网可容纳32个IP，范围（202.117.1.192 ~ 202.17.1.223）；子网广播地址为202.17.1.223。

IP地址分配示例2

例：C类网络202.112.10.0，子网掩码为：255.255.255.224分析其子网的个数及其可用地址范围。

解答：　11001010 01110000 00001010 xxxyyyyy

网络号+子网号　　新的主机号部分5bit

224→11100000B
二进制数xxx有八种组合，8个子网；
去掉全0/1的，剩下6种。

子网地址	主机可用IP地址范围
202.112.10. 0 (00000000)	202.112. 10. 1~30
202.112.10. 32(00100000)	202.112. 10. 33~62
202.112.10. 64(01000000)	202.112. 10. 65~94
202.112.10. 96(01100000)	202.112. 10. 97~126
202.112.10.128(10000000)	202.112. 10. 129~158
202.112.10.160(10100000)	202.112. 10. 161~190
202.112.10.192(11000000)	202.112. 10. 193~222
202.112.10.224(11100000)	202.112.10. 225~254

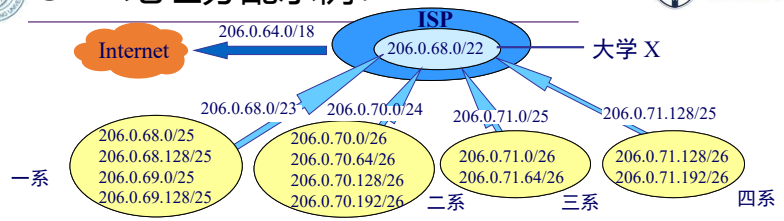
3) 无类域间路由CIDR

- CIDR(Classless Inter-Domain Routing)
  - 将32位的IP地址划分为前后两个部分，并采用斜线记法，即在IP地址后加上“/”，然后再写上网络前缀所占位数；如：202.115.64.33/24



  - 一个 CIDR 地址块可以表示很多地址，这种地址的聚合常称为路由聚合（route aggregation），也称为构成超网 (supernet)
  - 聚合技术在Internet中大量使用，它允许前缀重叠，数据包按具体路由的方向发送，即具有最少IP地址的最长匹配前缀

CIDR地址分配示例：



单位	地址块	二进制表示	地址数
ISP	206.0.64.0/18	11001110.00000000.01*	16384
大学	206.0.68.0/22	11001110.00000000.010001*	1024
一系	206.0.68.0/23	11001110.00000000.0100010*	512
二系	206.0.70.0/24	11001110.00000000.01000110.*	256
三系	206.0.71.0/25	11001110.00000000.01000111.0*	128
四系	206.0.71.128/25	11001110.00000000.01000111.1*	128

该ISP有2^6=64个C类网络。若不用CIDR技术，则与该ISP路由器交换路由信息时，相邻路由器路由表中就需要64个项目。用CIDR后，只需1个项目206.0.64.0/18就能找到该ISP。同理大学用206.0.68.0/22即可表示4个C。大大减小路由表项。

4) 最长前缀匹配

最长前缀匹配（Longest prefix match）

- CIDR可变长子网掩码以及路由聚合，需要最长前缀匹配来实现最精确匹配
- IP地址与IP前缀匹配时，总是选取子网掩码最长的匹配项
- 主要用于路由器转发表项的匹配，也应用于ACL规则匹配等

IP前缀（2种描述方式）		出接口号
200.23.16.0/21	11001000 00010111 00010	0
200.23.24.0/24	11001000 00010111 00011000	1
200.23.24.0/21	11001000 00010111 00011	2
Otherwise 0.0.0.0/0	--	3

IP地址：200.23.22.161（11001000 00010111 00010110 10100001），接口0

IP地址：200.23.24.170（11001000 00010111 00011000 10101010），接口1

最长前缀匹配

2.128.0.0/9	interface 1
2.192.0.0/10	interface 2
2.0.0.0/8	interface 3
2.2.3.0/24	interface 4
0.0.0.0/0	interface 5

根据最长前缀匹配，下述目的IP将匹配哪个表项（出接口）？

2.5.1.2 Interface 3

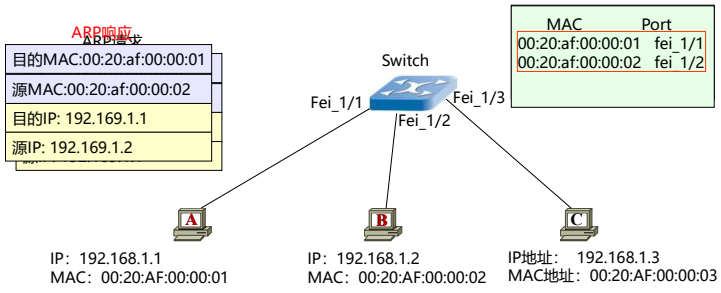
2.200.1.2 Interface 2

2.150.1.2 Interface 1

3.150.1.2 Interface 5

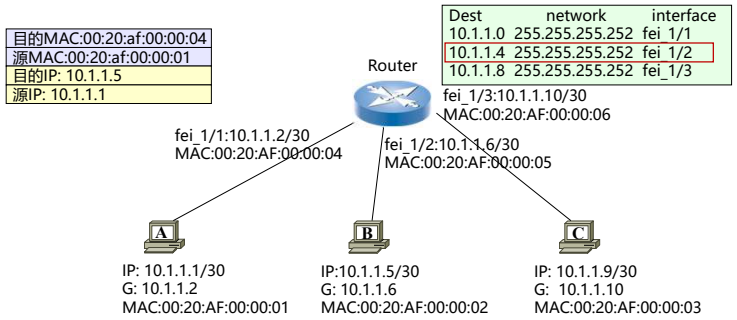
5) IP包转发

- 直接交付：与目的的主机在同一个IP子网内



IP包转发

➢ 间接交付：与目的主机不在同一个IP子网内



6) IPv4地址如何获取

➢ 公有IP地址要求全球唯一
- ICANN（Internet Corporation for Assigned Names and Numbers）即互联网名字与编号分配机构向ISP分配，ISP再向所属机构或组织逐级分配

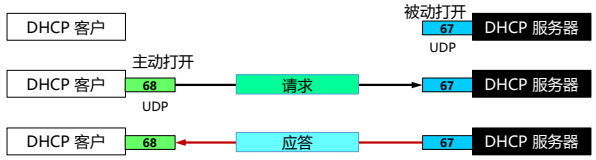
➢ 静态设定
- 申请固定IP地址，手工设定，如路由器、服务器

➢ 动态获取
- 使用DHCP协议或其他动态配置协议
- 当主机加入IP网络，允许主机从DHCP服务器动态获取IP地址
- 可以有效利用IP地址，方便移动主机的地址获取

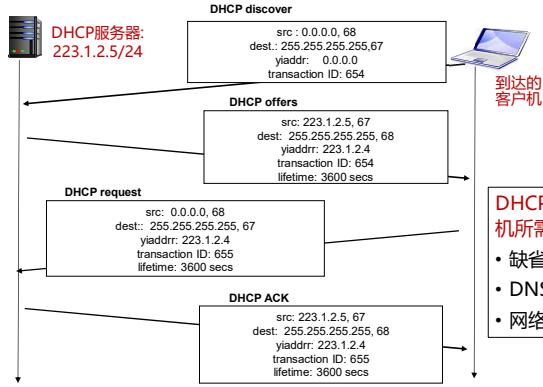
3. DHCP动态主机配置协议

➢ DHCP ： 动态主机配置协议
- 当主机加入IP网络，允许主机从DHCP服务器动态获取IP地址
- 可以有效利用IP地址，方便移动主机的地址获取

➢工作模式：客服/服务器模式(C/S)
- 基于UDP工作，客户端运行在68号端口，服务器运行在67号端口



DHCP 工作过程



DHCP服务不只返回客户机所需的IP地址，还包括:
- 缺省路由器IP地址
- DNS服务器IP地址
- 网络掩码

DHCP 工作过程

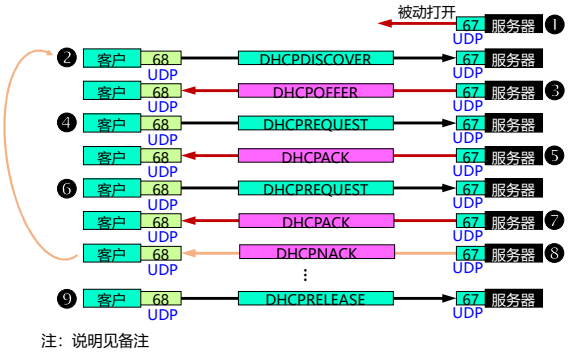
- DHCP 客户从UDP端口68以广播形式向服务器发送发现报文（DHCPDISCOVER）
- DHCP 服务器单播/广播发出提供报文（DHCPOFFER）
- DHCP 客户从多个DHCP服务器中选择一个，并向其以广播形式发送DHCP请求报文（DHCPREQUEST）
- 被选择的DHCP服务器单播/广播发送确认报文（DHCPACK）

DHCP 工作过程

- 小结

阶段	源MAC	目标MAC	源IP	目标IP	传输形式
Discover	PC机的MAC	全FF	0.0.0.0	255.255.255.255	广播
Offer	DHCP服务器或者中继器路由的MAC	DHCP客户机的MAC	DHCP服务器或中继路由器的IP地址	准备分配的IP地址	单播/广播
Request	PC机的MAC	全FF	0.0.0.0	255.255.255.255	广播
Ack	DHCP服务器或者中继器路由的MAC	DHCP客户机的MAC	DHCP服务器或中继路由器的IP地址	准备分配的IP地址	单播/广播

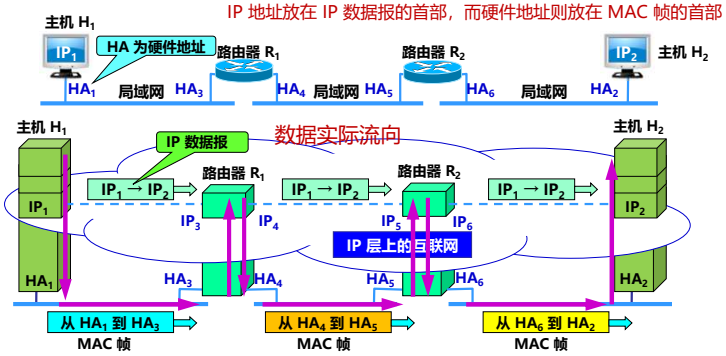
DHCP 完整工作过程



注：说明见备注

IP 与 MAC地址

IP 地址放在 IP 数据报的首部，而硬件地址则放在 MAC 帧的首部

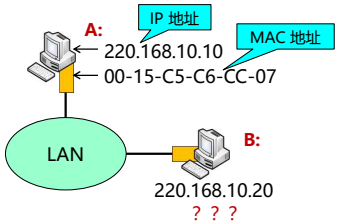


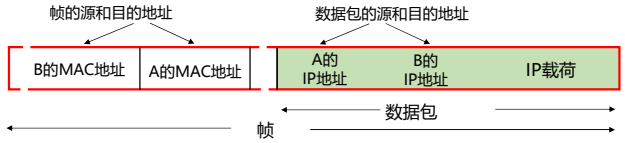
IP数据报经过不同链路时，IP数据报中封装的IP地址不发生改变，而MAC帧中的硬件地址要发生改变

4. ARP地址解析协议

- IP数据包转发：从主机A到主机B
  - 检查目的IP地址的网络号部分
  - 确定主机B与主机A属相同IP网络
  - 将IP数据包封装到链路层帧中，直接发送给主机B

问题：给定B的IP地址，如何获取B的MAC地址?





ARP地址解析协议

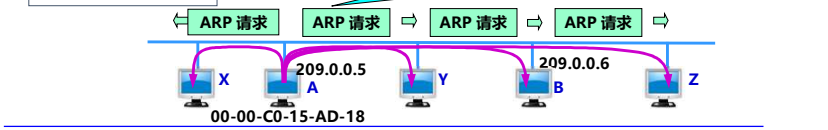
- A已知B的IP地址，需要获得B的MAC地址（物理地址）
- 如果A的ARP表中缓存有B的IP地址与MAC地址的映射关系，则直接从ARP表获取
- 如果A的ARP表中未缓存有B的IP地址与MAC地址的映射关系，则A广播包含B的IP地址的ARP query分组
  - 在局域网上的所有节点都可以接收到ARP query
- B接收到ARP query分组后，将自己的MAC地址发送给A
- A在ARP表中缓存B的IP地址和MAC地址的映射关系
  - 超时时删除

思考：ARP的优化策略?

ARP协议工作过程

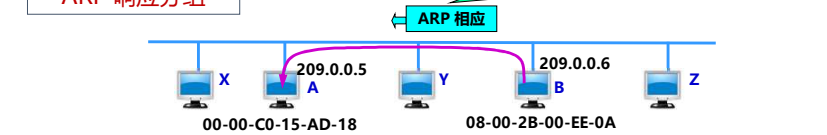
主机 A 广播发送 ARP 请求分组

我是 209.0.0.5，硬件地址是 00-00-C0-15-AD-18，我想知道主机 209.0.0.6 的硬件地址



主机B向A单播发送 ARP 响应分组

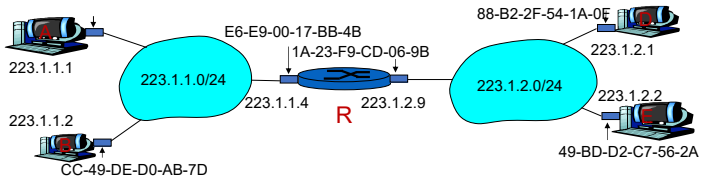
我是 209.0.0.6，硬件地址是 08-00-2B-00-EE-0A



路由到另一个局域网

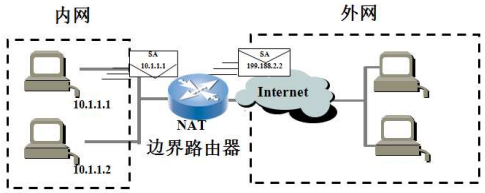
- A创建IP数据包（源为A、目的为E）
- 在源主机A的路由表中找到路由器R的IP地址223.1.1.4
- A根据R的IP地址223.1.1.4，使用ARP协议获得R的MAC地址
- A创建数据帧（目的地址为R的MAC地址）
- 数据帧中封装A到E的IP数据包
- A发送数据帧，R接收数据帧

例：从A经过R到E

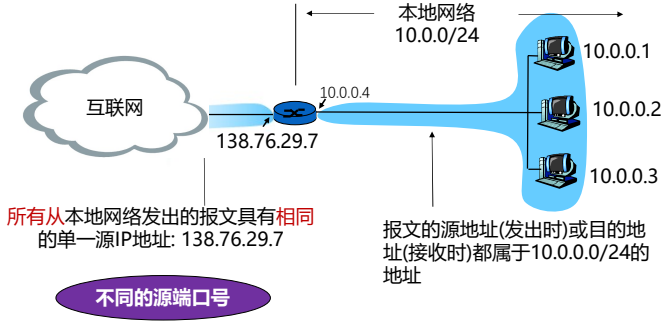


5. 网络地址转换NAT (实验六)

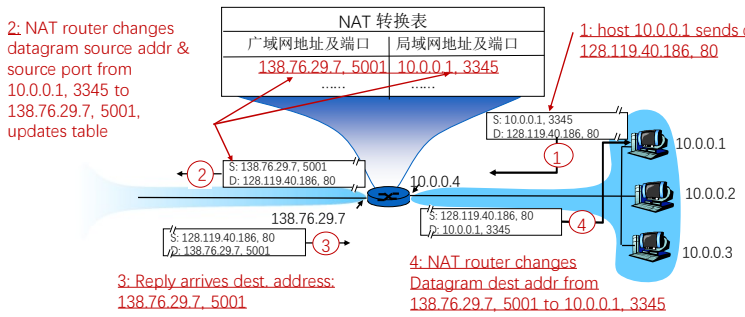
- 网络地址转换(NAT：Network Address Translation)用于解决IPv4地址不足的问题，是一种将私有（保留）地址转化为公有IP地址的转换技术。
- 私有IP地址：
  - A类地址：10.0.0.0--10.255.255.255　1个A网
  - B类地址：172.16.0.0--172.31.255.555　16个B网
  - C类地址：192.168.0.0--192.168.255.255　256个C网



NAT工作机制

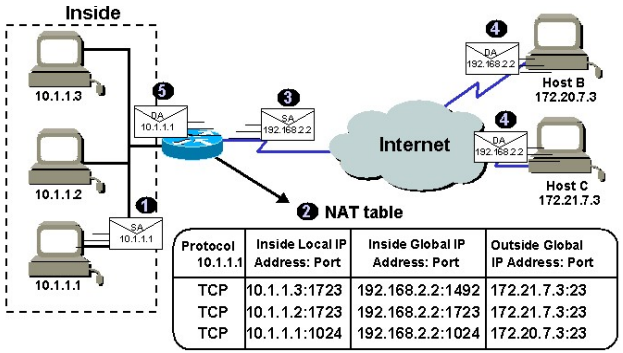


NAT工作机制



思考：同一主机不同应用，或者不同主机的同一端口，NAT转换如何处理?

NAT工作机制



- 出数据报：外出数据报用NAT IP地址(全局), 新port # 替代 源IP地址(私有), port #
- NAT转换表：每个 (源IP地址, port #)到(NAT IP地址, 新port #) 映射项
- 入数据报：对每个入数据报的地址字段用存储在NAT表中的(源IP地址, port #)替代对应的 (NAT IP地址, 新port #)

网络地址转换

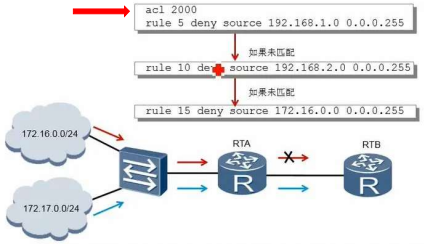
- NAT根据不同的IP上层协议进行NAT表项管理
  - TCP，UDP，ICMP
- 传输层TCP/UDP拥有16-bit 端口号字段
  - 所以一个WAN侧地址可支持60,000个并行连接

- NAT的优势
  - 节省合法地址，减少地址冲突
  - 灵活连接Internet
  - 保护局域网的私密性

- 问题或缺点
  - 违反了IP的结构模型，路由器处理传输层协议
  - 违反了端到端的原则
  - 违反了最基本的协议分层规则
  - 不能处理IP报头加密
  - 新型网络应用的设计者必须要考虑 NAT场景，如 P2P应用程序

6. 访问控制列表ACL （实验六）

- 访问控制列表(ACL：Access Control Lists)是一种基于包过滤的访问控制技术，它可以根据设定的条件对接口上的数据包进行过滤，允许其通过或丢弃。ACL被广泛地应用于路由器和三层交换机，借助于ACL，可以有效地控制用户对网络的访问，从而最大程度地保障网络安全。
- ACL是应用在路由器接口的指令列表。这些指令列表用来告诉路由器哪些数据包可以收、哪些数据包需要拒绝。可以由类似于源地址、目的地址、端口号等的特定指示条件或组合来决定。如可允许Web通信流量被路由，拒绝所有 FTP通信流量等。

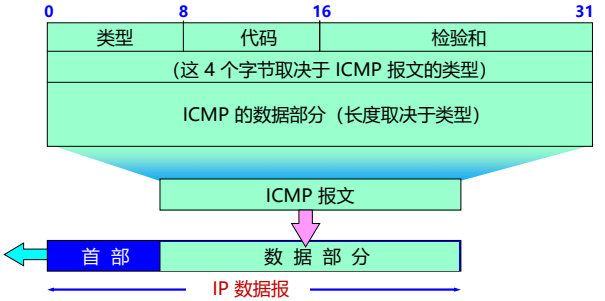


- 每个ACL可以包含多个规则，RTA根据规则来对数据流量进行过滤。

7. ICMP协议

- ICMP: 互联网控制报文协议 (Internet Control Message Protocol)
  - ICMP 允许主机或路由器报告差错情况和提供有关异常情况的报告
  - 由主机和路由器用于网络层信息的通信
  - ICMP 报文携带在IP 数据报中： IP上层协议号为1
- ICMP报文类型
  - ICMP 差错报告报文
    - 终点不可达：不可达主机、不可达网络，无效端口、协议
  - ICMP 询问报文
    - 回送请求/回答 (ping使用)

ICMP 报文格式



- ICMP报文的前 4 个字节包含格式统一的三个字段：类型、代码、检验和
- 相邻的后四个字节内容与ICMP的报文类型有关

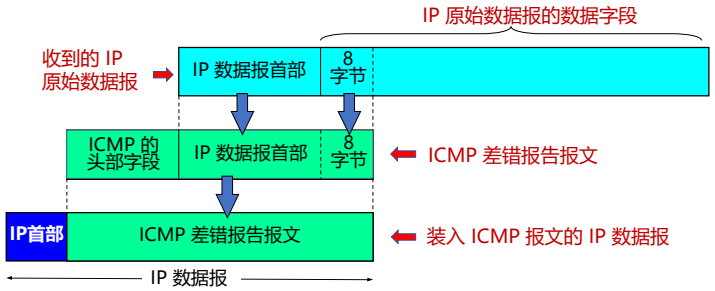
ICMP报文类型及功能

ICMP报文类型	类型值	功能描述
差错报告报文	3	终点不可达
	5	改变路由(Redirect)
	11	时间超时
	12	参数问题
询问报文	8或0	回送(Echo)请求或应答
	13或14	时间戳(Timestamp)请求或回答

注：根据RFC 6633规定，已不再使用类型值为4、10或9、15或16、17或18的报文。

类型	代码	功能描述
0	0	回送应答 (ping)
3	0	目的网络不可达
3	1	目的主机不可达
3	2	目的协议不可达
3	3	目的端口不可达
3	6	目的网络未知
3	7	目的主机未知
8	0	回送请求 (ping)
9	0	路由通告
10	0	路由发现
11	0	TTL过期
12	0	坏的IP首部

差错报告报文



Ping和ICMP

- PING (Packet InterNet Groper)
  - PING 用来测试两个主机之间的连通性
  - PING 使用了 ICMP 回送请求与回送回答报文

```
C:\>ping www.baidu.com

正在 Ping www.a.shifen.com [110.242.68.4] 具有 32 字节的数据:
来自 110.242.68.4 的回复: 字节=32 时间=32ms TTL=53
来自 110.242.68.4 的回复: 字节=32 时间=29ms TTL=53
来自 110.242.68.4 的回复: 字节=32 时间=29ms TTL=53
来自 110.242.68.4 的回复: 字节=32 时间=31ms TTL=53

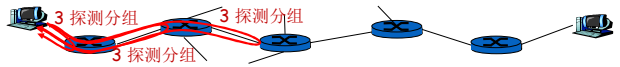
110.242.68.4 的 Ping 统计信息:
    数据包: 已发送 = 4, 已接收 = 4, 丢失 = 0 (0% 丢失),
往返行程的估计时间(以毫秒为单位):
    最短 = 29ms, 最长 = 32ms, 平均 = 30ms
```

连通性　往返时延　单向转发跳数

思考：
如何利用Ping命令返回的TTL值(报文剩余跳数)，来判断对方主机操作系统的类型？

Traceroute和ICMP

- 如何知道整个路径上路由器的地址？ 使用TraceRT命令



- 源向目的地发送一系列UDP段(不可能的端口号)
  - 第一个 TTL =1
  - 第二个 TTL=2, 等
- 当第n个数据报到达第n个路由器:
  - 路由器丢弃数据报
  - 并向源发送一个ICMP报文 (类型 11, 编码0)
  - 报文的源IP地址就是该路由器的IP地址

Traceroute和ICMP

C:\>tracert www.taobao.com

通过最多 30 个跃点跟踪
到 www.taobao.com.danuoyi.tbcache.com
[27.211.197.171] 的路由:

1	3 ms	2 ms	4 ms	192.168.3.1
2	3 ms	6 ms	3 ms	SMBSHARE [192.168.1.1]
3	6 ms	9 ms	5 ms	27.215.136.1
4	6 ms	11 ms	7 ms	61.162.199.89
5	7 ms	18 ms	21 ms	61.162.199.9
6	23 ms	29 ms	22 ms	61.156.223.69
7	28 ms	31 ms	20 ms	112.230.160.54
8	19 ms	27 ms	36 ms	60.208.64.230
9	15 ms	15 ms	16 ms	119.164.254.86
10	19 ms	13 ms	13 ms	27.211.197.171

跟踪完成。

- 当源收到ICMP报文，计算 RTT
- Tracert针对同一RTT值执行上述过程3次

停止条件 Windows是ping机制

- UDP段最终到达目的地主机
- 目的地返回ICMP “端口不可达”分组 (类型3, 编码3)
- 当源得到该ICMP，停止

本章内容

5.1 网络层服务(P5)
5.2 Internet 网际协议(P28)
5.3 路由算法(74)
5.4 Internet路由协议(P126)
5.5 路由器工作原理(P162)
5.6 拥塞控制算法(P170)
5.7 服务质量
5.8 三层交换与VPN
5.9 IPv6技术

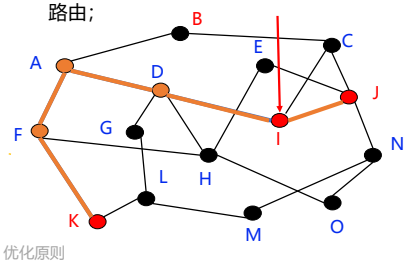
1. 最短路径算法SPF
2. 距离向量路由DV
3. 链路状态路由LS
4. 层次路由
5. 广播路由（可选）
6. 组播路由
7. 选播路由（可选）

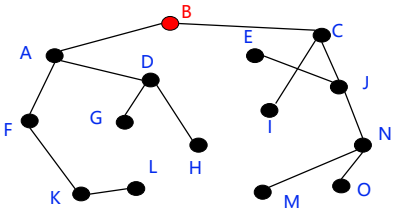
路由算法

- 路由（routing）是指分组从源到目的地时，决定端到端路径的算法或（进程）。
- 路由算法须满足的特性：
  - 正确性 • 简单性 • 鲁棒性 • 稳定性 • 公平性 • 有效性
- 根据路由算法分类（是否随网络的通信量或拓扑自适应划分）
  - 静态路由选择策略（非自适应路由选择）：管理员手工设置；适用于小型网络；拓扑稳定；或者非网状结构；
  - 动态路由选择策略（自适应路由选择）（路由算法）拓扑动态变化，网状网，抗毁性要求高。

优化原则

- 汇集树 (Sink Tree)　汇集树不是唯一的
  - 所有节点到一个指定目标节点的最优路径集合，构成一棵以目标节点为根的树(Sink tree)
  - 汇集树是最优化原则的一个直接结果；
  - 路由算法目标是为了所有路由器找到汇集树，并根据汇集树来转发数据包；
  - 若路由器I位于从路由器J到路由器K的最优路径上，则从I到K的最优路径也必定遵循同样的路由；





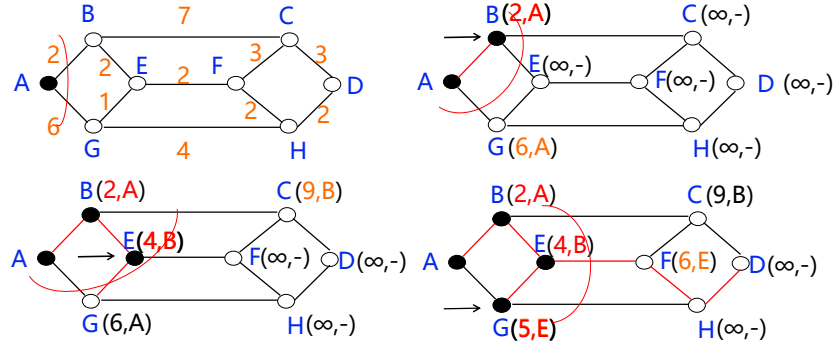
一棵路由器B的汇集树（距离度量单位: 步长数）

1. 最短路径算法SPF

- 定义
  - 用于计算一个节点到其他所有节点的最短路径，主要特点是以起始点为中心向外逐层扩展，直到扩展到终点为止。
- Dijkstra算法思想
  - 建立网络图
    - 节点：表示路由器
    - 边：表示通信线路/链路
    - 链路代价：表示链路上的距离、信道宽度或通信开销等参数
  - 根据算法在网络图上为某一对路由器找之间的最短路径

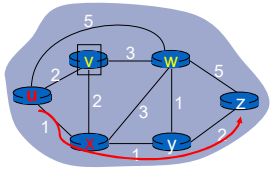
最短路径算法SPF

- 具体例子（A到D的最短路径过程）



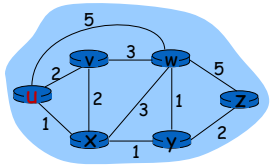
2. 距离向量路由DV

- Bellman-Ford 方程
  - 假设$D_x(y)$ 是 从x到y最小代价路径的代价值
  - 则：$D_x(y) = \min \{c(x,m) + D_m(y)\}$
    其中m为x的邻居, c(x,m)为m到x的代价
  - 示例：
    - 已获知$D_v(z) = 5$, $D_x(z) = 3$, $D_w(z) = 3$
    - $D_u(z) = \min \{ c(u,v) + D_v(z), \mathbf{c(u,x) + D_x(z)}, c(u,w) + D_w(z) \}$
      $= \min \{2 + 5, \mathbf{1 + 3}, 5 + 3\}$
      $= \mathbf{4}$
  - 算出代价最小的节点，就得到了对应转发项从u去往z，应从x转发。



距离向量路由DV

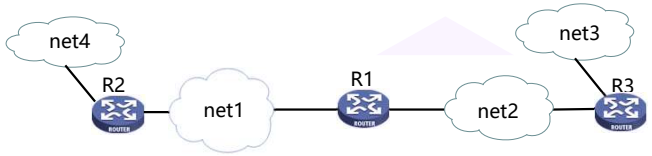
- 距离向量（Distance Vector）算法基本思想:
  - 每个节点周期性地向邻居发送它自己到某些节点的距离、向量;
  - 当节点x接收到来自邻居v 的新DV估值，它使用B-F方程更新其自己的DV:
    $D_x(y) \leftarrow min_v\{c(x,v) + D_v(y)\}$ *for each node* $y \in N$
  - 上述过程迭代执行，$D_x(y)$*收敛为最小费用* $d_x(y)$



- 距离向量算法特点：迭代的、分布式的
  - 每次本地迭代由下列引起: 本地链路费用改变、邻居更新报文
  - 分布式: 各节点依次计算，相互依赖

距离向量路由DV

- 路由器启动时初始化自己的路由表
  - 初始路由表包含所有直接相连的网络路径，距离均为0



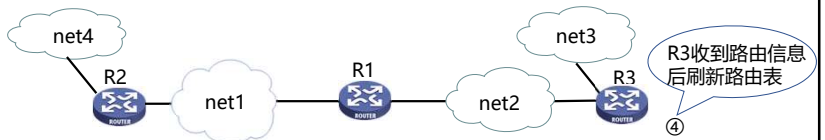
目的网络	距离	下一跳
net1	0	--
net4	0	--

目的网络	距离	下一跳
net1	0	--
net2	0	--

目的网络	距离	下一跳
net2	0	--
net3	0	--

距离向量路由DV

- 路由器周期性地向其相邻路由器广播自己知道的路由信息
- 相邻路由器可以根据收到的路由信息修改和刷新自己的路由表



目的网络	距离	下一跳
net1	0	--
net4	0	--

① R2将路由信息发送给R1

目的网络	距离	下一跳
net1	0	--
net2	0	--
net4	1	R2

② R1收到路由信息后刷新路由表

③ R1将路由信息发送给R3

目的网络	距离	下一跳
net2	0	--
net3	0	--
net1	1	R1
net4	2	R1

距离向量路由DV

- 路由器经过若干次更新后，最终都会知道到达所有网络的最短距离
- 所有的路由器都得到正确的路由选择信息时，网络进入“收敛”(convergence)状态。



目的网络	距离	下一跳
net1	0	--
net4	0	--
net2	1	R1
net3	2	R1

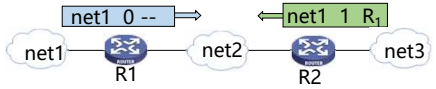
目的网络	距离	下一跳
net1	0	--
net2	0	--
net4	1	R2
net3	1	R3

目的网络	距离	下一跳
net2	0	--
net3	0	--
net1	1	R1
net4	2	R1

距离向量路由DV

- 计数到无穷问题（The Count-to-Infinity Problem）

正常情况

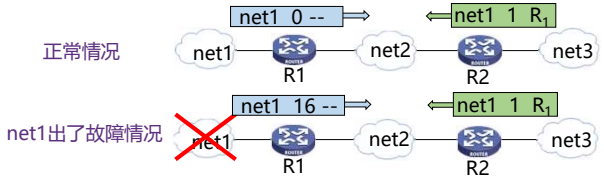


R_1 说：“我到net1 的距离是 0，是直接交付。”

R_2 说：“我到net1 的距离是 1，是经过 R_1。”

距离向量路由

- 计数到无穷问题（The Count-to-Infinity Problem）

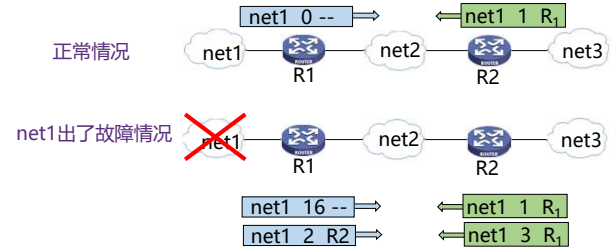


R_1 说：“我到net1 的距离是 16（表示无法到达），是直接交付。”

但 R_2 在收到 R_1 的更新报文之前，还发送原来的报文，因为这时 R_2 并不知道 R_1 出了故障。

距离向量路由

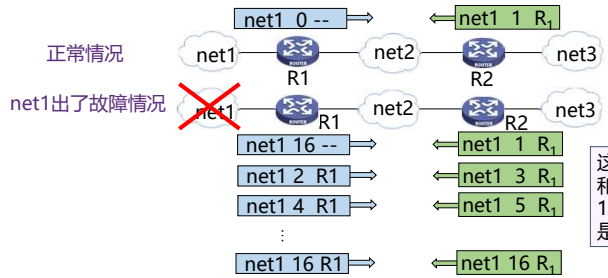
- 计数到无穷问题（The Count-to-Infinity Problem）



R_2 以后又更新自己的路由表为“net1, 3, R_1”，表明 “我到net 1 距离是 3，下一跳经过 R_1”。

距离向量路由

- 计数到无穷问题（The Count-to-Infinity Problem）



这样不断更新下去，直到 R_1 和R_2 到net 1的距离都增大到16时，R_1和R_2才知道net 1是不可达的。

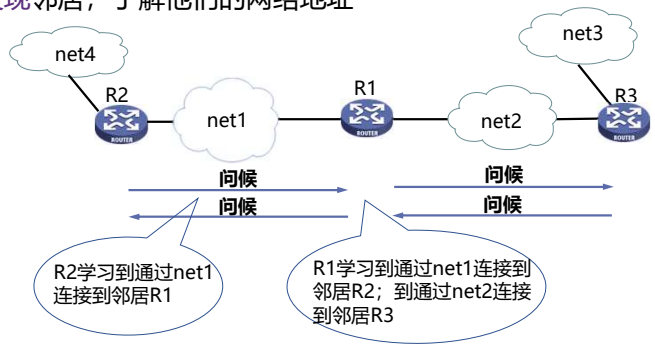
- “好消息传播快，坏消息传播慢”，是距离向量路由的一个主要缺点。

3. 链路状态路由LS

- 链路状态（Link State）路由可分为五个部分：
  1）发现邻居，了解他们的网络地址；
  2）设置到每个邻居的成本度量（metric）；
  3）构造一个分组，分组中包含刚收到的所有信息；
  4）将此分组发送给其他的路由器；
  5）计算到其他路由器的最短路径。

链路状态路由LS

➢ 1）发现邻居，了解他们的网络地址



链路状态路由

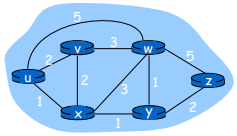
➢ 2）设置到每个邻居的成本度量（metric）

- 开销/度量/代价：
  - 自动发现设置或人工配置
  - 度量：带宽、跳数、延迟、负载、可靠性等
- 常用度量：链路带宽（反比）
  - 例如：1-Gbps以太网的代价为1，100-Mbps以太网的代价为10
- 可选度量：延迟
  - 发送一个echo包，另一端立即回送一个应答
  - 通过测量往返时间RTT，可以获得一个合理的延迟估计值

链路状态路由

➢ 3）构造一个分组，分组中包含刚收到的所有信息

- 构造链路状态分组（Link State Packet，LSP）
  - 发送方标识
  - 序列号Seq.
  - 年龄Age
  - 邻居列表(neighbor list)



u	
Seq.	
Age	
v	2
x	1
w	5

v	
Seq.	
Age	
u	2
x	2
w	3

x	
Seq.	
Age	
u	1
v	2
w	3
y	1

y	
Seq.	
Age	
x	1
w	1
z	2

w	
Seq.	
Age	
u	5
v	3
x	3
y	1
z	5

z	
Seq.	
Age	
w	5
y	2

链路状态路由

➢ 4）将LSP分组发送给网络中其他路由器

- 每个LSP分组包含一个序列号，且递增
- 路由器记录所收到的所有（源路由器、序列号）对
- 当一个新分组到达时，路由器根据记录判断：
  - 如果是新分组，洪泛广播
  - 如果是重复分组，丢弃
  - 如果是过时分组，拒绝

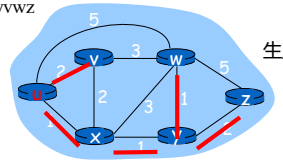
链路状态路由

➢ 5）计算到其他路由器的最短路径：Dijkstra算法示例

- D(k)：从计算节点到目的节点k当前路径代价
- p(k)：从计算节点到目的节点k的路径中k节点的前继节点

步骤	集合N	D(v),p(v)	D(w),p(w)	D(x),p(x)	D(y),p(y)	D(z),p(z)
0	u	2,u	5,u	1,u	∞	∞
1	ux	2,u	4,x		2,x	∞
2	uxy	2,u	3,y			4,y
3	uxyv		3,y			4,y
4	uxyvw					4,y
5	uxyvwz					

生成最短路径树



生成路由表

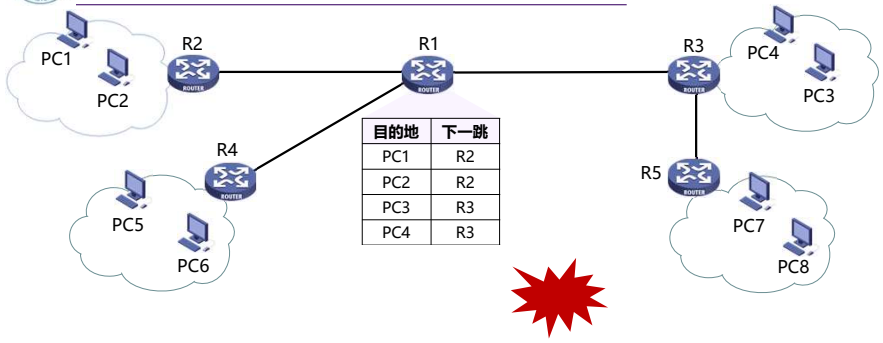
目的	下一跳	代价
v	v	2
w	x	3
x	x	1
y	x	2
z	x	4

链路状态路由

➢ 距离向量DV和链路状态LS算法比较：

- 网络状态信息交换的范围
  - DV:邻居间交换
  - LS:全网扩散
- 网络状态信息的可靠性
  - DV: 部分道听途说
  - LS: 自己测量
- 健壮性:
  - DV: 计算结果传递，健壮性差
  - LS: 各自计算路径，健壮性好
- 收敛速度：
  - DV：慢，可能有计数到无穷问题
  - LS：快

4. 层次路由-产生原因

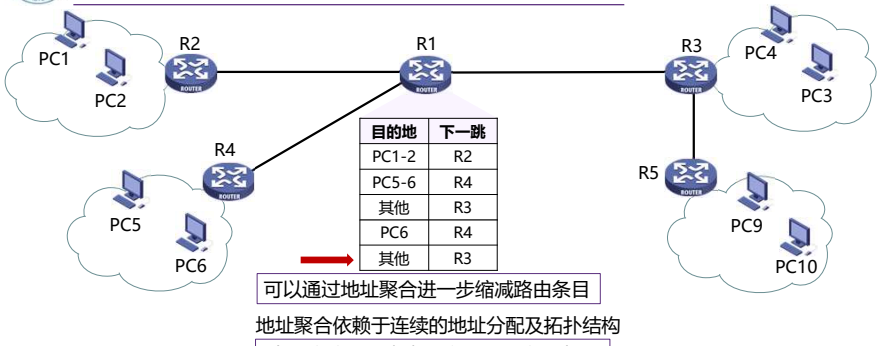


目的地	下一跳
PC1	R2
PC2	R2
PC3	R3
PC4	R3

....

过于庞大的路由表存储、查找困难，路由信息交互开销高

层次路由-产生原因



目的地	下一跳
PC1-2	R2
PC5-6	R4
其他	R3
PC6	R4
其他	R3

可以通过地址聚合进一步缩减路由条目

地址聚合依赖于连续的地址分配及拓扑结构

为提高路由器查表速度，减少路由表存储空间，需要缩减路由条目

....

层次路由-产生原因

- 现实情况：
  - 地址分配往往是随机的，难以进行高效的地址聚合
  - 每个网络的网络管理员有自己的管理方法和思路，并不希望每个路由器都干涉本网络内部的地址分配等问题
- 层次路由可以解决：
  - 网络扩展性问题：当网络扩大时，控制路由表条目和路由表存储空间的增长
  - 管理的自治问题：网络管理员可以控制和管理自己网络的路由

层次路由-AS

- 互联网由大量不同的网络互连而成，每个管理机构控制的网络是自治的。
- 自治系统（AS，Autonomous System）
  - 一个管理机构控制之下的网络
  - 一个AS内部通常使用相同的路由算法/路由协议，使用统一的路由度量
  - 不同的AS可使用不同的路由算法/路由协议
  - 每个AS都有一个唯一的AS编号。这个编号是由因特网授权的管理机构ICANN分配的。它的基本思想就是希望通过不同的编号来区分不同的自治系统。
  - 通过采用路由协议和AS编号，路由器就可确定彼此间的路径和路由信息的交换方法。AS编号范围是1到65535。其中1到64511是注册编号，64512到65535是专用网络编号
- 自治系统内的还可以进一步划分层次：私有自治系统或区域。

层次路由-AS

- 2005年，AS由16bits变为32bits。32位ASN的表示，采用<高16位十进制数>.<低16位十进制数>形式。
- 自治系统号码数据来自世界ASN分配中心数据系统。截止到2024-06-21 ‘’ 全球一共分批了191626个自治系统号码，一共有241国家、地区。中国所分配的AS号码数是3236个。AS总数全球第7 位。

19960104	AS4799	自治系统名称CHINA169-JT吉通
19960109	AS4808	自治系统名称CHINA169-BJ网通北京“省”网
19960109	AS4809	自治系统名称CHINANET-CORE-WAN-CN2
19960109	AS4812	自治系统名称CHINANET-SH-AP电信上海
19960109	AS4814	自治系统名称CNCGROUP IP network??China169 网通北京宽带网
19960109	AS4815	自治系统名称CHINANET-IDC-SH电信上海数据中心
19960206	AS4659	自治系统名称CHINA169-CN吉通
19960223	AS4798	自治系统名称UNSPECIFIED 似乎是复旦大学电信出口
19960910	AS4847	自治系统名称China Networks Inter-Exchange中国国家网络交换中心北京国际出口
19961028	AS4789	自治系统名称NAP1 at CERNET教育网交换中心（清华大学）
19961219	AS4859	自治系统名称CEISTNET-AS-AP国家信息中心
19970408	AS7497	自治系统名称CSTNET-AS-AP中科院计算机网络信息中心 （中国教育网CERNET），AS编号AS4538
19970502	AS7547	自治系统名称CEIEC-NET-AP国家信息中心（CEInet东部） （中国科技网CSTNET），AS编号AS7497
19970506	AS7549	自治系统名称CEINC-NET-AP国家信息中心（CEInet北部）
19970529	AS7576	自治系统名称ShaoGuan Information Center广东韶关信息中心
19971008	AS7638	自治系统名称INTERWAY BEIJIN TV ENTERPRISE DEVELOPMET FACTION
19971202	AS7692	自治系统名称CETIN-AS-AP中国工程技术网
19980417	AS9305	自治系统名称FHNET北京飞华电信

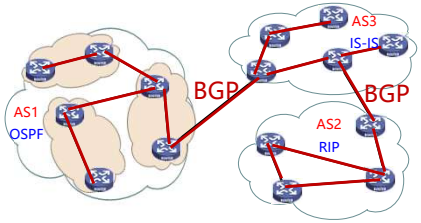
--- ---

http://as.chacuo.net/CN； http://as.chacuo.net/list

层次路由-基本思路

- 自治系统内部使用内部网关路由协议 IGP，Interior Gateway Protocols
  - 每个自治系统域内路由算法可不同
  - 典型IGP协议：OSPF，RIP，IS-IS，IGRP，EIGRP.....
- 自治系统之间之间使用外部网关路由协议EGP，Exterior Gateway Protocols
  - 各自治系统域之间的路由需统一
  - 典型EGP协议：BGP

注：IGP和EGP的具体工作方式，IGP和EGP之间的关联，详见5.5节Internet路由协议。



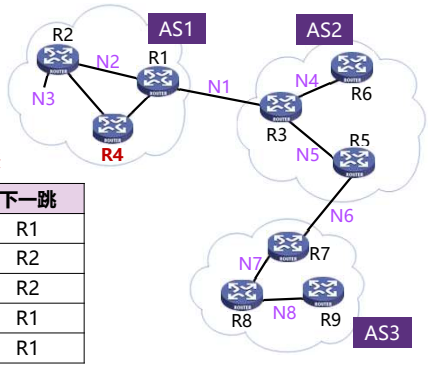
层次路由-效果

路由不分层的情况下
R4的路由表

目的地	下一跳
N1	R1
N2	R2
N3	R2
N4	R1
N5	R1
N6	R1
N7	R1
N8	R1

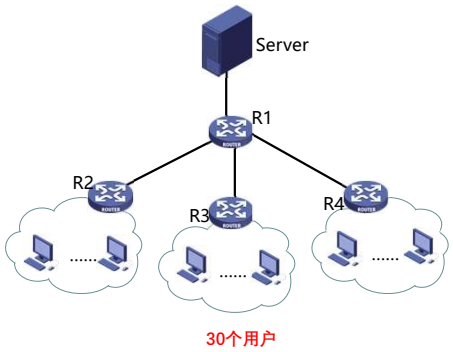
R4的层次表

目的地	下一跳
N1	R1
N2	R2
N3	R2
AS2内的所有网络	R1
AS3内的所有网络	R1



5. 广播路由

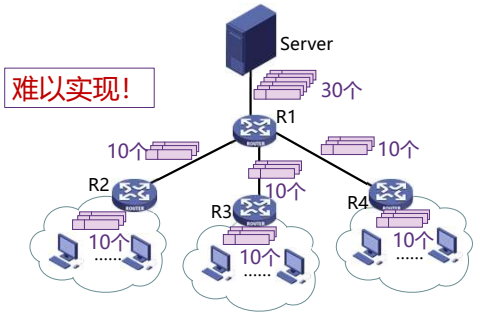
- 广播（Broadcasting）：源主机同时给全部目标地址发送同一个数据包
- 例：服务器希望将视频广播给3个网络中的所有30个用户，有哪些办法?



广播路由

- 方法1：给每个主机单独发送一个数据包
  - 效率低、浪费带宽
  - Server需要知道每个目的地址
- 方法2：多目标路由（multi-destination routing）
  - 在需要转发的路由器线路复制一次该数据报
  - 网络利用率高
  - Server依然需要知道所有的目的地址

难以实现!

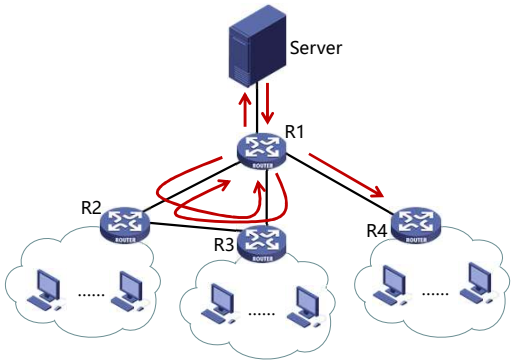


广播路由

- 方法3：泛洪（flooding）
  - 一种将数据包发送到所有网络节点的简单方法
  - 将每个进入数据包发送到除了进入线路外的每条出去线路
- 用途
  - 保证性：一种有效广播手段，可确保数据包被传送到网络中每个节点
  - 鲁棒性：即使大量路由器被损坏，也能找到一条路径（如果存在）
  - 简单性：仅需知道自己的邻居

广播路由

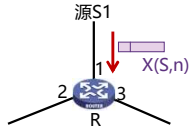
- 方法3：泛洪（flooding）
- 无控制的泛洪
  - 实现广播最显而易见的技术
  - 环路可能导致广播风暴
  - 路由器可能收到多个副本
  - 节点需要跟踪已泛洪的数据包以阻止洪泛
  - 即使利用跳数来限制，也会出现成倍爆炸



广播路由

解决方法：受控制的泛洪（每个路由器进行有选择的泛洪）

- 序号控制泛洪（sequence-number-controlled flooding）



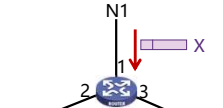
来源S	广播序号n
S1	1
S1	2
S1	3

①广播数据包X从接口1到达R
②R查看数据包来源S和广播序号n，比对R的序号表
③序号表中有该数据包的记录吗？
是，丢弃（曾经已经收到并转发过）
否，在序号表中记录，并在接口2和3转发

广播路由

解决方法：受控制的泛洪（每个路由器进行有选择的泛洪）

- 逆向路径转发（reverse path forwarding, RPF）



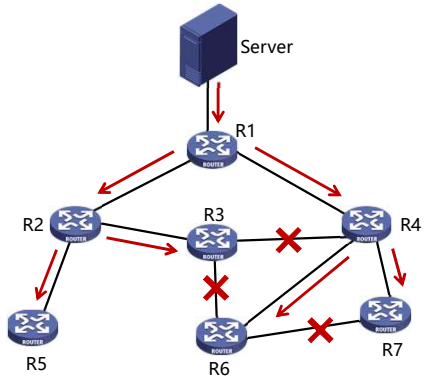
目标网络	接口
N1	1
N2	2
N3	3

假设R的路由表中表示了到达各网络的最优路径
①广播数据包X从接口1到达R
②R查看数据包来源S，比对R的路由表
③X的来源是N1吗？
是，X是从最佳路径来的，向接口2和接口3转发
否，X是重复包，丢弃

不能完全避免重复分组！

广播路由

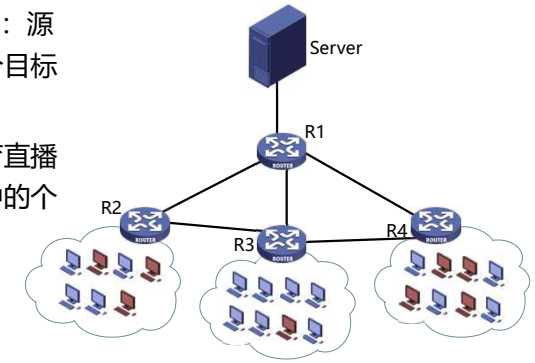
- 方法4：生成树（spanning tree）
  - 源节点向所有属于该生成树的特定链路发送分组
  - 改进了逆向路径转发
  - 没有环路
  - 最佳使用带宽
  - 最少副本，消除了冗余分组
  - 一个路由器可以不必知道整颗树，只需要知道在一颗树中的邻居即可



6. 组播路由

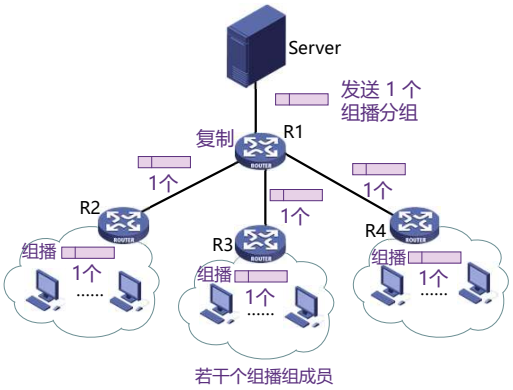
- 组播（multicasting）：源主机给网络中的一部分目标用户发送数据包
- 例：服务器希望将体育直播视频发送给某些网络中的个别用户，怎么办？





组播路由

- 组播（multicasting）路由算法的目标：
  - 为每个组建立多播转发树（到达该组所有成员的路径树）
  - 每个组成员应当只收到多播分组的一个拷贝
  - 非本组成员不应收到多播分组
  - 从源节点到每一个组成员节点的路径应当是最佳的（最短路径）

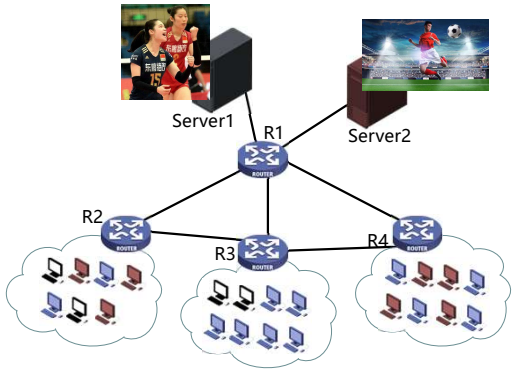


组播路由

- 组播实现的两个步骤：

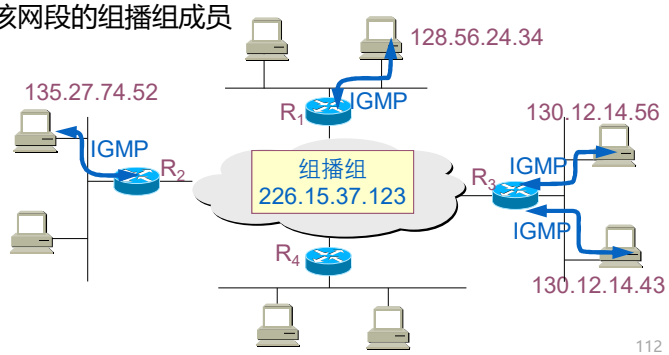
确定组成员：边缘路由器通过与主机交互，了解到从它的某个端口可以到达哪些组的成员——主机与路由器之间的组成员关系协议

- 怎样标识组成员？
- 如何编址？



组播路由

- IGMP (Internet Group Management Protocol) 路由器获悉该网段的组播组成员

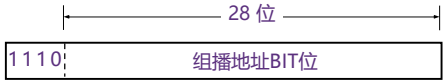


组播路由

➢常用组播地址段：224.0.0.0/24

局域网组播地址(一跳子网内使用)

- 224.0.0.1 LAN上所有设备
- 224.0.0.2 LAN上所有路由器
- 224.0.0.5 LAN上所有OSPF路由器
- 224.0.0.251 LAN上所有DNS服务器



D 类地址（组播地址）

组播路由

➢ 组播实现的两个步骤：

生成树——路由器与路由器之间的协议

- 建立在我们已经学习过的广播路由方案基础之上
- 数据包沿生成树发送
- 最佳生成树的使用取决于组的密度分布
  - 密集分布：接受者遍布在网络的大部分区域
  - 稀疏分布：大部分网络区域都不属于组播组

组播路由

➢ 密集分布，基于源点树（source-based trees）

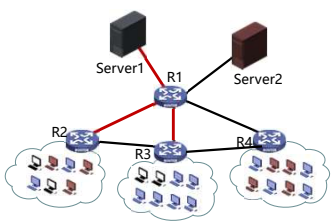
- 链路状态路由算法：每个路由器针对组内的每个发送者构造一颗独立树，例如多播开放最短通路优先协议（Multicast Open Shortest Path First，MOSPF）
- 距离向量路由算法：逆向路径转发，修剪没有组成员的路由器，例如距离向量多播路由协议（Distanse Vector Multicast Routing Protocol，DVMRP）、协议无关多播-稠密模式（Protocol Independent Multicast - Dense Mode, PIM-DM）

协议无关指的是与单播路由协议无关，即PIM不需要维护专门的单播路由信息

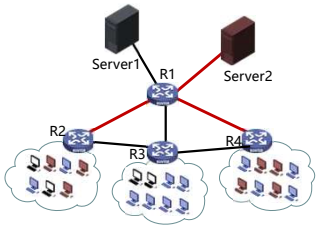
组播路由

➢ 基于源点树（source-based trees）存在的问题：

- 大型网络中，组播源很多时，路由器需生成多颗棵树，工作量巨大
- 路由器需要大量空间来存储多颗树



以Server1为源生成的树



以Server2为源生成的树

组播路由

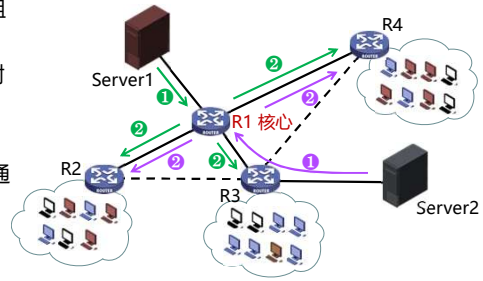
- 稀疏分布，基于核心树（core-based trees）
  - 多个组播源**共享树**
  - 大大节省存储开销、消息发送和计算
  - 每个路由器只需要保存一棵树
  - 不属于共享树的路由器不需要为组做任何工作
  - 例如协议无关多播-稀疏方式（Protocol Independent Multicast - Sparse Mode，PIM-SM），特定源组播（Protocol Independent Multicast - source-specific multicast, PIM-SSM）

组播路由

- 协议无关多播-稀疏方式 PIM-SM

① RP（Rendezvous Point），组播流量汇聚点，所有组播接收路由器以RP为树根构建共享树(RPT)；

② 发送端路由器将组播报文发给RP（通过最短路径），RP再通过RPT分发组接收者



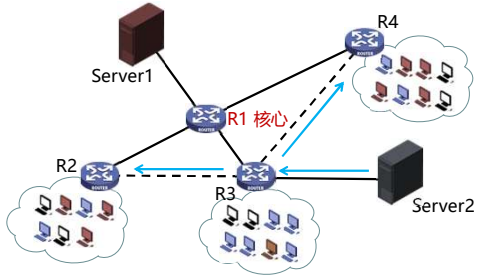
组播路由

- 协议无关多播-稀疏方式 PIM-SM
- 特定源组播 PIM-SSM
  - 组播接收者加入组播组时，即可以指定接收和拒绝来自特定组播源的组播流量
  - 组播源通过SPT（最短路径树）分发到接收路由器
- 思考：当存在多个组播源时，核心树的方式可能有什么问题?

组播路由

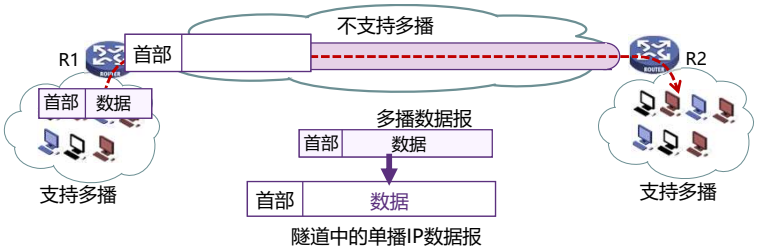
- 基于核心树（core-based trees）存在的问题：
  - 可能无法达到最优
  - 如果只有一个发送者，将发送者作为核心是最优的

例如，组播源Server2的数据，如果采用基于源点树的方法，可能到达目的主机所需跳数更少。



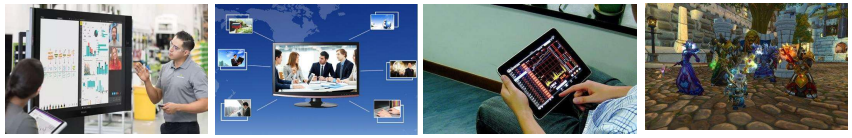
组播路由

- Internet的组播主干（MBone）：可以转发多播流量的路由器和主机组成的网络
- 通常Internet是单播方式工作，如何使多播流量穿越单播网络?
- 隧道（tunneling）：可以使多播数据报穿越不支持多播的网络



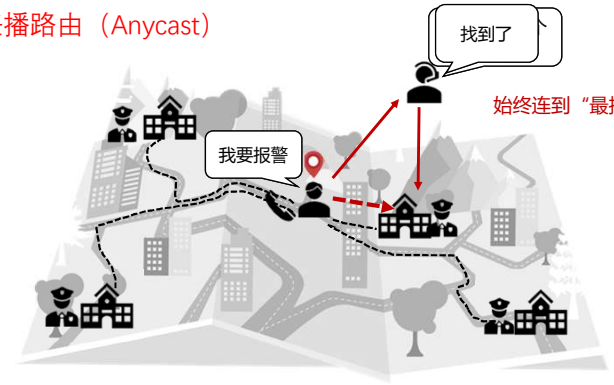
组播的应用

- 音频/视频会议
- 共享电子白板
- 数据分发
- 实时数据组播：音频视频点播、网络收看体育比赛直播、炒股……
- 游戏与仿真：同时有大量参与者的网络游戏



7. 选播路由

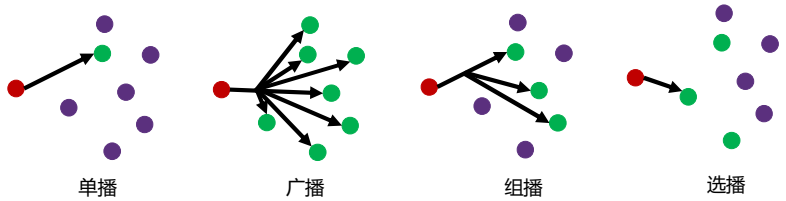
任播路由（Anycast）



始终连到“最接近”的服务器

选播路由

- 选播（Anycast）
  - 将数据包传送给最近的一个组成员
  - 在有多个服务器的情况下，用户希望快速获得正确信息，而不在乎从哪个服务器获得
  - 与单播、广播、组播的区别



选播路由

- 选播的典型应用：DNS
  - 在没有指定DNS服务器的情况下，用户将始终连接到“最接近”(从路由协议角度来看)服务器，可以减少延迟，并提供一定程度的负载平衡
  - 易于配置管理，不必根据服务器/工作站的部署位置(亚洲、美国、欧洲)配置不同的DNS服务器，而是在每个位置配置一个IP地址
  - 可以提供一定程度的高可用性，一旦服务器发生故障，用户请求将无缝转发到下一个最接近的DNS实例，而无需任何手动干预或重新配置
  - 可以水平缩放，如果一台服务器负载过重，只需在一个位置部署另一台服务器，以承担一部分重载服务器的请求，且不需要客户端配置

本章内容

5.1 网络层服务(P5)
5.2 Internet网际协议(P28)
5.3 路由算法(P74)
5.4 Internet路由协议
5.5 路由器工作原理(P162)
5.6 拥塞控制算法(P170)
5.7 服务质量
5.8 三层交换与VPN （三层交换---实验七）
5.9 IPv6技术

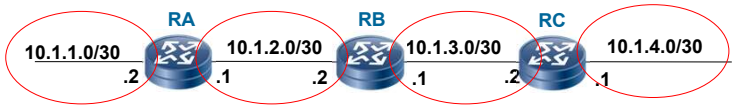
1. RIP-内部网关路由协议
2. OPSF-内部网关路由协议
3. BGP-外部网关路由协议
4. 标签交换 和 MPLS

1. RIP-概述（DV） （实验八）

- 路由信息协议RIP（Routing Information Protocol）是基于距离矢量(DV)算法的动态路由协议
- 使用跳数（hops）衡量到达目的网络的距离
  - RIP 认为一个好的路由就是它通过的路由器的数目少，即“距离短”
  - RIP 允许一条路径最多只能包含 15 个路由器，跳数16即认为网络断开
- RIP协议的基本思想
  - 仅和相邻路由器交换信息
  - 路由器交换的内容是自己的路由表
  - 默认周期性更新：30s

RIP-工作过程

- 初始化：



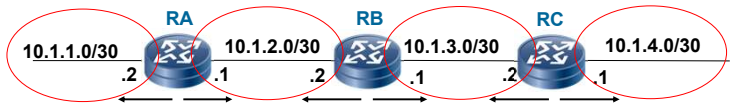
目标网络	下一跳	距离
10.1.1.0	– –	0
10.1.2.0	– –	0

目标网络	下一跳	距离
10.1.2.0	– –	0
10.1.3.0	– –	0

目标网络	下一跳	距离
10.1.3.0	– –	0
10.1.4.0	– –	0

RIP-工作过程

- 周期性更新



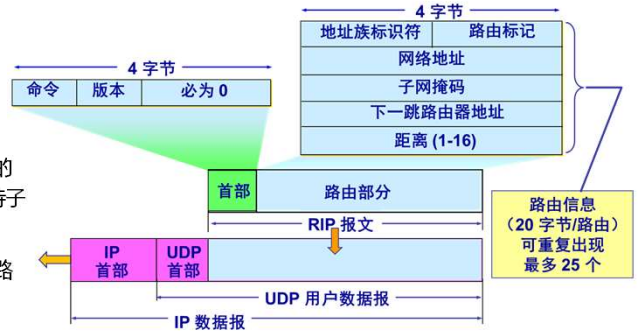
目标网络	下一跳	距离
10.1.1.0	– –	0
10.1.2.0	– –	0
10.1.3.0	10.1.2.2	1
10.1.4.0	10.1.2.2	2

目标网络	下一跳	距离
10.1.2.0	– –	0
10.1.3.0	– –	0
10.1.1.0	10.1.2.1	1
10.1.4.0	10.1.3.2	1

目标网络	下一跳	距离
10.1.3.0	– –	0
10.1.4.0	– –	0
10.1.2.0	10.1.3.1	1
10.1.1.0	10.1.2.1	2

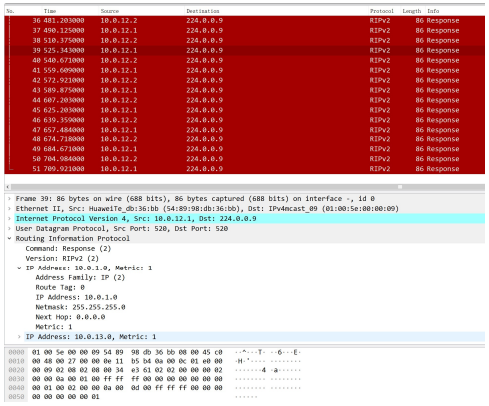
RIP-报文格式(V2)

- 协议封装
  - UDP，520
- 版本演进
  - V1：使用标准的IP地址，不支持子网路由
  - V2：支持子网路由、身份验证、多播



RIP-报文格式

- 请观察：
  - 这个报文是RIP版本多少?
  - RIP的周期更新如何实现?
  - 实现时是什么时候把跳数加1?
  - 为什么RIP没有确认机制?



RIP-小结

- RIP协议的特点
  - 算法简单，易于实现
  - 收敛慢
  - 需要交换的信息量较大
- RIP协议的适用场合
  - 中小型网络
- RIP协议的防环路机制
  - 触发更新（Triggered Update）
  - 毒性反转（Poisoned Reverse）
  - 水平分割（Split Horizon）
  - Hold - Down 定时器
  - 其他

2. OSPF-概述—实验八

- OSPF（Open Shortest Path First）开放最短路径优先协议于1989 年开发
- 采用分布式的链路状态L-S算法
- OSPF协议的基本思想
  - 向本自治系统AS中所有路由器洪泛信息
  - 发送的信息就是与本路由器相邻的所有路由器的链路状态
  - 只有当链路状态发生变化时路由器才用洪泛法发送此信息

OSPF-链路状态LS

- “链路状态”就是说明本路由器都和哪些路由器相邻，以及该链路的“度量”(metric)
  - OSPF度量值一般包括费用、距离、时延、带宽等
- 由于各路由器之间频繁地交换链路状态信息（通过Link State Advertisement，链路状态通告LSA），因此所有的路由器最终都能建立一个链路状态数据库LSDB
- 这个数据库实际上就是区域内的网络拓扑结构图，它在该区域内是一致的（这称为链路状态数据库的同步）

OSPF---五种报文

1）Hello 报文：最常用的一种报文，用于发现、维护邻居关系

2）数据库描述（Database Description，DD）报文
- 用于描述自己的LSDB
- 内容包括LSDB 中每一条LSA 的Header 头部，对端路由器根据LSA Header 就可以判断出是否已有这条LSA

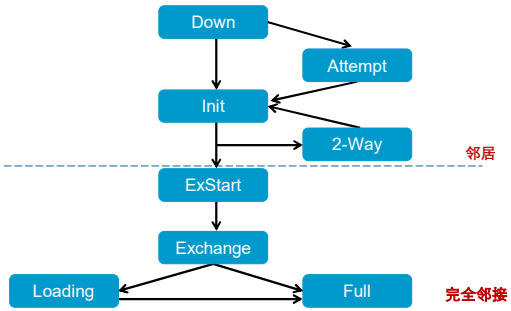
3）链路状态请求（LS Request，LSR）报文
- 用于请求缺少的LSA，内容包括所需要的LSA 的摘要

4）链路状态更新（LS Update，LSU）报文
- 用于向对端路由器发送所需要的LSA，内容是多条LSA（全部内容）的集合

5）链路状态确认（Link State Acknowledgment，LSACK）报文
- 用来对接收到的LSU 报文进行确认

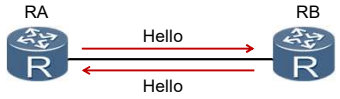
OSPF-邻居状态机

- 邻居
  - 端口连接到同一个网段
  - 由hello报文维护
- 完全邻接
  - 为了交换路由信息而形成的关系
  - 并非所有的邻居关系都可以成为邻接关系



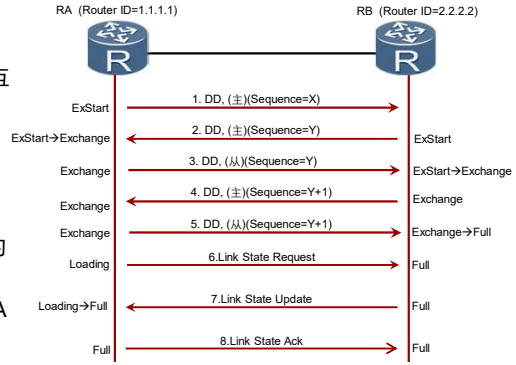
OSPF-报文交互

- 发现邻居
  - 使用HELLO报文
  - 检查HELLO报文中的参数，如果参数一致，形成邻居关系
  - 对于广播和NBMA 类型的网络，选举 指定路由器（Designated Router，DR）和备份指定路由器（Backup Designated Router，BDR）



OSPF-报文交互

- 数据库同步
  - 使用DD报文来进行主从路由器的选举和数据库摘要信息的交互
  - DD报文包含LSA的头部信息，用来描述LSDB的摘要信息
- 建立完全邻接关系
  - LSR用于向对方请求所需的LSA
  - LSU用于向对方发送其所需要的LSA
  - LSACK用于向对方发送收到LSA的确认

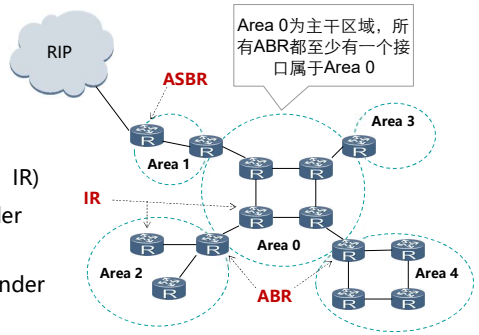


OSPF-区域的概念

- OSPF支持将一组网段组合在一起，称为一个区域area
- 详细的描述拓扑结构的链路状态信息仅在区域内传递，区域间传递的是抽象的路由信息
- 使用层次结构的区域划分，上层区域叫做主干区域（backbone area），其他区域都必须与主干区域相连
- 非主干区域之间不允许直接发布区域间路由信息
- 区域也不能太大，在一个区域内的路由器最好不超过 200 个
- 划分区域可以缩小LSDB规模，减少网络流量

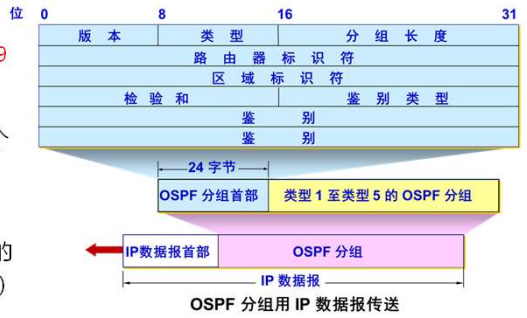
OSPF-区域的概念

- OSPF的区域
  - 主干区域
  - 非主干区域
- 路由器角色
  - 内部路由器(Internal Router，IR)
  - 区域边界路由器(Area Bounder Router，ABR)
  - 自治系统边界路由器(AS Bounder Router, ASBR)



OSPF-报文格式

- 协议封装
  - 运行于IP协议之上，协议号89
- 路由器标识符
  - 一个32位的值，唯一标识一个自治系统内的路由器
- 区域标识符
  - 每一个区域都有一个 32 位的标识符（用点分十进制表示）
  - 主干区域为0.0.0.0



OSPF-报文格式

- 请观察：
  - 这是什么报文?
  - 这个报文在什么区域?
  - 采用什么认证?

```
Internet Protocol Version 4, Src: 12.12.12.1 (12.12.12.1), Dst: 224.0.0.5 (224.0.0.5)
    Version: 4
    Header Length: 20 bytes
  ⊞ Differentiated Services Field: 0xc0 (DSCP 0x30: Class Selector 6; ECN: 0x00: Not-ECT
    Total Length: 76
    Identification: 0x0002 (2)
  ⊞ Flags: 0x00
    Fragment offset: 0
    Time to live: 1
    Protocol: OSPF IGP (89)
  ⊞ Header checksum: 0xc085 [validation disabled]
    Source: 12.12.12.1 (12.12.12.1)
    Destination: 224.0.0.5 (224.0.0.5)
    [Source GeoIP: Unknown]
    [Destination GeoIP: Unknown]
Open Shortest Path First
  ⊟ OSPF Header
      Version: 2
      Message Type: Hello Packet (1)
      Packet Length: 44
      Source OSPF Router: 1.1.1.1 (1.1.1.1)
      Area ID: 0.0.0.0 (0.0.0.0) (Backbone)
      Checksum: 0xea9c [correct]
      Auth Type: Null (0)
      Auth Data (none): 0000000000000000
```

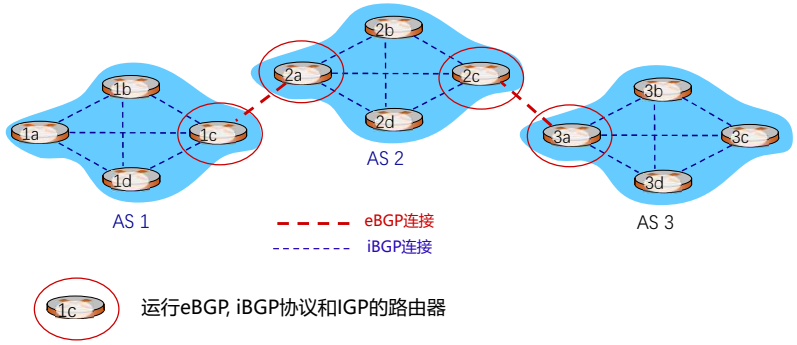

OSPF-小结

- OSPF的特点
  - 支持无类域间路由（CIDR）
  - 无路由自环
  - 收敛速度快
  - 使用IP组播收发协议数据
  - 支持多条等值路由
  - 支持协议报文的认证
- 请思考：
  - 为什么OSPF协议适合大型网络?
  - OSPF会不会存在“坏消息传得比较慢”的问题?

3. BGP-外部网关路由协议

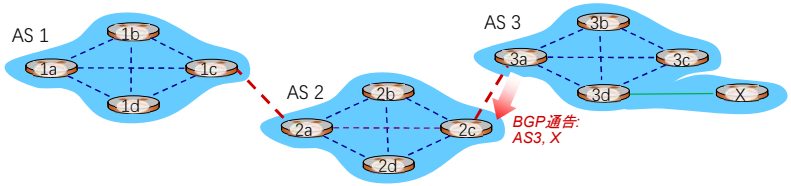
- 路由协议
  - 内部网关协议 IGP： 有 RIP 和、OSPF、ISIS 等多种具体的协议
  - 外部网关协议 EGP：目前使用的协议就是 BGP
- 边界网关协议BGP (Border Gateway Protocol)
  - 目前互联网中唯一实际运行的自治域间的路由协议
- BGP功能
  - eBGP：从相邻的AS获得网络可达信息
  - iBGP： 将网络可达信息传播给AS内的路由器
  - 基于网络可达信息和策略决定到其他网络的“最优”路由

eBGP & iBGP连接

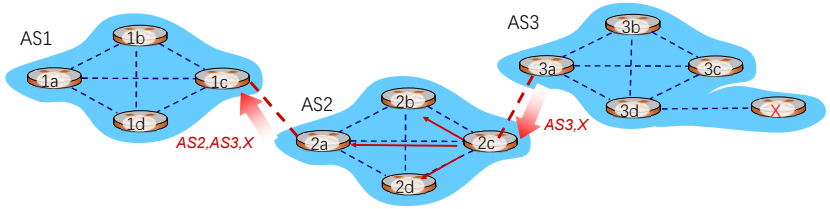


BGP基础

- BGP会话: 两个BGP路由器通过TCP连接交换BGP报文
  - 通告到不同网络前缀的路径，即路径向量（D-V）协议
- 例：当AS3的路由器3a向AS2的路由器2c通告路径AS3, X时，AS3向AS2承诺它会向X转发数据包

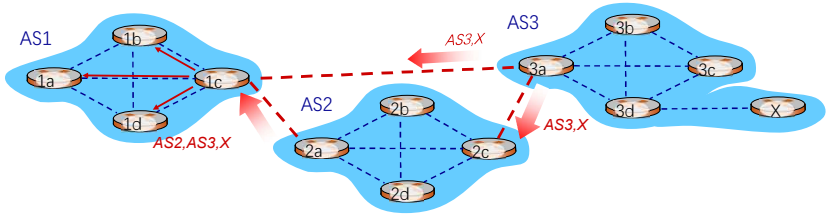


BGP路径通告



- AS2的路由器2c从AS3的路由器3a接收到路径AS3, X
- 根据AS2的策略，AS2的路由器2c接受路径AS3, X，通过iBGP传播给AS2的所有路由器
- 根据AS2策略，AS2的路由器2a通过eBGP向AS1的路由器1c通告从AS3的路由器3a接收到路径AS2, AS3, X

BGP路径通告



路由器可能会学到多条到目的网络的路径:

- AS1的路由器1c从2a学到路径*AS2, AS3, X*
- AS1的路由器1c从3a学到路径*AS3, X*
- 由策略，AS1路由器1c可能选择路径*AS3, X,* 并在AS1中通过iBGP通告路径

BGP协议的特点

- BGP 协议交换路由信息的结点数量级是自治系统数的量级
- 每一个自治系统边界路由器的数目是很少的
- 在 BGP 刚刚运行时，BGP 的邻站是交换整个的 BGP 路由表；以后只需要在发生变化时更新变化的部分
- BGP为每个AS提供：
  - 从邻居AS获取网络可达信息（eBGP协议）
  - 传播可达信息给所有的域内路由器（iBGP协议）
  - 根据“可达信息”和“策略”决定路由

BGP报文

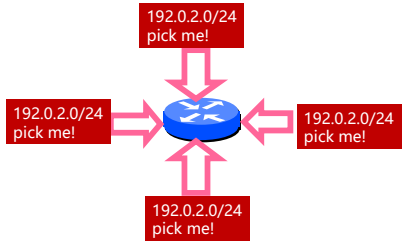
- BGP通过TCP的179端口交换报文
- BGP报文包括
  - Open报文：用于建立BGP对等体（peer）之间的会话连接，协商BGP参数（该过程需要认证）
  - Update报文：用于在对等体之间交换路由信息
  - Keepalive报文：用于保持BGP会话连接
  - Notification报文：用于差错报告和关闭BGP连接

BGP路径属性

- 发布的前缀信息包括BGP属性(BGP attributes)
  - 路由“route”=prefix + attributes
- 两个重要属性
  - AS路径（AS-PATH）：IP前缀通过经过的所有AS号
    如：AS 67, AS 17
  - 下一跳（NEXT-HOP）：说明路由信息对应的下一跳IP地址
- 网关路由器接收到路由通告时，通过既定策略采纳或拒绝(accept/decline)

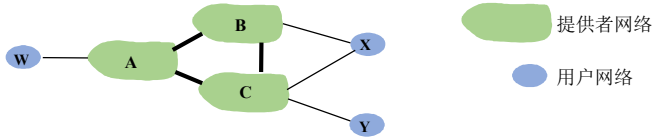
BGP 路由选择

- 路由器可能从多个对等体收到针对同一目的IP的路由
- 需要选择一条最佳路由
- 选择规则：自上向下，依次排序
  - 本地偏好值属性：政策决策
  - 最短的AS-PATH
  - 最近的NEXT-HOP路由器
  - 附加标准…
  - 最低路由器ID



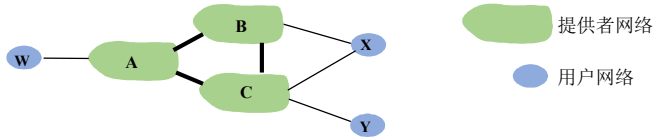
BGP路由策略

- 路由器使用策略决定接受或拒绝接收到的路由通告
- 路由器也会基于策略决定是否向其他相邻AS通告路径信息



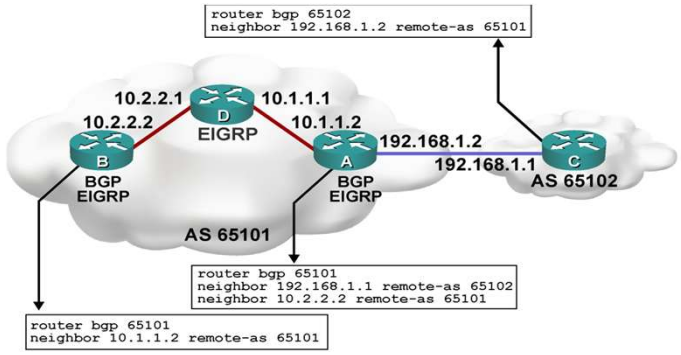
- 例如：X连接到两个提供者网络（dual-homed）
  - X为用户网络，X不希望从B到C的数据包经过X
  - X则不向B通告到C的路由

BGP路由策略



- A向B通告路径*AW*
- B通告到目的W的路径为*BAW*
- B是否向C通告路径*BAW*？
  - 由于W和C都不是B的用户，B要迫使C通过A路由到W
  - B只路由来自于或到达其用户的数据包

BGP配置实例

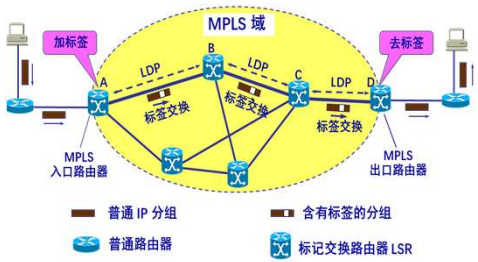


4. 标签交换和MPLS-概述

- MPLS (MultiProtocol Label Switching)全称是多协议标签交换
  - 多协议表示在 MPLS 的上层可以采用多种协议，例如：IP，IPv6、IPX
  - 标签是指每个分组被分配一个标签，路由器根据该标签对分组进行转发
  - 交换是指标签的交换，MPLS 报文交换和转发是基于标签的
- MPLS 设计初衷为了提升查找速度
- MPLS 主要有以下三个方面的应用
  - 面向连接的服务质量管理
  - 流量工程，平衡网络负载
  - 虚拟专用网VPN

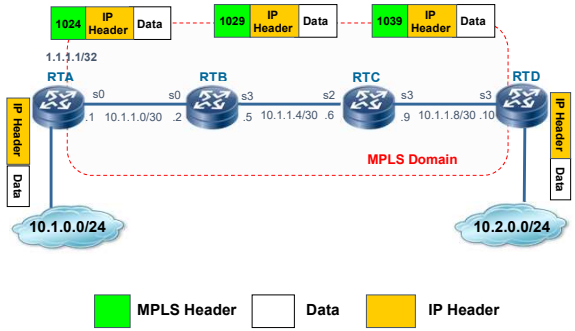
标签交换和MPLS

- 标签交换路由器LSR
  - 支持MPLS的路由器
  - 具备标签交换、路由选择两种功能
- MPLS 域
  - 所有相邻的支持MPLS技术的路由器构成的区域
- 标签分配协议LDP
  - 用来在LSR之间建立LDP 会话并交换Label/FEC映射信息



标签交换和MPLS-工作过程

- 加标签
  - 在MPLS域的入口处，给每一个IP数据报加上标签，然后对加上标记的IP数据报用硬件进行转发
- 标签交换
  - 采用硬件对加上标记的IP数据报进行转发称为标签交换
- 去标签
  - 当分组离开MPLS域时，MPLS出口路由器把分组的标签去除。后续按照一般IP分组的转发方法进行转发



标签交换和MPLS-标签

- 标签仅仅在两个LSR 之间才有意义
- LSR会维护一张转发表

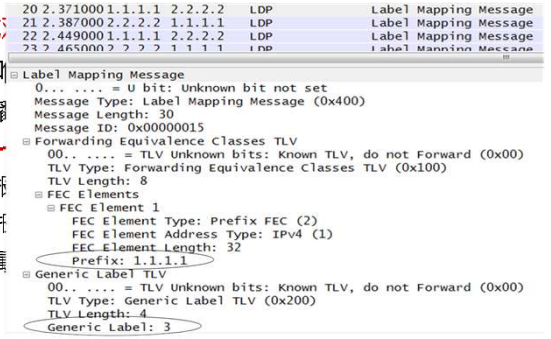
转发表

入接口	入标记	出接口	出标记
0	3	1	1

表项含义：从入接口 0 收到一个入标记为 3 的IP 数据报，转发时，应当把该IP数据报从出接口 1 转发出去，同时把标记对换为 1。

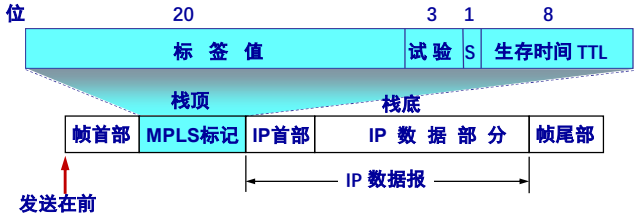
标签交换和MPLS - 转发等价类

- 路由器按照同样方式
- 通常对一个FEC分配
  - 属于某特定组的组播
  - **目的IP地址匹配了一**
  - 有相同QoS策略的报
  - 属于同一个VPN的报
  - 报文的目的IP地址属
  - 其他

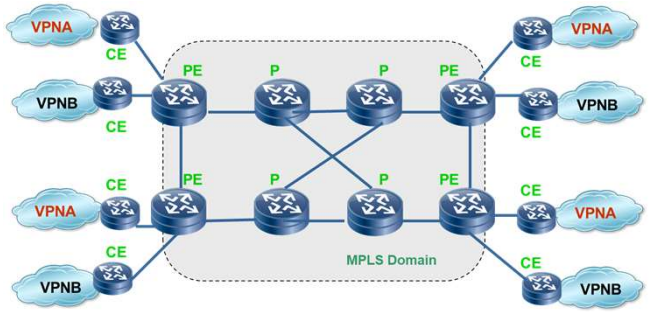


标签交换和MPLS-报文结构

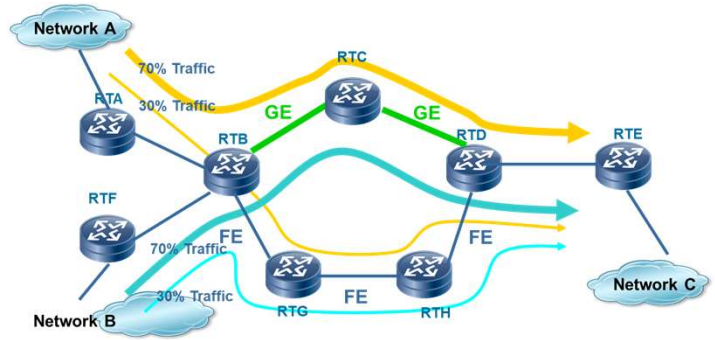
- “给IP数据报加标签”其实就是在以太网的帧首部和IP数据报的首部之间插入一个4字节的MPLS首部；
- MPLS又称为2.5层协议；



标签交换和MPLS-应用



标签交换和MPLS-应用



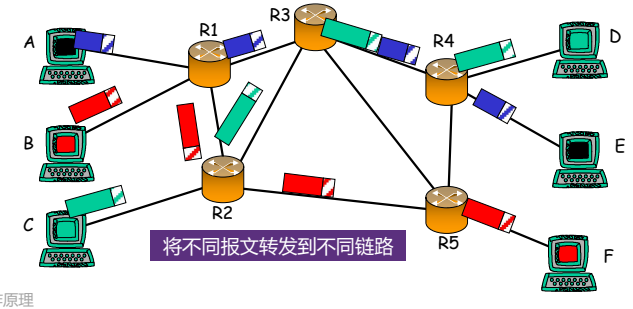
本章内容

5.1 网络层服务(P5)
5.2 Internet网际协议(P28)
5.3 路由算法(P74)
5.4 Internet路由协议(P126)
5.5 路由器工作原理
5.6 拥塞控制算法(P170)
5.7 服务质量
5.8 三层交换与VPN
5.9 IPv6技术

1. 路由器概述
2. 路由器控制层
3. 路由器数据层
4. 路由器交换结构

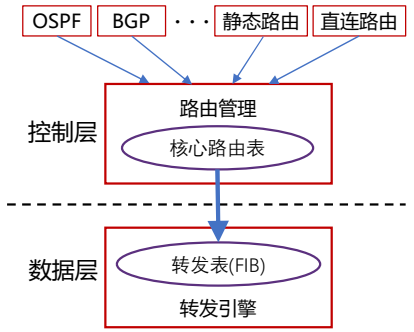
1. 路由器概述

- 路由器是互联网最主要的网络设备，包含2个核心功能
  - 控制层：运行各种路由协议：BGP、OSPF、RIP，学习去往不同目的的转发路径：路由表
  - 数据层：根据上述路由表，将收到的IP分组转发到正确的下一跳链路



2. 路由器控制层

- 路由器可同时运行多个路由协议
- 路由器也可不运行任何路由协议，只使用静态路由和直连路由
- 路由管理根据路由优先级，选择最佳路由，形成核心路由表
- 控制层将核心路由表下发到数据层，形成转发表（FIB）



路由器控制层

- 若存在多个“去往同一目的IP前缀”的不同类型路由，路由器根据优先级选择最佳路由【管理距离】（Administrative Distance，简称AD），优先级（或AD）数值越小，优先级越高。
- Metric则是同一种路由协议内部的比较，用来决定到达同一目的地的最优路径

路由种类	路由优先级（AD）
直连路由	0
静态路由	1
eBGP路由	20
OSPF路由	110
RIP路由	120
iBGP路由	200

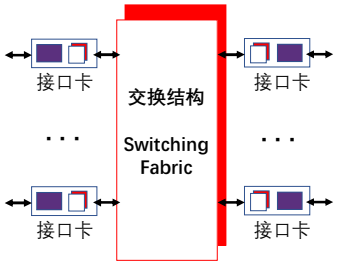
3. 路由器数据层

- 路由器中IP报文转发核心功能
  - 链路层解封装，IP头部校验
  - 获取报文目的IP地址
  - 用目的IP地址，基于最长前缀匹配规则查询转发表
  - 查询失败，丢弃报文
  - 查询成功：
    - 获取转发出接口和下一跳IP地址
    - IP头部“TTL”字段值减1，重新计算IP头部“校验和”
    - 重新进行链路层封装，发送报文
- IP报文在路由器转发前后的变化
  - 链路层封装更新，IP头部“TTL”减1，IP头部“校验和”更新

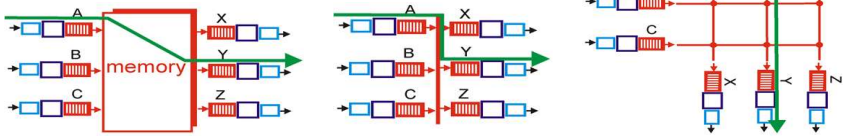
注：普通IP报文转发过程中，路由器不查看传输层及以上层协议的内容

路由器数据层

- 数据报在不同硬件单元的处理
  - 报文输入的接口卡
    - 链路层解封装
    - 转发表查询（该工作在输入接口卡处理）
    - 通过交换结构将报文排队发往目的接口卡（发送过快将产生拥塞）
  - 交换结构：从输入接口卡发往输出接口卡
  - 报文输出的接口卡
    - 从交换结构接收报文（排队进行后续处理，到达太快将产生拥塞）
    - 链路层封装
    - 从输出接口发送报文



4. 3种典型的交换结构



共享内存　　共享总线　　纵横式 Crossbar

应用于高性能分布式路由器

路由器扩展知识

- 路由器的端系统角色
  - 也作为网络端系统进行协议交互
    - 远程网络管理，SNMP
    - 远程网络配置，SSH
    - 文件传输，FTP，TFTP
    - 各种路由协议交互
    - ...
  - 路由器系统包含完整TCP/IP协议栈
    - 传输层协议
    - 应用层协议
- 家用路由器
  - 不运行动态路由协议（出口唯一）
  - 运行DHCP协议，分配私有IP
  - NAT地址转换
  - 本地DNS服务
  - 用户管理及认证
  - 防火墙功能
  - 无线AP
  - ...

与典型网络路由器差异较大

本章内容

5.1 网络层服务(P4)
5.2 Internet网际协议(P28)
5.3 路由算法(P73)
5.4 Internet路由协议(P124)
5.5 路由器工作原理(P162)
5.6 拥塞控制算法
5.7 服务质量
5.8 三层交换与VPN
5.9 IPv6技术

1. 拥塞控制概述
2. 流量感知路由
3. 流量调节
4. 随机早期检测

1. 拥塞控制概述

- **拥塞:**

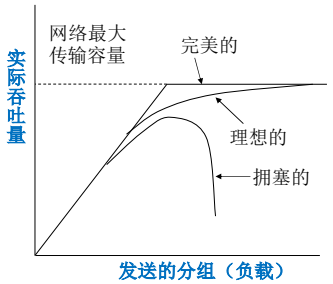
网络中存在太多的数据包导致数据包传输延迟或丢失，从而导致网络吞吐量下降

- **拥塞控制（congestion control）：**

需要确保通信子网能够承载用户提交的通信量，是一个全局性问题，涉及主机、路由器等多种因素

- **产生拥塞的原因:**

主机发送到网络的数据包数量过多，超过了网络的承载能力；突发的流量填满了路由器的缓冲区，造成某些数据包会被丢弃

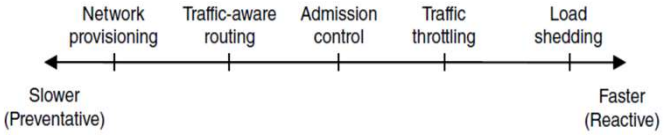


拥塞控制概述

- **拥塞控制的基本策略**
  - **开环控制**----事先对通信流参数进行协商，协商后，不管网络是拥塞还是带宽充足，参数不能动态改变
    - 开环控制属于预防性拥塞控制，它竭力使网络总是处于无拥塞状态运行。开环控制的方法包括决定什么时候接受新流量，什么时候丢弃数据包和丢弃哪些数据包。其缺点是没有考虑网络的当前状态
  - **闭环控制**---根据网络状态进行动态控制，包括两部分：反馈机制和控制机制。闭环控制方法分为两个子类：显式反馈与隐式反馈

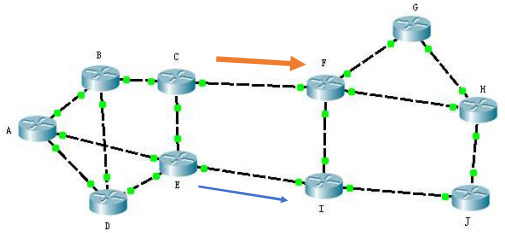
拥塞控制概述

- **拥塞控制的途径**
  - 提高网络供给
  - 流量感知路由
  - 准入控制
  - 流量调节
  - 负载丢弃



2. 流量感知路由

- 绕开热门的区域，疏散流量
- 计算路径权重时包含跳数、带宽、传输延迟、负载、平均排队延迟等参数
- 路由表可能会出现反复变化，从而导致不稳定的路由



3. 流量调节

- **抑制包(Choke Packets)**：用于通知发送方减小发送量，路由器选择一个被拥塞的数据包，给该数据包的源主机返回一个抑制包，抑制包中的目的地址取自该拥塞数据包。源主机收到抑制包后，减少发向特定目的地址的流量
- **逐跳的抑制包(Hop-by-Hop Choke Packets)**：在高速或长距离网络中，由于源主机响应太慢，抑制包算法对拥塞控制的效果并不好，可采用逐跳抑制方法；其核心思想是抑制包对它经过的每个路由器都起作用，能够迅速缓解发生拥塞处的拥塞，但要求上游路由器有更大的缓冲区

3. 流量调节

- **显式拥塞通告(ECN，Explicit Congestion Notification)**，在IP包头中记录数据包是否经历了拥塞。在数据包转发过程中，路由器可以在包头中标记为经历拥塞，然后接收方在它的下一个应答数据包里回显该标记作为显式拥塞信号
- **RFC2474中重新定义TOS域为包含一个6位的区分服务码点(DSCP)**和2位未使用位；**RFC3168重新定义RFC2474中TOS域未使用的两位为ECN域**，包含如下值：
  - 00：发送主机不支持ECN
  - 01或者10：发送主机支持ECN
  - 11：路由器正在经历拥塞

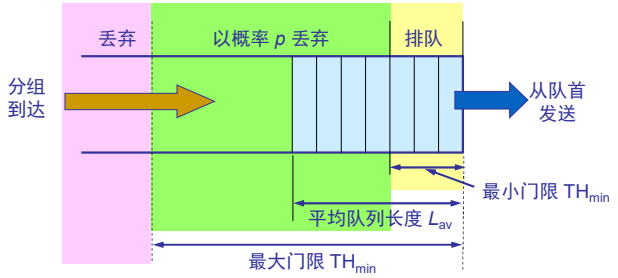
4. 随机早期检测

随机早期检测 RED (Random Early Detection)

- 使路由器的队列维持两个参数，即队列长度最小门限 TH_{min} 和最大门限 TH_{max}
- RED 对每一个到达的数据报都先计算平均队列长度 L_{AV}
- 若平均队列长度小于最小门限 TH_{min} ，则将新到达的数据报放入队列进行排队
- 若平均队列长度超过最大门限 TH_{max}，则将新到达的数据报丢弃
- 若平均队列长度在最小门限 TH_{min} 和最大门限TH_{max} 之间，则按照某一概率 p 将新到达的数据报丢弃

随机早期检测

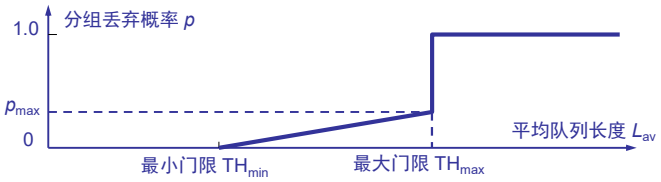
- RED 将路由器的到达队列划分成为三个区域



随机早期检测

丢弃概率 p 与 TH_{min} 和 Th_{max} 的关系

- 当 $L_{AV} < Th_{min}$ 时，丢弃概率 $p = 0$
- 当 $L_{AV} > Th_{max}$ 时，丢弃概率 $p = 1$
- 当 $TH_{min} < L_{AV} < TH_{max}$ 时，$0 < p < 1$
  例如，按线性规律变化，从 0 变到 p_{max}



本章内容

5.1 网络层服务
5.2 Internet网际协议
5.3 路由算法
5.4 Internet路由协议
5.5 路由器工作原理
5.6 拥塞控制算法
5.7 服务质量
5.8 三层交换与VPN
5.9 IPv6技术

1. 网络服务质量概述
2. 流量整形
3. 数据包调度
4. 综合服务
5. 区分服务

1. 网络服务质量概述

➢ **问题的提出**

- 互联网本身只能提供“尽力而为的服务”或称“尽最大努力交付的服务”
- 当互联网越来越多的用于传输多媒体信息时，由于这些实时业务对网络的传输延时、延时抖动等特性较为敏感，这样网络的传输质量就难以保障了
- IP网络不能保证特定业务的QoS要求，已经成为IP网络发展的巨大障碍
- 网络的服务质量越来越多的引起人们的关注，甚至成为网络技术研究的热点问题

➢ **什么是网络服务质量？ (QoS, Quality of Service)**

- QoS是网络在传输数据流时要满足一系列服务请求，具体可以量化为带宽、时延、抖动、丢包率等性能指标

网络服务质量概述

确保服务质量需要解决以下4个问题：

➢ （1）应用程序需要网络提供什么样的质量？
➢ （2）如何规范进入网络的流量？
➢ （3）为了保障性能如何在路由器预留资源？
➢ （4）网络能否安全的接受更多流量？

QoS的度量指标

➢ 带宽
➢ 时延
➢ 抖动
➢ 丢包率

QoS针对各种业务的不同需求，为其提供端到端的服务质量保证。在有限的带宽资源下，它允许不同的流量不平等地竞争网络资源，语音、视频和重要的数据应用在网络设备中可以优先得到服务



2. 流量整形

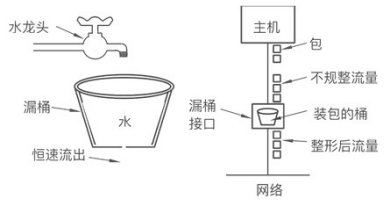
流量整形(traffic shaping)：其作用是限制流出某一网络的某一连接的流量与突发，使这类报文以比较均匀的速度向外发送

- 流量整形算法包括漏桶算法和令牌桶算法
  - 漏桶算法（Leaky Bucket Algorithm）：主要目的是控制数据注入到网络的速率，平滑网络上的突发流量。漏桶算法提供了一种控制机制，通过它，突发流量可以被整形以便为网络提供一个稳定的流量
  - 令牌桶算法（Token Bucket Algorithm）：用来控制发送到网络上的数据的数目，并允许突发数据的发送

流量整形

漏桶算法原理：Leaky Bucket

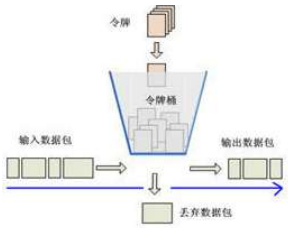
- 到达的数据包（网络层的PDU）被放置在底部具有漏孔的桶中（数据包缓存）
- 漏桶最多可**排队b个字节**，漏桶的尺寸受限于内存。如果数据包到达的时候漏桶已经满了，那么数据包应被丢弃
- 数据包从漏桶中漏出，以常量速率**（r字节/秒）**注入网络，因此平滑了突发流量



流量整形

令牌桶算法工作原理：

- 产生令牌：周期性的以速率r向令牌桶中增加令牌，桶中的令牌不断增多。如果桶中令牌数已到达上限，则丢弃多余令牌
- 消耗令牌：输入数据包会消耗桶中的令牌。在网络传输中，数据包的大小通常不一致。大的数据包相较于小的数据包消耗的令牌要多
- 判断是否通过：输入数据包经过令牌桶时存在两种可能：输出该数据包或者被丢弃。当桶中的令牌数量可以满足数据包对令牌的需求，则将数据包输出，否则将其丢弃



思考：漏桶算法和令牌桶算法的区别？

3. 数据包调度

- 在同一个流的数据包之间以及在竞争流之间分配路由器资源的算法称为包调度算法，它负责分配带宽和其他路由器资源，负责确定把缓冲区中的哪些数据包发送到输出链路上
  - 先来先服务FCFS（First-Come First-Serve）
  - 公平队列算法（Fair Queueing）
  - 加权公平队列算法（Weighted Fair Queueing）
  - 优先级调度（Priority Scheduling）

4. 综合服务

综合服务（IntServ：Integrated Services）/集成服务

- 综合服务特点是：需要所有的路由器在控制路径上处理每个流的消息，维护每个流的路径状态和资源预留状态，在路径上执行基于流的分类、调度、管理
- 综合服务基于资源预留协议RSVP，逐节点建立或拆除流的状态和资源预留状态，根据流的状态进行QoS路由
- 综合服务的特征：资源预分配、全局流状态、传输控制

5. 区分服务

区分服务（DiffServ：Differentiated services）

- 区分服务（DiffServ）是一种计算机网络体系结构，它指定了一种简单且可扩展的机制，用于在IP网络上分类和管理网络流量并提供服务质量（QoS）
- DiffServ可用于向诸如语音或流媒体之类的关键网络流量提供低延迟服务，同时向诸如web流量或文件传输之类的非关键服务提供简单的尽力而为服务
- DiffServ在IP报头的8位区分服务字段（DS字段）中使用6位区分服务码点（DSCP）进行分组分类。换言之，DS字段替换过时的IPv4 TOS字段

区分服务

区分服务（DiffServ：Differentiated services）

- 边界节点根据约定好的QoS规定，把将要进入网络的流量分类成不同的流。流的聚类信息用IP头部的DS field来标识。内部路由节点在转发这种包的时候，只需根据不同的DSCP选择相应的调度和转发服务即可。

Assured Forwarding behavior group

	Class 1	Class 2	Class 3	Class 4
Low drop probability	AF11 (DSCP 10) 001010	AF21 (DSCP 18) 010010	AF31 (DSCP 26) 011010	AF41 (DSCP 34) 100010
Med drop probability	AF12 (DSCP 12) 001100	AF22 (DSCP 20) 010100	AF32 (DSCP 28) 011100	AF42 (DSCP 36) 100100
High drop probability	AF13 (DSCP 14) 001110	AF23 (DSCP 22) 010110	AF33 (DSCP 30) 011110	AF43 (DSCP 38) 100110

本章内容

5.1 网络层服务
5.2 Internet网际协议
5.3 路由算法
5.4 Internet路由协议
5.5 路由器工作原理
5.6 拥塞控制算法
5.7 服务质量
5.8 三层交换与VPN
5.9 IPv6技术

1. 三层交换（实验七）
2. VPN技术

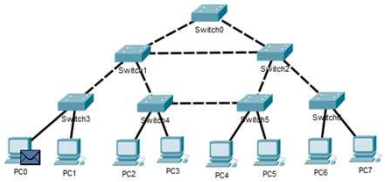
1. 三层交换的技术背景

- 二层交换网络中的广播，限制了网络规模的扩展
  - 交换机对目标地址无法匹配的数据帧进行广播转发
  - 交换机对目标地址为广播地址的数据帧进行广播转发
  - 交换机为维护生成树状态产生大量的桥协议数据单元(BPDU)
  - 这些广播帧会大量消耗网络资源，并频繁影响用户的数据通信
- VLAN虽然可以将广播的影响限定在一定范围内，但同时也隔离了正常的用户间数据通信
- 传统路由器致力于解决VLAN间互联互通，但是其转发效率和拓扑复杂性带来的网络通信瓶颈无法有效应对规模扩展

三层交换的技术背景

- 二层交换网络中的广播，限制了网络规模的扩展
  - 交换机对目标地址无法匹配的数据帧进行广播转发

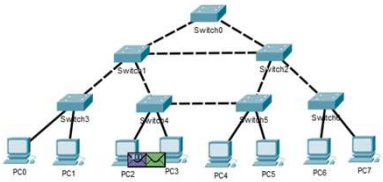
    当待转发数据帧的目标地址在转发表中没有可以匹配的记录，交换机会向除来源端口之外的所有端口复制该数据帧。



三层交换的技术背景

- 二层交换网络中的广播，限制了网络规模的扩展
  - 交换机对目标地址为广播地址的数据帧进行广播转发

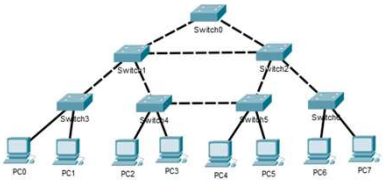
    端系统间传送IP报文时，经常需要用ARP请求的广播帧来获取目标IP的物理地址，这种频繁产生的广播帧会大量占用网络资源



PS：视频中紫色为ARP报文，绿色为数据报文

三层交换的技术背景

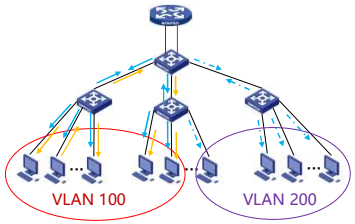
- 二层交换网络中的广播，限制了网络规模的扩展
  - 生成树协议带来的广播：交换机为维护生成树状态产生大量的桥协议数据单元（Bridge Protocol Data Unit，BPDU），例如802.1d协议周期性每隔2秒会向其所有UP状态的端口发出BPDU，这些BPDU会与端系统争用网络带宽资源



三层交换的技术背景

➢ VLAN不能解决的问题

- VLAN为了实现广播的隔离将通信限定在一定范围内，造成信息孤岛
- 没有第三层路由技术的辅助，不同VLAN之间无法通信

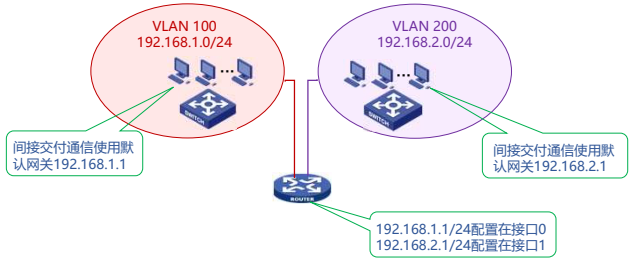


被广播的数据帧
交换机发送的BPDU

三层交换的技术背景

➢ 路由器的局限性

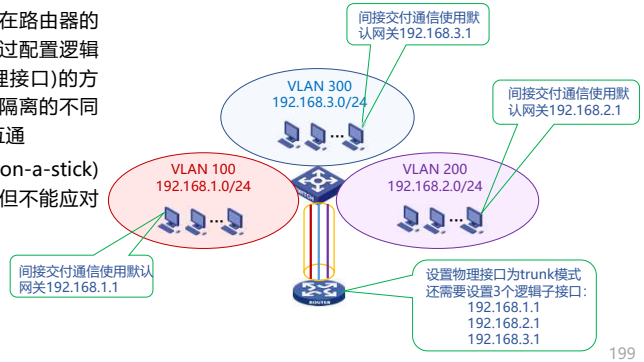
每个VLAN需要一个到路由器的物理连接，增加网络拓扑复杂性和部署成本



三层交换的技术背景

➢ 路由器的局限性

- ✓ 单臂路由技术通过在路由器的一个物理接口上通过配置逻辑子接口(不存在物理接口)的方式，实现原来相互隔离的不同VLAN之间的互联互通
- ✓ 单臂路由(router-on-a-stick)虽然简化物理拓扑但不能应对流量瓶颈



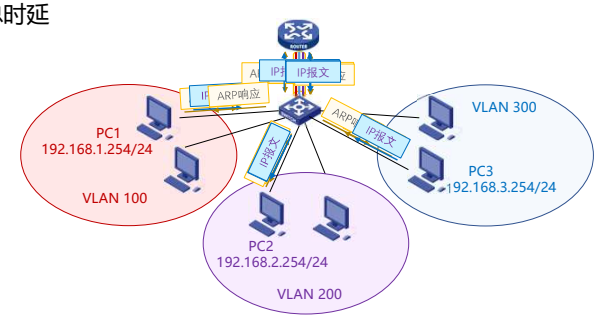
三层交换的技术背景

➢ 路由器的局限性

IP报文转发过程中产生大量ARP报文会消耗网络带宽资源，影响路由器转发性能，增加通信总时延

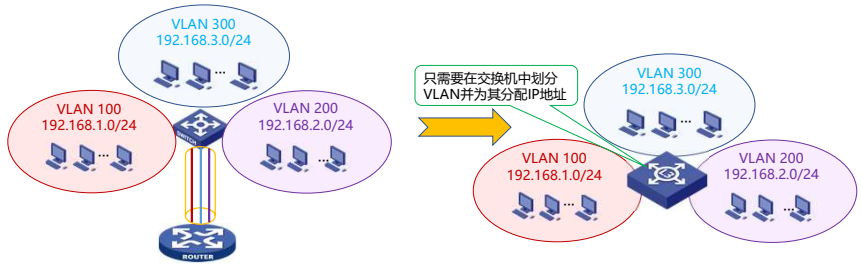
第一次通信PC1访问PC2:
阶段2：路由器路由器通信

第二次通信PC3访问PC2:
阶段2：路由器路由器通信



三层交换的动机（实验七）

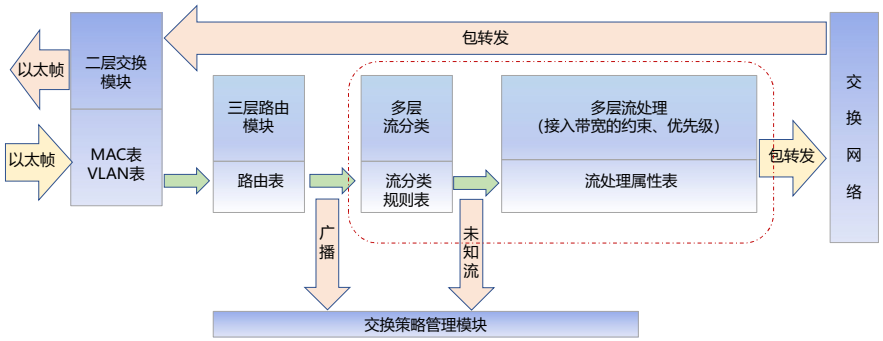
- 利用第三层协议中的信息来加强第二层交换功能，形成带有路由功能的交换
- 融合VLAN 间的二层隔离和三层互通，消除大规模网络中广播对性能的影响
- 简化网络配置，简化网络拓扑，优化网络管理，降低网络部署成本



三层交换的动机

- 全以太网的环境中，网络的帧长度是固定的，因此报文分片也是一个可以省略的工作
- 使用精确地址匹配处理，有利于硬件实现快速查找
- 使用高速缓存的方法，经常使用的主机路由放到硬件查找表中，只有在这个高速缓存中无法匹配的项目才通过软件去转发
- 使用流交换方式，对于一组具有相同源地址和目的地址的报文可以采用快速转发策略
- 简化的IP转发流程，利用专用的ASIC芯片实现硬件的转发

三层交换机的工作原理



三层交换机与路由器的比较

	三层交换机	路由器
端口数量	通常较多	通常较少
常规端口链路类型	以太链路	以太链路、串行链路、ATM等多种链路协议
对二层协议支持	MAC帧解析与封装、MAC表维护、MAC帧转发、VLAN管理	端口所支持链路类型的数据帧的解析与封装
对三层协议支持	通常基于软件进行路由表维护、路由计算，基于硬件进行报文转发	通常基于软件进行路由表维护、路由计算及报文转发
ARP Cache共享	所有交换机端口之间	路由器端口之间
业务流转发方式	报文到报文和流交换	报文到报文
报文转发时基于的地址	二层或三层	三层
VLAN间通信	三层交换机内部	二层交换机和路由器间协作
ACL访问控制列表	支持	支持
适用场景	主要连接用户端设备	主要连接网络设备

三层交换机与路由器的比较

- 路由器更注重网络（异构）互连，支持丰富的链路端口类型
- 三层交换机更注重转发效率，提供较多的端口数量，单一的以太网端口类型



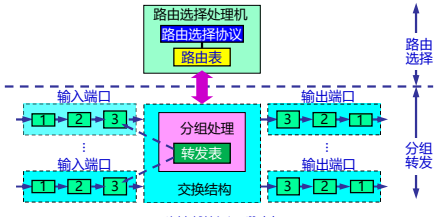
华为NetEngine 8000系列路由器



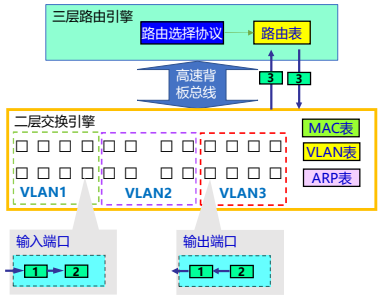
华为7900系列企业级三层交换机

三层交换机与路由器的比较

图中数字表示相应层次的构件：
3-网络层，2-数据链路层，1-物理层



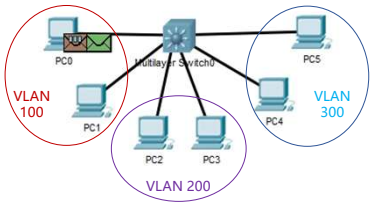
典型的路由器结构



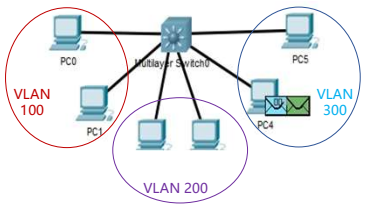
典型的三层交换机结构

三层交换机与路由器的比较

- 与路由器相比，三层交换机通过内置的二层交换引擎及其与三层交换引擎之间的高速背板，将ARP过程简化并隐藏在设备内部。



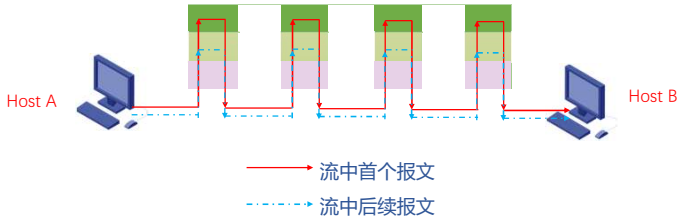
不同VLAN，交换机未知目标主机MAC地址
PS：绿色为ARP报文，棕色为IP报文



不同VLAN，交换机已知目标主机MAC地址
PS：绿色为ARP报文，蓝色为IP报文

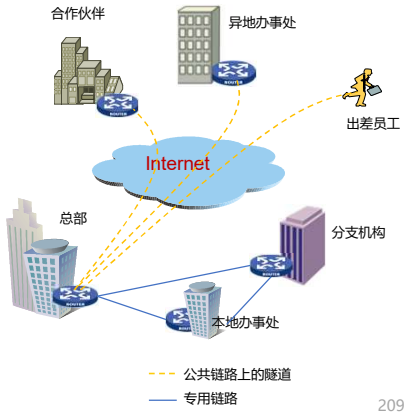
三层交换机与路由器的比较

- 流交换方式可以完成一次路由多次转发，使通信更高效。
  对于一组具有相同源地址和目的地址的报文流中第一个报文完成选路，其后续报文可以不在实施路由选路操作。



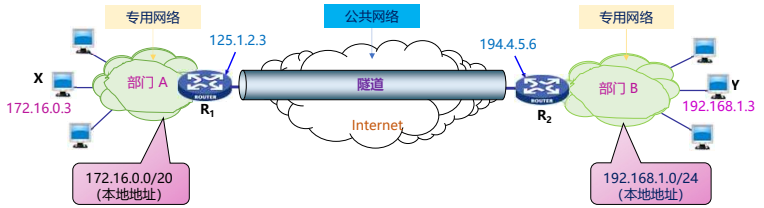
2. VPN的技术背景

- 计算机网络按用途分类
  - 专用、公用
- 专用网络的实现方式
  - 使用专用链路：铺设、租用（费用高，不灵活）
  - 使用公共链路：不安全
- 虚拟专用网VPN(Virtual Private Network)
  - 专用网络的经济、可靠、灵活的解决方案
  - 利用安全隧道技术将专用网络在公共网络上扩展
- VPN的设计原则
  - 安全性、隧道与加密、数据验证、用户验证、防火墙与攻击检测

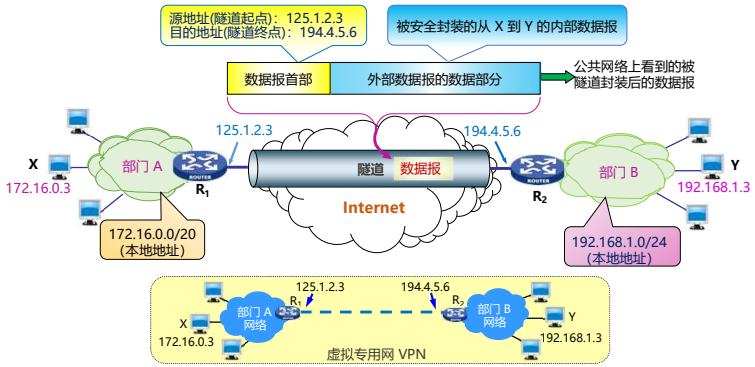


VPN的原理

- VPN指利用公用网络架设专用网络的远程访问技术
- VPN通过隧道技术在公共网络上模拟出一条点到点的逻辑专线，从而达到安全数据传输的目的

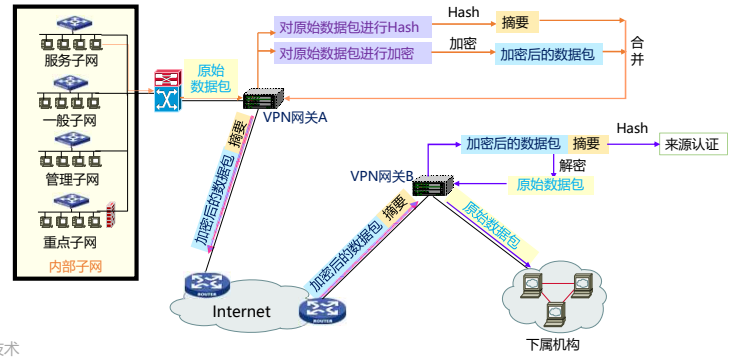


VPN的原理



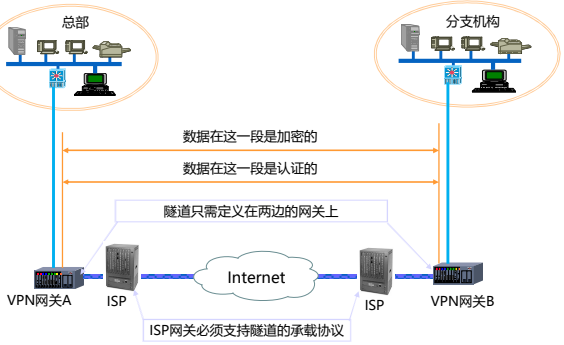
VPN的原理

- VPN对数据机密性和完整性的保护



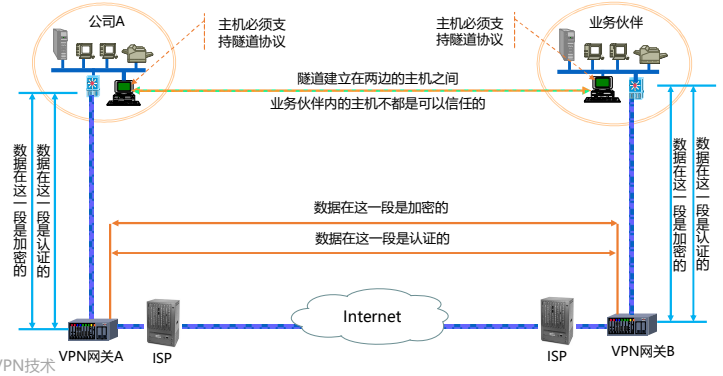
VPN的实现方式

- 用VPN连接分支机构



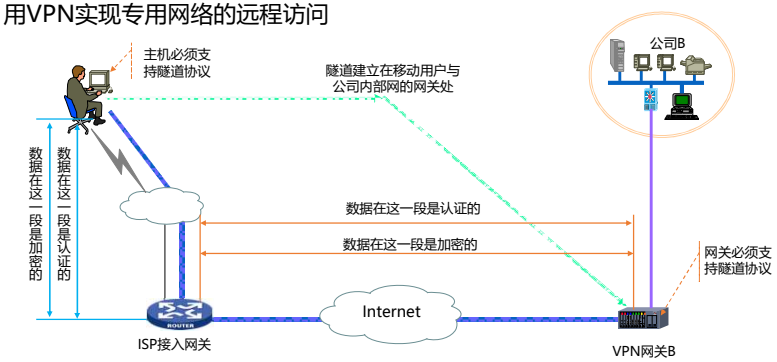
VPN的实现方式

- 用VPN连接合作伙伴



VPN的实现方式

- 用VPN实现专用网络的远程访问



VPN的分类

- 按功能位置
  - CPE-based VPN（基于客户端设备）
  - Network-based VPN（基于网络）
- 按业务构成
  - Access VPN（远程访问虚拟网）
  - Intranet VPN（企业内部虚拟网）
  - Extranet VPN（企业扩展虚拟网）
- 按实现层次
  - 二层隧道VPN（L2TP、PPTP、L2F）
  - 三层隧道VPN（GRE、IPSec）
  - 传输层隧道VPN（SSL、TLS）
- 按组网模型
  - VPDN：Virtual Private Dial Networks
    虚拟专用拨号网络
  - VPRN：Virtual Private Routed Networks
    虚拟专用路由网络
  - VPLS：Virtual Private LAN Segment
    虚拟专用LAN 网段
  - VLL：Virtual Leased Lines
    虚拟租用线

本章内容

5.1 网络层服务
5.2 Internet网际协议
5.3 路由算法
5.4 Internet路由协议
5.5 路由器工作原理
5.6 拥塞控制算法
5.7 服务质量
5.8 三层交换与VPN
5.9 IPv6技术

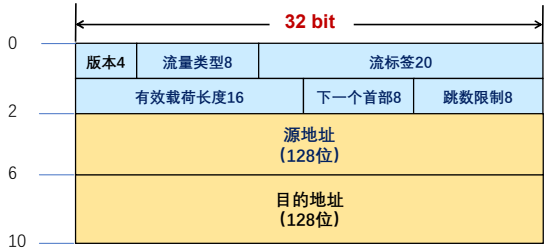
1. IPv6头部结构
2. IPv6扩展头
3. 邻居发现
4. IPv6地址配置
5. IPv6路由协议
6. IPv4/IPv6过渡技术

1. IPv6协议

- IPv6（Internet Protocol version 6）是互联网工程任务组（IETF）设计的用于替代IPv4的下一代协议
- 初始动机：应付“32-bit地址空间耗尽”问题（CIDR和NAT都无法从根本上解决地址短缺问题），需增加地址空间
- IPv6 地址
  - 地址长度为128bit，是IPv4地址长度的4倍
  - IPv6地址空间数量约为$3*10^{38}$（2^{128}）
  - IPv6地址表示法，冒分十六进制，x:x:x:x:x:x:x:x 8个x 8×16=128
    - 简化方法：每个x前面的0可省略，可把连续的值为0的x表示为“::”，且“::”只能出现1次
    - 简化前地址，2001:0DA8:0000:0000:200C:0000:0000:00A5
    - 简化后地址，2001:DA8:0000:0000:200C::A5

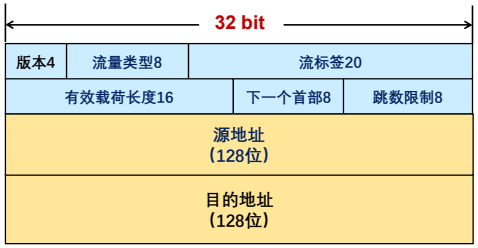
IPv6头部（40字节）

- 版本：4bit，协议版本号，值为6
- 流量类型：8bit，区分数据包的服务类别或优先级
- 流标签：20bit，标识同一个数据流
- 有效载荷长度：16bit，IPv6报头之后载荷的字节数(含扩展头)，最大值64K



IPv6头部

- 下一个首部：8bit，IPv6报头后的协议类型，可能是TCP/UDP/ICMP等，也可是不同的扩展头
- 跳数限制：8bit，类似IPv4的TTL，每次转发跳数减1，值为0时包将会被丢弃
- 源地址：128bit（16字节），标识该报文的源地址
- 目的地址：128bit（16字节），标识该报文的目的地址



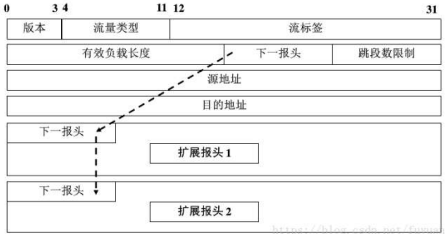
IPv6头部字段分析

- IPv6头部长度固定40字节，所有“选项”字段都在IPv6扩展头部分
- 与IPv4头部的比较
  - 去除“首部长度”（首部长度固定为40字节）
  - 去除“首部校验和”（传输层校验会涉及伪头部信息），提升转发速度
  - 去除分片字段：“标识”“标志”“片偏移”，移至扩展头（分段头）
- IPv6分片机制
  - IPv6分组不能在传输途中分片，只在源端进行分片
  - IPv6设计了专门的分片扩展头，分片字段不存在IPv6基本头部中
  - IPv6支持Path MTU发现机制

首部格式改变提升转发处理速度

2. IPv6扩展头

- IPv6报文可承载多个扩展头
- 每个扩展头都包含“下一个首部”字段（IPv6首部固定字段也有）
  - 可指向下一个**扩展头类型**
  - 或指明传统上层协议类型（**最后一个扩展头**）： TCP/UDP/ICMP . . .



头部类型	顺序	值
IPv6头部	1	41
逐跳选项	2	0
目的地选项	3、8	60
路由选项	4	43
分片选项	5	44
封装安全载荷(ESP)	7	50
认证(AH)	6	51
(无，没有下一个头部)	9	59
ICMPv6	最后	58
UDP	最后	17
TCP	最后	6
各种其它高层协议	最后	

扩展头类型

如有多个扩展头，需按规定顺序出现：

① 逐跳选项头，转发路径上每个节点都需检查该扩展头的信息

② 目的地选项头，目的端系统需要确认的信息

③ 路由头，指明转发途中需经过哪些节点，类似于IPv4的源路由机制

④ 分片头，包含类似IPv4分片处理信息：片偏移、“更多段”标志、标识符

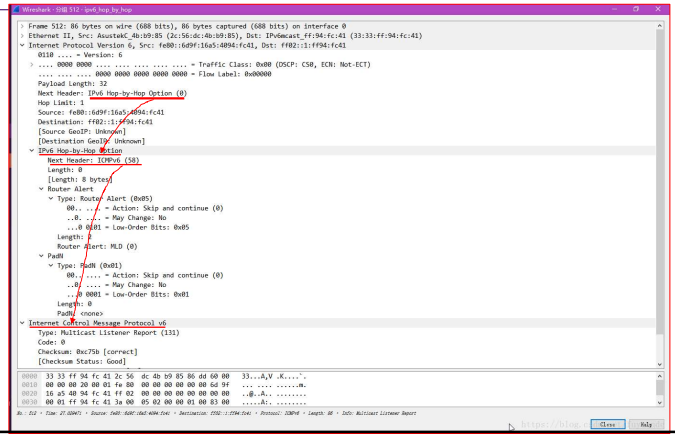
⑤ 认证AH报头，为报文提供认证、完整性校验、重放保护。对基本报头中的一些字段进行保护

⑥ 封装安全净载ESP报头，为报文提供认证、完整性校验、重放保护和 IPv6 数据报的加密

顺序：逐跳选项报头→目的选项报头→路由选择报头→分片扩展报头→认证扩展报头→封装安全净载报头→目的选项报头；

其中目的选项报头可以使用2次，第1次指出包含在IPv6头部中的目的地址，第2次是关于数据报的最终地址。

IPv6头部示例



3. 邻居发现

- 邻居发现协议（Neighbor Discovery Protocol，ND）
  - 邻居发现基于ICMPv6实现，不同的Type值和Code值表示不同的ND消息
- 消息类型1：邻居请求(Neighbor Solicitation，NS)
  - 类似于IPv4中的ARP请求报文，获取邻居的链路层地址，验证邻居可达，重复地址检测
- 消息类型2：邻居通告(Neighbor Adivertisment，NA)　NS ⟷ NA
  - 类似于IPv4中的ARP应答报文，对NS消息进行响应
- 消息类型3：路由器请求(Router Solicitation，RS)　RS ⟷ RA
  - 端系统通过RS消息向路由器发出请求，请求地址前缀和其他信息，用于节点的自动配置
- 消息类型4：路由器通告(Router Advertisement，RA)
  - 路由器通过RA消息向端系统发布地址前缀（IPv6地址自动配置）和其他配置信息
- 消息类型5：重定向(Redirect)
  - 通知主机重新选择正确的下一跳地址（针对某个目的IPv6地址）

4. IPv6地址及配置

- IPv6地址分类
  - 未指定地址（:: /128），不能分配给任何节点
  - 回环地址（::1 /128），表示节点自己，不分配，类似IPv4中的127.0.0.1
  - 组播地址（FF00:: /8）
  - 链路本地地址（FE80:: /10），也称为Link-local地址，仅在本地链路上使用，网络设备根据接口MAC地址自动生成
  - 全局单播地址，其它地址
- IPv6地址配置方式
  - 手动配置
  - DHCPv6（IPv6动态主机配置协议）
  - 无状态地址自动配置，基于ND协议的RS报文的IPv6前缀信息，结合自己的链路层地址生成IPv6地址

5. IPv6路由协议

- RIPng for IPv6，RFC 2080，对RIP修改以适应IPv6环境
  - 使用路由器的链路本地IPv6地址作为源地址，发送路由更新信息
- OSPFv3 for IPv6，RFC 5340，适应IPv6网络
  - 使用路由器的链路本地IPv6地址作为源地址，并作为下一跳地址
  - OSPFv3有7种类型的LSA，新增Link LSA和Intra Area Prefix LSA
- MP-BGP（Multi-Protocol BGP），来自RFC 4760文档，支持多种网络层协议（IPv6和IPX）
  - MP-BGP向前兼容，并支持组播
  - BGP连接可以是IPv4或IPv6，报文内可传递其它网络协议的路由信息
  - 多协议可达NLRI描述了到达目的地的信息：地址属于哪个网络层协议，下一跳地址

6. IPv4到IPv6迁移及过渡技术

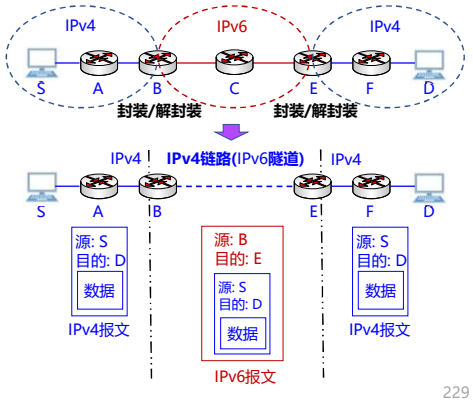
- IPv4协议和IPv6协议并不兼容，迁移可能经历很长时间
  - 涉及：互联网用户、互联网服务提供商（ISP）、互联网内容提供商（ICP）、网络设备厂家
- IPv4/IPv6过渡技术的关键要素
  - 尽量保证端到端透明原则
  - 高效、可行的编址及地址规划
  - 路由可扩展性，避免路由表膨胀（消耗转发资源）
  - 状态维护，减少因为过渡机制引起的状态维护，如IPv4-IPv6映射关系
- 主流过渡技术
  - 双栈技术：是指在单个节点同时支持IPv4和IPv6两种协议栈。
  - 隧道技术
  - 翻译技术

1）隧道技术

隧道技术：2个同构网络的系统，跨越中间异构网络进行通信。将A协议数据包封装在B协议中传输，目的端再将A解封装出来。

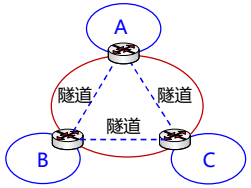
隧道类型：

- 应用层隧道
  - SSH隧道，HTTPS隧道
- 传输层隧道
  - TCP隧道，UDP隧道
- 网络层隧道
  - 4 in 4，4 in 6，6 in 4
  - GRE，通用路由封装隧道
- 链路层隧道
  - L2TP协议，链路层隧道
  - PPTP协议，点对点隧道

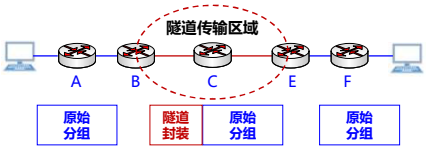


1）隧道技术

- 隧道链路的选择问题：
  - A发往B、C的报文，通过哪条隧道发送?
- 静态配置
  - ip route 30.0.0.0/8 tunnel 1
- 动态学习
  - Softwire，软线隧道过渡技术
    RFC 5565 [清华大学：吴建平、崔勇]



- 报文长度在传输途中增大导致分片问题
  - 途中分片与重组对传输性能影响较大
- 解决方法
  - 隧道网关提前分片
  - Path MTU发现机制



隧道配置(参考华三交换机)

隧道配置命令

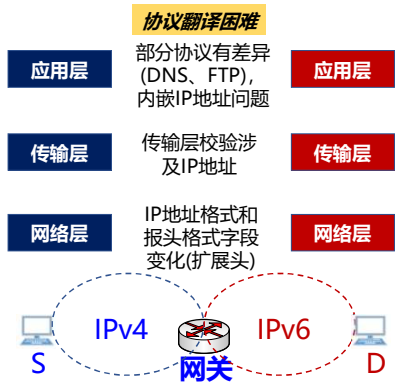
- **interface tunnel** *number* [**mode ipv6**] //创建隧道并设置隧道模式
- **ip address** *ip-address* { *mask* | *mask-length* } [**sub**] //设置Tunnel接口的IPv4地址
- **source** { *ipv6-address* | *interface-type interface-number* } //设置隧道源端地址或源接口
- **destination** *ipv6-address* // 设置隧道的目的端地址

隧道配置示例

- [SwitchA] interface tunnel 1 mode ipv6 //创建模式为IPv6隧道的接口Tunnel1
- [SwitchA-Tunnel1] ip address 30.1.2.1 255.255.255.0 //配置Tunnel1接口的IP地址
- [SwitchA-Tunnel1] source 2001::1:1 //配置Tunnel1接口的源端地址
- [SwitchA-Tunnel1] destination 2002::2:1 //配置Tunnel1接口的目的端地址
- [SwitchA] ip route-static 30.1.3.0 255.255.255.0 tunnel 1 //配置哪些报文经隧道传输

2）IPv4/IPv6翻译

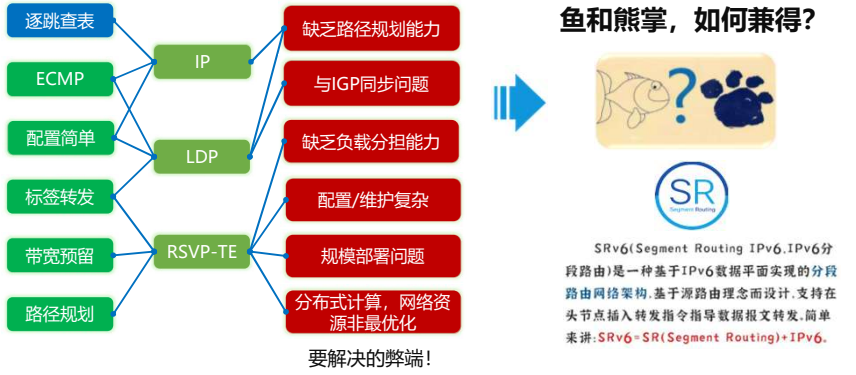
- IPv4-IPv6地址往返转换
- IPv4报头和IPv6报头翻译
  - 各字段对应，包括IP选项翻译
- 传输层校验和转换，涉及IPv6地址
- ICMP翻译
  - ICMPv6重新设计了类型值和代码值
- 其它应用层协议翻译
  - FTP（命令名称变化，内嵌IP地址）
  - 内嵌IP地址的其它应用层协议
- DNS处理
  - 实现域名查询中A记录和4A记录的双向翻译



IPv4/IPv6翻译的问题

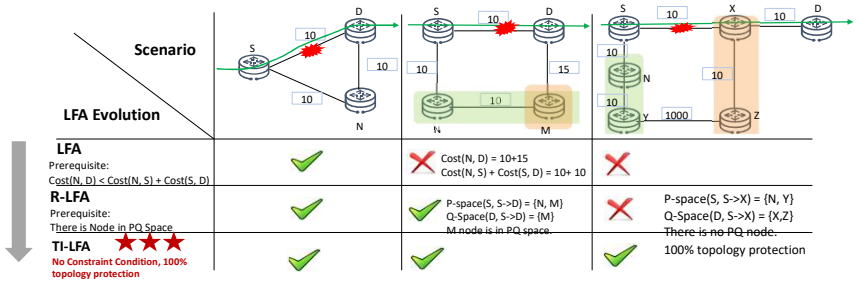
- 破坏互联网端到端原则
  - 通信双方只看到通信对端在本网络对应的地址
  - 翻译网关处理传输层、应用层数据（上层数据无法透明传输）
- 异构地址寻址问题
  - 通信双方至少有一方需感知本次通信涉及翻译技术
  - 域名访问需DNS服务支撑
- 路由可扩展问题
  - IPv4/IPv6翻译专用的96位前缀，给路由聚合带来困难
- 应用层内嵌IP地址
  - 部分应用层协议内嵌IP地址，将使翻译技术实施难度极大
- 翻译导致报文变长可能导致分片问题，影响转发性能

3）SR背景：IP/MPLS遇到瓶颈



要解决的弊端!

3）SR背景：追求更高FRR覆盖率

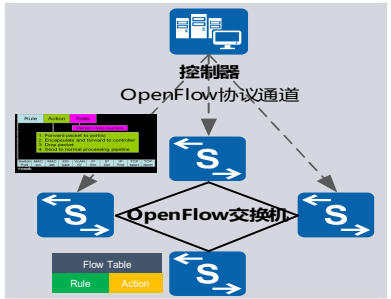


P-space(S, protected link/node): 用最短路径算法可从S节点到达且不经过保护链路/节点的路由器集合

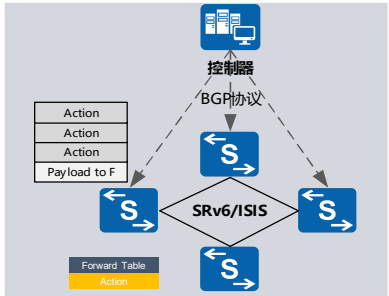
Q-space(D, protected link/node): 用最短路径算法可从D节点到达且不经过保护链路/节点的路由器集合

图例 10、 cost p空间 Q空间

SR背景：经典SDN遇到扩展性问题



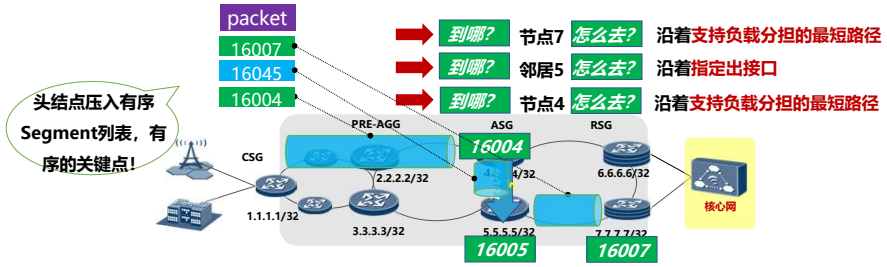
经典 SDN:
1. 有扩展性问题。随着网络规模增大，流表成N2级增长
2. 可靠性问题，单点故障
3. 性能问题，网络故障涉及海量的表项更新



Hybrid SDN:
1. 可扩展性：表项数量从N平方到N
2. 可靠性：集中式和分布式相结合，集中式故障分布式还可以维持连通性
3. 高性能：收敛只需要更新头结点

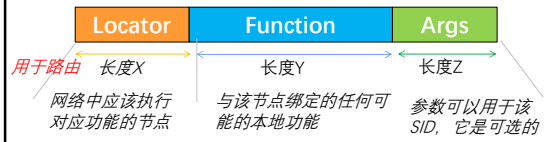
SR原理：源路由技术

Segment：本质是指令，指引报文去哪？怎么去？同时表示一个路径段。



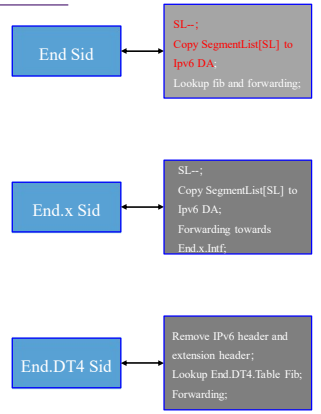
根据转发面的不同，SR分为SR MPLS和SRv6两种。

SRv6原理：SRv6 段ID

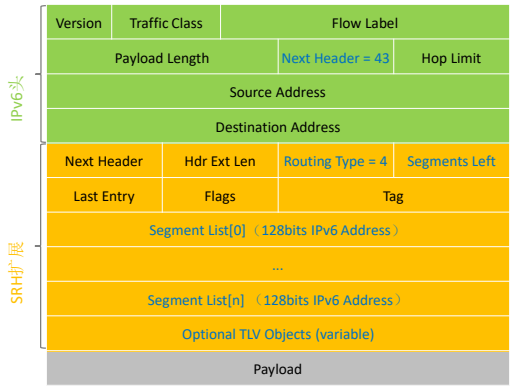


SRv6 Sid: 标识SRv6 Segment 的ID 被称为SRv6 SID，SRv6 SID是一个128 bit 的值，它通常由3 个部分组成。

- Locator: Locator 是网络拓扑中一个网络节点的标识，用于路由和转发报文到该节点。Locator 标识的位置信息有两个重要的属性：可路由和可聚合。
- Function : Function 用来表达该指令要执行的转发动作， 相当于计算机指令的Opcode。在SRv6 网络编程中， 不同的转发行为由不同的Function 来表达。和计算机的指令类似，按照不同功能将Function 定义成不同类型的SID，表达对应的转发行为，如转发报文到指定链路，或在指定表中进行查表转发等。
- Args : Arguments （Args）是一个可选字段。它是指令在执行时对应的参数，这些参数可能包含流、服务或任何其他相关的信息。



SRv6原理：SRv6 报文格式



SRH （段路由头）是 Routing Header (RFC8200)的一种，Next Header = 43; Routing Type = 4

SRH中的重要字段：

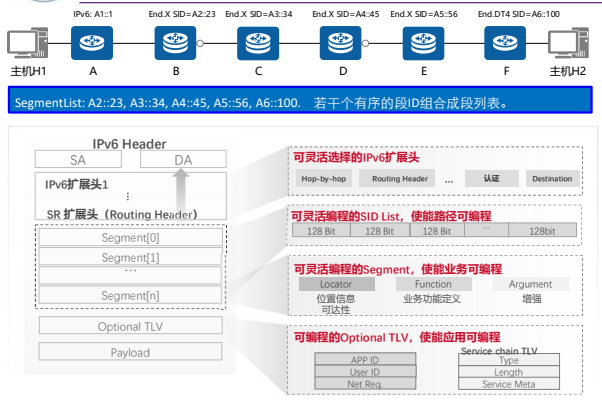
Segments Left :剩余的路由段数，即在到达最终目的地之前仍需访问的显式列出的中间节点的数目。

Segment List[n]: 表示分片列表中第n个分片的128位IPv6地址，从路径的最后一段开始编码。例如，Segment List[0]包含路径的最后一段。

Optional TLV Objects: 可以作为Segment列表中所有SID的全局参数，如NSH元数据、HMAC TLV、填充TLV等。

- *RFC 8200, Internet Protocol, Version 6 (IPv6) Specification*
- *draft-ietf-6man-segment-routing-header-xx, IPv6 Segment Routing Header (SRH)*

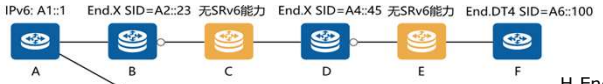
SRv6原理：SRv6 网络编程



SL--;
Copy SegmentList[SL] to Ipv6 DA;
Forwarding towards End.x.Intf;
Router to C:
SL--;
Copy SegmentList[SL] to Ipv6 DA;
Forwarding towards End.x.Intf;
.....
Router to F:
Remove IPv6 header and extension header;
Lookup End.DT4.Table Fib;

- SRv6网络可编程：
- 指令编程：VPN，SFC， 网络服务化
- SegmentList: 路径编程
- HBH Option(逐跳选项)：切片，检测，APN6
- 原生IPv6: Overlay技术

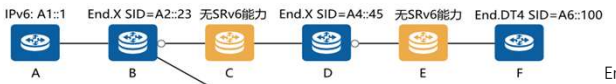
SRv6原理：SRv6 转发



Version	Traffic Class	Flow Label	
Payload Length		Next=43	Hop Limit
Source Address (A1::1)			
Destination Address (**A2::23**)			
Next Header	Hdr Ext Len	Routing Type=4	Segments Left=**2**
Last Entry	Flags	Tag	
Segment List[0]=A6::100			
Segment List[1]=A4::45			
Segment List[2]=**A2::23**			
Payload			

H.Encaps：头结点封装处理，原始报文在进入SRv6域对报文做SRv6封装处理。H.Encap执行的动作是在原始数据报文封装一个IPv6 报文头与 SRH，并设置源地址为当前节点的地址，目的地址为SRv6 Policy 的第一 个 SID，此外还要设置好外层IPv6报文头的各个字段，最后对这个新的IPv6报文进行查表转发。

SRv6原理：SRv6 转发



Version	Traffic Class	Flow Label	
Payload Length		Next=43	Hop Limit
Source Address (A1::1)			
Destination Address (**A4::45**)			
Next Header	Hdr Ext Len	Routing Type=4	Segments Left=**1**
Last Entry	Flags	Tag	
Segment List[0]=A6::100			
Segment List[1]=**A4::45**			
Segment List[2]=A2::23			
Payload			

Endpoint：在SRv6报文转发过程中，节点接收的报文的IPv6 目的地址是本地配置的SID，则该节点被称为Endpoint 节点。因此Endpoint 节点需要处理 SRv6 SID 和 SRH。

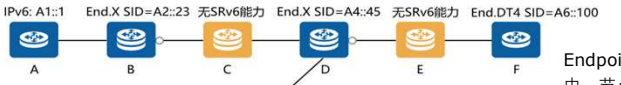
SRv6原理：SRv6 转发



Version	Traffic Class	Flow Label	
Payload Length		Next=43	Hop Limit
Source Address (A1::1)			
Destination Address (**A4::45**)			
Next Header	Hdr Ext Len	Routing Type=4	Segments Left=**1**
Last Entry	Flags	Tag	
Segment List[0]=A6::100			
Segment List[1]=**A4::45**			
Segment List[2]=A2::23			
Payload			

Transit：中转节点是在SRv6报文转发路径上不参与SRv6处理的IPv6节点，即中转节点只执行普通的IPv6报文转发。当节点收到SRv6报文后，会解析报文的IPv6 DA(目的地址)字段。如果IPv6目的地址既不是本地配置的 SRv6 SID，也不是本地接口地址，则节点将SRv6报文当作普通的IPv6 报文，按照最长匹配原则查找IPv6路由表，进行处理和转发，不处理SRH，此时该节点就是中转节点。

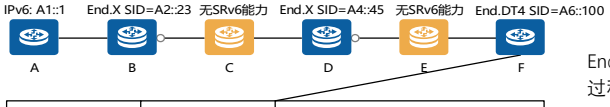
SRv6原理：SRv6 转发



Version	Traffic Class	Flow Label	
Payload Length		Next=43	Hop Limit
Source Address (A1::1)			
Destination Address (**A6::100**)			
Next Header	Hdr Ext Len	Routing Type=4	Segments Left=**0**
Last Entry	Flags	Tag	
Segment List[0]=**A6::100**			
Segment List[1]=A4::45			
Segment List[2]=A2::23			
Payload			

Endpoint：在SRv6报文转发过程中，节点接收报文的IPv6目的地址是本地配置的SID，则该节点被称为Endpoint节点。因此 Endpoint节点需要处理SRv6 SID 和SRH。PSP:(Penultimate Segment Pop of the SRH，倒数第二段弹出 SRH) 是指在倒数第二个Endpoint节点执行移除 SRH 的动作。PSP需要与End 、End.X和End.T结合使用，是附着在它们之上的额外动作。

SRv6原理：SRv6 转发



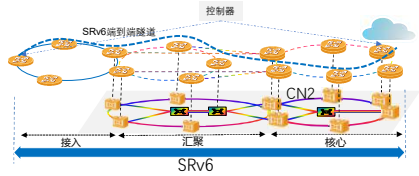
Version	Traffic Class	Flow Label	
Payload Length		Next=43	Hop Limit
Source Address (A1::1)			
Destination Address (**A6::100**)			
Next Header	Hdr Ext Len	Routing Type=4	Segments Left=**0**
Last Entry	Flags	Tag	
Segment List[0]=**A6::100**			
Segment List[1]=A4::45			
Segment List[2]=A2::23			
Payload			

Endpoint：在 SRv6 报文转发过程中，节点接收的报文的 IPv6 目的地址是本地配置的 SID，则该节点被称为 Endpoint 节点。因此 Endpoint 节点需要处理 SRv6 SID 和 SRH。

Decapsulation：解封装SRH头和外层IPv6头。

SRv6应用：Native IPv6能力

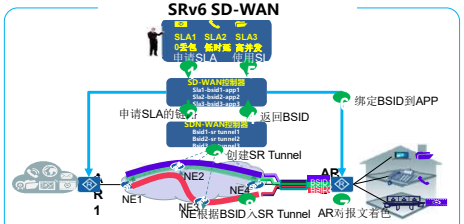
SRv6跨域：一跳入云



AS-IS
- VPN+VLAN分段跨域，部署运维复杂
- 骨干网业务开通时间>2周

TO-BE
- ✓ SRv6一跳直达，一跳入云
- ✓ 路由可聚合，支持超大规模网络
- ✓ 快速收敛

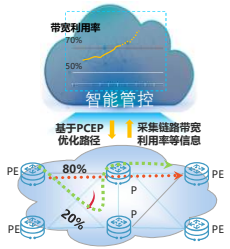
SRv6 SD-WAN



- **统一Underlay/Overlay**：Overlay: 利用SRv6的原生IPv6能力可以穿越多个Underlay网络。Underlay:利用SRv6可编程能力提供应用级选路能力
- **网络服务化**：网络可以把连接服务开放出去，用户可以方便远程访问网络服务

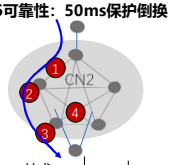
SRv6应用：路径编程

SRv6 Traffic Engineering



- 无状态流量工程
- 百万级连接
- 端到端

SRv6可靠性：50ms保护倒换



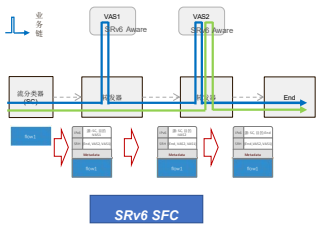
	技术	Time
1	SRv6 TI-LFA	50ms
2	SRv6 Midpoint protection	50ms
3	SRv6 Mirror protection	50ms
4	SRv6 microloop avoid	0

< 50ms

AS-IS
- 无TE FRR，BFD受限，平均倒换丢包时间大于200ms

TO-BE
- 端到端50ms保护

SRv6业务链：SRv6 SFC



- **无状态业务链**：基于SRv6 Policy提供路径编排能力，中间结点不需要维护业务链状态
- **业务一次解析多次使用**：业务深度识别，通过Metadata携带元属性信息，所有VAS都可使用

致谢社区本章贡献者

贡献者姓名	单 位	贡献内容
陈文龙	首都师范大学	本章统稿 5.5 5.9(IPv6协议)
吴黎兵	武汉大学	5.6 5.7
谢晓燕	西安邮电大学	5.8
邹莹	仲恺农业工程学院	5.4.1 5.4.2 5.4.4
李旭宏	枣庄学院	5.1.2 5.1.3 5.2.3 5.2.4 5.2.6 5.4.3
曲大鹏	辽宁大学	5.3.1 5.3.2
方诗虹	西南民族大学	5.1.4 5.3.5 5.3.6 5.3.7 5.3.8
舒挺	浙江理工大学	5.1.1
白云莉	内蒙古农业大学	5.3.3 5.3.4
余琨	荆楚理工学院	5.2.1 5.2.2 5.2.5
李振斌	华为技术有限公司	5.9(SRv6)