西南交通大学
Southwest Jiaotong University

云计算概论

CLOUD COMPUTING

丛荣

西南交通大学
计算机与人工智能学院





目录
Contents

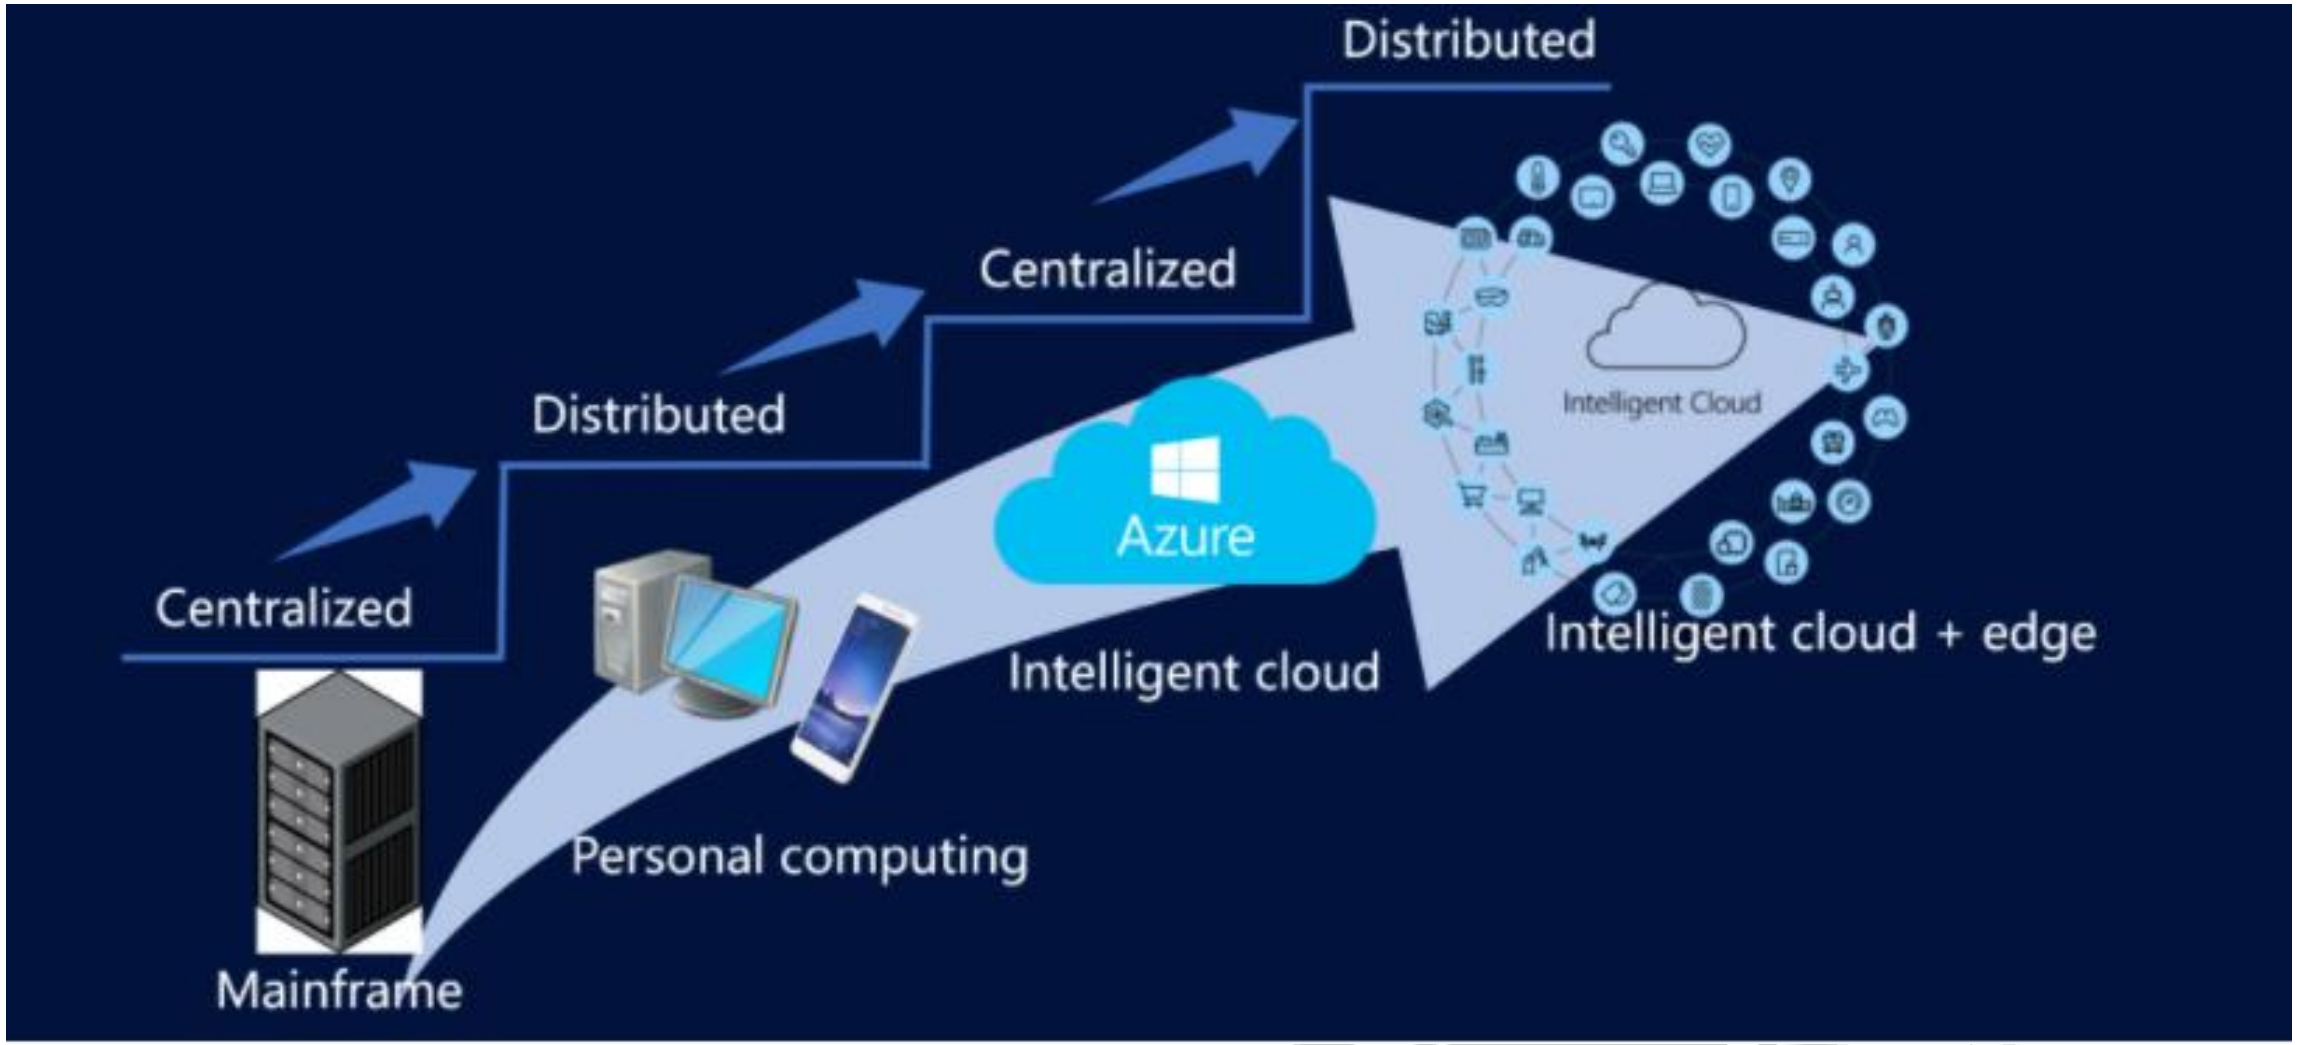
1 背景-计算时代的演进

2 云计算的基本概念

3 云计算核心技术栈

4 代码示例与解析

计算模式的演化


Distributed
Centralized
Distributed
Centralized
Azure
Intelligent Cloud
Intelligent cloud
Intelligent cloud + edge
Personal computing
Mainframe

为什么会重新集中？大数据的爆发

- **新摩尔定律**：每18个月全球新增信息量翻倍
- **人类活动已全面数字化**：从手工到自动化，从日常通信到智能制造
- **数据爆炸**：全球数据总量呈指数级增长（从EB到ZB时代）



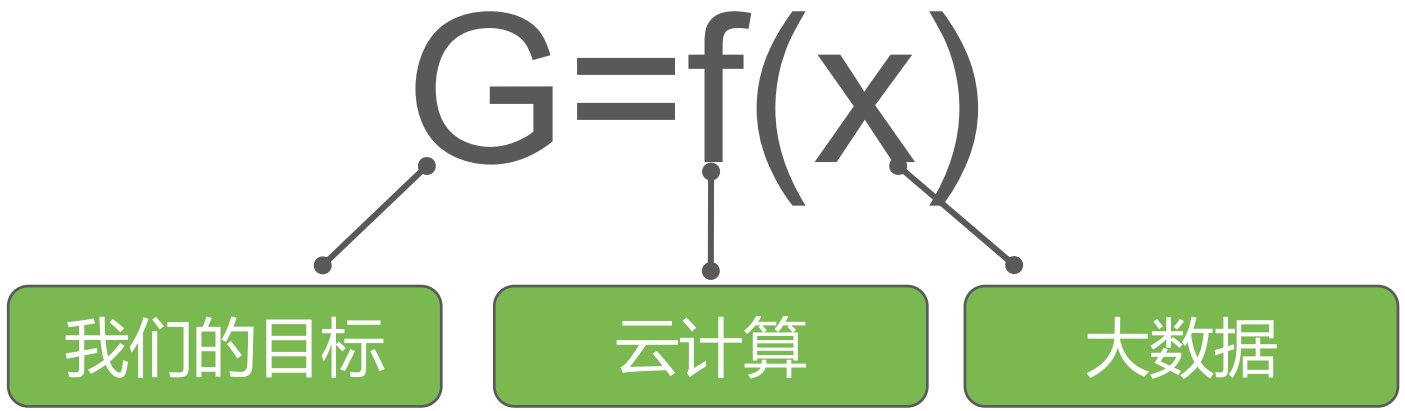
云计算的处理对象：大数据

- 什么是大数据

  海量数据或巨量数据，其规模巨大到无法通过目前主流的计算机系统在合理时间内获取、存储、管理、处理并提炼以帮助使用者决策。

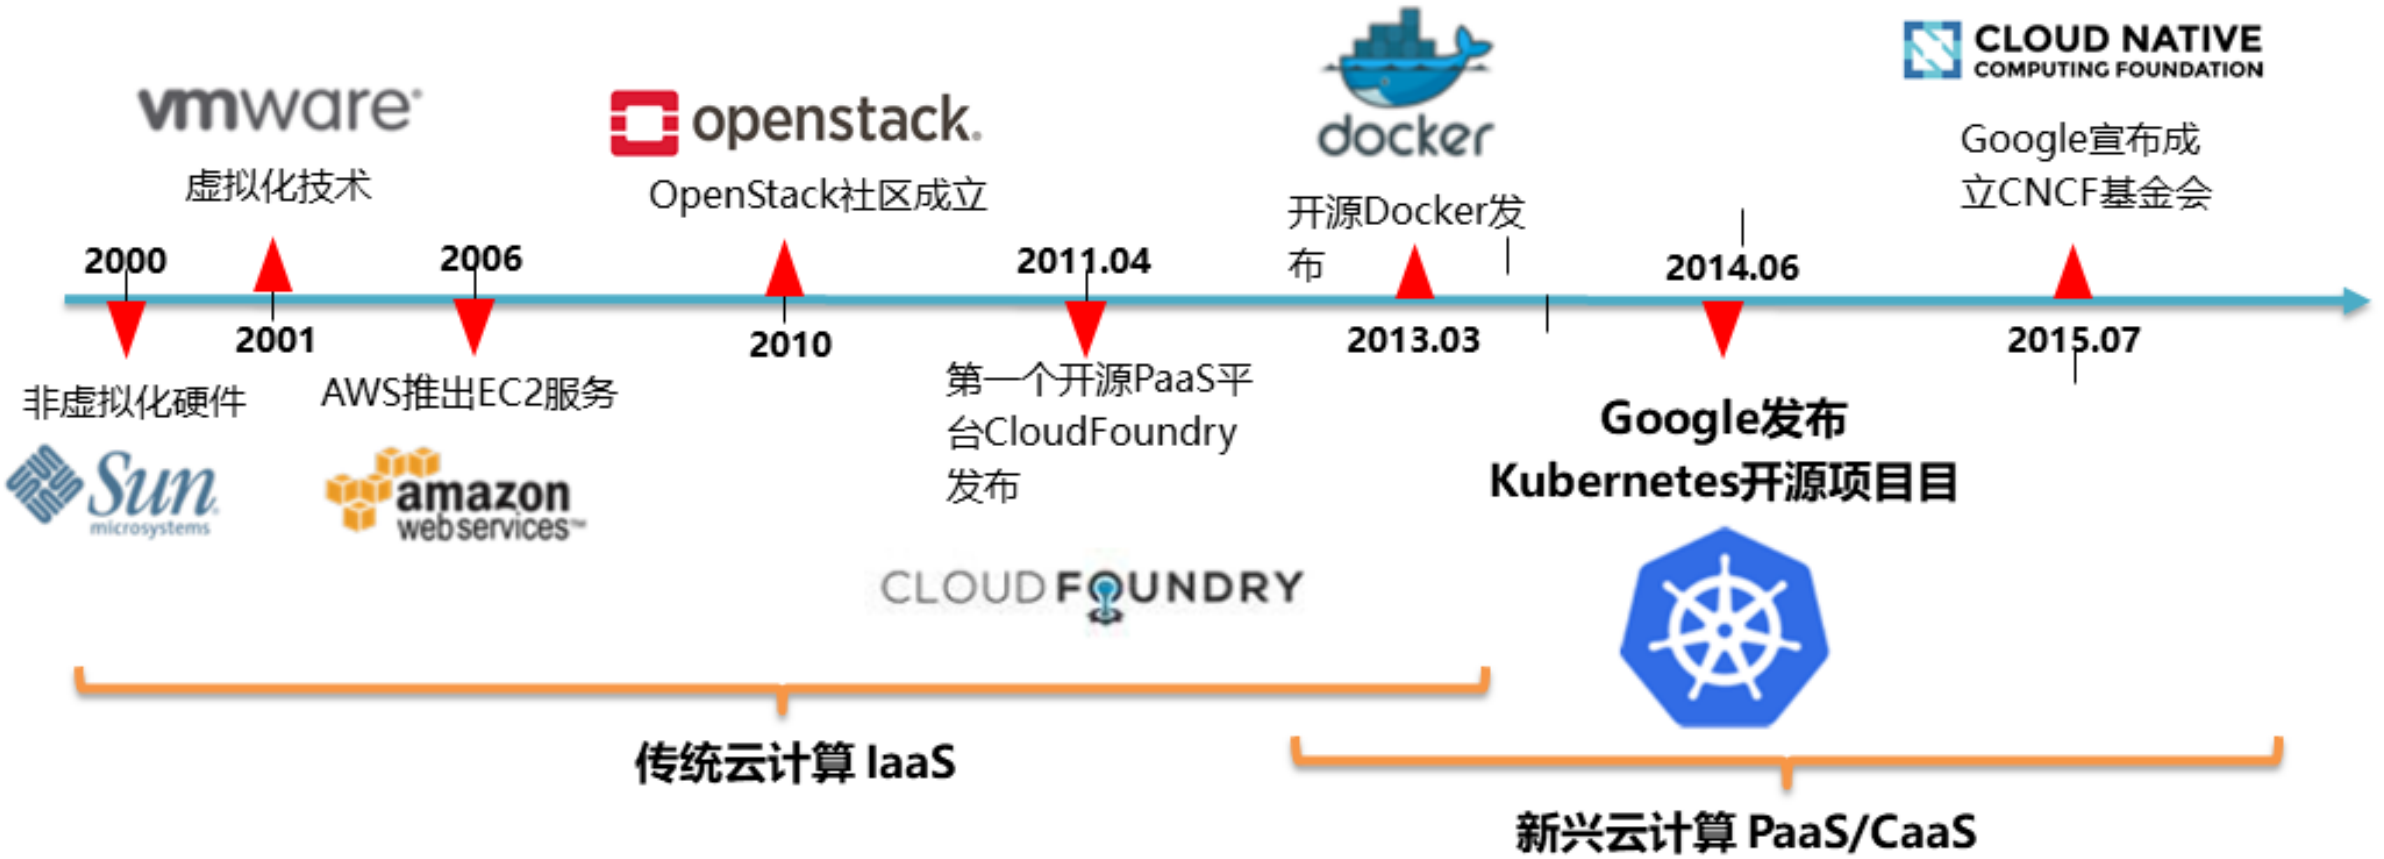
- 大数据4V+1C特征
  - Volume (数据量大)：PB/EB 级别成为常态 。
  - Velocity (快速)：数据产生与处理要求极速响应 。
  - Variety (多样)：结构化、半结构化、非结构化混合 。
  - Value (价值密度低)：需从海量沙砾中淘金 。
  - Complexity (复杂度高)：分析难度呈指数上升

云计算与大数据的共生关系



- **云计算是处理大数据的手段**
- 没有大数据，就不需要云计算
- 没有云计算，就无法处理大数据

云计算的发展变迁


vmware
虚拟化技术
openstack.
OpenStack社区成立
docker
开源Docker发布
CLOUD NATIVE COMPUTING FOUNDATION
Google宣布成立CNCF基金会
2000
2001
2006
2010
2011.04
2013.03
2014.06
2015.07
非虚拟化硬件
AWS推出EC2服务
第一个开源PaaS平台CloudFoundry发布
Google发布Kubernetes开源项目目
Sun microsystems
amazon web services
CLOUD FOUNDRY
传统云计算 IaaS
新兴云计算 PaaS/CaaS

云计算的发展变迁：关键事件

- 云计算的雏形阶段（1990年代）
  - 网络计算、 效用计算
- 虚拟化技术的成熟（2000年）
  - VMware
- 云计算概念提出（2006年 AWS S3/EC2）
  - Google提出概念
  - AWS推出S3/EC2
- 云计算爆发期（2010年后）
  - 移动互联网爆发
- 云原生时代（2015年后）
  - Docker与Kubernetes重塑架构

云计算的发展变迁：虚拟化与IaaS

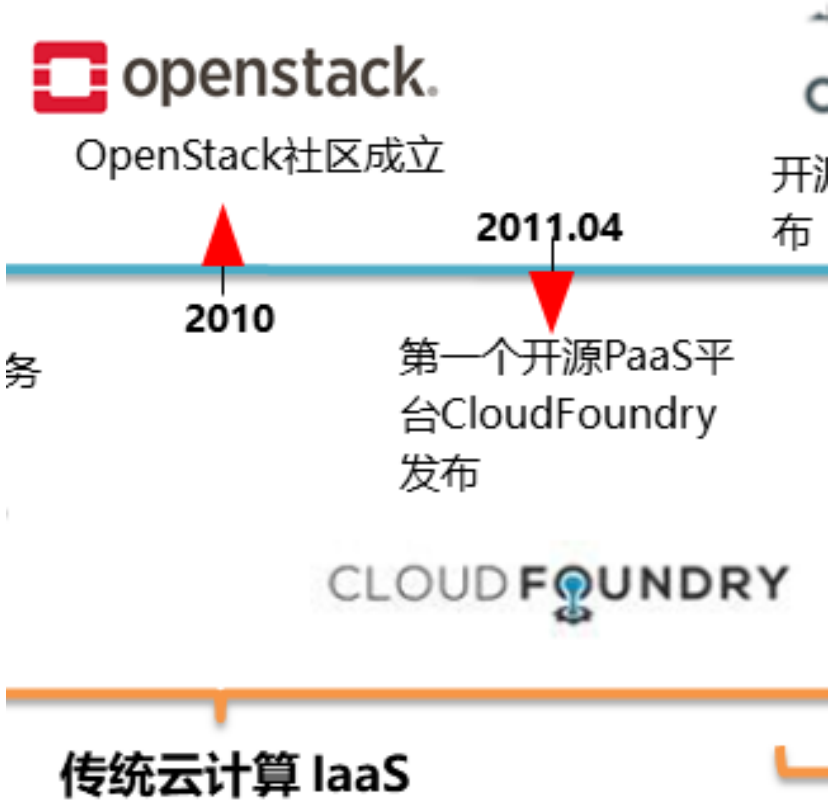
- 2000年 (非虚拟化硬件)
  - 以 Sun Microsystems 为代表的物理硬件集群
  - 资源被死死绑定在硬件上
- 2001年 (虚拟化技术)
  - VMware
  - 虚拟化技术成熟，物理机到虚拟机的资源池化
- 2006年 (商业里程碑):
  - Google提出云计算概念
  - AWS 推出 EC2 (弹性计算云)
  - 传统云计算 IaaS时代正式开启



云计算的发展变迁：开源力量与平台的崛起

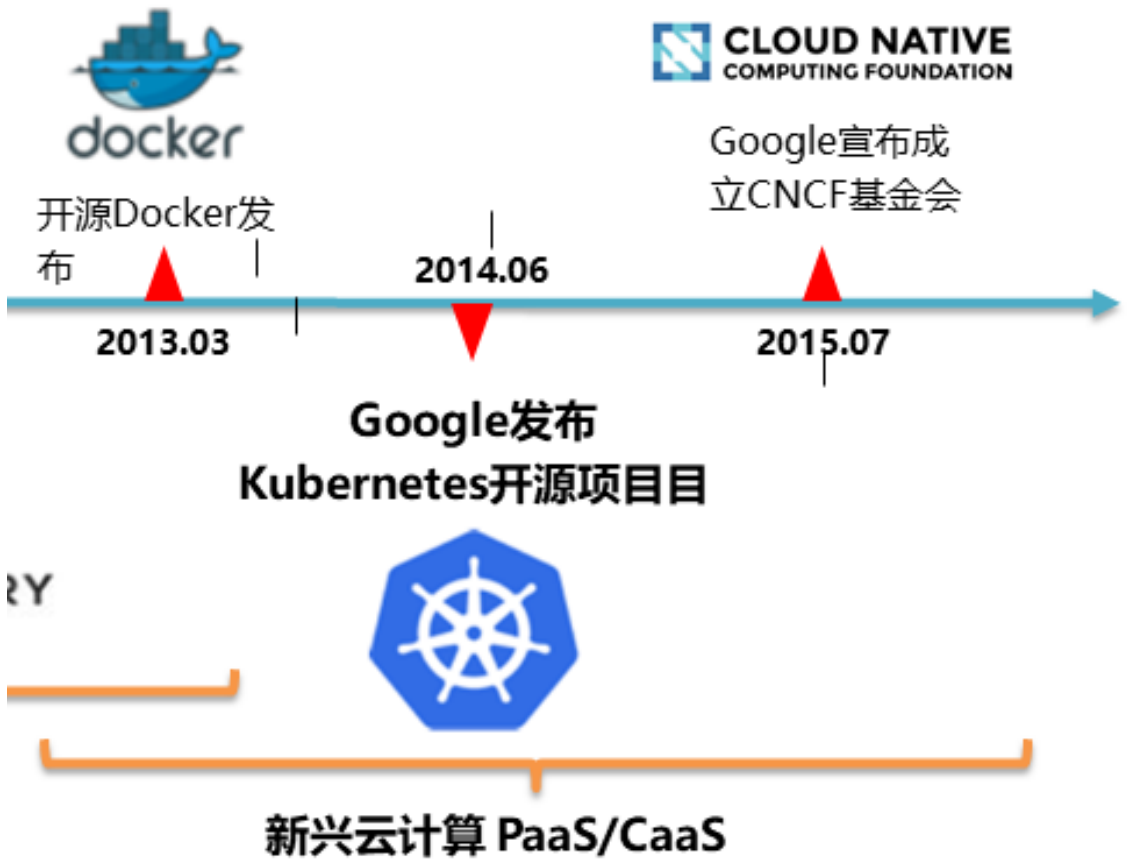
- 2010年 (IaaS开源繁荣)
  - OpenStack 社区成立
  - 企业开始利用开源技术搭建私有 IaaS 平台
- 2011年 (PaaS开源平台)
  - 第一个开源 PaaS 平台 CloudFoundry 发布

开发者不再满足于只租用IaaS
云计算开始向应用层上浮



云计算的发展变迁：云原生时代爆发

- 2013年 (Docker发布)
  - Docker 开源发布
  - 极其轻量级的容器技术彻底颠覆了软件交付方式
- 2014年 (K8S发布)
  - Google 发布 Kubernetes (K8s) 开源项目
  - 解决大规模容器调度问题
- 2015年 (CNCF成立):
  - Google 宣布成立 CNCF 基金会
  - 正式迈入云原生时代





目录
Contents

1 背景-计算时代的演进

2 云计算的基本概念

3 云计算核心技术栈

4 代码示例与解析

云计算的定义

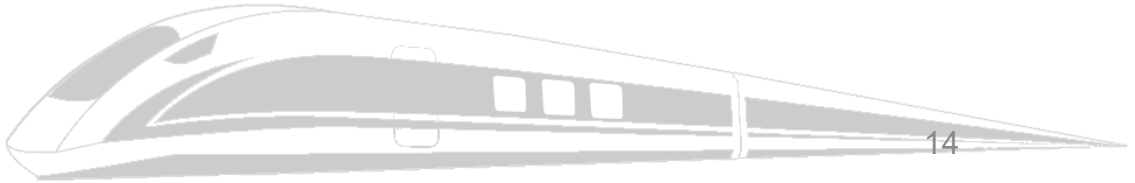
- 根据NIST (美国国家标准与技术研究院) 定义：
- 云计算是一种计算模型，允许无处不在的、便捷的、按需的网络访问
- 具备共享的可配置计算资源池（包括网络、服务器、存储、应用和服务）
- 资源能够用最小的管理代价或服务提供商的交互实现快速配置和发布

NIST
National Institute of Standards and Technology

"Cloud computing is a model for enabling convenient, on-demand network access to a shared pool of configurable computing resources (e.g., networks, servers, storage, applications, and services) that can be rapidly provisioned and released with minimal management effort or service provider interaction. "

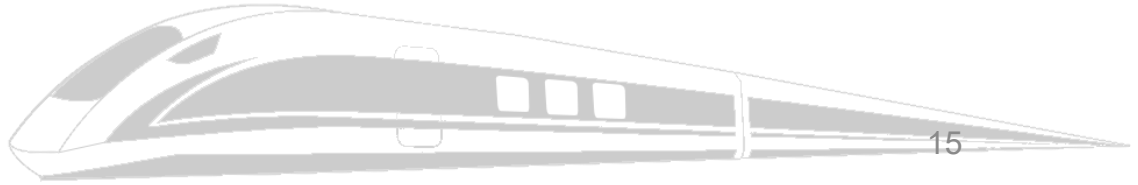
云计算的本质特征

- 按需自服务
- 弹性扩展
- 资源池化
- 网络访问
- 按量计费



云计算的本质

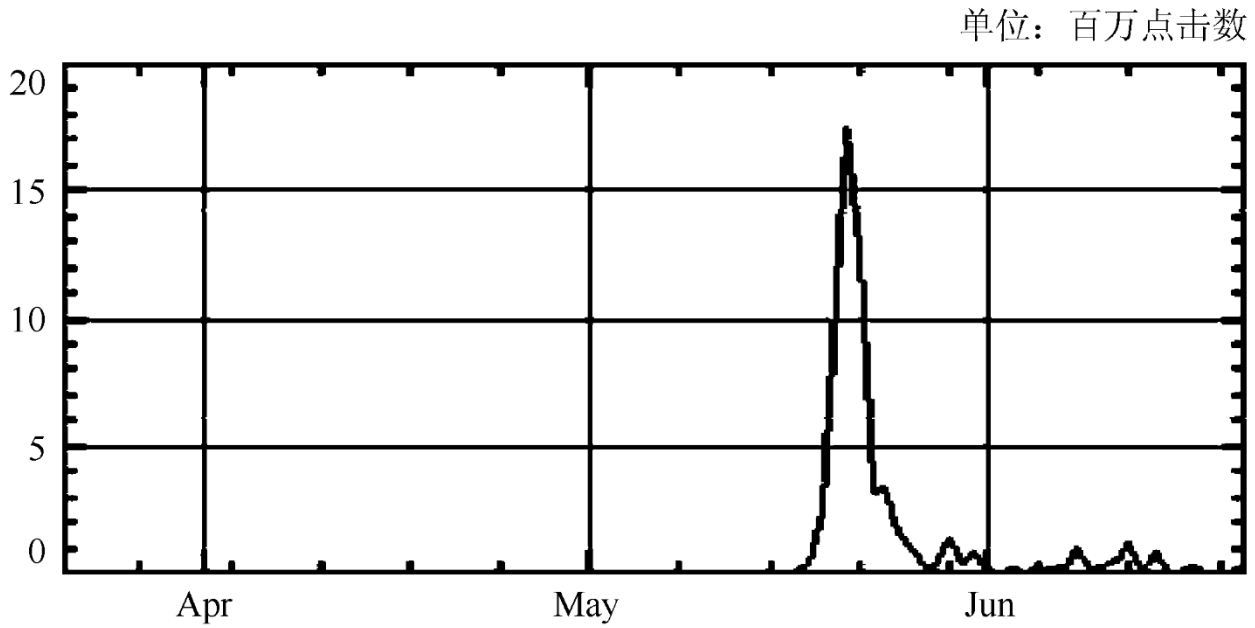
- 按需自服务
  - 用户可以根据单方面需要，自动配置计算能力（如服务器时间和网络存储）
  - 整个过程无需与每个服务提供商进行人工交互
  - 高度自动化的 API 调用是实现按需自服务的基础



云计算的本质

弹性扩展

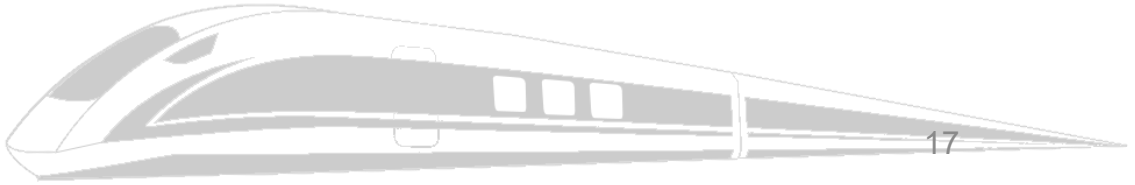
- 能力可以快速、弹性地提供，在某些情况下可以自动横向扩展 (Scale-out) 或缩减 (Scale-in)
- 对于消费者而言，可供配置的能力看起来是无限的
- 完美契合流量突发型业务（如电商大促、突发热点事件）



某典型网站的流量数据

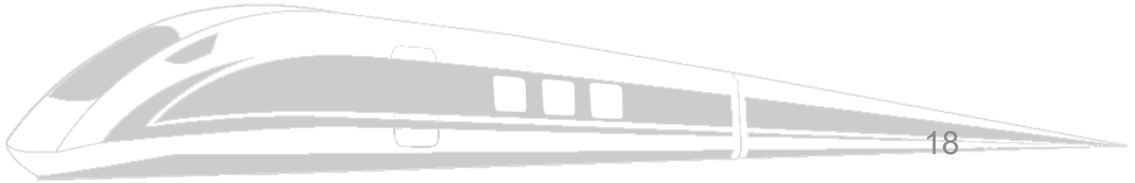
云计算的本质

- 资源池化
  - 多租户（multi-tenancy）
  - 上万台服务器被融合成一个巨大的计算资源池
  - 供应商的计算资源被池化以服务于多个消费者
  - 互相隔离、互不干扰



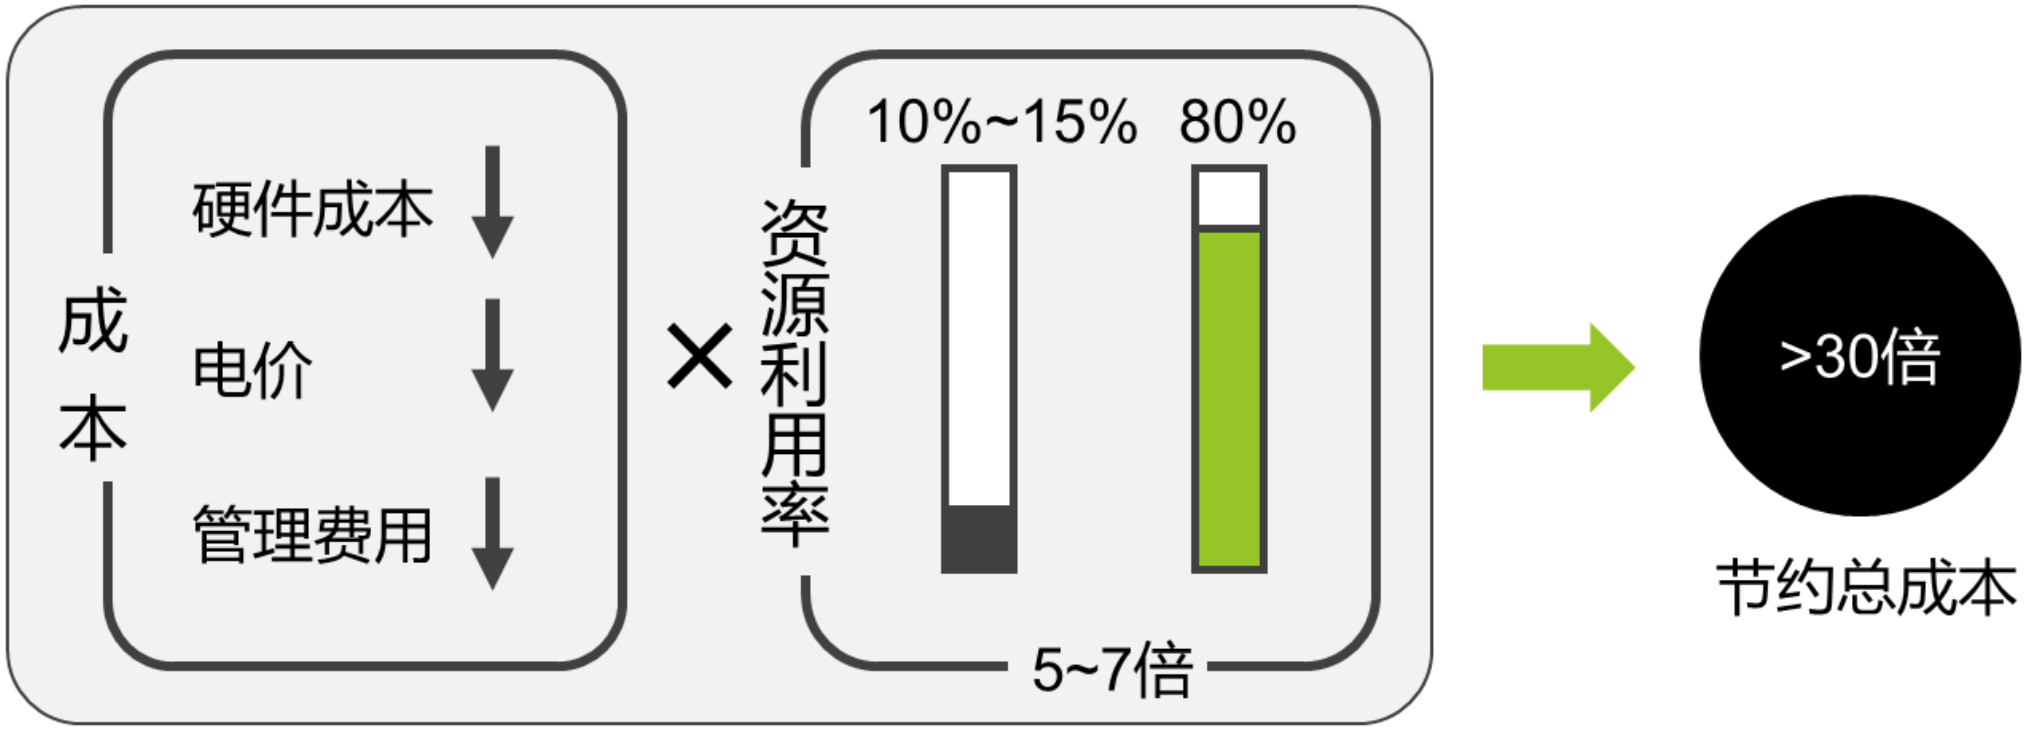
云计算的本质

- 网络访问
  - 能力可通过标准机制在网络上获取，支持异构客户端
- 按量计费
  - 云系统通过在某种抽象级别（如存储、处理、带宽或活动用户帐户）提供计量能力，自动控制和优化资源使用
  - 经济优势： 硬件成本、电价和管理费用全面下降
  - 资源利用率从传统模式的 10%~15% 提升至 80% (5~7倍提升)



云计算的本质

云计算较之传统方式的性价比优势



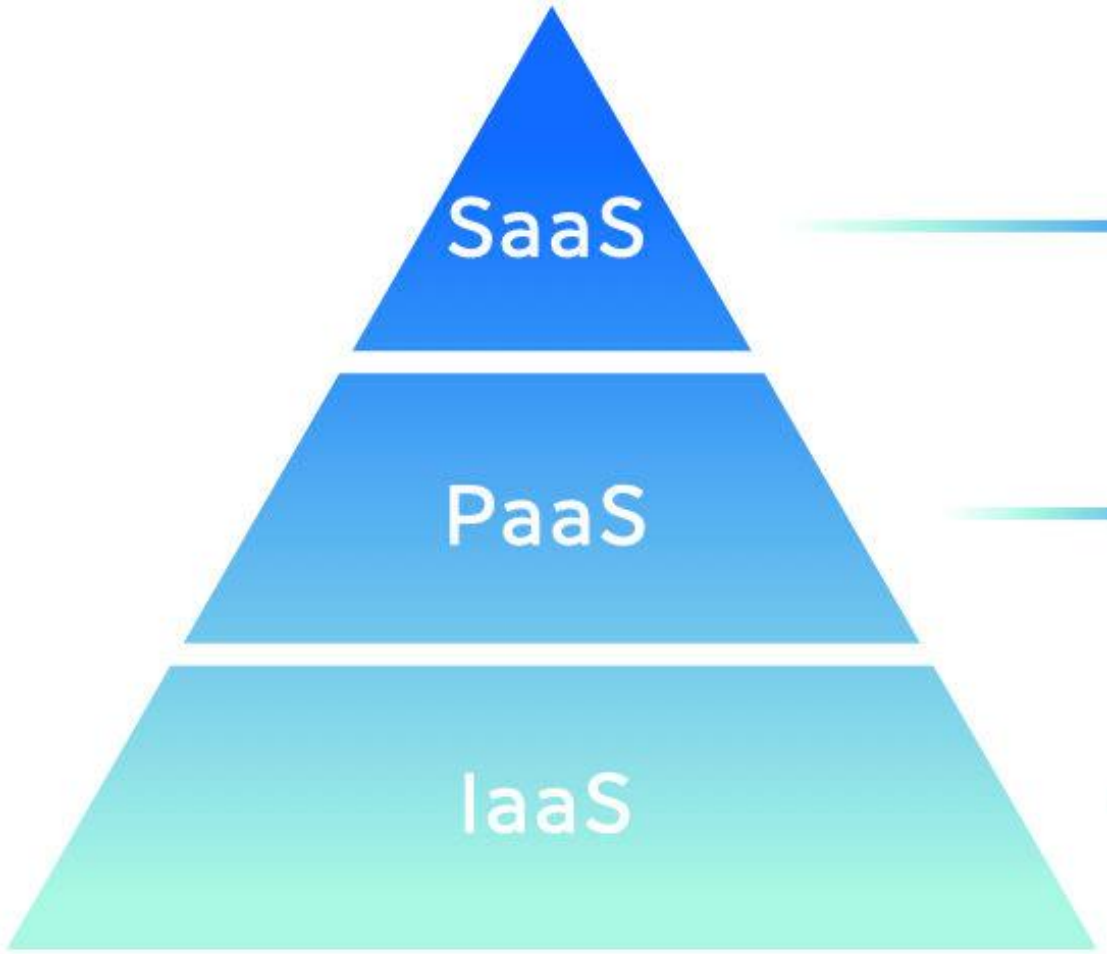
云计算将计算变成了大众用得上和用得起的“水和电”

云计算中心如何选址?

- 超大规模带来管理成本显著下降（单管理员可管理超1000台服务器）
- 最大物理开销：电力和制冷成本
- 选址关键：寻找便宜的电力和自然冷源
  - BAT到贵州山区建立云计算中心

价格	地点	可能的定价原因
3.6美分	爱达荷州	水力发电，没有长途输送
10.0美分	加州	电力在电网上长途输送，湾区的输送线有限，加州不允许煤电
18.0美分	夏威夷	发电的能源需要海运到岛上

云计算的服务模式



软件即服务

各类网盘，百度网盘，B端服务，第三方数据统计服务，办公协同，企业OA，销售CRM等

平台即服务

人脸识别开源系统（孤儿寻找系统），语音识别系统，自动驾驶开源系统等

基础架构即服务

虚拟机，虚拟网络、云存储服务，常见的阿里云，亚马逊云，华为云，微软云，中国电信

云计算的服务模式

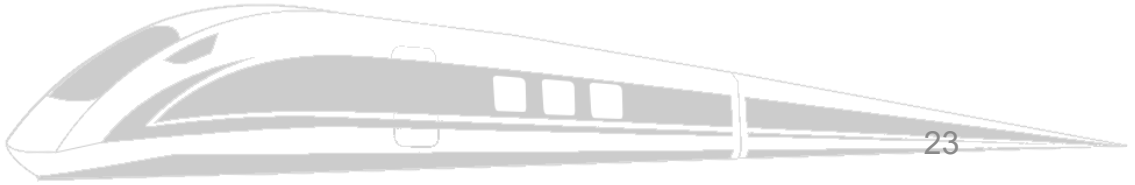
- Local Deployment：自己盖房子
  在本地运行应用，拥有从硬件到应用以及扩缩的所有资源
- IaaS：聘请工人盖房子
  租用运行应用的硬件，但需负责管理操作系统、运行时、扩缩和所有数据
- PaaS：租房自带水电气与家具
  自带代码并部署，但将服务器管理和纵向扩容交给云服务提供商
- SaaS：拎包入住-日常维护
  支付费用以使用特定用途的完整应用，仅需负责自己的数据

让我们以房屋的例子类比！



基础设施即服务（IaaS）

- IaaS： 将多台服务器组成的“云端”服务（内存、I/O、存储、计算能力）作为计量服务提供。
- 优势
  - 消除前期购买硬件设备的资金投入
  - 更好的灾难恢复
  - 专注于开发核心业务
- 典型产品：
  - Amazon EC2 (提供可调整大小的计算容量)
  - Amazon S3 (对象存储)

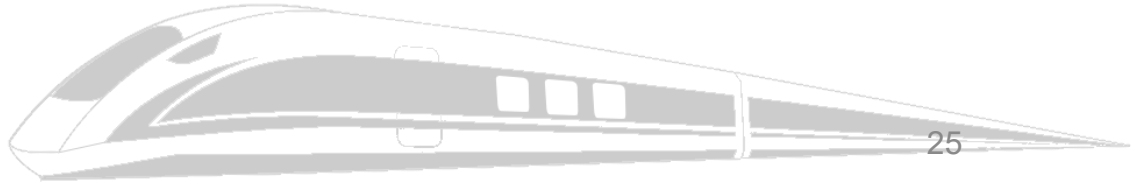


IaaS: Amazon EC2



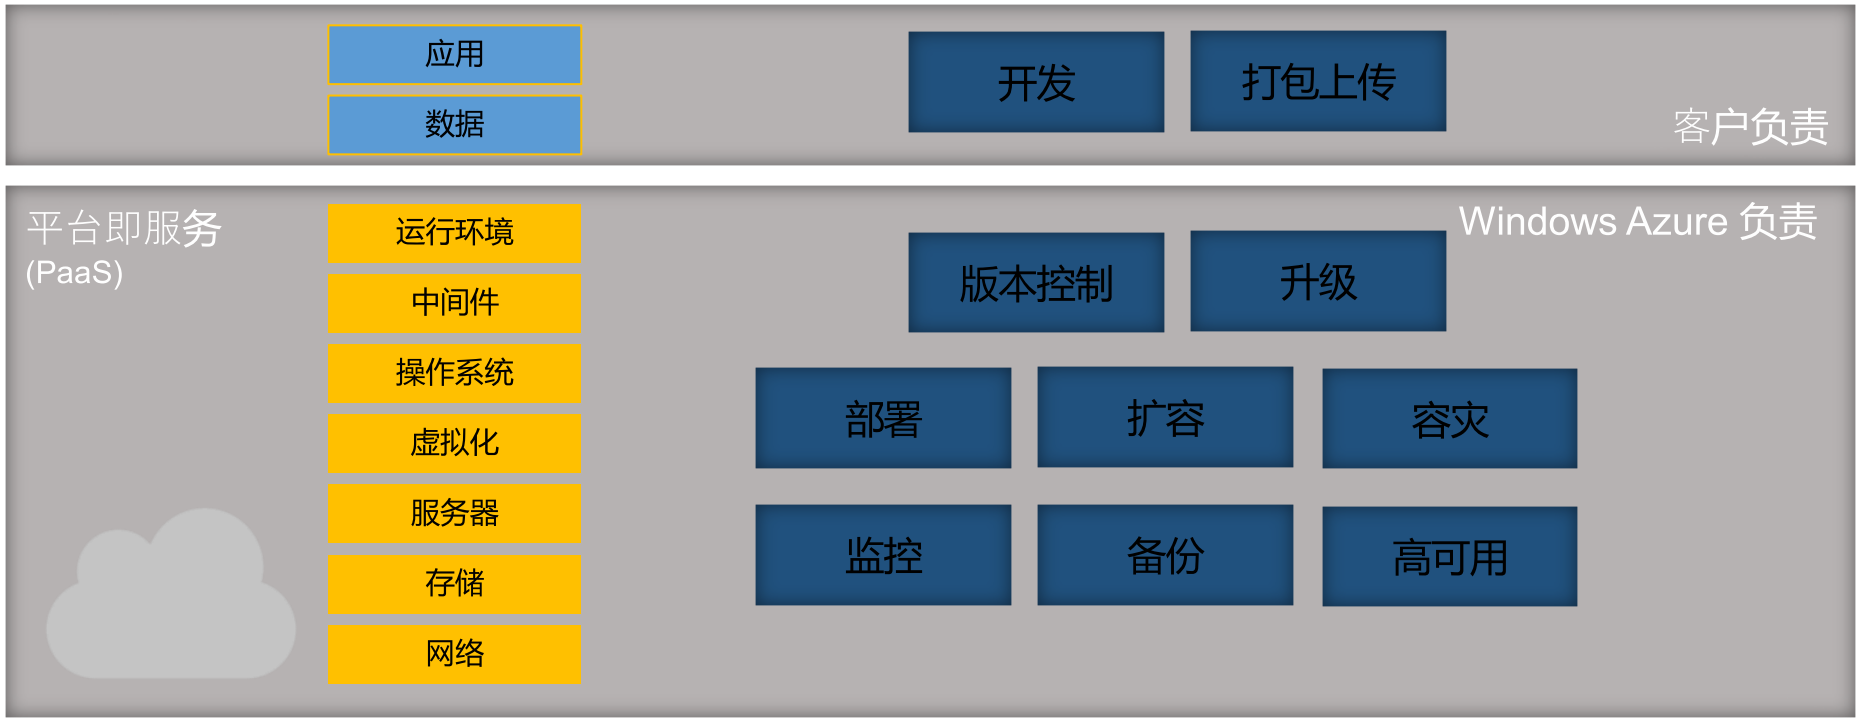
平台即服务（PaaS）

- PaaS：将服务器平台或者开发环境作为服务进行提供
- 优势
  - 减少OS、数据库、运行环境配置的开销
  - 只需要管理最上层的应用和数据
- 典型产品：
  - Google App Engine
  - Microsoft Azure



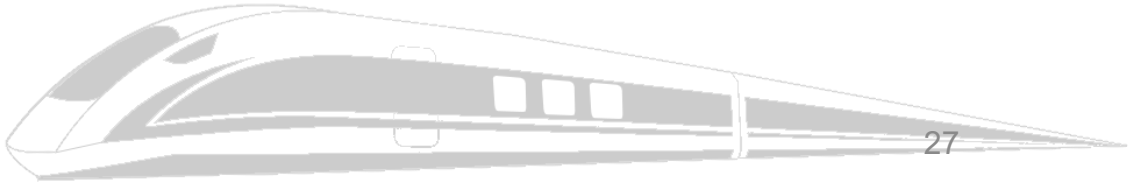
PaaS: Microsoft Azure

Windows Azure实现应用的快速开发和部署，简化管理



软件即服务（SaaS）

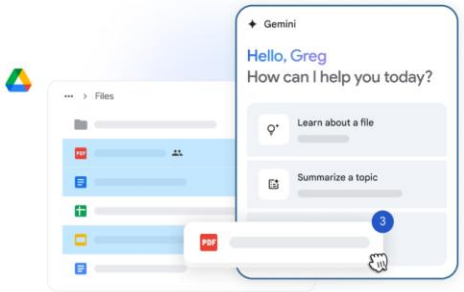
- SaaS：通过Internet提供软件的模式，用户无需下载软件客户端，而是向提供商租用基于Web的软件
- 优势：
  - 可以使用先进的应用程序
  - 只为自己使用的东西付费
  - 免客户端软件使用
  - 轻松增强员工移动性
  - 从任何位置访问应用数据
- 典型产品：
  - 文档协同、在线会议、企业OA…



SaaS：共享文档、网络云盘







使用云端硬盘中的 Gemini 做出更明智的决策

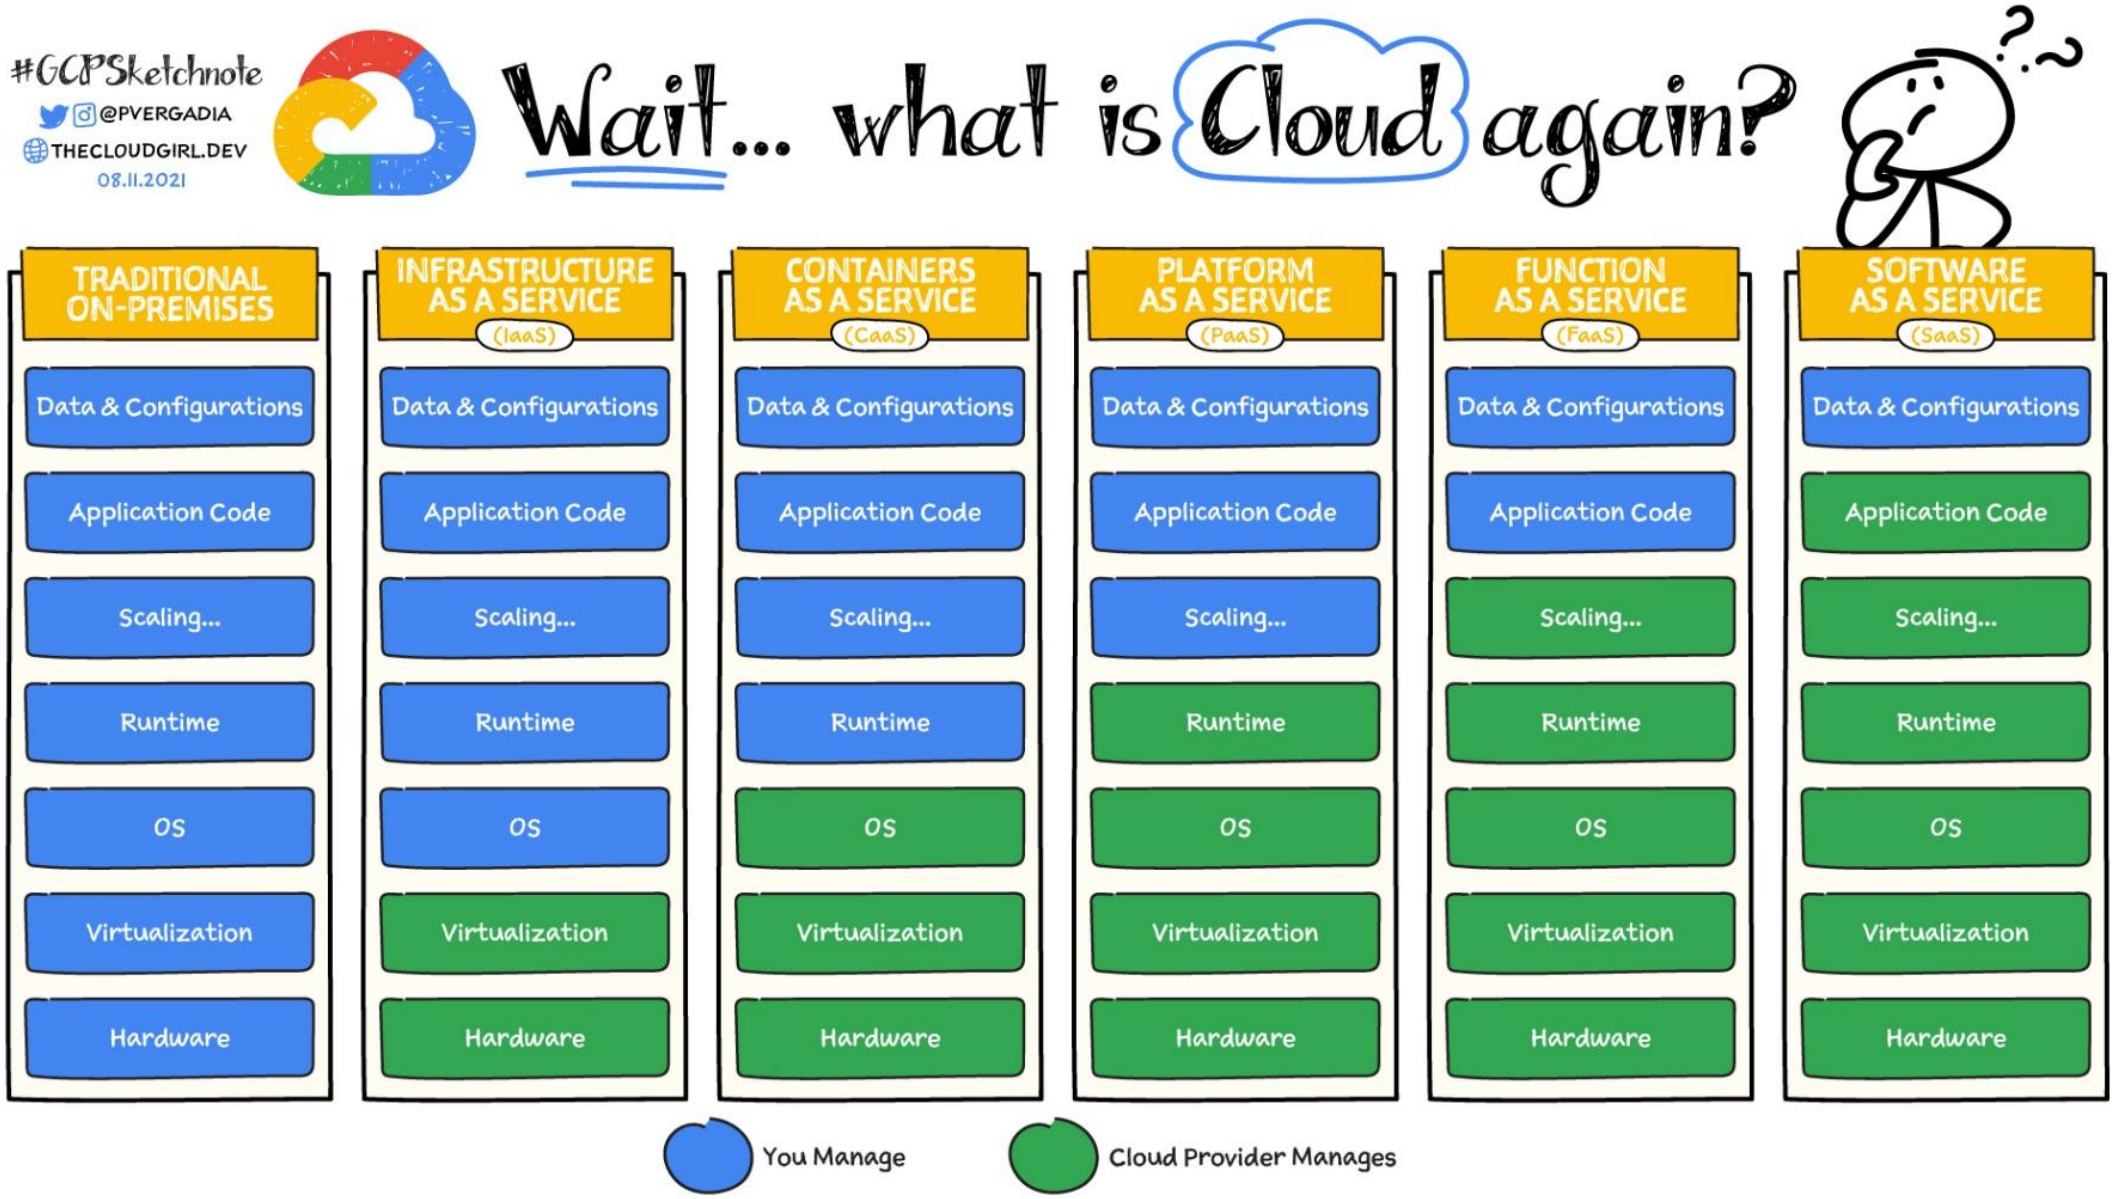
不仅能总结长文档的要点、整合信息，而且无需搜索多个文件就能快速回答与您的内容有关的问题，帮助您获得重要的分析洞见。看看 Gemini 还能帮助您做些什么，快来试试内置 Gemini 的 Google Workspace 吧！

三种云交付模型的比较

云交付模型	服务对象	使用方式	关键技术	用户的控制等级	系统实例
IaaS	需要硬件资源的用户	使用者上传数据、程序代码、环境配置	虚拟化技术、分布式海量数据存储等	使用和配置	Amazon EC2、Eucalyptus等
PaaS	程序开发者	使用者上传数据、程序代码	云平台技术、数据管理技术等	有限的管理	Google App Engine、Microsoft Azure、Hadoop等
SaaS	企业和需要软件应用的用户	使用者上传数据	Web服务技术、互联网应用开发技术等	完全的管理	Google Apps、Salesforce CRM等

注！随着云计算的深化发展，不同云计算解决方案之间相互渗透融合，同一种产品往往横跨两种以上的类型。

新兴服务模式：FaaS和CaaS



云计算的部署模式



部署模式	备注
私有云-Private Cloud	企业利用自有或租用的基础设施资源自建的云
公有云-Public Cloud	出租给公众的大型的基础设施的云
社区云-Community Cloud	为特定社区或行业所构建的共享基础设施的云
混合云-Hybrid cloud	由两种或两种以上部署模式组成的云

CSDN @管理大师小号

云计算的部署模式

部署模式	优点 (Pros)	缺点 (Cons)	典型适用场景
公有云	• 零初始硬件成本 • 极致弹性扩展 • 无需底层运维	• 数据控制权较弱 • 存在隐私与安全顾虑	互联网应用、初创企业、突发流量业务
社区云	• 多方均摊成本 • 满足特定行业的定制化与安全合规标准	• 参与方管理协调成本较高 • 扩展性不及公有云	医疗数据联盟、高校科研算力共享、政务云
私有云	• 最高的安全与隐私 • 满足严苛合规要求 • 底层资源完全可控	• 初始采购成本极高 • 需专门IT团队运维 • 扩展受限于物理硬件	政府机构、大型金融机构、核心机密系统
混合云	• 兼顾安全与弹性 • 优化整体IT成本	• 系统架构最复杂 • 跨云网络互通与数据同步难	核心稳态数据留存本地 + 突发流量溢出至公有云



目录
Contents

1 背景-计算时代的演进

2 云计算的基本概念

3 云计算核心技术栈

4 代码示例与解析

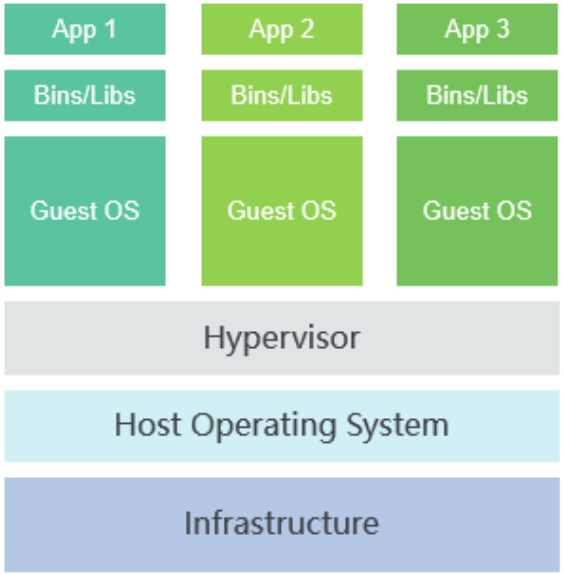
云计算的三大基础设施



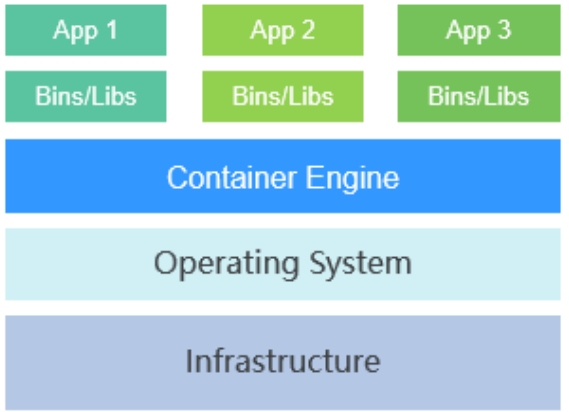
云核心技术栈：计算

云怎么把一台物理机切分给多个用户?

- 虚拟化技术 (Virtualization)
  - 通过 Hypervisor 层，将一台物理机分成多台拥有独立操作系统的虚拟机
  - 隔离性极强，安全性高，但相对笨重（每个VM都要跑完整的OS）
- 容器技术 (Containers - 如 Docker)
  - 多个容器共享同一个宿主机的操作系统内核，只隔离应用及其依赖库
  - 极致轻量、启动达到秒级/毫秒级，现代云原生架构的基石



传统虚拟化

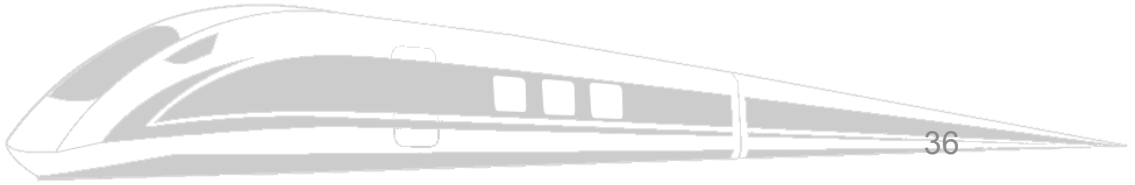


容器化

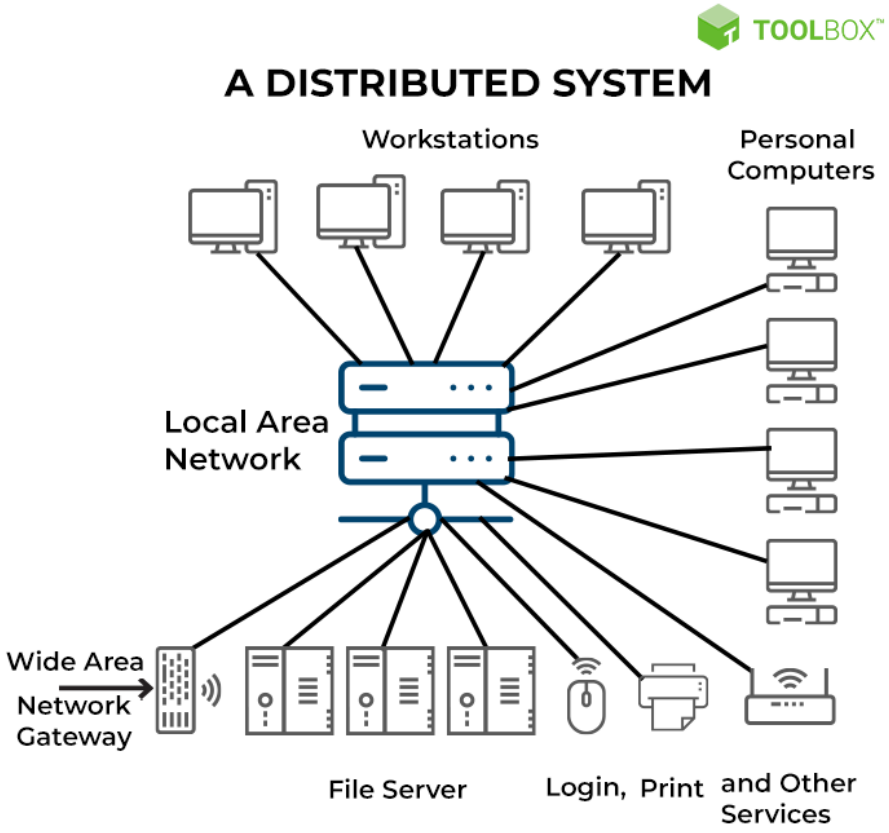
云核心技术栈：存储

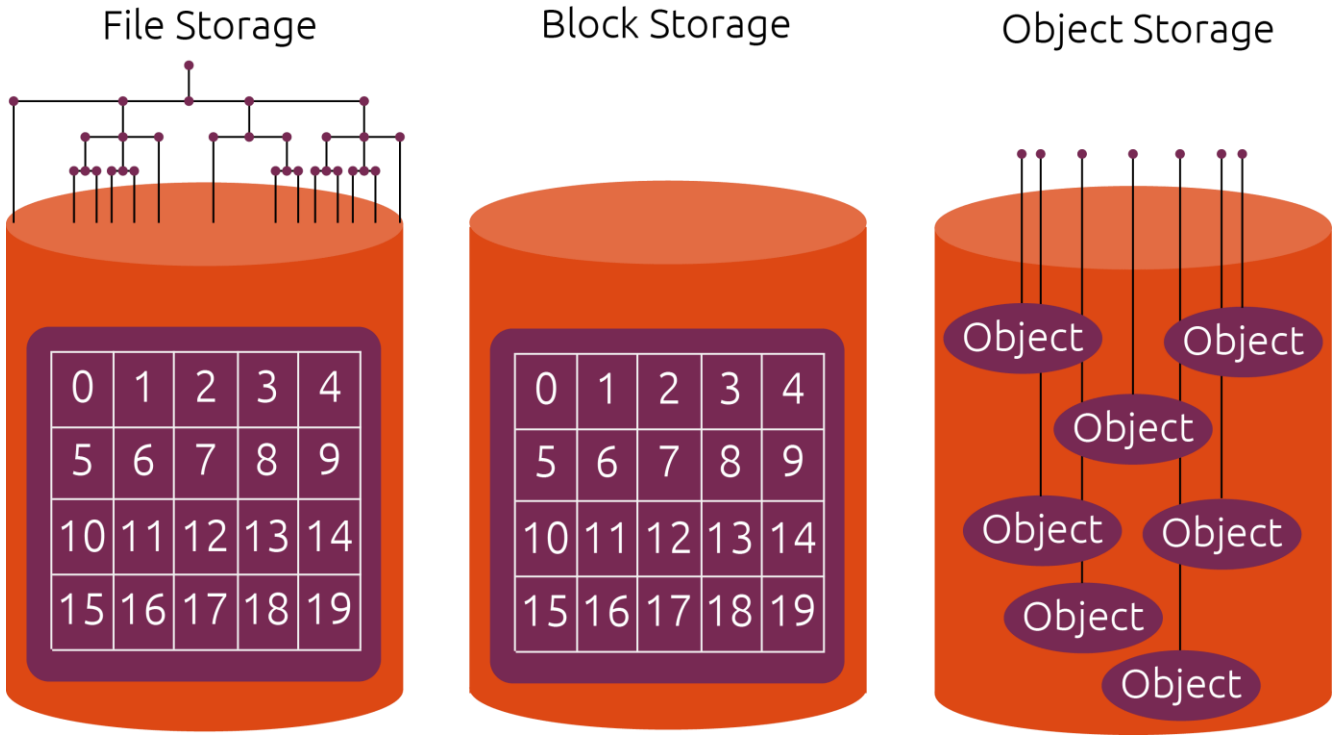
云计算怎么存储庞杂数据?

- 分布式存储 (Distributed Storage)
  - 将海量数据分散存储在多台服务器节点上，通过网络将其组合成一个巨大的逻辑磁盘
  - 极高的吞吐量和容错率（多副本机制）
- 对象存储 (Object Storage)
  - Amazon S3 / 阿里云 OSS
  - 抛弃了传统文件系统的目录树结构，采用扁平化命名空间。数据和元数据打包成一个对象，通过唯一的 URL (API) 进行访问。
  - 容量几乎无限扩展，适合存储非结构化数据（图片、视频、备份文件）



云核心技术栈：存储

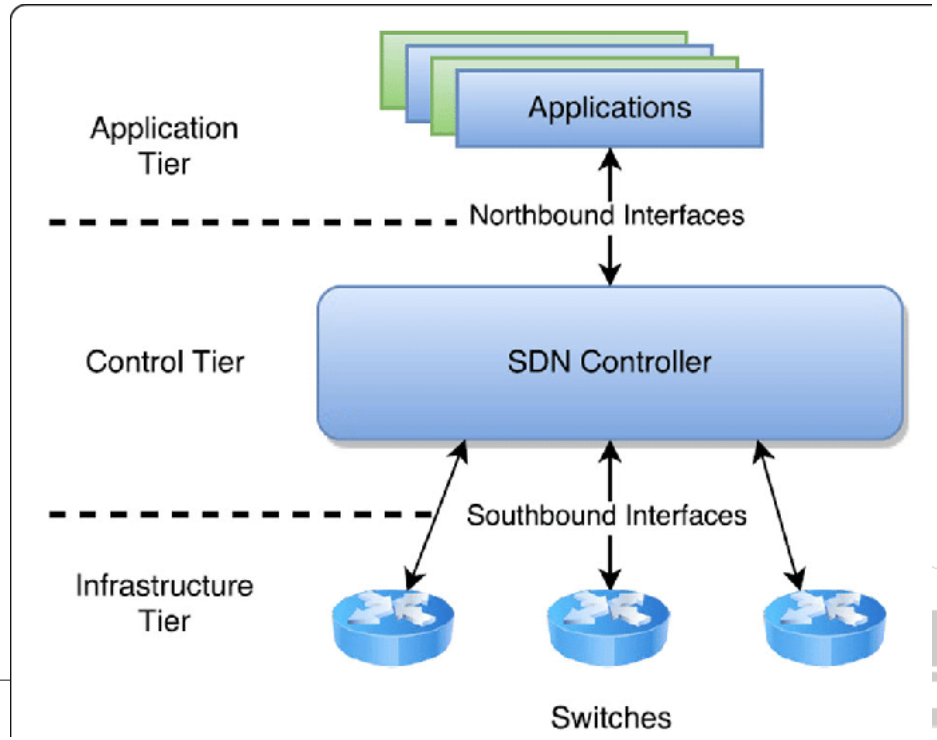

TOOLBOX™
A DISTRIBUTED SYSTEM
Workstations
Personal Computers
Local Area Network
Wide Area Network Gateway
File Server
Login, Print
and Other Services


File Storage
Block Storage
Object Storage
0 1 2 3 4
5 6 7 8 9
10 11 12 13 14
15 16 17 18 19
Object
Object
Object
Object
Object
Object

云计算的基础设施：网络

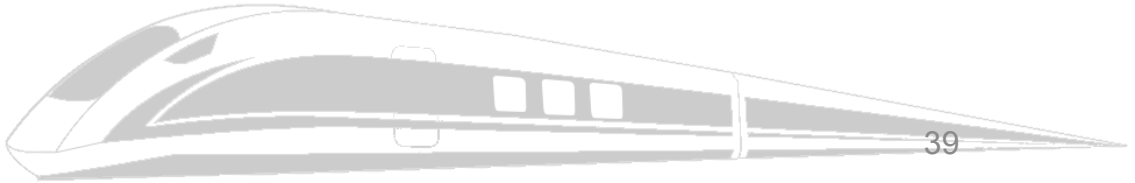
云端海量服务器怎么用网络管理起来?

- 软件定义网络 (SDN - Software-Defined Networking)：
  - 将网络的控制面与数据面分离，通过纯软件编程的方式来动态管理和配置网络资源
- 弹性负载均衡 (Load Balancing)：
  - 面对突发海量并发请求，将外部请求均匀分发到多个计算节点上



发展趋势：云计算与高性能计算（HPC）融合

- 高性能计算(HPC, High-Performance Computing)：
  - 超强算力：利用超级计算机或计算集群来解决极其复杂的计算问题
  - 节点通过低延迟网络连接而成
  - 例如，模拟天气变化，它会把大气层切成无数小方块，每个核心算一个方块
- 为什么云计算和HPC需要融合?
  - 算力需求爆发：AI 大模型（如 ChatGPT）的训练爆发
  - 现代 AI 训练既需要 HPC 级别的超强算力与极低延迟网络，又需要云计算的海量存储、极速弹性和随用随停的商业模式





目录
Contents

1 背景-计算时代的演进

2 云计算的基本概念

3 云计算核心技术栈

4 代码示例与解析

IaaS / PaaS / SaaS 的层级封装与调用

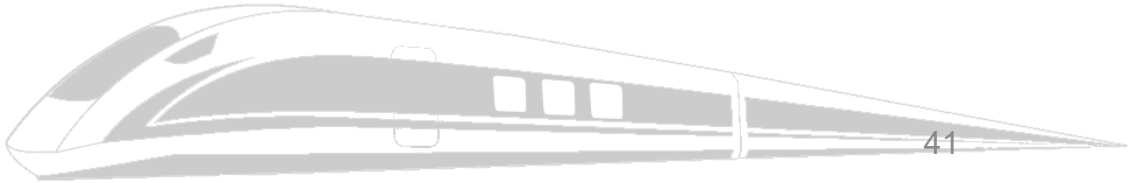
- 面向对象编程

```
# 1. 基础设施提供商构建底层资源
iaas = IaaS(provider_name="AliCloud")

# 2. 平台服务商购买/调用 IaaS，搭建应用平台
paas = PaaS(iaas=iaas)

# 3. 软件开发商基于 PaaS 部署面向最终用户的邮件服务
saas_email = SaaS(paas=paas, service_name="CloudMail")

# 4. 最终用户仅感知业务功能，底层资源调用被完美封装
saas_email.use_service("张三", "send_email")
```

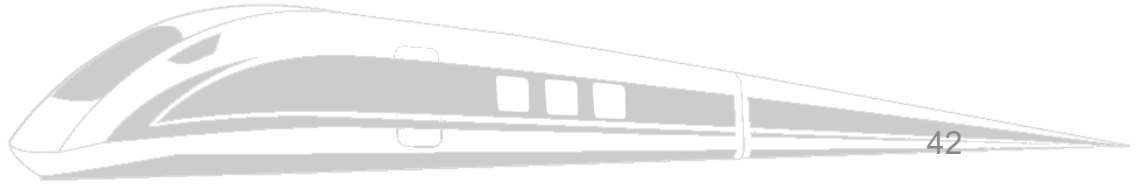


云计算弹性算力优势：串行与并行对比

- 大规模矩阵乘法
  - 串行计算：单进程完成所有计算
  - 并行计算：分配到多进程同时执行
- 矩阵并行乘法的核心思路

矩阵乘法 `C = A x B` 可以按行分块并行计算：

```
A (NxN)          B (NxN)          C (NxN)
+------+         +------+         +------+
| A_1  |         |      |         |C_1=A_1*B|
+------+    x    |  B   |    =    +------+
| A_2  |         |      |         |C_2=A_2*B|
+------+         |      |         +------+
| A_3  |         |      |         |C_3=A_3*B|
+------+         |      |         +------+
| A_4  |         |      |         |C_4=A_4*B|
+------+         +------+         +------+
```



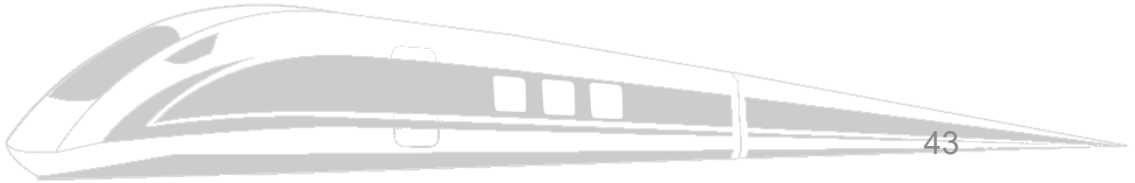
云计算弹性算力优势：串行与并行对比

- matrix_multiply_chunk(args) : 计算一个分块的矩阵乘法（供进程池调用）
- serial_multiply(A, B)` 串行计算整个矩阵乘法
- parallel_multiply(A, B, num_workers): 并行计算，将矩阵按行分块分配给多个进程
- np.vstack(args)：将数据（矩阵块）垂直拼接

```
def parallel_multiply(A, B, num_workers):
    # 1. 将大型矩阵拆解为 num_workers 个独立的子块
    chunks = np.array_split(A, num_workers)

    # 2. 模拟调用云端 API，横向拉起 num_workers 个计算实例
    with multiprocessing.get_context('fork').Pool(processes=num_) as pool:
        # 3. 将任务分发给各个实例并行计算workers
        results = pool.map(matrix_multiply_chunk, [(chunk, B) for chunk in chunks])

    return np.vstack(results)
```



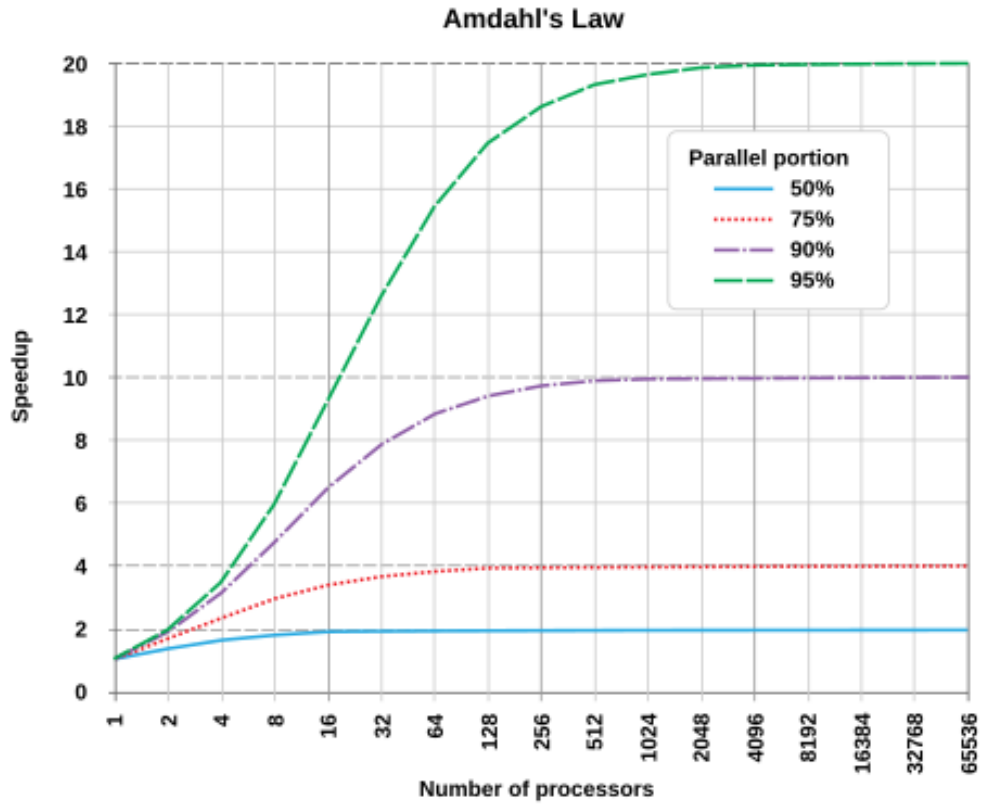
算力弹性的物理极限：阿姆达尔定律

阿姆达尔定律 (Amdahl's Law)
加速比受限于程序中串行部分的比例。即使无限增加处理器数量，加速比也有上限 `S_max = 1 / f`（f 为串行比例）

加速比=优化后的性能/未优化的系统性能

$$\text{Speedup}_{\text{overall}} = \frac{1}{(1 - \text{time}_{\text{optimized}}) + \frac{\text{time}_{\text{optimized}}}{\text{speedup}_{\text{optimized}}}}$$

- $\text{Speedup}_{\text{overall}}$ represents the total speedup of a program
- $\text{Time}_{\text{optimized}}$ represents the proportion of time spent on the portion of the code where improvements are made
- $\text{Speedup}_{\text{optimized}}$ represents the extent of the improvement



课程总结

- 产生背景： 计算模式的演化、大数据时代
- 云计算的概念（NIST）
- 云计算的5个核心特征
  - 按需自服务、弹性扩展、资源池化、网络访问、按量计费
- 云计算的服务模式
  - IaaS 、PaaS 、SaaS
- 云计算的部署模式
  - 公有云、私有云、混合云、社区云
- 云计算核心技术栈
  - 计算、存储、网络

