西南交通大學
Southwest Jiaotong University

《智能交通》大作业二

设计题目： 交通场景多目标精准识别与态势研判

组　　号： 2023112621、2023114337、2023114956

成员姓名： 程泽凯、王晨羽、金井直

班　　级： 计算机 2023 级 04 班

指导教师： 杜圣东　　老师

2026 年 5 月 12 日

摘要

本文围绕 TT100K 交通标志检测任务开展课程设计研究，目标是在复杂道路场景中完成多类别交通标志识别，并进一步支撑交通态势研判。基础实验部分以 YOLO11n 为检测模型，完成 TT100K 标注转换、数据集划分、模型训练、验证和可视化分析。实验结果表明，在相同模型规模下，将输入尺度由 640 提升至 704 并延长训练轮数，可显著改善小目标检测性能；其中 $704/8/0/e50$ 配置取得 Precision 0.7963、Recall 0.6732、mAP50 0.7580 和 mAP50-95 0.5313。针对小目标漏检、相似类别混淆和复杂背景误检等问题，本文进一步比较 Focaler-IoU、Gold-YOLO GD 和 SAHI 三类改进方法。结果显示，Focaler-IoU 在不增加模型参数的情况下使 mAP50-95 提升至 0.5343，SAHI 切片推理能够显著增加远距离交通标志检出数量，而结构改进方法在小规模数据和有限训练轮数下存在收敛不足。高阶部分将交通标志检测结果与交通流量预测模块整合，设计网页端交通态势智能感知分析流程，实现从目标识别、趋势预测到风险研判和预警诱导的闭环展示。

关键词：交通标志检测；TT100K；YOLO11n；Focaler-IoU；SAHI；交通态势研判

目录

一、 团队成员分工 1

二、 任务背景 1

三、 任务描述 1

四、 技术方案 1

4.1 方案总体架构 2

4.2 模块 1 2

4.3 模块 2 2

4.4 模块 3 2

4.5 近三年目标检测算法调研 3

4.6 主流方法对比与本文选型说明 3

4.7 典型论文方法原理分析 4

4.7.1 TT100K 数据集特点分析 4

4.7.2 YOLO 检测框架原理分析 5

4.7.3 YOLO11n 网络结构与计算原理 5

4.7.4 轻量化检测思路分析 6

4.8 实验设计与实现 7

4.9 数据集 7

4.10 评测指标 7

4.11 实现细节 7

4.12 定量实验 8

4.12.1 基线配置对比 8

4.12.2 消融实验 9

4.12.3 指标变化分析 9

4.12.4 检测速度分析 9

4.13 定性实验 10

4.13.1 案例分析 10

4.13.2 结果展示说明 10

4.13.3 失败案例与逐类别错误分析 12

4.14 问题分析与改进方案 14

五、 改进实验与结果分析 14

5.1 Focaler-IoU 损失函数改进 16
5.2 Gold-YOLO GD 结构改进 16
5.3 SAHI 切片推理改进 18
六、 交通态势智能感知分析解决方案 23
6.1 系统总体流程 23
6.2 网页端实现与功能设计 24
6.3 前后端调用流程 24
6.4 高阶要求完成情况分析 24
七、 总结 25
参考文献 27

一、 团队成员分工

- 金井直：负责文献检索、相关工作梳理、任务背景与任务描述撰写。
- 程泽凯：负责数据处理、模型训练、实验设计与结果整理。
- 王晨羽：负责方法分析、报告总结与 LaTeX 排版整合。

二、 任务背景

交通标志检测是智能交通与自动驾驶感知中的基础任务，其目标是在复杂道路场景中准确识别并定位交通标志，为驾驶辅助、道路预警和交通管理提供可靠信息。与通用目标检测相比，交通标志检测通常具有目标尺寸小、类别细粒度、背景干扰强、遮挡与光照变化明显等特点，因此更依赖模型的多尺度特征表达能力与小目标检测能力。

TT100K 是面向交通标志识别与检测的公开数据集，包含大量真实道路场景图像，在目标尺度变化、遮挡、远距离成像和复杂背景等方面具有较强代表性。围绕 TT100K 开展课程设计实验，既能够体现目标检测模型在真实交通场景中的适用性，也便于完成从数据整理、模型训练到结果分析的完整工程流程。

三、 任务描述

本课程设计围绕“交通场景多目标精准识别与态势研判”展开。基础部分以 TT100K 交通标志检测为主线，主要包括近三年交通标志检测、小目标检测和 YOLO 系列相关文献调研，TT100K 数据集整理与 YOLO 标注格式转换，以及模型训练、结果对比和误差分析等内容。上述工作共同构成交通标志检测实验的基本流程。

在基础实验之外，本文面向高阶要求进一步整合交通目标识别与交通流量预测两个模块，设计并实现交通态势智能感知分析方案。该方案通过网页端原型组织检测结果、流量预测结果和规则化研判逻辑，展示场景感知、趋势预测、风险研判、预警诱导和结果导出的全过程。

四、 技术方案

本文采用“文献调研 + 数据处理 + YOLO 训练 + 结果分析 + 改进设计”的技术路线。文献调研部分用于梳理近三年目标检测算法的发展趋势，并明确交通标志小目标检测的主要难点；数据处理部分将 TT100K 原始标注整理为 YOLO 所需格式，并完成训练集、验证集和测试集划分；模型实验部分以 YOLO11n 轻量化模型为主要对象，完成训练、验证与预测；结果分析部分结合 Precision、Recall、mAP50、mAP50-95、混淆矩阵和典型失败案例评价检测效果，并提出面向小目标交通标志的改进方向。

4.1 方案总体架构

整体技术方案包括数据准备、模型训练、结果评估和案例分析。数据准备环节负责类别映射、标注转换和样本划分；模型训练环节基于 Ultralytics YOLO 框架完成配置、训练与验证；结果评估环节比较不同输入尺度和训练配置下的检测指标；案例分析环节结合预测图、混淆矩阵和训练曲线，总结模型在真实交通标志场景中的优势与不足。

4.2 模块 1

模块 1 为数据处理与任务分析模块。TT100K 中交通标志种类较多，真实场景中的目标普遍较小、分布密集且易受遮挡，因此训练前需要完成统一的数据清洗、标注转换与类别映射。本文通过脚本将 TT100K 原始标注转换为 YOLO 所需的边界框格式，并按训练集、验证集和测试集完成划分，以保证后续实验流程的规范性和可复现性。

在任务分析层面，本文将交通标志检测归纳为典型的小目标多类别检测任务。该任务不仅要求模型能够完成目标定位，还要求在有限分辨率下保留尽可能多的局部细节，以提高对远距离、遮挡和密集交通标志的识别能力。

4.3 模块 2

模块 2 为模型实现与实验设计模块。实验部分以 YOLO11n 为主要基线模型，在 TT100K 数据集上完成训练和验证。考虑到课程设计强调可实现性和实验闭环，本文优先采用参数量较小、训练效率较高的轻量化模型，并通过调整输入尺度、训练轮数和训练策略，分析其对交通标志检测性能的影响。

改进设计主要围绕三类思路展开：一是通过调整输入分辨率等设置增强小目标特征保留能力；二是通过损失函数和网络结构改进提升模型在 TT100K 场景下的稳定性和检测效果；三是在推理阶段引入切片推理策略，提高远距离小目标的检出能力。最终以定量指标和可视化结果作为主要依据，对不同配置进行对比分析。

4.4 模块 3

模块 3 为交通态势智能感知分析模块。该模块面向高阶要求，将交通目标识别结果与交通流量预测结果进行整合，形成面向管理决策的态势研判流程。网页端原型提供场景输入、工作流选择、分析结果展示、报表导出、语音播报和后台任务状态展示等功能，后端接口返回结构化检测摘要、预测摘要和决策建议。通过该模块，实验指标进一步转化为面向交通管理的辅助信息。

4.5 近三年目标检测算法调研

近三年目标检测方法主要沿实时单阶段检测、多尺度小目标检测和 Transformer-based 检测三条路线发展。YOLO 系列仍是工程应用中最常用的实时检测框架之一。YOLOv8 延续 anchor-free 检测头和工程化训练流程，在精度、速度和易用性之间取得较好平衡 [10]；YOLOv9 通过 Programmable Gradient Information 与 GELAN 缓解深层网络中的信息丢失与梯度传递问题 [14]；YOLOv10 通过一致双分配实现 NMS-free 训练和推理，进一步降低实时检测后处理延迟 [12]。Ultralytics YOLO11 延续实时检测主线，强调特征提取效率、多任务扩展和工程部署便利性 [11]。这类方法的共同特点是训练和部署链路成熟，适合在课程实验条件下完成数据转换、训练、验证和网页端接入。

小目标检测研究更关注尺度变化和细粒度特征保留。FPN 通过自顶向下的特征金字塔将深层语义与浅层空间细节结合，为多尺度目标检测提供了基础结构 [5]；SNIP 和 SNIPER 则从图像尺度归一化与高效裁剪训练角度改善小目标和大目标在同一输入尺度下的训练冲突 [7, 8]。这些方法虽然提出时间早于近三年，但仍是理解交通标志小目标检测的重要基础。TT100K 中远距离标志占比较高，许多目标在缩放到网络输入尺寸后仅保留少量像素，因此输入尺度、浅层特征、切片推理和类别重采样都会显著影响最终检出率。

Transformer-based 检测器以 DETR 为代表，利用查询向量和集合预测减少手工设计的后处理步骤 [2]。Deformable DETR 通过可变形注意力改善原始 DETR 收敛慢和多尺度目标适应不足的问题 [18]；DINO 进一步通过去噪训练和查询设计提升检测稳定性 [15]。RT-DETR 在 2023 年将 DETR 推向实时检测场景，通过高效混合编码器和 IoU-aware 查询选择改善传统 DETR 的实时性问题 [17]。这一路线在端到端检测方面具有优势，但训练成本、模型规模和部署复杂度通常高于轻量 YOLO 模型，课程实验中更适合作为方法调研和后续扩展方向。

交通标志检测属于典型的小目标细粒度检测任务。近年的相关研究主要关注三个问题：提高输入分辨率或增加浅层检测分支，以保留远距离标志的纹理和边缘；引入注意力、多尺度上下文或特征重标定模块，以应对复杂背景、遮挡和天气变化；采用轻量化卷积、剪枝或重参数化结构降低部署成本。STC-YOLO 针对复杂环境下交通标志小目标检测构造增强 TT100K 数据并改进小目标特征表达 [3]，YOLO-TSF 面向雾天道路场景讨论了小交通标志漏检、误检和低识别率问题 [4]。这些研究表明，仅更换检测器难以完全解决交通标志检测问题，输入尺度、特征融合层级、类别不均衡和场景增强同样会影响检测效果。

4.6 主流方法对比与本文选型说明

表1 从方法层面对主流检测路线进行比较。需要说明的是，本文没有对 YOLOv8、YOLOv9、YOLOv10、RT-DETR 等模型重新完成公平训练和测试，因此不声称本文结果

优于这些方法。该表的作用是说明不同方法与 TT100K 交通标志检测任务之间的关系，并解释本文为何选择 YOLO11n 作为主要实验基线。

表 **1**　主流目标检测方法与本文选型说明

方法类别	核心特点	与 TT100K 任务的关系	本文处理方式
YOLOv8/YOLOv9 YOLOv10	实时单阶段检测，训练和部署链路成熟	适合交通标志实时识别，但不同版本需要单独配置和公平复现	作为文献调研和方法参照，未重新训练对比
YOLO11 YOLO11n	工程接口稳定，轻量版本参数量较低	适合课程算力条件下完成 12 类交通标志训练、验证和网页端接入	作为本文主要基线并完成多组实验
FPN/SNIP SNIPER	强调多尺度特征、尺度归一化和切片训练	为远距离小标志检测提供理论依据	作为小目标分析依据，引出高分辨率输入和 SAHI 推理
DETR/Deformable DETR/DINO RT-DETR	基于查询和注意力机制，端到端检测能力较强	有利于减少手工后处理，但训练成本和部署复杂度较高	作为后续扩展方向，不纳入本轮复现实验
STC-YOLO YOLO-TSF	面向交通标志或复杂道路环境进行小目标改进	与 TT100K、小目标和恶劣天气场景更接近	用于支撑问题分析和改进思路设计

4.7 典型论文方法原理分析

为说明交通标志检测和小目标检测的研究脉络，本文选取 TT100K 数据集、YOLO 检测框架和轻量化检测思路作为主要分析对象。三者分别对应任务基准、检测方法和部署需求，可为后续实验设计提供依据 [19, 6, 9]。

4.7.1 TT100K 数据集特点分析

TT100K 是面向交通标志检测与识别的公开数据集，图像来源于真实道路场景，包含复杂背景、尺度变化、远距离小目标和类别不均衡等问题。由于交通标志在图像中常占比较小，模型需要在较高分辨率特征图上保留足够的空间信息，才能更好地完成定位与分类。

TT100K 的任务设置更接近真实交通环境，而非理想化背景下的标准检测问题。因此，该数据集上的检测结果能够较好反映模型对复杂交通场景的适应能力。

4.7.2 YOLO 检测框架原理分析

YOLO 是单阶段目标检测框架的代表，其核心思想是在一次前向传播中同时完成目标定位和类别预测 [6]。与两阶段检测方法相比，YOLO 结构更紧凑、推理效率更高，更适合课程设计和工程实现中的快速训练与部署需求。

在交通标志检测任务中，YOLO 通过多尺度特征融合和密集预测机制增强小目标检测能力。对于 TT100K 这类类别较多、目标较小的数据集，YOLO 的训练与部署流程较为成熟，适合作为本文的基线框架。设第 s 个检测尺度的特征图大小为 $H_s \times W_s$，每个位置 (i, j) 输出边界框 $\hat{\mathbf{b}}_{sij}$、类别概率 $\hat{\mathbf{p}}_{sij}$ 和置信度 $\hat{o}_{sij}$，则单阶段检测器可表示为：

$$\left\{\hat{\mathbf{b}}_{sij}, \hat{o}_{sij}, \hat{\mathbf{p}}_{sij}\right\} = f_\theta\left(\mathbf{x}; s, i, j\right), \quad s \in \{8, 16, 32\}. \tag{1}$$

其中 s 表示相对输入图像的步长。步长为 8 的浅层输出保留更多空间细节，更有利于远距离交通标志；步长为 16 和 32 的输出具有更强语义信息，适合较大或更清晰的目标。本文使用的 YOLO11n 在训练后的 12 类 TT100K 子集上包含约 2.59M 参数，检测步长为 $\{8, 16, 32\}$，因此能够在较低计算量下覆盖不同尺度目标。

4.7.3 YOLO11n 网络结构与计算原理

YOLO11n 仍然遵循 Backbone–Neck–Head 的三段式结构。Backbone 负责逐级下采样和特征抽取，主要由 Conv、C3k2、SPPF 和 C2PSA 等模块组成；Neck 通过上采样、拼接和再次下采样形成类似 FPN/PAN 的双向特征融合路径；Head 在三个尺度上分别输出边界框分布和类别概率。该结构适合交通标志检测任务：浅层高分辨率特征保留标志边缘与颜色信息，深层语义特征提供类别判别能力，多尺度融合有助于缓解远近目标尺寸差异。

C3k2 模块可以理解为轻量化的跨阶段部分连接结构。输入特征 $\mathbf{X}$ 经 1×1 卷积分成两支，一支保留短路径，另一支进入若干瓶颈块 $\mathcal{B}(\cdot)$，最后拼接并压缩通道：

$$\mathbf{Y} = \mathrm{Conv}_{1\times1}\left(\mathrm{Concat}\left[\mathbf{X}_1, \mathcal{B}_1(\mathbf{X}_2), \ldots, \mathcal{B}_n(\mathbf{X}_2)\right]\right). \tag{2}$$

这种结构一方面保留梯度直通路径，降低深层训练难度；另一方面避免所有通道都进入复杂卷积分支，从而减少参数量和计算量。SPPF 模块通过连续最大池化扩大感受野，其计算可写为：

$$\mathbf{Y}_{sppf} = \mathrm{Conv}\left(\mathrm{Concat}\left[\mathbf{X}, \mathcal{M}(\mathbf{X}), \mathcal{M}^2(\mathbf{X}), \mathcal{M}^3(\mathbf{X})\right]\right), \tag{3}$$

其中 $\mathcal{M}$ 表示步长为 1 的最大池化。该模块能够在不显著增加计算量的情况下引入更大范围上下文，对区分远处交通标志和背景牌匾有帮助。C2PSA 则引入部分自注意力机制，使高层特征能够在更大空间范围内建立关联，提升复杂背景下的语义选择能力。

Neck 部分的核心是自顶向下和自底向上的特征融合。记 Backbone 输出为 $\mathbf{C}_3, \mathbf{C}_4, \mathbf{C}_5$，则自顶向下路径可概括为：

$$\mathbf{P}_i^{td} = \phi_i \left(\text{Concat} \left[\mathbf{C}_i, \text{Up}(\mathbf{P}_{i+1}^{td}) \right] \right), \tag{4}$$

自底向上路径可概括为：

$$\mathbf{P}_i^{out} = \psi_i \left(\text{Concat} \left[\mathbf{P}_i^{td}, \text{Down}(\mathbf{P}_{i-1}^{out}) \right] \right). \tag{5}$$

其中 ϕ_i 和 ψ_i 通常由卷积和 C3k2 模块构成。对于 TT100K，小目标类别常出现在图像远处，单独依赖深层语义会损失定位细节；PAN 式融合可以把高层语义回传到浅层，同时把浅层定位信息再传递回中高层。

检测头采用分类分支和回归分支解耦的形式。边界框回归使用分布式表示和 DFL 思路，将连续坐标距离表示为离散分布的期望：

$$\hat{d} = \sum_{k=0}^{K} k \cdot \text{softmax}(\mathbf{z})_k. \tag{6}$$

若真实距离 y 位于相邻离散点 y_l 与 y_r 之间，则 DFL 可写为：

$$\mathcal{L}_{DFL} = -(y_r - y) \log p_l - (y - y_l) \log p_r. \tag{7}$$

最终训练损失可概括为：

$$\mathcal{L} = \lambda_{box} \mathcal{L}_{box} + \lambda_{dfl} \mathcal{L}_{DFL} + \lambda_{cls} \mathcal{L}_{cls}. \tag{8}$$

其中 $\mathcal{L}_{box}$ 衡量预测框与真实框的几何重合程度，$\mathcal{L}_{cls}$ 衡量类别预测误差。对交通标志而言，边界框位置误差会显著影响小目标 IoU，因此提高输入分辨率和保留浅层特征对 mAP50-95 的提升尤其明显。

4.7.4 轻量化检测思路分析

交通标志检测的轻量化并不等同于简单压缩参数量。对单阶段检测器而言，主要计算开销来自卷积特征提取和多尺度特征融合。若输入特征尺寸为 $H \times W$，标准卷积核大小为 $k \times k$，输入和输出通道数分别为 C_{in}、C_{out}，则一次卷积的乘加计算量近似为

$$\text{FLOPs}_{conv} \approx HWC_{in}C_{out}k^2. \tag{9}$$

因此，输入分辨率、通道宽度和重复模块数量都会直接影响推理耗时。深度可分离卷积将空间卷积和通道混合拆开，计算量可近似写为

$$\text{FLOPs}_{dw} \approx HWC_{in}k^2 + HWC_{in}C_{out}, \tag{10}$$

相比标准卷积可显著降低计算成本，但过度替换也可能削弱通道间特征交互。

本文选择 YOLO11n 作为主模型，是因为其参数量约 2.59M，能够在有限训练资源下完成多组对比实验；同时，其检测头仍保留步长 $\{8, 16, 32\}$ 的多尺度输出，避免轻量化后完全牺牲小目标检测能力。对 TT100K 而言，轻量化模型的关键取舍不是单纯追求更少参数，而是在输入尺度、浅层特征保留和训练充分性之间取得平衡。后续实验也验证了这一点：在模型参数规模不变的情况下，提高输入尺度和延长训练轮数带来的收益，明显高于直接堆叠注意力模块或大幅修改网络结构。

4.8 实验设计与实现

实验部分围绕可复现、可对比和可分析三个要求展开。本文先完成数据集整理与配置文件编写，再在统一训练流程下比较不同输入尺度和训练设置的检测效果，并结合定量指标与定性样例分析模型在交通标志检测任务中的表现。

4.9 数据集

本文实验采用 TT100K 数据集，并通过脚本将原始标注转换为 YOLO 所需格式。数据集划分为训练集、验证集和测试集，分别用于模型拟合、参数调整和最终效果评估。针对交通标志尺度较小、类别较多的特点，实验中重点关注不同输入尺度下的检测性能变化。

4.10 评测指标

交通标志检测任务常用的定量指标包括 Precision、Recall、mAP50 和 mAP50-95。其中，Precision 用于衡量预测框的准确性，Recall 用于衡量真实目标的检出率，mAP50 和 mAP50-95 则用于综合评价不同 IoU 阈值下的检测性能。除定量指标外，本文还结合预测可视化结果分析模型在小目标、遮挡和复杂背景下的表现。

4.11 实现细节

本文基于 Ultralytics YOLO 框架完成训练、验证与推理流程。当前实验以 YOLO11n 为主要对象，在单卡 GPU 环境下完成训练，并通过统一的数据路径、模型权重、输入尺度和训练超参数实现规范化管理。数据处理阶段使用 `prepare_tt100k.py` 将 TT100K 原始标注转换为 YOLO 格式，再通过 `split_tt100k.py` 完成训练集、验证集和测试集划分；实验配置通过 YAML 文件管理，保证类别映射、数据路径和训练参数在不同实验之间保持一致。考虑到交通标志检测属于典型小目标任务，本文重点关注输入尺度调整对检测性能的影响。

在 Focaler-IoU 改进实验中，`train_focaler_iou.py` 通过 patch Ultralytics 框架中的 `BboxLoss.forward` 实现损失函数替换。具体做法是在保持分类损失和 DFL 分布式回归

损失不变的前提下，仅修改边界框 IoU 损失项：先调用 `bbox_iou(..., CIoU=True)` 计算预测框与真实框之间的 CIoU，再根据 Focaler-IoU 的重加权函数计算样本权重，使低重叠样本获得更高的定位梯度。本文实验中采用 $m = 0.7$、$\gamma = 2.0$ 的设置，因此当 IoU 低于 0.7 时权重会随重叠程度下降而增大；当 IoU 已经较高时，权重逐渐回落，避免高质量样本在训练后期占据过大梯度比例。该实现方式不改变 YOLO11n 的网络结构，主要用于观察定位损失调整对小目标边界框质量的影响 [16]。

在 Gold-YOLO GD 结构改进实验中，`train_gold_yolo_gd.py` 生成自定义模型 YAML，并在 YOLO11n 框架中引入 A2C2f、SCDown、C2PSA 等结构组合。A2C2f 用于增强局部特征表达，SCDown 用于控制下采样过程中的信息损失，C2PSA 用于在较高层引入更强的上下文建模。由于该自定义结构与官方 YOLO11n 权重并不完全匹配，实验中无法完整继承预训练参数，训练更接近从头优化。这一点直接影响了 Gold-YOLO GD 的收敛稳定性，也解释了后文中结构改进实验结果低于强基线的现象 [13]。

4.12 定量实验

定量实验的目标是比较不同配置在 TT100K 验证集上的检测表现。实验重点围绕 YOLO11n 在不同输入尺度下的指标变化展开，并对后续训练策略优化保留扩展空间。

4.12.1 基线配置对比

表2 给出了当前已完成的三组正式实验结果。三组实验均采用 YOLO11n 和相同的 12 类 TT100K 子集，主要改变输入尺度和训练轮数，从而观察输入分辨率与训练充分性对交通标志检测性能的影响。

表 **2**　不同检测配置在 **TT100K** 上的定量比较

方法	参数量 / M	Precision	Recall	mAP50	mAP50-95
YOLO11n (640/8/0)	2.59	0.6501	0.5290	0.5905	0.4089
YOLO11n (704/8/0)	2.59	0.6523	0.6049	0.6411	0.4357
YOLO11n (704/8/0/e50)	2.59	0.7963	0.6732	0.7580	0.5313

从表2 可以看出，在模型参数量保持不变的前提下，提高输入尺度能够明显改善 TT100K 场景下的 Recall、mAP50 和 mAP50-95。进一步结合当前已经完成的 $704/8/0/e50$ 实验结果可以发现，随着训练轮数和训练过程的充分展开，模型在 Precision、Recall 和平均精度方面均有进一步提升，说明该配置更适合当前交通标志检测任务。

4.12.2 消融实验

当前消融分析主要围绕输入尺度与训练充分性展开，重点考察输入尺度提升和训练轮数增加对检测结果的影响。该消融并不覆盖所有可能影响检测性能的因素，例如学习率、batch size、Mosaic/MixUp 数据增强强度、低频类别重采样、类别损失权重、SAHI 切片尺寸和重叠比例等。受课程时间和算力限制，本文优先保证主线实验的完整性和可复现性，因此将消融范围控制在最直接影响小目标检测的输入尺度和训练轮数上。后续若继续扩展，应在固定随机种子、数据划分和训练轮数的条件下，对上述超参数进行单因素或正交对比。

表 **3**　关键训练设置的消融结果

实验设置	关键变化	mAP50
YOLO11n (640/8/0)	基线配置	0.5905
YOLO11n (704/8/0)	提高输入尺度	0.6411
YOLO11n (704/8/0/e50)	更充分训练	0.7580

从消融结果可以看出，交通标志检测对输入尺度和训练充分性都较为敏感。对于 TT100K 中大量远距离、小尺寸标志而言，更高输入尺度有助于保留局部细节；在此基础上继续完成更充分训练，则进一步提升了整体检测精度。

4.12.3 指标变化分析

从 640 输入尺度提升到 704 输入尺度后，mAP50 从 0.5905 提升到 0.6411，绝对提升 0.0506；Recall 从 0.5290 提升到 0.6049，绝对提升 0.0759。这说明输入尺度提升主要改善了检出率，即更多远距离小标志被模型识别出来。继续在 704 输入尺度下训练 50 轮后，mAP50 提升到 0.7580，mAP50-95 提升到 0.5313，Precision 也提升到 0.7963，说明模型不仅检出更多目标，而且定位质量和类别置信度更加稳定。由于模型参数量保持不变，性能提升主要来自输入细节保留和训练收敛充分性，而不是模型规模增加。

4.12.4 检测速度分析

除检测精度外，推理速度也是交通场景应用中的重要指标。表4 给出了当前实验记录中的近似推理耗时及其换算 FPS。其中，普通 YOLO11n 和 Gold-YOLO GD 的耗时来自工程运行记录，主要用于反映量级差异，不作为严格 benchmark；SAHI 的耗时来自切片推理统计结果。

表 **4**　不同推理策略的速度比较

方法	平均耗时 / s • 图 $^{-1}$	约合 FPS	说明
YOLO11n (704/50 轮)	0.050	20.00	普通单图推理，工程近似记录
Gold-YOLO GD	0.080	12.50	自定义结构推理，工程近似记录
Baseline+SAHI	0.421	2.38	切片推理统计结果
Focaler-IoU+SAHI	0.432	2.31	切片推理统计结果

从速度结果可以看出，普通 YOLO11n 仍然具有明显的实时性优势，适合作为网页端演示和后续部署的主模型。Gold-YOLO GD 因结构更复杂，单图推理耗时高于 YOLO11n；SAHI 的速度代价更为明显，主要来自一张图像被拆分为多个重叠切片后需要多次前向推理，并在最后执行跨切片 NMS 合并。因此，SAHI 更适合用于离线分析、重点路段复核或对小目标召回要求更高的场景；若用于实时视频流，需要进一步限制切片数量、降低输入分辨率或结合目标区域先验减少无效推理。

4.13 定性实验

定性实验主要通过预测样例、混淆矩阵和训练曲线展示模型在交通标志定位与识别方面的实际表现。与纯数值指标相比，定性结果更能反映模型在真实交通场景中的应用效果。

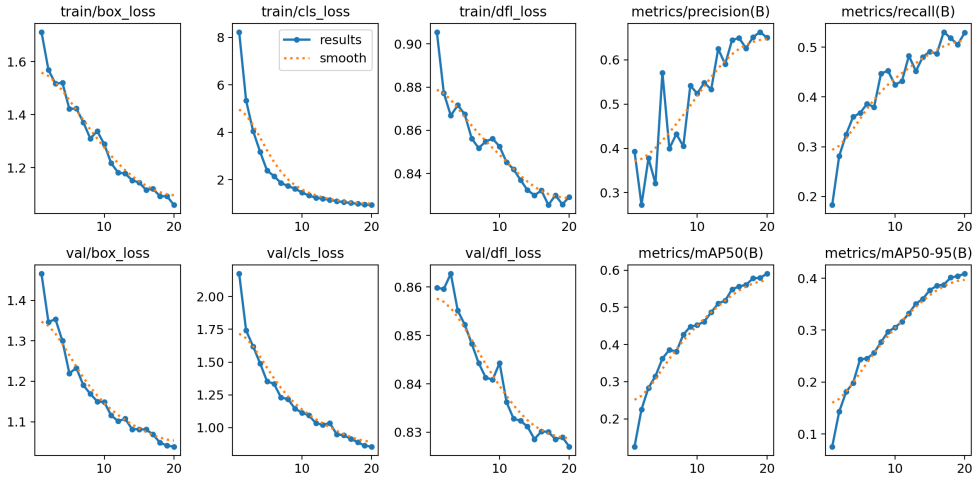
4.13.1 案例分析

从预测样例可以看出，当前模型能够在多数场景中较为准确地检测限速、禁停、禁鸣和直行等交通标志；对于远距离小目标、遮挡目标和背景复杂区域，仍存在漏检、误检和定位不稳定的问题。这说明当前模型已具备一定应用基础，但复杂场景鲁棒性仍有优化空间。

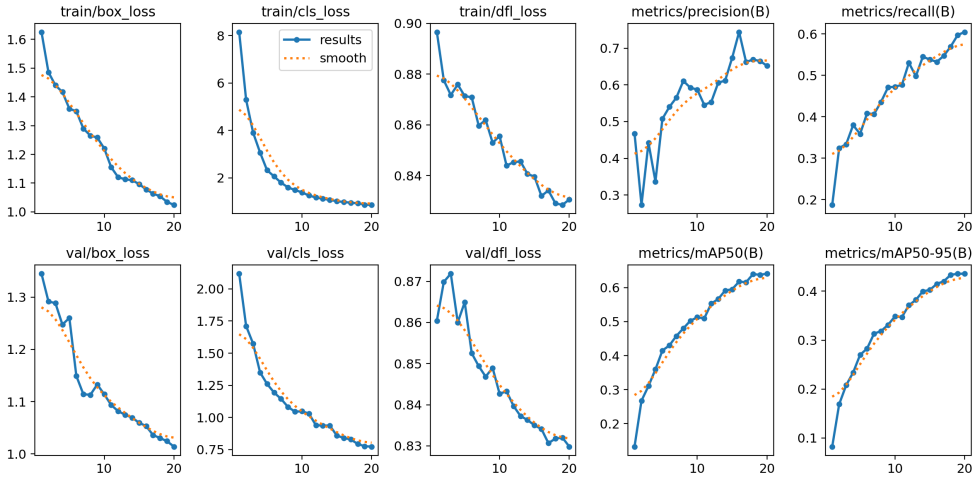
4.13.2 结果展示说明

为了增强结果解释性，本文保留了训练曲线、归一化混淆矩阵和验证集预测图三类可视化结果。训练曲线用于观察指标收敛趋势，混淆矩阵用于分析类别间误判情况，预测图用于直观展示模型在真实交通场景中的目标识别能力。

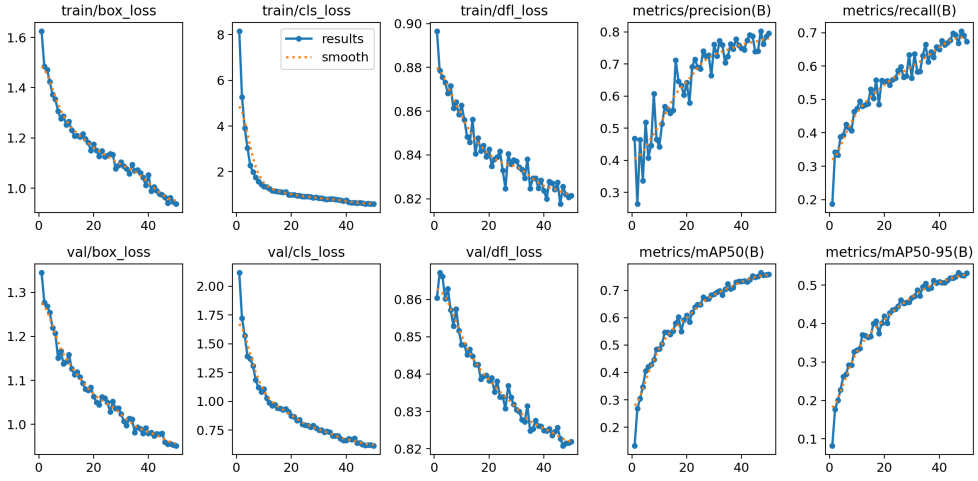
图1 展示了训练过程中主要指标的变化趋势，704/50 轮配置在训练后期仍有稳定收益；图2 反映了部分类别之间的混淆情况，说明相近外观交通标志的区分仍有难度；图3 展示了模型在真实道路图像中的交通标志检测效果。整体来看，当前实验能够支撑“交通标志检测/目标识别”这一课程设计主线。



(a) 640/20 轮

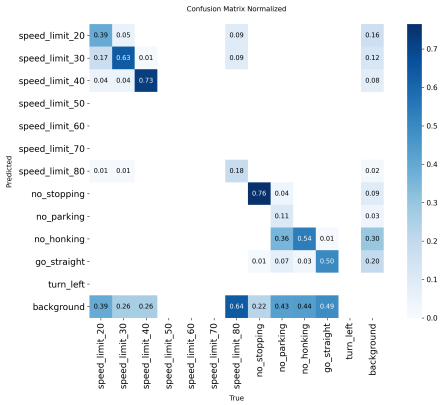


(b) 704/20 轮

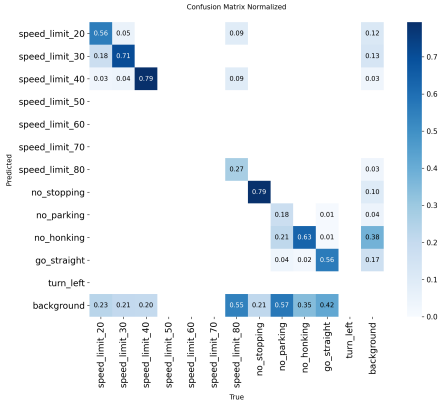


(c) 704/50 轮

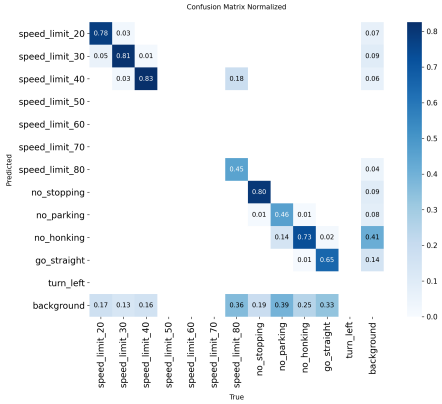
图 **1**　三组 **YOLO11n** 实验的训练曲线对比



(a) 640/20 轮



(b) 704/20 轮



(c) 704/50 轮

图 **2**　三组 **YOLO11n** 实验的归一化混淆矩阵对比

4.13.3 失败案例与逐类别错误分析

为进一步分析模型缺陷，本文选取 704/50 轮最优配置的验证集标签图和预测图进行对比，如图4 所示。该组样例中，模型对 `speed_limit_40`、`no_honking`、`no_stopping` 等类别检测较稳定，但仍出现三类典型问题：第一，远距离小目标被预测为背景，例如部分 `go_straight` 标志在标签图中存在，但预测图中未检出；第二，相邻或重叠标志容



(a) 640/20 轮　　**(b) 704/20** 轮　　**(c) 704/50** 轮

图 **3**　三组 **YOLO11n** 实验的验证集预测样例对比

易导致类别遗漏，例如同一区域同时存在禁鸣、直行和限速标志时，模型更容易保留置信度较高的禁鸣或限速标志；第三，背景广告牌、杆件或路侧标识可能产生低置信度误检，体现为背景列中出现较多 `no_honking` 等预测。



(a) 验证集真实标注　　**(b)** 模型预测结果

图 **4**　**704/50** 轮配置下的典型成功与失败案例对比

结合归一化混淆矩阵可以进一步得到逐类别结论。限速类中，`speed_limit_20`、`speed_limit_30` 和 `speed_limit_40` 的对角线识别比例分别约为 0.78、0.81 和 0.83，说明常见限速标志已有较好识别效果；但 `speed_limit_80` 的对角线比例约为 0.45，且有较高比例被判为背景。该类别性能偏低的原因可能包括三点：其一，限速 80 在当前 12 类子集中出现频率低于常见限速标志，模型获得的类别先验较弱；其二，限速标志的判别信息主要集中在圆形标志内部数字区域，远距离成像或缩放后“80”的细节容易模糊；其三，小目标定位框略有偏移就会显著降低 IoU，进而使检测结果在置信度阈值附近被

过滤。

禁令类中，no_stopping 识别比例约为 0.80，明显优于 no_parking 的约 0.46。二者均包含红色圆环、蓝色底色和斜线结构，外观差异主要体现在内部线条组合上；当目标较小、存在遮挡或图像压缩较强时，模型容易学习到“红蓝圆形禁令牌”这一粗粒度模式，而难以稳定区分内部符号。指示类中，go_straight 识别比例约为 0.65，但仍有约三分之一样本被判为背景。该类标志通常为蓝色指示牌，容易出现在道路边缘、车道上方或远距离位置，关键语义来自箭头形状；当箭头细节在下采样后丢失时，模型更可能将其视为背景纹理或普通蓝色路牌。

上述错误说明，低性能类别并非单纯由模型容量不足导致，而是样本数量、目标尺度、外观相似性、背景干扰和类别先验共同作用的结果。后续改进应优先针对低召回类别增加样本或进行类别重采样，使用复制粘贴、小目标局部裁剪和高分辨率训练增强远距离标志的可见性；在损失函数层面，可结合类别权重或 focal 类损失缓解低频类别梯度不足；在部署阶段，可适当降低低频类别阈值，并结合道路区域约束和视频连续帧一致性过滤背景误检。

4.14 问题分析与改进方案

综合定量指标、训练曲线和失败案例，当前模型的主要问题可以归纳为三类。小目标漏检仍然是主要误差来源，尤其集中在远距离、边缘位置和被杆件遮挡的标志上；外观相近类别之间存在混淆，例如不同限速数字之间、禁停与禁泊之间的误判；复杂背景区域还会产生低置信度误检，说明模型对交通标志结构和道路上下文的利用仍不充分。

针对上述问题，后续改进应优先提高模型对小目标的适应能力。在不显著增加模型规模的前提下，可以保留 704 或更高输入尺度，并增加复制粘贴、随机缩放和局部裁剪等小目标增强策略；也可以在 Neck 中加入更明确的浅层特征融合分支，使步长 8 的检测层获得更强语义信息，从而改善远距离交通标志召回。对于 no_parking、speed_limit_80 和 go_straight 等低识别类别，可采用类别重采样或损失加权缓解类别不均衡。部署阶段还可以结合交通场景先验进行后处理，例如利用标志尺寸范围、道路区域位置和连续帧一致性过滤明显背景误检。

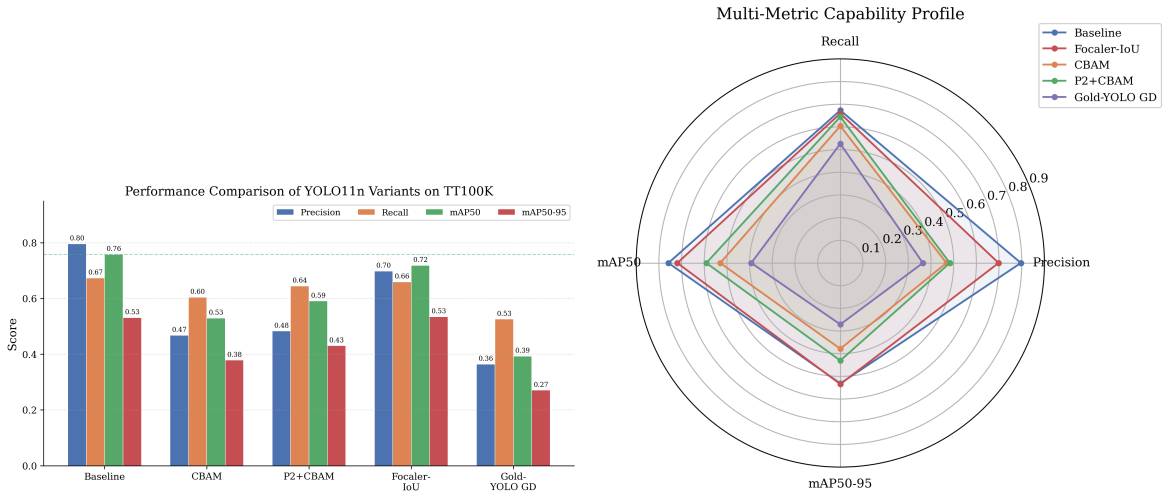
五、 改进实验与结果分析

在强基线实验基础上，本文从损失函数、网络结构和推理策略三个层面开展改进实验。Focaler-IoU 用于调整边界框回归损失的样本权重，Gold-YOLO GD 用于增强跨尺度特征交互，SAHI 用于提高推理阶段小目标的有效分辨率。三类方法分别作用于训练目标、特征表达和输入切片，便于分析不同改进路径在 TT100K 小目标交通标志检测中的收益与代价。

表 **5**　改进实验结果对比

方法	类型	Precision	Recall	mAP50	mAP50-95
YOLO11n (704/50 轮)	强基线	0.7963	0.6732	0.7580	0.5313
YOLO11n + CBAM	结构改进	0.4681	0.6042	0.5294	0.3785
YOLO11n + P2 + CBAM	结构改进	0.4830	0.6444	0.5908	0.4303
YOLO11n + Focaler-IoU	损失函数	0.6979	0.6594	0.7187	0.5343
Gold-YOLO GD	结构改进	0.3641	0.5258	0.3927	0.2709

从表5 可以看出，强基线仍然取得最高的 Precision、Recall 和 mAP50。CBAM 与 P2+CBAM 均未超过强基线，但二者之间存在差异：P2+CBAM 的 Recall 从 0.6042 提升到 0.6444，mAP50 从 0.5294 提升到 0.5908，说明新增 P2 小目标检测头对远距离交通标志的召回具有一定帮助。其总体指标仍低于强基线，主要原因在于新增模块缺少对应预训练权重，且 TT100K 子集规模有限，50 轮训练不足以使注意力模块和新增检测头充分收敛。由于 CBAM 和 P2+CBAM 是结构探索实验，后续重点围绕三组主要改进方法展开分析。



(a) 综合指标柱状对比　　**(b)** 综合能力雷达图

图 **5**　不同改进方法的综合性能对比

图5 展示了不同改进方法在多项指标上的差异。强基线在综合精度上仍然最优，Focaler-IoU 在定位质量指标上更具优势，P2+CBAM 相比单独 CBAM 有所恢复，但仍未达到强基线水平。该结果表明，在小数据集交通标志检测任务中，输入尺度、训练轮数、预训练权重匹配和数据增强通常比直接增加结构复杂度更重要。

5.1 Focaler-IoU 损失函数改进

Focaler-IoU 的改动对象是边界框回归损失。YOLO 系列常用的 CIoU 损失同时考虑重叠面积、中心点距离和宽高比一致性，可写为

$$\mathcal{L}_{CIoU} = 1 - IoU + \frac{\rho^2(\mathbf{b}, \mathbf{b}^{gt})}{c^2} + \alpha v, \tag{11}$$

其中 $\rho(\cdot)$ 表示预测框与真实框中心点距离，c 为最小外接框对角线长度，v 衡量宽高比差异，α 为平衡系数。CIoU 对所有样本使用相同形式的损失，未显式区分低 IoU 的困难样本和高 IoU 的易样本。TT100K 中远距离交通标志占比较高，轻微定位偏差就会造成 IoU 明显下降，因此有必要在损失层面对困难定位样本赋予更高权重。

Focaler-IoU 在 CIoU 外乘一个由当前 IoU 决定的焦点权重：

$$\mathcal{L}_{Focaler-IoU} = w_{focaler}\mathcal{L}_{CIoU},$$

$$w_{focaler} = \left(\frac{1 - IoU}{1 - m + \epsilon}\right)^{\gamma}.$$

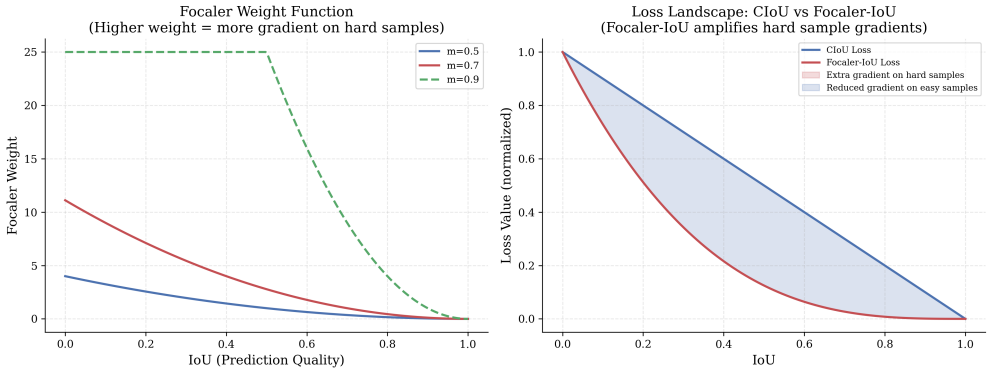
其中 m 为焦点阈值，γ 控制权重变化幅度，ϵ 用于避免分母为零。本文采用 $m = 0.7$、$\gamma = 2.0$。当 $IoU < m$ 时，$1 - IoU > 1 - m$，因此 $w_{focaler} > 1$，困难样本的回归梯度被放大；当 $IoU > m$ 时，$w_{focaler} < 1$，已经较好匹配的样本被抑制。以 $m = 0.7$ 为例，若 $IoU = 0.5$，权重约为 $(0.5/0.3)^2 = 2.78$；若 $IoU = 0.9$，权重约为 $(0.1/0.3)^2 = 0.11$。该设计使训练更集中于低重叠框的修正，而不是继续在大量易样本上分配相近梯度。

实验结果显示，Focaler-IoU 的 Precision 为 0.6979，Recall 为 0.6594，mAP50 为 0.7187，mAP50-95 为 0.5343。与强基线相比，其 mAP50 从 0.7580 降至 0.7187，但 mAP50-95 从 0.5313 提升至 0.5343。该结果表明，Focaler-IoU 并没有全面提高检出稳定性，却对更严格 IoU 阈值下的边界框质量具有积极作用。换言之，该方法更适合对定位精度要求较高的交通标志识别场景，例如需要将检测框进一步映射到道路区域、交通标志牌面或规则库条目的任务。

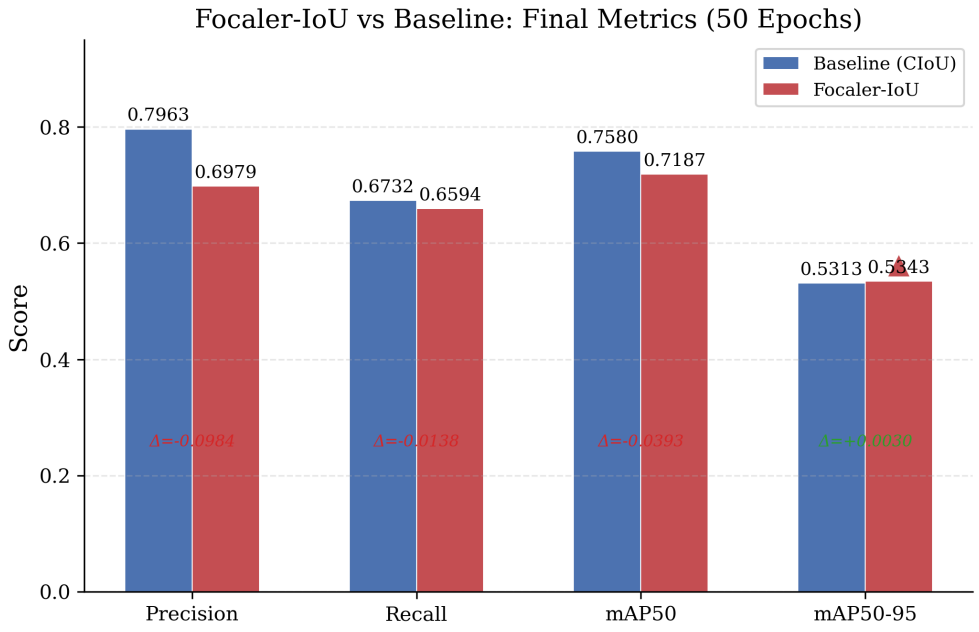
图6 展示了 Focaler-IoU 的权重机制、指标变化和训练曲线。指标对比说明，该方法主要改善 mAP50-95，而 Precision 和 mAP50 有所下降。这一现象与损失设计一致：模型将更多梯度用于修正低 IoU 定位框，严格阈值下的平均定位质量略有提高，但宽松阈值下的检出稳定性受到影响。因此，Focaler-IoU 更适合作为定位质量优化项，而不宜单独用于解决小目标漏检问题；若目标是提高远距离标志检出数量，应与输入尺度提升、类别重采样或 SAHI 切片推理配合使用。

5.2 Gold-YOLO GD 结构改进

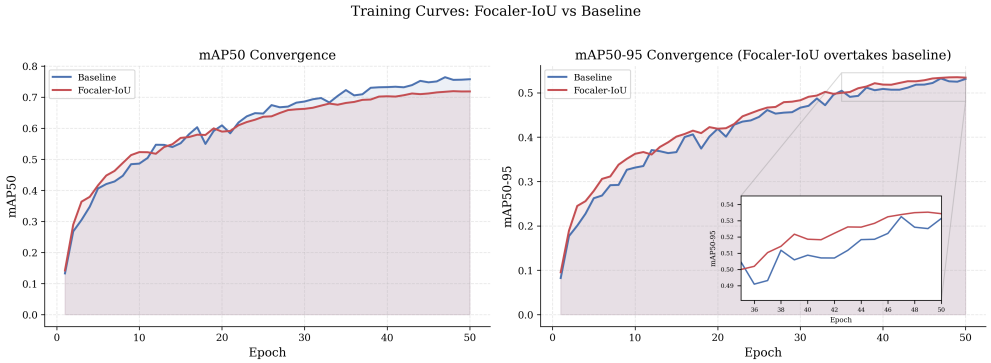
Gold-YOLO GD 的改进重点在于跨尺度特征的信息聚合与分发。交通标志检测同时包含近距离大目标和远距离小目标，模型需要在浅层细节信息与深层语义信息之间



(a) Focaler-IoU 机制示意



(b) Focaler-IoU 与基线指标对比



(c) Focaler-IoU 训练曲线

图 **6**　**Focaler-IoU** 改进实验图表

取得平衡。传统 YOLO 结构依靠 FPN/PAN 类路径完成多尺度融合，但在小目标密集、背景复杂的情况下，浅层特征的语义表达可能不足，深层特征又容易丢失小目标细节。Gold-YOLO GD 试图通过更强的信息分发结构改善这一问题，使不同尺度特征在检测前获得更充分的交互。

在课程实验条件下，本文采用近似实现方式构建 Gold-YOLO GD 改进模型，主要包括 A2C2f、SCDown 和 C2PSA 前移等结构调整。这些模块用于增强特征表达、控制下采样过程中的信息损失，并在较早阶段引入注意力或上下文建模。理论上，该结构有助于提升模型对多尺度目标的适应能力，尤其适合交通标志这类尺寸变化明显、类别细粒度差异较强的检测任务。

实际实验结果低于预期。Gold-YOLO GD 的 Precision 为 0.3641，Recall 为 0.5258，mAP50 为 0.3927，mAP50-95 为 0.2709，明显低于 YOLO11n 强基线。造成这一结果的主要原因并不是跨尺度融合思想本身无效，而是结构改动与训练条件之间存在不匹配：一方面，较大幅度的结构调整使模型难以直接继承 YOLO11n 的完整预训练权重；另一方面，TT100K 子集规模有限，batch size 和训练轮数也受到课程实验环境限制，新增模块无法充分收敛。该结果说明，在数据规模有限、训练预算较低的情况下，复杂结构改进可能带来更高的优化难度。

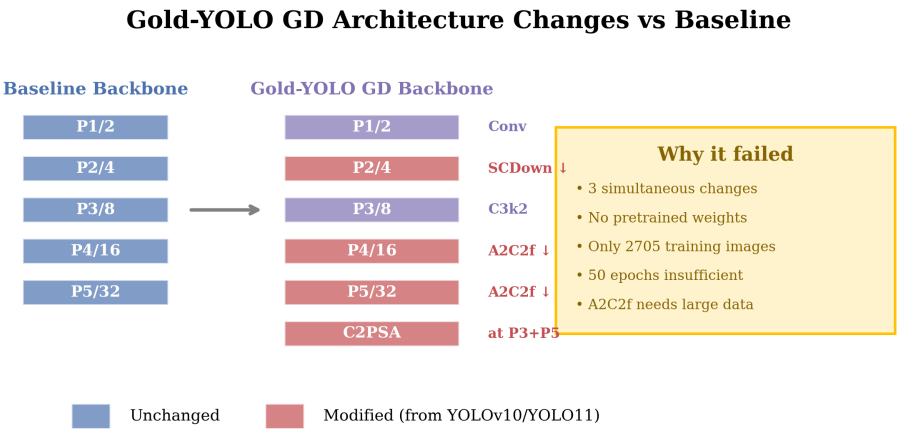
图7 中的结构图和训练曲线进一步说明了上述问题。Gold-YOLO GD 的改进方向具有明确的结构动机，但训练曲线反映出模型在当前数据和轮数下没有形成足够稳定的收敛过程。与 Focaler-IoU 相比，Gold-YOLO GD 的改动范围更大，收益更依赖预训练权重、数据量和训练策略。若后续继续研究该方向，应优先补充与结构匹配的预训练权重，延长训练轮数，并采用更充分的数据增强和学习率搜索，而不是直接在小规模子集上从零训练。

5.3 SAHI 切片推理改进

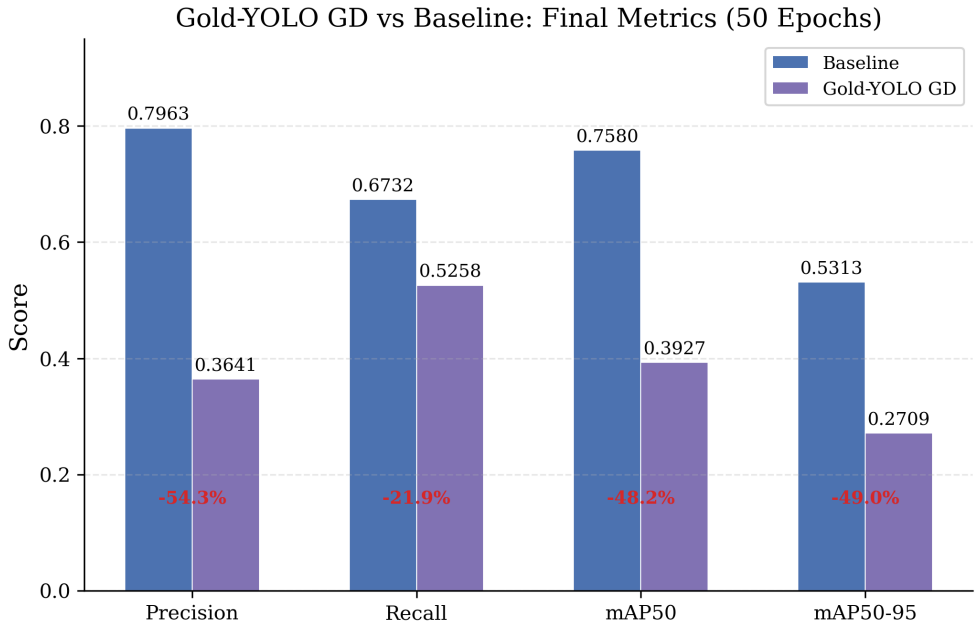
SAHI 属于推理阶段改进方法，其核心优势是不需要重新训练模型 [1]。TT100K 图像中存在大量远距离交通标志，目标在原图中占比较小，直接缩放到模型输入尺寸后容易被背景纹理淹没。SAHI 将原始图像切分为带重叠区域的小块，在每个切片上单独推理，再通过后处理合并检测框。切片后，小目标在局部图像中的相对尺寸增大，检测器更容易捕捉其形状和边界特征。

本文实验采用切片尺寸 640、重叠比例 0.2 的设置，对基线模型和 Focaler-IoU 模型分别进行 SAHI 推理测试。与训练阶段改进相比，SAHI 不涉及权重更新，因此能够直接接入现有网页端推理流程。其代价主要体现在推理时间增加和后处理复杂度上：一张图像需要拆分为多个切片分别推理，随后还要进行跨切片的结果合并与重复框过滤。

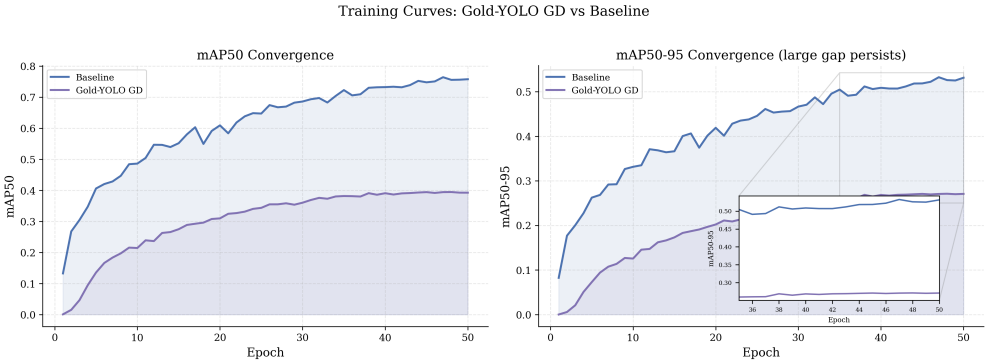
实验结果表明，Baseline+SAHI 的总检测数为 2397，平均每张图像检测 1.64 个目标；Focaler-IoU+SAHI 的总检测数为 5526，平均每张图像检测 3.79 个目标，约为前者



(a) Gold-YOLO GD 结构示意



(b) Gold-YOLO GD 与基线指标对比



(c) Gold-YOLO GD 训练曲线

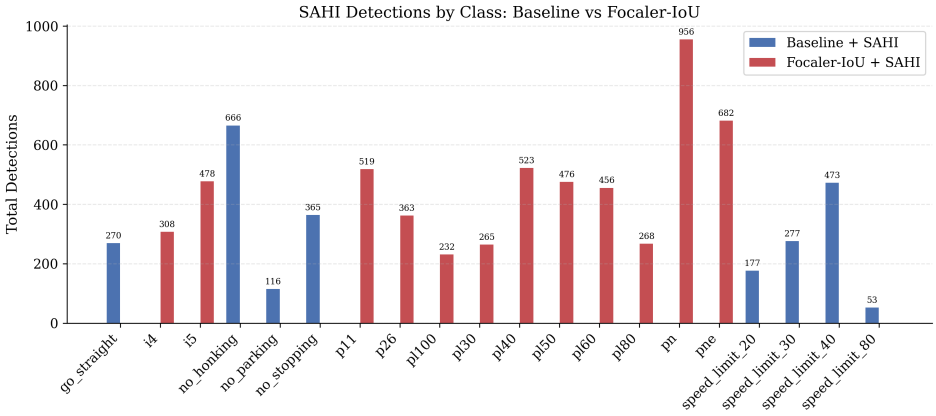
图 7　**Gold-YOLO GD** 改进实验图表

的 2.3 倍。在推理时间方面，Baseline+SAHI 平均每张图像约 0.421 s，Focaler-IoU+SAHI 约 0.432 s，二者时间差异较小。该结果说明，Focaler-IoU 与 SAHI 组合后，能够在推理成本基本相近的条件下显著增加小目标检出数量。

SAHI Comparison: Baseline vs Focaler-IoU

Metric	Baseline + SAHI	Focaler-IoU + SAHI	Delta
Total Images	1460	1460	—
Total Detections	2397	5526	**+3129 (2.3x)**
Avg Dets/Image	1.64	3.78	**+2.14**
Avg Time/Image	0.421s	0.432s	**+0.011s**
Base Model mAP50	0.7580	0.7187	**-0.0393**
Dets/mAP50 Ratio	3162	7689	**—**

(a) SAHI 检测数量对比

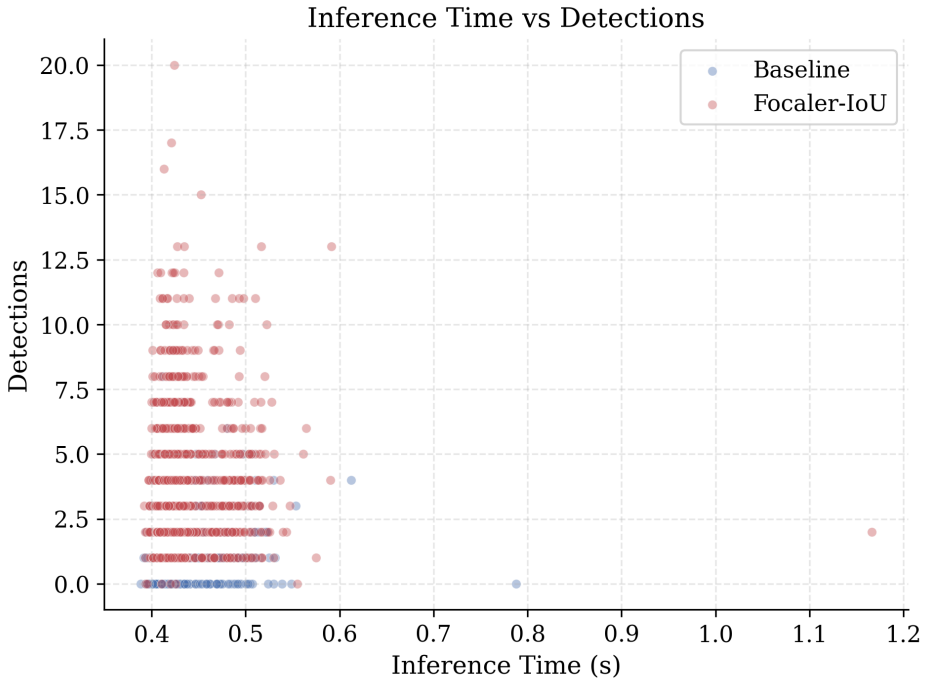


(b) SAHI 逐类别检测结果

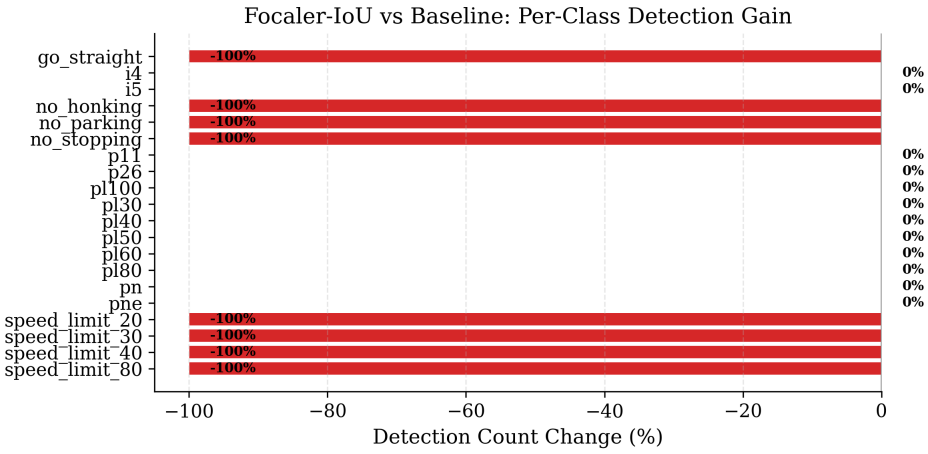
图 **8**　**SAHI** 切片推理检测数量与类别分布

图8 和图9 显示，SAHI 的增益主要体现在小目标数量更多、类别分布更丰富的场景中。逐类别统计结果表明，限速类标志和部分指示类标志的检测数量增长较明显，这与 TT100K 中远距离小目标比例较高的特点一致。需要注意的是，检测数量增加并不完全等同于准确率提升，切片推理也可能带来重复框和低置信度误检。因此，在实际部署中应结合置信度阈值、NMS 参数、道路区域约束和连续帧一致性进行过滤。综合来看，SAHI 更适合作为强基线模型的部署增强策略，而不是替代训练阶段的模型优化。

图10 补充展示了 CBAM、P2+CBAM 的训练过程和不同方法的指标热力分布。CBAM 单独引入后没有取得预期收益，说明通道与空间注意力并不会自动提升小目标检测效果；P2+CBAM 在 Recall 和 mAP50 上相对 CBAM 有所改善，说明浅层检测头对小目标召回具有一定意义，但新增分支也增加了训练难度。结合三组主要改进实验可以看出，



(a) SAHI 推理时间对比

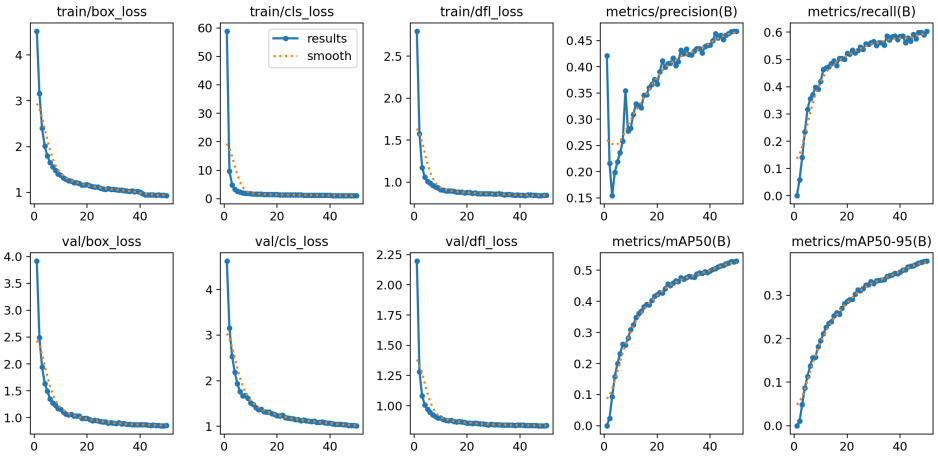


(b) SAHI 检测增益分析

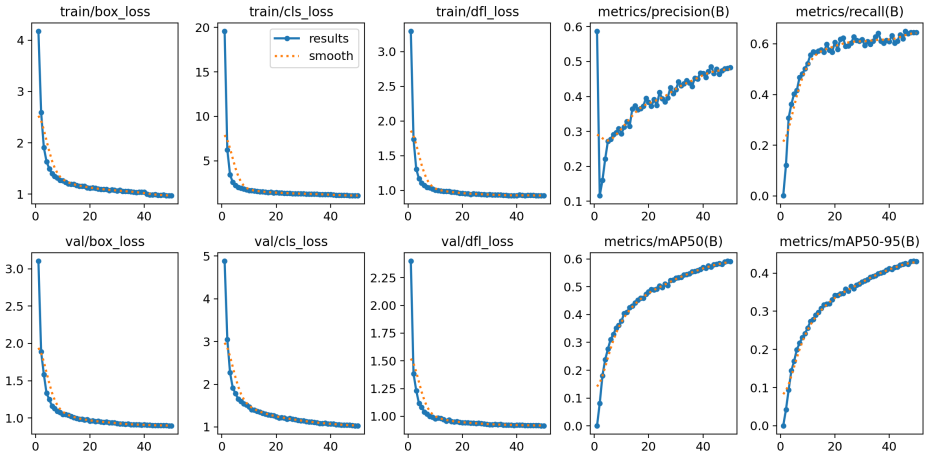
图 **9**　**SAHI** 切片推理效率与增益分析

当前任务更适合优先采用“强基线 + 轻量损失调节 + 推理增强”的路径，而不是在训练数据不足时大幅增加结构复杂度。

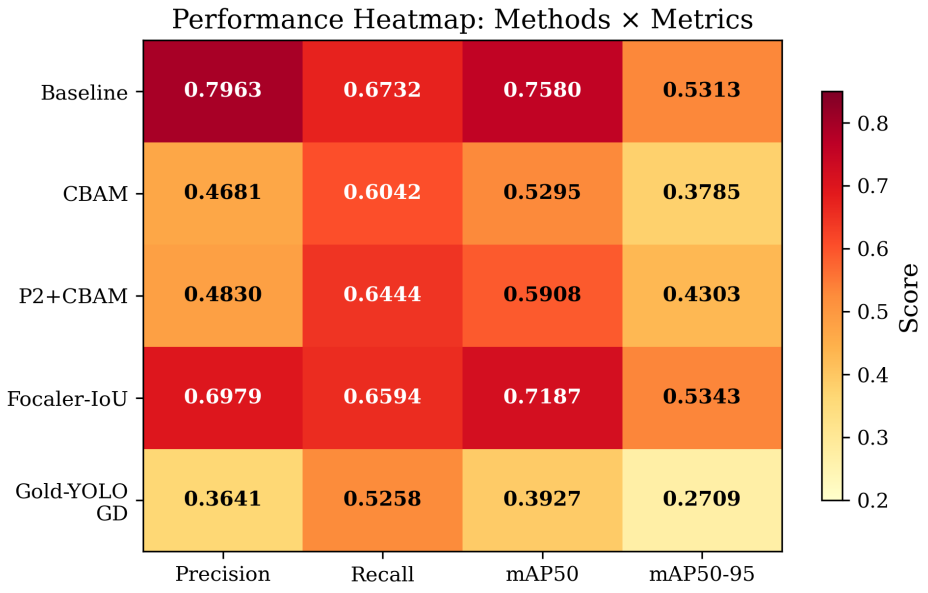
综合三组主要改进实验，本文认为 Focaler-IoU+SAHI 是当前条件下更值得采用的组合。Focaler-IoU 的优势在于不改变网络结构，能够以较低成本改善定位质量；SAHI 的优势在于不依赖重新训练，能够直接提高小目标在推理阶段的可见性。二者分别作用于训练目标和推理输入，彼此之间不存在明显冲突，且便于接入网页端演示系统。相比之下，Gold-YOLO GD 的结构思路具有研究价值，但在课程实验规模下尚未体现出稳定收益，后续若要继续推进，应将其作为更长期的结构优化方向，而不是当前系统演示的



(a) CBAM 训练曲线



(b) P2+CBAM 训练曲线



(c) 改进方法指标热力图

图 **10**　结构探索实验与综合指标补充图表

表 **6**　改进方法适用性综合比较

方法	改进位置	主要收益	局限性与适用场景
Focaler-IoU	损失函数	mAP50-95 略有提升，定位质量更稳定	对召回提升有限，适合与推理增强组合使用
Gold-YOLO GD	网络结构	理论上增强跨尺度信息交互	当前训练条件下收敛不足，更依赖预训练权重和长轮次训练
SAHI	推理阶段	检测数量显著增加，对远距离小目标更友好	推理时间增加，需配合阈值和后处理控制误检

主方案。

六、 交通态势智能感知分析解决方案

为满足高阶要求，本文在交通标志检测实验基础上，综合交通目标识别与交通流量预测两个模块，设计并构建交通态势智能感知分析方案。该方案不替代检测模型本身，而是将模型输出整理为面向交通管理的结构化信息，使实验结果能够用于态势研判、分级预警和诱导管控。

6.1 系统总体流程

系统采用“感知输入—流量预测—态势研判—预警诱导—结果输出”的流程。感知输入阶段接收道路视频、图像或检测结果，由交通标志检测模型输出目标类别、位置和置信度；流量预测阶段根据历史交通流序列估计未来短时交通变化趋势；态势研判阶段融合目标识别结果、流量预测结果和规则知识，形成拥堵、事故、限速、诱导等态势标签；预警诱导阶段根据风险等级生成管理建议；结果输出阶段通过网页端展示分析结论，并支持导出和语音播报。

该流程与网页端原型保持一致。网页端提供场景名称、工作流类型和备注信息输入，用户可以选择“完整决策流”“仅预测”或“仅识别”等工作模式。后端接口返回结构化分析结果，包括预测模块摘要、识别模块摘要、风险等级、诱导建议和事实依据。通过这一设计，交通标志检测从单独的模型实验扩展为态势研判系统中的感知模块。

6.2 网页端实现与功能设计

网页端原型基于 React 实现，主要承担系统展示和交互入口功能。页面上部展示系统叙事和五段式协同架构，包括场景感知、流量预测、态势研判、分级预警和诱导管控；中部提供分析请求入口，用户可输入场景名称、选择工作流并触发后端分析；下部展示结构化结果、实验图表、后台任务状态和后续扩展路线。该设计将算法实验、系统方案和演示流程集中在同一页面中呈现。

在结果展示方面，网页端将检测模块的类别数、Precision、Recall、mAP50、mAP50-95 等指标与预测样例、归一化混淆矩阵等图表一起展示；同时将交通流量预测结果组织为 Baseline MAE、Baseline RMSE、DGL RMSE 和推理时间等摘要指标。对于完整决策流，页面进一步显示风险等级、诱导建议、解释说明和事实依据，并支持将结果导出为 JSON 或 Markdown。语音播报功能基于浏览器语音合成接口实现，用于将风险等级和诱导建议转化为可听化提示。

6.3 前后端调用流程

系统前后端通过 REST 接口连接。网页端向 `/api/analyze-scene` 发送场景名称、工作流类型、是否生成报表和是否生成语音等参数；后端根据工作流调用交通流量预测模块、交通目标识别模块或完整决策逻辑，并返回统一结构的分析结果。网页端随后通过 `/api/results/{result_id}` 查询结果，通过 `/api/tasks` 查询报表、语音播报和每日总结等后台任务状态。

这种接口设计便于模块化调试和扩展。交通目标识别和交通流量预测可以独立运行，也可以在完整决策流中组合使用；系统输出不依赖单一页面状态，结果编号和任务编号便于后续扩展为持久化存储、日报生成或 Hermes Agent 自动化任务。对于课程演示而言，该流程能够体现“输入场景—调用模型—生成研判—导出结果”的完整过程。

6.4 高阶要求完成情况分析

从功能覆盖角度看，本文方案已经完成高阶要求中的两个核心点。交通目标识别模块基于 TT100K 和 YOLO11n 实现，能够输出 12 类交通标志的检测结果，并提供训练曲线、混淆矩阵和预测样例用于结果解释；交通流量预测模块作为态势分析的预测输入，为未来短时交通压力变化提供趋势信息。二者在网页端通过统一工作流整合，并进一步转化为风险等级、诱导建议和可导出的分析报告。

交通流量预测模块复用大作业 1 中已经完成的 STAEformer 实验结果，其作用是为高阶系统提供未来短时交通状态估计。表7 给出了 PEMS08 数据集上的主要指标。需要说明的是，该模块与 TT100K 交通标志检测模块并非联合训练关系，而是在系统层面通过网页端接口进行结果融合；因此，表中指标用于说明预测模块本身的可用性，不与目

标检测 mAP 指标直接比较。

表 **7** **STAEformer** 交通流量预测模块指标

数据集	MAE	RMSE	MAPE / %	推理时间 / s	参数量 / M
PEMS08	13.7056	23.7665	9.0453	1.8565	1.22

从指标看，STAEformer 在 PEMS08 上能够提供稳定的短时流量预测结果，误差水平可支持课程 demo 中的趋势研判和风险提示。网页端使用该模块输出未来交通压力摘要，再与交通标志检测得到的道路语义约束进行组合。例如，当预测模块给出流量上升趋势，而识别模块同时检测到限速、禁停或道路施工相关标志时，系统可以提高拥堵或管控风险等级，并生成更保守的诱导建议。通过这种方式，高阶方案不是简单并列展示两个模型结果，而是将“未来交通状态”和“当前道路语义”共同转化为态势研判依据。

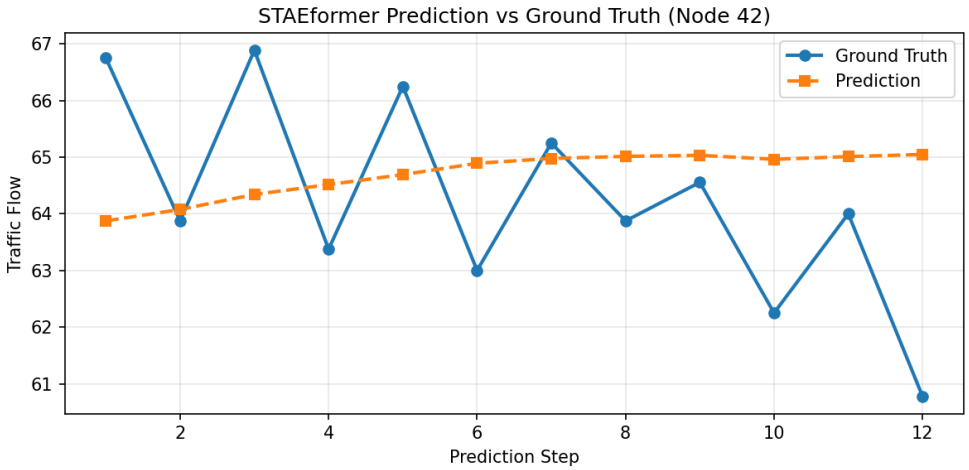
从系统价值角度看，该方案将模型指标进一步转化为管理信息。交通标志检测提供道路语义和规则约束，交通流量预测提供未来交通状态变化，两者结合后可以支撑拥堵预警、限速提醒、事故扰动分析和诱导管控建议。当前系统仍属于课程 demo 版本，但模块划分、接口设计和结果展示流程已具备继续接入真实模型服务、视频流输入和自动化任务代理的基础。

图11 展示了交通流量预测模块的可视化结果。预测曲线用于说明模型对未来交通流变化趋势的拟合情况，分步指标用于观察不同预测步长下的误差变化，热力图对比则用于展示不同区域或时间片上的流量分布差异。该部分结果与交通标志检测结果共同构成高阶方案的输入基础：前者提供未来交通压力变化，后者提供道路语义和目标约束，二者结合后能够支撑更完整的态势研判。

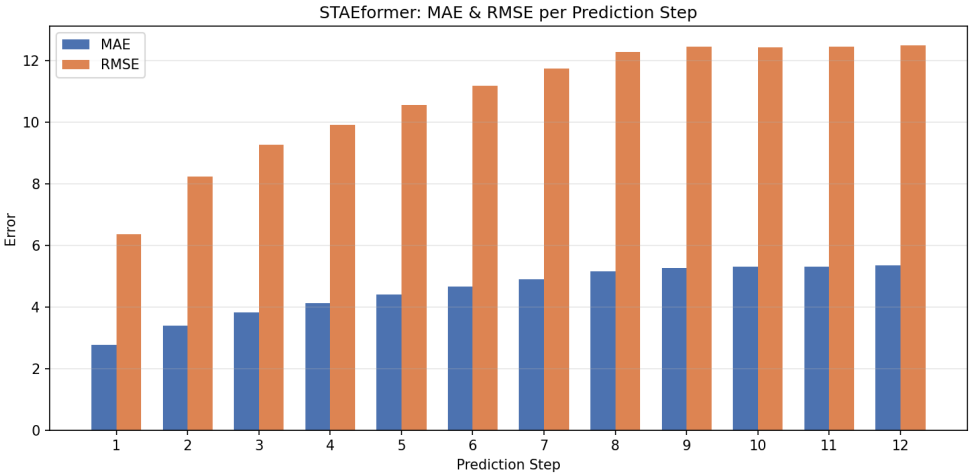
七、 总结

本文完成了 TT100K 交通标志检测的完整实验流程，包括数据整理、YOLO 格式转换、YOLO11n 训练验证、定量指标比较和可视化误差分析。实验结果表明，在模型参数量保持约 2.59M 的条件下，输入尺度和训练轮数对小目标检测影响显著；$704/8/0/e50$ 配置取得 Precision 0.7963、Recall 0.6732、mAP50 0.7580 和 mAP50-95 0.5313，是本文基础实验中的最优设置。

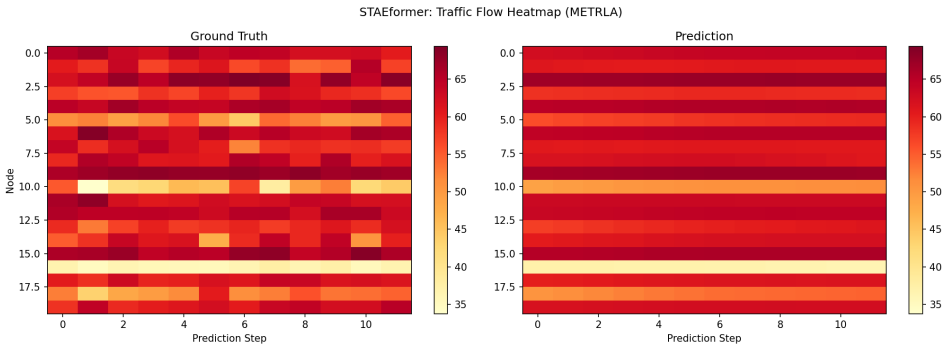
改进实验进一步说明，损失函数、结构模块和推理策略的收益并不相同。Focaler-IoU 通过 IoU 相关权重放大低重叠样本的定位梯度，使 mAP50-95 提升至 0.5343，但 Precision 和 mAP50 下降，说明其更偏向定位质量优化；Gold-YOLO GD 在缺少匹配预训练权重和长轮次训练时收敛不足；SAHI 切片推理能够在不修改权重的情况下增加小目标检出



(a) 预测曲线



(b) 分步指标



(c) 热力图对比

图 **11**　交通流量预测模块的可视化结果

数量。综合准确率、可复现性和工程接入成本，本文推荐将 Focaler-IoU 与 SAHI 作为后续小目标优化的主要组合。

高阶方案将交通标志检测结果与交通流量预测结果接入网页端流程，形成场景输入、模型调用、态势研判、分级预警、结果导出和语音播报的演示闭环。后续工作应优先完善数据增强、低频类别重采样、视频连续帧过滤和真实后端模型服务接入，以提升复杂交通场景下的鲁棒性和系统可用性。

参考文献

[1] Fatih Cagatay Akyon, Sinan Onur Altinuc, and Alptekin Temizel. Slicing aided hyper inference and fine-tuning for small object detection. In Proceedings of the IEEE International Conference on Image Processing (ICIP), pages 966–970, 2022.

[2] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In Proceedings of the European Conference on Computer Vision (ECCV), pages 213–229, 2020.

[3] Huaqing Lai, Liangyan Chen, Weihua Liu, Zi Yan, and Sheng Ye. STC-YOLO: Small object detection network for traffic signs in complex environments. Sensors, 23(11):5307, 2023.

[4] Rongzhen Li, Yajun Chen, Yu Wang, and Chaoyue Sun. YOLO-TSF: A small traffic sign detection algorithm for foggy road scenes. Electronics, 13(18):3744, 2024.

[5] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 2117–2125, 2017.

[6] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 779–788, 2016.

[7] Bharat Singh and Larry S. Davis. An analysis of scale invariance in object detection: SNIP. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 3578–3587, 2018.

[8] Bharat Singh, Mahyar Najibi, and Larry S. Davis. SNIPER: Efficient multi-scale training. In Advances in Neural Information Processing Systems, volume 31, 2018.

[9] Mingxing Tan, Ruoming Pang, and Quoc V. Le. Efficientdet: Scalable and efficient object detection. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 10781–10790, 2020.

[10] Ultralytics. Ultralytics YOLOv8. `https://docs.ultralytics.com/models/yolov8/`, 2023. Accessed: 2026-04-26.

[11] Ultralytics. Ultralytics YOLO11. `https://docs.ultralytics.com/models/yolo11/`, 2024. Accessed: 2026-04-26.

[12] Ao Wang, Hui Chen, Lihao Liu, Kai Chen, Zijia Lin, Jungong Han, and Guiguang Ding. YOLOv10: Real-time end-to-end object detection. arXiv preprint arXiv:2405.14458, 2024.

[13] Chengcheng Wang, Wei He, Yao Nie, Jianyuan Guo, Chuanjian Liu, Kai Han, and Yunhe Wang. Gold-YOLO: Efficient object detector via gather-and-distribute mechanism. Advances in Neural Information Processing Systems, 36, 2023.

[14] Chien-Yao Wang, I-Hau Yeh, and Hong-Yuan Mark Liao. YOLOv9: Learning what you want to learn using programmable gradient information. arXiv preprint arXiv:2402.13616, 2024.

[15] Hao Zhang, Feng Li, Shilong Liu, Lei Zhang, Hang Su, Jun Zhu, Lionel M. Ni, and Heung-Yeung Shum. DINO: DETR with improved denoising anchor boxes for end-to-end object detection. In International Conference on Learning Representations (ICLR), 2023.

[16] Yi-Fan Zhang, Weiqi Ren, Zhang Zhang, Zhen Jia, Liang Wang, and Tieniu Tan. Focaler-IoU: More focused intersection over union loss. arXiv preprint arXiv:2401.10525, 2024.

[17] Yian Zhao, Wenyu Lv, Shangliang Xu, Jinman Wei, Guanzhong Wang, Qingqing Dang, Yi Liu, and Jie Chen. DETRs beat YOLOs on real-time object detection. arXiv preprint arXiv:2304.08069, 2023.

[18] Xizhou Zhu, Weijie Su, Lewei Lu, Bin Li, Xiaogang Wang, and Jifeng Dai. Deformable DETR: Deformable transformers for end-to-end object detection. In International Conference on Learning Representations (ICLR), 2021.

[19] Zhe Zhu, Dun Liang, Songhai Zhang, Xiaolei Huang, Baoli Li, and Shimin Hu. Traffic-sign detection and classification in the wild. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 2110–2118, 2016.