arXiv :2308.10425v 5 [cs.LG] 2023年10月8日

STAEformer：时空自适应嵌入技术使基础Transformer SOTA 应用于交通预测

刘汉晨*[1]、董正*[1]、蒋仁河†[2]、邓杰文[1]、邓金良[3]、陈全军[2]、宋轩†[1,2]
[1]南方科技大学、[2]东京大学、[3]悉尼科技大学
{liuhc3，zhengdong00}@outlook.com，jiangrh@csis.u-tokyo.ac.jp

摘要

随着智能交通系统（ITS）的快速发展，精准交通预测已成为关键挑战。核心瓶颈在于捕捉复杂的时空交通模式。近年来，为解决这一问题，人们提出了多种具有复杂架构的神经网络模型。然而，网络架构的改进已遭遇性能提升趋缓的瓶颈。本研究提出一种名为***时空自适应嵌入*** 的创新组件，该组件可在基础Transformer模型上取得卓越性能。我们提出的时空-自适应嵌入Transformer（**STAEformer**）在六个真实交通预测数据集上实现了业界领先水平。进一步实验表明，时空自适应嵌入通过有效捕捉交通时间序列中的内在时空关系与时序信息，在交通预测中发挥着关键作用。

中国化学会概念

• 信息系统→时空系统；• 计算方法论→人工智能。

关键词

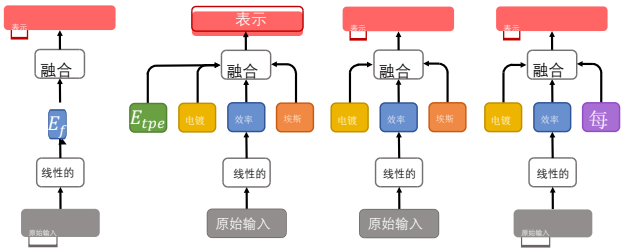
交通预测、时空嵌入、Transformer

ACM参考格式：

Hangchen Liu*[1]、 Zheng Dong*[1]、 Renhe Jiang †[2]、 Jiewen Deng [1]、 Jinliang Deng [3]、 Quanjun Chen [2]、 Xuan Song †[1,2]。2023 年 。 STAEformer：时空自适应嵌入使普通Transformer SOTA 于交通预测。收录于*第32届ACM信息与知识管理国际会议论文集（CIKM '23），2023年10月21–25日，英国伯明翰*。ACM，美国纽约州纽约市，5页。https://doi.org/10.1145/3583780.3615160

1 引言

交通预测[15]旨在基于历史观测数据对道路网络中的未来交通时间序列进行预测。近年来，



(a) STGNNs (b) 基于变压器的模型 (c) 时空同一性 (d) 我们的

图1：不同交通模型中的输入嵌入向量

深度学习模型的成功表现尤为显著，这主要归功于其能够捕捉交通系统中固有的时空依赖关系。其中，时空图神经网络（STGNNs）[18, 37]和基于Transformer的模型[11, 13, 35, 41]凭借卓越性能广受青睐。研究人员投入大量精力开发复杂精细的交通预测模型，例如创新的图卷积[2, 3, 8–10, 12, 17, 20, 27, 30, 31, 36, 40]、图结构学习[14, 23, 33, 34, 39]、高效注意力机制[5, 19, 32, 42, 43]以及其他方法[4, 16, 21, 22,25, 26]。然而，网络架构的进步已遭遇性能提升瓶颈，促使研究重点从复杂模型设计转向数据本身的有效表征技术。

鉴于此，在本研究中，我们聚焦于***输入嵌入*** ——一种被广泛使用、简单却强大的表示技术，其有效性常被许多研究者忽视。具体而言，该技术在输入端添加嵌入层，为模型主干提供多种类型的嵌入向量。图1展示了先前模型所采用嵌入方式的对比分析。STGNNs主要使用特征嵌入*Ef*（即将原始输入投影到隐空间的变换）。基于Transformer的模型由于注意力机制无法保留时间序列的位置信息，需要额外知识如时间位置编码*EtPe*和周期性（日、周、月）嵌入E_p。近期模型（包括PDFormer[13]、 GMAN[41]和STID[24]）均采用空间嵌入*Es*。值得注意的是，STID[24]是少数探索此类嵌入的研究之一。该方法采用空间嵌入与时间周期性嵌入技术，结合简单的多层感知器（MLP）实现，展现出卓越的性能表现。

为进一步提升表征效果，我们提出了一种新颖的***时空自适应嵌入*** E_a，并将其应用于基础Transformer[29]以及*EP*和*Ef*上，如图1d所示。具体而言，原始输入会经过一个嵌入

---

* 等额贡献。t 通讯作者。

本作品允许个人或课堂教学用途免费制作数字版或纸质版全部或部分内容，但需满足以下条件：不得为营利或商业利益制作/分发副本，且首页必须标注本声明及完整引用信息。对于作者以外第三方持有的作品组成部分，必须遵守版权规定。允许进行摘要引用并注明出处。如需其他复制方式、转载发布、服务器存储或邮件列表分发，请事先获得书面许可及/或支付费用。授权申请请发送邮件至permissions@acm.org。

CIKM 2023年10月21日至25日，英国伯明翰
⑥ 2023 版权所有者/作者保留。出版权授权给ACM。ACM ISBN 979-8-4007-0124-5/23/10... $15.00 https://doi.org/10.1145/3583780.3615160

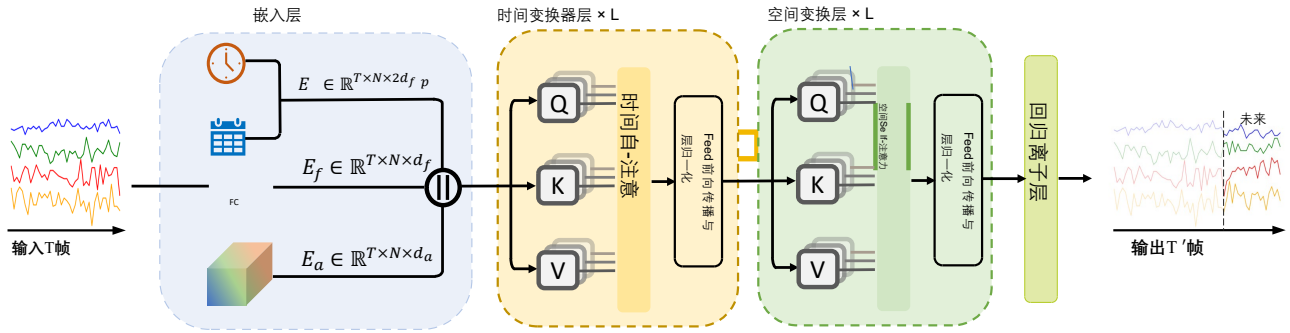


图2：时空自适应嵌入变换器（STAEformer）的架构。

通过输入层获取输入嵌入向量，该向量被输入时序与空间变换器层，随后通过回归层进行预测。我们提出的模型命名为空间-时序自适应嵌入变换器（**STAEformer**），其架构更为简洁却实现了最先进的（SOTA）性能。在模型中，*Ea*通过有效捕捉交通时间序列中的内在时空关系与时序信息发挥关键作用。基于六个真实交通数据集的实验与分析表明，我们提出的*Ea*可使基础变换器 SOTA 用于交通预测。

2 问题定义

给定前*T*个时间帧中的交通序列*xt* − *T*+1:*t*，交通预测旨在通过训练参数为*θ*的模型F（·），来推断未来*T′*个时间帧中的交通数据，该模型可表述为：

$$[X_{t-T+1},\ldots,X_t] \xrightarrow[\theta]{\mathbb{F}(\cdot)} [X_{t+1},\ldots,X_{t+T'}] \tag{1}$$

其中每个帧*xi* ∈ *RN*×*d*，*N*表示空间节点数量。*d*为输入特征维度，在本案例中等于1，代表交通流量。

3 方法学

如图2所示，我们的模型包含嵌入层、沿时间轴应用的常规Transformer作为时间变换器层、沿空间轴应用的空间变换器层，以及回归层。嵌入层通过特征嵌入、周期性嵌入和时空自适应嵌入融合获得隐藏表示。时空变换器层用于捕捉交通关联特征，最终由回归层完成预测输出。

3.1 嵌入层

为保留原始数据中的原始信息，我们采用全连接层来获取特征嵌入*Ef* ∈ RT × *N* × *df*：

$$E_f = FC(X_{t-T+1:t}) \tag{2}$$

其中*df*表示特征嵌入的维度，*FC*（·）表示全连接层。

我们将可学习的星期几嵌入字典表示为*Tw* ∈ $\mathbb{R}^{N_w \times d_f}$，将日期时间戳嵌入字典表示为Td ∈ RNd × *df*，其中*Nw*= 7 表示一周中的天数。在本案例中，*Nd*= 288 是每天的时间戳数量。将*w* ^{t} ∈ RT、*Dt* ∈ RT 分别表示为*t*-*T*+1 时间序列中交通时间序列的星期几数据和日期时间戳数据*t*，我们利用它们作为索引从嵌入字典中提取对应的星期几嵌入*E tw* ∈ $\mathbb{R}^{T \times d_f}$和日期时间戳嵌入*Etd* ∈ RT × *df*。通过拼接并广播这些数据，我们得到交通时间序列的周期性嵌入E_p ∈ RT × *N* ×2 ^{d_f}。

一方面，时间关系不仅由周期性决定，还受交通时间序列中时间顺序的影响，这一点显而易见。例如，交通时间序列中的某个时间帧应当与邻近时间帧更具相似性。另一方面，不同传感器采集的时间序列往往呈现差异化的时序特征。因此，我们摒弃了采用预定义或动态邻接矩阵进行空间关系建模的传统方法，转而设计了时空自适应嵌入*Ea* ∈ $^{RT\times N\times da}$，以统一方式捕捉复杂时空关联。特别需要指出的是，*Ea*可跨不同交通时间序列共享使用。

通过拼接上述嵌入向量，我们得到隐藏的时空表示*Z* ∈ RT × *N* × *dh*，具体如下：

$$Z = E_f || E_p || E_a \tag{3}$$

其中隐藏维度*dh*等于3df +*da*。

3.2 变压器与回归层

我们在时间轴和空间轴上应用基础Transformer模型以捕捉复杂的交通关系。给定包含*T*帧和*N*个空间节点的隐式时空表示*Z* ∈ RT × *N* × *dh*，我们通过时间Transformer层获得查询矩阵、键值矩阵如下：

$$Q^{(te)} = ZW_Q^{(te)},\ K^{(te)} = ZW_K^{(te)},\ V^{(te)} = ZW_V^{(te)} \tag{4}$$

其中$W_Q^{(te)}$，$W_K^{(te)}$，W_V $^{(te)}$∈ Rdh × *dh*为可学习参数。随后我们计算自注意力分数如下：

$$A\ (te) = 软性\ tmax\left(\frac{Q^{(te)}K^{(te)\top}}{\sqrt{d_h}}\right) \tag{5}$$

其中*A*$^{(te)}$∈ RN × *T* × *T*用于捕捉不同空间节点中的时间关系。最终，我们得到时间变换器的输出。

表1：METR-LA与 PEMS -BAY评分表现

数据集		指标	嘿	GWNet	DCRNN	AGCRN	STGCN	制导试验装置	MTGNN	标准规范	泛发性恶性黑棘皮症	PD前体	科技情报处	**STAEformer**
METR-LA	地平线3号（15分钟）	更多的	6.80	2.69	2.67	2.85	2.75	2.75	2.69	2.81	2.80	2.83	2.82	**2.65**
		中误差	14.21	5.15	5.16	5.53	5.29	5.27	5.16	5.57	5.55	5.45	5.53	**5.11**
		教育哲学的多维评价	16.72%	6.99%	6.86%	7.63%	7.10%	7.12%	6.89%	7.40%	7.41%	7.77%	7.75%	**6.85%**
	地平线6号（30分钟）	更多的	6.80	3.08	3.12	3.20	3.15	3.14	3.05	3.18	3.12	3.20	3.19	**2.97**
		中误差	14.21	6.20	6.27	6.52	6.35	6.33	6.13	6.59	6.49	6.46	6.57	**6.00**
		教育哲学的多维评价	16.72%	8.47%	8.42%	9.00%	8.62%	8.62%	8.16%	8.47%	8.73%	9.19%	9.39%	**8.13%**
	地平线12（60分钟）	更多的	6.80	3.51	3.54	3.59	3.60	3.59	3.47	3.57	3.44	3.62	3.55	**3.34**
		中误差	14.20	7.28	7.47	7.45	7.43	7.44	7.21	7.51	7.35	7.47	7.55	**7.02**
		教育哲学的多维评价	10.15%	9.96%	10.32%	10.47%	10.35%	10.25%	9.70%	10.24%	10.07%	10.91%	10.95%	**9.70%**
PEMS-BAY	地平线3号（15分钟）	更多的	3.06	**1.30**	1.31	1.35	1.36	1.37	1.33	1.33	1.35	1.32	1.31	1.31
		中误差	7.05	**2.73**	2.76	2.88	2.88	2.92	2.80	2.82	2.90	2.83	2.79	2.78
		教育哲学的多维评价	6.85%	**2.71%**	2.73%	2.91%	2.86%	2.85%	2.81%	2.76%	2.87%	2.78%	2.78%	2.76%
	地平线6号（30分钟）	更多的	3.06	1.63	1.65	1.67	1.70	1.72	1.66	1.65	1.65	1.64	1.64	**1.62**
		中误差	7.04	3.73	3.75	3.82	3.84	3.86	3.77	3.77	3.82	3.79	3.73	**3.68**
		教育哲学的多维评价	6.84%	3.73%	3.71%	3.81%	3.79%	3.88%	3.75%	3.66%	3.74%	3.71%	3.73%	**3.62%**
	地平线12（60分钟）	更多的	3.05	1.99	1.97	1.94	2.02	2.06	1.95	1.92	1.92	1.91	1.91	**1.88**
		中误差	7.03	4.60	4.60	4.50	4.63	4.60	4.50	4.45	4.49	4.43	4.42	**4.34**
		教育哲学的多维评价	6.83%	4.71%	4.68%	4.55%	4.72%	4.88%	4.62%	4.46%	4.52%	4.51%	4.55%	**4.41%**

$Z_{(te)} \in \mathrm{RT} \times N \times dh$如下：

$$Z_{(te)} = A_{(te)} V_{(te)} 。 \tag{6}$$

同样地，空间变换器层的功能表现为：

$$Z^{(sp)} = 自注意力\,(Z_{(te)}) \tag{7}$$

其中*自注意力*遵循公式4、5、6，$Z^{(sp)} \in RT \times N \times dh$为空间变换器的输出。值得注意的是，我们还应用了层归一化、残差连接和多头机制。

最后，我们利用时空变换器层的输出$Z' \in \mathrm{RT} \times N \times dh$来生成预测结果。回归层可表述为：

$$\hat{Y} = FC(Z') \tag{8}$$

在哪里$\hat{Y} \in \mathrm{RT}' \times N \times d$是预测结果，$T'$是预测时间范围。$d$是输出特征的维度，在本案例中等于1。因此，全连接层将维度从Z'中的$T \times d_h$回归为$T' \times (d = 1)\hat{Y}$.

4 实验

4.1 实验设置

数据集。我们的方法在六个交通预测基准数据集上进行了验证，即METR-LA、 PEMS -BAY、PEMS03、PEMS04、PEMS07和PEMS08。前两个数据集由 DCRNN[18]提出，后四个数据集由 STSGCN[27]提出。这六个数据集的时间间隔均为5分钟，因此每小时包含12帧数据。更多细节见表2。

实现方案。我们使用PyTorch工具包在搭载GeForce RTX 3090显卡的Linux服务器上实现了该模型。METR-LA

表2：数据集摘要

数据集	#传感器(N)	#时间步长	时间范围
METR-LA	207	34,272	03/2012 - 06/2012
PEMS-BAY	325	52,116	01/2017 - 05/2017
PEMS03	358	26,209	05/2012 - 07/2012
PEMS04	307	16,992	01/2018 - 02/2018
PEMS07	883	28,224	05/2017 - 08/2017
PEMS08	170	17,856	07/2016 - 08/2016

表3：PEMS03、04、07及08试验中的性能表现

数据集	PEMS03			PEMS04			PEMS07			PEMS08		
指标	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
嘿	32.62	49.89	30.60%	42.35	61.66	29.92%	49.03	71.18	22.75%	36.66	50.45	21.63%
GWNet	**14.59**	25.24	15.52%	18.53	**29.92**	12.89%	20.47	33.47	8.61%	14.40	23.39	9.21%
DCRNN	15.54	27.18	15.62%	19.63	31.26	13.59%	21.16	34.14	9.02%	15.22	24.17	10.21%
AGCRN	15.24	26.65	15.89%	19.38	31.25	13.40%	20.57	34.40	8.74%	15.32	24.41	10.03%
STGCN	15.83	27.51	16.13%	19.57	31.38	13.44%	21.74	35.27	9.24%	16.08	25.39	10.60%
制导试验装置	15.41	26.15	15.39%	20.96	32.95	14.66%	22.15	35.10	9.38%	16.49	26.08	10.54%
MTGNN	14.85	**25.23**	14.55%	19.17	31.70	13.37%	20.89	34.06	9.00%	15.18	24.24	10.20%
标准规范	15.32	25.93	**14.37%**	18.96	30.98	12.69%	20.50	34.66	8.75%	15.41	24.77	9.76%
泛发性恶性黑棘皮症	16.87	27.92	18.23%	19.14	31.60	13.19%	20.97	34.10	9.05%	15.31	24.92	10.13%
PD前体	14.94	25.39	15.82%	18.36	30.03	12.00%	19.97	32.95	8.55%	13.58	23.41	9.05%
科技情报处	15.33	27.40	16.40%	18.38	29.95	12.04%	19.61	32.79	8.30%	14.21	23.28	9.27%
STAEformer	15.35	27.55	15.18%	**18.22**	30.18	**11.98%**	**19.14**	**32.60**	**8.01%**	**13.46**	**23.25**	**8.88%**

表4：PEMS04、PEMS07及PEMS08的消融研究

数据集	PEMS04			PEMS07			PEMS08		
指标	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
w/o E_a	21.63	34.88	14.26%	22.37	37.21	9.25%	15.00	25.85	9.74%
w/o E_p	18.92	30.74	12.27%	20.21	33.59	8.40%	15.00	24.05	9.56%
无T-Trans	18.50	30.34	12.24%	19.87	33.67	8.29%	13.83	23.79	9.09%
无*sT-Trans*	25.17	39.89	18.00%	27.71	42.99	17.61%	19.96	31.47	18.53%
STAEformer	**18.22**	**30.29**	**12.01%**	**19.14**	**32.60**	**8.01%**	**13.46**	**23.25**	**8.88%**

并且 PEMS -BAY数据集按7:1:2的比例划分为训练集、验证集和测试集。PEMS03、PEMS04、PEMS07和PEMS08数据集按6:2:2的比例划分。实际上，我们模型的性能对超参数并不敏感。具体参数设置如下：嵌入维度*df*为24，*da*为80；空间变换器和时间变换器的层数*L*均为3，头数为4。我们将输入和预测长度设为1小时，即$T = T' = 12$。选择Adam作为优化器，学习率从0.001开始递减，批量大小为16。若验证误差在连续30步内收敛，则启用提前停止机制。代码可在**https://github.com/XDZhelheim/STAEformer**获取。

指标。我们在流量预测任务中采用三种常用指标：MAE（均方误差）、RMSE 和 MAPE 。基于既往研究方法，我们选取所有12个预测时段的平均性能表现。

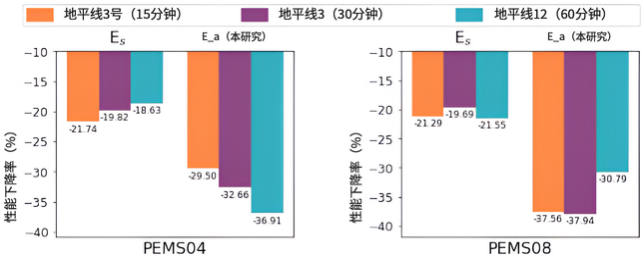


图3：通过沿时间轴对输入数据进行随机打乱，我们的时空自适应嵌入方法相较于空间嵌入显示出更显著的性能下降，这表明其在捕捉时序信息方面具有更强的能力。

PEMS03、PEMS04、PEMS07和PEMS08数据集。为评估METR-LA与PEMS -BAY数据集，我们比较了其在3分钟、6分钟和12分钟（15分钟、30分钟和60分钟）时间范围内的性能表现。

基线模型。本研究将我们提出的方法与该领域中几种广泛使用的基线模型进行比较。HI[6]是典型的传统模型。我们还考虑了 STGNNs，如 GWNet[34]、DCRNN[18]、AGCRN[1]、STGCN[37]、GTS[23]和 MTGNN[33]，这些模型采用了图1(a)所示的嵌入向量。此外，我们考察了专注于流量时间序列分解的STNorm[7]。虽然存在基于Transformer的时间序列预测方法，如Informer[42]、Pyraformer[19]、FEDformer[43]和Autoformer[32]，但它们并非专门针对短期流量预测设计。因此，我们选择了 GMAN[41]和PDFormer[13]，这些Transformer模型与我们的任务目标一致。图[41]和[13]中的输入嵌入向量遵循图1(b)所示配置。此外，我们考虑了STID[24]方法，该方法通过利用图1(c)所示的输入嵌入，增强了交通时间序列中的时空区分度。

4.2 性能赋值

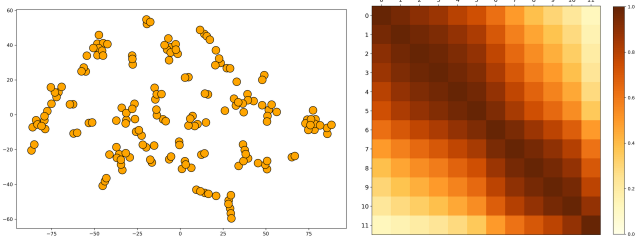
如表1和3所示，我们的方法在全部六个数据集上多数指标均表现出更优性能。STAEformer无需任何图模型即可显著超越STGNNs。STNorm和STID同样取得优异结果，而基于Transformer的模型能更精准捕捉复杂的时空关系。与PDFormer相比，这些令人鼓舞的结果表明STAEformer虽结构更简洁，但效果更为显著。

4.3 消融研究

为评估STAEformer中各组件的有效性，我们采用以下四种模型变体进行消融研究：

- **w/o** *Ea*。它移除了时空自适应嵌入*Ea*。
- **w/o** *EP*。该方法移除了周期性嵌入*EP*，包括星期几和日期时间戳嵌入。
- **无***T-Trans*。该方法移除了时间变换器层。
- **w/o** *ST-Trans*。该方法同时移除了时间变换器层和空间变换器层。

表4揭示了不同嵌入方式对模型性能的影响程度。E_p能够捕捉日度与周度模式，而提出的*Ea*对交通建模至关重要。此外，移除空间或时间变换器层后观察到的显著性能下降表明，我们提出的嵌入方式能有效建模固有的时空模式。



(a) 空间轴 (b) 时间轴

图4：时空自适应嵌入可视化在PEMS08上E_a的丁基化反应。

在交通数据中，因此需要同时利用空间层和时间层来提取这些特征。

4.4 案例研究

与空间嵌入的比较。为验证时空自适应嵌入在捕捉*T*输入帧中隐含的时间顺序信息的有效性，我们在PEMS04和PEMS08数据集上进行了更多实验。根据[38]的方法，我们沿时间轴*T*对原始输入进行随机打乱。作为对比，我们将时空自适应嵌入*Ea*替换为[13, 24]中使用的空间嵌入*Es*。如图3所示，当沿时间轴*T*打乱原始输入时，我们的模型性能下降更为显著。这意味着时空自适应嵌入*Ea*使模型对时间顺序更为敏感，而采用*Es*的模型则相对不敏感。综上所述，*Ea*能更好地建模原始输入中的时间顺序信息及其他复杂交通模式，这对任务至关重要。

时空自适应嵌入可视化。图4以PEMS08数据集为例，进一步展示了我们提出的时空嵌入*Ea*在空间和时间轴上的可视化效果。在空间轴上，我们采用t-SNE[28]得到图4a，显示不同节点的嵌入向量自然聚集成簇，这与交通数据的空间特征相符。在时间轴上，我们计算了12个输入帧间的相关系数并绘制热力图如图4b，表明各帧与相邻帧高度相关，且相关性随帧数递增逐渐降低。这证明我们提出的*Ea*模型能准确建模时间序列中的时序信息。

5 结论

本研究聚焦于交通时间序列预测中的基础表征学习技术——输入嵌入。我们提出了一种新型时空自适应嵌入方法，该方法基于基础Transformer架构即可在六个交通基准数据集上达到 SOTA 性能。后续研究表明，我们的模型能有效捕捉内在时空依赖关系。相较于设计复杂模型，本研究为解决交通预测难题指明了可行方向。

致谢

本研究部分由国家重大研究发展计划（2021YFB1714400）资助支持。

参考文献

[1] Lei Bai 、 Lina Yao 、 Can Li 、 Xianzhi Wang 和 Can Wang . 2020. 用于交通预测的自适应图卷积循环网络. *神经信息处理系统进展* 33(2020), 17804–17815.

[2] 曹德夫、王宇静、段娟勇、张策、朱霞、黄聪睿、童云海、徐必雄、白静、童杰等. 2020. 多变量时间序列预测的光谱时序图神经网络. *神经信息处理系统进展*33(2020)，17766–17778.

[3] Yuzhou Chen 、 Ignacio Segovia-Dominguez 与 Yulia R. Gel 。2021年。Z-GCNETs：用于时间序列预测的图卷积网络中的时间锯齿结构。发表于*ICML*。

[4] Razvan- Gabriel Cirstea 、 Tung Kieu 、 Chenjuan Guo 、 Bin Yang 和 Sinno Jialin Pan. 2021. EnhanceNet：用于增强相关时间序列预测的插件神经网络. 在*2021 IEEE第37届国际数据工程会议（ICDE）*上. IEEE，1739–1750.

[5] Razvan- Gabriel Cirstea 、 Bin Yang 、 Chenjuan Guo 、 Tung Kieu 和 Shirui Pan . 2022. 基于时空感知的交通时间序列预测——完整版.*arXiv预印本 arXiv:2203.15737*(2022).

[6] Yue Cui 、 Jiandong Xie 与 Kai Zheng 。2021年。历史惯性：长期序列时间序列预测中被忽视但具有强大作用的基准模型。收录于*第30届ACM国际信息与知识管理会议论文集*，第2965–2969页。

[7] Jinliang Deng 、 Xiusi Chen 、 Renhe Jiang 、 Xuan Song 和Ivor W Tsang. 2021. Stnorm：多变量时间序列预测中的空间与时间归一化方法. 收录于*第27届ACM SIGKDD 知识发现与数据挖掘会议论文集* . 269–278页。

[8] Zulong Diao 、 Xin Wang 、 Dafang Zhang 、 Yingru Liu 、 Kun Xie 和 Shaoyao He 。2019年。动态时空图卷积神经网络在交通预测中的应用。收录于*AAAI人工智能会议论文集* 第33卷，第890–897页。

[9] Zheng Fang 、 Qingqing Long 、 Guojie Song 与 Kunqing Xie 。2021年。用于交通流量预测的空间时间图常微分方程网络。收录于*第27届ACM SIGKDD 知识发现与数据挖掘会议论文集*，第364–373页。

[10] Kan Guo 、 Yongli Hu 、 Yanfeng Sun 、 Sean Qian 、 Junbin Gao 和 Baocai Yin 。2021年。用于交通预测的层次图卷积网络。收录于*AAAI人工智能会议论文集* 第35卷，第151–159页。

[11] Shengnan Guo 、 Youfang Lin 、 Ning Feng 、 Chao Song 和 Huaiyu Wan 。2019年。基于注意力机制的空间-时间图卷积网络在交通流量预测中的应用。收录于*AAAI人工智能会议论文集* 第33卷，第922–929页。

[12] Liangzhe Han 、 Bowen Du 、 Leilei Sun 、 Yanjie Fu 、 Yisheng Lv 和 Hui Xiong 。2021年。动态多维时空深度学习在交通速度预测中的应用。收录于*第27届ACM SIGKDD 知识发现与数据挖掘会议论文集*，第547–555页。

[13] Jiawei Jiang 、 Chengkai Han 、 Wayne Xin 赵和 Jingyuan Wang . 2023. PDFormer：传播延迟感知型动态长距离Transformer用于交通流量预测. 在*AAAI*. AAAI Press.

[14] Renhe Jiang 、 Zhaonan Wang 、 Jiawei Yong 、 Puneet Jeph 、 Quanjun Chen 、 Yasumasa Kobayashi 、 Xuan Song 、 Shintaro Fukushima 和 Toyotaro Suzumura 。2023年。时空元图学习在交通预测中的应用。收录于*AAAI人工智能会议论文集* 第37卷，第8078–8086页。

[15] Renhe Jiang，Du Yin，Zhaonan Wang，Yizhuo Wang，Jiewen Deng，Hangchen Liu，Zekun Cai，Jinliang Deng，Xuan Song， 与 Ryosuke Shibasaki . 2021. Dl-traf：城市交通预测深度学习模型的调查与基准测试. 收录于*第30届ACM信息与知识管理国际会议论文集* . 4515–4525.

[16] Hyunwook Lee 、 Seungmin Jin 、 Hyeshin Chu 、 Hongkyu Lim 和 Sungahn Ko 。2022年。《学习记忆模式：用于交通预测的模式匹配记忆网络》。收录于*国际学习表征会议* 。

[17] Mengzhang Li 与 Zhanxing Zhu . 2021. 时空融合图神经网络在交通流量预测中的应用. 收录于*美国人工智能协会（AAAI）人工智能会议论文集* 第35卷，第4189–4196页。

[18] Yaguang Li 、 Rose Yu 、 Cyrus Shahabi 和 Yan Liu . 2018. 扩散卷积循环神经网络：数据驱动的交通预测. 在*国际学习表征会议* 上发表。

[19] Shizhan Liu 、 Hang Yu 、 Cong Liao 、 Jianguo Li 、 Weiyao Lin 、 AlexXLiu和 Schahram Dustdar . 2021. Pyraformer：用于长时序建模与预测的低复杂度金字塔注意力机制. 在*国际学习表征会议* 上发表。

[20] Bin Lu 、 Xiaoying Gan 、 Haiming Jin 、 Luoyi Fu 和 Haisong Zhang 。2020年。用于城市交通流量预测的时空自适应门控图卷积网络。收录于*第29届ACM国际信息与知识管理会议论文集*，第1025–1034页。

[21] Zheyi Pan 、 Songyu Ke 、 Xiaodu Yang 、 Yuxuan Liang 、 Yong Yu 、 Junbo Zhang 和 Yu Zheng 。2021年。AutoSTG：用于时空图预测的神经架构搜索。收录于*Web会议2021论文集*，第1846–1855页。

[22] Zheyi Pan 、 Yuxuan Liang 、 Weifeng Wang 、 Yong Yu 、 Yu Zheng 和 Junbo Zhang 。2019年。基于时空数据的深度元学习方法在城市交通预测中的应用。收录于*第25届ACM SIGKDD 国际知识发现与数据挖掘会议论文集*，第1720–1730页。

[23] Chao Shang 、 Jie Chen 与 Jinbo Bi 。2021年。离散图结构学习在多时间序列预测中的应用。收录于*国际学习表征会议* 。

[24] Zezhi Shao 、 Zhao Zhang 、 Fei Wang 、 Wei Wei 和 Yongjun Xu 。2022年。时空身份：多变量时间序列预测的简单而有效的基线方法。收录于*第31届ACM国际信息与知识管理会议论文集*，第4454–4458页。

[25] Zezhi Shao 、 Zhao Zhang 、 Fei Wang 和 Yongjun Xu . 2022. 基于预训练增强的空间-时间图神经网络在多变量时间序列预测中的应用. 收录于*第28届ACM SIGKDD 知识发现与数据挖掘会议论文集* . 1567–1577.

[26] Zezhi Shao 、 Zhao Zhang 、 Wei Wei 、 Fei Wang 、 Yongjun Xu 、 Xin Cao 和Christian S Jensen. 2022. 用于交通预测的解耦动态时空图神经网络. *VLDB 基金会议论文集* 15卷，11期(2022年)，2733–2746页。

[27] Chao Song 、 Youfang Lin 、 Shengnan Guo 和 Huaiyu Wan . 2020. 空时同步图卷积网络：一种用于时空网络数据预测的新框架. 收录于*AAAI人工智能会议论文集* 第34卷，第914–921页。

[28] Laurens Van Maaten和 Geofrey Hinton . 2008. 使用t-SNE进行数据可视化。*机器学习研究杂志*9,11 (2008).

[29] Ashish Vaswani 、 Noam Shazeer 、 Niki Parmar 、 Jakob Uszkoreit 、 Llion Jones 、AidanN.Gomez、 Łukasz Kaiser和 Illia Polosukhin .2017.注意力就是你需要的一切。*神经信息处理系统研究进展*30(2017).

[30] Chunnan Wang 、 Kaixin Zhang 、 Hongzhi Wang 和 Bozhou Chen 。2022年。AutoSTGCN：自主时空图卷积网络搜索。*ACM数据知识发现汇刊*（2022年）。

[31] Xiaoyang Wang 、 Yao Ma 、 Yiqi Wang 、 Wei Jin 、 Xin Wang 、 Jiliang Tang 、 Caiyan Jia 和 Jian Yu 。2020年。基于时空图神经网络的交通流量预测。收录于*2020年网络会议论文集*，第1082–1092页。

[32] Haixu Wu 、 Jiehui Xu 、 Jianmin Wang 和 Mingsheng Long . 2021. 自适应分解变换器：用于长期序列预测的自相关分解变换器。*神经信息处理系统进展* 34 (2021)，22419–22430.

[33] Zonghan Wu 、 Shirui Pan 、 Guodong Long 、 Jing Jiang 、 Xiaojun Chang 和 Chengqi Zhang 。2020年。连接数据点：基于图神经网络的多元时间序列预测。收录于*第26届ACM SIGKDD 国际知识发现与数据挖掘会议论文集*，第753–763页。

[34] Zonghan Wu 、 Shirui Pan 、 Guodong Long 、 Jing Jiang 和 Chengqi Zhang 。2019年。用于深度时空图建模的图波网。收录于*第28届国际人工智能联合会议论文集*，第1907–1913页。

[35] Mingxing Xu 、 Wenrui Dai 、 Chunmiao Liu 、 Xing Gao 、 Weiyao Lin 、 Guo- Jun Qi 和 Hongkai Xiong . 2020. 用于交通流量预测的空间-时间变换器网络.*arXiv预印本 arXiv:2001.02908*(2020).

[36] Junchen Ye 、 Leilei Sun 、 Bowen Du 、 Yanjie Fu 和 Hui Xiong 。2021年。耦合分层图卷积用于交通需求预测。收录于*AAAI人工智能会议论文集* 第35卷，第4617–4625页。

[37] Bing Yu 、 Haoteng Yin 和 Zhanxing Zhu . 2018. 空时图卷积网络：一种用于交通预测的深度学习框架. 收录于*第27届国际人工智能联合会议论文集* . 3634–3640页。

[38] Ailing Zeng 、 Muxi Chen 、 Lei Zhang 和 Qiang Xu 。2023年。《变形金刚算法在时间序列预测中的有效性研究》*《AAAI人工智能会议论文集》*。

[39] Qi Zhang 、 Jianlong Chang 、 Gaofeng Meng 、 Shiming Xiang 和 Chunhong Pan 。2020年。时空图结构学习在交通预测中的应用。收录于*AAAI人工智能会议论文集* 第34卷，第1177–1185页。

[40] Ling Zhao 、 Yujiao Song 、 Chao Zhang 、 Yu Liu 、 Pu Wang 、 Tao Lin 、 Min Deng 和 Haifeng Li 。2019年。T-gcn：一种用于交通预测的时间图卷积网络。*IEEE智能交通系统汇刊*21卷9期（2019年），3848–3858页。

[41] Chuanpan Zheng 、 Xiaoliang Fan 、 Cheng Wang 和 Jianzhong Qi 。2020年。Gman：一种用于交通预测的图多注意力网络。收录于*AAAI人工智能会议论文集*，第34卷，1234–1241页。

[42] Haoyi Zhou 、 Shanghang Zhang 、 Jieqi Peng 、 Shuai Zhang 、 Jianxin Li 、 Hui Xiong 和 Wancai Zhang 。2021年。信息提供者：超越高效变换器在长序列时间序列预测中的应用。收录于*AAAI人工智能会议论文集* 第35卷，第11106–11115页。

[43] Tian Zhou 、 Ziqing Ma 、 Qingsong Wen 、 Xue Wang 、 Liang Sun 和 Rong Jin 。2022年。Fedformer：用于长期序列预测的频率增强分解变换器。在*国际机器学习会议* 上。 PMLR ，27268–27286。