报告定位

- 聚焦交通流预测任务中的时空依赖建模问题
- 从方法对比、模型结构、关键创新和实验结果展开
- 目标是给出“为什么选它、它怎么做、效果是否成立”的完整论证

关键词

Transformer

时空建模

自适应嵌入

多步预测

汇报目录

研究背景与问题定义

方法调研与模型选型

模型结构与关键机制

实验设置与结果分析

总结

研究背景与问题定义

研究背景：为什么要做交通流预测

任务背景

- 交通流预测是智能交通系统的核心关键技术，直接支撑精细化管控、动态路径规划和出行时间估计
- 随着城市路网规模持续扩大，拥堵频发、效率下降等问题使高精度预测成为现实刚需
- 该任务本质上属于典型时空序列预测，需要同时处理历史依赖、节点关联和外部扰动

应用价值

- 为智能信号配时、诱导发布和拥堵预警提供前置决策依据
- 可预测流量、速度、占有率等关键交通状态量
- 兼具学术价值与工程部署意义，适合作为课程大作业研究对象

多节点
路网级联合预测

多步长
未来连续时刻输出

多因素
时间与空间共同作用

任务定义与评价目标

预测任务定义

给定历史观测序列

$$X \in \mathbb{R}^{B \times T_{in} \times N \times C},$$

其中 B 表示 batch，T_{in} 表示历史时间步，N 表示传感器节点数，C 表示输入特征维度；模型输出未来多步预测

$$\hat{Y} \in \mathbb{R}^{B \times T_{out} \times N \times 1}.$$

核心挑战

空间依赖复杂、时间模式多尺度、突发事件频繁，使得交通流预测必须同时具备精度、鲁棒性和可部署性。

评价目标

- MAE：绝对误差，直观反映预测偏差
- RMSE：对大误差更敏感
- MAPE：便于衡量相对误差

理想模型应满足

- 准确率高
- 参数规模合理
- 训练稳定、易复现
- 对不同数据集有较好泛化性

研究目标与章节安排

研究目标

1. 调研统计学习、RNN、GNN 与 Transformer 系列方法的发展脉络
2. 以 STAEformer 为核心对象分析其嵌入机制、编码结构与预测流程
3. 基于公开数据集完成模型复现，并用 MAE / RMSE / MAPE 验证结果
4. 从长序列、异常事件、计算成本和外部因素建模等角度分析不足
5. 在复现基础上提出改进模块，为后续研究提供可落地方向

报告主线



一句话概括

本次汇报采用“复现 - 分析 - 改进”的完整研究思路，而不是只介绍论文结论。

方法调研与模型选型

主流方法对比

方法类别	代表模型	时间建模	空间建模	主要局限
CNN 类	TCN / STGCN	局部卷积	依赖预定义图	感受野有限，长依赖建模不充分
RNN 类	LSTM / GRU	递归记忆	弱或间接建模	串行计算，长序列训练效率低
GNN 类	DCRNN / Graph WaveNet	较强	显式图传播	需要图结构或复杂传播机制
Transformer 类	GMAN / ASTTN / STAEformer	全局注意力	可学习或分离建模	需控制计算复杂度

选择 Transformer 路线的原因

- 更擅长捕获长程依赖，适合多步交通预测
- 并行计算友好，训练效率优于纯 RNN 结构
- 模型表达能力强，便于统一时间和空间信息

选型结论

长程依赖　并行训练　结构清晰

STAEformer 同时兼顾效果、结构简洁性和复现可行性，因此被选为本次分析对象。

为什么选择 STAEformer

模型优势

1. 不强依赖人工构造图结构，降低先验设计负担
2. 将时空注意力拆分，缓解直接联合注意力带来的高复杂度
3. 自适应嵌入可以直接学习“节点-时间”级别的表示
4. 结构比较清晰，便于解释模型每个模块的功能

适合作业汇报的原因

- 既有理论亮点
- 又能清楚展示代码实现
- 实验结果易于量化呈现

一句话概括

STAEformer 的核心思路是：用可学习嵌入替代固定图先验，用时空分离注意力提高效率。

选题模型概述

STAEformer 的核心思想

STAEformer 全称为 **Spatio-Temporal Adaptive Embedding Transformer**。其设计重点不是堆叠复杂模块，而是先构造高质量时空表示，再交给较简洁的 Transformer 骨干完成建模。

与常见复杂模型的区别

- 不强调图卷积、门控模块和多分支结构的反复叠加
- 更强调“高质量时空表示 + 简洁骨干”的范式
- 通过统一嵌入将空间依赖与时间动态隐式融合到同一特征空间

模型定位

- 预测精度高
- 结构规整清晰
- 实现难度可控
- 复现与部署友好

结论

借助高质量前期嵌入，Vanilla Transformer 也能有效建模复杂交通时空依赖，并实现较好的性能与工程平衡。

模型结构与关键机制

STAEformer 整体框架



输入输出维度

历史输入通常为 $(B,12,N,3)$，未来输出为 $(B,12,N,1)$，适用于多节点、多步长预测场景。

结构特点

模型主干保持简洁，把复杂性集中在“嵌入设计”和“注意力分解”上，解释性较好。

关键创新一：时空自适应嵌入

嵌入组成

嵌入类型	维度	作用
Input Embedding	24	原始特征映射
ToD Embedding	24	时间片信息编码
DoW Embedding	24	星期模式编码
Adaptive Embedding	80	节点-时间联合表示
总维度	152	统一输入表示

设计意义

- 不再完全依赖静态邻接矩阵
- 让模型自行学习不同节点在不同时间片的潜在关系
- 提升对复杂交通模式的表达能力

直观理解

固定图结构刻画的是“谁和谁可能相关”，自适应嵌入更进一步学习“在什么时间、相关到什么程度”。

自适应嵌入与图神经网络对比

方面	图神经网络	STAEformer	说明
图结构依赖	需要预定义邻接矩阵	不需要	减轻图先验设计负担
空间建模方式	基于图结构稀疏连接	全连接自适应关系	更偏数据驱动
灵活性	受固定图结构约束	可学习节点-时间表示	对复杂关联更灵活
复杂度	$\mathcal{O}(E \times D)$	$\mathcal{O}(N^2 \times D)$	大规模路网下需关注开销

优势

不需要手工给定固定图结构，能够从数据中直接学习潜在时空关系。

代价

当节点数增大时，空间注意力复杂度仍然较高，这也是后续改进的重要出发点。

关键创新二：时空分离注意力

核心思路

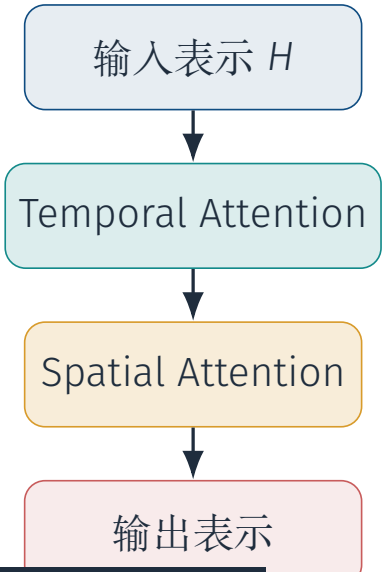
如果直接对 $(T \times N)$ 个时空 token 做联合注意力，计算和显存开销会迅速增大。STAEformer 将其拆分为：

- 先沿时间维度做 Temporal Attention
- 再沿空间维度做 Spatial Attention

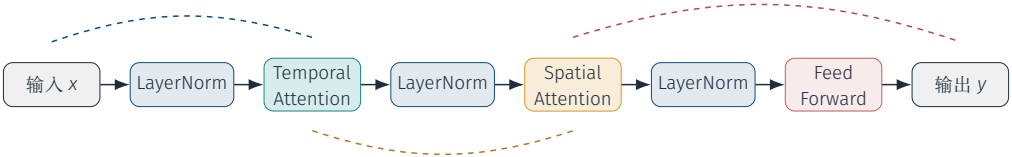
这样在保留建模能力的同时，能显著降低复杂度。

复杂度对比

联合时空注意力约为 $\mathcal{O}((TN)^2)$，分离后可近似写作 $\mathcal{O}(T^2 + N^2)$，更适合实际训练。



STAE Layer 内部结构



模块理解

一个 STAE Layer 可以看成“归一化 + 时间建模 + 空间建模 + 非线性映射”的串联模块，多层堆叠后逐步提升时空表征能力。

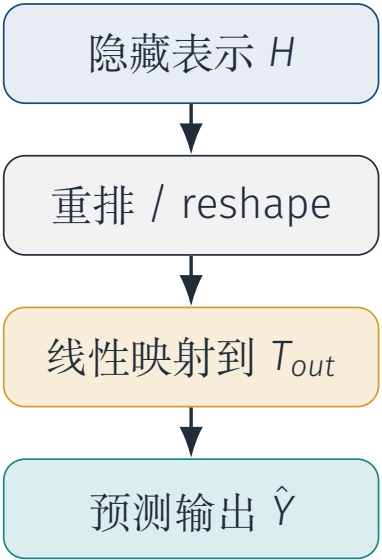
输出层：Mixed Projection 的作用

为什么不用逐步自回归输出

传统逐步预测往往误差会累积，而 Mixed Projection 直接将隐藏表示映射为未来多个时间步，能够更稳定地完成多步预测。

优势

- 端到端输出未来序列
- 减少滚动预测带来的误差传播
- 结构简单，和主干模块衔接自然



实验设置与结果分析

实验设计与评价指标

实验设计

- 使用公开交通数据集开展复现实验，核心验证模型短时多步预测能力
- 通过定量指标、定性曲线和工程开销三条线共同评价模型
- 在复现 STAEformer 基线后，再引入改进模块做横向对比

结果分析维度

- 定量分析：MAE / RMSE / MAPE 的整体对比
- 定性分析：高峰期、平峰期与突变点的拟合表现
- 工程分析：参数量、显存占用、训练耗时和推理速度

指标说明

- MAE：整体偏差越小越好
- RMSE：更关注极端误差
- MAPE：便于跨模型跨数据集比较

预期验证结论

STAEformer 应在短时预测精度、收敛效率和结构简洁性上体现较强综合优势。

实验配置概览

主要超参数

参数	取值
num_nodes	207
in_steps / out_steps	12 / 12
input_dim / output_dim	3 / 1
model_dim	152
num_heads	4
num_layers	3
feed_forward_dim	256
adaptive_embedding_dim	80

配置特点

- 模型容量适中
- 不依赖超大显存即可训练
- 结构设计与论文实现保持一致

说明

207 节点　3 层编码　4 头注意力

这类配置适合课程作业场景，既有研究价值，也具有较强可复现性。

模型复现：当前已完成内容

基线复现进展

- 已完成 STAEformer 基线训练脚本梳理与参数核对
- 本地改进实验框架已搭建，包含 Baseline、EFF、DGL、LA、MST 五类模型
- 当前仓库中已有 **PEMS08** 基线训练日志，可确认数据划分、模型参数量和训练入口已跑通

PEMS08 已确认信息

Train: 10700，Val: 3567，Test: 3566；输入窗口 12，输出窗口 12；总参数量 **1,223,460**。

已完成证据

- `baseline_PEMS08_train.log`
- `train_baseline.py`
- `train.py`
- 各改进模型 `model.py`

说明

目前仓库里尚未生成各模型完整 `json` 结果文件，因此本页只展示已确认复现数据，不虚构最终误差指标。

复现实验数据与工程信息

数据集	节点数	采样间隔	输入/输出步长	本地已确认信息	备注
PEMS08	170	5 min	12 / 12	Train 10700 / Val 3567 / Test 3566	已有训练日志
METR-LA	207	5 min	12 / 12	参数配置已整理	待补复现结果
PEMS-BAY	325	5 min	12 / 12	参数配置已整理	待补复现结果

工程侧观察

STAEformer 基线在 PEMS08 上参数量约 1.22M，属于较易复现、便于后续做模块化改进的骨干模型。

汇报建议

口头说明时可强调：本次作业不是停留在阅读论文，而是已经把复现入口、配置和改进框架都搭了起来。

复现结果展示页设计

基线模型结果表

模型	MAE	RMSE	MAPE
STAEformer Baseline	待补	待补	待补

当前状态

由于结果 `json` 尚未生成，误差指标位先留作实验完成后的填充位置；表格结构已经留好，可直接替换。

本页建议讲法

- 先说明复现环境、数据集和训练配置
- 再展示基线误差指标与训练开销
- 最后引出“为什么还需要做改进”

过渡作用

这一页的重点是把“复现成功”与“继续优化”顺畅衔接起来。

结果解读：模型表现为什么更好

性能优势来源

- 自适应嵌入提高了对复杂空间关系的表达能力
- 分离注意力兼顾了时间依赖和空间依赖
- 多步直接预测减少了误差累积
- 结构清晰，训练过程中更稳定

实验汇报可强调的观察

- 短时预测和中时预测都保持较好精度
- 在多节点路网场景中泛化性更强
- 相较传统图模型，对图先验依赖更弱
- 在效果和实现复杂度之间取得更好平衡

答辩表达建议

如果老师更关注“你做了什么”，这一页可以口头补充：代码复现、参数理解、模块拆解、误差指标对比和模型优缺点分析。

模型不足与问题定位

当前局限

- 长序列预测场景下误差仍可能逐步积累
- 极端突发事件下仍可能预测失稳
- 自适应嵌入可解释性仍然有限
- 大规模路网下空间注意力计算成本较高

后续优化方向

- 融合天气、事件、节假日等外部因素
- 引入动态图或在线更新机制增强空间依赖刻画
- 使用轻量化注意力降低大图计算开销
- 采用多尺度时间建模提升长周期建模能力

总结判断

STAEformer 不是简单地“把 Transformer 用在交通预测上”，而是围绕交通数据的时空特性做了结构化改造，因此更适合作为课程汇报中的重点分析对象。

改进方案设计

改进方案总览

四类改进模块

1. **EFF**：外部特征融合，引入天气、节假日、道路事件等信息
2. **DGL**：动态图结构学习，增强节点间动态空间依赖建模
3. **LA**：轻量化注意力，降低大规模路网下的计算开销
4. **MST**：多尺度时间建模，联合建模短期、日周期和周周期

总体原则

在不破坏 STAEformer “高质量时空表示 + 简洁 Transformer 骨干”设计范式的前提下，采用模块化方式嵌入改进组件。

改进目标

- 更强异常场景适应能力
- 更灵活的空间依赖建模
- 更低推理成本
- 更稳的长序列预测表现

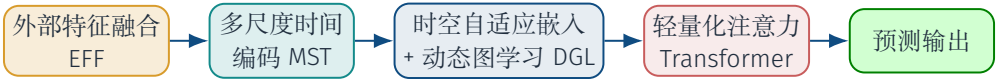
四类改进模块的实现思路

简称	改进方向	实现要点	主要收益
EFF	外部特征融合	将天气、节假日、事件等特征编码后与原始交通状态共同输入嵌入层	强化异常场景鲁棒性
DGL	动态图学习	基于实时交通状态动态生成邻接关系或图结构表示	增强空间依赖灵活性
LA	轻量化注意力	用稀疏、线性或分块注意力替代稠密注意力	降低复杂度与推理成本
MST	多尺度时间建模	分别编码短期、日周期、周周期信息后再做特征融合	提升长时预测稳定性

实现方式

改进模块均已在 ‘improvements/‘ 目录中建立独立实现入口，便于和基线模型做公平对比。

改进后的整体实现思路



设计原则

输入端新增外部特征融合与多尺度时间编码，嵌入层增强动态空间关系学习，编码层用轻量化注意力替代稠密注意力，输出层保持不变。

改进结果与对比

改进实验结果表设计

模型对比表

模型	MAE	RMSE	MAPE	参数量	推理
Baseline	待补	待补	待补	1.22M	待补
EFF	待补	待补	待补	∼1.3M	待补
DGL	待补	待补	待补	∼1.4M	待补
LA	待补	待补	待补	∼1.2M	待补
MST	待补	待补	待补	∼1.3M	待补

本页用途

- 用于展示最终实验结果
- 当前参数量可先填入工程估计值
- 指标结果待 `results/*.json` 生成后补齐

结论模板

可以按“谁精度最好、谁速度最快、谁最适合部署”三个角度总结改进效果。

改进结果的分析口径

若结果显示 EFF 最优

说明外部因素确实对异常场景和高波动时段具有显著补充作用。

若结果显示 LA 最快

说明轻量化注意力在大规模路网部署中更具工程价值。

若结果显示 DGL 最优

说明静态嵌入之外，动态空间结构学习对复杂路网建模仍有增益。

若结果显示 MST 更稳

说明多尺度时间编码有助于提升长时依赖建模和长序列预测稳定性。

答辩建议

如果最终只跑出部分实验，也可以明确说明：已完成基线复现，改进模型框架已实现，当前重点展示的是设计逻辑、对比框架与可补充的结果页。

总结

谢谢观看