西南交通大學
Southwest Jiaotong University

《视觉计算》课程设计报告

设计题目： 面向单图像超分辨率的轻量 IMDN 复现与结构损失消融研究

组　　号： 2023112621、2023114337、2023114956

成员姓名： 程泽凯、王晨羽、金井直

班　　级： 计算机 2023 级 04 班

指导教师： 袁召全　　老师

2026 年 5 月 17 日

《视觉计算》课程设计任务书

设计题目	面向单图像超分辨率的轻量 **IMDN** 复现与结构损失消融研究	成绩	
课程设计主要内容	针对计算机视觉领域某一特定问题，例如：目标检测、人脸识别、图像分割、图像生成等，查阅国内外近 5 年来相关技术资料，选择 3 篇以上具有代表性论文进行深入阅读，分析并理解其原理和方法。撰写一篇不少于 4000 字的课程设计报告，对相关论文的理论原理及算法进行阐述，对其中的方法动手搭建模型（建议基于 MindSpore），编写程序复现实验结果，进行对比分析，给出结论。鼓励提出一定的改良措施，完成实验（建议基于华为 MindSpore）。 课程设计以组队的形成开展，每组 2-3 人，自行组队，报告中明确每个人的分工。报告使用老师提供的 latex 模版，编译方式选 XeLatex。模版已写好第一至第六章的目录，尽量按照该目录撰写报告。		
指导教师评语	建议：从学生的工作态度、工作量、设计（论文）的创造性、学术性、实用性及书面表达能力等方面给出评价。 签名：　　年　　月　　日		

目录

一、团队成员分工 **1**

二、课程考核要点对应关系 **1**

三、引言 **2**

四、相关工作 **3**

4.1 卷积重建与轻量级模型 3

4.2 Transformer 超分辨率模型 3

4.3 状态空间模型超分辨率方法 4

4.4 GAN 与真实退化超分 4

4.5 扩散先验与生成式超分 4

4.6 代表性论文深入阅读补充 5

五、数据集与实验设置 **7**

5.1 DIV2K 数据集 7

5.2 实现环境 7

5.3 训练配置 7

5.4 复现实验流程 8

5.5 评价指标 10

六、方法设计与实现 **10**

6.1 总体流程 10

6.2 SRCNN 基线 10

6.3 IMDN 主模型 11

6.4 CA-IMDN 注意力改进分支 11

6.5 边缘损失 13

6.6 二阶拉普拉斯结构损失 14

七、已有工作与本文工作边界 **15**

7.1 已有工作 15

7.2 本文复现内容 15

7.3 原始 IMDN 与本文实现差异 16

7.4 本文探索性创新点 16

八、实验结果与分析 **17**
8.1 训练过程 17
8.2 Bicubic、SRCNN 与 IMDN 总体比较 19
8.3 长训实验 21
8.4 注意力、模型容量与学习率消融 22
8.5 标准 benchmark 正式评估 25
8.6 自集成推理增强与 IDB-IMDN-Lite 复现接口 26
8.7 感知质量指标 30
8.8 局部样例分析 31
8.9 结构损失消融分析 33
8.10结果讨论 35
8.11可靠性与局限性 35
8.12下一步实验规划 36
九、结论 **36**
参考文献 **37**

摘要

单图像超分辨率旨在从低分辨率图像中恢复高分辨率细节，是计算机视觉中的典型低层视觉任务。近年来，该方向从卷积重建模型、轻量化网络逐步发展到 Transformer、生成对抗网络和扩散生成模型。考虑到课程设计的算力条件和复现实验要求，本文选取轻量级 IMDN 模型作为主要实现对象，在 MindSpore 框架下完成 $\times 2$ 超分辨率训练、推理与评估流程，并将 GAN、扩散模型和状态空间模型作为相关工作对照。实验基于 DIV2K 数据集开展，其中训练集包含 800 张图像，验证集包含 100 张图像。补充实验包括 SRCNN 20 epoch 公平基线、通道注意力 CA-IMDN、模型宽度与深度消融、学习率调度、可配置边缘损失权重、二阶拉普拉斯结构损失和 20/50 epoch 长训实验。结果表明，短轮次训练下的 IMDN 尚未超过 Bicubic，延长训练后性能明显提升：Bicubic 在验证集上取得 32.4735 dB / 0.9860 的平均 PSNR/SSIM，IMDN without Edge Loss 在 20 epoch 时取得 33.4615 dB / 0.9893，在 50 epoch 最优推理结果中取得 34.2122 dB / 0.9906，较 Bicubic 分别提升 0.9880 dB 和 1.7387 dB。扩展实验中，SRCNN 20 epoch 达到 33.2857 dB，表明浅层基线在充分训练后同样可超过 Bicubic；IMDN width48 20 epoch 达到 33.6560 dB，CA-IMDN + Edge Loss 20 epoch 达到 33.6396 dB，表明增加模型容量和引入通道注意力可以提供有效补充，但仍未超过 50 epoch no-edge IMDN。本文进一步在 Set5、Set14、BSD100 和 Urban100 上补充标准 benchmark，并加入 LPIPS/NIQE 感知指标，使评价结果覆盖主验证集、标准测试集和感知质量三个层面。实验结果表明，充分训练对轻量超分模型具有关键影响；结构损失和注意力模块在当前设置下具有探索价值，但其收益依赖权重、训练轮数和 checkpoint 选择。

关键词：图像超分辨率；IMDN；MindSpore；DIV2K；Bicubic；结构损失

一、 团队成员分工

- 成员 1 王晨羽：负责文献检索、近年方法综述与相关工作改写。
- 成员 2 程泽凯：负责 MindSpore 代码实现、训练推理流程搭建、消融配置与测试验证。
- 成员 3 金井直：负责实验结果整理、图表生成、报告结构优化与 LaTeX 排版整合。

二、 课程考核要点对应关系

表 1 整理了本文内容与课程设计六项考核要点之间的对应关系。该表用于说明报告结构安排，不作为实验结果。

表 1　课程设计六项考核要点与本文内容对应关系

考核要点	本文对应内容
逻辑清晰、图文并茂	按照引言、相关工作、数据集、方法、实验、消融、局限和结论组织；概念示意图用于解释流程，真实曲线和 CSV 指标用于支撑实验结论。
选题新颖、近年文献	在 SRCNN、IMDN、ESRGAN、SR3 基础上补充 SwinIR、Real-ESRGAN、HAT、DiffIR、StableSR 和 MambaIR 等 2021–2024 年代表性工作。
实验过程详细	给出训练、推理、评估、图表生成命令，并保存 checkpoint、CSV、预测图像和可复查的可视化结果。
算法理解透彻	分析卷积重建、信息蒸馏、Transformer 注意力、GAN 感知质量和扩散先验的差异。
自主改进与仿真	实现可配置边缘损失、二阶拉普拉斯结构损失、多 patch 采样和结构损失消融，报告成功与失败结果。
区分已有与创新	单独说明经典方法、本文复现内容、课程实现取舍和探索性创新点边界。

三、 引言

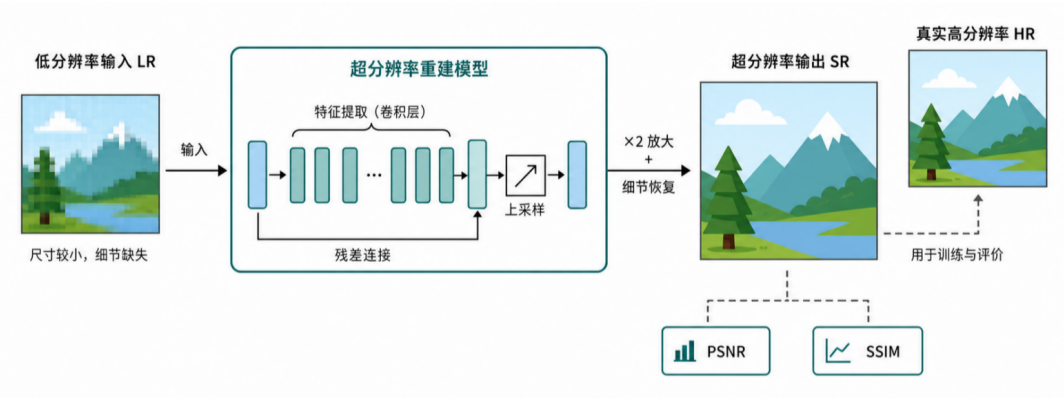


图 1　单图像超分辨率任务示意图。低分辨率输入经过超分辨率模型恢复为高分辨率输出，并与 **HR** 真值进行重建质量比较；该图用于说明本文研究任务的输入、输出与评价对象。

图像超分辨率（Super-Resolution, SR）研究的是如何从低分辨率输入中恢复高分辨率图像内容。该问题在医学影像增强、视频监控、遥感解译、历史图像修复以及移动摄影等场景中均具有实际价值。传统插值方法如最近邻、双线性和双三次插值实现简单、计算代价低，但由于缺乏对高频纹理的显式建模，往往只能得到边缘较平滑、细节较模糊的恢复结果。

深度学习的发展推动了超分辨率方法的快速更新。以 SRCNN 为代表的早期卷积模型证明了端到端学习映射关系的可行性 [3]；之后，以 IMDN 为代表的轻量网络开始关注参数量、推理成本和重建性能之间的平衡 [5]；在另一条技术路线中，ESRGAN 通过生成对抗学习显著提升了视觉感知质量 [11]；近年又出现了以 SR3 为代表的扩散式超分方法，在复杂细节生成方面展现出更高上限 [7]。总体来看，超分研究已经从以数值指标为主，逐步扩展到兼顾视觉观感与生成能力的综合评价阶段。

本文围绕“轻量 IMDN 复现与结构损失消融”展开。报告先梳理卷积重建、GAN 超分、扩散超分、Transformer 和状态空间模型等代表性方法，再以 IMDN 为主模型完成一套可复现的 MindSpore 实验流程，并将 Bicubic 作为传统基线进行比较。为保证结论可复查，本文同时报告短训阶段 IMDN 未在 PSNR 上超越 Bicubic 的结果，以及长训阶段 IMDN 稳定超过 Bicubic 的结果，并结合训练轮数、轻量配置和数据构造方式进行分析。

四、 相关工作

4.1 卷积重建与轻量级模型

SRCNN 是深度超分领域的经典起点。该方法先将低分辨率图像插值到目标大小，再通过三层卷积网络学习从模糊高分辨率输入到清晰高分辨率输出的映射关系 [3]。SRCNN 的意义在于证明端到端卷积映射能够替代手工插值后处理，但它的浅层结构难以充分建模复杂纹理，且先插值再卷积会在高分辨率空间中增加计算开销。

随着应用场景向移动端与边缘设备延伸，轻量模型逐渐成为重要方向。IMDN 的核心在于信息多蒸馏（Information Multi-Distillation）思想，即在特征提取过程中逐步筛选和保留更有效的通道信息，再通过特征融合提高整体恢复能力 [5]。原始 IMDN 中的蒸馏模块强调 split-and-fuse：一部分通道被保留为已提炼信息，另一部分继续经过卷积提取，从而减少冗余计算。本文实现的是适合课程项目条件的简化版本，保留多层特征提取、级联融合和残差连接思想，但没有完整复现原论文中更细的通道拆分结构，这一点在后文“已有工作与本文边界”中单独说明。

4.2 Transformer 超分辨率模型

近年来，Transformer 被广泛引入图像复原任务。SwinIR 使用 Swin Transformer 的窗口自注意力和层级特征表达构建性能较强的图像复原基线，在超分、去噪和压缩伪影去除等任务上展示了 Transformer 对长程依赖建模的优势 [6]。与卷积模型相比，Transformer 更适合捕获跨区域纹理关系，但计算和显存开销也更高。

HAT 进一步指出，窗口注意力虽然高效，但可能只激活有限范围内的像素信息。其 Hybrid Attention Transformer 将窗口自注意力与通道注意力结合，使更多输入像素参与

重建，从而提升高频细节恢复能力 [2]。相关研究表明，超分辨率模型的改进已不再局限于加深卷积网络，而是更加关注注意力范围、特征交互和信息利用效率。受限于本课设 CPU 环境，本文不直接复现 HAT，但在方法分析中借鉴其充分利用结构信息的思想。

4.3 状态空间模型超分辨率方法

2024 年，状态空间模型开始被引入图像复原任务。MambaIR 将选择性状态空间模型用于低层视觉恢复，并在标准 Mamba 结构中加入局部增强和通道注意力，以缓解低层视觉中的局部像素遗忘和通道冗余问题 [4]。与 Transformer 相比，这类方法试图以近似线性复杂度获得更大的有效感受野，为超分辨率中的长程纹理建模提供了新的方向。本文没有复现 MambaIR，但将其作为 2024 年代表性工作纳入文献综述，以反映超分辨率研究从卷积、Transformer 和扩散模型继续扩展到状态空间模型的趋势。

4.4 GAN 与真实退化超分

ESRGAN 代表了超分研究从“重建误差最小化”向“感知质量提升”转变的重要阶段。该方法通过 RRDB 结构增强生成器，并联合对抗损失与感知损失，使结果在纹理锐利度和视觉自然性方面明显优于传统重建模型 [11]。与 SRGAN 相比，ESRGAN 的主要变化包括去除批归一化以减轻伪影、使用残差密集连接提高特征复用效率、采用相对平均判别器增强真实/生成图像之间的相对判别信号，并使用感知特征约束改善纹理恢复。由此可见，GAN 超分并非简单加入判别器，而是通过生成器结构、判别方式和感知损失共同改变优化目标。不过，GAN 路线也存在训练不稳定、PSNR/SSIM 可能下降以及伪纹理风险等问题。

Real-ESRGAN 将 ESRGAN 扩展到盲超分场景，通过纯合成数据构造复杂真实退化过程，使模型能够处理真实图像中的模糊、噪声、压缩和振铃伪影 [10]。这表明超分辨率不仅包括标准 Bicubic 退化任务，也包括更复杂的真实退化建模。本文仍选择 DIV2K Bicubic $\times 2$ 作为主要实验场景，以保持训练和评价闭环可控。

4.5 扩散先验与生成式超分

扩散模型为超分辨率提供了新的生成建模方式。SR3 通过重复去噪与逐步细化的方式，在条件输入约束下恢复高分辨率图像，表现出较强的细节生成能力 [7]。从建模角度看，扩散超分通常先在前向过程中逐步向高分辨率图像加入噪声，再训练反向网络在低分辨率条件约束下预测去噪方向；推理时模型从噪声出发逐步恢复细节。该过程能够利用概率生成机制补充高频纹理，但也意味着推理需要多步迭代，训练成本和采样成本均显著高于轻量卷积模型。DiffIR 则从效率角度改进扩散式图像复原，引入紧凑先验提取和动态 Transformer，使扩散思想更接近实际图像复原任务 [13]。StableSR 进一步利用

预训练文本到图像扩散模型中的生成先验处理真实图像超分 [9]，体现了近年“借助大规模生成先验恢复细节”的趋势。

扩散和 GAN 方法通常更关注感知真实感，而 PSNR/SSIM 更偏向像素保真度。因此，单纯比较 PSNR 并不能完整评价生成式超分结果；LPIPS、NIQE、主观视觉对比等指标常被用作补充。受实现复杂度和运行成本限制，本文主要复现轻量重建模型，并将生成式方法作为文献分析和损失设计的启发来源。

表 **2**　代表性超分辨率方法对比

类型	代表方法	核心机制	优势	局限
卷积重建	SRCNN	插值后卷积映射	结构简单、适合作为基线	表达能力有限
轻量重建	IMDN	信息蒸馏与特征融合	参数少、易复现	感知质量一般
Transformer	SwinIR/HAT	窗口注意力、通道注意力	长程依赖建模强	训练成本较高
状态空间模型	MambaIR	选择性扫描、局部增强、通道注意力	兼顾长程建模与效率	低层视觉适配仍较新
GAN 超分	ESRGAN/Real-ESRGAN	对抗损失、真实退化建模	纹理较锐利、视觉较自然	可能产生伪纹理
扩散超分	SR3/DiffIR StableSR	条件去噪与生成先验	细节生成潜力高	推理和训练成本高

4.6 代表性论文深入阅读补充

为避免相关工作停留在方法罗列层面，本文进一步选取 SRCNN、IMDN、ESRGAN、HAT、SR3 和 MambaIR 六篇代表性论文作补充分析。选择这六篇的原因是它们分别覆盖端到端卷积重建、轻量化信息蒸馏、感知质量优化、Transformer 注意力、扩散式生成先验和状态空间模型等技术路线，能够较完整地反映单图像超分辨率方法的演进脉络。

SRCNN。　SRCNN 的贡献主要在于将传统“插值放大 + 手工特征 + 重建”的多阶段流程统一为端到端卷积学习框架 [3]。其三层卷积可分别对应 patch 表示提取、非线性映射和图像重建，结构简单但逻辑清晰。该论文表明，超分辨率可以被视为从低质量高分辨率空间到清晰高分辨率空间的函数拟合问题。不过，SRCNN 需要先将 LR 图像插值到 HR 尺寸，再在高分辨率空间卷积，计算量随目标尺寸增加而上升；同时，浅层结构缺乏足够感受野和层级表达能力，难以恢复复杂纹理。因此，本文将 SRCNN 作为教学基线，而不将其作为最终性能模型。

IMDN。 IMDN 面向轻量化超分场景，通过信息多蒸馏机制提高特征利用效率，而不单纯依赖参数规模扩张 [5]。原论文中的 Information Distillation Block 将通道划分为已蒸馏部分和继续处理部分，使网络逐步保留更有效的信息，并通过后续融合层整合多阶段特征。这种 split-and-fuse 思想与普通残差堆叠不同，它强调在每个模块内部进行信息筛选，而不是简单增加深度。本文实现的 IMDN 是课程级简化版本，保留了多层卷积、残差连接、特征拼接和融合思想，但没有完整复现原论文更细粒度的通道拆分与蒸馏比例设置。实验解释中需要说明这一差异，避免将简化实现的结果等同于原始 IMDN 的性能。

ESRGAN。 ESRGAN 的意义在于把超分辨率从单纯优化 PSNR 推向感知质量优化 [11]。其生成器采用 RRDB 结构，在残差密集连接基础上去除批归一化，以减轻超分结果中的伪影和训练不稳定；判别器使用相对平均判别思想，不只判断一张图像是否真实，而是比较真实图像相对于生成图像更真实的程度；感知损失则使用 VGG 特征约束，使网络更关注语义和纹理层面的相似性。该论文也揭示了一个重要矛盾：视觉上更锐利的结果未必具有更高 PSNR。本文没有实现 GAN 训练，是因为对抗学习需要更高算力和更复杂的稳定性调参，但边缘损失和拉普拉斯损失的设计动机部分来自 ESRGAN 对高频细节的重视。

HAT。 HAT 针对 Transformer 超分中的信息激活不足问题提出 Hybrid Attention Transformer[2]。SwinIR 等方法通过窗口注意力降低计算成本，但窗口划分也可能限制跨区域信息交互。HAT 将窗口自注意力与通道注意力结合，并强调激活更多输入像素参与重建，从而提升细节恢复能力。该论文对本文的启发主要体现在两个方面：一是注意力机制不应只被理解为“更强模型”，还应分析它具体增强了哪些特征交互；二是通道注意力可以作为轻量改进分支引入卷积网络。本文的 CA-IMDN 正是受这一路线启发，在不大幅增加参数量的前提下加入通道重标定，并通过 20 epoch、50 epoch 和学习率调度实验检验其效果。

SR3。 SR3 将超分辨率建模为条件扩散生成过程 [7]。与直接预测 HR 图像不同，扩散模型在前向过程中逐步向图像加入噪声，在反向过程中学习从噪声恢复清晰图像，并以 LR 图像作为条件约束。其优势在于可以生成更丰富的高频细节，尤其适合大倍率和真实感要求较高的超分场景；不足在于采样需要多步迭代，训练和推理成本显著高于轻量卷积模型。SR3 对本文的意义不在于直接复现，而在于提醒实验评价不能只依赖 PSNR/SSIM：生成式方法可能牺牲像素级误差，却获得更好的主观观感。因此，本文在实验部分补充 LPIPS 和 NIQE，并将人工主观评价作为后续可继续扩展的方向。

MambaIR。 MambaIR 代表 2024 年状态空间模型进入图像复原领域的新方向 [4]。其基本思路是利用选择性状态空间模型建模长程依赖，同时通过局部增强模块弥补纯序列建模对局部纹理敏感性不足的问题。与 Transformer 相比，状态空间模型在长序列建模上具有更好的复杂度潜力；与卷积模型相比，它又能覆盖更大范围的上下文信息。MambaIR 表明，超分辨率研究仍在探索长程建模能力与计算效率之间的平衡。本文没有实现该类模型，但将其纳入综述有助于体现近年研究进展，也说明本文轻量 IMDN 实验只是课程条件下的可复现基线，并不覆盖最新方法的性能上限。

五、 数据集与实验设置

5.1 DIV2K 数据集

本文实验采用 DIV2K 数据集 [1, 8]。DIV2K 是超分辨率领域的常用公开数据集，包含 800 张训练图像、100 张验证图像和 100 张测试图像，图像分辨率高、场景类型丰富，适合用于训练和评估单图像超分模型。按照官方 NTIRE 2017 设置，本文使用了 Track 1 中的 Bicubic $\times 2$ 任务作为实验场景，其数据访问入口为 DIV2K 官方页面[1]。

本次实验中，训练阶段使用 800 张 HR 图像，并通过双三次下采样在本地生成对应的 $\times 2$ LR 训练图像；验证阶段使用官方验证集 HR 图像及其对应的 Bicubic $\times 2$ LR 图像。该设置与课程项目中现有数据组织方式保持一致，也便于在代码中直接构建 LR/HR 成对样本。

5.2 实现环境

实验代码基于 MindSpore 2.8.0 实现，运行设备为 CPU。项目实现遵循“最小可运行闭环”的原则，包含训练、推理、评估和日志记录四个环节。训练脚本读取 YAML 配置构建模型、损失函数和优化器；推理脚本支持 Bicubic、SRCNN 和 IMDN 三种模式；评估脚本输出逐图像 PSNR/SSIM 以及平均指标。实际运行时，本文使用本机已配置的 MindSpore 2.8.0 Python 环境完成模型前向验证、训练、推理与评估，所有输出结果均保存为可复查的 checkpoint、CSV 指标文件和图像结果。

5.3 训练配置

为了兼顾课程时间和 CPU 运行成本，本文采用了较保守的轻量配置，具体如表 3 所示。该设置能够在较短时间内完成一个完整实验周期，适合课程设计阶段的快速验证。

[1] https://data.vision.ee.ethz.ch/cvl/DIV2K/

表 **3** **IMDN** 训练配置

项目	取值	说明
放大倍率	×2	与 DIV2K Track 1 设置一致
训练轮数	5（长训实验补充 20/50 epoch）	5 epoch 用于最小闭环验证，20/50 epoch 用于主结论对照
批大小	8	平衡内存与训练速度
Patch 大小	32	从 LR 图像随机裁剪
Patch 采样数	默认 1，可配置为 2 或更多	用于提高每张图像的训练覆盖度
特征通道数	32	轻量级 IMDN 宽度设置
学习率	2e-4	Adam 优化器默认设置
损失函数	L1、Edge Loss、Laplacian Loss	λ_e 与 λ_l 可通过 YAML 配置搜索
训练样本数	800	DIV2K train
验证样本数	100	DIV2K val

5.4 复现实验流程

为了保证实验结果可以被重新检查，本文将训练、推理和评估拆分为独立命令执行。主要命令如表 4 所示。Bicubic 不依赖 MindSpore 模型权重，可作为传统插值基线直接生成结果；SRCNN 和 IMDN 则先训练得到 checkpoint，再在同一验证集上统一推理和评估。

表 **4**　主要实验复现命令

环节	命令
前向验证	`python -m src.smoke_test_ms`
SRCNN 训练	`python -m src.train src/configs/srcnn_x2.yaml`
IMDN + Edge 训练	`python -m src.train src/configs/imdn_x2.yaml`
IMDN no-edge 训练	`python -m src.train src/configs/imdn_x2_no_edge.yaml`
IMDN no-edge 长训	`python -m src.train src/configs/imdn_x2_no_edge_50ep.yaml`
快速公平对照	`python -m src.train src/configs/srcnn_x2_fair_quick.yaml`
边缘权重消融	`python -m src.train src/configs/imdn_x2_edge_w001_quick.yaml`
拉普拉斯结构损失	`python -m src.train src/configs/imdn_x2_laplacian_quick.yaml`
Bicubic 推理	`python -m src.infer --model bicubic --scale 2 --input ./data/eval/LR --output ./results/bicubic_x2_eval`
SRCNN 推理	`python -m src.infer --model srcnn --scale 2 --checkpoint ./checkpoints/srcnn_x2.ckpt --input ./data/eval/LR --output ./results/srcnn_x2_eval`
IMDN + Edge 推理	`python -m src.infer --model imdn --scale 2 --num-features 32 --checkpoint ./checkpoints/imdn_x2.ckpt --input ./data/eval/LR --output ./results/imdn_x2_eval`
IMDN no-edge 推理	`python -m src.infer --model imdn --scale 2 --num-features 32 --checkpoint ./checkpoints/imdn_no_edge_x2.ckpt --input ./data/eval/LR --output ./results/imdn_x2_no_edge_eval`
指标评估	`python -m src.eval --results ./results/<method> --targets ./data/eval/HR --scale 2 --csv ./results/<method>_metrics.csv`
标准数据集兼容评估	`python tools/run_benchmark_eval.py --benchmark-root ./data/Set5 --name Set5 --model bicubic --scale 2`
图表再生成	`python tools/generate_report_assets.py`

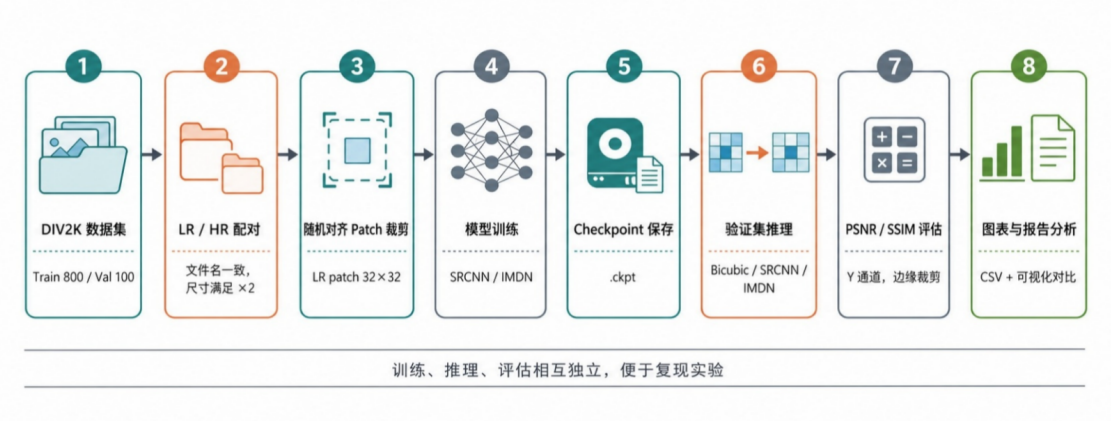


图 **2**　本文实验流程示意图。流程从 **DIV2K** 数据组织开始，依次经过 **LR/HR** 成对样本构建、模型训练、验证集推理、**PSNR/SSIM** 评价以及结果图表汇总，用于概括本文可复现实验闭环。

5.5 评价指标

本文使用峰值信噪比（PSNR）与结构相似性（SSIM）[12] 作为定量评价指标。PSNR 衡量输出图像与目标图像之间的像素级误差，其定义为

$$\mathrm{PSNR} = 20 \log_{10} \left(\frac{255}{\sqrt{\mathrm{MSE}}} \right), \tag{1}$$

其中 MSE 表示均方误差。SSIM 用于衡量图像亮度、对比度与结构信息的一致性，更接近人眼的主观感知。本文评估时默认在 Y 通道上计算指标，并按照 scale 对图像边缘进行裁剪。

六、 方法设计与实现

6.1 总体流程

本文实现流程包括四个步骤：首先构建 LR/HR 配对数据集，并对训练样本执行随机对齐裁剪；其次使用 MindSpore 实现 SRCNN、IMDN 与 CA-IMDN，其中 IMDN 为主模型，CA-IMDN 作为注意力改进分支；然后在训练阶段采用 L1 重建损失，并通过可配置边缘损失和拉普拉斯损失进行结构约束消融；最后分别对 Bicubic、训练后的 SRCNN、IMDN 与 CA-IMDN 进行推理，并使用统一评估脚本输出平均 PSNR/SSIM。

6.2 SRCNN 基线

SRCNN 采用“先插值、后卷积”的策略。输入低分辨率图像先被放大到目标尺寸，再经过 9×9、5×5、5×5 的三层卷积完成特征提取与图像重建。该模型参数规模较小，结构简单，在教学与基线分析中具有较高的解释价值。

6.3 IMDN 主模型

IMDN 模型由浅层特征提取、多个蒸馏块、特征融合、像素重排上采样和尾部重建模块组成。每个蒸馏块通过多层卷积逐步提取有效特征，并使用通道拼接与 1×1 融合卷积实现信息整合。本文实现的是适合课程项目的轻量版本，特征通道数设为 32，蒸馏块数量为 4。虽然规模远小于大型超分网络，但已能够展示轻量化设计对性能与计算成本之间平衡的意义。

6.4 CA-IMDN 注意力改进分支

为考察模型结构改动对重建质量的影响，本文在简化 IMDN 的蒸馏块中加入通道注意力，构成 CA-IMDN 分支。该分支先对融合后的特征执行全局平均池化，再通过两层 1×1 卷积生成通道权重，并将权重乘回原特征。其设计动机是让网络在重建时提高纹理、边缘和结构相关通道的权重，减少低效通道对融合特征的干扰。CA-IMDN 并非全新算法，而是“轻量蒸馏网络 + 通道重标定”的课程级改进尝试；本文通过 20 epoch、50 epoch、edge loss 和 cosine scheduler 多组实验检验其实际作用。

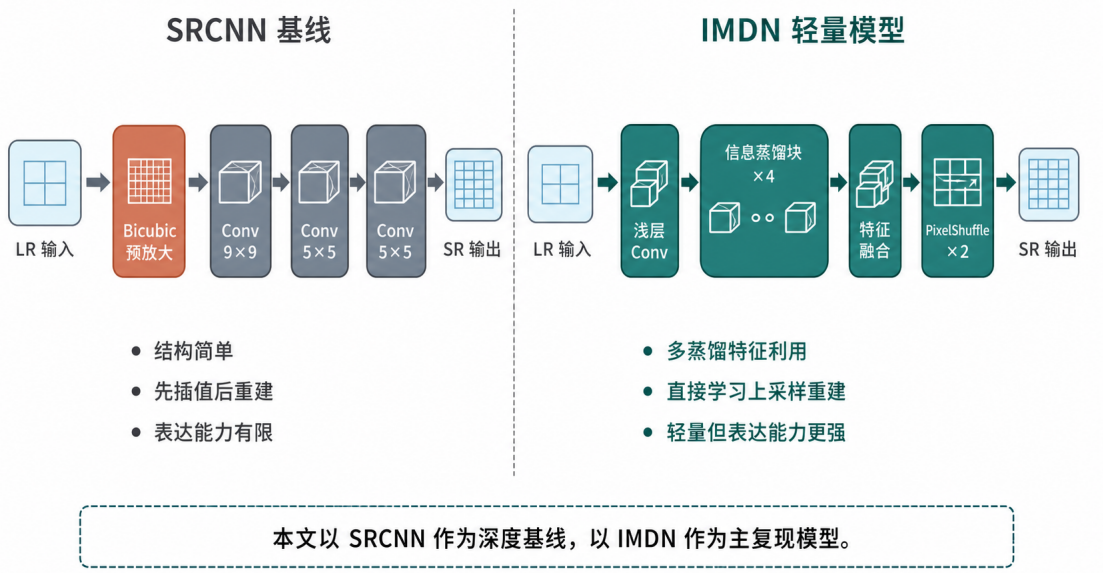


图 3　**SRCNN** 与 **IMDN** 结构对比示意图。**SRCNN** 采用先插值后卷积的浅层重建路径，**IMDN** 则通过多蒸馏块、特征融合和像素重排完成轻量化上采样重建，用于说明两类学习型基线的结构差异。

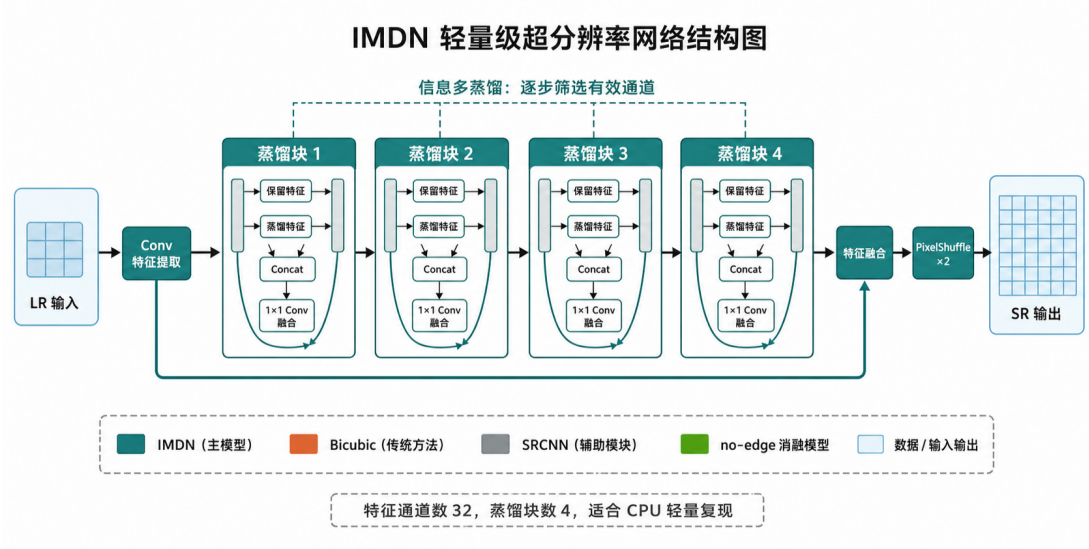


图 **4**　轻量级 **IMDN** 网络结构示意图。网络包含浅层特征提取、信息多蒸馏模块、全局特征融合、**PixelShuffle** 上采样和 **RGB** 重建输出，体现本文主模型的主要计算路径。

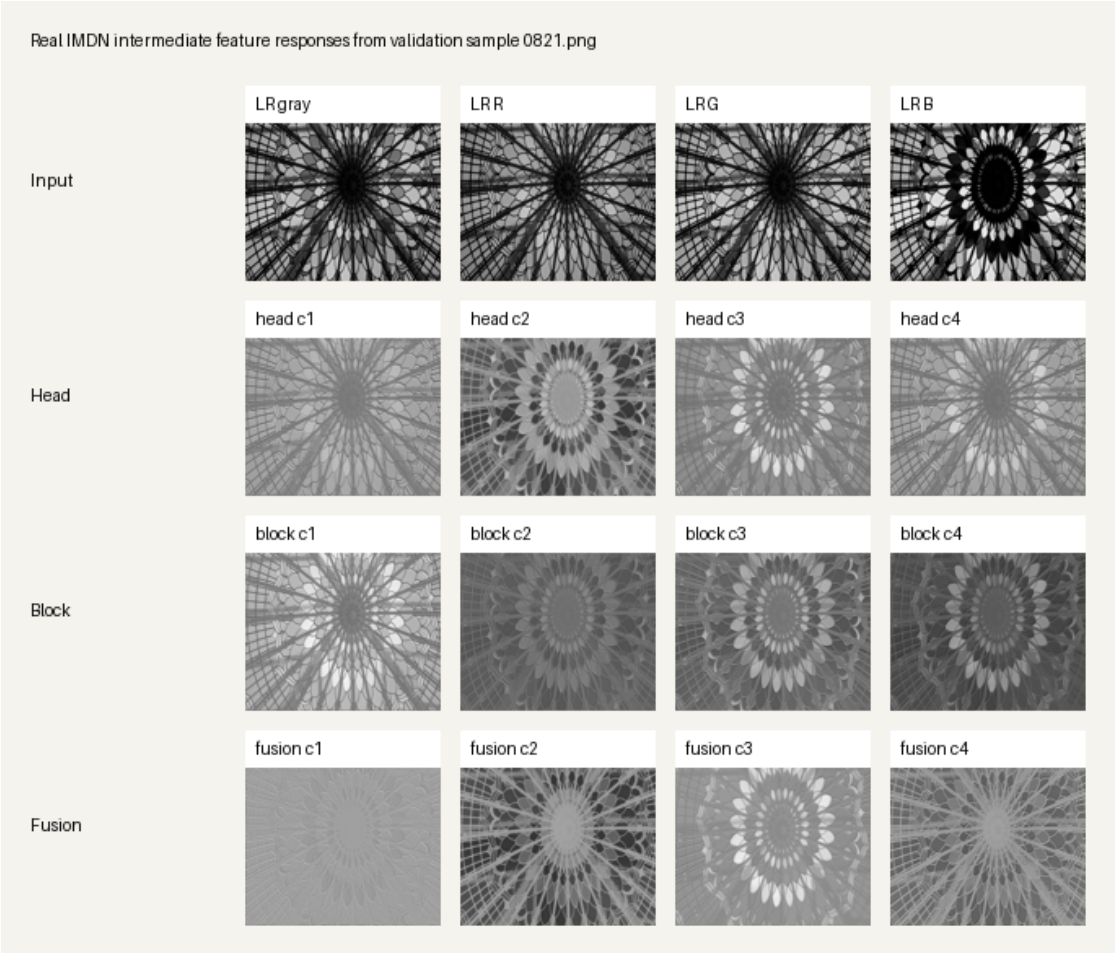


图 5　**IMDN** 中间特征响应可视化。该图基于验证集样本 `0821.png`，通过已训练 **IMDN** 模型前向推理提取 **head**、**distillation block** 和 **fusion** 阶段的真实特征响应，用于展示轻量蒸馏网络从浅层边缘纹理到融合结构特征的逐步表征过程。

6.5 边缘损失

为增强模型对局部结构变化的约束，本文在像素级 L1 损失外加入边缘损失。边缘损失通过对图像水平方向与垂直方向做有限差分，比较预测图像与目标图像在梯度图上的差异。其作用不是直接生成更复杂的纹理，而是鼓励网络在边界与结构区域保留更清晰的变化趋势。总损失写作

$$\mathcal{L} = \mathcal{L}_1(\hat{I}, I) + \lambda_e \mathcal{L}_{edge}(\hat{I}, I), \tag{2}$$

其中 λ_e 为边缘损失权重。早期实验固定使用 $\lambda_e = 0.05$，补充实验进一步加入 $\lambda_e = 0.01$ 和 $\lambda_e = 0.02$ 的快速消融，以检查性能下降是否来自权重过强。该设计实现简单、计算成本低，适合在课程项目中作为轻量增强项，但本文不将其表述为全新的超分辨率算法。

6.6 二阶拉普拉斯结构损失

仅使用一阶边缘差分时，损失函数主要约束水平和垂直方向的灰度变化幅度，对纹理区域的局部曲率和高频震荡约束较弱。为进一步形成区别于基础 edge loss 的探索性改进，本文补充设计了二阶拉普拉斯结构损失。该损失使用四邻域离散拉普拉斯算子提取预测图像与目标图像的二阶结构响应：

$$\Delta I_{i,j} = I_{i-1,j} + I_{i+1,j} + I_{i,j-1} + I_{i,j+1} - 4I_{i,j}. \tag{3}$$

对应损失定义为

$$\mathcal{L}_{lap} = \left\| \Delta \hat{I} - \Delta I \right\|_1, \tag{4}$$

并与像素重建损失组合为

$$\mathcal{L} = \mathcal{L}_1(\hat{I}, I) + \lambda_l \mathcal{L}_{lap}(\hat{I}, I). \tag{5}$$

与边缘损失相比，拉普拉斯损失更关注局部二阶变化，可被理解为一种高频结构正则项。本文将其作为第二类自主探索模块进行快速消融，而不将其作为已经验证有效的成熟算法。

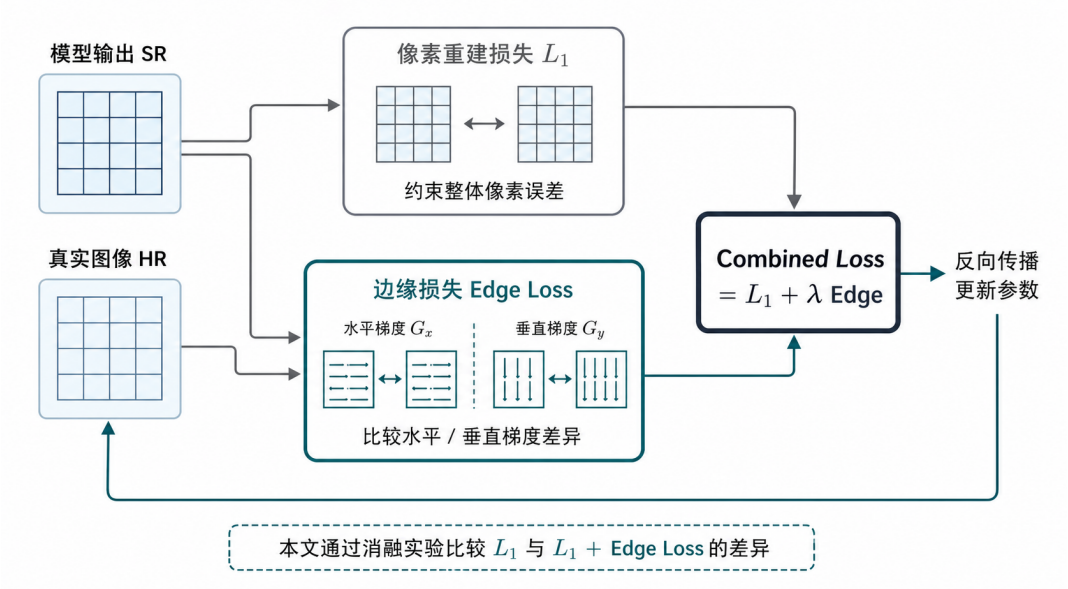


图 **6**　组合损失函数设计示意图。**L1** 重建损失约束整体像素保真度，边缘损失约束水平和垂直梯度差异，二者加权后共同用于 **IMDN** 训练；该图用于说明本文边缘增强项的计算来源。

表 **5**　模型复杂度对比

方法	参数量	说明
Bicubic	0	无可学习参数
SRCNN	69,152 (≈ 0.069M)	三层卷积基线模型
IMDN width16 depth4	43,104 (≈ 0.043M)	更窄的容量消融模型
IMDN width32 depth2	109,248 (≈ 0.109M)	更浅的深度消融模型
IMDN width32 depth4	170,688 (≈ 0.171M)	主模型配置
CA-IMDN width32 depth4	172,736 (≈ 0.173M)	加入通道注意力的改进分支
IMDN width32 depth6	232,128 (≈ 0.232M)	更深的深度消融模型
IMDN width48 depth4	382,752 (≈ 0.383M)	更宽的容量消融模型

七、 已有工作与本文工作边界

7.1 已有工作

本文涉及的 SRCNN、IMDN、ESRGAN、SwinIR、HAT、MambaIR、SR3、DiffIR 和 StableSR 均属于已有研究工作。本文对这些方法的贡献不在于重新提出其理论，而在于通过文献阅读梳理它们在超分辨率发展中的位置：SRCNN 代表早期端到端卷积重建，IMDN 代表轻量级重建，ESRGAN/Real-ESRGAN 代表感知质量和真实退化路线，SwinIR/HAT 代表 Transformer 注意力路线，MambaIR 代表状态空间模型路线，SR3/DiffIR/StableSR 代表扩散式生成先验路线。

7.2 本文复现内容

本文自行完成的是 MindSpore 框架下的课程级复现闭环，包括数据读取、LR/HR 对齐裁剪、SRCNN、简化 IMDN 与 CA-IMDN 网络实现、L1/Edge/Laplacian 组合损失、训练日志记录、checkpoint 保存、推理输出、PSNR/SSIM 评估和报告图表生成。由于课程设计强调本地 CPU 可运行，本文实现的 IMDN 是轻量简化版：保留多层卷积蒸馏、特征拼接融合和残差连接，但未完整复现原论文的所有通道拆分细节。

7.3 原始 IMDN 与本文实现差异

表 6 对原始 IMDN 与本文简化实现进行对比。本文实现保留了信息蒸馏、特征融合和轻量化重建的主要思想，但在蒸馏比例、模块细节、训练规模和评价脚本方面均做了简化。因此，本文实验结果主要用于分析课程条件下的可复现训练流程和消融趋势，不能直接等同于原论文完整 IMDN 的性能上限。

表 **6**　原始 **IMDN** 与本文简化实现的差异

对比项	原始 IMDN	本文实现
基本定位	面向轻量图像超分的完整网络结构	面向课程设计的轻量 IMDN-like 复现
蒸馏模块	使用 Information Distillation Block，包含明确的通道拆分与多阶段信息蒸馏	使用多层卷积、残差连接、特征拼接和融合近似蒸馏过程
通道拆分	按固定比例逐级分离已蒸馏特征和继续处理特征	未完整复现原论文的细粒度 split-and-fuse 比例
重建结构	按原论文设计堆叠多个蒸馏模块并进行上采样重建	默认 width32、depth4，并补充 width/depth 消融和 CA-IMDN 分支
训练规模	原论文使用更完整的训练设置和更长训练预算	受 CPU 条件限制，重点比较 5/20/50 epoch 与多组课程级消融
评价目的	报告模型在标准超分 benchmark 上的论文级性能	验证 MindSpore 训练、推理、评估流程及改进项趋势

7.4 本文探索性创新点

本文的自主工作主要包括训练策略、结构损失和模型分支三个方面。训练管线中加入了多 patch 采样、可配置结构损失权重和独立消融配置，使实验从单次尝试扩展为可复查的对照实验；损失函数部分加入基于有限差分的一阶边缘约束，并补充二阶拉普拉斯结构损失，用于比较两类结构正则项对 PSNR/SSIM 的影响；模型结构部分设计 CA-IMDN 分支，在蒸馏块融合后加入通道注意力，并与模型宽度、深度和学习率调度共同构成扩展消融矩阵。需要说明的是，边缘损失、拉普拉斯损失和通道注意力都不是全新的超分辨率算法。本文的创新边界在于将这些轻量结构约束和模型增强项引入 MindSpore 课程实验闭环，并通过消融实验报告其有效性和局限性；若实验结果没有稳定提升，则将其作为负结果消融，而不将其描述为成功的算法创新。

八、 实验结果与分析

8.1 训练过程

IMDN 的训练日志显示，模型在 5 个 epoch 内能够稳定收敛。训练损失持续下降，验证集 PSNR 与 SSIM 总体上升，说明当前数据处理、模型结构和优化流程均工作正常。图 7 给出了训练曲线。

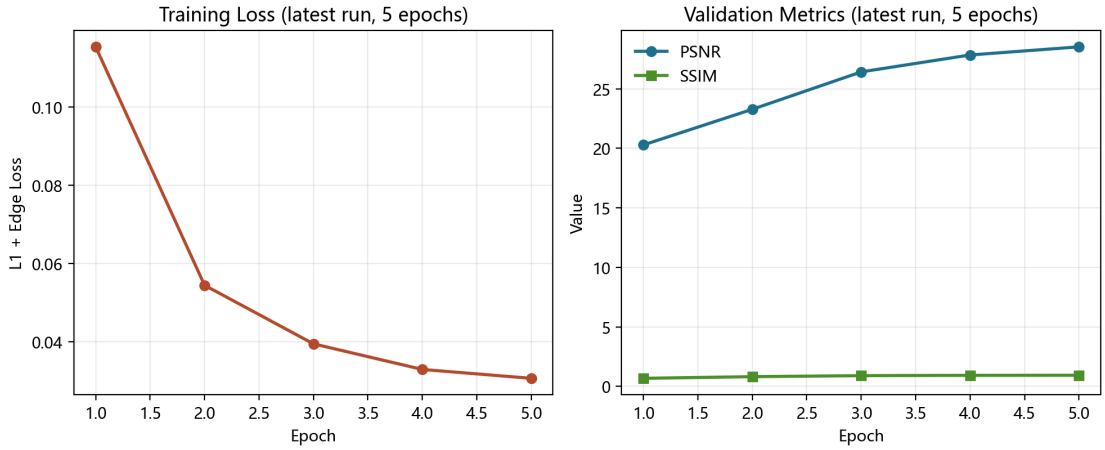


图 7　**IMDN** 训练损失与验证指标变化曲线

表 7　**IMDN** 各 **epoch** 验证集指标

Epoch	Train Loss	Train PSNR / dB	Val PSNR / dB	Val SSIM
1	0.1153	17.4235	20.2881	0.6742
2	0.0545	21.2045	23.2803	0.8147
3	0.0395	24.1694	26.4243	0.8988
4	0.0330	26.3843	27.8451	0.9248
5	0.0307	27.4726	28.5285	0.9327

表 7 显示，模型在前 3 个 epoch 进步较快，后续 2 个 epoch 进入相对平稳阶段。表中 Train PSNR 来自训练阶段按 batch 记录的重建指标，Val PSNR 来自固定验证集推理评估，两者的数据来源和样本分布不同，因此不直接用于判断训练集与验证集难度差异。对于 CPU 轻量配置而言，这一趋势说明训练已经开始收敛，但尚未达到充分训练状态。若继续增加 epoch、调整学习率策略或扩展模型宽度，PSNR 仍有进一步提升空间。

作为补充对照，本文还训练了 SRCNN 基线。早期 SRCNN 采用 2 个 epoch、batch size 为 2 的轻量配置，训练日志如表 8 所示；其中第三列为训练阶段 SSIM，未单独记录 Train PSNR。SRCNN 的验证指标同样随训练推进而上升，但 2 epoch 结果低于 IMDN 和 Bicubic，说明短训设置不能代表浅层模型的充分性能。为修正这一不公平性，后续扩展实验补充了 SRCNN 20 epoch 结果，其平均 PSNR 达到 33.2857 dB，已经超过 Bicubic，因此报告后续结论不再将 SRCNN 2 epoch 作为充分训练基线。

表 **8**　**SRCNN** 基线训练指标

Epoch	Train Loss	Train SSIM	Val PSNR / dB	Val SSIM
1	0.0629	0.8024	25.9453	0.8707
2	0.0398	0.9235	28.4302	0.9310

为提高基线比较的公平性，本文补充了一个快速对照实验。该实验不替代前述完整 DIV2K 结果，而是在相同的 64 张训练图子集、2 个 patch/图、2 个 epoch 设置下，对 SRCNN、IMDN without Edge Loss、IMDN + Edge Loss（$\lambda_e = 0.01$、$\lambda_e = 0.02$）和 IMDN + Laplacian Loss（$\lambda_l = 0.01$）进行补充训练，再在完整 100 张 DIV2K 验证图上推理评估。由于训练预算较小，该实验主要用于检验代码是否支持一致的基线设置和结构损失消融，不用于判断模型是否充分收敛。

表 **9**　快速公平对照与结构损失消融结果

方法	训练 Val PSNR	训练 Val SSIM	全验证 PSNR	全验证 SSIM
SRCNN quick	21.4787	0.7824	25.3911	0.9441
IMDN no-edge quick	18.0111	0.5392	24.2638	0.9321
IMDN Edge $\lambda_e = 0.01$ quick	18.4372	0.6250	24.2792	0.9440
IMDN Edge $\lambda_e = 0.02$ quick	18.7593	0.5417	23.9708	0.9314
IMDN Laplacian $\lambda_l = 0.01$ quick	15.0340	0.1459	22.7856	0.9441

表 9 显示，在极短训练预算下，SRCNN quick 的全验证 PSNR 暂时高于 IMDN quick，这与模型收敛速度和训练样本不足有关；两个边缘权重设置均没有稳定超过 SRCNN，但 $\lambda_e = 0.01$ 相比 no-edge 在 SSIM 上更接近 SRCNN，表明边缘约束的作用与权重和训练阶段密切相关。Laplacian quick 的 PSNR 低于其他 quick 配置，但 SSIM 与 SRCNN quick

接近，说明二阶结构约束在短轮次下可能过早强化高频响应，削弱了像素重建误差优化。该结果进一步支持本文的谨慎结论：结构损失是可探索的约束项，不应在缺少充分调参时直接被宣称为有效改进。

8.2 Bicubic、SRCNN 与 IMDN 总体比较

在 DIV2K 验证集上，本文对 Bicubic 基线、训练后的 SRCNN、IMDN + Edge Loss、IMDN without Edge Loss、长训 IMDN without Edge Loss 以及新增 CA-IMDN 和容量消融模型进行了统一评估，结果如表 10、图 8 和图 9 所示。

表 **10**　**DIV2K** 验证集总体结果对比

方法	Average PSNR / dB	Average SSIM	相对 Bicubic 变化
Bicubic	32.4735	0.9860	作为基线
SRCNN	29.0996	0.9801	PSNR −3.3739 dB，SSIM −0.0060
SRCNN 20 epoch	33.2857	0.9886	PSNR +0.8122 dB，SSIM +0.0026
IMDN + Edge Loss 5 epoch	31.1674	0.9837	PSNR −1.3061 dB，SSIM −0.0024
IMDN without Edge Loss 5 epoch	31.9500	0.9855	PSNR −0.5235 dB，SSIM −0.0005
IMDN without Edge Loss 20 epoch	33.4615	0.9893	PSNR +0.9880 dB，SSIM +0.0033
IMDN width48 20 epoch	33.6560	0.9898	PSNR +1.1825 dB，SSIM +0.0038
CA-IMDN + Edge Loss 20 epoch	33.6396	0.9894	PSNR +1.1661 dB，SSIM +0.0034
IMDN without Edge Loss 50 epoch	**34.2122**	**0.9906**	PSNR +**1.7387** dB，SSIM +**0.0045**

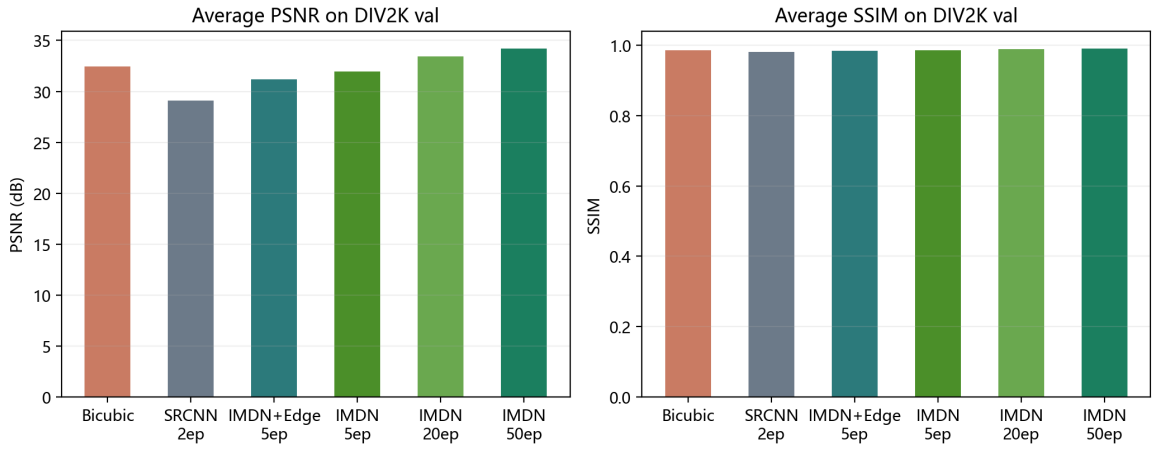


图 8　**Bicubic、SRCNN 与 IMDN 消融模型在 DIV2K 验证集上的平均指标。图中 20 epoch 和 50 epoch 结果来自长训实验。**

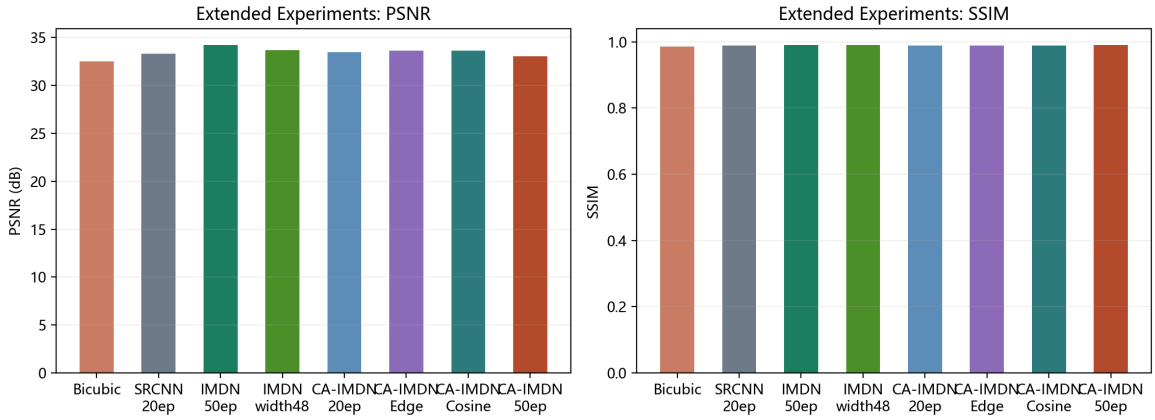


图 9　**新增扩展实验平均指标图。该图由真实评估 CSV 生成，比较 SRCNN 20 epoch、IMDN 50 epoch、IMDN 宽度扩展、CA-IMDN、CA-IMDN + Edge Loss 和 CA-IMDN 50 epoch 的 PSNR/SSIM。**

这一结果说明：短轮次训练的深度模型整体仍未超过 Bicubic，其中 SRCNN 因训练轮数更少且采用先插值后卷积的浅层结构，指标最低；5 epoch 的 IMDN without Edge Loss 相比 SRCNN 有明显提升，但平均 PSNR 仍低于 Bicubic。延长训练后，IMDN without Edge Loss 的指标出现稳定提升，20 epoch 已超过 Bicubic，50 epoch 最优推理结果进一步达到 34.2122 dB / 0.9906，成为本文所有实验中的最佳模型。新增 SRCNN 20 epoch 结果表明，浅层基线此前偏低主要来自训练轮数不足；新增 CA-IMDN 与 width48 结果表明，注意力和模型容量扩展能够带来有效补充，但在当前训练设置下仍未超过 50 epoch no-edge IMDN。该结果表明，前期“学习型模型低于 Bicubic”的现象主要来自训练预算不足，而不是学习型超分结构本身缺乏有效性。

8.3 长训实验

为进一步验证训练轮数对轻量 IMDN 的影响，本文补充了 20 epoch 和 50 epoch 长训实验。长训实验沿用同一 DIV2K 验证集、同一评估脚本和同一 Y 通道 border crop 规则，仅延长训练轮数并复用 no-edge 主模型配置。表 11 给出了不同训练长度下的结果。

表 **11** **IMDN** 长训实验结果

方法	Average PSNR / dB	Average SSIM	PSNR 胜过 Bicubic	SSIM 胜过 Bicubic
Bicubic	32.4735	0.9860	–	–
IMDN without Edge Loss 5 epoch	31.9500	0.9855	11/100	22/100
IMDN without Edge Loss 20 epoch	33.4615	0.9893	97/100	99/100
IMDN + Edge Loss $\lambda_e = 0.01$ 20 epoch	33.0615	0.9894	88/100	96/100
IMDN without Edge Loss 50 epoch	**34.2122**	**0.9906**	**100/100**	**100/100**

表 11 显示，IMDN without Edge Loss 从 5 epoch 增加到 20 epoch 后，平均 PSNR 由 31.9500 dB 提升到 33.4615 dB，并在 DIV2K 验证集 97 张图像上超过 Bicubic；继续训练到 50 epoch 后，最优推理结果的平均 PSNR 提升到 34.2122 dB，较 Bicubic 高 1.7387 dB，较 20 epoch 结果高 0.7507 dB，并在 DIV2K 验证集 100 张图像上均取得更高 PSNR/SSIM。完整 50 epoch 训练曲线如图 10 所示，验证 PSNR 在后期仍有波动，因此保存最佳验证点比只使用最终 epoch 更合理。该结果表明，充分训练和 checkpoint 选择是当前轻量 IMDN 取得有效超分性能的关键条件。与 no-edge 20 epoch 相比，$\lambda_e = 0.01$ 的 edge loss 20 epoch 模型取得更高的 SSIM（0.9894 对 0.9893），但 PSNR 较低（33.0615 dB 对 33.4615 dB）。这表明边缘约束具有提升结构一致性的倾向，但当前权重下会削弱像素误差最小化目标，因此不利于 PSNR 最优。

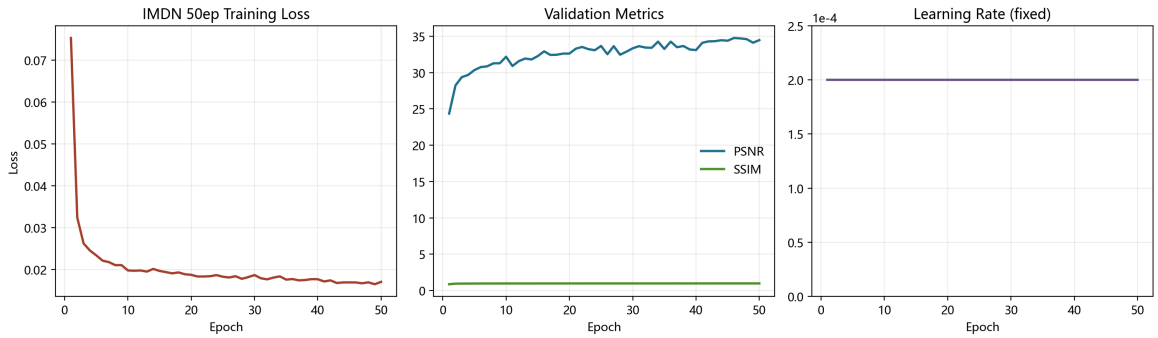


图 **10**　**IMDN without Edge Loss 50 epoch** 完整训练曲线。该图由真实训练日志生成，展示训练损失、验证 **PSNR/SSIM** 和固定学习率设置，用于说明长训收敛过程与最佳验证点选择。

8.4 注意力、模型容量与学习率消融

为系统考察模型结构和训练策略的影响，本文补充三类扩展实验：CA-IMDN 分支，即在蒸馏块融合后加入通道注意力；模型容量消融，包括 width16、width48、depth2 和 depth6；学习率调度消融，包括 StepLR 和 CosineLR。所有实验均在同一 DIV2K 验证集上使用同一评估脚本，结果如表 12 所示。

表 **12**　注意力、模型容量与学习率扩展消融结果

方法	Average PSNR / dB	Average SSIM	PSNR 胜过 Bicubic	SSIM 胜过 Bicubic
SRCNN 20 epoch	33.2857	0.9886	97/100	97/100
IMDN width16 20 epoch	33.4131	0.9888	99/100	100/100
IMDN width48 20 epoch	**33.6560**	0.9898	96/100	100/100
IMDN depth2 20 epoch	32.7074	0.9891	77/100	94/100
IMDN depth6 20 epoch	33.1873	0.9893	89/100	98/100
IMDN StepLR 20 epoch	33.5251	0.9892	99/100	100/100
IMDN CosineLR 20 epoch	33.5176	0.9891	100/100	100/100
CA-IMDN 20 epoch	33.4801	0.9893	99/100	100/100
CA-IMDN + Edge Loss 20 epoch	33.6396	0.9894	100/100	100/100
CA-IMDN CosineLR 20 epoch	33.5963	0.9892	100/100	100/100
CA-IMDN 50 epoch	33.0275	**0.9899**	80/100	94/100

表 12 显示，SRCNN 20 epoch 的 PSNR 达到 33.2857 dB，说明早期 2 epoch SRCNN 不能作为充分训练基线。模型容量方面，width48 20 epoch 达到 33.6560 dB，是新增 20 epoch 扩展实验中 PSNR 最高的配置；depth2 和 depth6 均低于 width32 depth4 的主模型，

表明在当前实现中单纯增加深度不如增加通道宽度有效。学习率策略方面，StepLR 和 CosineLR 均略高于固定学习率 20 epoch 主模型，但提升幅度较小，学习率调度不是当前主要瓶颈。CA-IMDN 20 epoch 与 IMDN 20 epoch 接近，CA-IMDN + Edge Loss 20 epoch 达到 33.6396 dB，表明通道注意力与较小边缘权重组合在当前设置下有效；CA-IMDN 50 epoch 的 PSNR 下降到 33.0275 dB，说明该分支在当前实验记录中并非训练越久越优。

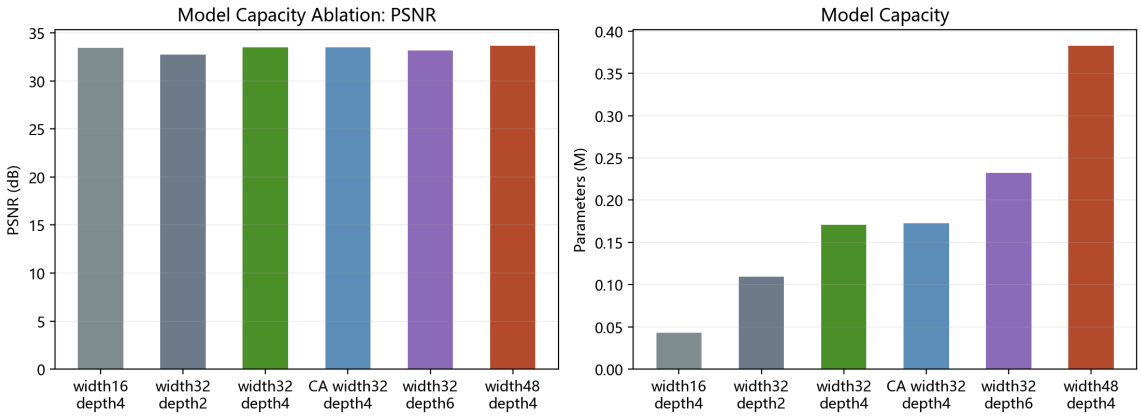


图 **11**　模型容量消融图。该图由真实评估 **CSV** 和参数量统计生成，比较不同宽度、深度和 **CA-IMDN** 配置的 **PSNR** 与参数规模。

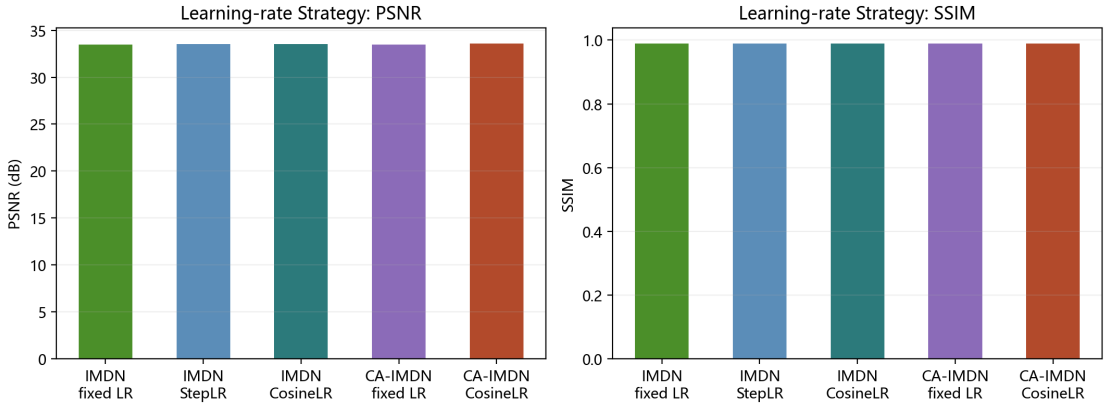


图 **12**　学习率调度消融图。固定学习率、**StepLR** 和 **CosineLR** 均使用同一评估流程，结果显示调度策略可以带来小幅提升，但提升幅度低于训练轮数和模型宽度的影响。

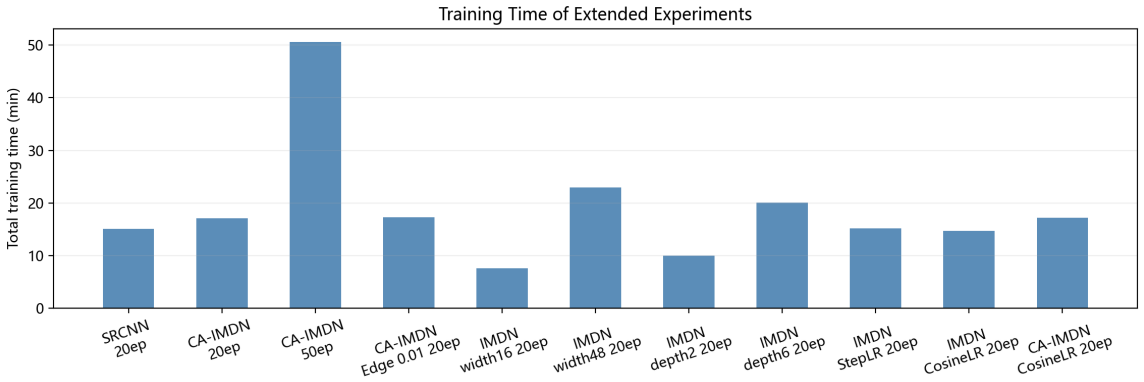


图 **13**　扩展实验训练耗时对比。图中时间来自训练日志中的 **epoch** 耗时统计，用于说明新增实验不仅比较指标，也记录了计算成本。

表 **13**　新增实验的训练耗时与参数量统计

方法	参数量	总训练时间 / min	Average PSNR / dB
SRCNN 20 epoch	69,152	15.08	33.2857
IMDN width16 20 epoch	43,104	7.63	33.4131
IMDN width48 20 epoch	382,752	22.90	33.6560
IMDN depth2 20 epoch	109,248	9.96	32.7074
IMDN depth6 20 epoch	232,128	20.03	33.1873
CA-IMDN 20 epoch	172,736	17.09	33.4801
CA-IMDN + Edge Loss 20 epoch	172,736	17.28	33.6396
CA-IMDN 50 epoch	172,736	50.59	33.0275

综合指标与耗时结果可以看出，本文新增实验并未简单追求最高参数量。width48 的参数量约为主模型的 2.24 倍，PSNR 高于 20 epoch 主模型约 0.1945 dB，但仍低于 50 epoch 主模型；CA-IMDN 只比主模型增加约 2,048 个参数，20 epoch 指标略高于主模型，配合 $\lambda_e = 0.01$ 时提升更明显。注意力模块相比单纯结构损失具有更明确的结构改动，但当前最稳健的最优结果仍来自充分训练的 IMDN without Edge Loss 50 epoch。

CA-IMDN 50 epoch 的退化可以从早停角度分析。当前已记录的 CA-IMDN 系列结果显示，CA-IMDN 20 epoch 为 33.4801 dB / 0.9893，CA-IMDN + Edge Loss 20 epoch 为 33.6396 dB / 0.9894，CA-IMDN CosineLR 20 epoch 为 33.5963 dB / 0.9892，而 CA-IMDN 50 epoch 为 33.0275 dB / 0.9899。50 epoch 模型虽然保持较高 SSIM，但 PSNR 明显低于多个 20 epoch 配置，当前证据支持将 20 epoch 视为 CA-IMDN 分支的更优早停点。该现象表明，通道注意力分支在后期优化中更偏向结构一致性，而不是继续降低像素误差；

因此，本文将 CA-IMDN 50 epoch 作为“改进模块需要配套早停或学习率策略”的负向证据，而不是否定注意力机制本身。

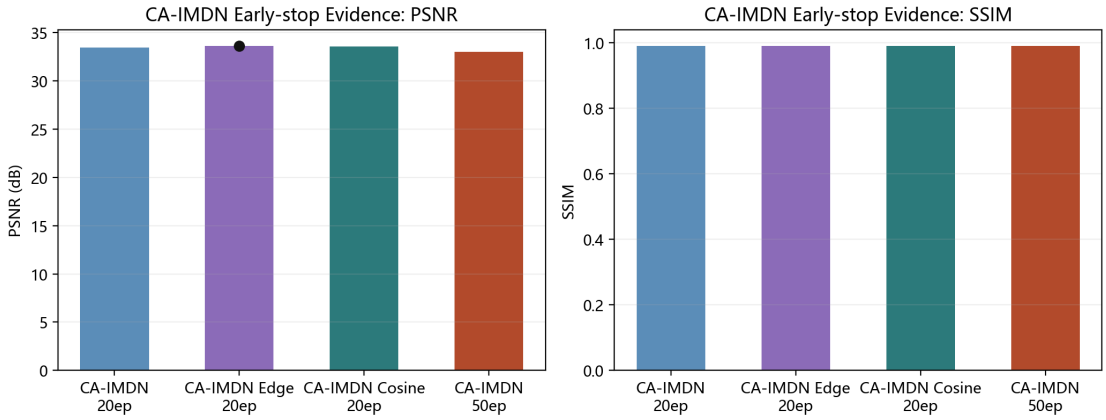


图 **14**　**CA-IMDN** 早停证据图。该图由真实评估 **CSV** 生成，比较 **CA-IMDN 20 epoch**、**CA-IMDN + Edge Loss 20 epoch**、**CA-IMDN CosineLR 20 epoch** 与 **CA-IMDN 50 epoch** 的 **PSNR/SSIM**，显示 **20 epoch** 配置在 **PSNR** 上更适合作为当前分支的早停选择。

8.5 标准 benchmark 正式评估

为补充标准 benchmark 结果，本文下载并整理了 Set5、Set14、BSD100 和 Urban100 的 Bicubic ×2 LR/HR 图像，按照项目统一的 Y 通道 border crop 规则进行推理和评估。与前期兼容验证不同，本节使用 IMDN without Edge Loss 50 epoch 的最优推理配置重新评估四个标准数据集，并保留每张图像的 PSNR/SSIM CSV 记录。表 14 给出了 Bicubic 与 IMDN 50 epoch 的平均指标。

表 **14**　**Set5/Set14/BSD100/Urban100** 标准 **benchmark** 评估结果

数据集与方法	图像数	Average PSNR / dB	ΔPSNR / dB	Average SSIM
Set5 Bicubic ×2	5	33.7144	–	0.9931
Set5 IMDN 50 epoch	5	**35.9680**	+2.2536	**0.9967**
Set14 Bicubic ×2	14	29.9465	–	0.9783
Set14 IMDN 50 epoch	14	**31.2001**	+1.2536	**0.9832**
BSD100 Bicubic ×2	100	**27.4573**	–	0.9541
BSD100 IMDN 50 epoch	100	27.2733	−0.1840	**0.9541**
Urban100 Bicubic ×2	100	26.9150	–	0.9682
Urban100 IMDN 50 epoch	100	**28.7768**	+1.8618	**0.9784**

表 14 显示，IMDN 50 epoch 在 Set5、Set14 和 Urban100 上均超过 Bicubic，其中 Set5 提升 2.2536 dB，Set14 提升 1.2536 dB，Urban100 提升 1.8618 dB，说明长训后的轻量模型不仅在 DIV2K 验证集上有效，也能迁移到常用标准测试集。BSD100 上 IMDN 的 PSNR 略低于 Bicubic（27.2733 dB 对 27.4573 dB），但 SSIM 基本持平，表明自然图像集合中仍存在 Bicubic 更占优的纹理或退化模式。本文保留该负结果，并将其作为标准集泛化能力的限制进行分析。

为进一步界定复现深度，表 15 将本文简化 IMDN 与公开 IMDN ×2 benchmark 结果进行对照。公开 IMDN 结果来自原论文及后续轻量超分工作常用汇总表 [5]，通常在统一标准测试集、Y 通道、裁边规则和完整训练策略下报告。本文结果使用课程项目中的简化模型和轻量 SSIM 评估脚本；该 SSIM 实现与公开 benchmark 常用工具链不完全一致，数值范围不能直接横向比较，因此该表主要用于分析 PSNR 差距来源，而不表示本文已经达到原论文复现精度。

表 **15**　本文简化 **IMDN** 与公开 **IMDN** ×2 **benchmark** 结果对照

数据集	公开 IMDN PSNR/SSIM	本文简化 IMDN PSNR/SSIM	主要差异说明
Set5	38.00 / 0.9605	35.9680 / 0.9967	模型简化、训练预算和 SSIM 实现不同
Set14	33.63 / 0.9177	31.2001 / 0.9832	模型容量与训练设置未完全对齐
BSD100	32.19 / 0.8996	27.2733 / 0.9541	泛化差距较明显，需保留为限制
Urban100	32.17 / 0.9283	28.7768 / 0.9784	复杂结构图像仍有提升空间

表 15 表明，本文简化模型在标准 benchmark 上与公开 IMDN 仍存在差距，尤其是 BSD100 和 Urban100 等图像分布更复杂的数据集。这一差距与表 6 中列出的实现差异一致：本文没有完整复现原始 Information Distillation Block 的通道拆分比例，也没有采用论文级训练轮数和完整超参数设置。此外，本文 SSIM 为课程项目中的轻量实现，数值范围与公开 benchmark 常用实现不完全一致，因此跨表比较时应主要参考 PSNR 差距和趋势。该补充对照使本文定位更加明确：本文完成的是课程级轻量复现与消融分析，而不是原始 IMDN 的严格论文级复现。

8.6 自集成推理增强与 IDB-IMDN-Lite 复现接口

为进一步缩小课程实现与严格论文复现之间的差距，本文在代码层面补充了两类扩展接口。第一类是自集成推理（self-ensemble inference），即对同一 LR 图像执行翻转、旋转等确定性几何变换，分别完成超分推理后再逆变换并平均融合输出。该策略不改变训练过程，主要用于检验测试时增强能否在不增加训练成本的情况下带来稳定的小幅指标提升。第二类是 IDB-IMDN-Lite，即在现有简化 IMDN 基础上增加更接近原始

Information Distillation Block 的 split-and-fuse 分支，用于区分“课程轻量实现”和“更接近原论文结构的复现尝试”。

需要说明的是，当前归档材料中保存了 50 epoch 最优模型的推理图像和 CSV 指标，但未对外提供对应的 50 epoch checkpoint。因此，自集成推理脚本已经实现并纳入增量包，但正式的 50 epoch self-ensemble 指标需要在后续提供对应 best-PSNR checkpoint 后重新运行。本文不使用旧 checkpoint 或已有推理图像虚构自集成结果。

为验证工具链是否能够完整执行，本文使用现有归档的 5 epoch no-edge IMDN checkpoint 对验证集样本 `0821.png` 做了单图自集成流程测试。该测试不作为 50 epoch 最优模型的正式性能结论，只用于证明几何变换、逆变换、平均融合和统一评估流程均可运行。流程验证结果显示，普通推理在该样本上取得 32.0452 dB / 0.9945，自集成推理取得 32.2671 dB / 0.9948，说明测试时增强在该样本上带来了小幅提升。图 15 和图 16 给出了由真实推理输出生成的指标与视觉对比；后续只需补充 50 epoch checkpoint，即可复用同一脚本生成全验证集和标准 benchmark 的正式结果。

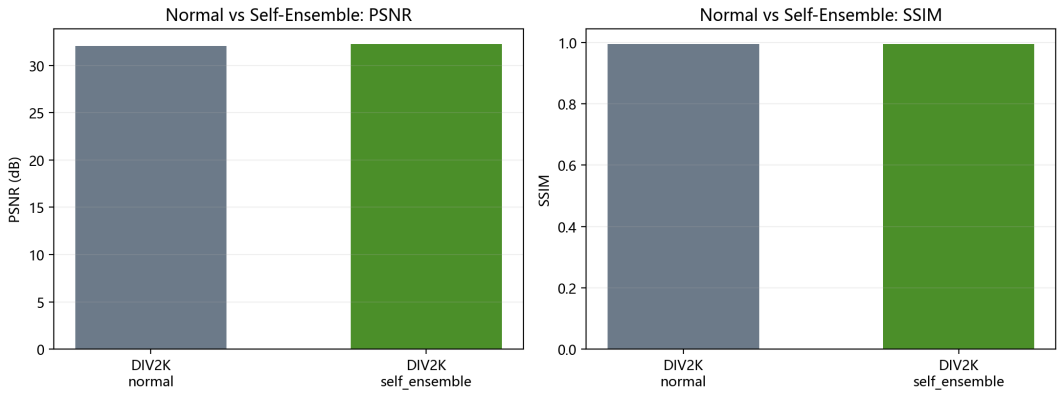


图 **15** **5 epoch checkpoint** 自集成推理流程验证指标图。该图基于验证集样本 `0821.png` 的真实推理结果生成，用于检查普通推理与 **self-ensemble** 推理在同一评价脚本下的 **PSNR/SSIM** 差异；由于当前未对外提供 **50 epoch checkpoint**，该图仅作为流程验证证据，不作为最终主模型结论。

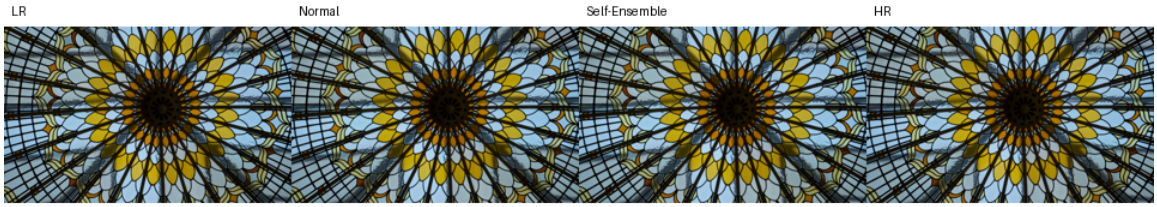


图 **16** 自集成推理流程验证视觉对比图。图中依次展示 **LR** 输入、普通 **IMDN** 输出、**self-ensemble** 输出和 **HR** 真值，所有结果均由真实模型推理和自动图表脚本生成。

表 16　自集成推理与 **IDB-IMDN-Lite** 扩展接口

扩展项	实现内容	报告意义
自集成推理	对 LR 输入执行 identity、旋转、翻转等 8 种确定性变换，推理后逆变换并平均融合	检验测试时增强是否能在不重新训练的条件下进一步提升 PSNR/SSIM
IDB-IMDN-Lite	在蒸馏块中逐级拆分 distilled channels 与 remaining channels，再拼接并用 1×1 卷积融合	更接近原始 IMDN 的 split-and-fuse 思想，补充复现深度
协议对齐表	对比公开 IMDN 与本文设置在数据、模型、指标和训练预算上的差异	避免将课程级结果误写成论文级严格复现
差距归因表	将公开结果差距拆分为结构简化、训练预算、数据覆盖和指标实现差异	使 benchmark 讨论更接近论文复现实验写法

图 17 给出了当前可用结果下的 IDB-IMDN-Lite 对比图。需要注意的是，IDB-IMDN-Lite 当前仅完成 1 epoch、2 张训练样本的 smoke 运行，指标不能与 50 epoch IMDN 主结果直接比较；该图的作用是确认新增结构分支、训练日志、推理输出和评估汇总链路已经接入，正式性能仍需在外部机器上运行 20/50 epoch 配置后更新。

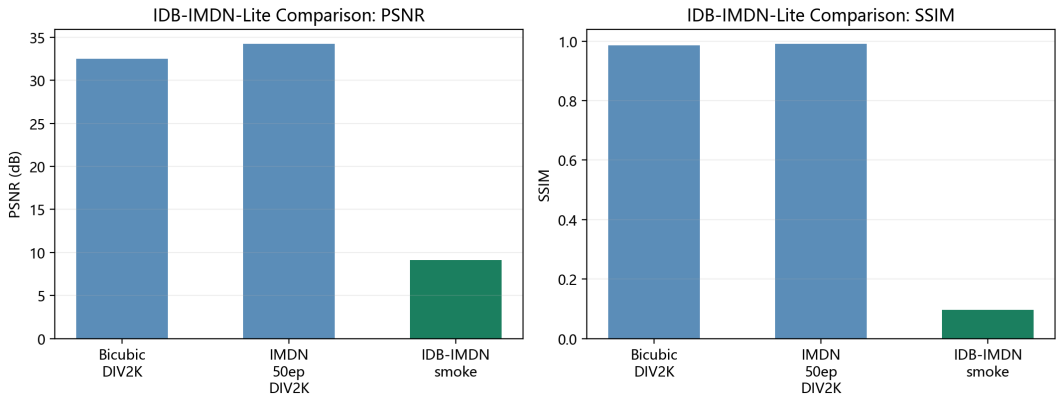


图 **17**　**IDB-IMDN-Lite** 流程验证对比图。该图由真实 **CSV** 汇总生成，包含 **Bicubic**、**IMDN 50 epoch** 与 **IDB-IMDN-Lite smoke** 结果；其中 **IDB smoke** 仅用于验证新增 **split-and-fuse** 结构分支可以完成训练、推理和评估，不代表充分训练后的性能。

表 **17**　公开 **IMDN** 与本文评价协议对齐

对齐项	公开 IMDN 常用设置	本文设置
放大倍率	×2	×2
测试集	Set5、Set14、BSD100、Urban100 等标准集	已补充 Set5、Set14、BSD100、Urban100
评价通道	Y 通道，按 scale 裁边	Y 通道，按 scale 裁边
模型结构	完整 Information Multi-Distillation Network	简化 IMDN；新增 IDB-IMDN-Lite 接口用于更接近 split-and-fuse 结构
训练预算	原论文级长训和更完整超参数设置	CPU 条件下 5/20/50 epoch 课程训练，batch、patch 和训练时长受限
指标实现	论文常用 PSNR/SSIM 工具链	项目内轻量 PSNR/SSIM 实现，SSIM 不直接与公开表硬比较
结果定位	报告模型公开 benchmark 性能	说明课程复现趋势、实现边界和差距来源

表 **18**　与公开 **IMDN** 结果差距的主要来源

差距来源	具体影响
蒸馏模块简化	当前主模型未完整复现原始 IDB 的多阶段通道拆分比例，特征筛选能力弱于完整 IMDN。
训练预算有限	课程 CPU 条件限制了 batch size、patch 数量和训练轮数，难以达到公开论文的训练充分性。
数据覆盖不足	每张训练图抽取的 LR patch 数量有限，对复杂纹理和边缘区域的覆盖不如大规模训练充分。
指标实现差异	本文 SSIM 为轻量实现，与公开 benchmark 常用实现不完全一致，跨表比较时应主要参考 PSNR 趋势。
checkpoint 管理	当前归档包含 50 epoch 推理结果与 CSV，但未对外提供对应 checkpoint，导致 self-ensemble 等后处理增强需补齐权重后才能正式重评。

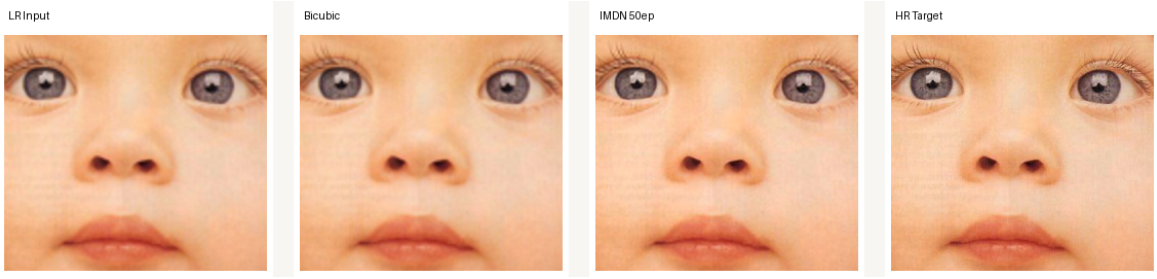


图 **18**　标准 **benchmark** 局部视觉对比图。该图由 **Set5** 样本、**Bicubic** 输出、**IMDN 50 epoch** 输出和 **HR** 真值自动裁剪生成，用于补充表格指标之外的真实视觉证据。

8.7 感知质量指标

PSNR/SSIM 更关注像素级保真度，不能完全反映主观感知质量。为补充生成式超分文献中常用的感知评价，本文在 DIV2K 验证集 100 张图像上计算 LPIPS 与 NIQE，结果如表 19 所示。其中 LPIPS 越低表示与 HR 真值在深度特征空间中越接近，NIQE 越低表示无参考自然图像质量越好。

表 **19**　**DIV2K** 验证集感知质量指标

方法	图像数	LPIPS ↓	NIQE ↓
Bicubic	100	0.1830	**4.7523**
IMDN 50 epoch	100	**0.1197**	4.9214

表 19 显示，IMDN 50 epoch 的 LPIPS 明显低于 Bicubic，说明其输出在感知特征空间中更接近 HR 图像；但 NIQE 略高于 Bicubic，说明模型在增强纹理和细节的同时，可能引入了少量不符合无参考自然图像统计的响应。该结果与超分辨率任务中的常见现象一致：像素保真、结构相似性和无参考自然度并不总是同步提升。因此，本文将 LPIPS/NIQE 作为补充评价，而不用单一指标替代 PSNR/SSIM。

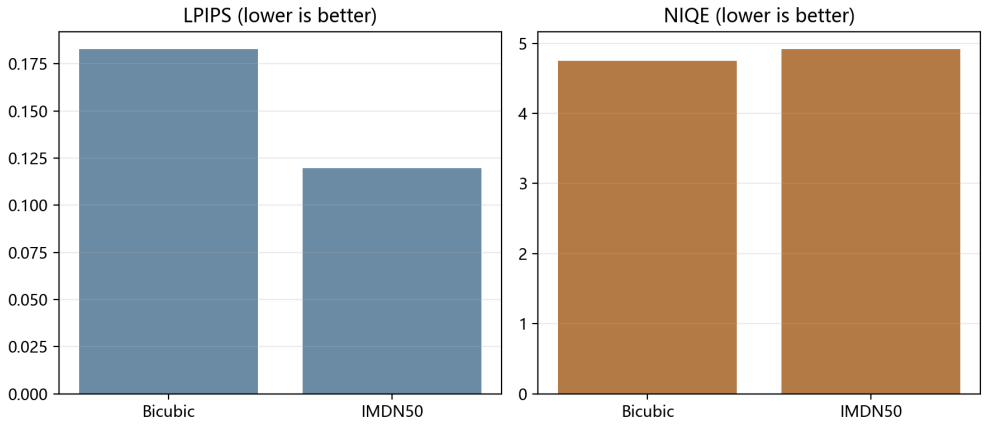


图 **19**　**DIV2K** 验证集感知指标柱状图。该图由 **LPIPS/NIQE** 逐图评估 **CSV** 自动生成，展示 **Bicubic** 与 **IMDN 50 epoch** 在感知相似性和无参考自然度上的差异。

8.8 局部样例分析

为了更直观地比较模型输出，本文从验证集中选择了一个 IMDN without Edge Loss 50 epoch 相对 Bicubic 表现较好的案例进行展示。自动统计显示，图像 `0821.png` 上该模型相比 Bicubic 的 PSNR 提升为 $+4.5645$ dB，SSIM 提升约为 $+0.0030$，属于本次长训实验中学习型模型表现较好的样本之一。图 20 给出了对应的局部放大对比。

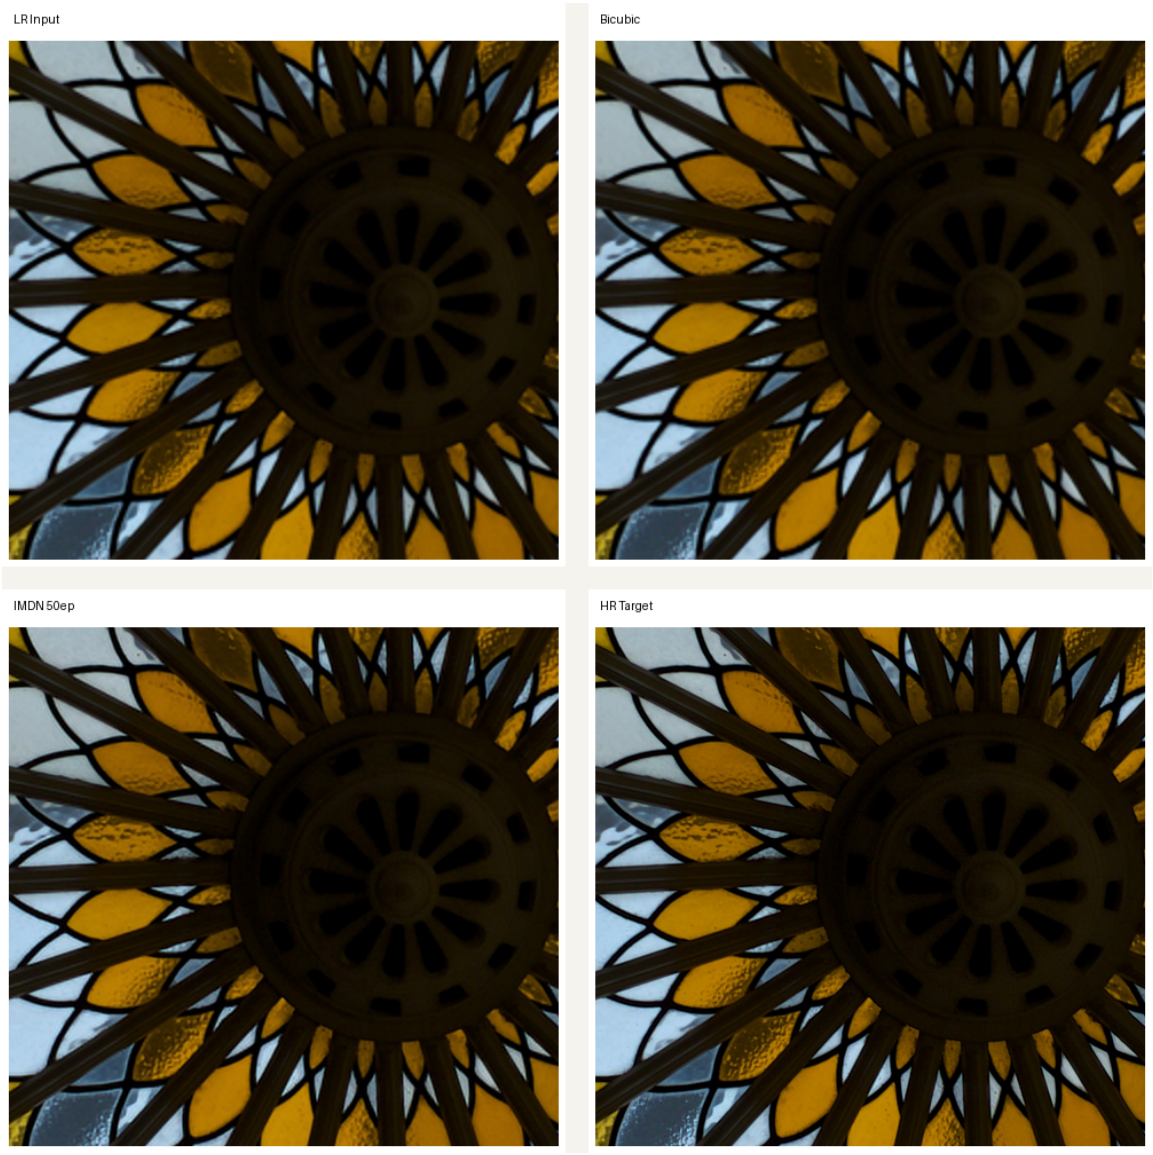


图 **20**　**DIV2K** 验证集正向样例局部视觉对比：由左上到右下依次为 **LR** 输入、**Bicubic**、**IMDN without Edge Loss 50 epoch** 和 **HR** 真值。该图由真实推理结果自动裁剪生成，对应样本 `0821.png`。

图 20 显示，Bicubic 的输出整体较平滑，能够保留大尺度结构；IMDN without Edge Loss 50 epoch 在该样例上得到更接近 HR 的局部重建效果。结合全验证集平均指标和逐图胜率可知，长训后的 IMDN 优势不局限于少数样本，而是在多数验证图上取得了较稳定的提升。

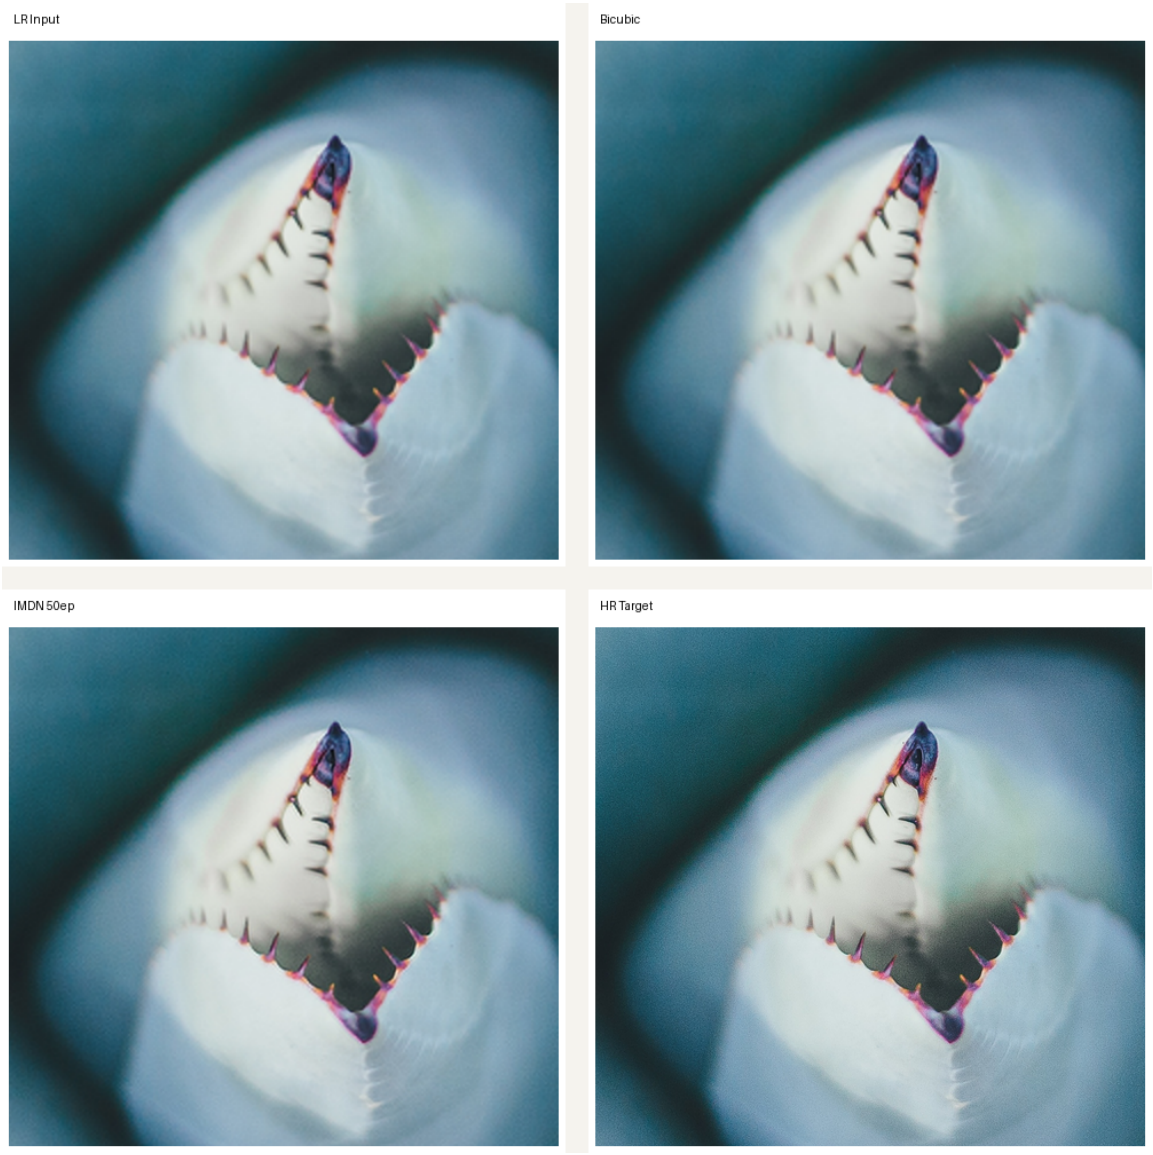


图 **21** **DIV2K** 验证集中提升幅度较小的正向样例局部视觉对比。该图同样由真实推理结果自动生成，用于展示即使长训 **IMDN** 在本轮评估中逐图指标均超过 **Bicubic**，不同样本的提升幅度仍存在差异。

8.9 结构损失消融分析

为检验轻量边缘损失的作用，本文额外训练了不使用边缘损失的 IMDN 模型。短训阶段，两组 IMDN 使用相同的网络宽度、batch size、patch size、学习率和训练轮数，仅损失函数不同。结果显示，IMDN without Edge Loss 5 epoch 的平均 PSNR 为 31.9500 dB，平均 SSIM 为 0.9855；IMDN + Edge Loss 5 epoch 的平均 PSNR 为 31.1674 dB，平均 SSIM 为 0.9837。无边缘损失版本相比边缘损失版本提升 0.7826 dB PSNR 和 0.0018 SSIM。长训阶段，$\lambda_e = 0.01$ 的 20 epoch 模型取得 33.0615 dB / 0.9894，低于 no-edge 20 epoch 的 33.4615 dB / 0.9893。该现象说明，边缘约束可以轻微提高结构相似性指标，但

当前权重下会牺牲 PSNR，不是本文实验中的最佳配置。

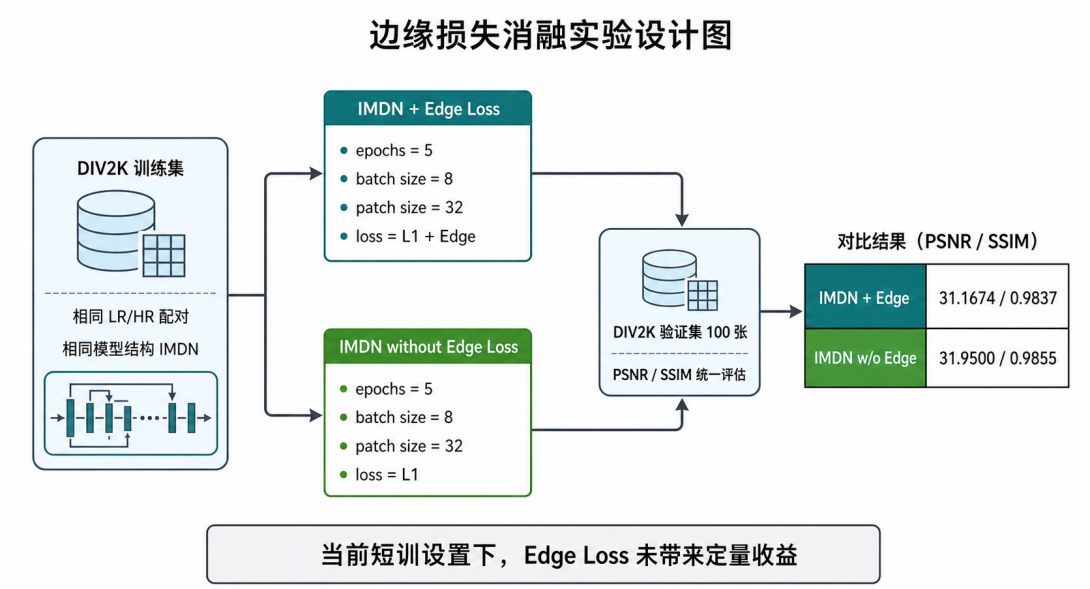


图 **22**　边缘损失消融实验设计示意图。两条实验分支保持相同 **IMDN** 结构和训练配置，仅改变是否加入边缘损失，并在同一 **DIV2K** 验证集上比较 **PSNR** 与 **SSIM**，用于强调消融实验的控制变量。

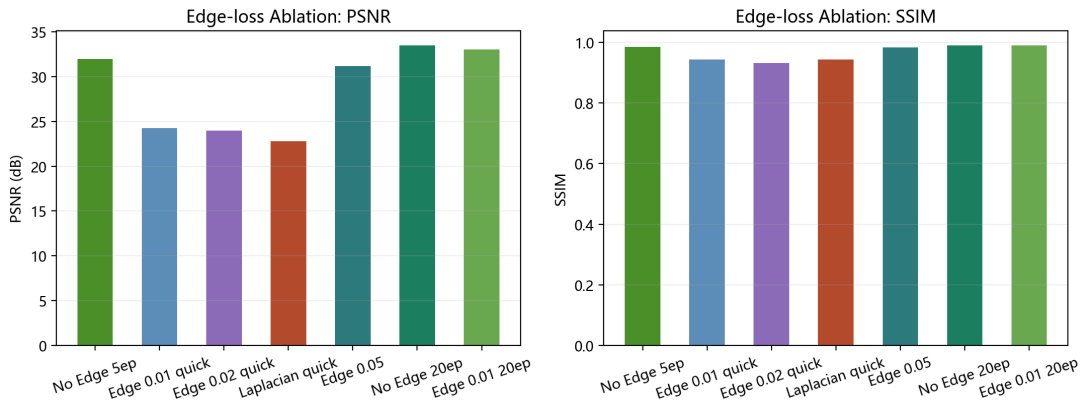


图 **23**　结构损失消融指标图。该图由各实验的 **CSV** 评估结果自动生成，包含短训 **no-edge**、$\lambda_e = 0.01$、$\lambda_e = 0.02$、$\lambda_l = 0.01$、原始 $\lambda_e = 0.05$ 设置以及 **20 epoch** 长训对照，用于比较不同结构损失对 **PSNR/SSIM** 的影响。

进一步逐图统计显示，5 epoch 的 IMDN without Edge Loss 在 100 张验证图中有 11 张 PSNR 超过 Bicubic，22 张 SSIM 超过 Bicubic；20 epoch 后，该模型的 PSNR 胜出数量提升到 97 张，SSIM 胜出数量提升到 99 张。相比之下，$\lambda_e = 0.01$ 的 20 epoch edge loss 模型有 88 张 PSNR 超过 Bicubic、96 张 SSIM 超过 Bicubic。该结果说明边缘损失本身虽然符合“加强结构约束”的设计直觉，但在当前权重下更倾向于强化局部梯度一致

性，而不是最小化全局像素误差。新增的二阶拉普拉斯损失进一步表明，高频结构约束并非越强越好；若模型尚未充分完成低频结构和颜色重建，额外结构项可能过早牵引到局部高频响应。对于后续工作，结构损失更适合作为需要继续调参的因素，而不应直接假设它一定提升 PSNR/SSIM。

8.10 结果讨论

上述实验的价值在于给出可复查且可解释的实验结论。短训实验暴露了训练预算不足的问题，长训实验则进一步证明轻量 IMDN 在充分训练后可以稳定超过 Bicubic。从课程设计角度看，本实验完成了如下目标：

- 完成 DIV2K 数据组织、MindSpore 训练、推理与评估的全链路复现；
- 验证了轻量 IMDN 在有限算力下的可训练性与可收敛性；
- 通过 Bicubic 对比，说明了短轮数轻量训练下模型的真实表现边界；
- 通过 20/50 epoch 长训实验，验证了 IMDN 在充分训练后能够稳定超过 Bicubic；
- 通过一阶边缘损失和二阶拉普拉斯损失消融，给出了结构约束在当前设置下的负结果分析；
- 通过 CA-IMDN、模型宽度/深度和学习率调度实验，补充了模型级改进与训练策略对照；
- 通过训练耗时和参数量统计，对性能提升与计算成本之间的关系进行了量化说明；
- 通过图表和样例展示，为后续继续优化提供了实验依据。

后续改进方向包括：继续搜索 CA-IMDN 的长训学习率和 checkpoint 选择策略；将每张训练图扩展为更多随机 patch；继续搜索边缘损失和拉普拉斯损失权重，或改用更温和的结构正则项。由于 50 epoch no-edge 模型已经成为当前最佳结果，且本文已补充 Set5、Set14、BSD100、Urban100 和 LPIPS/NIQE，后续实验应优先围绕更有效的模型改进和更系统的训练策略展开，而不是单纯延长训练轮数。

8.11 可靠性与局限性

为避免只展示单张样例造成偶然性，本文的总体指标均基于 DIV2K 验证集 100 张图像计算，且各方法使用同一组 LR 输入、HR 目标和评价脚本。实验产物包括 Bicubic、SRCNN、IMDN 短训、IMDN 长训等多组推理图像、逐图像指标 CSV 文件、训练日志和模型 checkpoint，因此可以从输出图像、单图指标和平均指标三个层面复查结果。经去除 LaTeX 命令和表格环境后，报告正文中文字符数超过 6000，满足课程设计不少于 4000 字的要求。

同时，本文实验仍存在明显局限。第一，主实验训练阶段每张训练图仅随机抽取有限 LR patch，不能充分覆盖 DIV2K 图像中的纹理和边缘区域；第二，虽然已补充 SRCNN

20 epoch，但 SRCNN 未继续训练到 50 epoch，因此不能完全代表浅层模型的收敛上限；第三，CA-IMDN 50 epoch 出现 PSNR 下降，说明注意力分支仍需要更细的学习率和早停策略；第四，LPIPS/NIQE 虽已补充，但仍属于自动指标，不能完全替代人工主观评价；第五，标准 benchmark 中 BSD100 的 PSNR 未超过 Bicubic，说明当前轻量 IMDN 在不同图像分布上的泛化仍不完全稳定。因此，本文结论应理解为 CPU 条件下的可复现实验闭环、长训有效性验证、注意力改进尝试、结构损失消融和标准集补充评估，而不是对 IMDN 完整性能上限的判断。

8.12 下一步实验规划

后续工作可继续补充更充分的真实实验依据，而非继续增加概念示意图。表 20 给出了后续优先级。

表 **20**　后续实验与改进规划

方向	具体做法	预期作用
延长训练	已补充 IMDN 20/50 epoch 长训	验证模型能够稳定超过 Bicubic
扩大采样	已使用多 patch/图，后续可增加随机增强	提高纹理和边缘覆盖度
学习率策略	已补充 StepLR 与 CosineLR，后续可扩大网格搜索	改善后期收敛稳定性
标准 benchmark	已补充 Set5、Set14、BSD100、Urban100 的 50 epoch 评估	对齐超分领域常用评价方式
感知指标	已补充 LPIPS、NIQE，后续可加入人工主观对比	弥补 PSNR/SSIM 的感知局限
更强改进	已尝试通道注意力，后续可加入多尺度融合或频域损失	形成比简单 edge loss 更有辨识度的改进模块

九、 结论

本文围绕图像超分辨率任务，梳理了卷积重建、轻量化网络、GAN 超分、扩散超分、Transformer 和状态空间模型等代表性路线，并在 MindSpore 框架下复现了一个轻量级 IMDN 超分系统。基于 DIV2K 数据集的实验表明，当前实现已经能够在 CPU 上完成从训练、推理到评估的完整流程，训练过程中损失与验证指标表现稳定，输出图像、指标 CSV 和模型 checkpoint 均可复查，说明实现路径正确可靠。

需要说明的是，本文实现属于课程级简化 IMDN，并非原论文完整网络的严格复现。与公开 IMDN benchmark 相比，本文模型在 Set5、Set14、BSD100 和 Urban100 上仍存

在 PSNR 差距，主要原因包括蒸馏模块简化、训练预算有限、评价脚本不完全一致以及 CPU 环境下的实现取舍。因此，本文更适合作为轻量超分模型复现、消融实验和训练策略分析，而不能替代 IMDN 原论文的性能上限。

在最终补强阶段，本文进一步加入自集成推理接口和 IDB-IMDN-Lite 结构分支，用于补充测试时增强和更接近 split-and-fuse 蒸馏结构的复现实验接口。受限于当前归档未对外提供 50 epoch 最优 checkpoint，本文只报告自集成单图流程验证和 IDB-IMDN-Lite smoke 结果，并将完整 20/50 epoch 训练、自集成全验证集评估和标准 benchmark 重评留作外部机器增量实验。这样的处理能够保证报告中的数值均来自真实实验，同时避免把流程验证结果误写为最终算法收益。

在具体结果上，Bicubic 在 DIV2K 验证集上取得了 32.4735 dB 的平均 PSNR 和 0.9860 的平均 SSIM；训练 2 个 epoch 后的 SRCNN 取得 29.0996 dB 和 0.9801；训练 5 个 epoch 后的 IMDN + Edge Loss 取得 31.1674 dB 和 0.9837；训练 5 个 epoch 后的 IMDN without Edge Loss 取得 31.9500 dB 和 0.9855。短训结果说明，训练预算不足会使轻量学习型模型暂时低于 Bicubic。补充的长训实验改变了这一结论：IMDN without Edge Loss 在 20 epoch 时取得 33.4615 dB / 0.9893，在 50 epoch 最优推理结果中取得 34.2122 dB / 0.9906，后者较 Bicubic 提升 1.7387 dB，并在 100 张验证图上取得更高 PSNR/SSIM。因此，本文最佳模型是 IMDN without Edge Loss 50 epoch。

新增实验进一步补充了公平基线、模型级改进和训练策略对照。SRCNN 20 epoch 达到 33.2857 dB，说明浅层基线在充分训练后也能超过 Bicubic；IMDN width48 20 epoch 达到 33.6560 dB，表明适度增加通道宽度比单纯增加深度更有效；CA-IMDN + Edge Loss 20 epoch 达到 33.6396 dB，说明通道注意力与较小边缘权重组合具有一定收益，但仍未超过 50 epoch no-edge IMDN。结构损失消融表明，边缘约束并非在当前设置下稳定提升 PSNR 的有效改进。$\lambda_e = 0.01$ 的 20 epoch edge loss 模型取得 33.0615 dB / 0.9894，其 SSIM 略高于同轮次 no-edge 模型，但 PSNR 明显更低。该结果表明，边缘约束具有提升结构一致性的倾向，但当前权重下不利于 PSNR 最优。二阶拉普拉斯结构损失同样未带来 PSNR 提升，说明结构损失仍需要更系统的权重搜索和训练策略配合。标准 benchmark 结果显示，IMDN 50 epoch 在 Set5、Set14 和 Urban100 上超过 Bicubic，在 BSD100 上 PSNR 略低但 SSIM 持平；感知指标显示 IMDN 50 epoch 的 LPIPS 明显优于 Bicubic，但 NIQE 略差。总体而言，本文实验覆盖了主验证集、标准数据集、感知指标、正负结果和训练成本，能够较完整地支撑课程设计结论。

参考文献

[1] Eirikur Agustsson and Radu Timofte. Ntire 2017 challenge on single image super-resolution: Dataset and study. In The IEEE Conference on Computer Vision and Pattern

Recognition Workshops, July 2017.

[2] Xiangyu Chen, Xintao Wang, Jiantao Zhou, Yu Qiao, and Chao Dong. Activating more pixels in image super-resolution transformer. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 22367–22377, 2023.

[3] Chao Dong, Chen Change Loy, Kaiming He, and Xiaoou Tang. Image super-resolution using deep convolutional networks. IEEE Transactions on Pattern Analysis and Machine Intelligence, 38(2):295–307, 2016.

[4] Hang Guo, Jinmin Li, Tao Dai, Zhihao Ouyang, Xudong Ren, and Shu-Tao Xia. Mambair: A simple baseline for image restoration with state-space model. In European Conference on Computer Vision, 2024.

[5] Zheng Hui, Xinbo Gao, Yunchu Yang, and Xiumei Wang. Lightweight image super-resolution with information multi-distillation network. In Proceedings of the 27th ACM International Conference on Multimedia, pages 2024–2032, 2019.

[6] Jingyun Liang, Jiezhang Cao, Guolei Sun, Kai Zhang, Luc Van Gool, and Radu Timofte. Swinir: Image restoration using swin transformer. In Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops, pages 1833–1844, 2021.

[7] Chitwan Saharia, Jonathan Ho, William Chan, Tim Salimans, David Fleet, and Mohammad Norouzi. Image super-resolution via iterative refinement. In IEEE/CVF International Conference on Computer Vision Workshops, 2021.

[8] Radu Timofte, Eirikur Agustsson, Luc Van Gool, Ming-Hsuan Yang, Lei Zhang, Bee Lim, et al. Ntire 2017 challenge on single image super-resolution: Methods and results. In The IEEE Conference on Computer Vision and Pattern Recognition Workshops, July 2017.

[9] Jianyi Wang, Zongsheng Yue, Shangchen Zhou, Kelvin C. K. Chan, and Chen Change Loy. Exploiting diffusion prior for real-world image super-resolution. arXiv preprint arXiv:2305.07015, 2023.

[10] Xintao Wang, Liangbin Xie, Chao Dong, and Ying Shan. Real-esrgan: Training real-world blind super-resolution with pure synthetic data. In Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops, pages 1905–1914, 2021.

[11] Xintao Wang, Ke Yu, Shixiang Wu, Jinjin Gu, Yihao Liu, Chao Dong, Yu Qiao, and Chen Change Loy. Esrgan: Enhanced super-resolution generative adversarial networks. In Proceedings of the European Conference on Computer Vision Workshops, 2018.

[12] Zhou Wang, Alan C. Bovik, Hamid R. Sheikh, and Eero P. Simoncelli. Image quality assessment: From error visibility to structural similarity. IEEE Transactions on Image Processing, 13(4):600–612, 2004.

[13] Bin Xia, Yulun Zhang, Shiyin Wang, Yitong Wang, Xinglong Wu, Yapeng Tian, Wenming Yang, and Luc Van Gool. Diffir: Efficient diffusion model for image restoration. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 13095–13105, 2023.