西南交通大学
Southwest Jiaotong University

SCAI011112 视觉计算

目标识别

计算机科学与技术专业
2025-2026 (2)

本章主要内容

- 图像分类
- 目标定位
- 基于语言监督的视觉识别

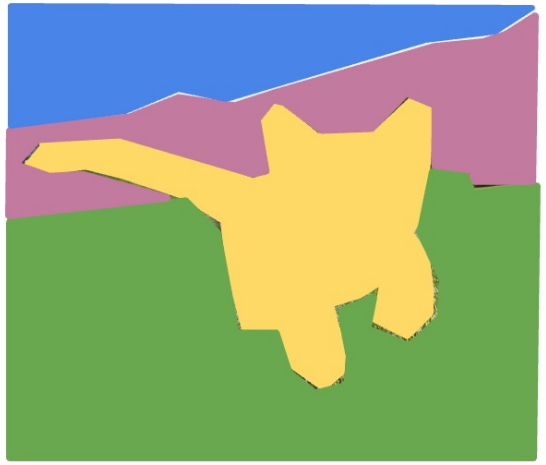
分类，检测，与分割

Classification



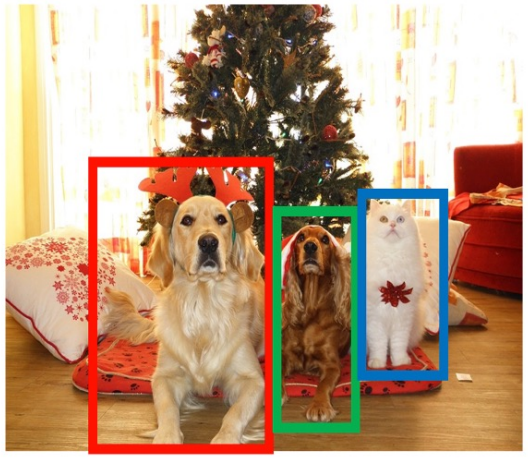
CAT

Semantic Segmentation



GRASS, CAT, TREE, SKY

Object Detection



DOG, DOG, CAT

Instance Segmentation



DOG, DOG, CAT

No spatial extent

No objects, just pixels

Multiple Objects

图像分类

- 在高维张量构成的输入空间 x 与有限离散标签空间 y 之间，通过从独立同分布样本中学习一个映射函数 $f: x \rightarrow y$，使得在未知数据分布上的分类错误期望最小

$$\hat{\mathbf{y}} = f(\mathbf{x})$$

Is there a **car** in this image?



→ **Yes**

$$p(Y_c = 1 \mid \mathbf{x}) = \hat{y}_c$$



$$\begin{bmatrix}1\\0\\0\end{bmatrix}$$



$$\begin{bmatrix}0\\1\\0\end{bmatrix}$$



$$\begin{bmatrix}1\\0\\0\end{bmatrix}$$



$$\begin{bmatrix}1\\0\\0\end{bmatrix}$$



$$\begin{bmatrix}0\\0\\1\end{bmatrix}$$



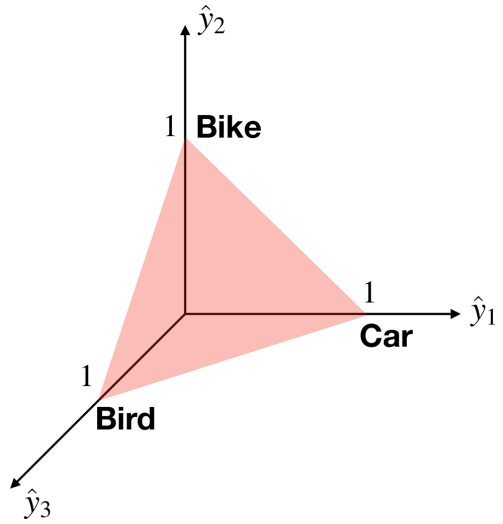
$$\begin{bmatrix}0\\0\\1\end{bmatrix}$$

图像分类 — 互斥类别

- 在 k 个可能的类别中，图像只会出现一个类别，即 $\sum_{c=1}^{K} \hat{y}_c = 1$

- 在这种情况下，函数 f 是一个从RGB图像集映射到 $(K-1)$维单纯形 Δ^{K-1}的映射，记作 $f: \mathbb{R}^{\mathbb{N}\times\mathbb{M}\times 3} \rightarrow \Delta^{K-1}$





$$f : \mathbb{R}^{N\times M\times 3} \rightarrow \triangle^{K-1}$$

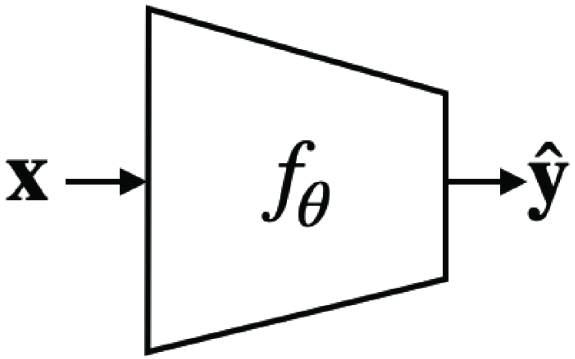
图像分类 — 多标签分类

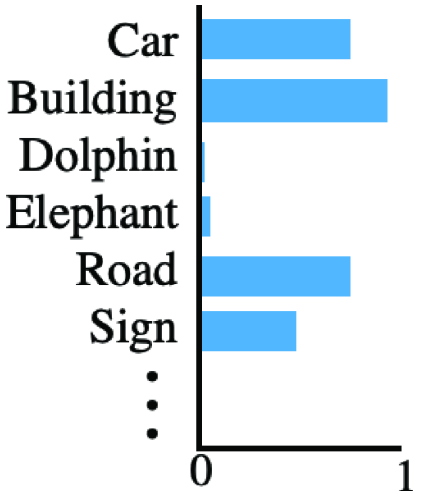
- 当图像可以同时具有多个标签时，分类问题可以可以表述为 K 个二分类问题

$$\hat{y}_c = p_\theta(Y_c = 1 \mid \mathbf{x})$$

但此时，不再满足类别之和为 1 的约束







图像分类 — 分类损失

- 0-1 损失

$$\mathcal{L}(\hat{\mathbf{y}}, \mathbf{y}) = \sum_{t=1}^{T} \sum_{c=1}^{K} \mathbb{1}(\hat{y}_c^{(t)} \neq y_c^{(t)}).$$

但不可微分，无法用梯度下降来训练参数

- 常用交叉熵损失

图像分类 — 交叉熵损失

- 对于**互斥类别**，有 $\sum_{c=1}^{K} \hat{y}_c = 1$
  - 其似然函数为：

$$\prod_{t=1}^{T} \prod_{c=1}^{K} \left(\hat{y}_c^{(t)}\right)^{y_c^{(t)}}$$

- 当类别 c **不是**正确类别时，$y_c^{(t)} = 0$。此时 $\left(\hat{y}_c^{(t)}\right)^0 = 1$。乘以 1 不会改变连乘的结果。
- 当类别 c **是**正确类别时，$y_c^{(t)} = 1$。此时 $\left(\hat{y}_c^{(t)}\right)^1 = \hat{y}_c^{(t)}$。

$$\mathcal{L}_{cls}(\hat{\mathbf{y}}, \mathbf{y}) = -\sum_{t=1}^{T} \sum_{c=1}^{K} y_c^{(t)} \log(\hat{y}_c^{(t)})$$

图像分类 — 交叉熵损失

- 对于**多标签分类**，其似然函数：

$$\prod_{t=1}^{T}\prod_{c=1}^{K}\left(\hat{y}_c^{(t)}\right)^{y_c^{(t)}}\left(1-\hat{y}_c^{(t)}\right)^{1-y_c^{(t)}}$$

- **情况 A：真实情况是“有猫” ($y_c^{(t)}=1$)**

  代入公式：$\left(\hat{y}_c^{(t)}\right)^{1}\times\left(1-\hat{y}_c^{(t)}\right)^{0}=\hat{y}_c^{(t)}$

  公式结果变成了模型预测“有”的概率。

- **情况 B：真实情况是“没猫” ($y_c^{(t)}=0$)**

  代入公式：$\left(\hat{y}_c^{(t)}\right)^{0}\times\left(1-\hat{y}_c^{(t)}\right)^{1}=1-\hat{y}_c^{(t)}$

  公式结果变成了模型预测“没有”的概率。

- 多类二分类交叉熵损失：

$$\mathcal{L}_{cls}(\hat{\mathbf{y}},\mathbf{y})=-\sum_{t=1}^{T}\sum_{c=1}^{K}y_c^{(t)}\log(\hat{y}_c^{(t)})+(1-y_c^{(t)})\log(1-\hat{y}_c^{(t)})$$

图像分类 — 评估

- 根据预测类别的概率排序
- Top-1
  - 在测试集中，真实类别标签与最高分预测值 $\hat{y} = \underset{c}{\operatorname{argmax}}(\hat{y}_c)$

$$\text{TOP-1} = \frac{100}{T}\sum_{t=1}^{T}\mathbb{1}(\hat{y}^{(t)} = y^{(t)})$$

- Top-5
  - 在测试集中，真实标签出现在得分最高的前 5 个预测结果中的次数百分比

- 混淆矩阵

True class \ Predicted class	Cat	Car	Dog	
Cat	80	5	15	$\rightarrow \sum = 100$
Car	2	95	3	$\rightarrow \sum = 100$
Dog	4	0	96	$\rightarrow \sum = 100$

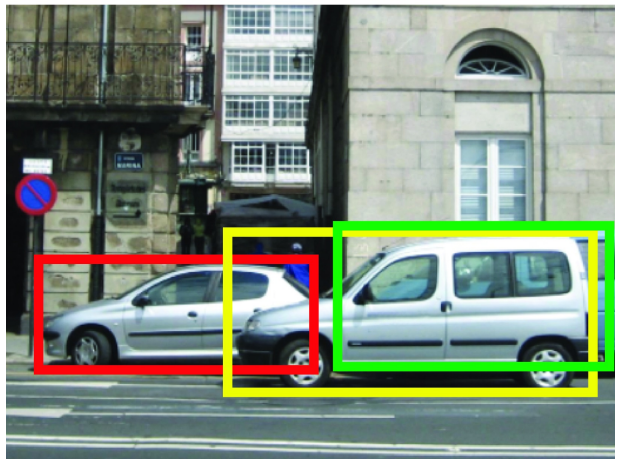
$$C_{i,j} = 100\frac{\sum_{i=1}^{N}\mathbb{1}(\hat{y}^{(t)} = j)\mathbb{1}(y^{(t)} = i)}{\sum_{i=1}^{N}\mathbb{1}(y^{(t)} = i)}$$

目标检测



$$\{\hat{\mathbf{y}}_i, \hat{\mathbf{b}}_i\} = f(\mathbf{x})$$

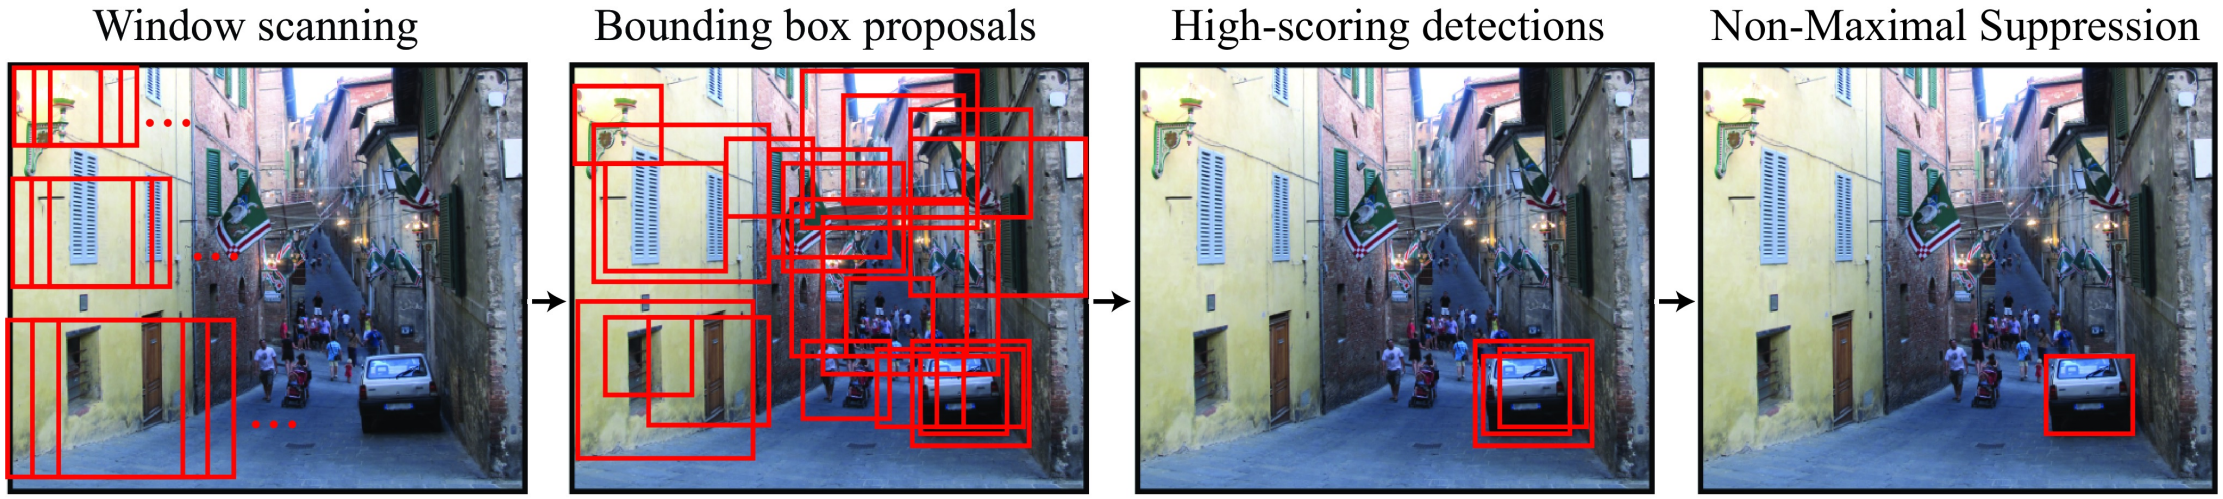
Locate all **cars** in this image

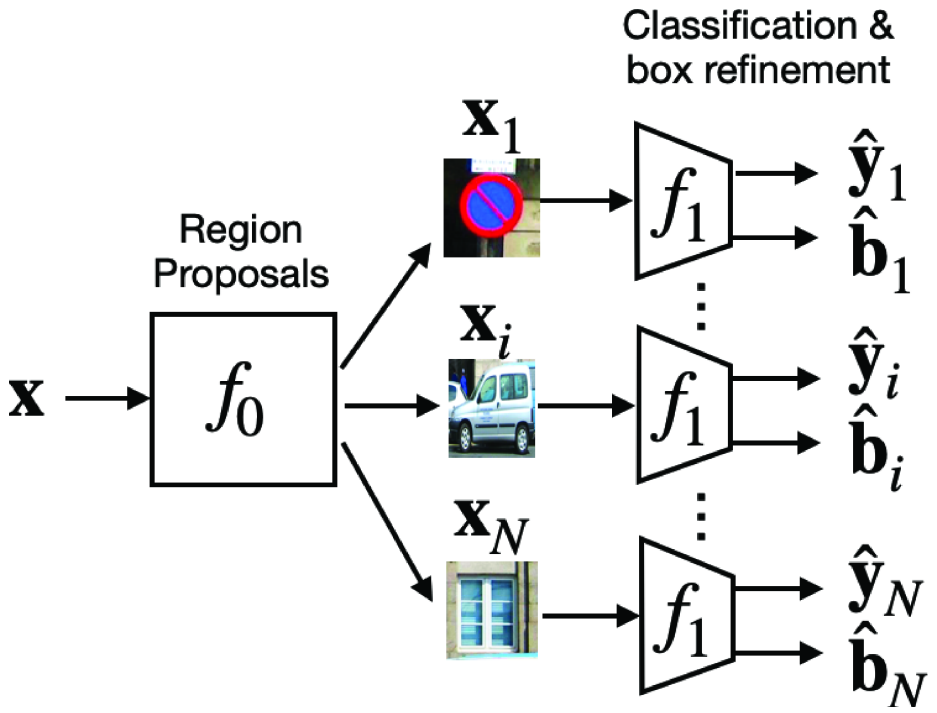


$$\mathbf{b} = [x_1, y_1, x_2, y_2]$$

$$\mathbf{b} = [x_c, y_c, w, h]$$

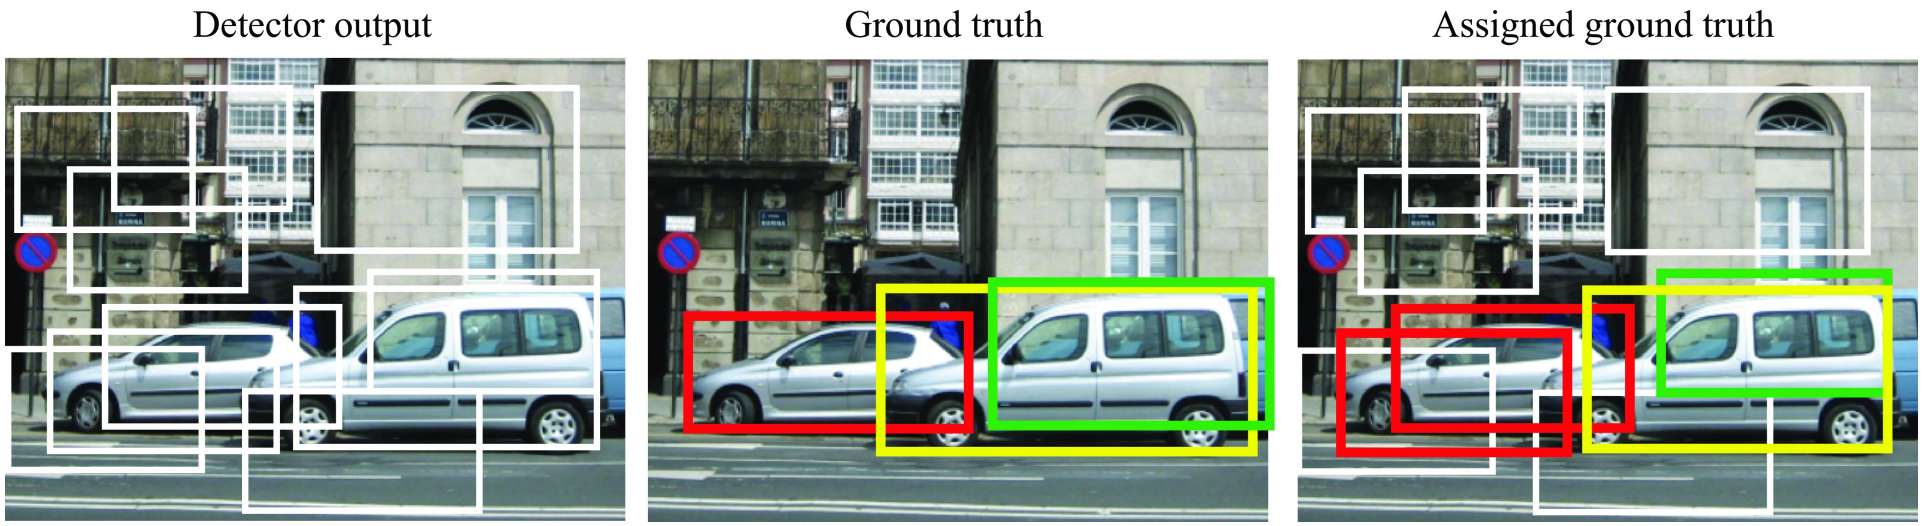
目标检测


Window scanning
Bounding box proposals
High-scoring detections
Non-Maximal Suppression


Classification &
box refinement
Region
Proposals
x
f_0
$\mathbf{x}_1$
$\mathbf{x}_i$
$\mathbf{x}_N$
f_1
f_1
f_1
$\hat{\mathbf{y}}_1$
$\hat{\mathbf{b}}_1$
$\hat{\mathbf{y}}_i$
$\hat{\mathbf{b}}_i$
$\hat{\mathbf{y}}_N$
$\hat{\mathbf{b}}_N$

目标检测 — 损失函数

- 目标检测需考虑两个互补的任务：分类与定位
- 检测输出的边界框个数很可能大于真实边界框的个数。因此，将检测结果与一个真实标签相关联



多个检测框可能被分配给同一个真实的边界框

- 对于与真实目标实例存在重叠的每个预测边界框，优化系统参数以改进其预测位置和标签。
- 其余与真实目标实例没有重叠的预测边界框则被分配为背景类，即 $\mathbf{y}_i = 0$
- 匹配方法：IoU 匹配，二分匹配等

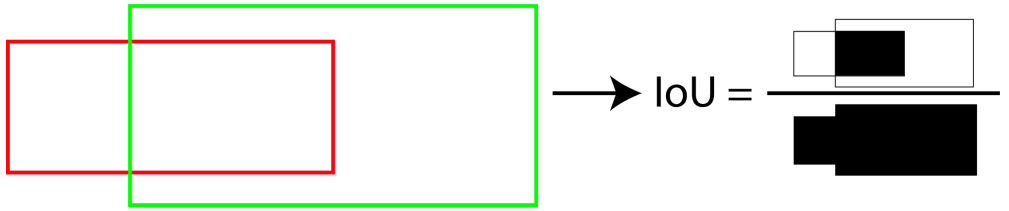
目标检测 — 损失函数

- 分类损失：

$$\mathcal{L}_{\text{cls}}(\hat{\mathbf{y}}_i, \mathbf{y}_i) = -\sum_{c=1}^{K} y_{c,i} \log(\hat{y}_{c,i})$$

- 定位损失：

$$\mathcal{L}_{\text{loc}}(\hat{\mathbf{b}}, \mathbf{b}) = 1 - IoU(\hat{\mathbf{b}}, \mathbf{b})$$



- 总的损失：

$$\mathcal{L}(\{\hat{\mathbf{b}}_i, \hat{\mathbf{y}}_i\}, \{\mathbf{b}_i, \mathbf{y}_i\}) = \mathcal{L}_{\text{cls}}(\hat{\mathbf{y}}_i, \mathbf{y}_i) + \lambda \mathbb{1}(\mathbf{y}_i \neq 0) \mathcal{L}_{\text{loc}}(\hat{\mathbf{b}}_i, \mathbf{b}_i)$$

目标检测 — 评估

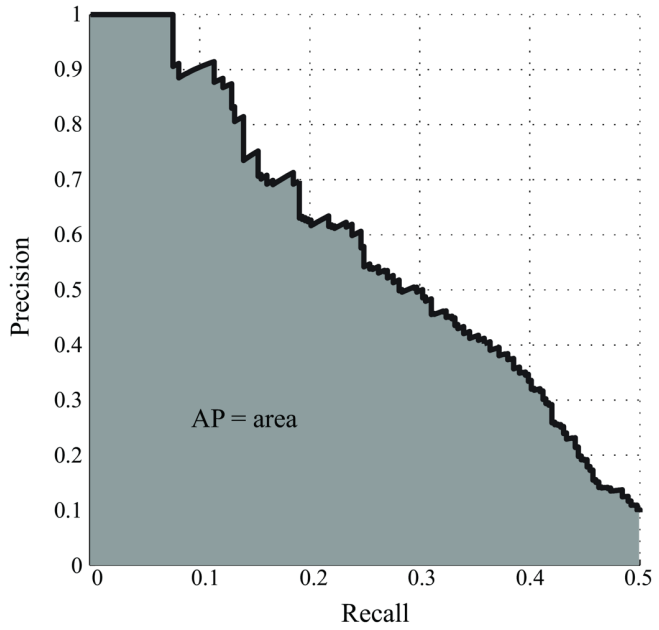
- **将检测结果分配给真实标签**
  - 对每幅图像，依据置信度分值 $\hat{y}_i$ 对所有检测结果进行排序
  - 按分值从高到低的顺序遍历排序列表。对于每个边界框，计算其与所有真实边界框的交并比（IoU）
- **选择IoU值最高的真实边界框**
  - 若该IoU大于预设阈值（通常设为0.5），则将该检测结果标记为正确，并从列表中移除对应的真实边界框，以避免对同一目标重复计数；
  - 若IoU低于阈值，则将该检测结果标记为错误，同时保留该真实标签。
  - 重复此操作，直至没有更多待评估的检测结果。
  - 最后，将剩余的真实边界框标记为漏检。

目标检测 — 评估

- **精度-召回率曲线：**衡量检测性能随决策阈值变化的函数关系。
- 由于每个边界框都附带一个置信度分数 $\hat{\mathbf{y}}_i$，需要使用一个阈值 β 来判断该边界框位置 $\hat{\mathbf{b}}_i$ 处是否存在目标。
- 给定阈值 β，检测数量为 $\sum_i \mathbb{1}(\hat{\mathbf{y}}_i > \beta)$，正确检测数量为 $\sum_i \mathbb{1}(\hat{\mathbf{y}}_i > \beta) \times \mathbf{y}_i$

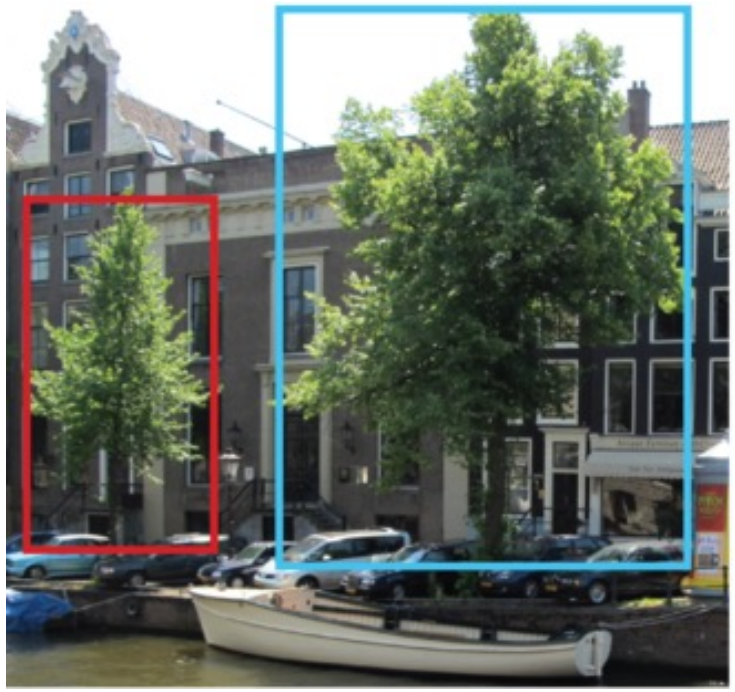
$$Precision(\beta) = \frac{\sum_i \mathbb{1}(\hat{\mathbf{y}}_i > \beta) \times \mathbf{y}_i}{\sum_i \mathbb{1}(\hat{\mathbf{y}}_i > \beta)}$$

$$Recall(\beta) = \frac{\sum_i \mathbb{1}(\hat{\mathbf{y}}_i > \beta) \times \mathbf{y}_i}{\sum_i \mathbf{y}_i}$$



目标检测的局限

- 对于具有长而薄结构的物体，或没有明显边界的区域，使用边界框表示目标位置是不合适的





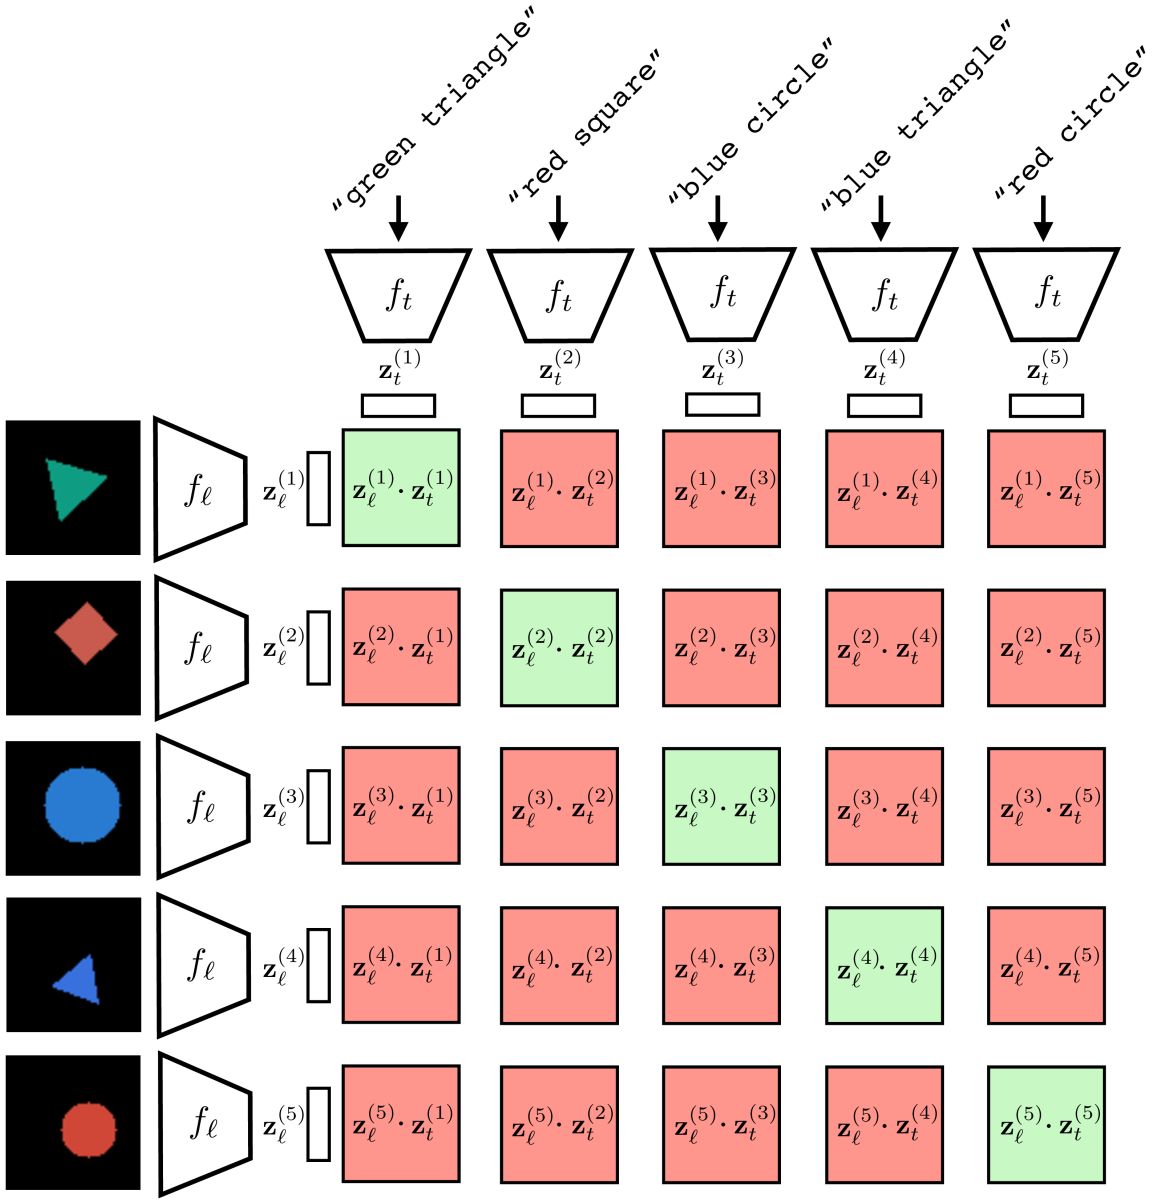


Learning visual representations from language supervision

- **Image classification:** given an image, predict its class name
- **Image captioning:** given an image, predict its caption
- **Contrastive learning:** align image and text embeddings that describe the same thing

[Radford*, Kim* et al., ICML 2021]

Contrastive Language-Image Pre-training (CLIP)



- **Positive pairs:** image and its caption.
- **Negative pairs:** image and a different image's caption.
- Learn a representation in which **positives are pulled together**, **negatives are pushed apart**.

[Radford*, Kim* et al., ICML 2021]

Contrastive Language-Image Pre-training (CLIP)

Data

$$\{\mathbf{t}^{(i)}, \boldsymbol{\ell}^{(i)}\}_{i=1}^{N} \longrightarrow$$

CLIP

Objective

$$\left(-\log \frac{e^{f_\ell(\boldsymbol{\ell})^\top f_t(\mathbf{t}^+)/\tau}}{e^{f_\ell(\boldsymbol{\ell})^\top f_t(\mathbf{t}^+)/\tau} + \sum_i e^{f_\ell(\boldsymbol{\ell})^\top f_t(\mathbf{t}_i^-)/\tau}} + \right.$$

$$\left. -\log \frac{e^{f_t(\mathbf{t})^\top f_\ell(\boldsymbol{\ell}^+)/\tau}}{e^{f_t(\mathbf{t})^\top f_\ell(\boldsymbol{\ell}^+)/\tau} + \sum_i e^{f_t(\mathbf{t})^\top f_\ell(\boldsymbol{\ell}_i^-)/\tau}} \right) /2$$

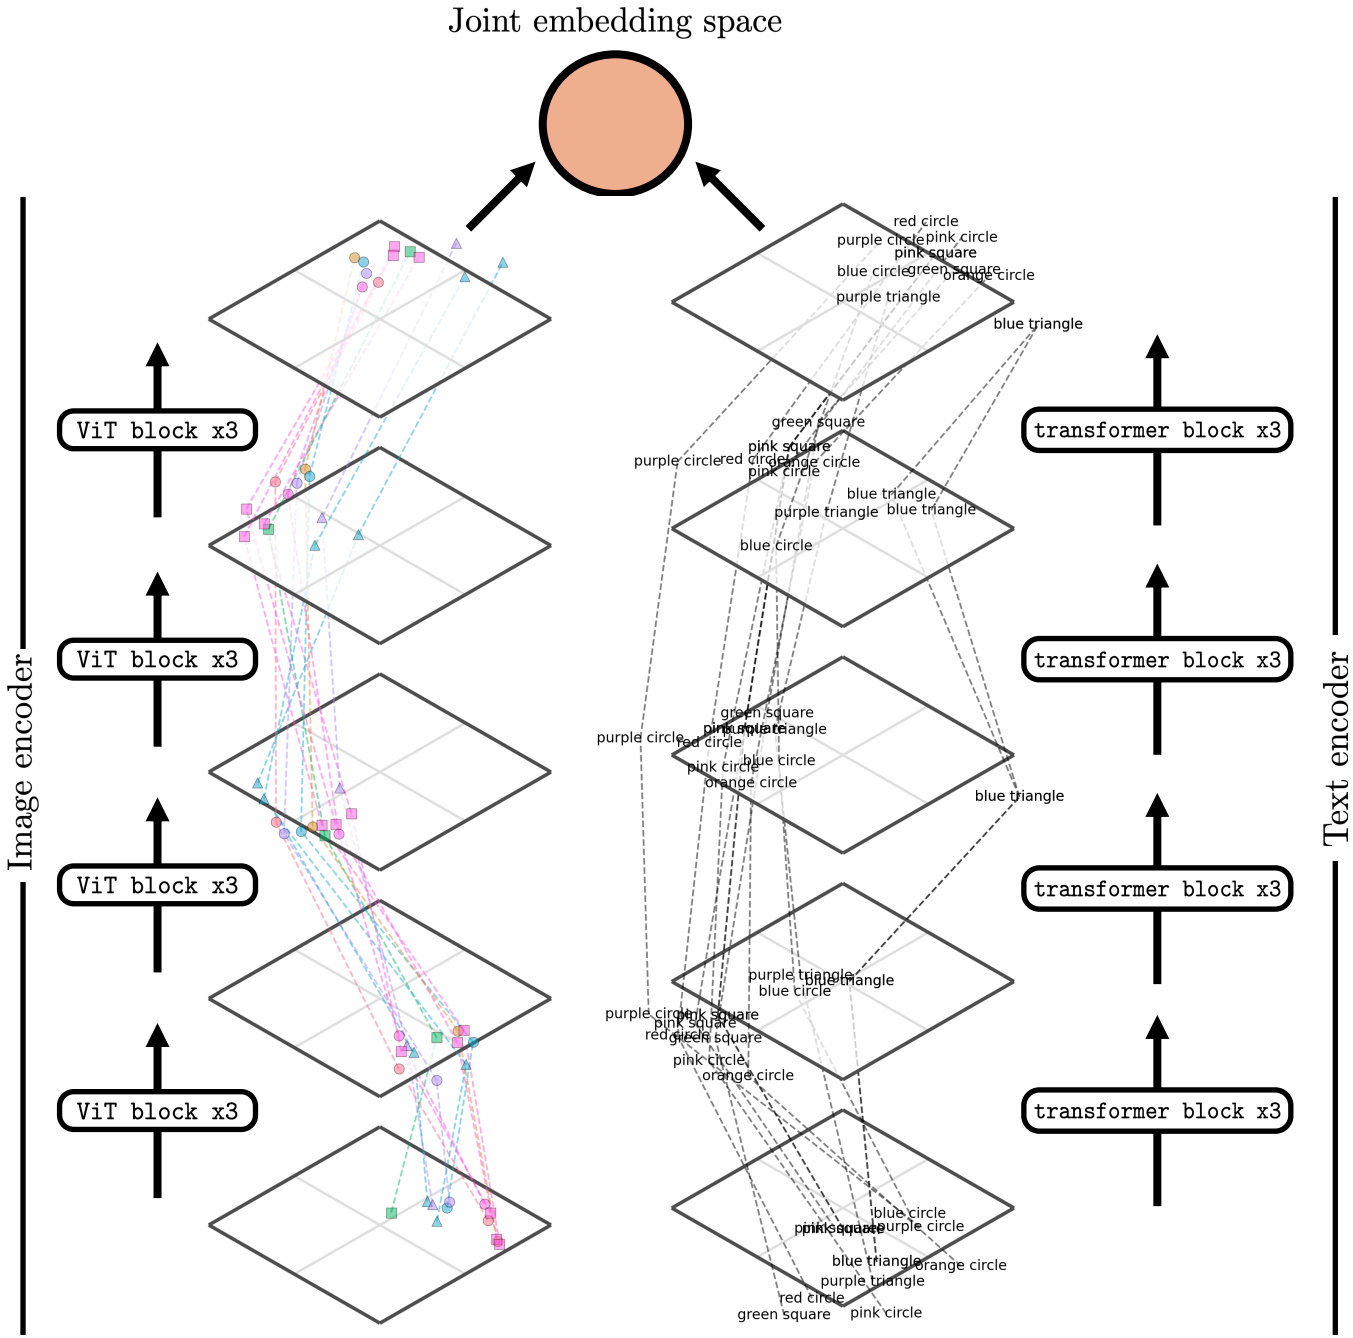
Hypothesis space

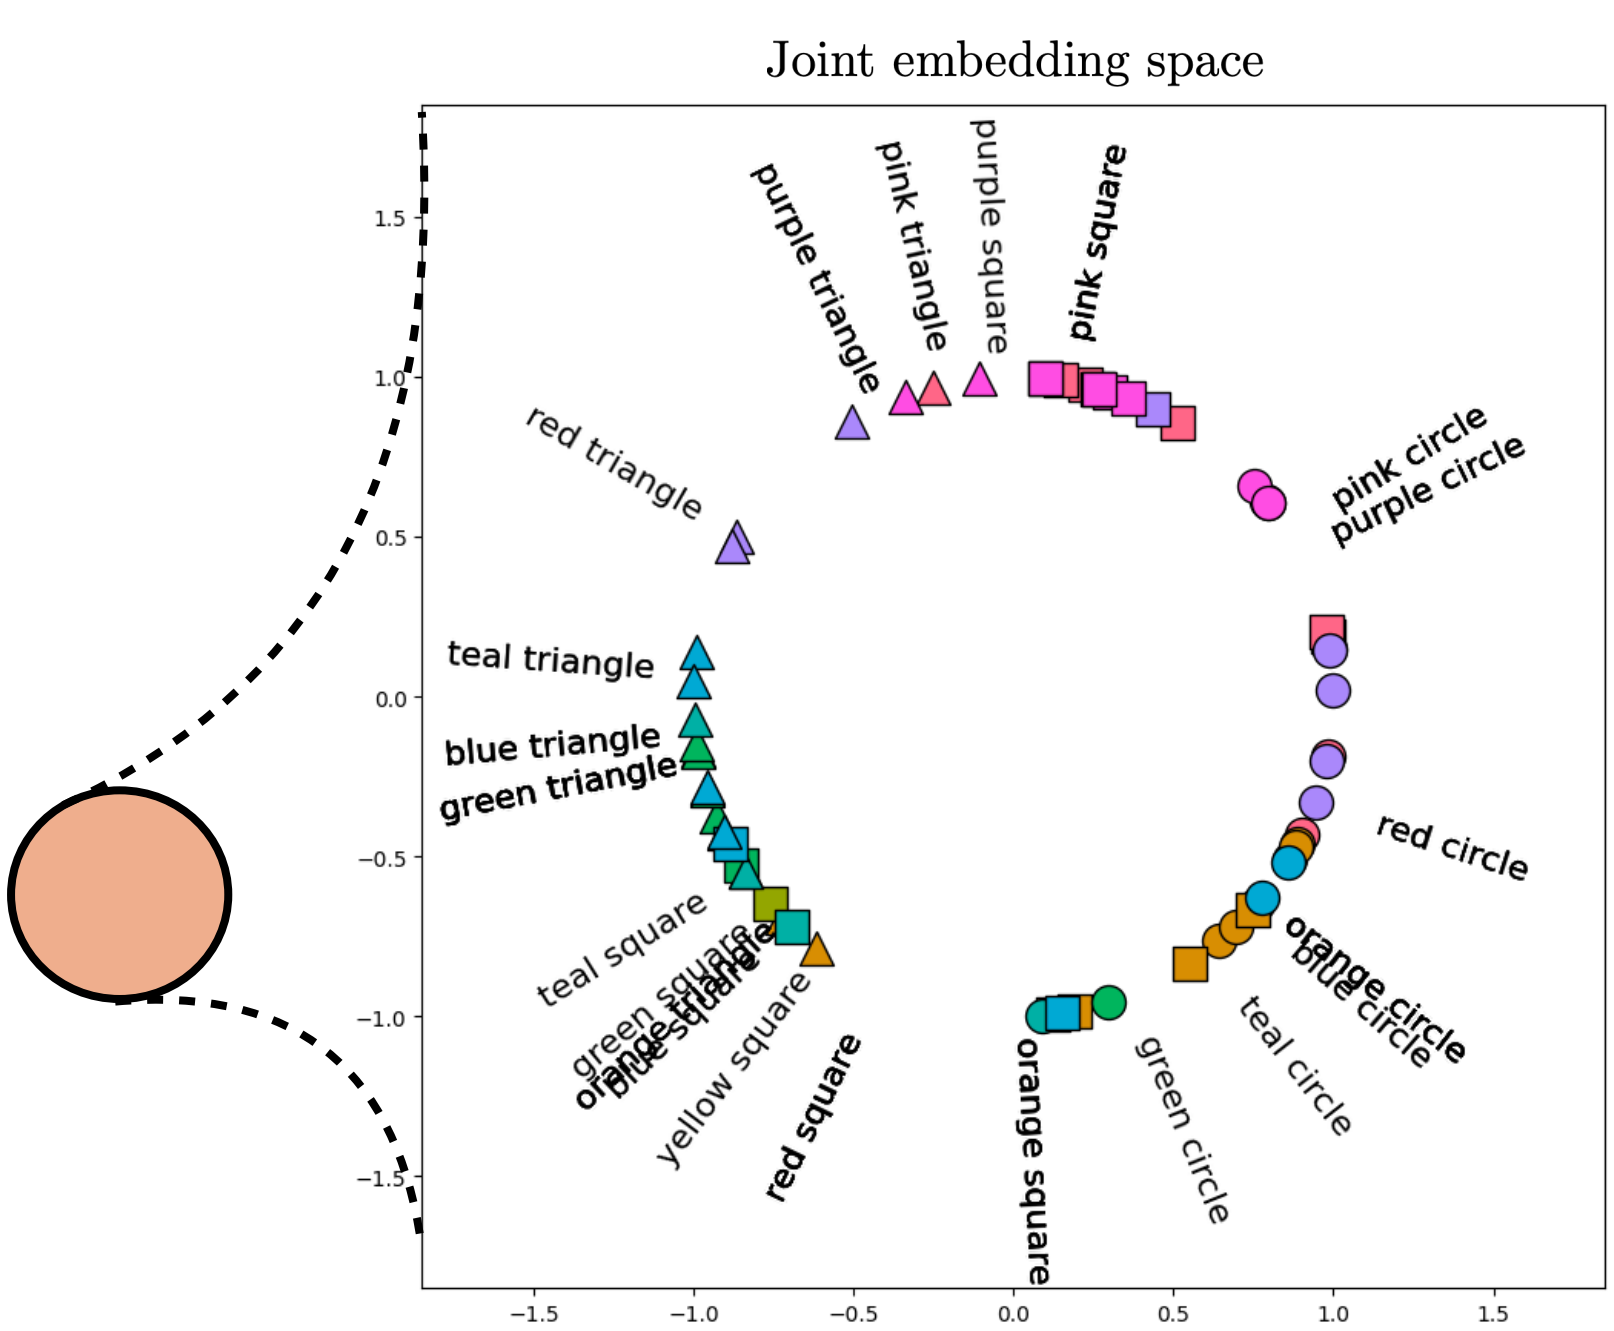
$$f_\ell : \mathbb{R}^{3\times N\times M} \to \mathbb{S}^{d_z}$$

$$f_t : \mathbb{R}^{T\times d_t} \to \mathbb{S}^{d_z}$$

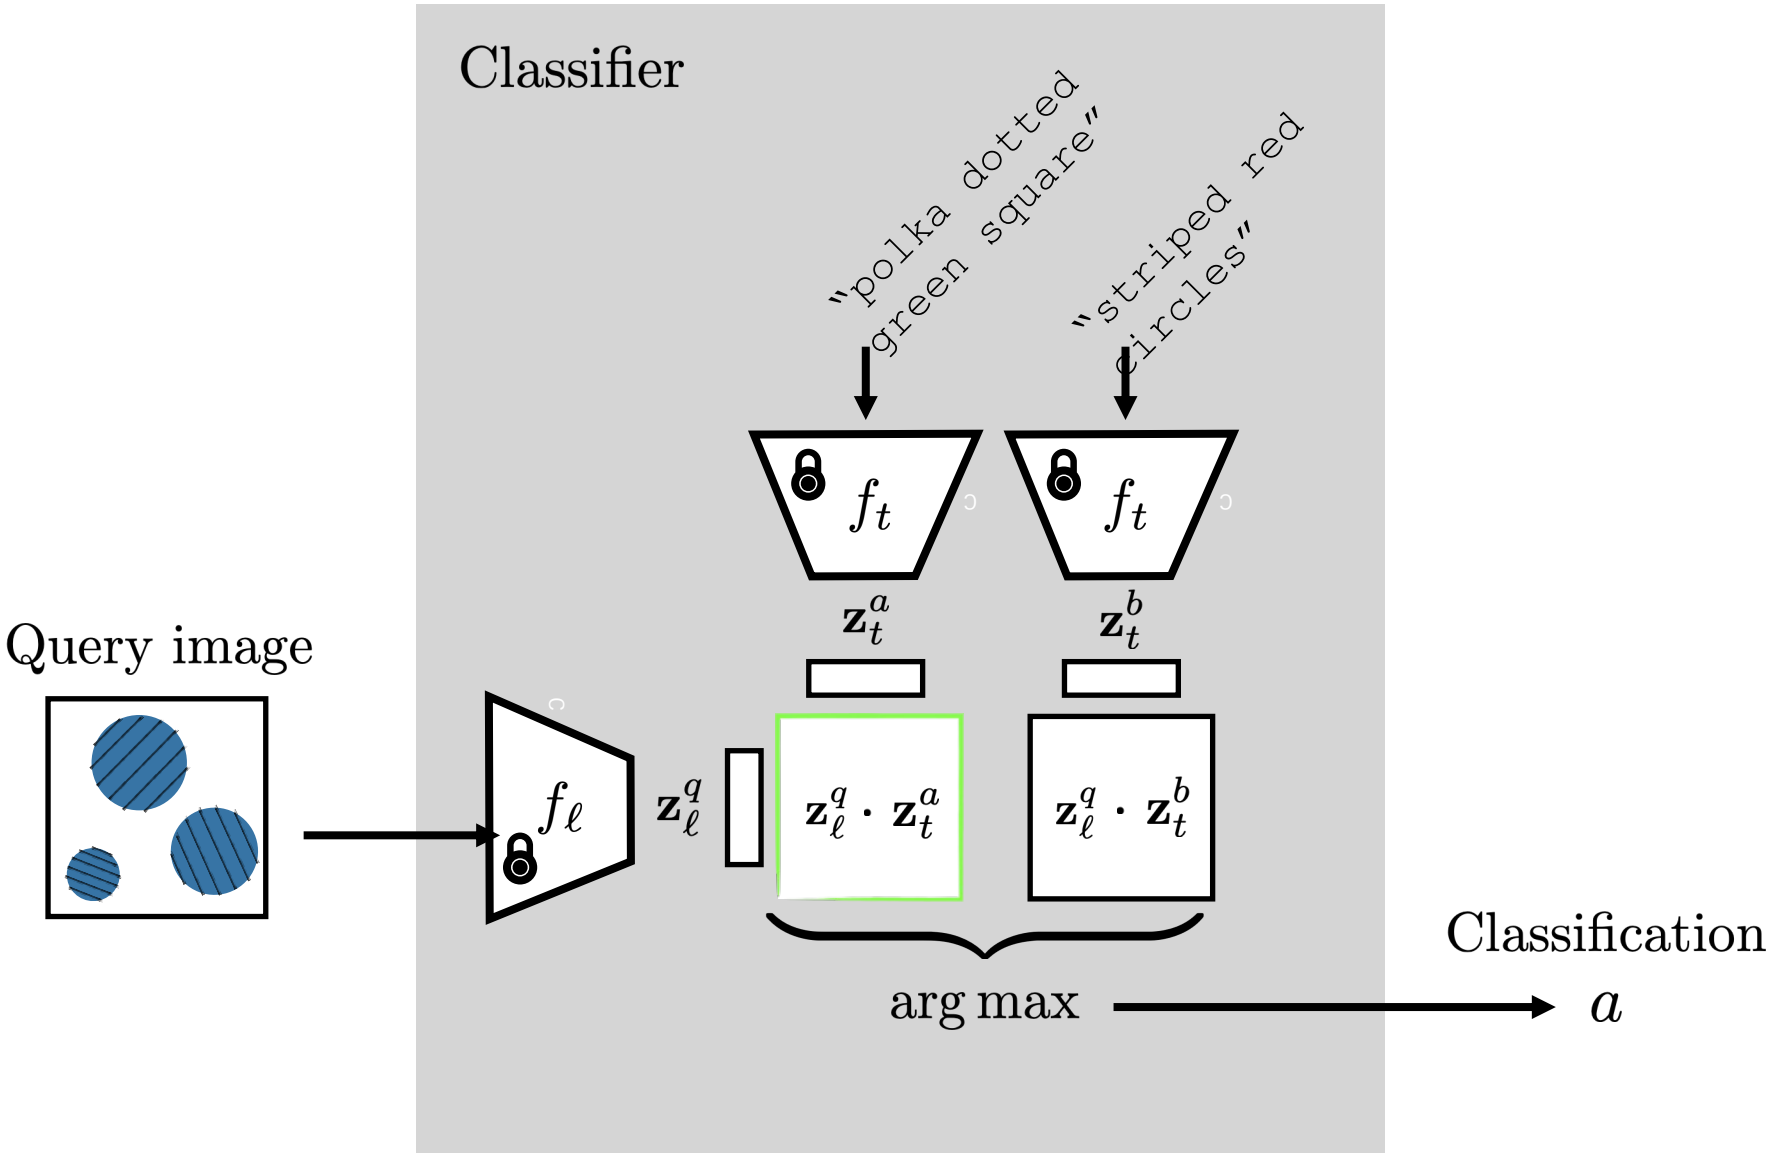
$$\longrightarrow f_\ell, f_t$$

双向的 InfoNCE 损失


Joint embedding space
Image encoder
ViT block x3
ViT block x3
ViT block x3
ViT block x3
Text encoder
transformer block x3
transformer block x3
transformer block x3
transformer block x3
red circle
purple circle
pink circle
pink square
blue circle
green square
orange circle
purple triangle
blue triangle
green square
pink square
purple circle
red circle
orange circle
pink circle
blue triangle
purple triangle
blue triangle
blue circle
green square
purple circle
red circle
pink circle
blue circle
orange circle
blue triangle
purple triangle
blue triangle
blue circle
purple circle
pink square
pink square
red circle
green square
pink circle
orange circle
blue circle
purple circle
pink square
blue triangle
orange circle
purple triangle
red circle
green square
pink circle


Joint embedding space
purple triangle
pink triangle
purple square
pink square
red triangle
pink circle
purple circle
teal triangle
blue triangle
green triangle
red circle
teal square
green square
orange square
blue square
yellow square
red square
orange circle
blue circle
teal circle
green circle
orange square
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5

Constructing a classifier using CLIP



西南交通大学
Southwest Jiaotong University

SCAI011112 视觉计算

Thank You