西南交通大学
Southwest Jiaotong University

SCAI011112 视觉计算

卷积神经网络

计算机科学与技术专业
2025-2026 (2)

Multilayer Perceptron (MLP)

linear comb. of neurons ▷

neuron-wise nonlinearity ▷

linear comb. of neurons ▷

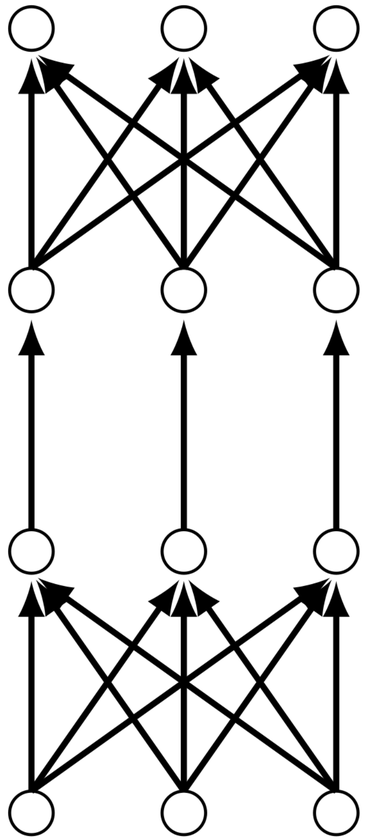

+ Universal
+ Simple (elegant theory)
+ Embarrassingly parallel

- Weak inductive biases
- Sample inefficient / data hungry
- Dense (fully-connected) linear layers take a lot of compute

- 画面中有很多物体，但天空也占据了很大一部分。
- 标签应该为“鸟群”？还是“天空”？
- 通常，一个标签是不够的！

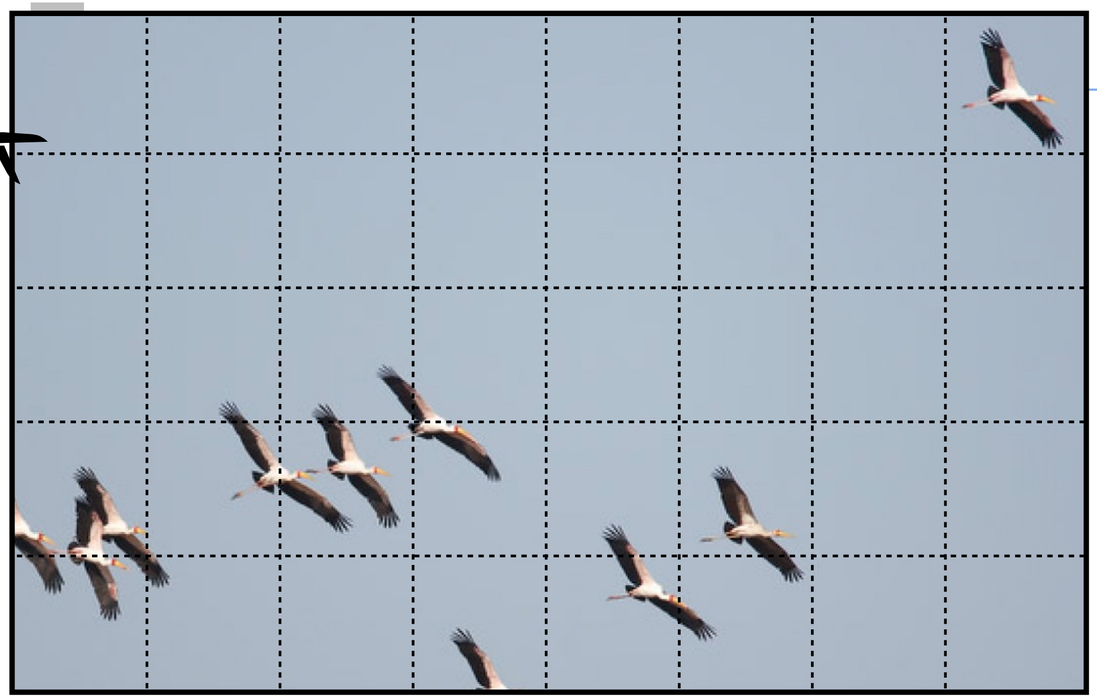

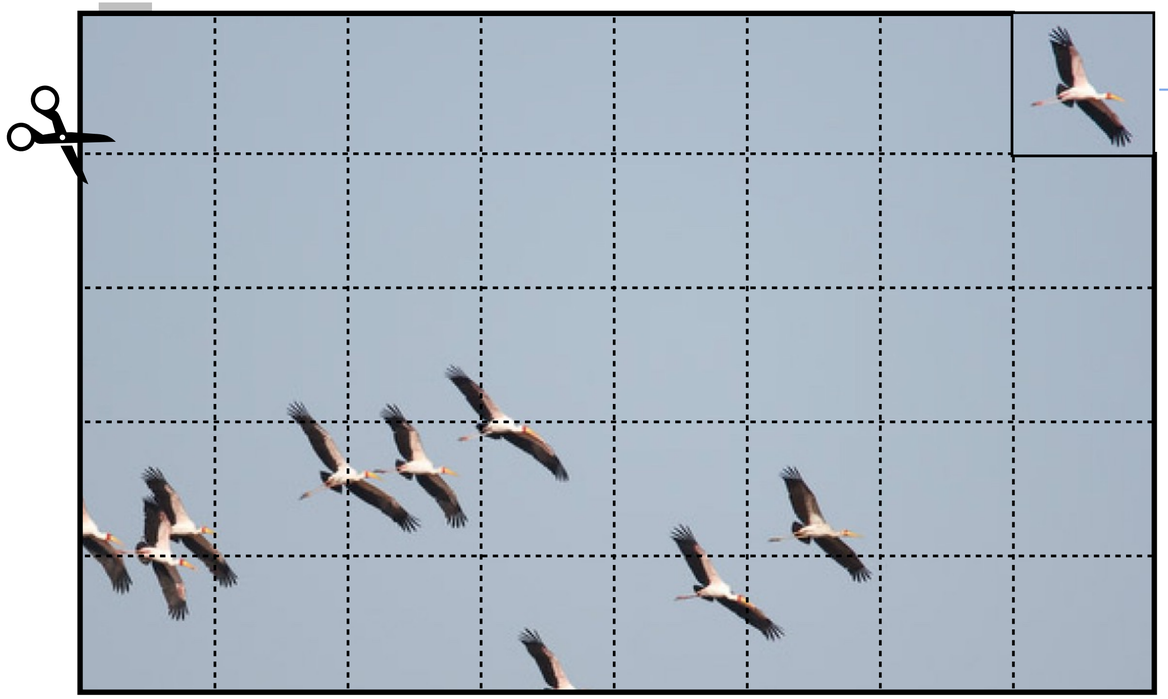

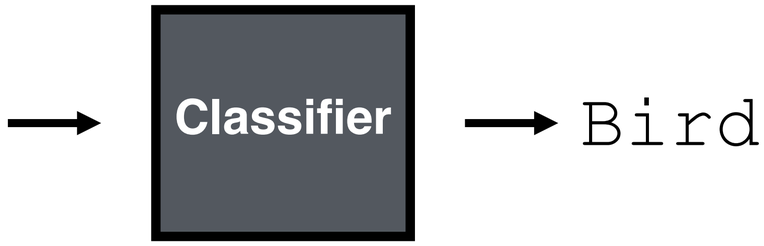
Classifier
Bird

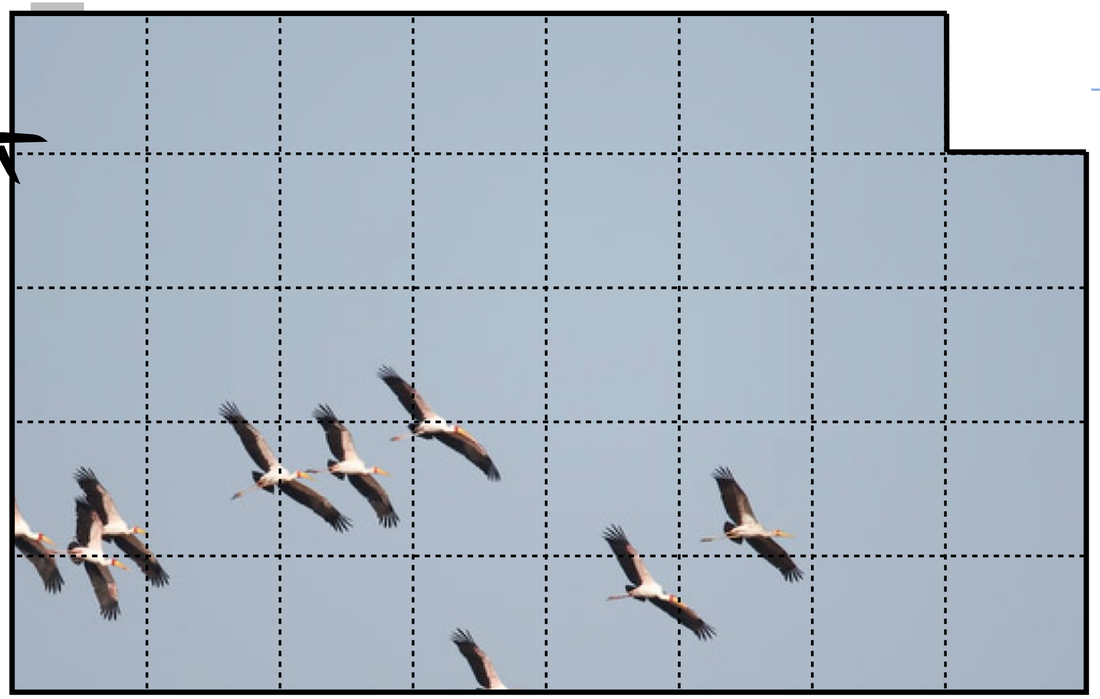

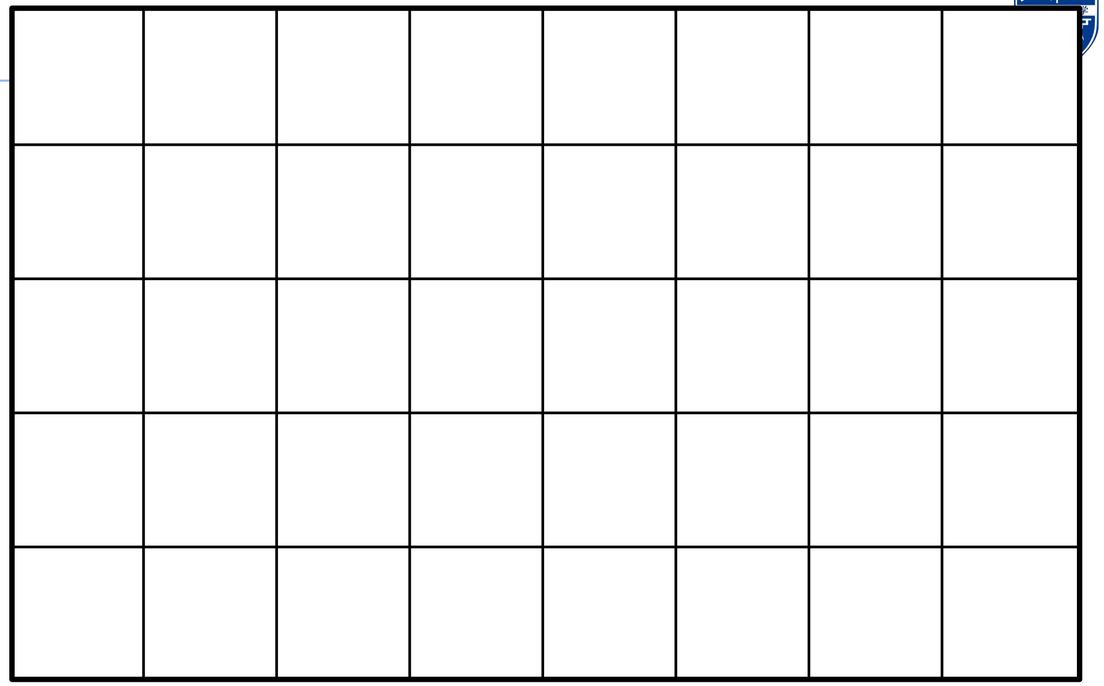

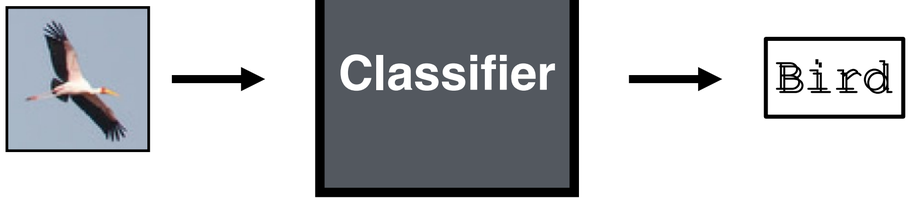
Classifier
Bird

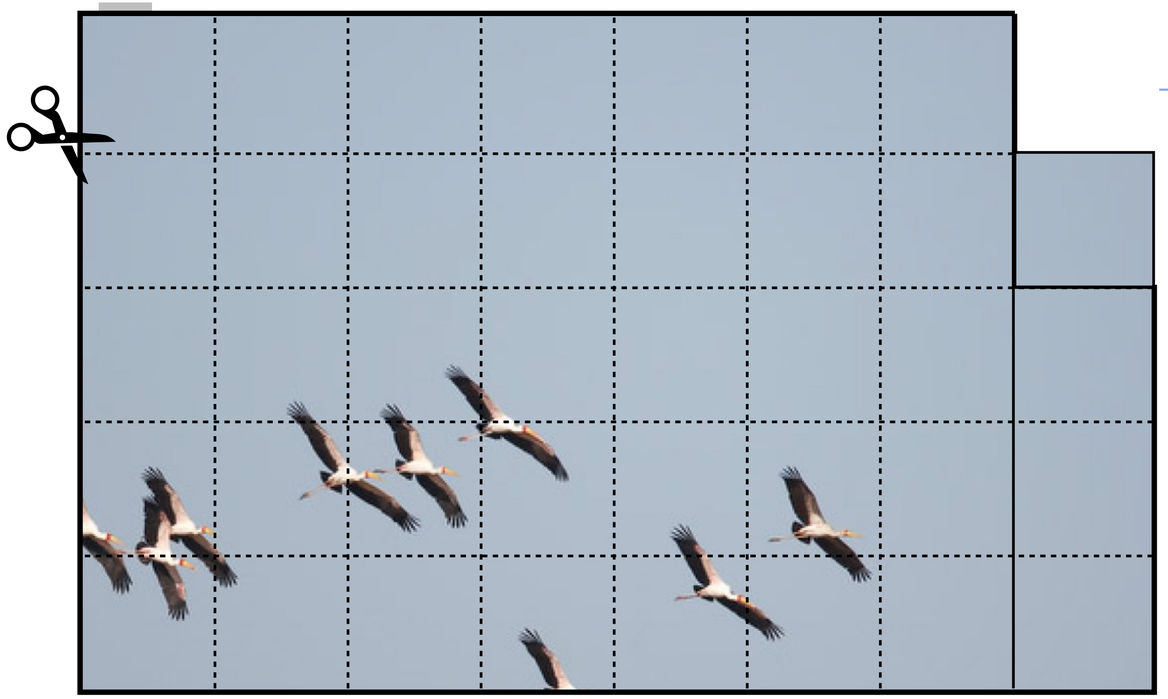

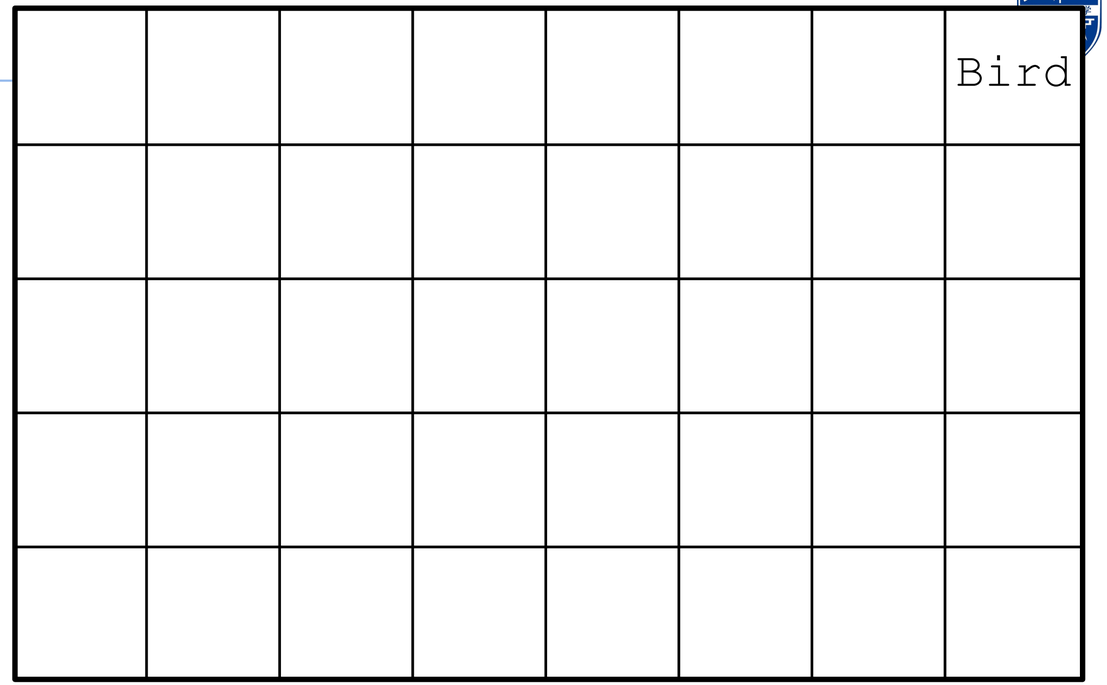
Bird

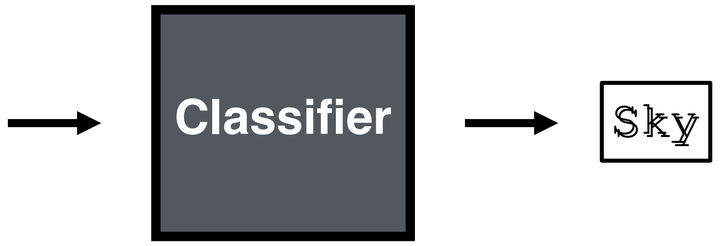
Classifier
Sky

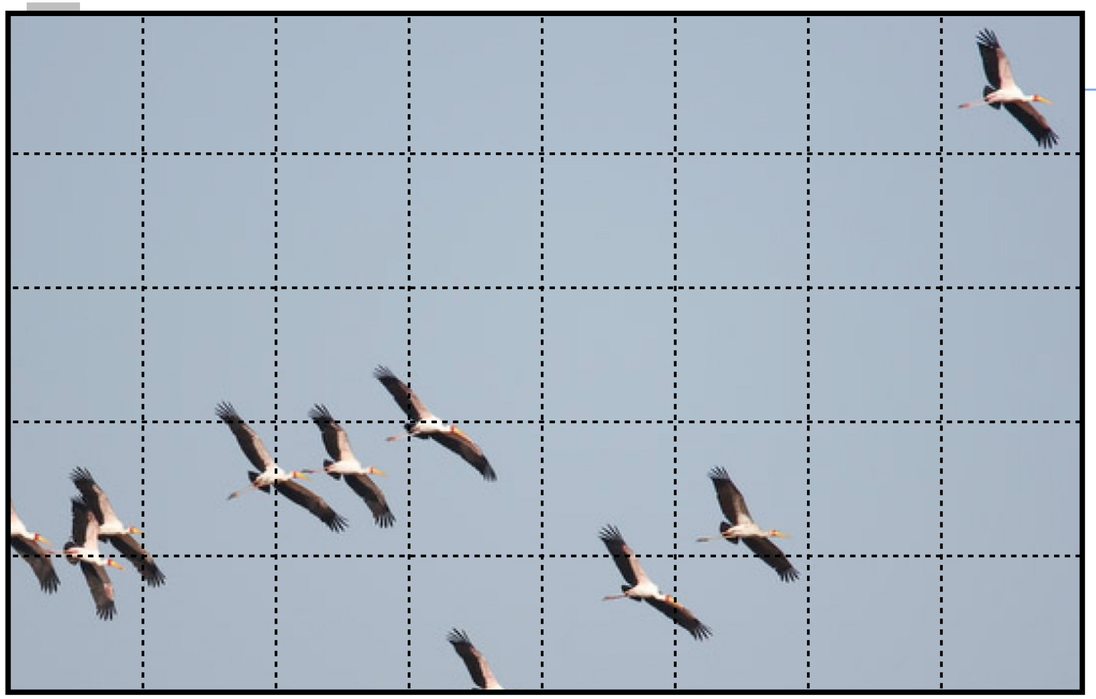

Sky	Sky	Sky	Sky	Sky	Sky	Sky	Bird
Sky	Sky	Sky	Sky	Sky	Sky	Sky	Sky
Sky	Sky	Sky	Sky	Sky	Sky	Sky	Sky
Bird	Bird	Bird	Sky	Bird	Sky	Sky	Sky
Sky	Sky	Sky	Bird	Sky	Sky	Sky	Sky

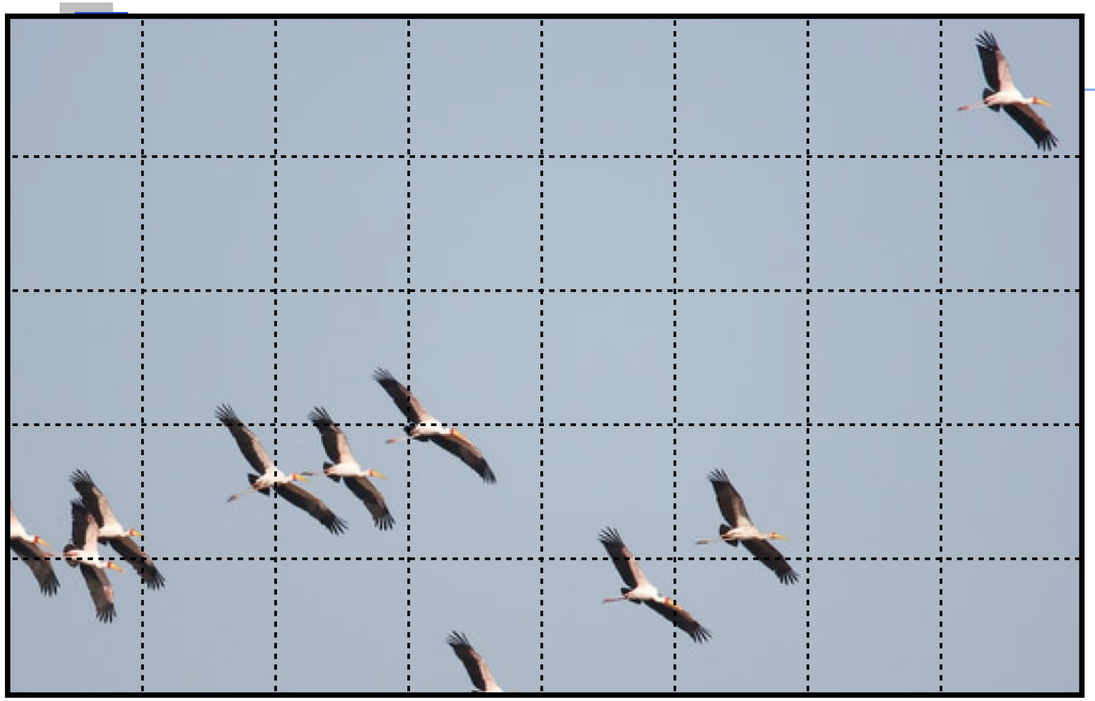

CNN

sky	sky	sky	sky	sky	sky	sky	bird
sky	sky	sky	sky	sky	sky	sky	sky
sky	sky	sky	sky	sky	sky	sky	sky
bird	bird	bird	bird	sky	bird	sky	sky
sky	sky	sky	bird	bird	sky	sky	sky

- 如果物体无法完美地适合这些区域怎么办?
- 如何提高输出的图（map）的分辨率?

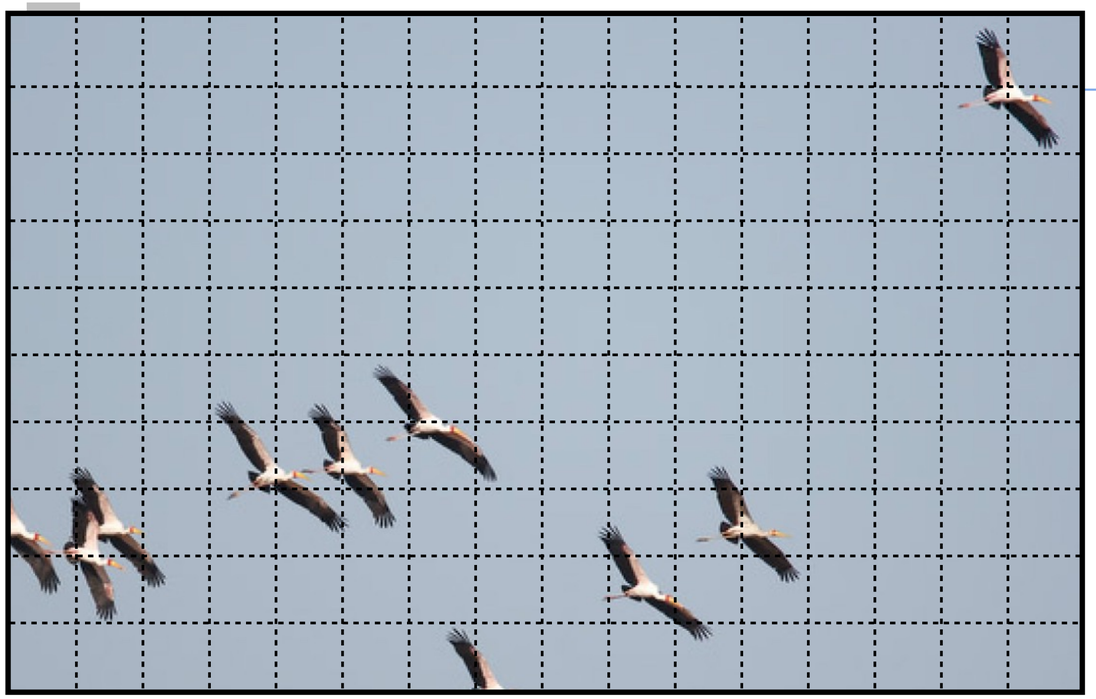

更小的区域块（patch）可以提高分辨率，但每个块中的内容不易辨认。

因此，我们使用大但是有重叠的区域块

What's the object class of the center pixel?

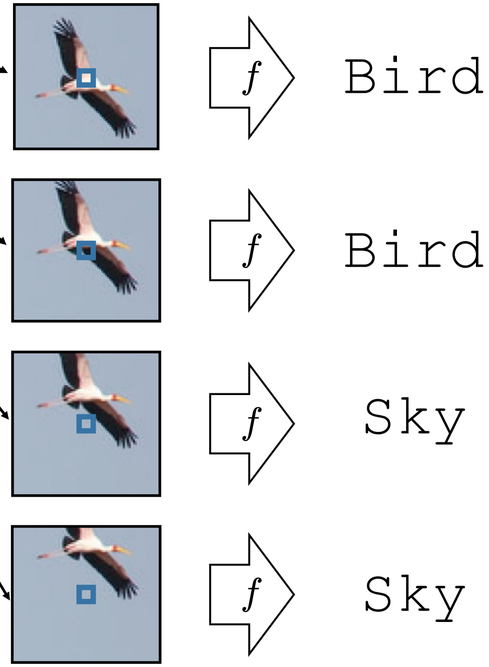

What's the object class of the center pixel?

Training data

$\mathbf{x}$ y

{ , Bird }

{ , Bird }

{ , Sky }

⋮

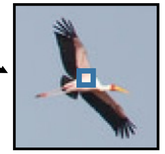 f Bird

f Bird

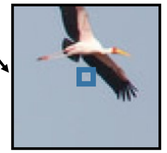 f Sky

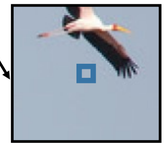 f Sky

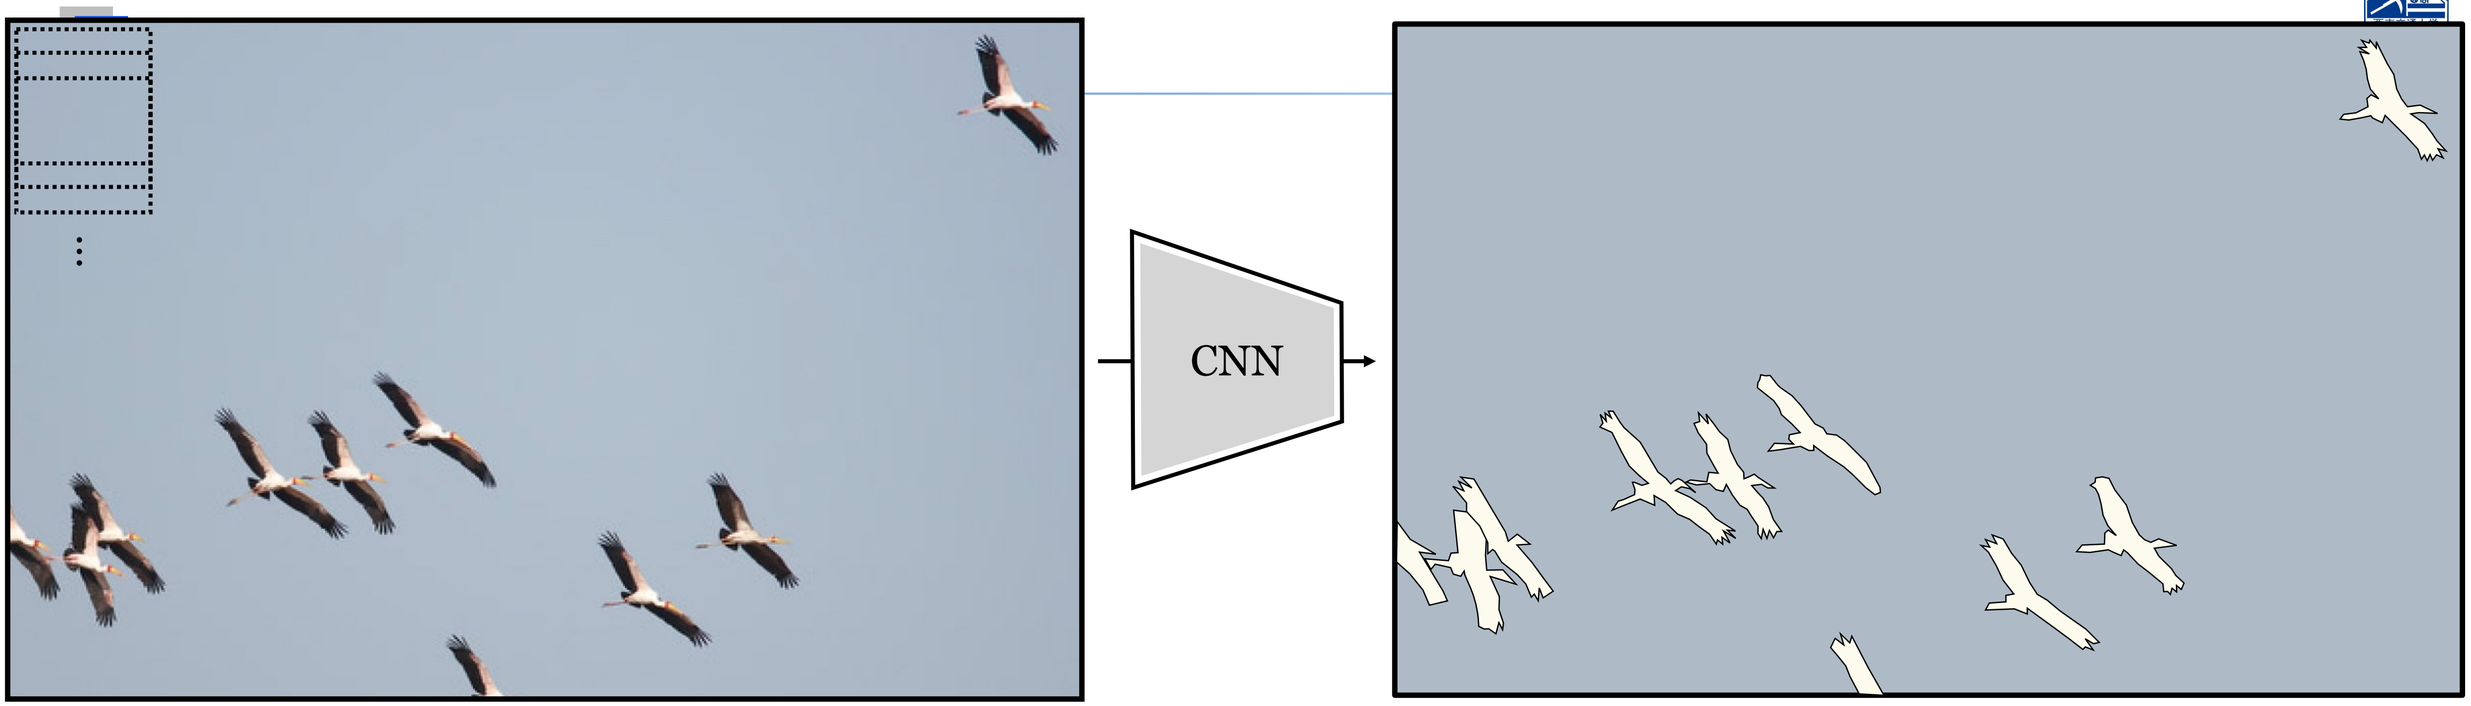

(Colors represent one-hot codes)

语义分割

What's the object class of the center pixel?

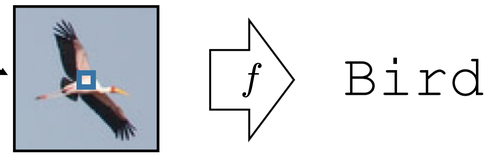

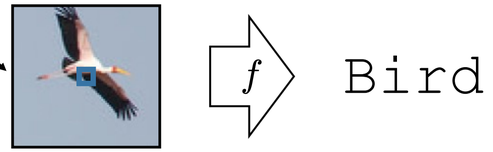

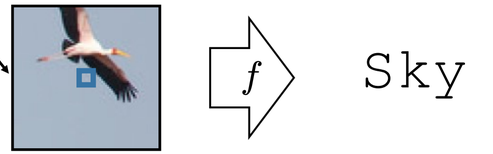

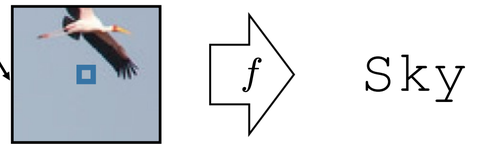

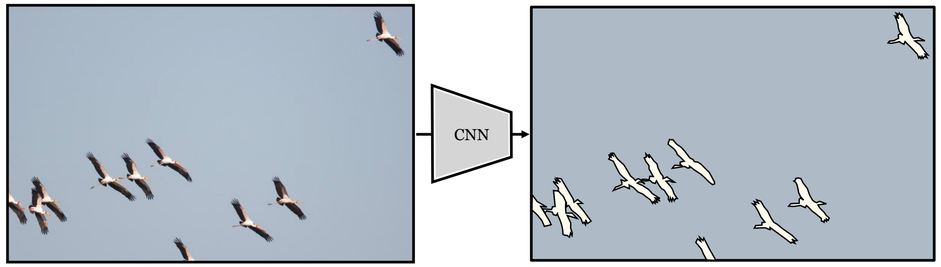

平移不变：以相同的方式处理每个区域块。

等变映射:

$$f(\texttt{translate}(x)) = \texttt{translate}(f(x))$$

W 计算该图像块中所有像素的加权和

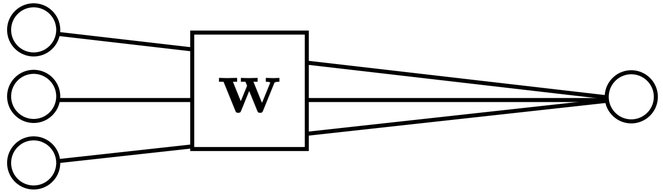

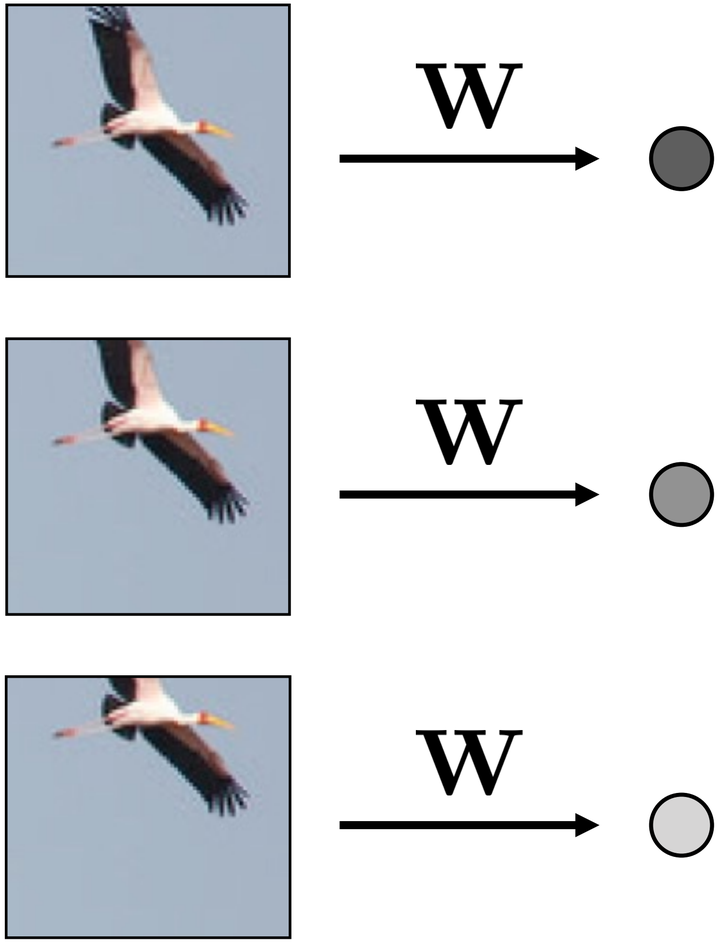

W 是一个应用于整张图像的**卷积核**!

全连接网络

Fully-connected (fc) layer

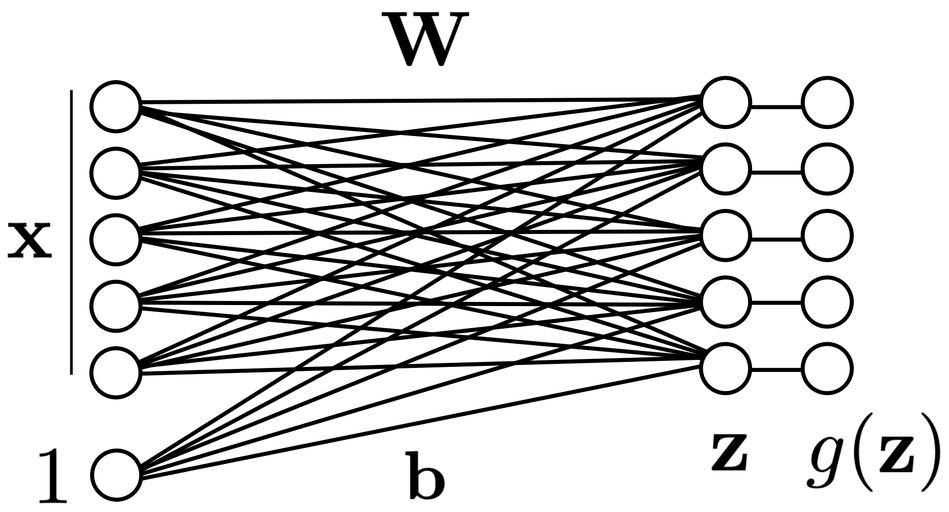

局部全连接网络

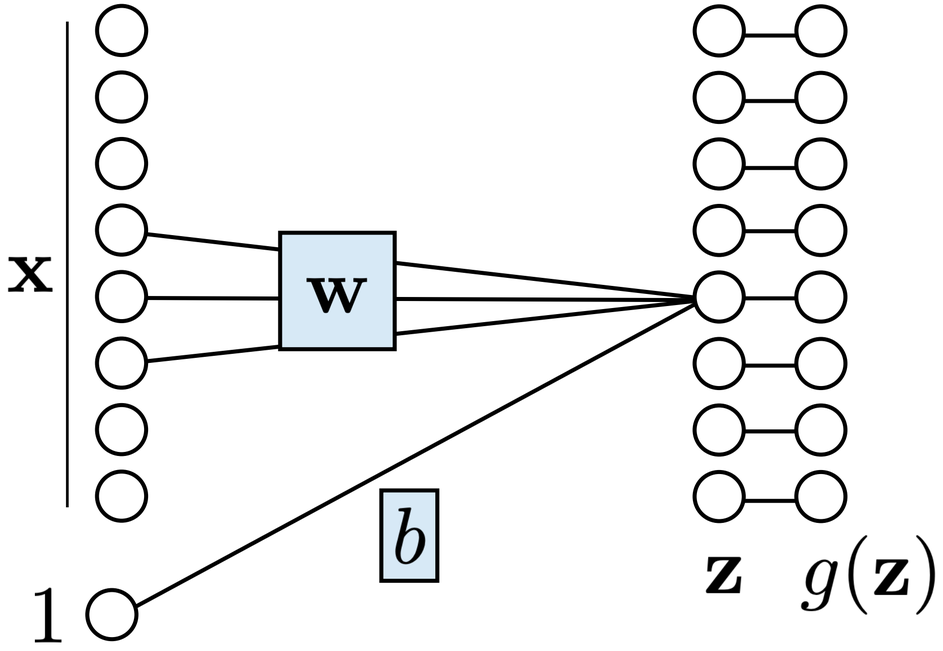

- 通常，我们假设输出是输入的局部函数。
- 如果我们使用相同的权重（即权重共享）来计算每一个局部函数，我们就得到了一个卷积神经网络。

卷积神经网络

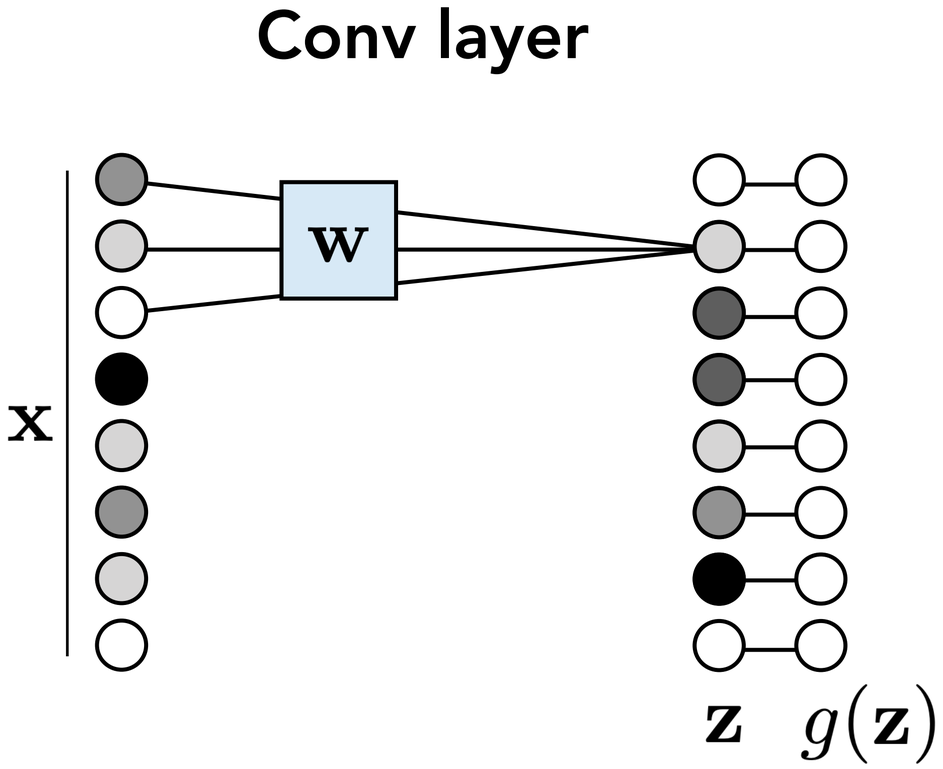

$$\mathbf{z} = \mathbf{w} \star \mathbf{x} + b$$

- 通常，我们假设输出是输入的局部函数。
- 如果我们使用相同的权重（即权重共享）来计算每一个局部函数，我们就得到了一个卷积神经网络。

全连接的线性层

$$\mathbf{x}_{\mathbf{out}} = \mathbf{W}\mathbf{x}_{\mathbf{in}} + \mathbf{b}$$

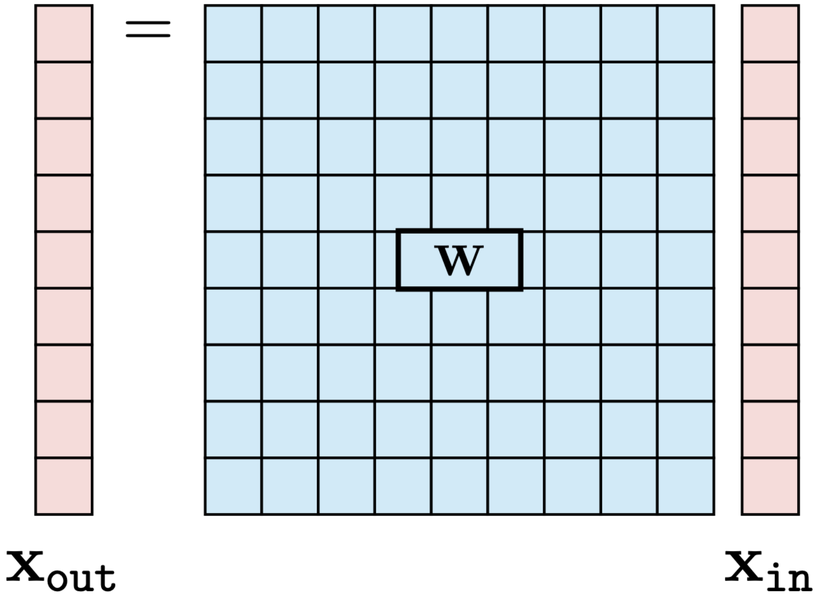

$\Longleftrightarrow$

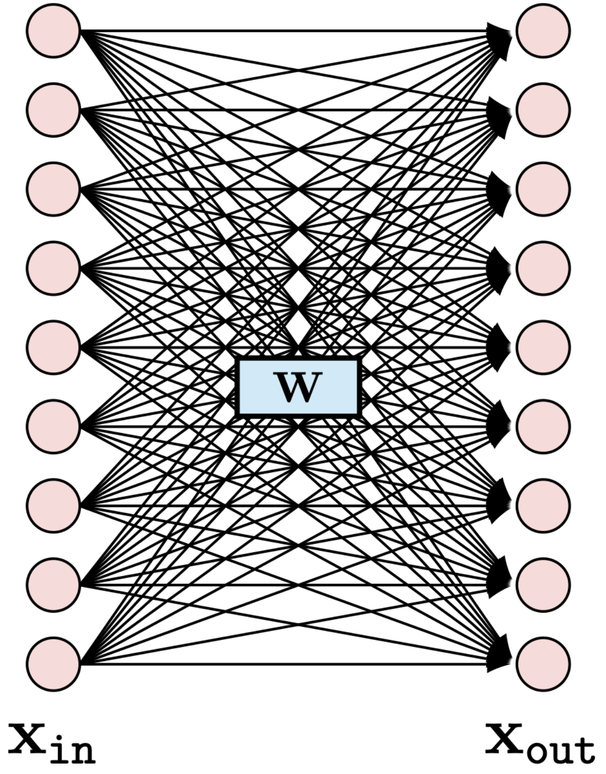

卷积层

$$\mathbf{x}_{\text{out}} = \mathbf{w} \star \mathbf{x}_{\text{in}} + b$$

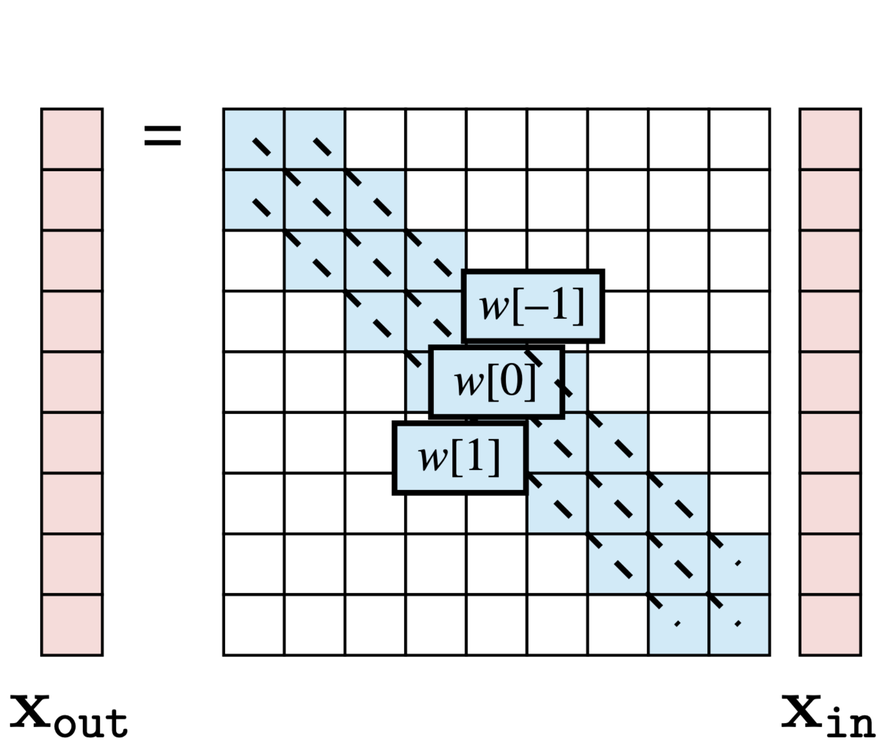

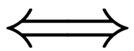

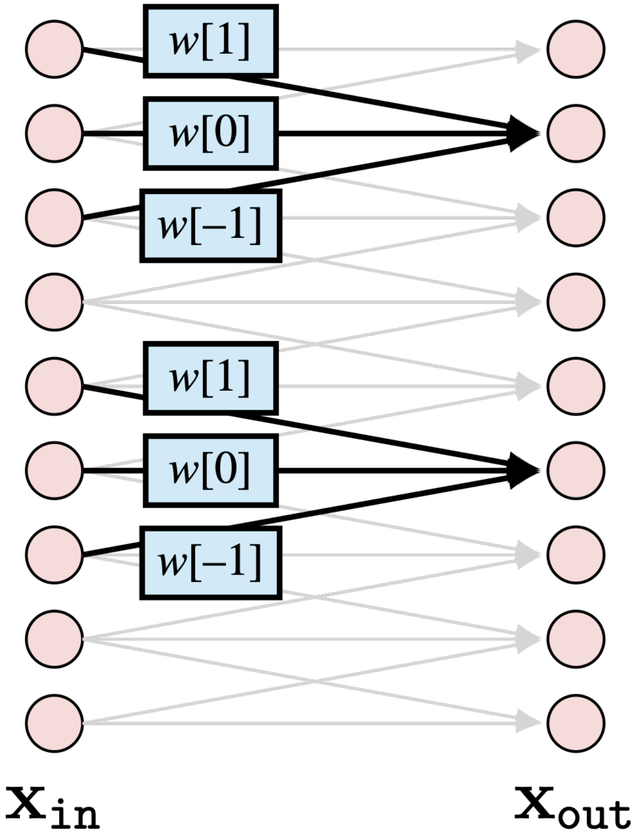

卷积层

Toeplitz（托普利茨）矩阵

$$\begin{pmatrix} a & b & c & d & e \\ f & a & b & c & d \\ g & f & a & b & c \\ h & g & f & a & b \\ i & h & g & f & a \end{pmatrix}$$

Toeplitz矩阵是指每一条从左上到右下的对角线上的元素都分别相同的矩阵。

$$\mathbf{y} = \quad \mathbf{x}$$

e.g., pixel image

- 约束的线性层
- 更少的参数—> 更容易学习, 更少的过拟合

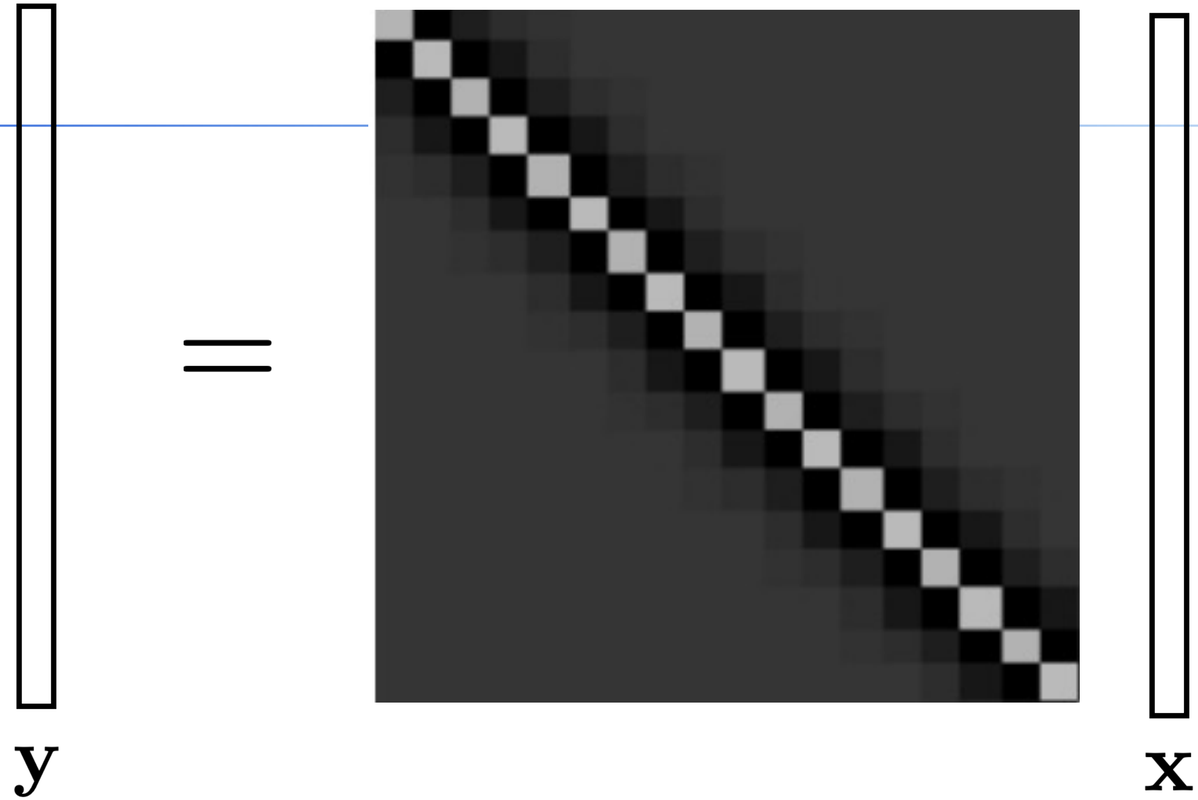
y
=
x

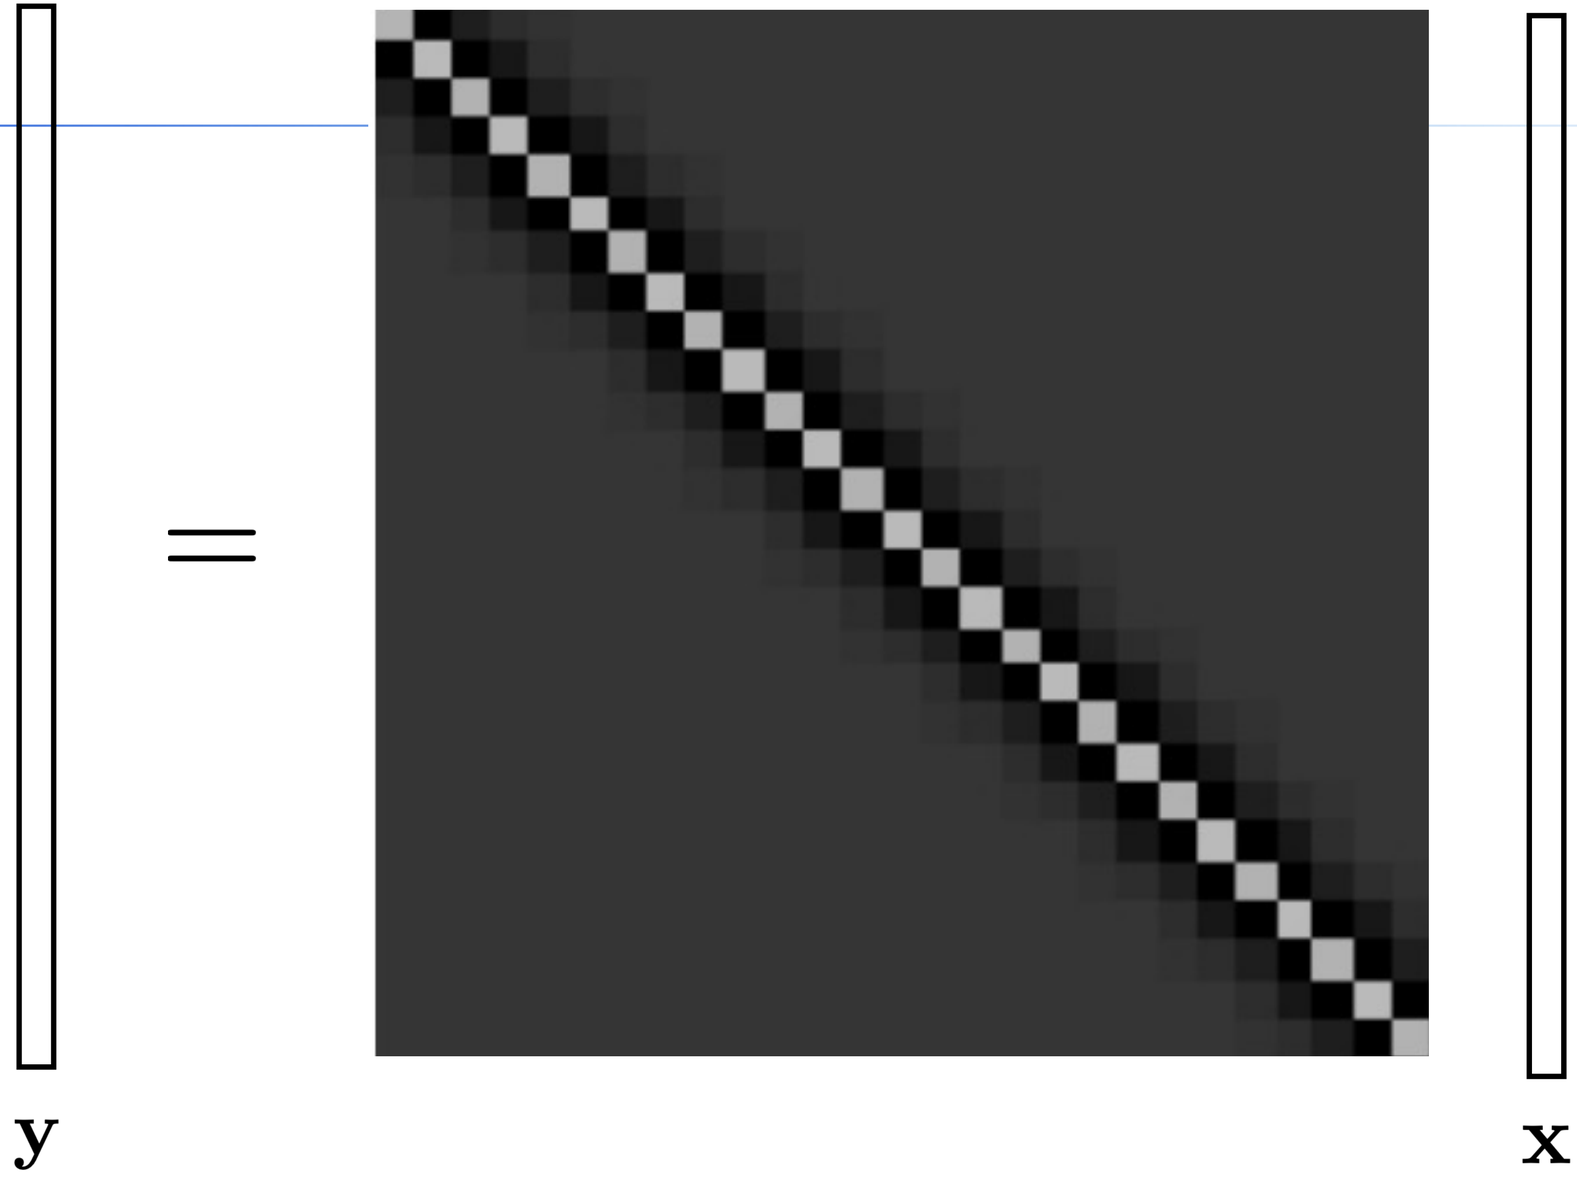

卷积层可以应用于任意尺寸的输入

(得益于其架构特性，它能够泛化处理与训练数据尺寸不同的图像！)

卷积层的五个视角

1. 平移等变 $f(\texttt{translate}(x)) = \texttt{translate}(f(x))$

2. 区域块的处理

3. 图像滤波

4. 参数共享

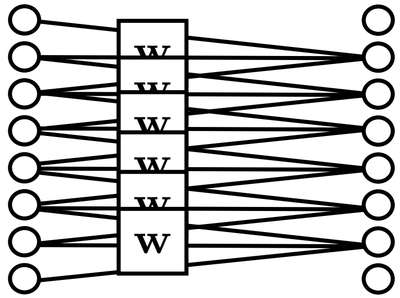

5. 一种处理可变大小张量的方法

多通道输入与多通道输出

- 在图像处理中，卷积通常指的是对单通道信号进行滤波并产生单通道输出
- 但是在神经网络中，卷积层更加通用，通常**将多通道输入映射为多通道输出**。

多通道输入

- 假设我们有一张RGB图像 $\mathrm{x}_{in} \in \mathbb{R}^{3\times N\times M}$，要将卷积层应用于这样的多通道图像，可使用一个多通道的滤波器 $w \in \mathbb{R}^{C\times N\times M}$，用对应的滤波器通道对每个输入通道进行滤波，然后将这些响应（计算结果）相加：

$$\mathbf{x}_{\text{out}} = \sum_{c} \mathbf{w}[c,:,:] \star \mathbf{x}_{\text{in}}[c,:,:] + b[c] \quad \triangleleft \quad \textbf{conv} \quad (\text{multichannel in})$$

该输出 x_{out} 为一个单通道图像

多通道输出

- 通常，神经网络中的每个卷积层都会应用一组滤波器，即一个滤波器组（filter bank）$w_0, w_1, \ldots, w_{C-1}$
- 将它们应用于一张灰度输入图像 $\mathrm{x}_{in} \in \mathbb{R}^{N \times M}$，我们就会得到相应数量的输出图像：

$$\begin{aligned}
\mathbf{x}_{\mathrm{out}}[0,:,:] &= \mathbf{w}[0,:,:] \star \mathbf{x}_{\mathrm{in}} + b[0] \\
&\vdots \\
\mathbf{x}_{\mathrm{out}}[C,:,:] &= \mathbf{w}[C-1,:,:] \star \mathbf{x}_{\mathrm{in}} + b[C-1]
\end{aligned}$$

- 该输出 x_{out} 为一个 C 通道图像，每一个通道都是输入图像对其中一个滤波器的响应。
- 我们使用“图像”一词来指代任何测量值或特征的二维数组。将每一个通道称为特征图（feature map），因为它展示了输入的某些特征。

多通道输入，多通道输出

- 可以定义一个通用的卷积层，它能将具有C_{in}个输入通道的信号映射为具有C_{out} 个输出通道的信号。
- 对于一张输入图像 $\mathrm{x}_{in} \in \mathbb{R}^{C_{in} \times N \times M}$ ，其中 c_2 是输出通道的索引：

$$\mathbf{x}_{\mathrm{out}}[c_2, :, :] = \sum_{c_1=1}^{C_{\mathrm{in}}} \mathbf{w}[c_1, c_2, :, :] \star \mathbf{x}_{\mathrm{in}}[c_1, :, :] + b[c_2]$$

$$c_2 \in \{0, \ldots, C_{\mathrm{out}} - 1\}$$

多通道输入，多通道输出

- $\mathbf{x}_{\text{in}}[c_1,:,:]$是输入信号的第 c_1 个通道。
- 滤波器组由一个张量 $\mathbf{w} \in \mathbb{R}^{c_{\text{in}} \times c_{\text{out}} \times \text{K} \times \text{K}}$ 来表示。
- 该卷积层将输入 $\mathbf{x}_{\text{in}} \in \mathbb{R}^{c_{\text{in}} \times N \times M}$ 映射为输出 $\mathbf{x}_{\text{out}} \in \mathbb{R}^{c_{\text{out}} \times N \times M}$

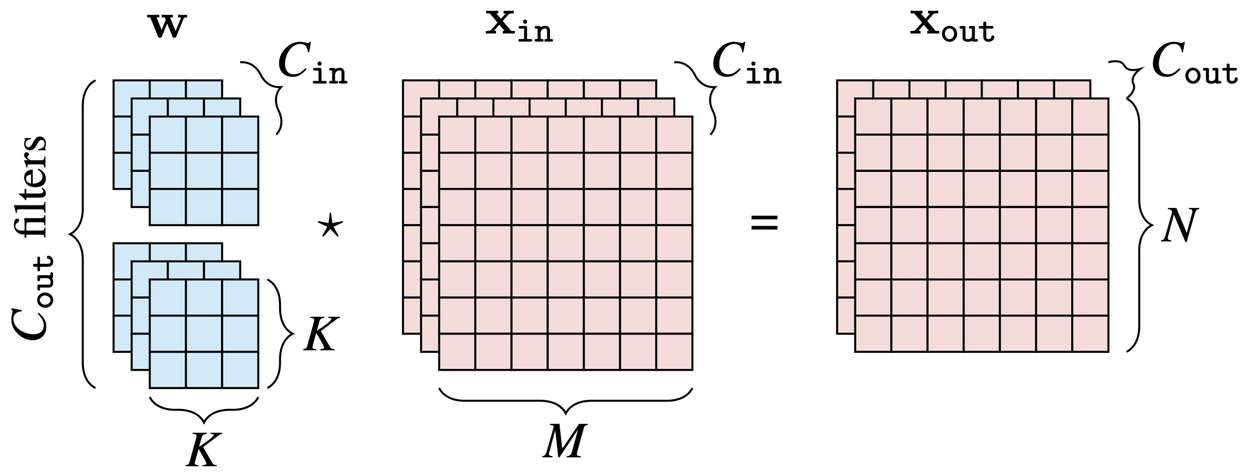

$$\mathbf{x}_{\text{out}}[c_2,:,:] = \sum_{c_1=1}^{C_{\text{in}}} \mathbf{w}[c_1, c_2, :, :] \star \mathbf{x}_{\text{in}}[c_1, :, :] + b[c_2]$$

Input channel　　Output channel

例

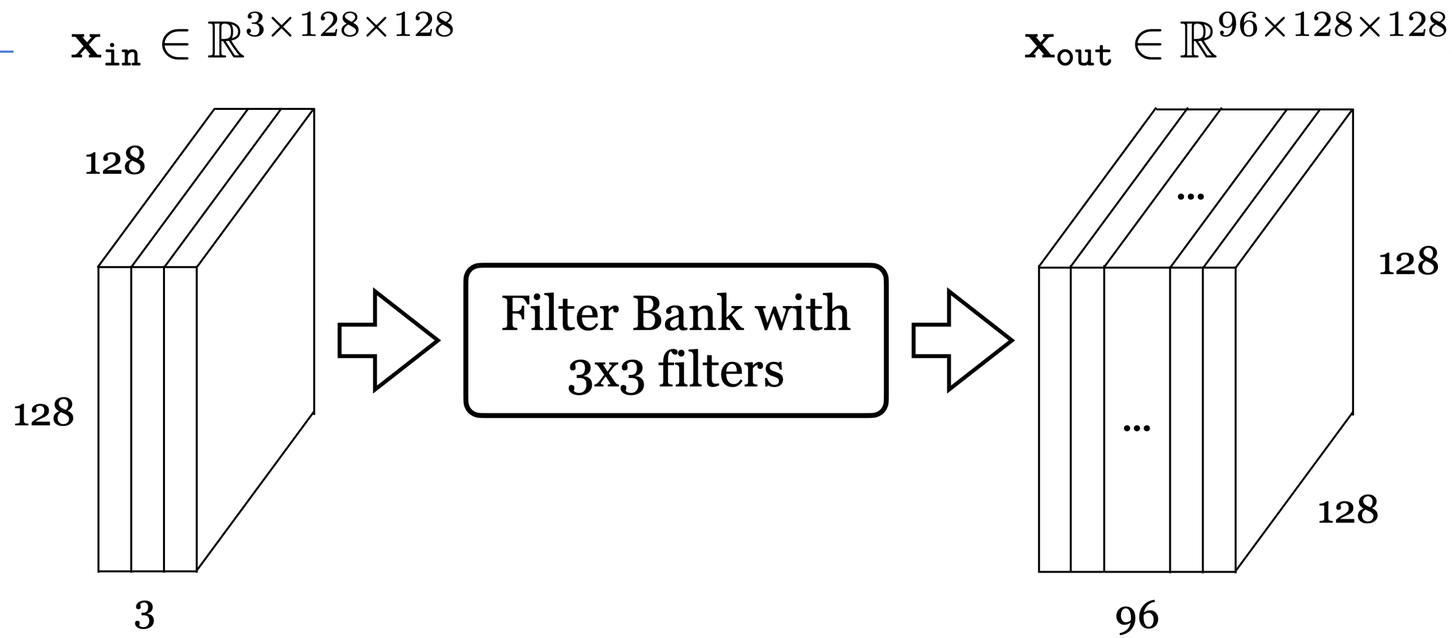

How many parameters does each filter have?

(a) 9 (b) 27 (c) 96 (d) 864

How many filters are in the bank?

(a) 3 (b) 27 (c) 96 (d) can't say

步长卷积（Strided Convolution）

- 标准的卷积层会保持其所处理信号的空间分辨率（即图像的长宽不变）
- 通常情况下，输出一个较低的分辨率往往就已经足够了，这可以通过步长卷积来实现：

$$x_{\text{out}}[n,m] = b + \sum_{k_1,k_2=-K}^{K} w[k_1,k_2]\, x_{\text{in}}[s_n n - k_1, s_m m - k_2]$$

S_n 和 S_m分别是垂直和水平方向上的步长

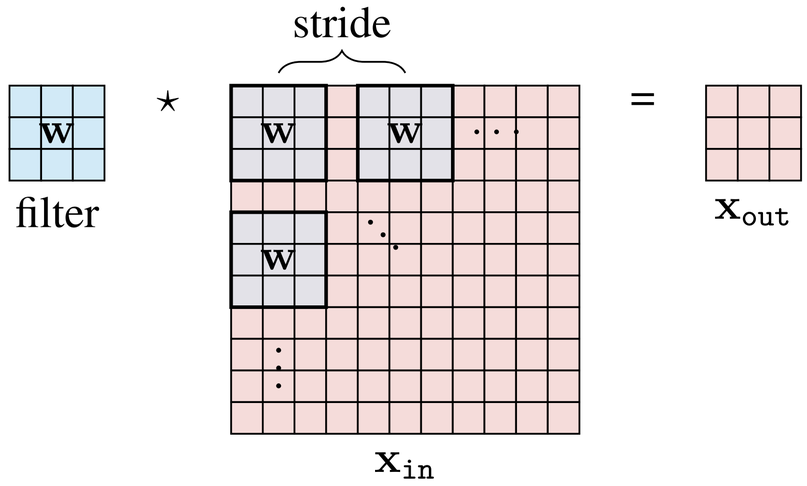

可实现下采样
(Downsampling)

$$\mathbb{R}^{N\times M} \rightarrow \mathbb{R}^{N/\mathbf{s}_n \times M/\mathbf{s}_m}$$

步长卷积（Strided Convolution）

- 当神经网络规模较大时，步长卷积可以显著降低计算成本和内存需求。
- 然而，步长卷积也会降低卷积的质量。
- 它本质上是一种“跳跃式”的扫描。类比看书时，每次只读每页的第一句话，虽然翻书很快，但必然会漏掉很多细节。

步长卷积（Strided Convolution）

$$\mathbf{w} = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

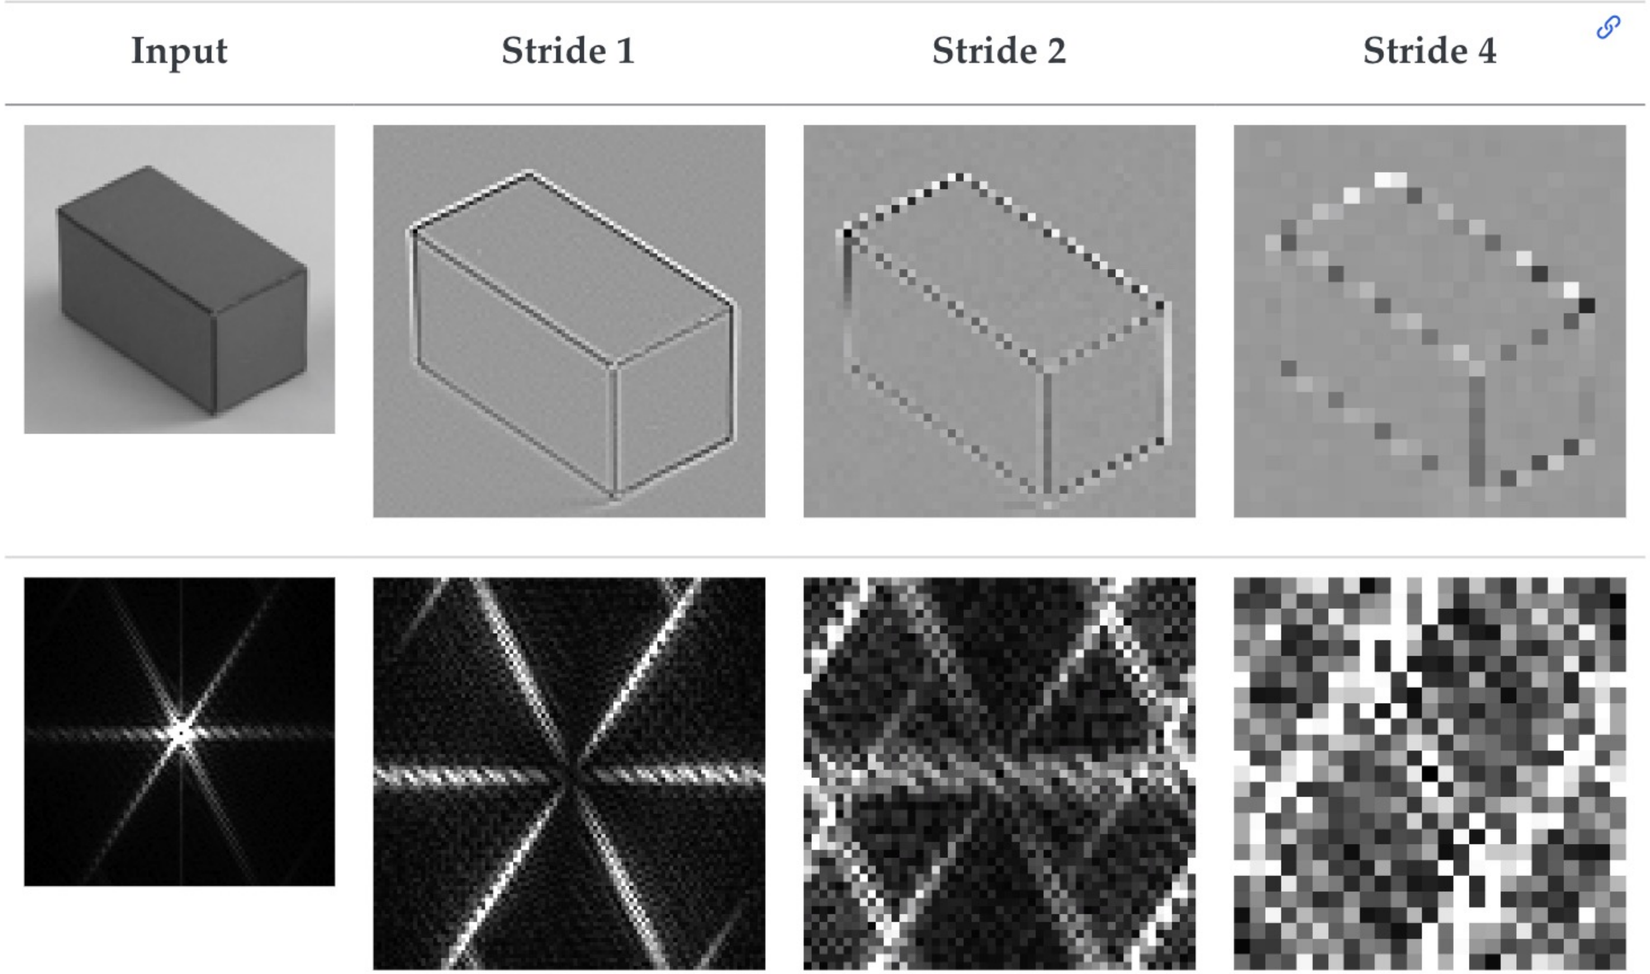

步长增大时，边界开始出现一些伪影（artifacts）；甚至导致部分边界直接消失。

离散傅里叶变换（DFT）的幅度谱，步长增大时，可以观察到严重的混叠（aliasing）伪影

- 学习过程会倾向于寻找能减少混叠伪影的卷积核，因为这些伪影通常会导致损失函数升高。
- 每一层包含多个通道，这组可学习的卷积核也许能够学会协同，去补偿其他通道所产生的混叠现象。
- 然而，这样一来就会压缩有效卷积核的探索空间，并且网络最终的学习结果也未必能成功清除掉所有的伪影。

空洞卷积（Dilated Convolution）

- 空洞卷积将滤波器（卷积核）本身的元素在空间上拉开间距
- 它允许网络在不降低图像空间分辨率，且不增加额外参数量的前提下，呈指数级地扩大感受野（Receptive Field）
- **空洞率 d**：卷积核中相邻两个有效权重之间的物理距离

深灰色单元的取值为0，空洞率2

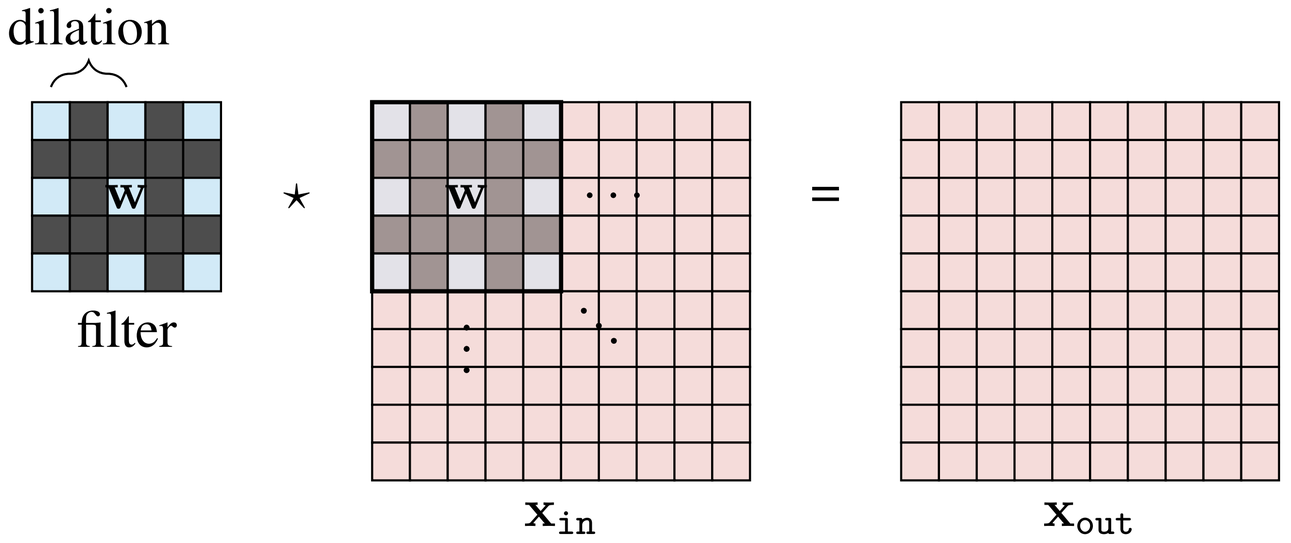

$$K_{\text{dilated}} = (K-1)\times d + 1$$

$$x_{\text{out}}[n,m] = b + \sum_{k_1,k_2=-K}^{K} w[k_1,k_2]\,x_{\text{in}}[n-d_k k_1, m-d_k k_2]$$

空洞卷积（Dilated Convolution）

- 与步长卷积类似，空洞卷积也同样会引入伪影（artifacts）

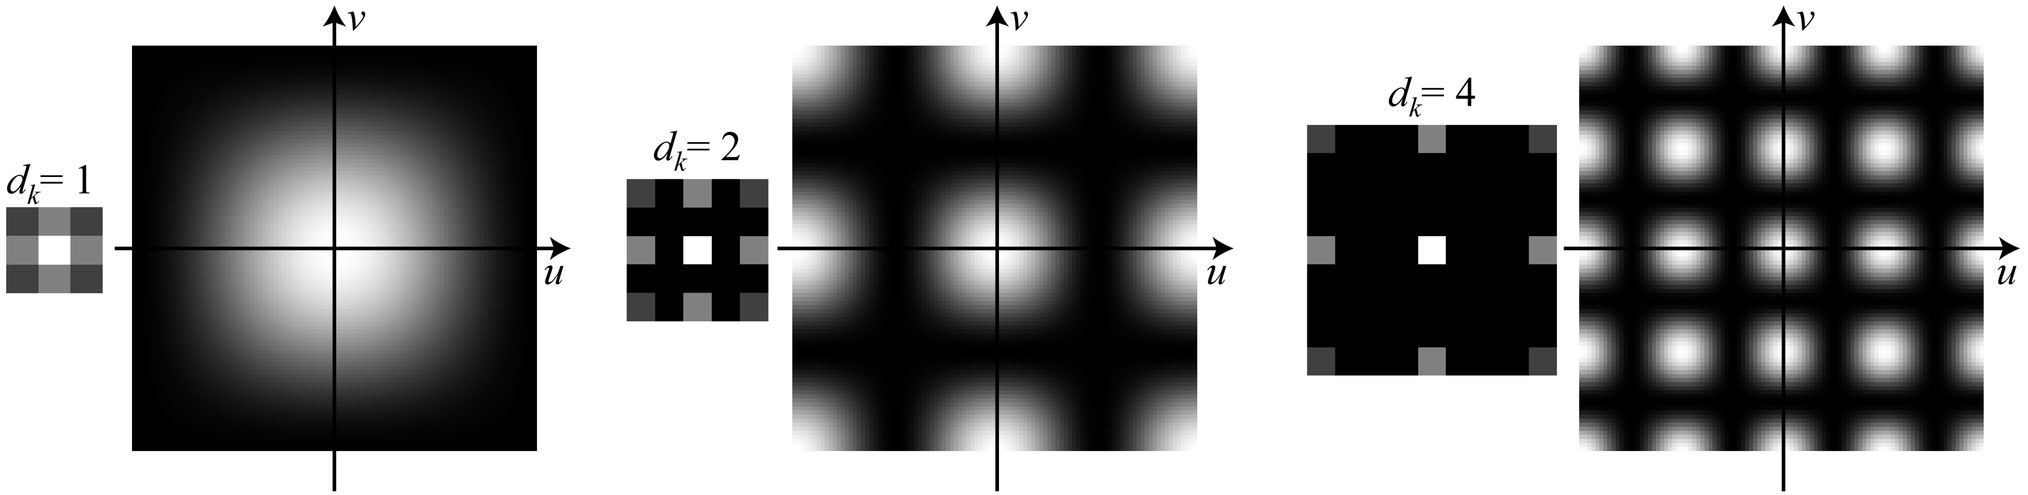

$$\mathbf{w} = \frac{1}{16}\begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$$

改变了滤波器的行为方式，使其不再具备模糊平滑滤波器的作用。

空洞卷积（Dilated Convolution）

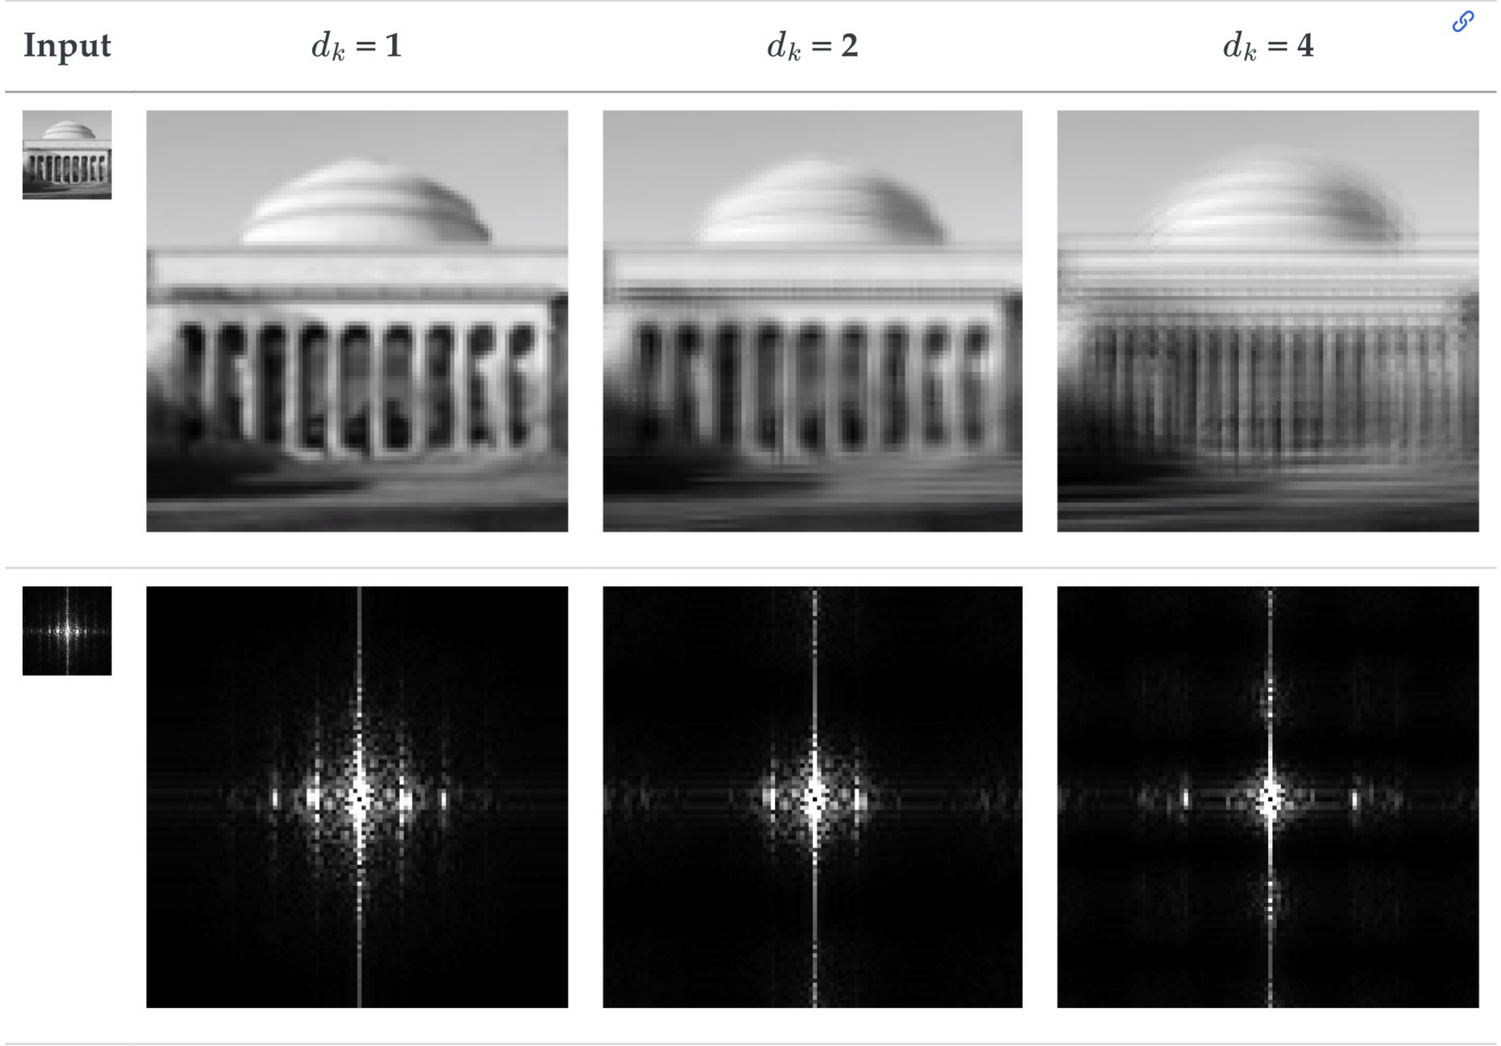

DFT
幅度谱

降采样与上采样层 (Downsampling and Upsampling Layers)

- CNN 可以被构建为分析和合成金字塔
  - 分析期间进行降采样，在合成期间进行上采样
- **降采样层**主要目的是减少空间维度（长和宽），从而减少计算量，并扩大后续卷积核的感受野，提取更高级的全局语义特征。它将输入张量转换为在空间维度上更小的输出张量：

$$\mathbb{R}^{N\times M} \rightarrow \mathbb{R}^{\boldsymbol{N/s_n\times M/s_m}}$$

- CNN中两类降采样层：**步长卷积**，**池化**

降采样与上采样层 (Downsampling and Upsampling Layers)

- 上采样的目的是将高度抽象的、低分辨率的特征图放大，恢复其空间细节，它输出的是一个在空间维度上比输入更大的张量：

$$\mathbb{R}^{N\times M} \longrightarrow \mathbb{R}^{Ns_n\times Ms_m}$$

包括这几类方法：

- **反池化 (Unpooling)**
- **插值法**：最近邻插值，双线性插值
- **转置卷积 / 反卷积：**步长卷积的反向模拟，先对信号进行膨胀，然后再进行卷积，从一张全为零的空白图像 $\mathbf{h}=\mathbf{0}$ 开始，进行如下设定：

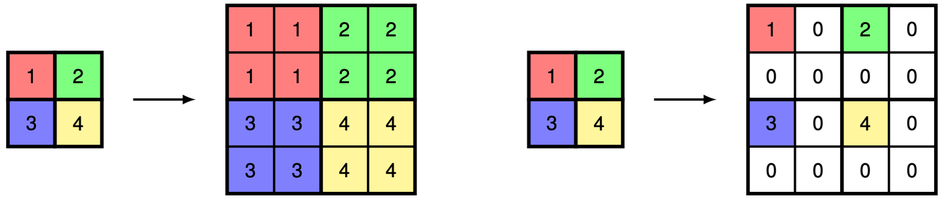

$$h[ns_n, ms_m] = x_{\text{in}}[n, m]$$

$$\mathbf{x}_{\text{out}} = \mathbf{w} \star \mathbf{h} + b$$

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} \Rightarrow \begin{bmatrix} A & 0 & B & 0 \\ 0 & 0 & 0 & 0 \\ C & 0 & D & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

1 ×1 卷积

- **跨通道的信息集成**
- **升维与降维**
- **引入非线性**

  - 可以每经过一个1 ×1卷积层，后面通常都会紧跟一个激活函数
  - 可在**不改变感受野、不改变特征图尺寸、且增加极少参数**的情况下，给网络多增加一层非线性变换
  - 可让网络变得更深，能够学习更复杂的决策边界，而计算代价微乎其微

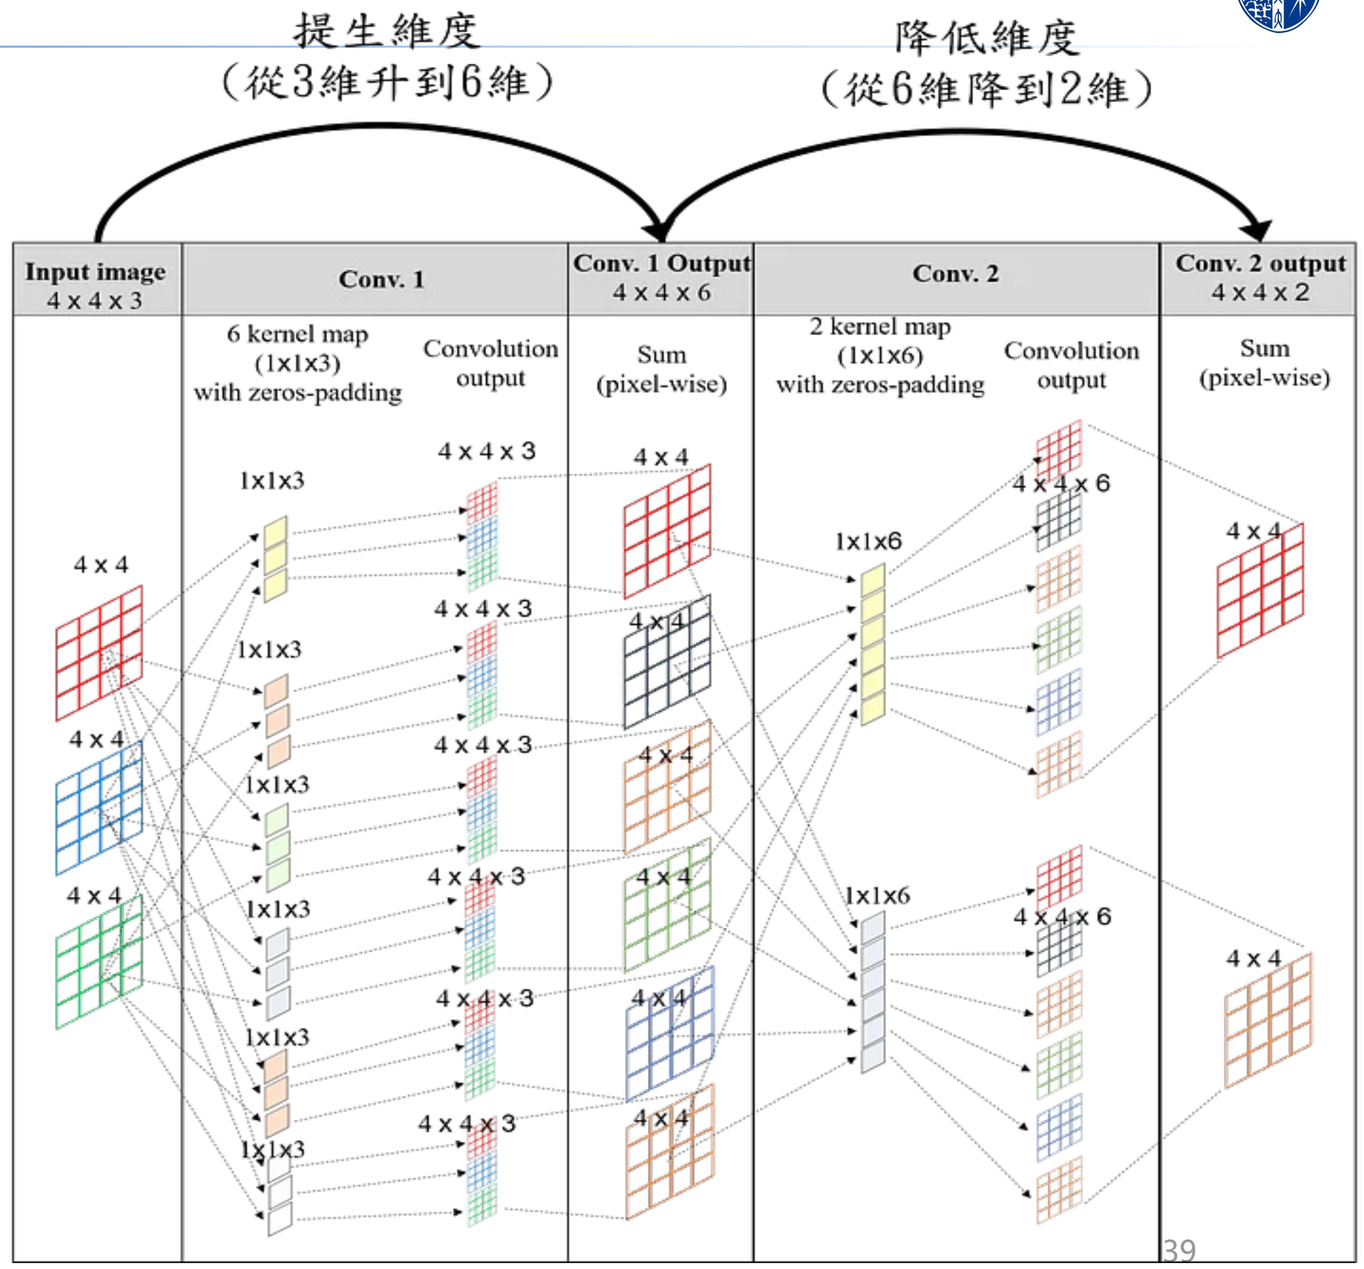

资料来源：https://chih-sheng-huang821.medium.com/%E5%8D%B7%E7%A9%8D%E7%A5%9E%E7%B6%93%E7%B6%B2%E8%B7%AF-convolutional-neural-network-cnn-1-1%E5%8D%B7%E7%A9%8D%E8%A8%88%E7%AE%97%E5%9C%A8%E5%81%9A%E4%BB%80%E9%BA%BC-7d7ebfe34b8

非线性滤波层

- 卷积操作是线性的
- 在卷积网络中，我们也可以定义非线性的滤波器。与卷积滤波器类似，这些滤波器在输入张量上滑动，并且以相同且独立的方式处理每一个窗口，但它们所执行的操作是对局部窗口内数据的非线性函数。

池化层（Pooling layers）

- 池化层是一种降采样层，它使用某种聚合统计量来概括一个图像块（patch）内的信息
- 平均池化：使用该图像块的平均值
- 最大池化：使用该图像块的最大值

$$x_{\text{out}}[i] = \max_{i \in \mathcal{N}(i)} x_{\text{in}}[i] \quad \triangleleft \quad \texttt{max pooling}$$

$$x_{\text{out}}[i] = \frac{1}{|\mathcal{N}|} \sum_{i \in \mathcal{N}(i)} x_{\text{in}}[i] \quad \triangleleft \quad \texttt{mean pooling}$$

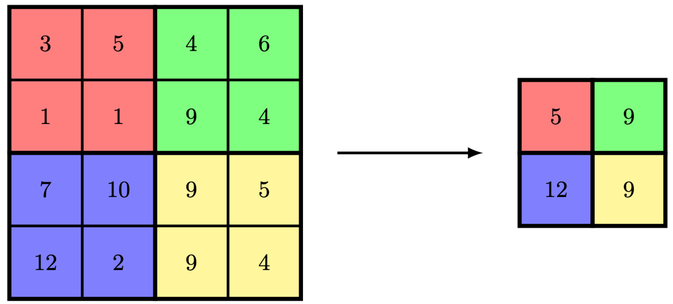

池化层（Pooling layers）

Pooling across spatial locations achieves stability w.r.t. small translations:

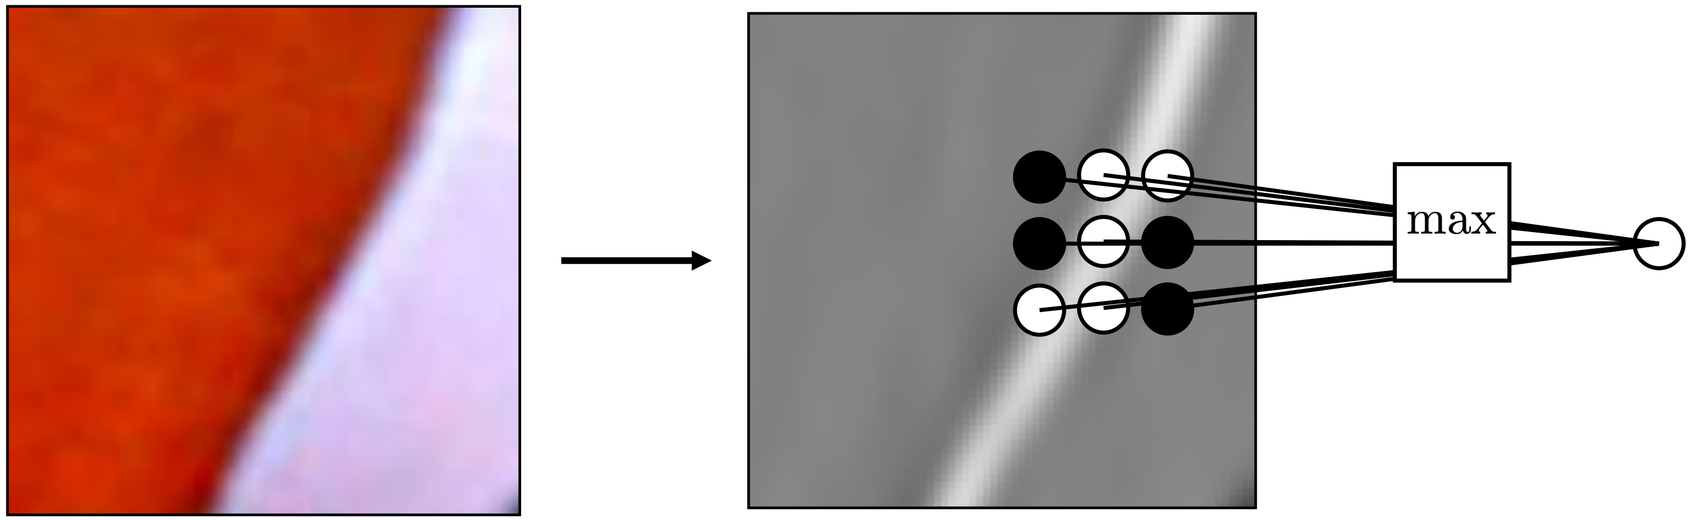

池化层（Pooling layers）

Pooling across spatial locations achieves stability w.r.t. small translations:

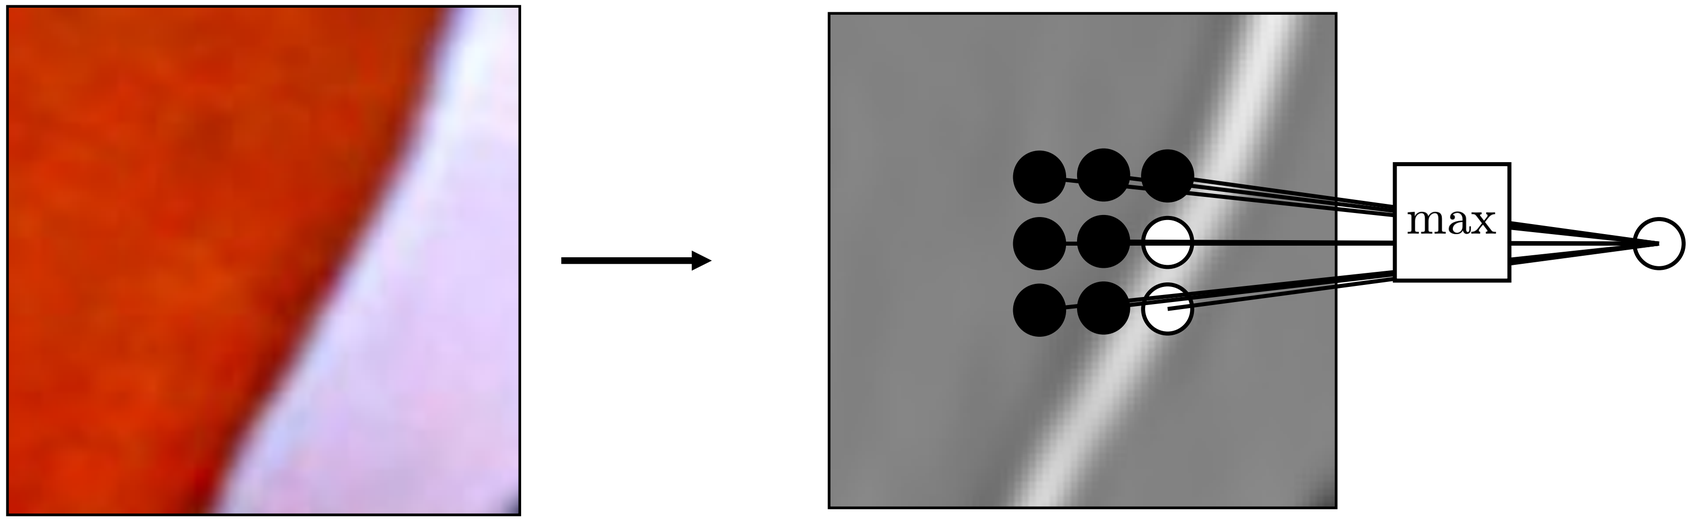

large response regardless of exact position of edge

池化层（Pooling layers）

Pooling across spatial locations achieves stability w.r.t. small translations:

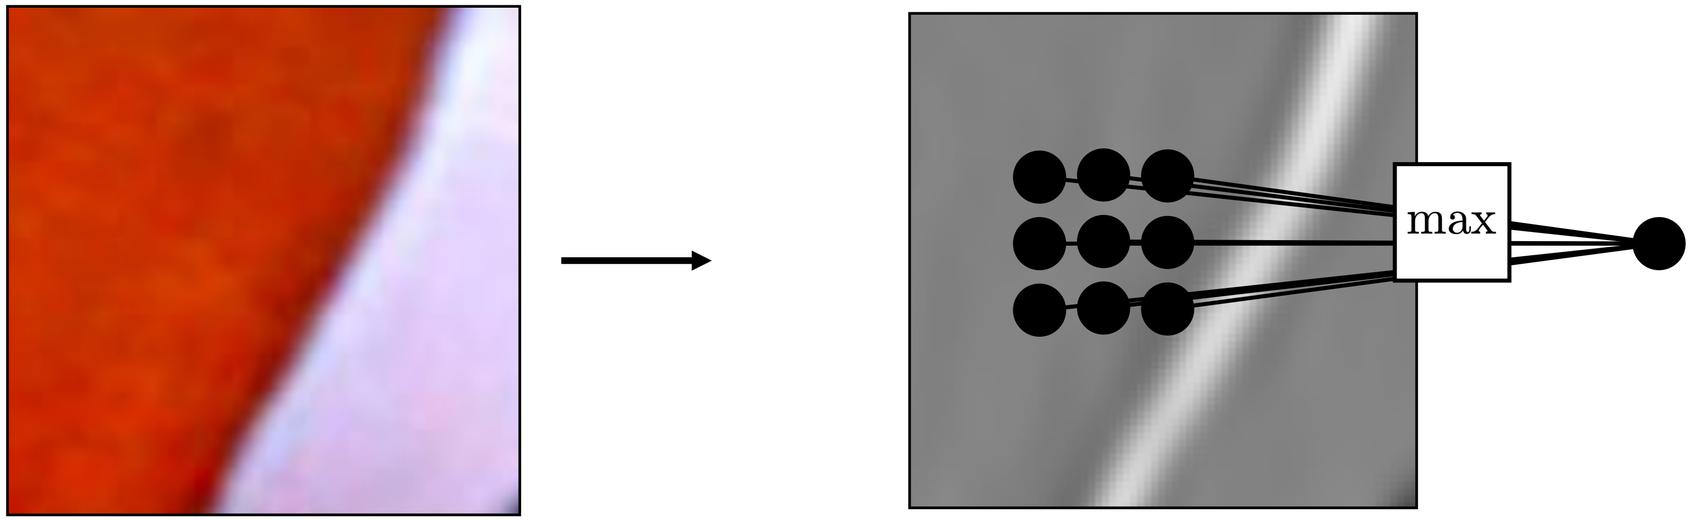

跨通道池化

Pooling across feature channels (filter outputs) can achieve other kinds of invariances:

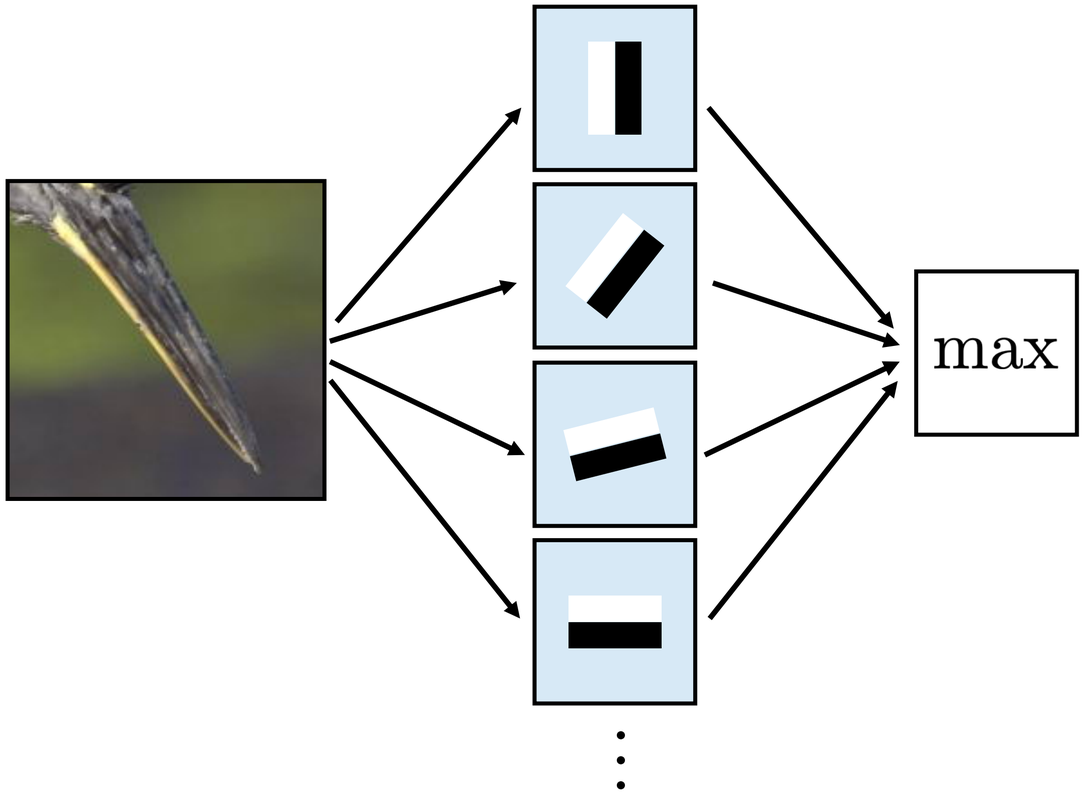

large response for any edge, regardless of its orientation

- 不论图像中的方向是如何，总有一个特定角度的滤波器会捕捉到它
- 跨通道池化可实现**旋转不变性（Rotation Invariance）**

全局池化层 (Global Pooling Layers)

- 池化的一种极端情况是对特征图的整个空间范围进行池化。全局池化是一个函数，它将一个 $C \times M \times N$ 张量映射为一个长度为 C 的向量，其中 C 等于输入的通道数
- 全局池化通常用于非常靠近网络输出端的层中，即取整张特征图中的统计量。

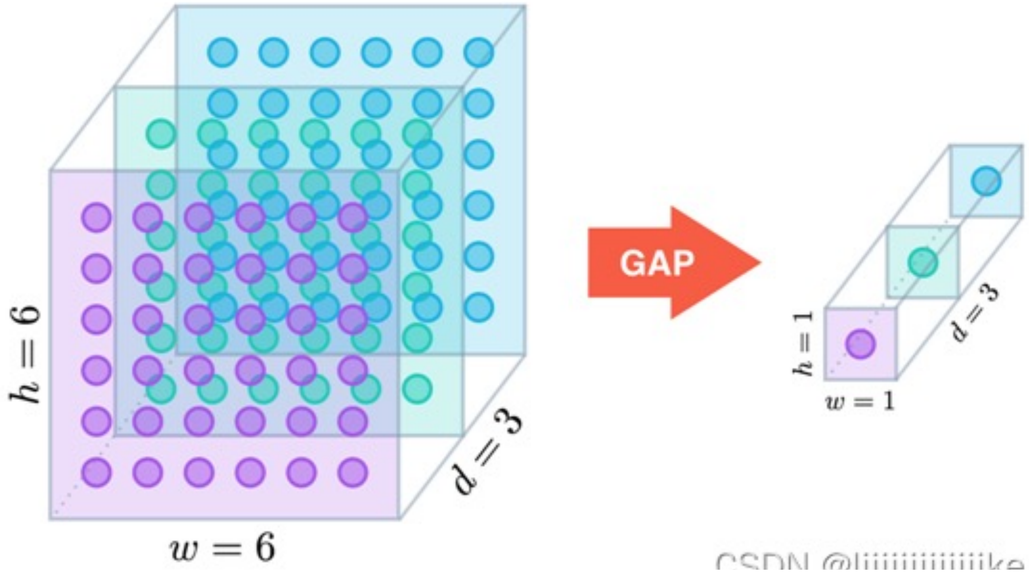

CSDN @liiiiiiiiiiiike

一个简单的 CNN 分类器

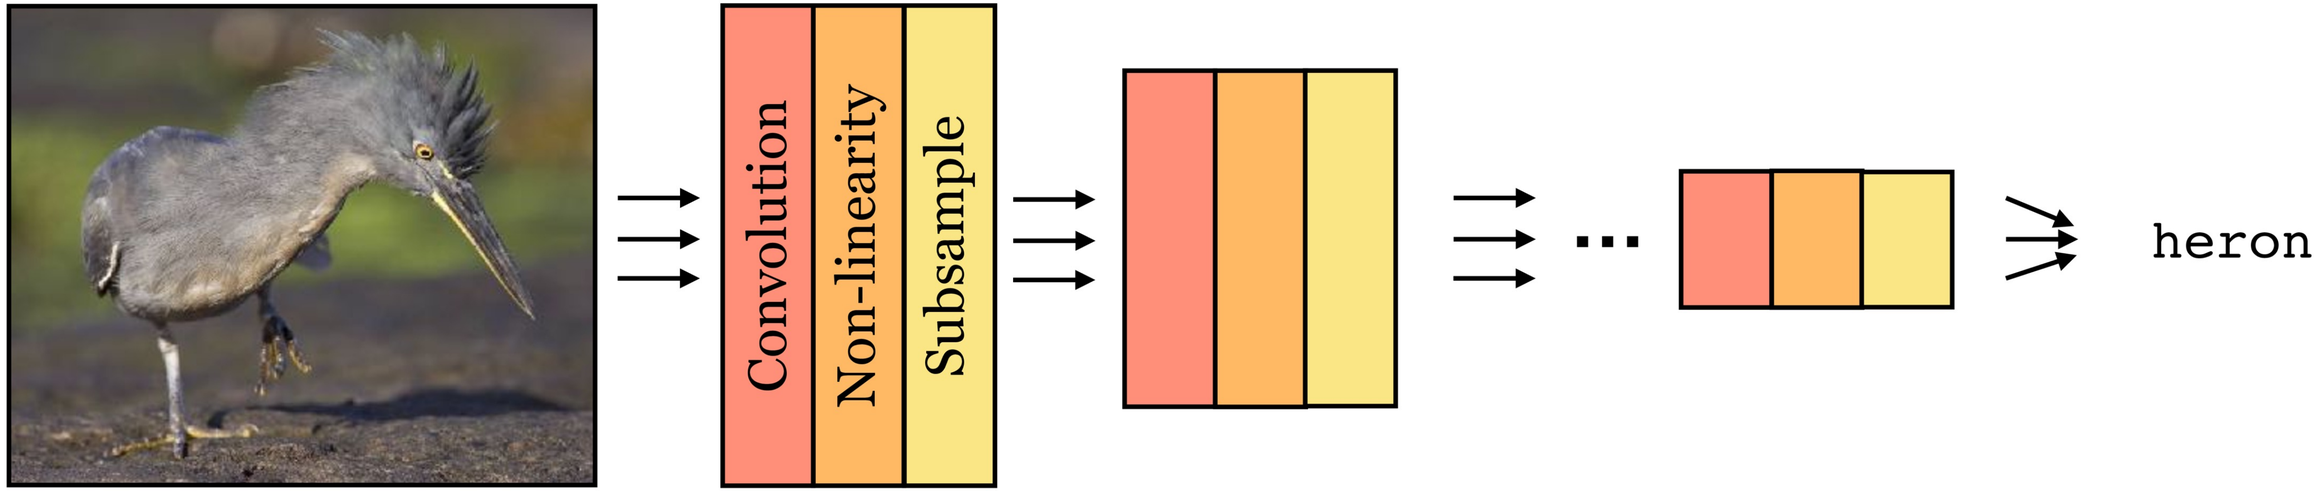

$$\mathbf{z}_1[c,:,:] = \mathbf{w}[c,:,:] \star \mathbf{x} + b[c] \quad \triangleleft \quad \texttt{conv} : [M \times N] \to [C \times M \times N]$$

$$h[c,n,m] = \max(z_1[c,n,m], 0) \quad \triangleleft \quad \texttt{relu} : [C \times M \times N] \to [C \times M \times N]$$

$$z_2[c] = \frac{1}{NM} \sum_{n,m} h[c,n,m] \quad \triangleleft \quad \texttt{gap} : [C \times M \times N] \to [C]$$

全局平均池化

$$\mathbf{z}_3 = \mathbf{W}\mathbf{z}_2 + \mathbf{c} \quad \triangleleft \quad \texttt{fc} : [C] \to [K]$$

$$y[k] = \frac{e^{-\tau z_3[k]}}{\sum_{l=1}^{K} e^{-\tau z_3[l]}} \quad \triangleleft \quad \texttt{softmax} : [K] \to [K]$$

CNN 中的特征图（Feature Map）

- 特征图既可以指卷积层输出的某一个通道，也可以指网络某一层中所有通道的整个堆叠。
- 特征图的核心思想是，这些是输入数据的特征，并且这些特征被排列在一个图中，即一个与输入数据形状相匹配的数组
  - 对于图像，特征图是二维（2D）空间数组
  - 对于视频，特征图是三维（3D）时空数组

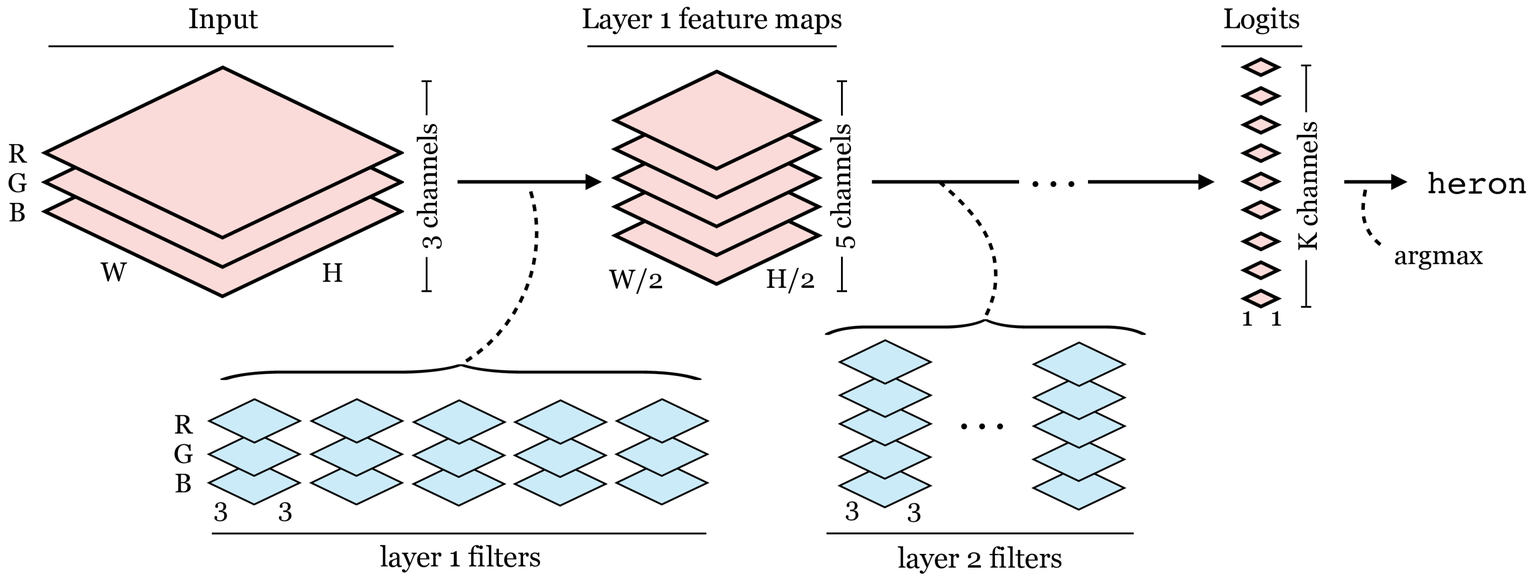

可以将这些输入和输出看作是特征图：

- 输入RGB通道的特征图；
- 输出是一个分辨率为 1×1 的以各个类别的 logits 作为通道的特征图。

AlexNet 网络中的特征图

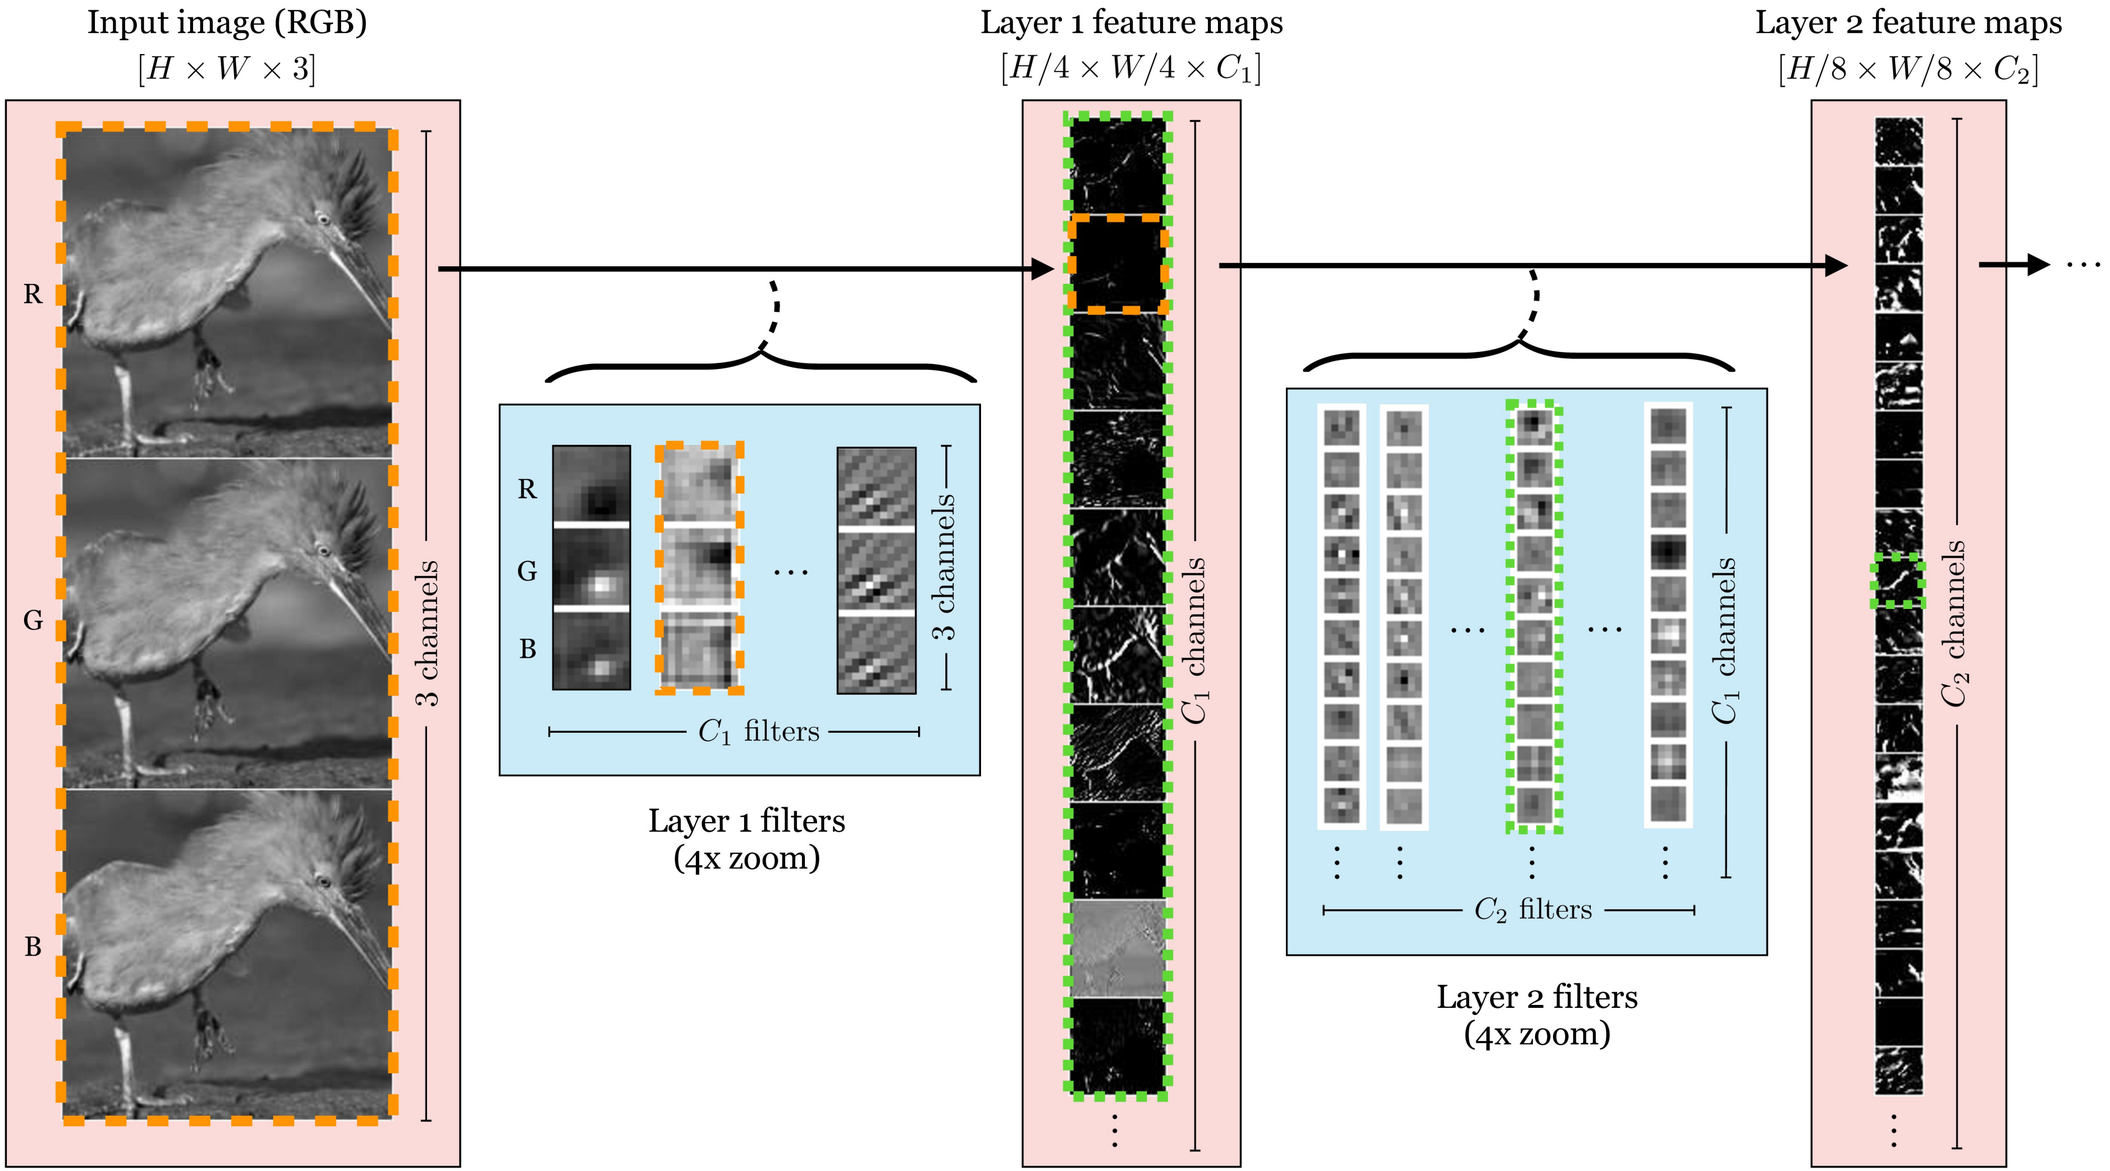

AlexNet 网络中的特征图

- 随着网络加深，特征图的空间分辨率变得越来越低，而通道的数量却在增加
  - 每一层都会进行降采样并增加通道数，以此来部分补偿分辨率下降所带来的信息损失
- 第一层特征图：特征图对输入图像中的基本模式（边缘、线条等）极其敏感
- 第二层特征图：图像开始变得模糊和抽象。网络不再关注单纯的线条，而是开始将第一层的线条组合起来，寻找角点、简单的几何形状或特定的纹理模式。空间分辨率通常也比第一层更小。
- 这本质上是一种“信息重组”。网络将铺垫在巨大空间网格上的低级视觉信息，强行挤压、浓缩成了数量庞大的、高度抽象的高级语义概念。

CNN 中的特征图（Feature Map）

- 观察浅层特征很容易，但面对很深的 512 或 2048 个通道时，逐个观察灰度图就失去意义
- 可以将成百上千个通道的复杂信息，提炼出方差最大、最具有代表性的 3 个主成分
- 把这 3 个成分映射到红、绿、蓝（RGB）三个颜色通道上
- 这样渲染出来的彩色特征图，能够极其直观地向我们展示网络是如何对图像进行“语义聚类”的
  - 如原图中的所有“天空”区域可能在深层特征图上都呈现出同一种纯粹的蓝色，而所有的“建筑”都呈现出红色）。

颜色相近的区域，意味着网络在那里提取到了极其相似的特征

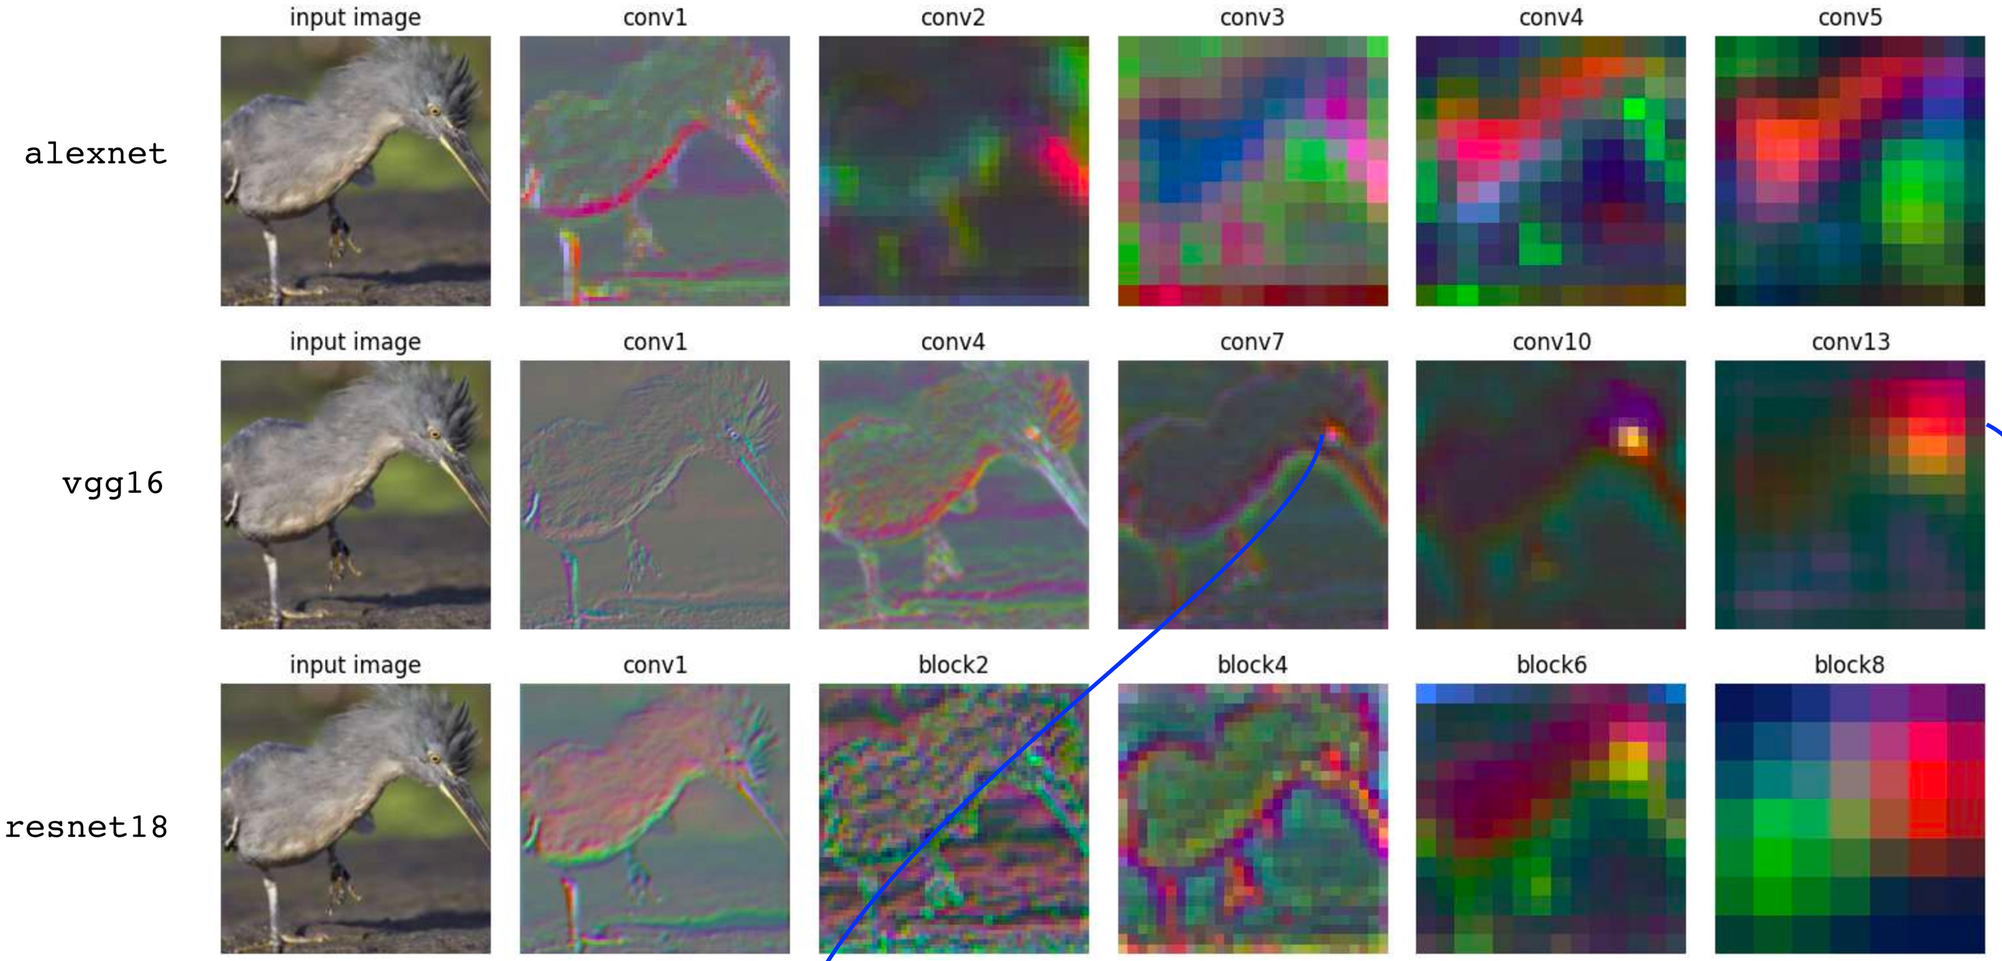

将边缘组合起来，寻找更复杂的局部模式。

大块的红色马赛克区域可能代表着“这里是鸟的身体（前景）”，而周围的蓝色/绿色马赛克区域代表着“这里是水面/沙滩（背景）”

感受野

- 一个神经元的感受野是指**输入信号中该神经元所敏感的区域**
- 在多层感知机（MLP）中，每个神经元的感受野是**整个输入向量**
- 在 CNN 中，每个神经元只能“看到”输入的一部分，因为卷积层上的每个输出神经元仅连接到该卷积层输入的一个子集，这个子集是由产生该输出的滤波器的卷积核大小决定的

CNN中的感受野

- 随着网络深入，感受野会不断增大。
- 通常，我们希望 CNN 的最后一层具有足够大的感受野以覆盖整个输入图像，从而使输出神经元对输入中的所有像素都敏感。这可以通过全局平均池化层来实现，其输出的感受野尺寸始终覆盖整个输入。

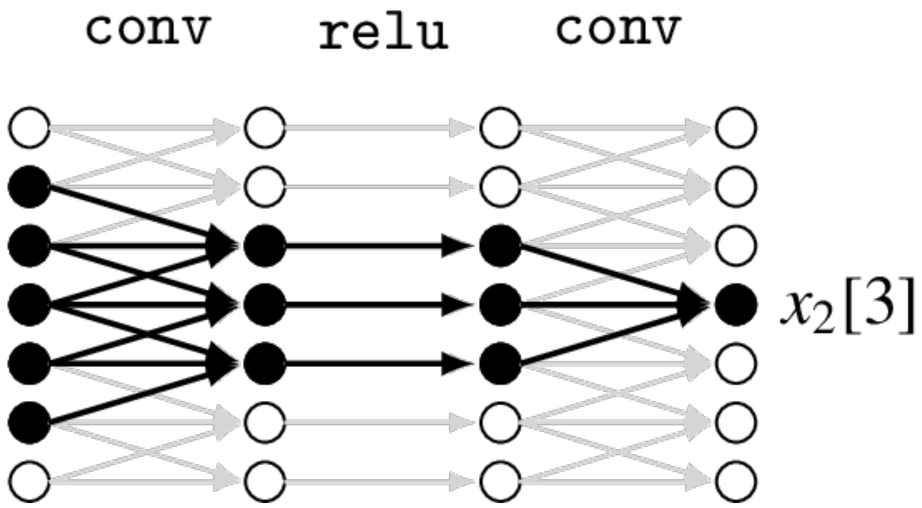

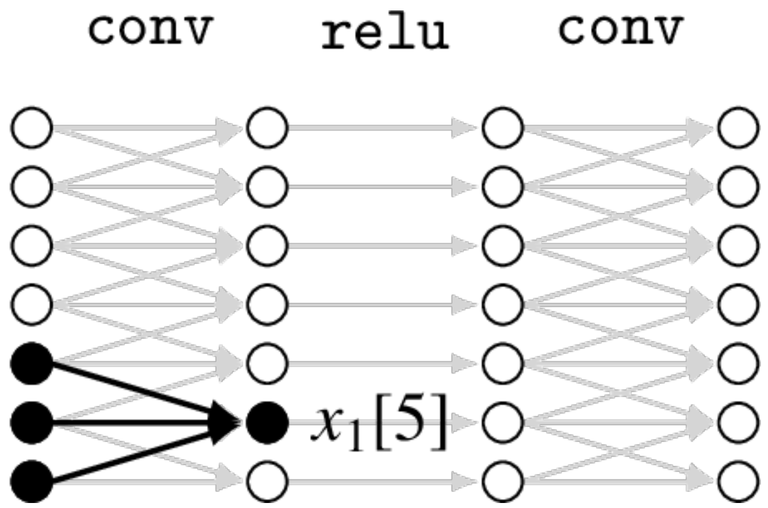

从分类到像素级理解

- **图像分类**：一个 CNN 为一张图像输出单个类别概率向量
  - 网络的最后会使用全局平均池化将所有空间信息压扁成一个点
- **稠密预测**：输出一个随空间位置变化的预测图，需要保留空间位置
  - 如语义分割：像素级理解

从分类到像素级理解

Classification

CAT

Semantic Segmentation

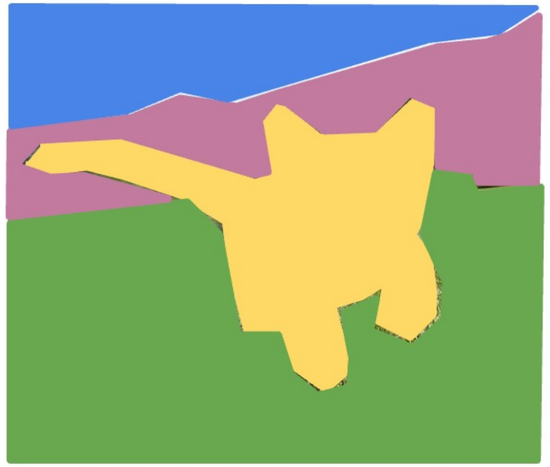

GRASS, CAT, TREE, SKY

No objects, just pixels

Object Detection

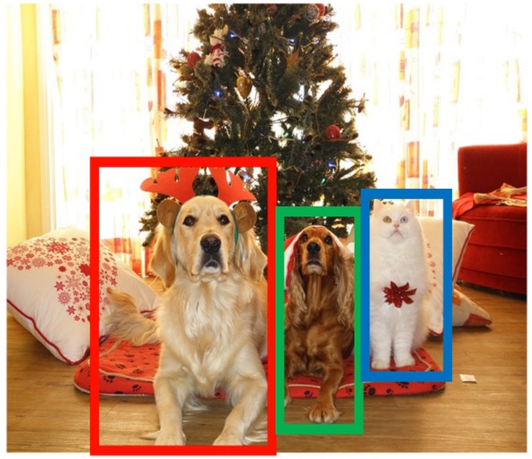

DOG, DOG, CAT

Instance Segmentation

DOG, DOG, CAT

Multiple Objects

空间输出

- 要实现空间输出，可减少降采样的次数，使得 CNN 的最后一层是一个保持较高空间分辨率的特征图

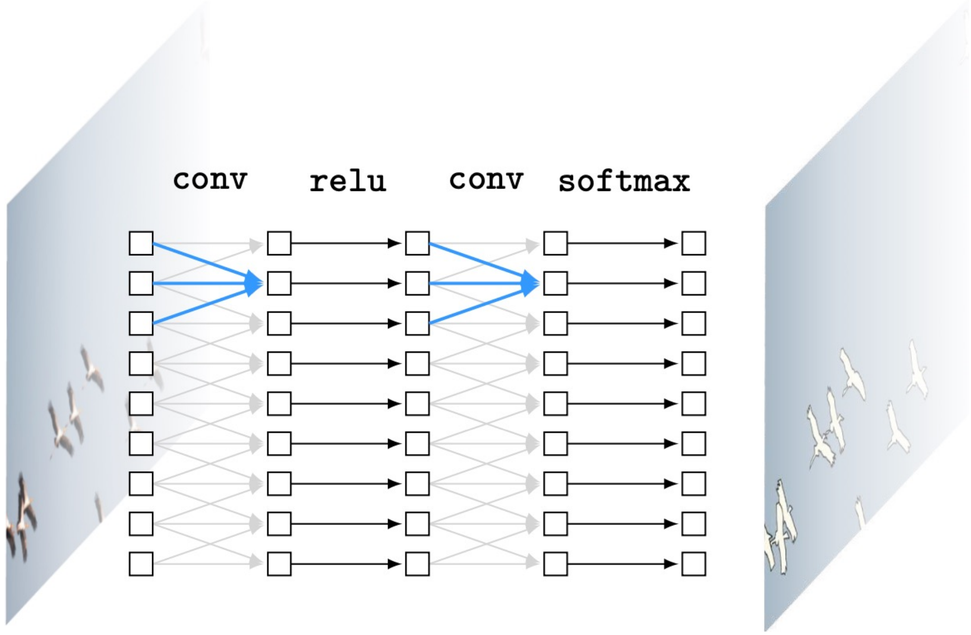

$$\mathbf{z}_1[c_1,:,:] = \sum_{c=0}^{2} \mathbf{w}_1[c,c_1,:,:] \star \mathbf{x} + b_1[c_1] \qquad \triangleleft \ \texttt{conv}$$

$$[3 \times N \times M] \to [C_1 \times N \times M]$$

$$h[c_1,n,m] = \max(z_1[c_1,n,m],0) \qquad \triangleleft \ \texttt{relu}$$

$$[C_1 \times N \times M] \to [C_1 \times N \times M]$$

$$\mathbf{z}_2[c_2,:,:] = \sum_{c_1=0}^{C_1-1} \mathbf{w}_2[c_1,c_2,:,:] \star \mathbf{x} + b_2[c_2] \qquad \triangleleft \ \texttt{conv}$$

$$[C_1 \times N \times M] \to [C_2 \times N \times M]$$

$$y[k,n,m] = \frac{e^{-\tau z_2[k,n,m]}}{\sum_{l=1}^{K} e^{-\tau z_2[l,n,m]}} \qquad \triangleleft \ \texttt{softmax}$$

$$[K \times N \times M] \to [K \times N \times M]$$

- 如果降采样太多，语义很强，但位置很模糊（分辨率太低，对不齐边缘）；
- 如果降采样太少，位置很准（分辨率高），但语义很弱（感受野太小，网络可能只看到一簇毛发，不知道这是一只猫）。

作为滑动滤波的 CNN

- 一个仅由卷积层和逐点非线性层组成的完整 CNN，其本身就是一个非线性算子，它对输入信号的每个块独立且相同地应用变换
- CNN 是一个非线性滤波器。

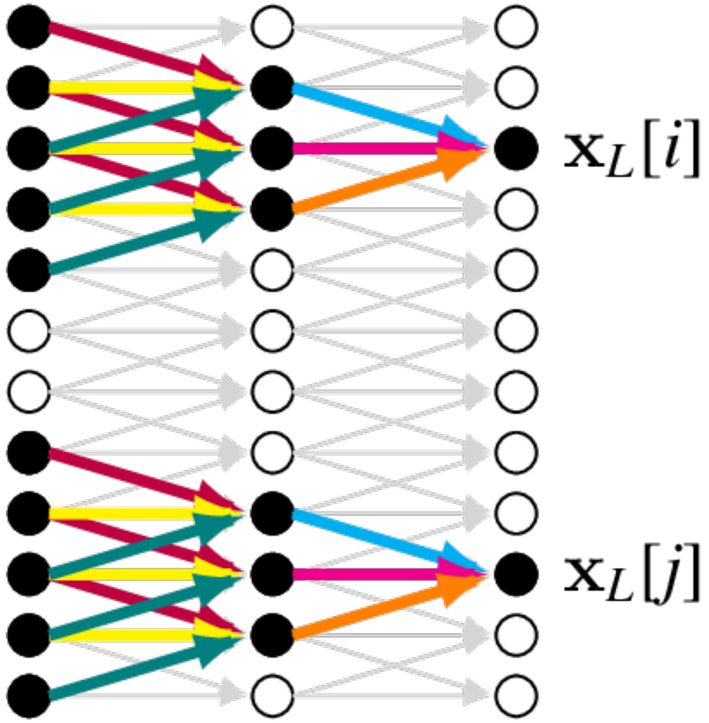

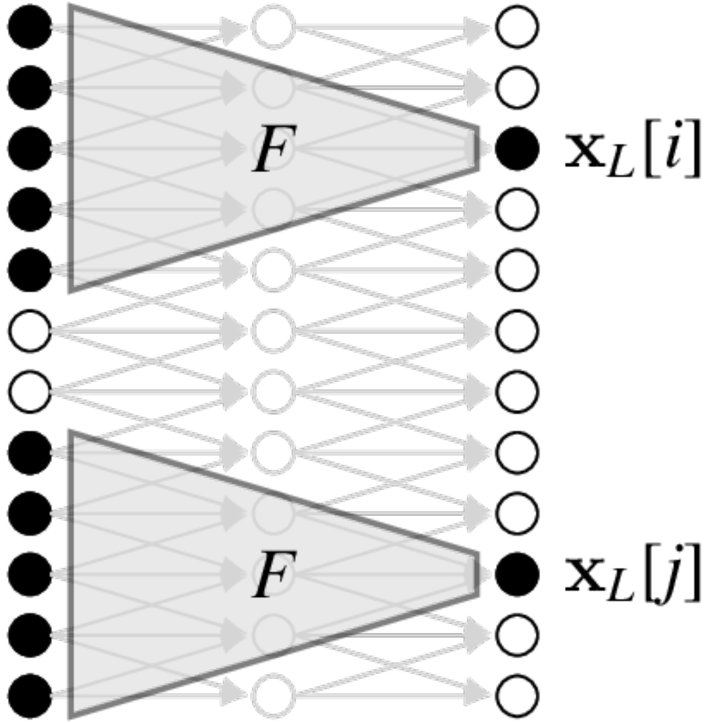

为什么按图像片段逐一处理

- **特性 1：将图像块视为独立的**
  - 将一个大问题（即“解释整张照片”）拆解成一堆小问题（即“解释图像中的每个小块”）
  - 世界展现出**局部性（Locality）**：相关的事物往往聚集在一起（即在同一个图像块内）；相距甚远的事物通常可以被安全地假设为是相互独立的。
- **特性 2：相同地处理每个图像块**
  - 视觉内容往往具有**平移不变性**，卷积算子本身也是平移不变的。
  - 等变性：如果我们平移输入信号，那么输出信号也会发生相同量的平移。也就是说，如果 f 是一个卷积操作，有如下性质：

$$f(\mathrm{translate}(\mathbf{x})) = \mathrm{translate}(f(\mathbf{x}))$$

编码器与解码器

- 编码器通常是那些以图像为输入，然后逐层进行降采样，直到输出一个维度低得多的特征图的网络
- 解码器则相反，它以一组低维特征为输入，然后逐层进行上采样，直到生成一张图像作为最终输出

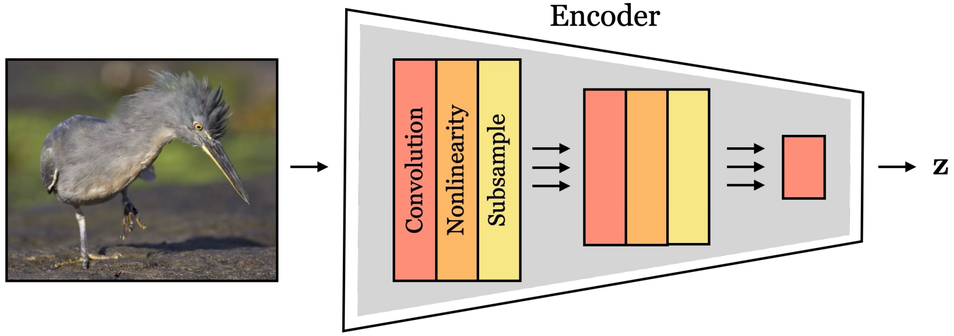

编码器-解码器结构强制信号通过一个“瓶颈”

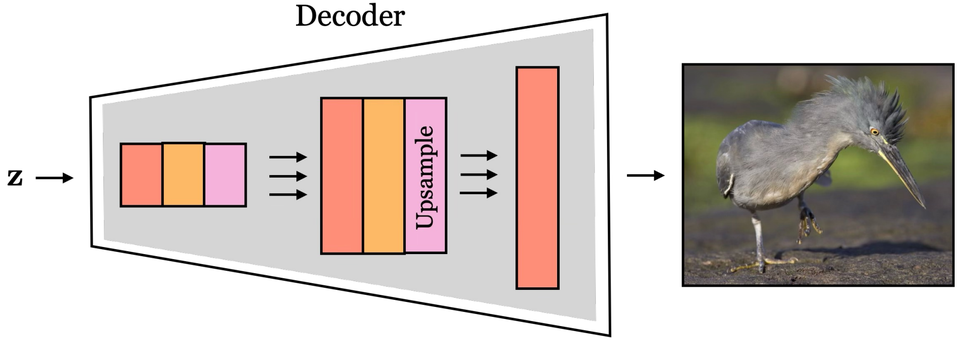

编码器与解码器

- 将编码器和解码器结合在一起，形成编码器-解码器（encoder-decoder）架构
- **效率优化：**通过降采样，内部特征图的尺寸更小，从而消耗更少的内存和计算资源。
- **信息瓶颈：**编码器-解码器引入了一个“信息瓶颈”，即编码器和解码器之间的中间表示是低维的，只能传输有限的信息量，这迫使网络进行抽象

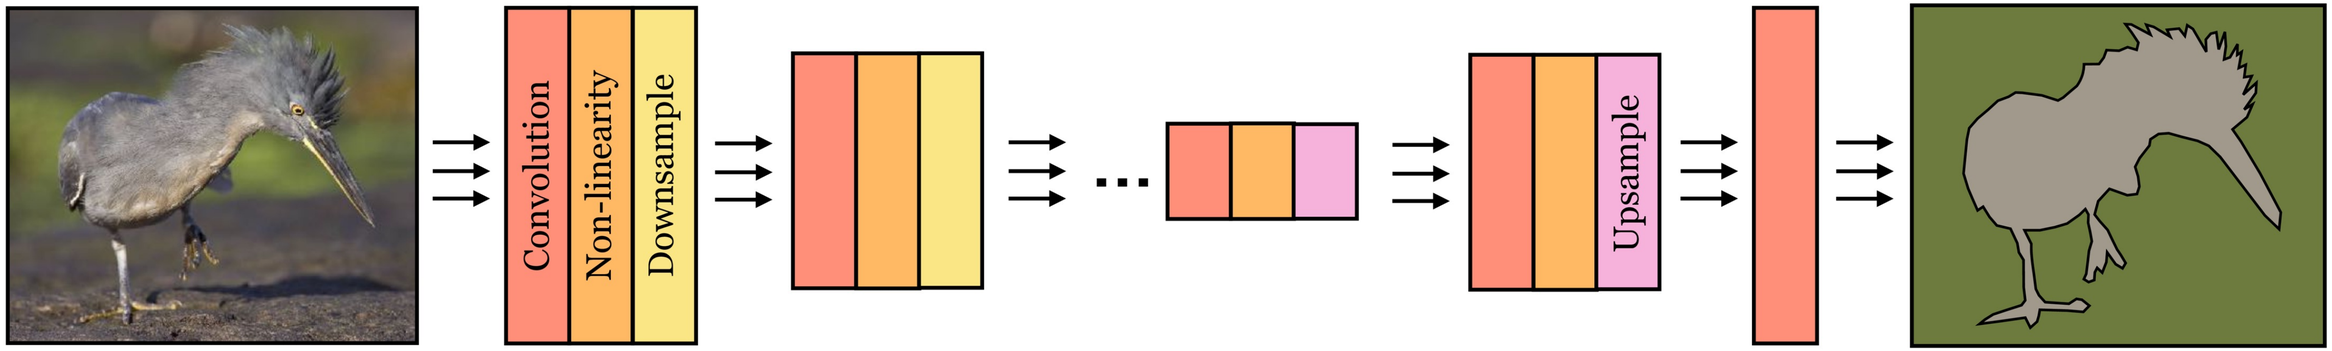

U-Net

- 编码器-解码器中的低维表示使得解码器的任务变得相当困难。解码器可能无法输出高频细节。
- U-Net增加跳跃连接，可以维持编码器-解码器的信息瓶颈，同时也允许残差信息通过跳跃连接流动，从而不会牺牲输出高频空间预测的能力。

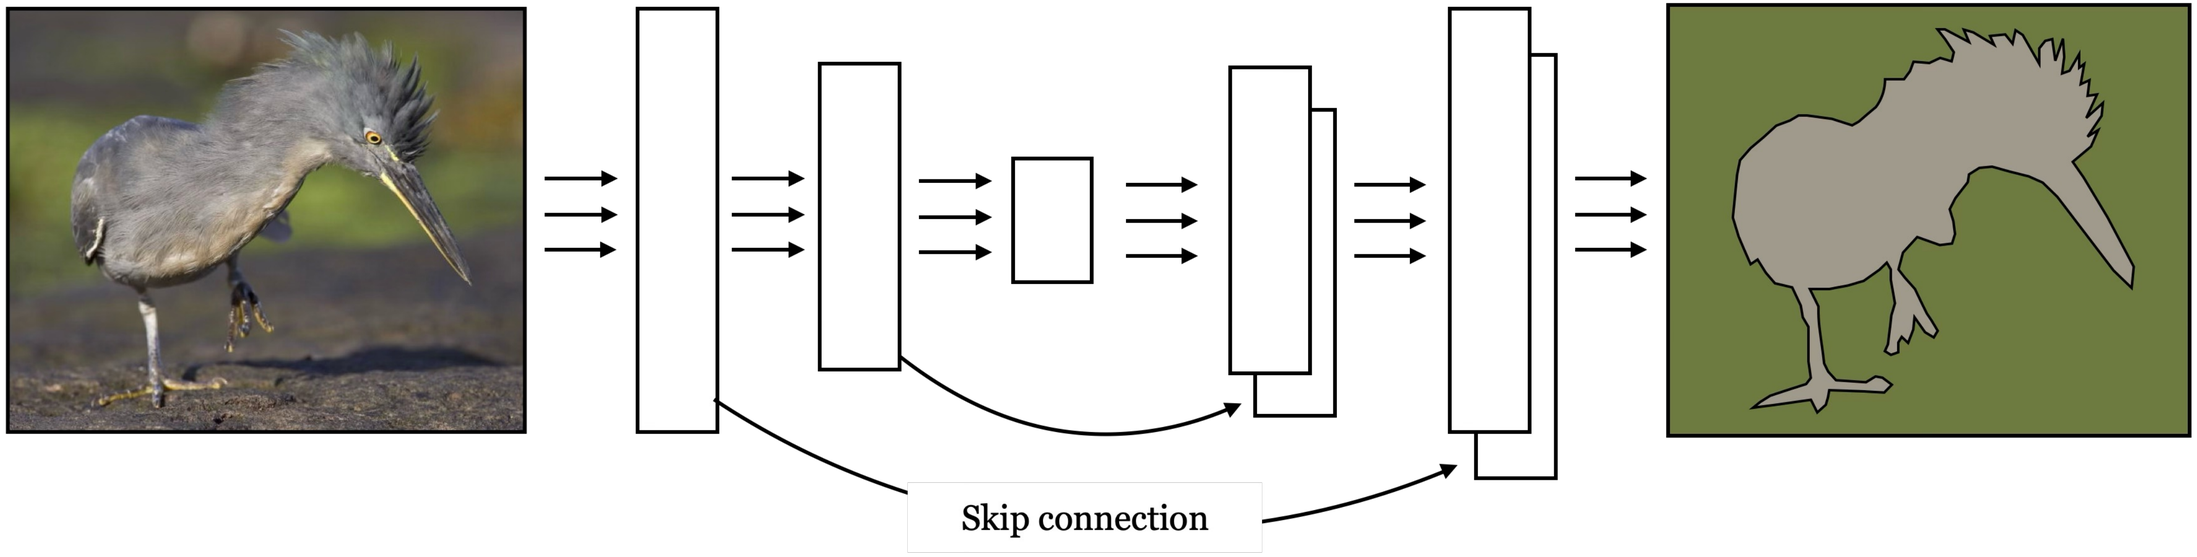

U-Net

- 对于每一个下采样层，都有一个对应的上采样层
- 并且将每个下采样层最后的通道激活值，与上采样层中对应的第一组通道进行拼接，从而使这些层能够获取更高分辨率的空间信息

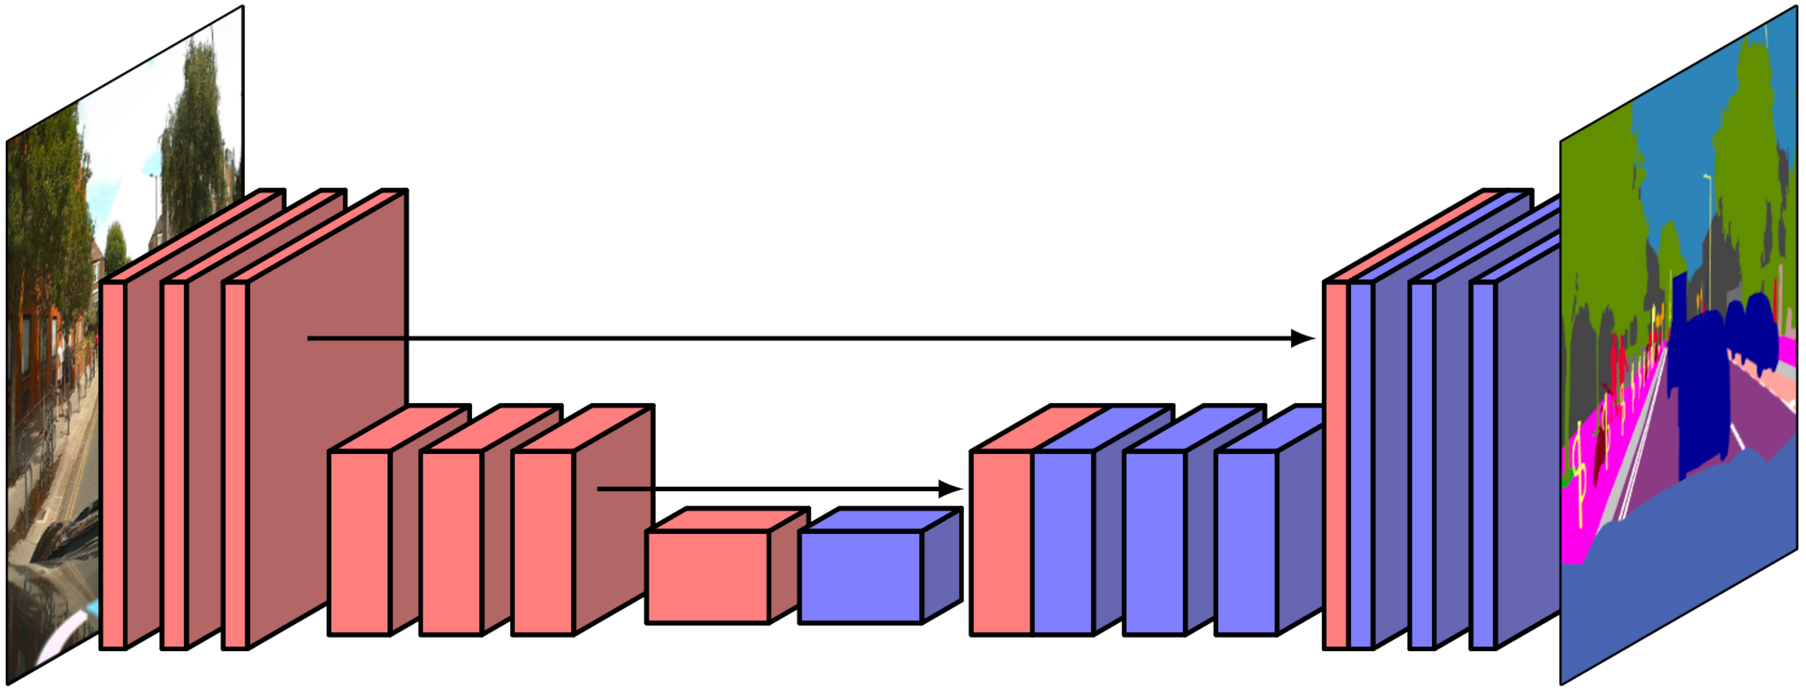

ResNet

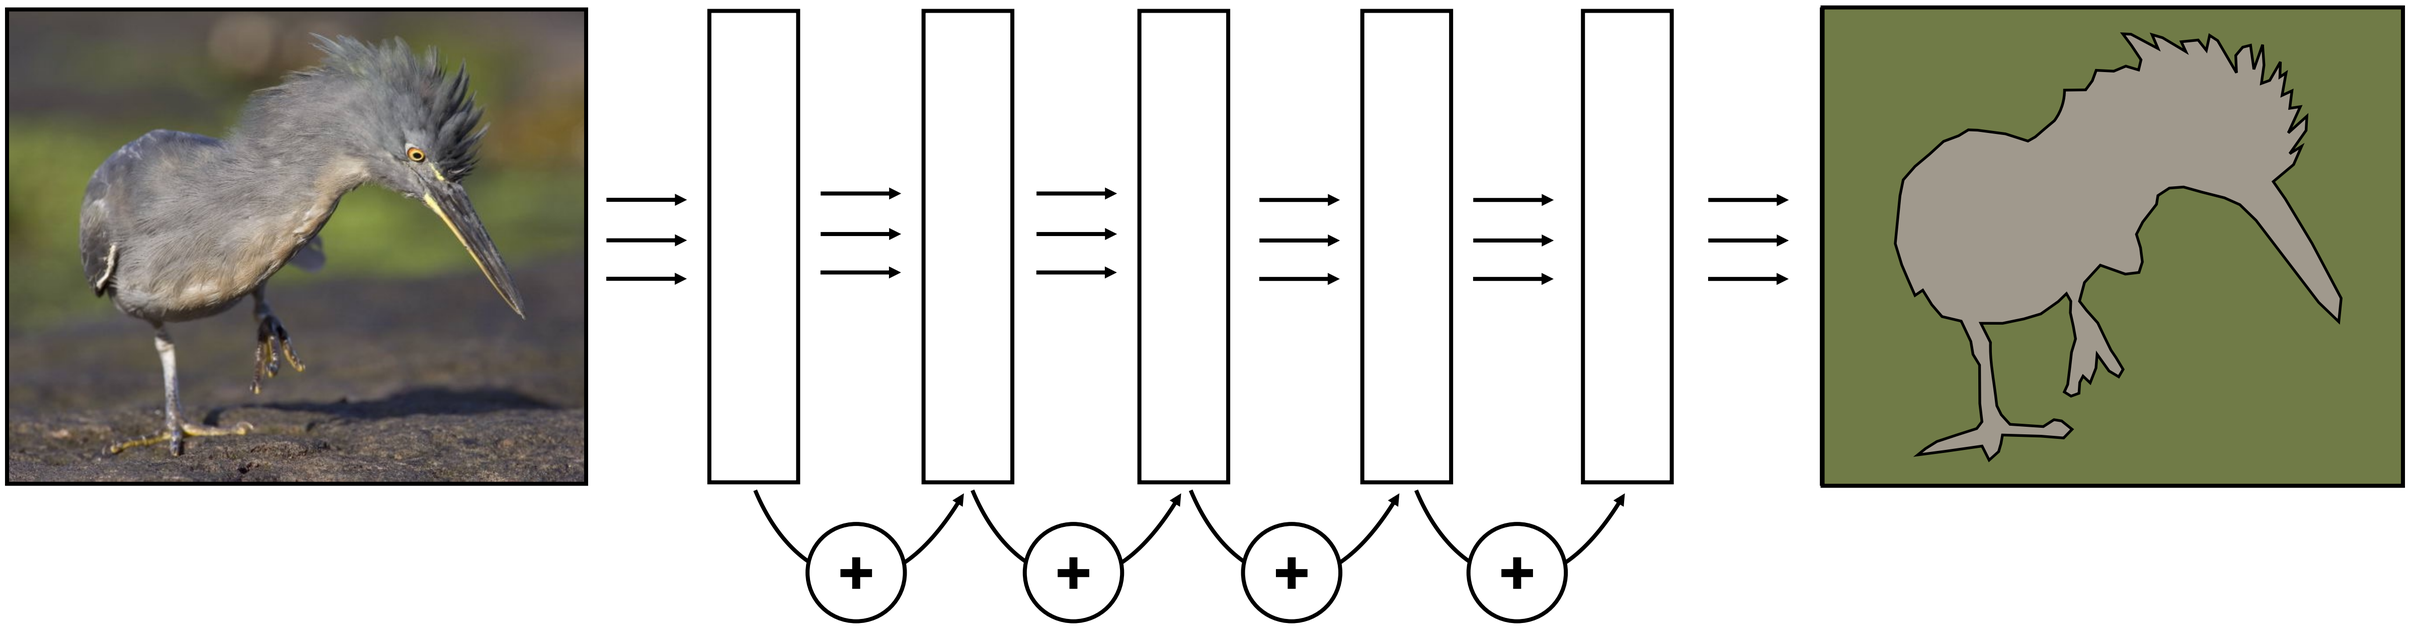

Residual connection: $\mathbf{x}_{\text{out}} = F(\mathbf{x}_{\text{in}}) + \mathbf{x}_{\text{in}}$

Or, if you want to change dimensionality: $\mathbf{x}_{\text{out}} = F(\mathbf{x}_{\text{in}}) + \mathbf{W}\mathbf{x}_{\text{in}}$

ResNet

- 图像分类先前工作
  - CNN (7层)，AlexNet (8层)，VGG (16层)，GoogleNet (22)， …

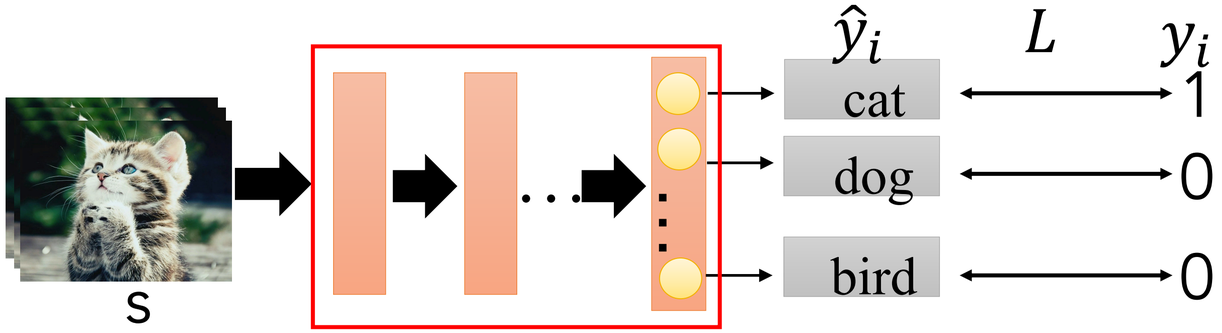

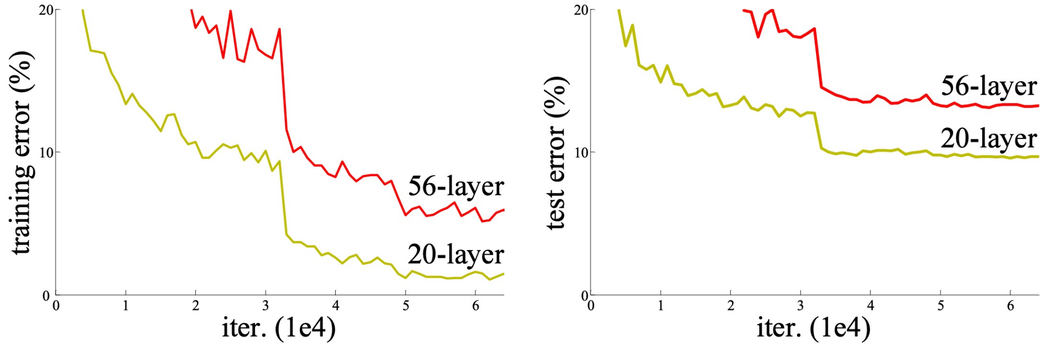

Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer "plain" networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.

He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. "Deep residual learning for image recognition." In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770-778. 2016.

ResNet

$$f_{\mathcal{F}}^* := \underset{f}{\operatorname{argmin}}\, L(\mathbf{X}, \mathbf{y}, f) \text{ subject to } f \in \mathcal{F}$$

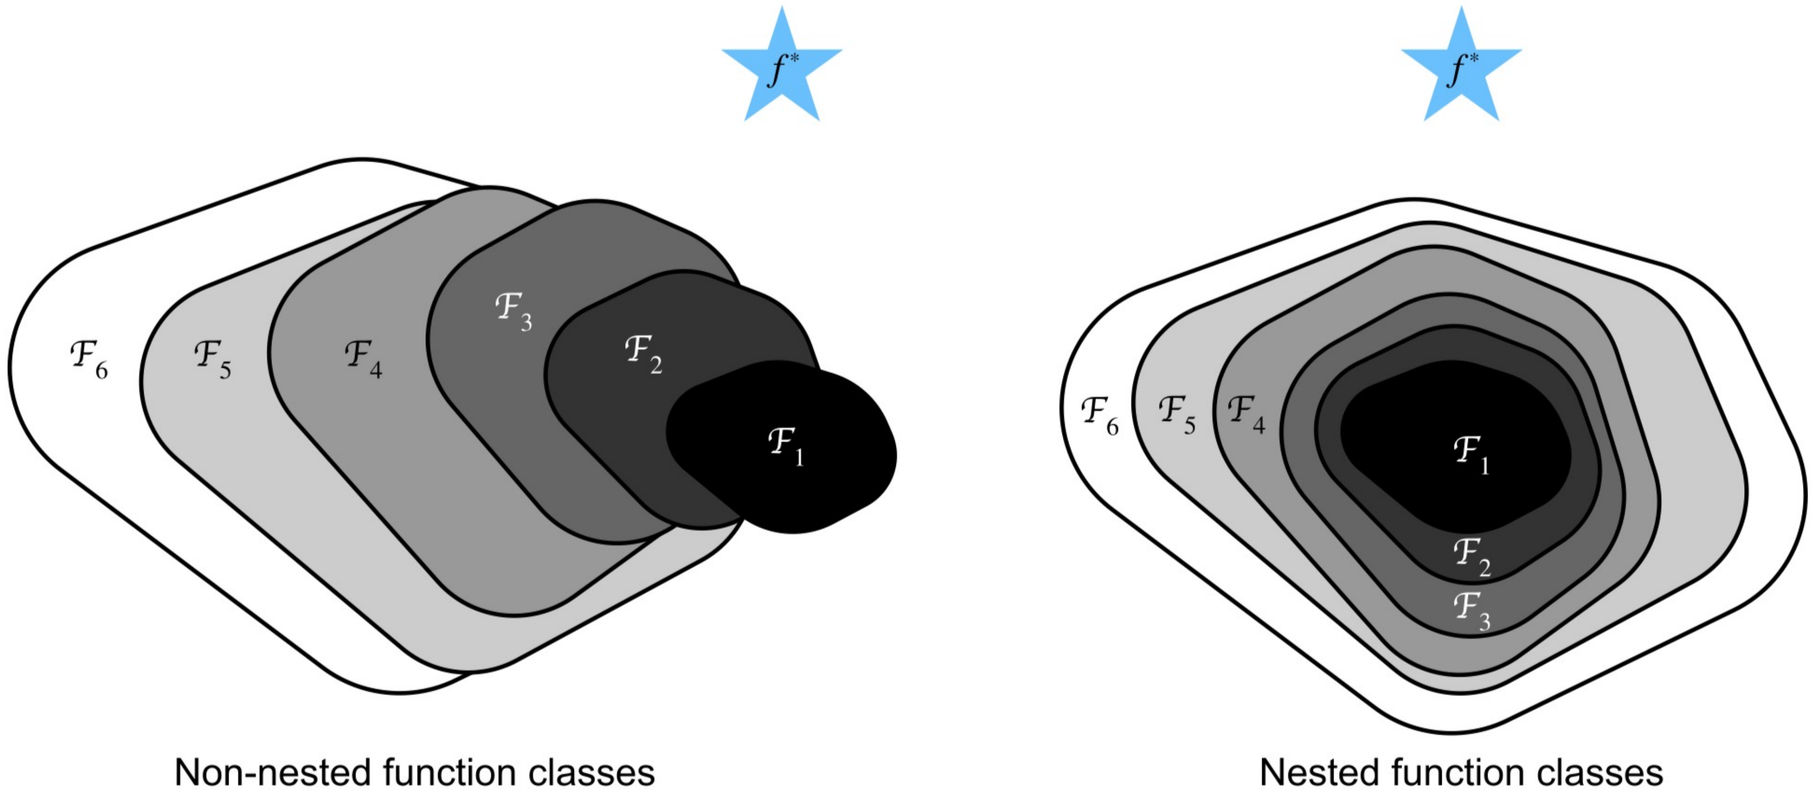

- 对于非嵌套函数类，较复杂（由较大区域表示）的函数类不能保证更接近“真”函数（f^*）。
- 这种现象在嵌套函数类中不会发生。

ResNet

- 残差网络（Residual Network，ResNet）是通过给非线性的卷积层增加直连边的方式来提高信息的传播效率。
- 将目标函数拆分成两部分：恒等函数和残差函数
- 让非线性单元 $f(\boldsymbol{x};\theta)$ 去近似残差函数 $h(\boldsymbol{x})-\boldsymbol{x}$，并用 $f(\boldsymbol{x};\theta)+\boldsymbol{x}$ 去逼近 $h(\boldsymbol{x})$

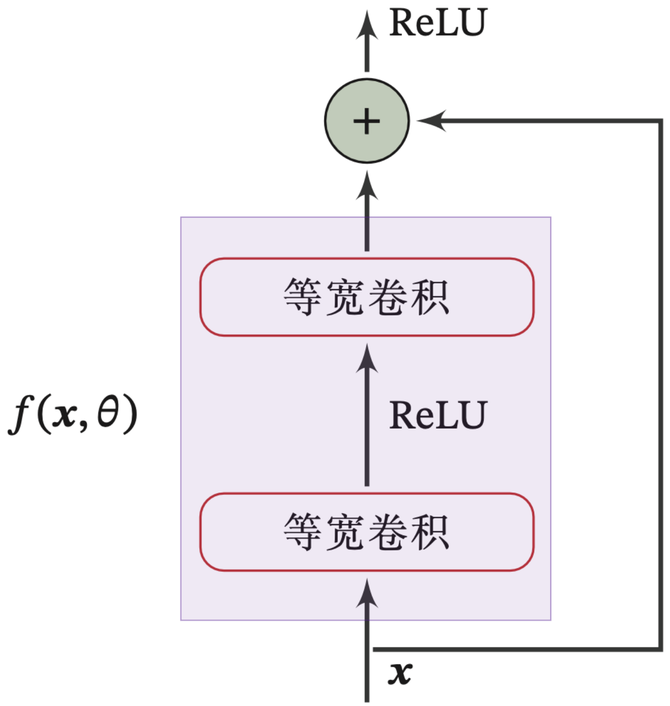

$$h(\boldsymbol{x}) = \underbrace{\boldsymbol{x}}_{\text{恒等函数}} + \underbrace{\big(h(\boldsymbol{x})-\boldsymbol{x}\big)}_{\text{残差函数}}$$

$f(\mathbf{x},\theta)$

ImageNet数据集

ResNet

- 2015 ILSVRC winner （152层）
  - 错误率：3.57%

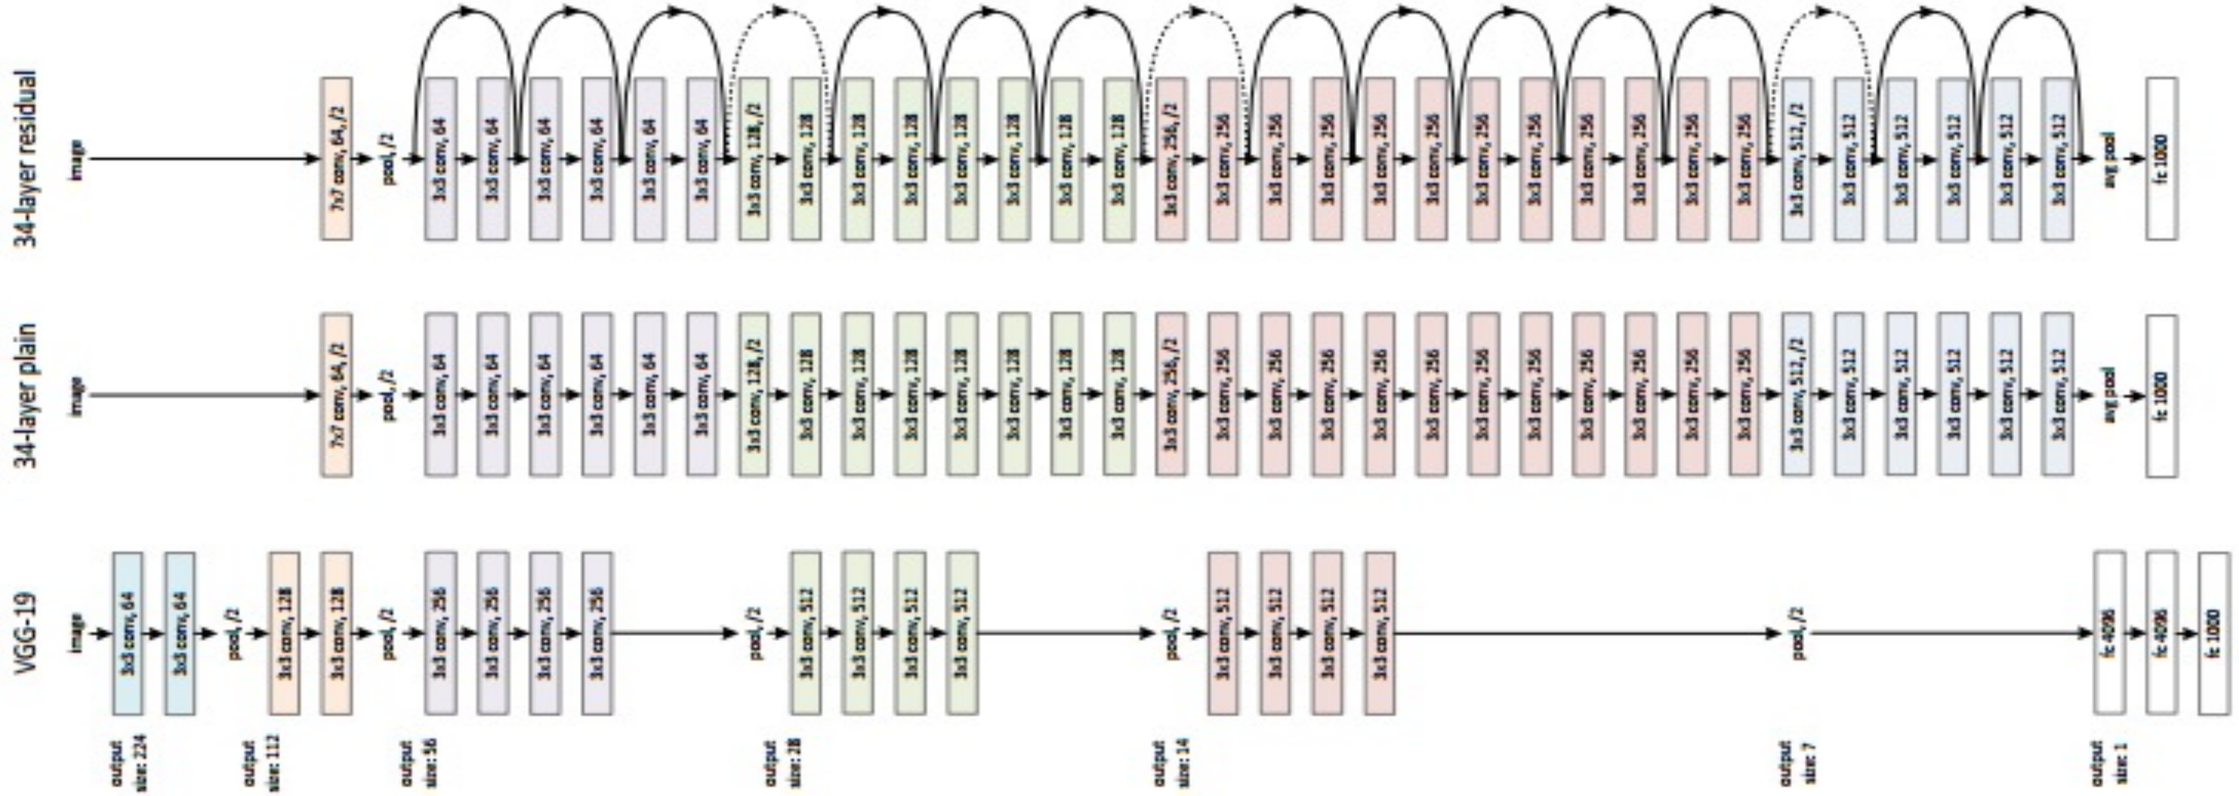

西南交通大學
Southwest Jiaotong University

Thank You