机器学习

第 1 章 绪论

詹大为

计算机与人工智能学院

zhandawei@swjtu.edu.cn

1. 课程介绍：分数组成

(1) **课堂表现：**10 分，考勤，平时作业。

(2) **实验报告：**10 分，共 10 个实验，1 个实验 1 分。

(3) **课程设计：**10 分。

(4) **期中考试：**20 分。

(5) **期末考试：**50 分。

1. 课程介绍：教材

(1) **理论课：**周志华，机器学习，清华大学出版社，2016，第一版。

(2) **实验课：**笔记本电脑，无线网络，2-17 周。

python™

NumPy

1. 课程介绍：先修课程

(1) **线性代数：**向量、矩阵、向量内积、向量范数、矩阵乘法、矩阵的逆、矩阵特征值。

(2) **高等数学：**导数、偏导数、梯度、海森矩阵、求导链式法则、泰勒展开式。

(3) **概率论：**随机变量、期望、方差、一元正态分布、多元正态分布、协方差矩阵。

1. 课程介绍：符号定义

(1) **标量：** $x = 1, y = 5.2$。

(2) **向量：** $\boldsymbol{x} = [1, 2, 3]^{\mathrm{T}}, \boldsymbol{x} = [x_1, x_2, \cdots, x_d]^{\mathrm{T}}$。

(3) **矩阵：**

$$\boldsymbol{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & & & \\ x_{m1} & x_{m2} & \cdots & x_{md} \end{bmatrix}$$

(4) **随机变量：** $X \sim N(\mu, \sigma^2)$

2. 机器学习定义

阿瑟·萨缪尔：机器学习是**不通过显式编程**赋予机器学习能力的学科。

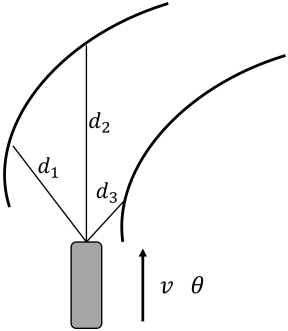

输入： d_1、d_2、d_3。

输出： v、θ。

目标： 根据输入 3 个距离参数，调节速度和转向角实现在车道内自动行驶。

2. 机器学习定义

if $d_1 > d_3$

$\quad \theta = \theta + 1$

$\quad v = v - 1$

else if $d_1 < d_3$

$\quad \theta = \theta - 1$

$\quad v = v - 1$

else if $\cdots$

$\vdots$

end if

显示编程

$$d_{11}, d_{12}, d_{13} \longrightarrow v_1, \theta_1$$
$$d_{21}, d_{22}, d_{23} \longrightarrow v_2, \theta_2$$
$$\vdots$$
$$d_{n1}, d_{n2}, d_{n3} \longrightarrow v_n, \theta_n$$

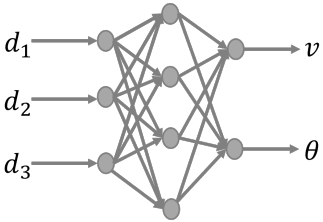

非显示编程

3. 机器学习问题分类

回归问题

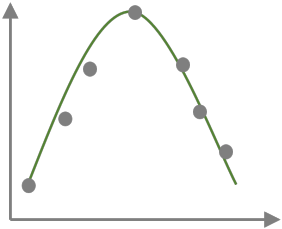

有标签、标签为连续值

分类问题

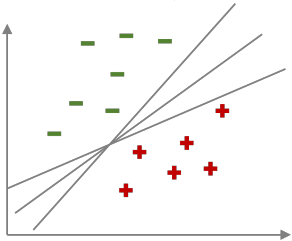

有标签、标签为离散值

聚类问题

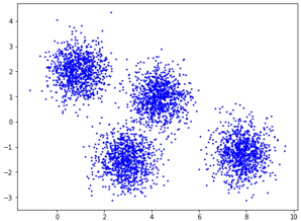

无标签

监督学习

无监督学习

3. 机器学习问题分类

(1) **回归问题：**线性回归。

(2) **分类问题：**逻辑回归、决策树、神经网络、支持向量机、贝叶斯分类器、集成模型。

(3) **聚类问题：**k 均值聚类、高斯混合聚类、层次聚类。

4. 机器学习三要素：线性回归

(1) **模型：** $f = w_1 x + w_2$，模型所能表达的所有函数集合成为**假设空间**。

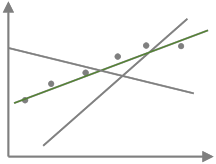

(2) **策略：** 评价模型参数好坏的指标函数，$Loss = \sum_{i=1}^{n}(w_1 x_i + w_2 - y_i)^2$。

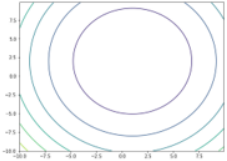

(3) **算法：** 求解策略函数的方法，解析解，$\boldsymbol{w}^\star = (\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{y}$。

4. 机器学习三要素：神经网络

(1) **模型：** $f = \phi(x, \boldsymbol{w})$，模型所能表达的所有函数集合成为**假设空间**。

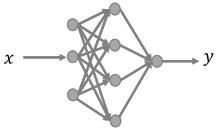

(2) **策略：** 评价模型参数好坏的指标函数，$Loss = \sum_{i=1}^{n} (\phi(x_i, \boldsymbol{w}) - y_i)^2$ 。

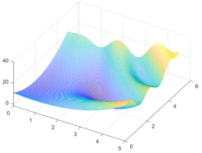

(3) **算法：** 求解策略函数的方法，梯度下降法，$\boldsymbol{w}^\star = \arg\min Loss(\boldsymbol{w})$ 。

5. 没有免费午餐理论：No Free Lunch Theorem

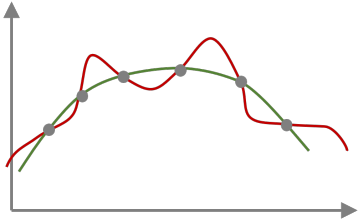

红色和绿色哪个好？

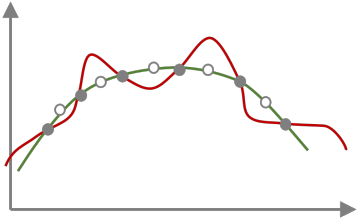

绿色模型比红色好。

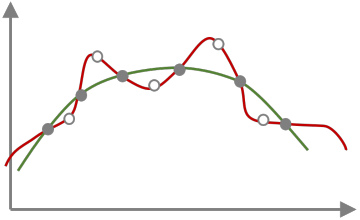

红色模型比绿色好。

考虑**所有**学习问题，任意学习算法 A 和学习算法 B **平均**性能相同。

5. 没有免费午餐理论：No Free Lunch Theorem

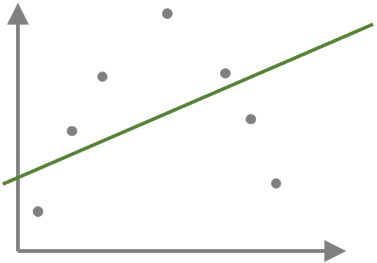

神经网络比线性模型好

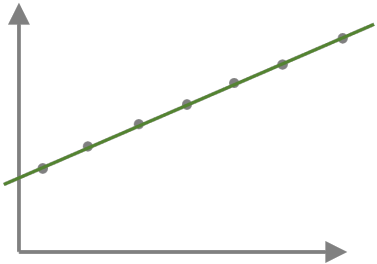

线性模型比神经网络好

5. 没有免费午餐理论：No Free Lunch Theorem

(1) 如果在一个问题上模型 A 比模型 B 好，总是可以找到另一个模型 A 比模型 B 差的问题。

(2) 没有一种模型可以解决所有的机器学习问题。

(3) 根据你的问题和数据特点选取合适的模型。

(4) 简单模型（线性回归）参数少，倾向于欠拟合；复杂模型（神经网络）参数多，倾向于过拟合。

6. 机器学习应用

观看视频

github.com/greerviau/SnakeAI