机器学习

第 4 章 决策树

詹大为

计算机与人工智能学院

zhandawei@swjtu.edu.cn

1. 决策树模型：基本概念

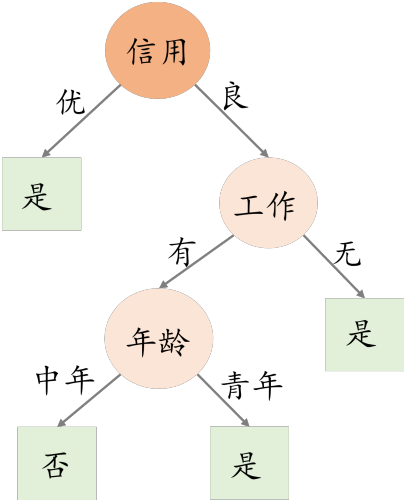

- 根节点、内部节点对应属性（特征）；
- 叶节点对应类别（标签）；
- 一条路径对应一条分类规则；
- 分类规则通过学习数据得到。

1. 决策树模型：引入示例

x_1 年龄	x_2 信用	y 放贷
青年	优	是
中年	良	否
青年	良	否
青年	优	是
中年	优	是
中年	良	否

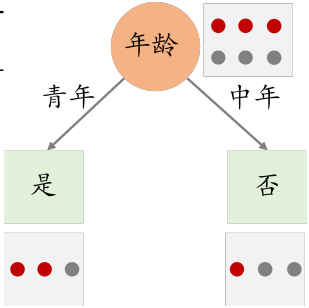

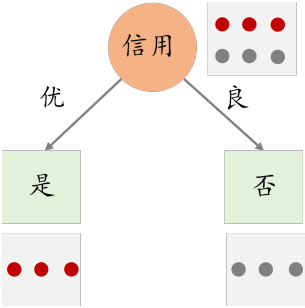

2. 属性划分准则：信息增益

信息熵是随机变量不确定性的度量，不确定性越大，熵越大。随机变量 X 有 k 个取值 $x_1, x_2, \cdots, x_k$，其取值概率为 $P(X = x_i) = p_i$，则这个随机变量的熵为：

$$\mathrm{Ent}(X) = -\sum_{i=1}^{k} p_i \log_2 p_i$$

用信息熵来描绘样本标签不确定性，样本集 D 中样本标签有 k 种 $y_1, y_2, \cdots, y_k$，每种标签的比例为 p_i，则样本集 D 的信息熵为：

$$\mathrm{Ent}(D) = -\sum_{i=1}^{k} p_i \log_2 p_i$$

2. 属性划分准则：信息增益

样本集 D 的信息熵为：

$$\mathrm{Ent}(D) = -\sum_{i=1}^{k} p_i \log_2 p_i$$

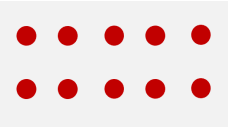

$$\mathrm{Ent}(D) = -\sum_{i=1}^{k} p_i \log_2 p_i = -1 \times \log_2(1) = 0$$

$$\mathrm{Ent}(D) = -\sum_{i=1}^{k} p_i \log_2 p_i = -0.9 \times \log_2(0.9) - 0.1 \times \log_2(0.1) = 0.469$$

$$\mathrm{Ent}(D) = -\sum_{i=1}^{k} p_i \log_2 p_i = -0.1 \times \log_2(0.1) - 0.9 \times \log_2(0.9) = 0.469$$

$$\mathrm{Ent}(D) = -\sum_{i=1}^{k} p_i \log_2 p_i = -0.5 \times \log_2(0.5) - 0.5 \times \log_2(0.5) = 1$$

2. 属性划分准则：信息增益

信息增益是样本集根据属性 a 划分后信息熵的减少量，假设属性一共 v 个分支：

$$\mathrm{Gain}(D,a)=\mathrm{Ent}(D)-\sum_{i=1}^{v}\frac{|D_i|}{|D|}\mathrm{Ent}(D_i)$$

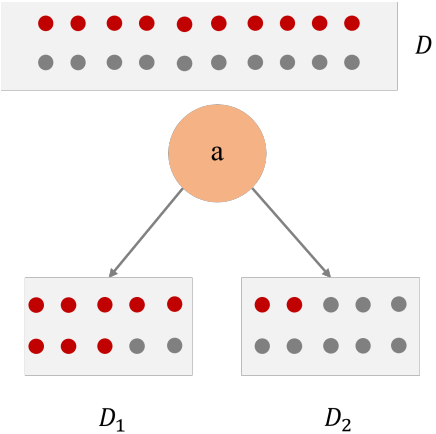

$$\begin{aligned}\mathrm{Gain}(D,a)&=\mathrm{Ent}(D)-\frac{1}{2}\mathrm{Ent}(D_1)-\frac{1}{2}\mathrm{Ent}(D_2)\\&=1-\frac{1}{2}\times 0.7219-\frac{1}{2}\times 0.7219\\&=0.2781\end{aligned}$$

2. 属性划分准则：信息增益

信息增益是样本集根据属性 a 划分后信息熵的减少量，假设属性一共 v 个分支：

$$\mathrm{Gain}(D,a)=\mathrm{Ent}(D)-\sum_{i=1}^{v}\frac{|D_i|}{|D|}\mathrm{Ent}(D_i)$$

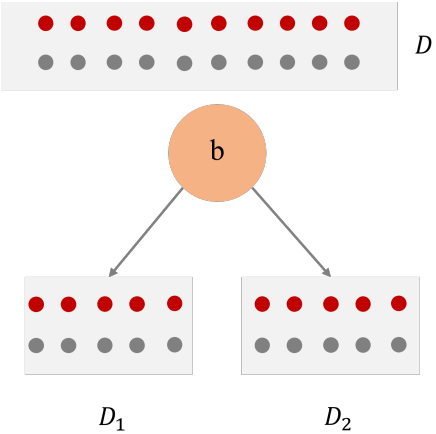

$$\begin{aligned}\mathrm{Gain}(D,b)&=\mathrm{Ent}(D)-\frac{1}{2}\mathrm{Ent}(D_1)-\frac{1}{2}\mathrm{Ent}(D_2)\\&=1-\frac{1}{2}\times 1-\frac{1}{2}\times 1\\&=0\end{aligned}$$

2. 属性划分准则：信息增益

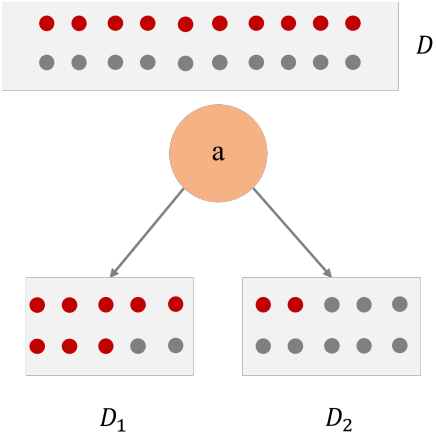

$$\text{Gain}(D, a) = 0.2718$$

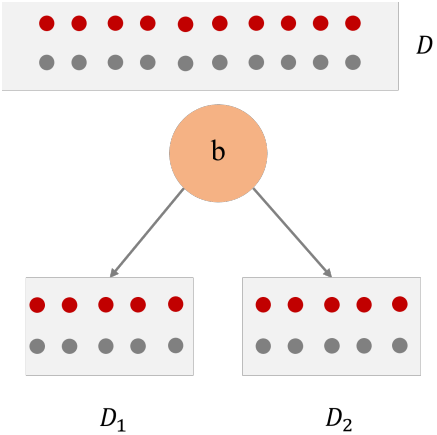

$$\text{Gain}(D, b) = 0$$

2. 属性划分准则：作业 4

计算工作这个属性的信息增益。

序号	年龄	工作	房子	信贷	类别
1	青年	否	否	中	否
2	青年	否	否	良	否
3	青年	是	否	良	是
4	青年	是	是	中	是
5	青年	否	否	中	否
6	中年	否	否	中	否
7	中年	否	否	良	否
8	中年	是	是	良	是
9	中年	否	是	优	是
10	中年	否	是	优	是
11	老年	否	是	优	是
12	老年	否	是	良	是
13	老年	是	否	良	是
14	老年	是	否	优	是
15	老年	否	否	中	否

$$\mathrm{Ent}(D) = -\sum_{i=1}^{k} p_i \log_2 p_i$$

$$\mathrm{Gain}(D, a) = \mathrm{Ent}(D) - \sum_{i=1}^{v} \frac{|D_i|}{|D|} \mathrm{Ent}(D_i)$$

2. 属性划分准则：作业 4

按照工作属性划分得到 2 个子集，工作为是的集合 D_1 包含 5 个正例，工作为否的集合 D_2 包含 4 个正例和 6 个反例。

$$
\begin{aligned}
\mathrm{Ent}(D) &= -\frac{9}{15}\log_2\frac{9}{15} - \frac{6}{15}\log_2\frac{6}{15} = 0.9710 \\
\mathrm{Ent}(D_1) &= 0 \\
\mathrm{Ent}(D_2) &= -\frac{4}{10}\log_2\frac{4}{10} - \frac{6}{10}\log_2\frac{6}{10} = 0.9710 \\
\mathrm{Gain}(D, \text{工作}) &= 0.9710 - \frac{5}{15}\times 0 - \frac{10}{15}\times 0.9710 = 0.3237
\end{aligned}
$$

2. 属性划分准则：信息增益率

信息增益率是属性 a 信息增益与其属性固有值的比值

$$\text{GainRatio}(D,a)=\frac{\text{Gain}(D,a)}{\text{IV}(a)}=\frac{\text{Gain}(D,a)}{-\sum_{i=1}^{v}\frac{|D_i|}{|D|}\log_2\frac{|D_i|}{|D|}}$$

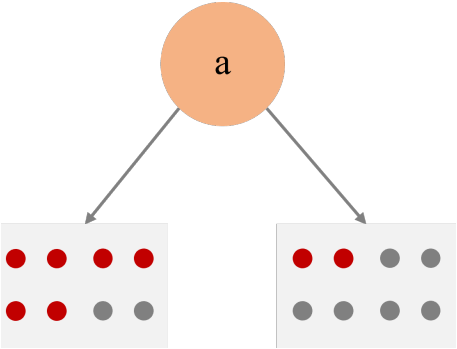

$\text{Gain}(D,a)=0.1887$

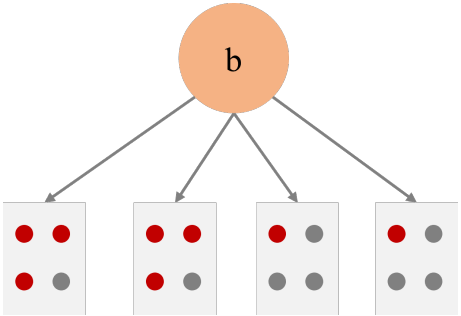

$\text{Gain}(D,b)=0.1887$

2. 属性划分准则：信息增益率

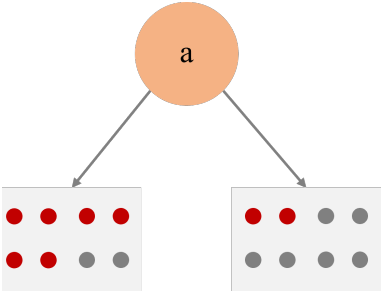

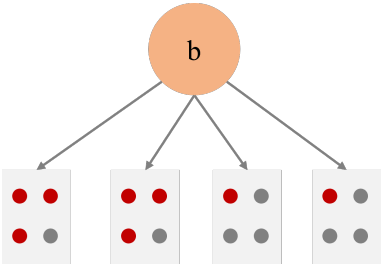

$$
\begin{aligned}
\mathrm{IV}(a) &= -\sum_{i=1}^{2} \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|} \\
&= -\sum_{i=1}^{2} \frac{1}{2} \times \log_2 \frac{1}{2} \\
&= 1
\end{aligned}
$$

$$
\begin{aligned}
\mathrm{IV}(b) &= -\sum_{i=1}^{4} \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|} \\
&= -\sum_{i=1}^{4} \frac{1}{4} \times \log_2 \frac{1}{4} \\
&= 2
\end{aligned}
$$

2. 属性划分准则：信息增益率

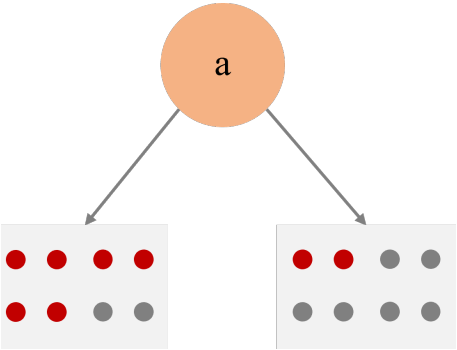

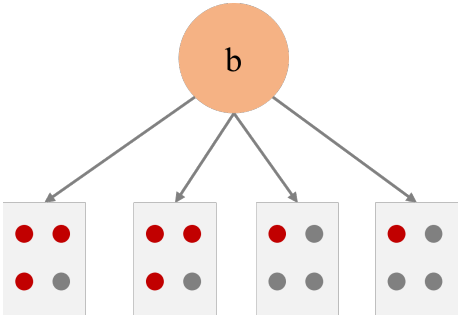

$$\begin{aligned}\text{GainRatio}(D,a) &= \frac{\text{Gain}(D,a)}{\text{IV}(a)} \\ &= \frac{0.1887}{1} \\ &= 0.1887\end{aligned}$$

$$\begin{aligned}\text{GainRatio}(D,b) &= \frac{\text{Gain}(D,b)}{\text{IV}(b)} \\ &= \frac{0.1887}{2} \\ &= 0.0944\end{aligned}$$

2. 属性划分准则：信息增益率

计算工作这个属性的信息增益率。

序号	年龄	工作	房子	信贷	类别
1	青年	否	否	中	否
2	青年	否	否	良	否
3	青年	是	否	良	是
4	青年	是	是	中	是
5	青年	否	否	中	否
6	中年	否	否	中	否
7	中年	否	否	良	否
8	中年	是	是	良	是
9	中年	否	是	优	是
10	中年	否	是	优	是
11	老年	否	是	优	是
12	老年	否	是	良	是
13	老年	是	否	良	是
14	老年	是	否	优	是
15	老年	否	否	中	否

$$\mathrm{Ent}(D) = -\sum_{i=1}^{k} p_i \log_2 p_i$$

$$\mathrm{Gain}(D, a) = \mathrm{Ent}(D) - \sum_{i=1}^{v} \frac{|D_i|}{|D|} \mathrm{Ent}(D_i)$$

$$\mathrm{GainRatio}(D, a) = \frac{\mathrm{Gain}(D, a)}{-\sum_{i=1}^{v} \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|}}$$

2. 属性划分准则：作业 4

按照工作属性划分得到 2 个子集，工作为是的集合 D_1 包含 5 个正例，工作为否的集合 D_2 包含 4 个正例和 6 个反例。

$$\text{Gain}(D, \text{工作}) = 0.9710 - \frac{5}{15} \times 0 - \frac{10}{15} \times 0.9710 = 0.3237$$

$$\text{IV}(\text{工作}) = -\frac{5}{15} \times \log_2 \frac{5}{15} - \frac{10}{15} \times \log_2 \frac{10}{15} = 0.9183$$

$$\text{GainRatio}(D, \text{工作}) = \frac{\text{Gain}(D, \text{工作})}{\text{IV}(\text{工作})} = \frac{0.3237}{0.9183} = 0.3525$$

2. 属性划分准则：基尼指数

信息熵 $\mathrm{Ent}(D) = -\sum_{i=1}^{k} p_i \log_2 p_i$

基尼值 $\mathrm{Gini}(D) = 1 - \sum_{i=1}^{k} p_i^2$

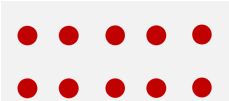

$\mathrm{Ent}(D) = 0$

$\mathrm{Gini}(D) = 1 - 1^2 = 0$

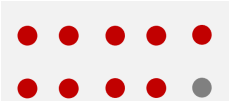

$\mathrm{Ent}(D) = 0.469$

$\mathrm{Gini}(D) = 1 - 0.9^2 - 0.1^2 = 0.18$

$\mathrm{Ent}(D) = 0.469$

$\mathrm{Gini}(D) = 1 - 0.1^2 - 0.9^2 = 0.18$

$\mathrm{Ent}(D) = 1$

$\mathrm{Gini}(D) = 1 - 0.5^2 - 0.5^2 = 0.5$

2. 属性划分准则：基尼指数

$$\text{基尼指数} \quad \text{GiniIndex}(D,a)=\sum_{i=1}^{v}\frac{|D_i|}{|D|}\text{Gini}(D_i)$$

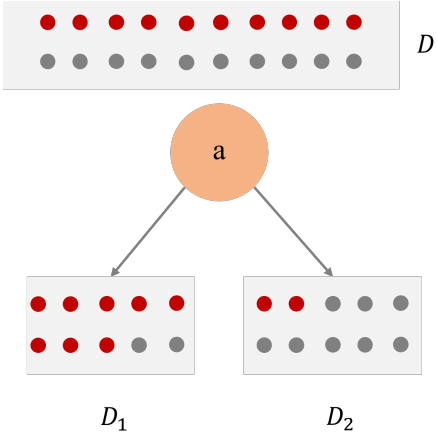

$$\text{Gini}(D_1)=1-0.8^2-0.2^2=0.32$$
$$\text{Gini}(D_2)=1-0.2^2-0.8^2=0.32$$

$$\begin{aligned}\text{GiniIndex}(D,a)&=\frac{|D_1|}{|D|}\text{Gini}(D_1)+\frac{|D_2|}{|D|}\text{Gini}(D_2)\\&=0.5\times0.32+0.5\times0.32\\&=0.32\end{aligned}$$

2. 属性划分准则：作业 4

计算工作这个属性的基尼指数。

序号	年龄	工作	房子	信贷	类别
1	青年	否	否	中	否
2	青年	否	否	良	否
3	青年	是	否	良	是
4	青年	是	是	中	是
5	青年	否	否	中	否
6	中年	否	否	中	否
7	中年	否	否	良	否
8	中年	是	是	良	是
9	中年	否	是	优	是
10	中年	否	是	优	是
11	老年	否	是	优	是
12	老年	否	是	良	是
13	老年	是	否	良	是
14	老年	是	否	优	是
15	老年	否	否	中	否

$$\text{Gini}(D) = 1 - \sum_{i=1}^{k} p_i^2$$

$$\text{GiniIndex}(D, a) = \sum_{i=1}^{v} \frac{|D_i|}{|D|} \text{Gini}(D_i)$$

2. 属性划分准则：作业 4

按照工作属性划分得到 2 个子集，工作为是的集合 D_1 包含 5 个正例，工作为否的集合 D_2 包含 4 个正例和 6 个反例。

$$\text{Gini}(D_1) = 1 - \frac{5}{5}^2 = 0$$

$$\text{Gini}(D_2) = 1 - \frac{4}{10}^2 - \frac{6}{10}^2 = 0.48$$

$$\text{GiniIndex}(D, \text{工作}) = \frac{5}{15} \times 0 + \frac{10}{15} \times 0.48 = 0.32$$

3. 决策树的构建

序号	年龄	工作	房子	信贷	类别
1	青年	否	否	中	否
2	青年	否	否	良	否
3	青年	是	否	良	是
4	青年	是	是	中	是
5	青年	否	否	中	否
6	中年	否	否	中	否
7	中年	否	否	良	否
8	中年	是	是	良	是
9	中年	否	是	优	是
10	中年	否	是	优	是
11	老年	否	是	优	是
12	老年	否	是	良	是
13	老年	是	否	良	是
14	老年	是	否	优	是
15	老年	否	否	中	否

$$\text{Gain}(D, \text{年龄}) = 0.083$$

$$\text{Gain}(D, \text{工作}) = 0.324$$

$$\text{Gain}(D, \text{房子}) = 0.420$$

$$\text{Gain}(D, \text{信贷}) = 0.363$$

3. 决策树的构建

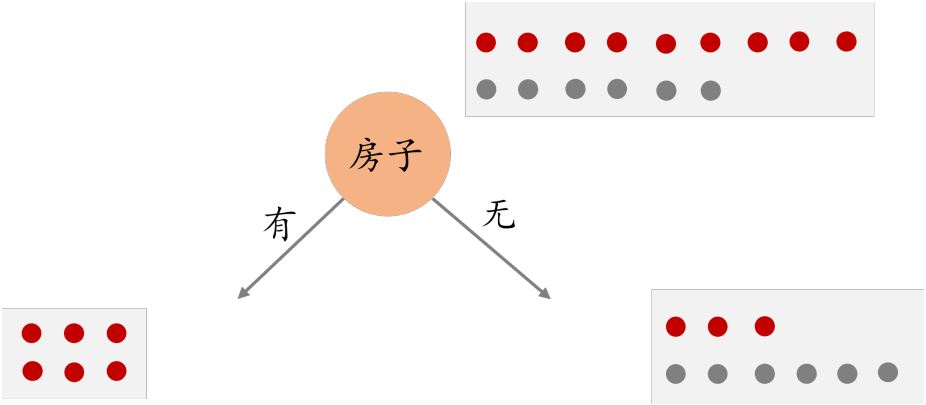

3. 决策树的构建

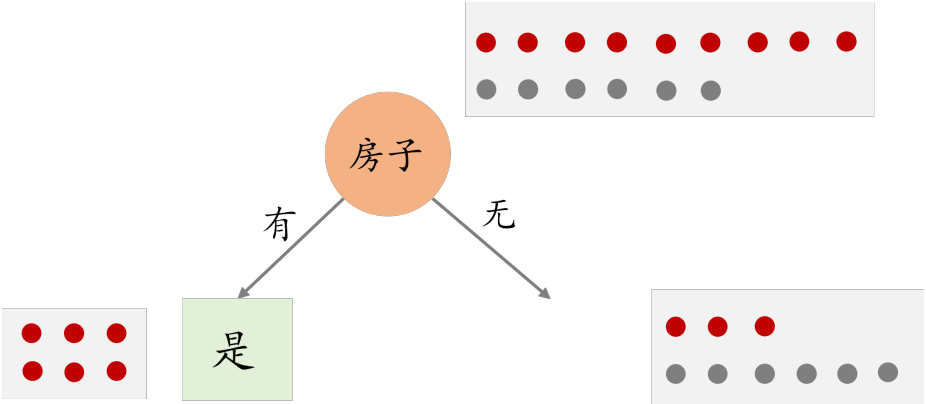

3. 决策树的构建

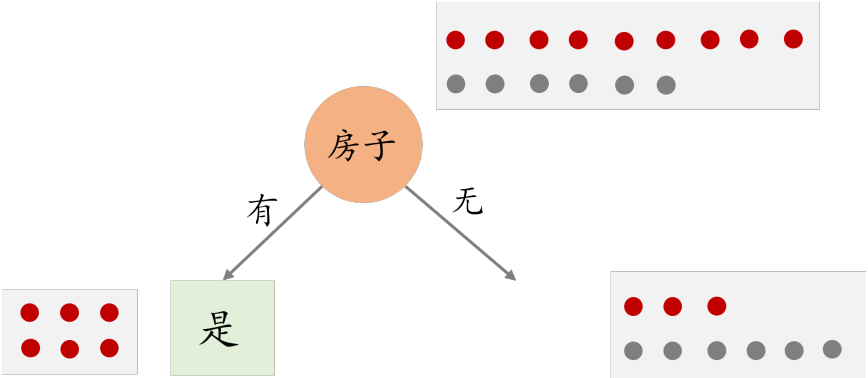

$$\text{Gain}(D, \text{年龄}) = 0.251$$

$$\text{Gain}(D, \text{工作}) = 0.918$$

$$\text{Gain}(D, \text{信贷}) = 0.474$$

3. 决策树的构建

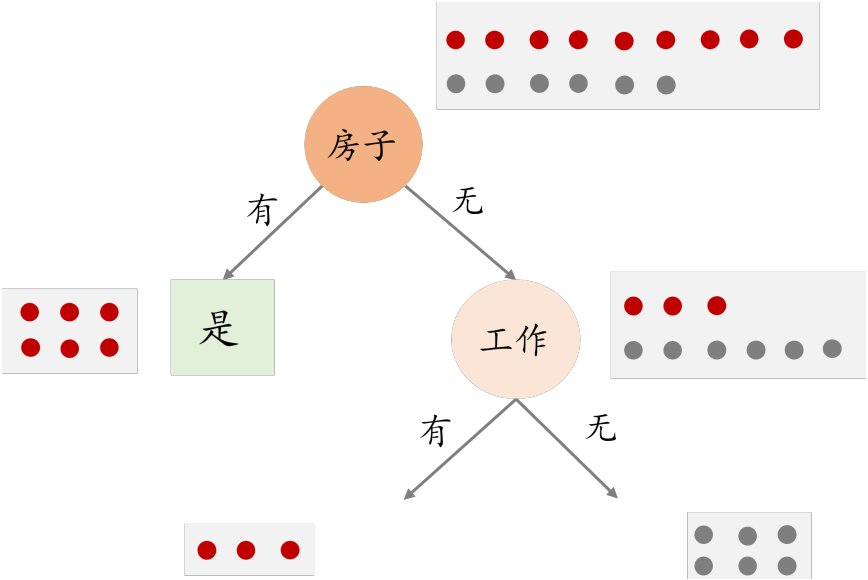

3. 决策树的构建

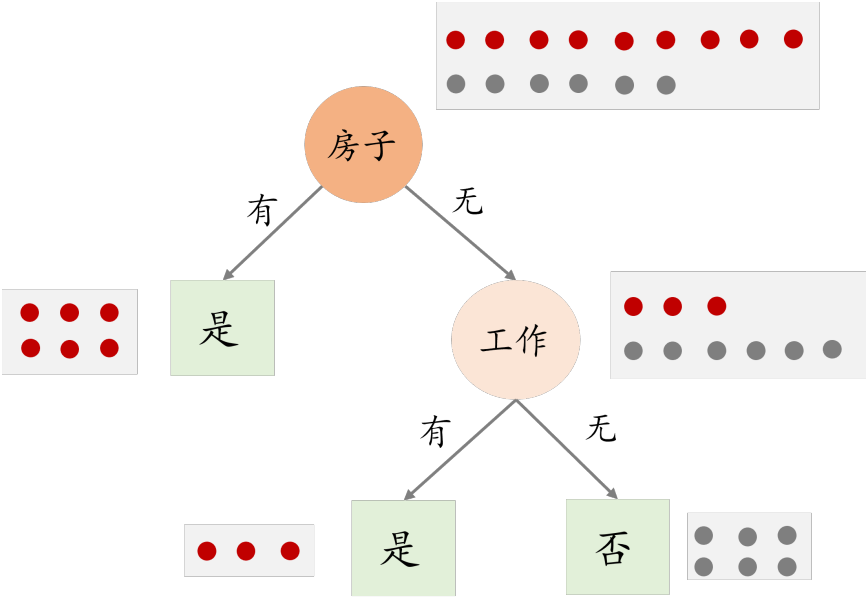

4. 决策树的剪枝：预剪枝

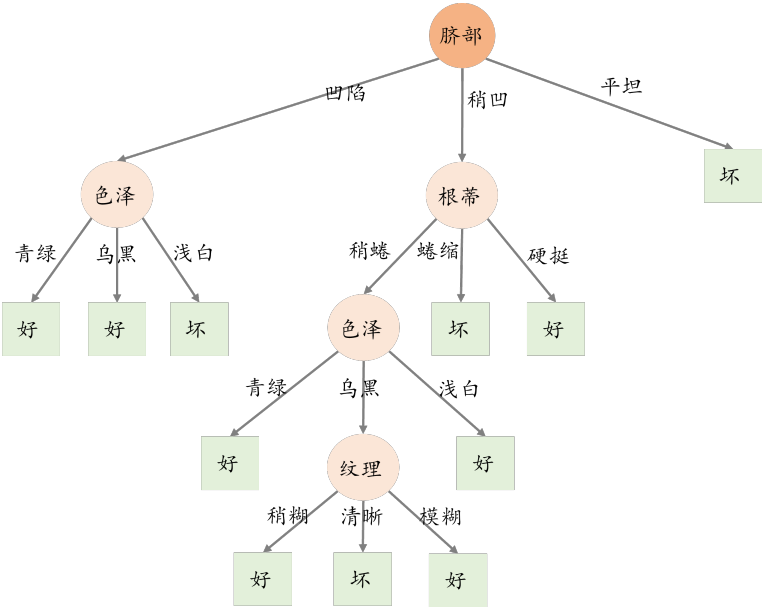
脐部
凹陷
稍凹
平坦
色泽
根蒂
坏
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好
好
坏
色泽
坏
好
青绿
乌黑
浅白
好
纹理
好
稍糊
清晰
模糊
好
坏
好

4. 决策树的剪枝：预剪枝

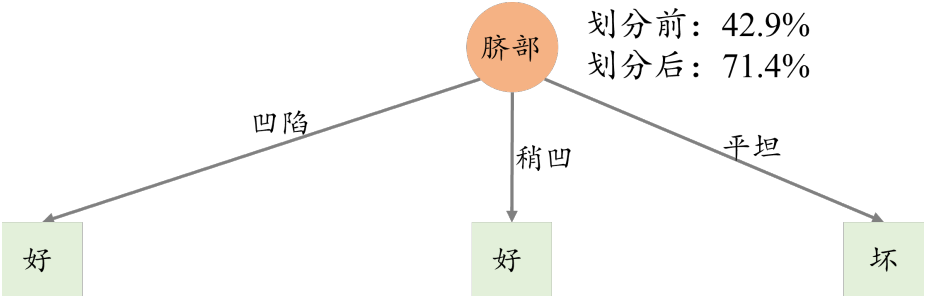

4. 决策树的剪枝：预剪枝

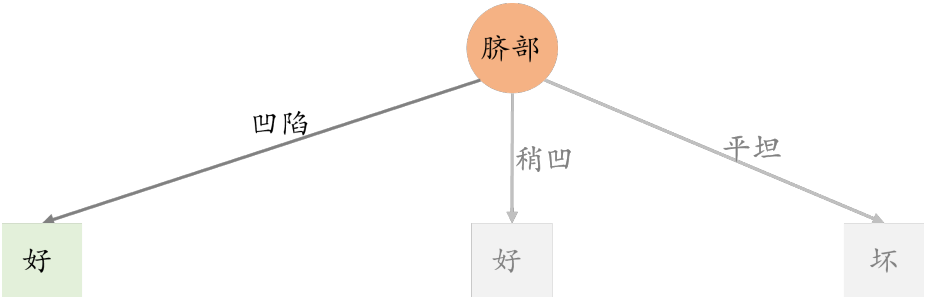

4. 决策树的剪枝：预剪枝

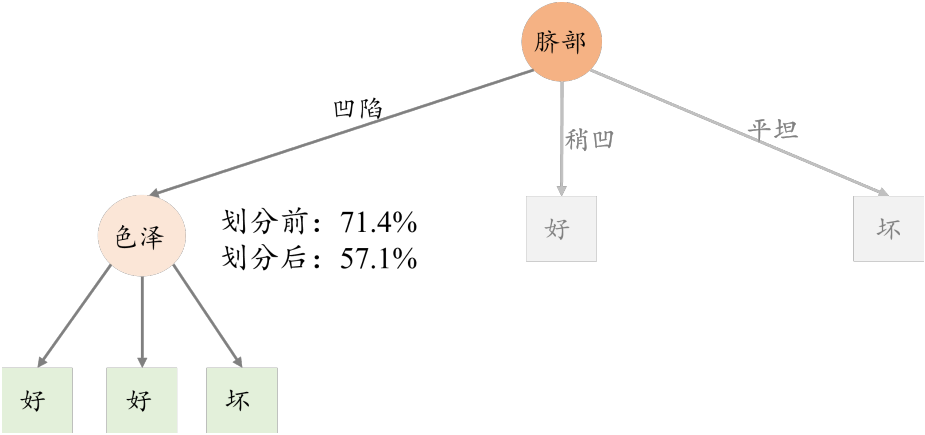

4. 决策树的剪枝：预剪枝

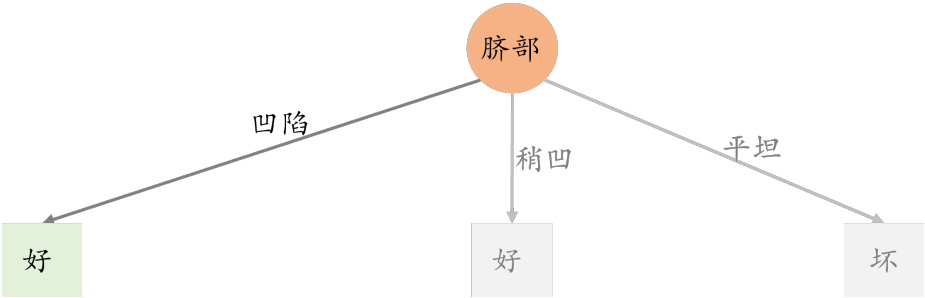

4. 决策树的剪枝：预剪枝

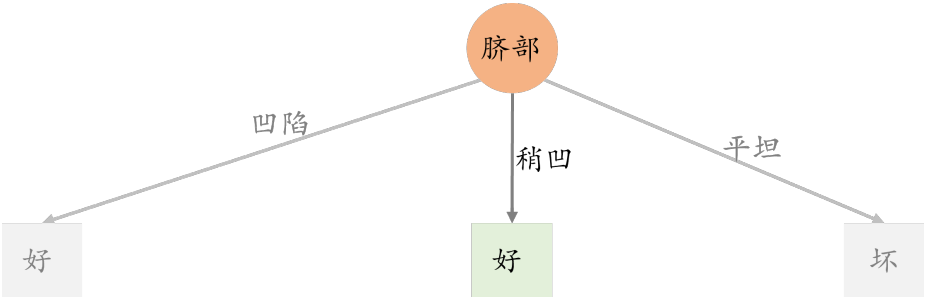

4. 决策树的剪枝：预剪枝

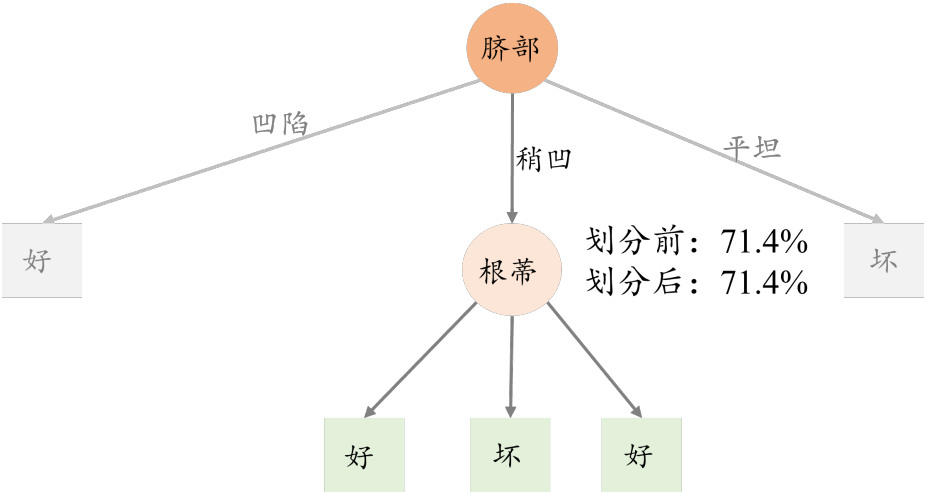

4. 决策树的剪枝：预剪枝

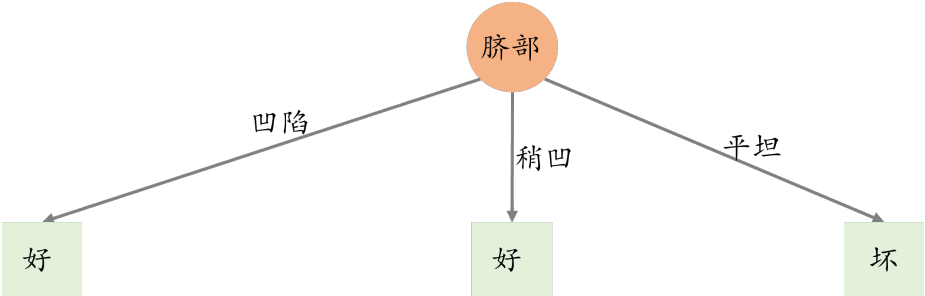

- 贪心策略
- 有欠拟合风险
- 训练开销小

4. 决策树的剪枝：后剪枝

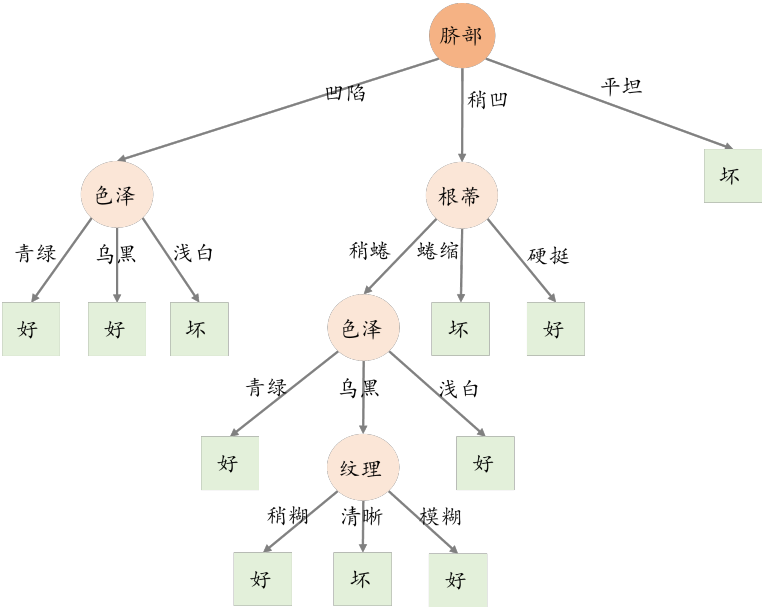
脐部
凹陷
稍凹
平坦
色泽
根蒂
坏
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好
好
坏
色泽
坏
好
青绿
乌黑
浅白
好
纹理
好
稍糊
清晰
模糊
好
坏
好

4. 决策树的剪枝：后剪枝

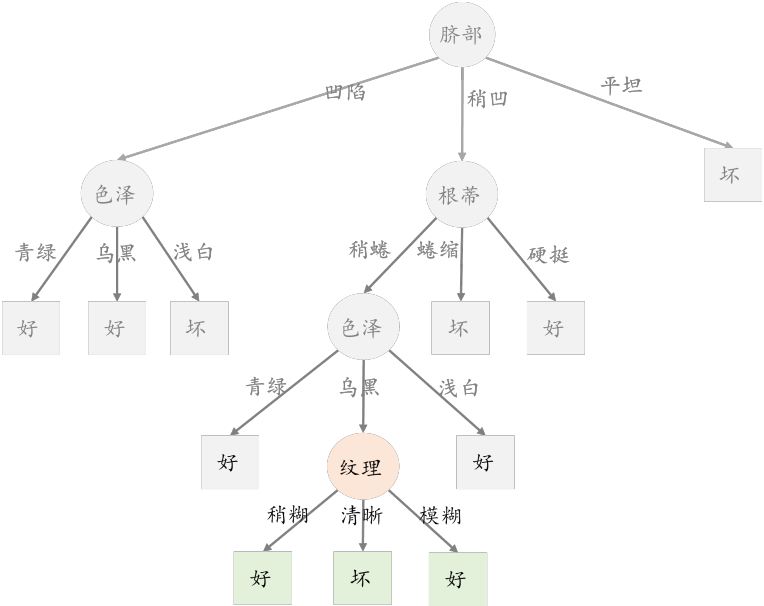
脐部
凹陷
稍凹
平坦
色泽
根蒂
坏
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好
好
坏
色泽
坏
好
青绿
乌黑
浅白
好
纹理
好
稍糊
清晰
模糊
好
坏
好

4. 决策树的剪枝：后剪枝

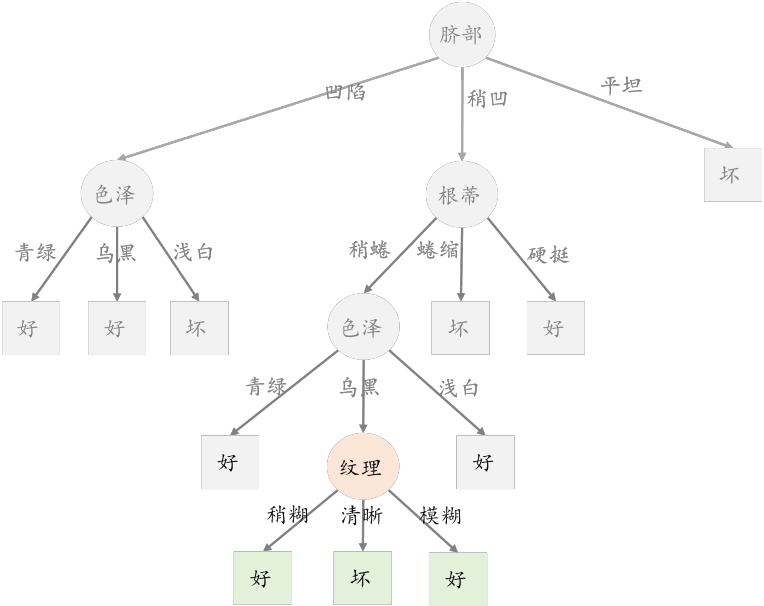
脐部
凹陷
稍凹
平坦
色泽
根蒂
坏
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好
好
坏
色泽
坏
好
青绿
乌黑
浅白
好
纹理
好
稍糊
清晰
模糊
好
坏
好

4. 决策树的剪枝：后剪枝

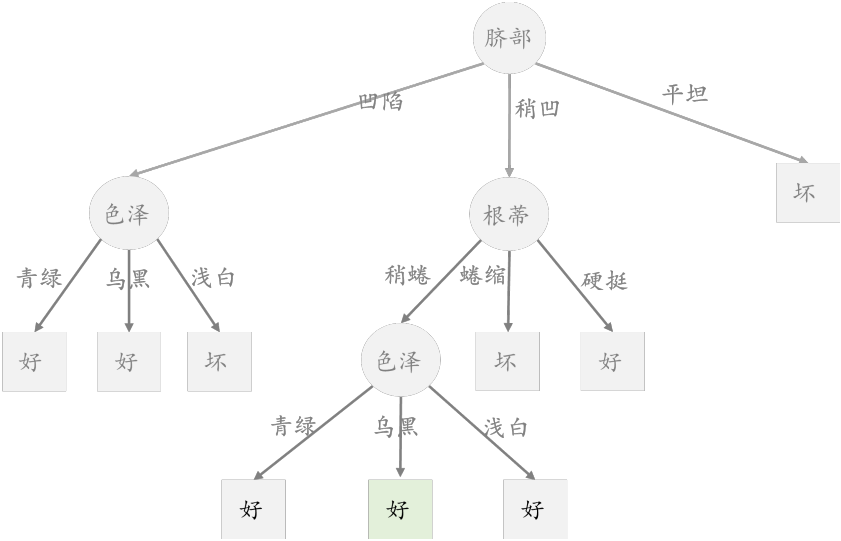

4. 决策树的剪枝：后剪枝

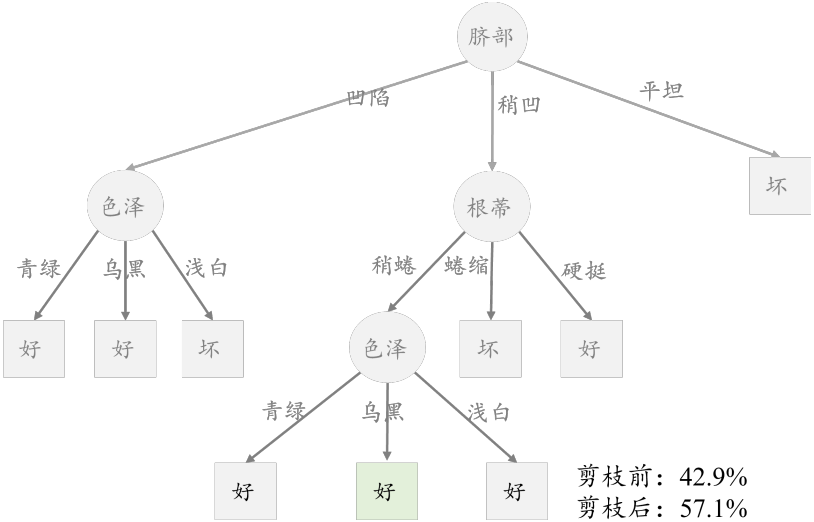

剪枝前：42.9%
剪枝后：57.1%

4. 决策树的剪枝：后剪枝

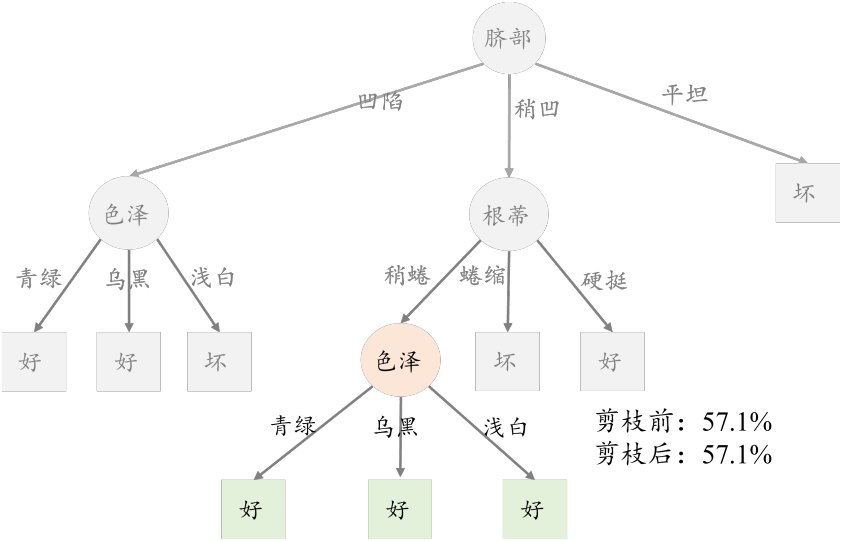

剪枝前：57.1%
剪枝后：57.1%

4. 决策树的剪枝：后剪枝

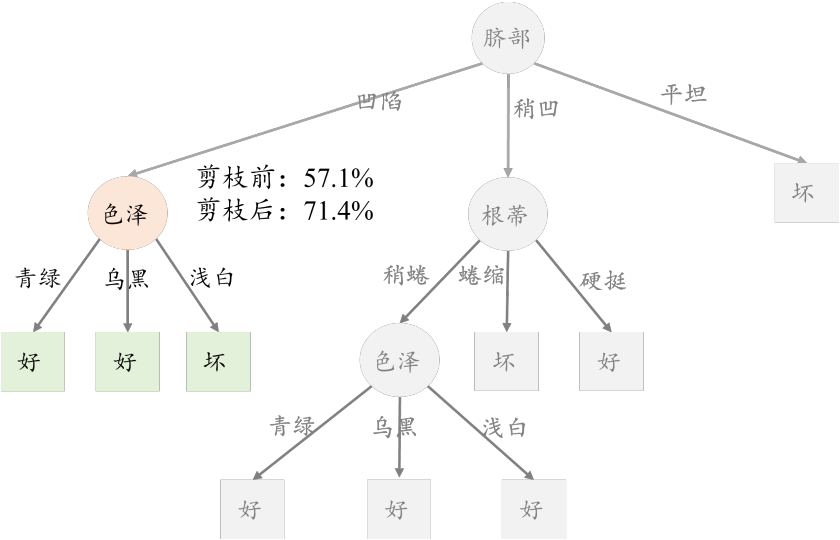
脐部
凹陷
稍凹
平坦
色泽
剪枝前：57.1%
剪枝后：71.4%
根蒂
坏
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好
好
坏
色泽
坏
好
青绿
乌黑
浅白
好
好
好

4. 决策树的剪枝：后剪枝

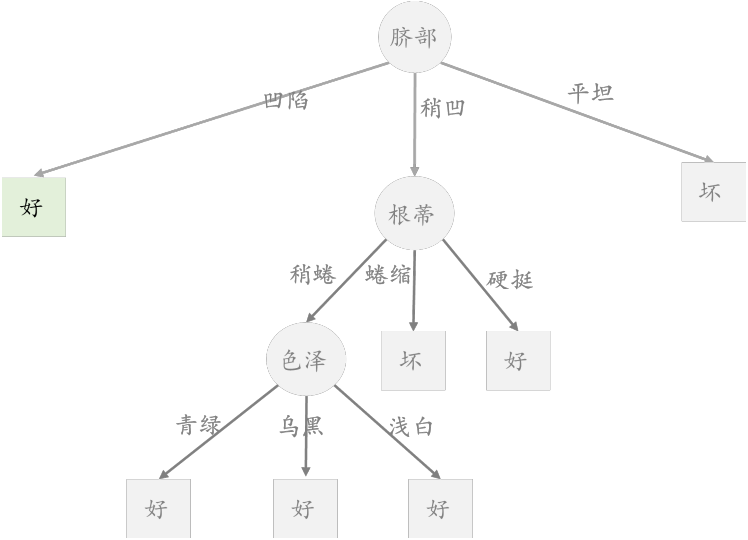

4. 决策树的剪枝：后剪枝

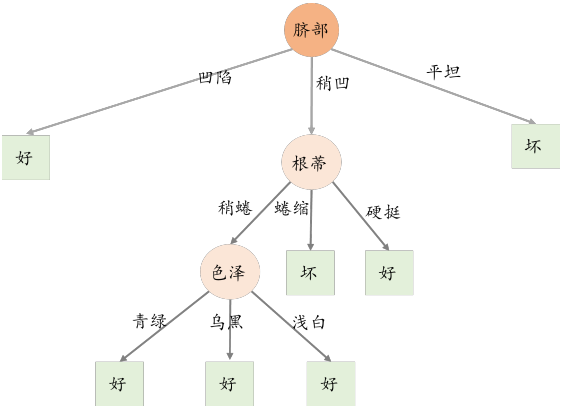

- 欠拟合风险小
- 训练开销大
- 泛化性能优于预剪枝

5. 连续值和缺失值的处理：连续值

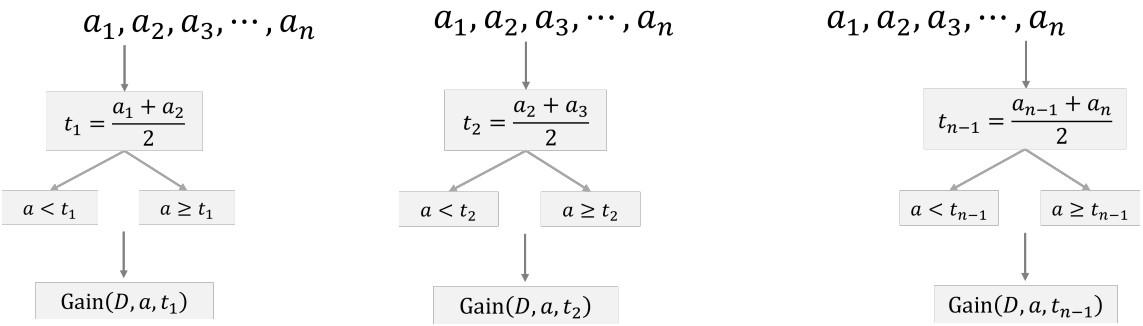

$$t = \arg\max_{i=1}^{n-1} \text{Gain}(D, a, t_i)$$

$$\text{Gain}(D, a) = \max_{i=1}^{n-1} \text{Gain}(D, a, t_i)$$

5. 连续值和缺失值的处理：缺失值

序号	色泽	···	类别
1	–	···	是
2	乌黑	···	是
3	乌黑	···	是
4	青绿	···	是
5	–	···	是
6	青绿	···	是
7	乌黑	···	是
8	乌黑	···	是
9	乌黑	···	否
10	青绿	···	否
11	浅白	···	否
12	浅白	···	否
13	–	···	否
14	浅白	···	否
15	乌黑	···	否
16	浅白	···	否
17	青绿	···	否
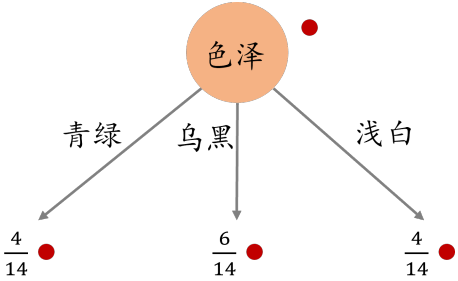
$$\mathrm{Gain}(D, \text{色泽}) = \frac{14}{17}\mathrm{Gain}(\tilde{D}, \text{色泽})$$