机器学习

第 8 章 集成方法

詹大为

计算机与人工智能学院

zhandawei@swjtu.edu.cn

1. 提升集成方法：AdaBoost

假设基分类器为 $h(x)=\begin{cases}+1, x<v\\-1, x>v\end{cases}$ 或者 $h(x)=\begin{cases}-1, x<v\\+1, x>v\end{cases}$，其中 $v=\{1.5, 2.5, \cdots, 9.5\}$ 是分类器参数，损失是分类器在训练集上分类错误率最低。

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1

训练模型

$x < v$ 为 $+1$	v	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
	错误率	0.5	0.4	**0.3**	0.4	0.5	0.6	0.5	0.4	0.3
$x < v$ 为 -1	v	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
	错误率	0.5	0.6	0.7	0.6	0.5	0.4	0.5	0.6	0.7

得到

$$h(x) = \begin{cases} +1, x < 3.5 \\ -1, x > 3.5 \end{cases}$$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1

初始化所有样本权重 0.1，以带权重错误率为准则，训练第 1 个基模型 $h_1(x)$，

$x < v$ 为 $+1$	v	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
	带权错误率	0.5	0.4	**0.3**	0.4	0.5	0.6	0.5	0.4	0.3
$x < v$ 为 -1	v	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
	带权错误率	0.5	0.6	0.7	0.6	0.5	0.4	0.5	0.6	0.7

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1

$$h_1(x) = \begin{cases} +1, x < 3.5 \\ -1, x > 3.5 \end{cases}$$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
$h_1(x)$	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
$w_{2,i}$	0.072	0.072	0.072	0.072	0.072	0.072	0.167	0.167	0.167	0.072

根据基模型 $h_1(x)$ 预测结果，调整样本权重。

$$h_1(x) = \begin{cases} +1, x < 3.5 \\ -1, x > 3.5 \end{cases}$$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
$h_1(x)$	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
$w_{2,i}$	0.072	0.072	0.072	0.072	0.072	0.072	0.167	0.167	0.167	0.072

根据新的样本权重，以带权重错误率为准则，训练基模型 $h_2(x)$

$x < v$ 为 $+1$	v	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
	带权错误率	0.645	0.573	0.501	0.573	0.645	0.717	0.55	0.383	**0.216**
$x < v$ 为 -1	v	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
	带权错误率	0.36	0.432	0.504	0.432	0.36	0.288	0.455	0.622	0.789

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
$h_1(x)$	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
$w_{2,i}$	0.072	0.072	0.072	0.072	0.072	0.072	0.167	0.167	0.167	0.072

得到：

$$h_2(x) = \begin{cases} +1, x < 9.5 \\ -1, x > 9.5 \end{cases}$$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
$h_1(x)$	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
$w_{2,i}$	0.072	0.072	0.072	0.072	0.072	0.072	0.167	0.167	0.167	0.072
$h_2(x)$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	-1
$w_{3,i}$	0.046	0.046	0.046	0.167	0.167	0.167	0.106	0.106	0.106	0.046

根据基模型 $h_2(x)$ 预测结果，调整样本权重。

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
$h_1(x)$	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
$w_{2,i}$	0.072	0.072	0.072	0.072	0.072	0.072	0.167	0.167	0.167	0.072
$h_2(x)$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	-1
$w_{3,i}$	0.046	0.046	0.046	0.167	0.167	0.167	0.106	0.106	0.106	0.046

根据新的样本权重，以带权重错误率为准则，训练基模型 $h_3(x)$

$x < v$ 为 $+1$	v	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
	带权错误率	0.41	0.364	0.318	0.485	0.652	0.819	0.652	0.485	0.318
$x < v$ 为 -1	v	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
	带权错误率	0.593	0.639	0.685	0.518	0.351	**0.184**	0.29	0.396	0.502

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
$h_1(x)$	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
$w_{2,i}$	0.072	0.072	0.072	0.072	0.072	0.072	0.167	0.167	0.167	0.072
$h_2(x)$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	-1
$w_{3,i}$	0.046	0.046	0.046	0.167	0.167	0.167	0.106	0.106	0.106	0.046

得到

$$h_3(x) = \begin{cases} -1, x < 6.5 \\ +1, x > 6.5 \end{cases}$$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1

$$h_1(x) = \begin{cases} +1, x < 3.5 \\ -1, x > 3.5 \end{cases} \quad h_2(x) = \begin{cases} +1, x < 9.5 \\ -1, x > 9.5 \end{cases} \quad h_3(x) = \begin{cases} -1, x < 6.5 \\ +1, x > 6.5 \end{cases}$$

计算过程中可以算出基模型的权重 $\alpha_1, \alpha_2, \alpha_3$，得到 AdaBoost 集成模型

$$H(x) = \text{sign}\Big(0.4236h_1(x) + 0.6496h_2(x) + 0.7514h_3(x)\Big)$$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$H(x)$	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1

$H(1) = \text{sign}(0.4326 + 0.6496 - 0.7541) = +1$
$H(2) = \text{sign}(0.4326 + 0.6496 - 0.7541) = +1$
$H(3) = \text{sign}(0.4326 + 0.6496 - 0.7541) = +1$
$H(4) = \text{sign}(-0.4326 + 0.6496 - 0.7541) = -1$
$H(5) = \text{sign}(-0.4326 + 0.6496 - 0.7541) = -1$
$H(6) = \text{sign}(-0.4326 + 0.6496 - 0.7541) = -1$
$H(7) = \text{sign}(-0.4326 + 0.6496 + 0.7541) = +1$
$H(8) = \text{sign}(-0.4326 + 0.6496 + 0.7541) = +1$
$H(9) = \text{sign}(-0.4326 + 0.6496 + 0.7541) = +1$
$H(10) = \text{sign}(-0.4326 - 0.6496 + 0.7541) = -1$

AdaBoost 集成模型错误率为 0。

1. 提升集成方法：AdaBoost

假设求解二分类问题，标签为 $\{-1,+1\}$。AdaBoost 集成模型

$$H(\boldsymbol{x}) = \sum_{t=1}^{T} \alpha_t h_t(\boldsymbol{x})$$

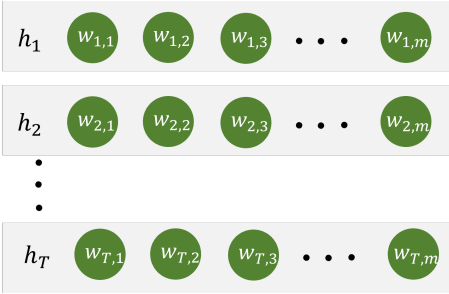

1. 每个基模型 $h_t(\boldsymbol{x})$ 训练时，每个训练样本 $w_{t,i}$ 权重也不相同。
2. 每个基模型 $h_t(\boldsymbol{x})$ 集成时，权重 α_t $(t=1,2,\cdots,T)$ 不同。

1. 提升集成方法：AdaBoost

错误率

$$e = \frac{1}{m}\sum_{i=1}^{m}\mathbb{I}\left(h(\boldsymbol{x}_i) \neq y_i\right)$$

带权重错误率

$$e = \sum_{i=1}^{m} w_i \mathbb{I}\left(h(\boldsymbol{x}_i) \neq y_i\right), \quad \sum_{i=1}^{m} w_i = 1$$

指数损失函数

$$Loss = \sum_{i=1}^{m} \exp\left(-y_i h(\boldsymbol{x}_i)\right)$$

带权重指数损失函数

$$Loss = \sum_{i=1}^{m} w_i \exp\left(-y_i h(\boldsymbol{x}_i)\right), \quad \sum_{i=1}^{m} w_i = 1$$

1. 提升集成方法：AdaBoost

$$H(\boldsymbol{x}) = \sum_{t=1}^{T} \alpha_t h_t(\boldsymbol{x})$$

第 t 个集成模型 $$H_t(\boldsymbol{x}) = H_{t-1}(\boldsymbol{x}) + \alpha_t h_t(\boldsymbol{x})$$

第 t 个集成模型指数损失函数

$$Loss = \sum_{i=1}^{m} \exp\left\{-y_i\left[H_{t-1}(\boldsymbol{x}_i) + \alpha_t h_t(\boldsymbol{x}_i)\right]\right\}$$

$$Loss = \sum_{i=1}^{m} \exp\left(-y_i H_{t-1}(\boldsymbol{x}_i)\right) \exp\left(-y_i \alpha_t h_t(\boldsymbol{x}_i)\right)$$

令 $w_{t,i} = \exp\left(-y_i H_{t-1}(\boldsymbol{x}_i)\right)$，可得

$$Loss = \sum_{i=1}^{m} w_{t,i} \exp\left(-\alpha_t y_i h_t(\boldsymbol{x}_i)\right)$$

1. 提升集成方法：AdaBoost

带权重指数损失函数

$$Loss = \sum_{i=1}^{m} w_{t,i} \exp\left(-\alpha_t y_i h_t(\boldsymbol{x}_i)\right)$$

训练样本能被基模型 $h_t(\boldsymbol{x}_i)$ 正确分类 $y_i h_t(\boldsymbol{x}_i) = 1$ 和不能正确分类 $y_i h_t(\boldsymbol{x}_i) = -1$

$$Loss = \sum_{y_i = h_t(\boldsymbol{x}_i)} w_{t,i} \exp\left(-\alpha_t\right) + \sum_{y_i \neq h_t(\boldsymbol{x}_i)} w_{t,i} \exp\left(\alpha_t\right)$$

梯度与驻点的关系

$$\frac{\partial Loss}{\partial \alpha_t} = -\sum_{y_i = h_t(\boldsymbol{x}_i)} w_{t,i} \exp\left(-\alpha_t\right) + \sum_{y_i \neq h_t(\boldsymbol{x}_i)} w_{t,i} \exp\left(\alpha_t\right) = 0$$

$$\alpha_t = \frac{1}{2} \ln\left(\frac{\sum_{y_i = h_t(\boldsymbol{x}_i)} w_{t,i}}{\sum_{y_i \neq h_t(\boldsymbol{x}_i)} w_{t,i}}\right) = \frac{1}{2} \ln\left(\frac{1-e}{e}\right)$$

1. 提升集成方法：AdaBoost

样本权重

$$w_{t,i} = \exp\left[-y_i H_{t-1}(\boldsymbol{x}_i)\right]$$

$$\begin{aligned}
w_{t+1,i} &= \exp\left[-y_i H_t(\boldsymbol{x}_i)\right] \\
&= \exp\left[-y_i\big(H_{t-1}(\boldsymbol{x}_i) + \alpha_t h_t(\boldsymbol{x}_i)\big)\right] \\
&= \exp\left[-y_i H_{t-1}(\boldsymbol{x}_i)\right] \exp\left[-y_i \alpha_t h_t(\boldsymbol{x}_i)\right] \\
&= w_{t,i} \exp\left[-y_i \alpha_t h_t(\boldsymbol{x}_i)\right]
\end{aligned}$$

$$w_{t+1,i} = \frac{w_{t+1,i}}{\sum_{i=1}^{m} w_{t+1,i}}$$

1. 提升集成方法：AdaBoost

Algorithm 1 AdaBoost 集成方法

初始化样本权重 $w_{1,i} = \frac{1}{m}$，$i = 1, 2, \cdots, m$

for $t = 1$ to T **do**

  以 $w_{t,i}, i = 1, 2, \cdots, m$ 为样本权重训练基分类器 $h_t(\boldsymbol{x})$

  计算基分类器带权重错误率 $e = \sum_{y_i \neq h_t(\boldsymbol{x}_i)} w_{t,i}$

  计算基分类器权重 $\alpha_t = \frac{1}{2} \ln \left(\frac{1-e}{e} \right)$

  更新样本权重并归一化 $w_{t+1,i} = w_{t,i} \exp\left(-y_i \alpha_t h_t(\boldsymbol{x_i})\right), w_{t+1,i} = \frac{w_{t+1,i}}{\sum_{i=1}^{m} w_{t+1,i}}$

end for

输出集成模型 $H(\boldsymbol{x}) = \sum_{t=1}^{T} \alpha_t h_t(\boldsymbol{x})$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1

(1) 以带权样本训练分类器 $h_1(x) = \begin{cases} +1, x < 3.5 \\ -1, x > 3.5 \end{cases}$

(2) 计算 $h_1(x)$ 带权错误率 $e = \sum\limits_{y_i \neq h_t(\boldsymbol{x}_i)} w_{t,i} = 0.3$

(3) 计算基分类器权重 $\alpha_1 = \dfrac{1}{2} \ln \left(\dfrac{1-e}{e} \right) = 0.4326$

(4) 更新样本权重并归一化得到 $w_{2,i} = w_{1,i} \exp\left(-y_i \alpha_1 h_1(\boldsymbol{x_i})\right), w_{2,i} = \dfrac{w_{2,i}}{\sum_{i=1}^{m} w_{2,i}} (i = 1, 2, \cdots, 10)$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
$h_1(x)$	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
$w_{2,i}$	0.072	0.072	0.072	0.072	0.072	0.072	0.167	0.167	0.167	0.072

(1) 以带权样本训练分类器 $h_2(x) = \begin{cases} +1, x < 9.5 \\ -1, x > 9.5 \end{cases}$

(2) 计算 $h_2(x)$ 带权错误率 $e = \sum\limits_{y_i \neq h_t(\boldsymbol{x}_i)} w_{t,i} = 0.216$

(3) 计算基分类器权重 $\alpha_2 = \dfrac{1}{2} \ln \left(\dfrac{1-e}{e} \right) = 0.6496$

(4) 更新样本权重并归一化得到 $w_{3,i} = w_{2,i} \exp\left(-y_i \alpha_2 h_2(\boldsymbol{x_i})\right), w_{3,i} = \dfrac{w_{3,i}}{\sum_{i=1}^{m} w_{3,i}} (i = 1, 2, \cdots, 10)$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
$h_1(x)$	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
$w_{2,i}$	0.072	0.072	0.072	0.072	0.072	0.072	0.167	0.167	0.167	0.072
$h_2(x)$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	-1
$w_{3,i}$	0.046	0.046	0.046	0.167	0.167	0.167	0.106	0.106	0.106	0.046

(1) 以带权样本训练分类器 $h_3(x) = \begin{cases} -1, x < 6.5 \\ +1, x > 6.5 \end{cases}$

(2) 计算 $h_3(x)$ 带权错误率 $e = \sum\limits_{y_i \neq h_t(\boldsymbol{x}_i)} w_{t,i} = 0.184$

(3) 计算基分类器权重 $\alpha_3 = \dfrac{1}{2} \ln \left(\dfrac{1-e}{e} \right) = 0.7514$

(4) 更新样本权重并归一化得到 $w_{4,i} = w_{3,i} \exp\left(-y_i \alpha_3 h_3(\boldsymbol{x_i})\right), w_{4,i} = \dfrac{w_{4,i}}{\sum_{i=1}^{m} w_{4,i}}$

1. 提升集成方法：AdaBoost

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
$w_{1,i}$	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
$h_1(x)$	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
$w_{2,i}$	0.072	0.072	0.072	0.072	0.072	0.072	0.167	0.167	0.167	0.072
$h_2(x)$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	-1
$w_{3,i}$	0.046	0.046	0.046	0.167	0.167	0.167	0.106	0.106	0.106	0.046

$$h_1(x) = \begin{cases} +1, x < 3.5 \\ -1, x > 3.5 \end{cases} \qquad h_2(x) = \begin{cases} +1, x < 9.5 \\ -1, x > 9.5 \end{cases} \qquad h_3(x) = \begin{cases} -1, x < 6.5 \\ +1, x > 6.5 \end{cases}$$

$$H(x) = \text{sign}\Big(0.4236h_1(x) + 0.6496h_2(x) + 0.7514h_3(x)\Big)$$

2. 自助集成方法：Bootstrap Aggregating, Bagging

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1

假设基分类器为 $h(x)=\begin{cases}+1, x<v\\-1, x>v\end{cases}$ 或者 $h(x)=\begin{cases}-1, x<v\\+1, x>v\end{cases}$，其中 $v=\{1.5, 2.5, \cdots, 9.5\}$ 是分类器参数。现用自助采样的方法获得三组训练数据集

$$D_1=\{(2,+1),(3,+1),(5,-1),(6,-1),(9,+1),(10,-1)\}$$
$$D_2=\{(1,+1),(2,+1),(3,+1),(4,-1),(8,+1),(9,+1),(10,-1)\}$$
$$D_3=\{(1,+1),(5,-1),(6,-1),(7,+1),(8,+1),(9,+1)\}$$

试用 D_1、D_2、D_3 训练得到三个基模型 $h_1(x)$、$h_2(x)$、$h_3(x)$。

2. 自助集成方法：Bootstrap Aggregating, Bagging

数据集 $D_1 = \{(2,+1),(3,+1),(5,-1),(6,-1),(9,+1),(10,-1)\}$

x	2	3	5	6	9	10
y	$+1$	$+1$	-1	-1	$+1$	-1

训练模型

$x < v$ 为 $+1$	v	2.5	3.5	5.5	6.5	9.5
	错误率	$\frac{2}{6}$	$\mathbf{\frac{1}{6}}$	$\frac{2}{6}$	$\frac{3}{6}$	$\frac{2}{6}$
$x < v$ 为 -1	v	2.5	3.5	5.5	6.5	9.5
	错误率	$\frac{4}{6}$	$\frac{5}{6}$	$\frac{4}{6}$	$\frac{3}{6}$	$\frac{4}{6}$

得到

$$h_1(x) = \begin{cases} +1, x < 3.5 \\ -1, x > 3.5 \end{cases}$$

2. 自助集成方法：Bootstrap Aggregating, Bagging

数据集 $D_2 = \{(1,+1),(2,+1),(3,+1),(4,-1),(8,+1),(9,+1),(10,-1)\}$

x	1	2	3	4	8	9	10
y	$+1$	$+1$	$+1$	-1	$+1$	$+1$	-1

训练模型

$x < v$ 为 $+1$	v	1.5	2.5	3.5	4.5	8.5	9.5
	错误率	$\frac{4}{7}$	$\frac{3}{7}$	$\frac{2}{7}$	$\frac{3}{7}$	$\frac{2}{7}$	$\mathbf{\frac{1}{7}}$
$x < v$ 为 -1	v	1.5	2.5	3.5	4.5	8.5	9.5
	错误率	$\frac{3}{7}$	$\frac{4}{7}$	$\frac{5}{7}$	$\frac{4}{7}$	$\frac{5}{7}$	$\frac{6}{7}$

得到

$$h_2(x) = \begin{cases} +1, x < 9.5 \\ -1, x > 9.5 \end{cases}$$

2. 自助集成方法：Bootstrap Aggregating, Bagging

数据集 $D_3 = \{(1,+1),(5,-1),(6,-1),(7,+1),(8,+1),(9,+1)\}$

x	1	5	6	7	8	9
y	$+1$	-1	-1	$+1$	$+1$	$+1$

训练模型

$x < v$ 为 $+1$	v	1.5	5.5	6.5	7.5	8.5
	错误率	$\frac{3}{6}$	$\frac{4}{6}$	$\frac{5}{6}$	$\frac{4}{6}$	$\frac{3}{6}$
$x < v$ 为 -1	v	1.5	5.5	6.5	7.5	8.5
	错误率	$\frac{3}{6}$	$\frac{2}{6}$	$\boldsymbol{\frac{1}{6}}$	$\frac{2}{6}$	$\frac{3}{6}$

得到

$$h_3(x) = \begin{cases} -1, x < 6.5 \\ +1, x > 6.5 \end{cases}$$

2. 自助集成方法：Bootstrap Aggregating, Bagging

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1

根据 D_1、D_2、D_3 训练得到基分类器

$$h_1(x) = \begin{cases} +1, x < 3.5 \\ -1, x > 3.5 \end{cases} \quad h_2(x) = \begin{cases} +1, x < 9.5 \\ -1, x > 9.5 \end{cases} \quad h_3(x) = \begin{cases} -1, x < 6.5 \\ +1, x > 6.5 \end{cases}$$

2. 自助集成方法：Bootstrap Aggregating, Bagging

根据 D_1、D_2、D_3 训练得到基分类器

$$h_1(x) = \begin{cases} +1, x < 3.5 \\ -1, x > 3.5 \end{cases} \quad h_2(x) = \begin{cases} +1, x < 9.5 \\ -1, x > 9.5 \end{cases} \quad h_3(x) = \begin{cases} -1, x < 6.5 \\ +1, x > 6.5 \end{cases}$$

x	1	2	3	4	5	6	7	8	9	10
y	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1
h_1	$+1$	$+1$	$+1$	-1	-1	-1	-1	-1	-1	-1
h_2	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	$+1$	-1
h_3	-1	-1	-1	-1	-1	-1	$+1$	$+1$	$+1$	$+1$
H	$+1$	$+1$	$+1$	-1	-1	-1	$+1$	$+1$	$+1$	-1

2. 自助集成方法：Bootstrap Aggregating, Bagging

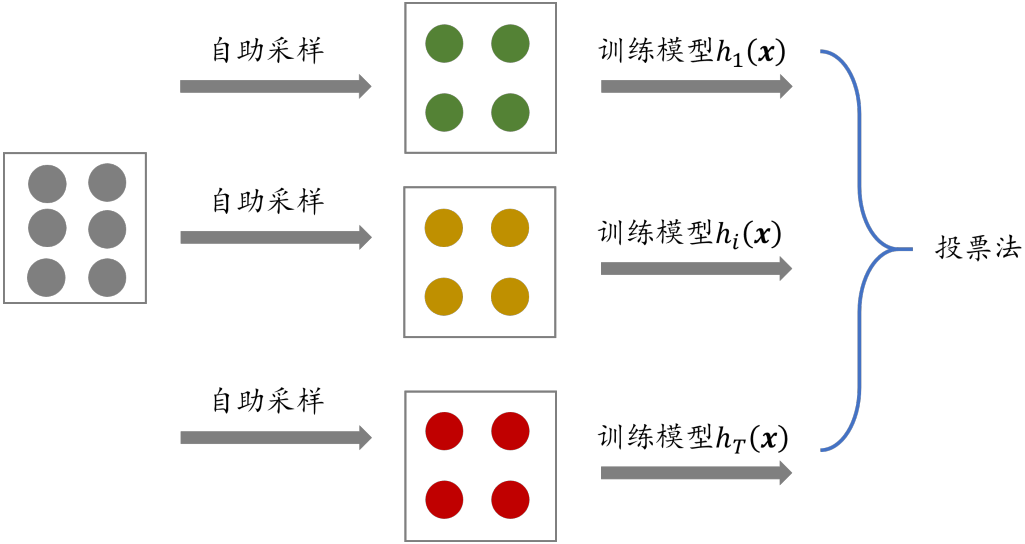

2. 自助集成方法：算法框架

Algorithm 2 自助采样集成方法

1: **for** $t = 1$ to T **do**
2: 　从原始数据集 $\mathcal{D}$ 自助采样得到 $\mathcal{D}_t$
3: 　在数据集 $\mathcal{D}_t$ 上训练模型 $h_t(\boldsymbol{x})$
4: **end for**
5: 输出集成模型 $H(\boldsymbol{x}) = \underset{1 \le i \le k}{\arg\max} \sum_{t=1}^{T} \mathbb{I}\left(h_t(\boldsymbol{x}) == c_i\right)$

- 自助采样得到不同的数据集，可以增加基模型的多样性。
- 36.79% 未被采样的样本可以用于基模型调参。

2. 自助集成方法：自助采样

从 m 个样本中有放回地重复抽取 m 次。一个样本被抽到的概率为 $\frac{1}{m}$，不被抽到的概率为 $1-\frac{1}{m}$。重复抽取 m 次该样本没被抽到的概率为

$$P=\left(1-\frac{1}{m}\right)^m$$

$$m=10,\quad P=\left(1-\frac{1}{m}\right)^m=0.3487$$

$$m=100,\quad P=\left(1-\frac{1}{m}\right)^m=0.3660$$

$$m=1000,\quad P=\left(1-\frac{1}{m}\right)^m=0.3677$$

$$m\to\infty,\quad P=\left(1-\frac{1}{m}\right)^m\to 0.3679$$

2. 自助集成方法：Random Forest 随机森林

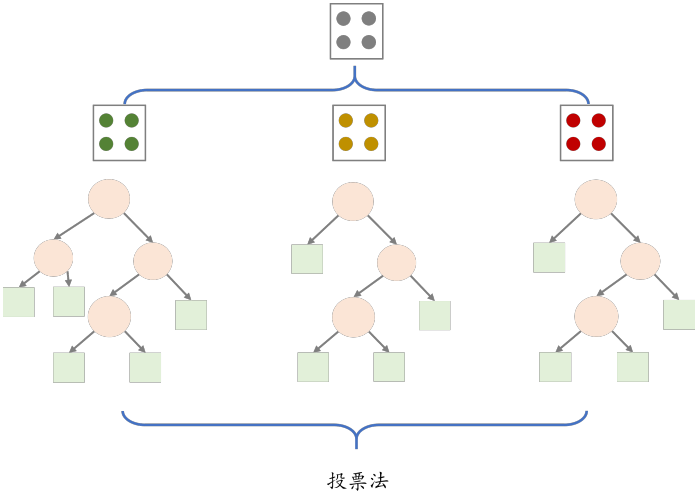

- 基模型采用决策树。
- 引入随机选取属性子集策略。从 k（$k < d$）个随机属性中选取最优属性进行划分。

3. 提升集成方法与自助集成方法比较：Boosting v.s Bagging

集成策略	Boosting	Bagging
基模型多样性策略	样本赋不同权重	采用不同训练集
基模型训练集	所有样本	部分样本
样本权重	不同	相同
基模型权重	不同	相同
集成策略	加权法	投票法
串并行训练	串行	并行
减少误差	减少偏差	减少方差